

Skew-Aware Stratified Sampling for Vector-Augmented Analytical Query

벡터 카디널리티 추정에서 distribution-aware stratified sampling 의 정량적 가치

TEAM

속도는벡터

박세은 · 강재현 · 조현빈 · 이동욱

ADVISOR

박광현 교수

BDAI Research Lab

REFERENCE

arXiv:2512.09695v2

Exqutor (BDAI)

DATE

2026.05.27

Final Presentation

01

Problem

문제 정의

02

Prior Work

Exqutor 보완책

03

Approach

Skew-Aware Sampling

04

RQ1 · Diagnostic

단조성 통계 확정

05

RQ2 · Aware

40 / 40 oracle

06

RQ3 · Agnostic

22 method 비교

07

Cross-Scale

1M → 8M

08

Mechanism

locality + redundancy

09

Effect Honesty

DEFF · ESS · routing

10

Future Work

L1 ~ L4

기존 시스템의 고정 비율 추정

PGVECTOR

33.3%

fixed ratio

VBASE

50.0%

fixed ratio

DUCKDB

100%

fixed ratio

세 시스템 모두 query별 selectivity 분포를 단일 비율로 처리.
정확도와 안정성을 동시에 잃는다.

실제 SELECTIVITY 분포

0.001 ~ 90 %

- 5 orders of magnitude 광범위 분포
- query마다 분포가 다르다
- 고정 비율은 underestimate / overestimate 동시 발생

PGVECTOR

1000×

plan cost gap

VBASE

10000×

plan cost gap

DUCKDB

1.5-37×

plan cost gap

02 이전 연구 — Exqutor의 두 보완책

ECQO · ADAPTIVE SAMPLING

속도는벡터 · STYLE A · ACADEMIC

04 / 18

A ECQO

빠른 카디널리티 견적

HNSW 보조 인덱스로 1~2 ms 안에 견적 — 옵티마이저 비용 추정 시점에 사용 가능.

1-2_{MS}

B ADAPTIVE SAMPLING

균등 sampling 비용 절감

모멘텀 기반 동적 비율 — Sequential Scan 비용을 1000배 낮춤.

1000_x

그러나 시스템별 PLAN COST GAP 은 여전히 크다 (논문 보고)

PGVECTOR

1,000x

VBASE

10,000x

DUCKDB

1.5-37x

→ 비용 절감만으로는 부족 — 분포 인지 자체의 가치를 따로 정량화해야 한다.

RQ1

Diagnostic

Skew가 추정 오차에 영향을 주는가?

→ 단조성 통계 확정

RQ2

Aware

분포를 알 때 어떤 분할이 최적인가?

→ 40 / 40 cells (oracle)

RQ3

Agnostic

분포를 모를 때 채택 가능한 방법은?

→ 22 / 16 method

SPEARMAN P · DEEP-KM20

-0.680

Phase 6 (SQL D, vector.c hook, production-near)

95% CI

[-0.800, -0.440]

0 제외 ✓

SIFT-KM20


 $\rho = -0.140$

[-0.220, -0.100]

n = 5 seeds × 6 selectivity bins

Phase 7 (numpy D, simulation): $\rho = +0.240$ [-0.061, +0.480] CI 0 포함 —

measurement methodology robustness sub-contribution 별도 정직 보고



→ BERN은 selectivity가 높을수록 더 부정확 — 그래디언트 단조적으로 확정.

40/40

cells: KM20 > BERN

ANTI-NEYMAN COUNTERFACTUAL

+5.21%

DEEP [+1.36, +9.16]

+9.49%

SIFT [+4.66, +11.75]

둘 다 CI 0 제외

KM20 ADVANTAGE · 8 SIZES × 5 ALLOCATIONS

	50	100	200	400	600	800	1000	1500
equal	✓	✓	✓	✓	✓	✓	✓	✓
prop	✓	✓	✓	✓	✓	✓	✓	✓
neyman	✓	✓	✓	✓	✓	✓	✓	✓
opt	✓	✓	✓	✓	✓	✓	✓	✓
kde	✓	✓	✓	✓	✓	✓	✓	✓


each cell = 5 seeds · paired test · ✓ = KM20 win

06 RQ3 — Distribution-agnostic (22 method)

EFFECT SIZE · COHEN'S D

속도는벡터 · STYLE A · ACADEMIC

08 / 18



→ 4 method (Hilbert · MiniBatch · Hybrid · HDBSCAN) paired CI 0 제외 — 분포 모르는 상황의 실용 alternative.



Contribution 1 — Hilbert Curve

LEARNING-FREE · 1ST RANK · $P < 0.01$

속도는벡터 · STYLE A · ACADEMIC

09 / 18

COHEN'S D · HILBERT VS BERN

-0.156

★★ $p < 0.01$ paired bootstrap CI excludes 0

- 학습 비용 0 · deployment cost 0
- distribution-aware 효과의 대부분 확보

TWO CURVES · INVERSE MANHATTAN

1.000 vs **1.992**
HILBERT Z-ORDER

STRATUM COMPACTNESS GAIN

1.25x **2.54x**
DEEP_1M SIFT_1.5M

RANK · LEARNING-FREE METHODS

#1 of 22

→ Hilbert는 학습 비용 0, deployment cost 0으로 distribution-aware 효과의 대부분을 확보.



Contribution 2 — MiniBatch K-means

PRODUCTION-READY · N = 1M

속도는벡터 · STYLE A · ACADEMIC

10 / 18

SPEEDUP · VS FULL K-MEANS


1,189_x

partial_fit ARI = 1.000

= identical clustering output

- 정확도 손실 없이 학습 비용 세 자리수 이상 절감
- production drop-in 교체 가능

TRAINING TIME · LOG SCALE



SAME ACCURACY · 1000_x CHEAPER

→ SAME ACCURACY · 1000_x CHEAPER — production drop-in 교체 가능.



Contribution 3 — Negative Control

HURT-MEDIUM · PQ · SOBOL · IS

속도는벡터 · STYLE A · ACADEMIC

11 / 18

COHEN'S D (MEAN) · HURT


+0.7

hurt-medium effect

분할이 항상 도움이 되는 것은 아니다.

적절한 분할만이 효과를 만들고, 그렇지 않은 분할은 분산을 키운다.

POSITIVE D = DEGRADED ESTIMATION



→ 분할이 항상 도움 되는 것은 아니다 — 적절한 분할만이 효과.



RQ3 핵심 contribution 5: HDBSCAN — Density-Based Clustering 의 가치

SIFT MID-SEL · #1 OF 22 · DENSITY-BASED

속도는벡터 · STYLE A · ACADEMIC

12 / 18

Δ Q-ERROR · SIFT MID-SEL (S=0.10)

-3.99%

95% CI [-5.34, -2.12]

paired bootstrap · 0 제외 ✓

★ #1 of 22 method

SIFT high-skew

DENSITY-BASED 의 이점

- SIFT 의 더 큰 skew 환경에서 mid-sel 가장 강한 effect
- oracle (KM20) 에 근접한 효과를 분포 모르고 달성

MID-SEL SWEET SPOT

1%

너무 좁음 / noise

10%

SWEET SPOT

50%

너무 넓음 / 약화

4강 마지막 핵심

Hilbert · MiniBatch · Hybrid · HDBSCAN

→ Density 인식 분할이 high-skew 환경의 mid-sel 에서 oracle 에 근접한 효과.

	BERN	RAND20	PCA	Z-ord	Hilb	PQ	KD	Hyb	HDBS	Minib	KM20	DShl	IS-l	IS-h	Sob	Halt
DEEP_1M	0.00	-0.04	-0.07	-0.09	-0.16	0.18	-0.10	-0.16	-0.19	-0.18	-0.20	0.49	0.50	0.70	0.22	0.18
DEEP_8M	-0.02	-0.04	-0.05	-0.10	-0.15	0.16	-0.10	-0.14	-0.20	-0.17	-0.22	0.49	0.52	0.69	0.23	0.16

RANKING 일관성

4강 — Hilbert · MiniBatch · Hybrid · HDBSCAN — 1M 과 8M 모두 상위 유지.

DEEP_8M MID-SEL

증 0 / 감 2 (n=3) — 1M 의 단조성이 자동 이전되지 않음. sample_size=385 한계

LOCALITY (INVERSE MANHATTAN)

1.000 vs **1.992**

HILBERT

Z-ORDER

거리 보존이 effect size로 직접 연결 — stratum compactness **1.25x ~ 2.54x**.

ARI · 4 OFFLINE METHOD

	Hilbert	KM20	MiniBatch	HDBSCAN
Hilbert	1.00	0.74	0.73	0.62
KM20	0.74	1.00	1.00	0.71
MiniBatch	0.73	1.00	1.00	0.70
HDBSCAN	0.62	0.71	0.70	1.00

KM20 ↔ MiniBatch **ARI = 1.00** — 동일 신호, 다른 비용.

HILBERT · ESS / SRS-EQUIVALENT

6x

SRS effective sample

DEFF

0.338


ESS

2,325

MEAN D

≈ 0.3

Q4_HARD · SPREAD VS DIFFICULTY

**p = 0.78**

per-query routing — 어려운 query에서 spread 강한 양의 상관

L1 OPEN

Single-table only

multi-table은 Exqutor main scope. 단일 정확성이 multi의 필요 조건 (future work).

L2 OPEN

KM20 oracle 학습 부담

full K-means ~30분. partial_fit (OLTP) + Hilbert (learning-free) 가 production replacement.

L3 OPEN

Effect size practical small

모든 RQ3 method $|d| < 0.8$. 어려운 query routing 가치 (spread $\rho = 0.78$).

L4 OPEN

numpy estimator scope

$\leq 10K$ row 캐시 + HT weight만 $N=1M$. 절대 q-error 인용 시 명시, 상대 비교 보존.

L5 OPEN

RQ1 measurement robustness

Phase 6 (SQL D, vector.c) vs Phase 7 (numpy D) 5-cell 격차. 핵심 수치 Phase 6 기준.

L6 OPEN

 σ_i 신호 약함 honest 입증

Anti-Neyman vs Proportional CI 0 제외, paired Wilcoxon $p > 0.5$, $d < 0.1$. Agnostic 추구의 motivation.

예상 질문 — Q & A Anticipated

6 ANTICIPATED QUESTIONS

속도는벡터 · STYLE A · ACADEMIC

17 / 18

Q1

왜 Hilbert curve가 PCA-1D보다 좋은가?

1D-2D continuity — inverse Manhattan 1.000 vs 1.992. Hilbert는 거리 보존이 완벽, PCA는 분산 축 1개로 압축하며 stratum 단위 compactness 손실.

Q2

Effect size가 작은데 contribution 인정?

practical small이지만 어려운 query 군 (Q4_hard)에서 spread vs difficulty $\rho=0.78$. cluster method = production per-query routing 가치.

Q3

Multi-table 일반화는?

단일 정확성이 multi의 필요조건. multi 일반화 future work — Exqutor multi-relation framework 결합.

Q4

vector.c integration 안 한 이유?

5/6 시도 → memory leak. Python 시뮬레이션으로 본질 검증. integration future work, 5/8 채림 석사 자문 예정.

Q5

산업 표준 (FAISS) 와 비교?

PQ 측정 ready. 결과 기반 5/27 보강. 현 deck은 stratification gain 자체에 집중.

Q6

Phase 6 vs Phase 7 격차의 origin은?

(1) numpy estimator는 $\leq 10K$ row 캐시 + HT weight만 $N=1M$ — sampling-population scope가 SQL tablesample과 다름. (2) vector.c hook의 production env 측정 path가 numpy 시뮬레이션과 다름. Phase 6 production-near 핵심 인용, Phase 7 honest 별도 보고. 5-cell 격차를 measurement methodology robustness sub-contribution으로 격상. 5/15 채림 석사 자문 메일.

감사합니다.

Q & A

GITHUB

github.com/johyunbin/Capstone

REFERENCE

[arXiv:2512.09695v2](https://arxiv.org/abs/2512.09695v2)

Exqutor (BDAI)