

속도는벡터 — RQ1·RQ2 실험 결과 정리

작성: 조현빈 · 2026-05-06 21:45 KST **대상:** 박세은 · 강재현 · 이동욱 **범위:** 5/5 RQ 재정립 회의 후 진행한 RQ1·RQ2 실험 결과 — 처음 보는 사람도 이해 가능한 수준으로 정리 **참고:** RQ3 측정은 별도 세션에서 진행 중, 별도 자료로 공유 예정

0. 큰 그림 — 새 RQ 구조 (5/5 회의에서 결정)

박세은 팀장 제안으로 연구 질문 3가지 재정립. 본 자료는 그중 RQ1·RQ2 결과만.

RQ	한 줄 질문
RQ1	기존 random sampling 이 skew (한쪽으로 쏠린) 데이터에서 얼마나 부정확한가?
RQ2	데이터 분포를 미리 알 때 어떤 sampling 방식이 가장 정확한가?
RQ3	데이터 분포를 모를 때 어떤 sampling 방식이 가장 정확한가? (별도 자료)

알아두면 좋은 용어 (자주 등장)

용어	의미
selectivity (sel)	쿼리 조건에 맞는 행이 전체의 몇 % 인지 (예: 0.01 = 1%)
q_error	추정한 행 수와 실제 행 수의 비율. 1.0 이면 완벽, 클수록 부정확
BERN (BERNOULLI)	행 단위 무작위 추출 (각 행을 독립적으로 선택)
SYSTEM	디스크 블록 단위 추출 (블록 안 행들이 묶여서 선택됨)
KM20	K-means 알고리즘으로 데이터를 20개 클러스터로 사전 분할
RANDOM20	데이터를 20개로 무작위 분할 (공간 구조 무시)
Stratified sampling	그룹별로 일정 비율씩 추출하는 층화 추출

1. RQ1 — random sampling 이 skew 데이터에서 얼마나 부정확?

(a) 동기 — 왜 이 실험을?

벡터 데이터베이스는 쿼리 실행 전에 "이 조건에 맞는 행이 대략 몇 개일까?" 를 추정한다. 이 추정이 정확해야 좋은 실행 계획을 세울 수 있다. Exqutor 는 이 추정을 위해 데이터의 일부를 무작위로 뽑아보는 sampling 방식을 사용한다.

문제는 데이터가 한쪽에 쏠려 있을 때 (skew) random sampling 이 제대로 작동하는가? 이다. SIFT 데이터셋은 DEEP 보다 더 쏠려 있는데 (HHI 0.058 vs 0.053, CV 0.394 vs 0.234, 약 1.7배 더 skew), 이 차이가 sampling 부정확성에 어떻게 나타나는지 정량 측정이 필요했다.

(b) 가설 (H1)

데이터가 더 skew 일수록 BLOCK 단위 sampling 의 q_error 가 ROW 단위보다 더 부정확해진다.

즉 SIFT (skew) 의 SYSTEM-BERN 격차 > DEEP (normal) 의 SYSTEM-BERN 격차.

(c) 예상 결과


- 모든 selectivity 에서 SIFT 의 격차가 DEEP 보다 클 것
- 좁은 sel (1%) 에서 가장 큰 격차 — sampling 부정확성이 좁은 영역에서 증폭

(d) 실제 결과

SYSTEM-BERN 격차 (BLOCK 단위가 ROW 단위보다 얼마나 더 부정확?)

sel	DEEP (normal)	SIFT (skew)	격차 (SIFT - DEEP)
0.01 (1%)	+4.66%	+10.27%	+5.61%p
0.05 (5%)	+12.61%	+17.32%	+4.71%p
0.10 (10%)	+14.76%	+16.68%	+1.92%p
0.30 (30%)	+14.05%	+14.85%	+0.80%p
0.50 (50%)	+12.59%	+14.36%	+1.77%p

→ 모든 selectivity 에서 SIFT 의 격차가 DEEP 보다 큼. 통계 검정 (paired Wilcoxon) $p \leq 1e-4 \sim 1e-49$, 다중 비교 보정 (BH-FDR) 후에도 유의성 유지.



KM20 vs RANDOM20 — "공간 구조를 아는 것" 의 가치 (DEEP 1M)

sel	KM20 개선	RANDOM20 개선	격차	해석
0.50 (50%)	+1.64%	+2.20%	~0	공간 구조 몰라도 비례 배분 효과만으로 OK
0.30	+2.62%	+0.26%	2.4%p	공간 구조의 효과 등장
0.10	+4.19%	+1.74%	2.5%p	공간 구조의 효과 증가
0.05	+1.85%	+0.79%	1.1%p	공간 구조 유지
0.01 (1%)	+8.93%	-10.67%	19.6%p	공간 구조 모르면 오히려 악화

→ 좁은 쿼리 ($s=1\%$) 에서 격차 19.6%p. 쿼리 범위가 좁아질수록 "데이터의 공간 구조를 아는 것" 이 점점 더 중요해짐.

의의

- H1 정량 입증 — skew 데이터일수록 random sampling 이 부정확하다는 사실 측정으로 증명
- Selectivity Gradient narrative 정립 — 쿼리 범위 좁아질수록 공간 인식의 가치 증가
- 박세은 팀장이 5/5 회의에서 제기한 "Normal vs Skew 직접 비교 부재" 의문을 정량 답변

- 4/30 중간발표 시점 부족했던 Cross-Dataset 비교를 W1 sprint 에서 완성

2. RQ2 — 분포 알 때 어떤 sampling 방식이 최적?

(a) 동기 — 왜 이 실험을?

RQ1 에서 KM20 (공간 구조 인식) 이 RANDOM20 (무작위 분할) 보다 우수함을 확인. 이제 KM20 위에 더 정교한 할당 (allocation) 방식을 적용할 수 있는지 검증.

기존 KM20 은 사실상 **Equal Allocation** (각 클러스터에 같은 수의 sample 배분)이었음. 통계학 정통은 **Neyman Allocation (1934)** 을 제안하는데, 이는 각 클러스터의 분산 (σ_i) 에 비례해서 배분하는 방법. "분산 큰 곳에 sample 더 많이" 가 핵심 아이디어.

(b) 가설 (H2)

(H2-N) Neyman Allocation 이 Equal Allocation 보다 q_{error} 가 작다 (variance-optimal 정리). (H2-AN) Anti-Neyman (분산 반비례) 은 Proportional 보다 q_{error} 가 크다 (ablation, 분산 비례 배분의 정당성).

(c) 예상 결과

- 모든 stratified > BERN baseline (이미 RQ1 에서 보인 패턴)
- Neyman > Proportional > Equal (정교할수록 우수)
- Anti-Neyman 은 Proportional 보다 나쁨 (반증 ablation)

(d) 실제 결과


5-mode 비교 — BERN baseline 대비 mean q_error 개선 (%)

Mode	DEEP $s=0.01$	DEEP $s=0.05$	SIFT $s=0.01$	SIFT $s=0.05$
Equal (KM20 base)	-0.83%	-8.15%	(+9.4% anomaly)	-6.55%
Proportional (N_i 비례)	-3.62%	-4.25%	-2.50%	-5.78%
Neyman ($N_i \times \sigma_i$ 비례)	-3.08%	-4.76%	-11.91% ★	-9.62% ★
Anti-Neyman (N_i / σ_i 비례)	(Prop 차이 X)	(차이 X)	-2.55%	(차이 X)

→ 모든 stratified 방식이 BERN 보다 우수 (DEEP -1.3~-7.0%, SIFT -3.7~-10.5%, $p \leq 1e-7$).

→ Neyman의 추가 가치는 SIFT × 좁은 sel에서만 강함 ($s=0.01$ 에서 -11.91%, BH-FDR 보정 후 $p_{BH} = 0.024$). DEEP에서는 통계적으로 유의하지 않음.

→ Anti-Neyman 가설 반증 — Proportional과 차이가 모든 case 통계 noise 안. 즉 σ_i (분산) 신호가 N_i (크기) 신호보다 약함. RQ3의 query-aware online σ 추정으로 미룸.



새 발견 — SIFT × Equal × $s=0.01$ anomaly

SIFT의 Equal Allocation q_error (1.85)가 BERN baseline (1.69)보다도 부정확. 이유: 클러스터 크기 변동이 큰 SIFT에서 균등 배분 (각 클러스터에 19 sample)이 큰 클러스터 (148K rows)에서 sample 부족 → 부정확. Proportional / Neyman이 이 문제를 해결.

→ "Equal은 normal 데이터엔 OK, skew에서는 Proportional 이상 필요" narrative의 직접 증거.

부수 — Sample size 영향력

Sample size 100~3000 (30 배 차이) × DEEP/SIFT × 5 sel = 40 조합 모두에서 KM20 > BERN 일관 (개선 -0.83 ~ -13.50%). 어떤 sample 예산에서도 KM20의 가치 robust하게 유지된다는 증거.

의의

- 모든 stratified 방식이 BERN 우수 — 공간 인식 sampling 의 근본적 가치 재확인
- Neyman 의 가치 영역 정량화 — SIFT × 좁은 sel 에서만 추가 가치, 다른 영역에서는 Proportional 로 충분
- Anti-Neyman 반증 — variance-optimal 의 정당성 ablation 으로 입증 시도했으나 σ 신호 약해 검출 안 됨
- SIFT × Equal anomaly 새 발견 — 클러스터 크기 변동이 큰 데이터에선 Equal 이 BERN 보다는 나쁨 (역설적)
- KM20 의 sample_size robustness — production 적용 시 비용 자유롭게 조정 가능 (cost-tunable)

3. 추가 작업 — DEEP 8M mid-selectivity 측정 (진행 중)

RQ1 의 Cross-Dataset 표가 DEEP 8M 에서만 비대칭이라 (1M/SIFT 5점 × 8M 3점) 외적 타당성 매듭을 위한 추가 측정.

데이터셋	1%	5%	10%	30%	50%
DEEP 1M	✓	✓	✓	✓	✓
SIFT 1.5M	✓	✓	✓	✓	✓
DEEP 8M	✓	✓	↻	↻	✓

DEEP 8M 의 10% / 30% selectivity 에서 SYSTEM·BERN·KM20 측정 진행 중 (5/6 KST 19:11~). 1M 에서 본 selectivity gradient 단조성이 8M 에서도 재현되는지가 외적 타당성의 핵심. ETA ~KST 24:00. 결과 받자마자 별도 카톡으로 공유.

4. 진행한 실험 종합 표

실험	RQ	dataset	측정 mode	rows	결과
실험 #1 — SIFT × SYSTEM baseline	RQ1	SIFT 1.5M	SYSTEM × 5 sel × 5 seed × 100 query	2,500	H1 정량 입증
실험 #2+#3 — 5-mode Allocation	RQ2	DEEP 1M + SIFT 1.5M	5 mode × 5 sel × 5 seed × 100 query	25,000	Neyman 부분 입증 / Anti-Neyman 반증
실험 #4 — Sample size sensitivity	RQ2	DEEP+SIFT	4 ssize × 5 sel × 5 seed × 100 query × 2 mode	40,000	KM20 robustness 입증
보강 — BH-FDR + figures + DEEP query difficulty	RQ1·RQ2	—	5 figures + 다중 비교 보정	—	모든 결과 BH-FDR 후에도 robust
추가 측정 (진행 중) — DEEP 8M mid-sel	RQ1	DEEP 8M	SYSTEM/BERN/KM20 × 2 sel × 5 seed × 100 query	3,000	외적 타당성 매듭 (KST 24:00 완료 예정)

자료 위치 (GitHub [johyunbin/Capstone](#)): - 측정 코드: [experiments/code/rq1/](#), [experiments/code/rq2/](#) - 결과: [experiments/results/rq1_motivation/](#), [experiments/results/rq2_aware/](#) - 시각화: [experiments/figures/rq1_rq2_w1_sprint/](#) (5 figures) - 통합 정리: [experiments/results/RQ1_RQ2 실험 결과 정리.md](#) - 새 RQ 구조: [plans/RQ재정립_20260505_2122.md](#)