

박광현 교수님 5/22 (목) 미팅 — 예상 질문 + 답변 가이드 (v11 framing)

이 자료의 목적: 박광현 교수님 5/22 미팅 (5/27 발표 D-5 시점 사전 review) 학술 review 자리에서 예상되는 질문과 답변 narrative 사전 준비. 박세은 / 강재현 / 이동욱 / 조현빈 모두 동일 깊이 답변 가능 수준 정리.

framing 기준: prompt v11 (5/16 00:50 작성) — "Distribution-aware Sample Selection for VAQ Cardinality Estimation". paper 영역 (cardinality 추정 mechanism 그대로) vs 우리 영역 (sample selection augment) 명확 분리.

작성: 2026-05-16 KST · v11 framing reframing + handoff v32 + narrative v5 + 측정 portfolio ~2039 file 종합.

1-page 요약 (under 250 words)

본 발표 영역 핵심 framing: "**Distribution-aware Sample Selection**" (prompt v11, 박세은 5/16 00:18 단순화 의도 반영). paper Exqutor §V-B Adaptive Sampling base 위 우리 영역 sample selection augment 한정. cardinality 추정 mechanism 자체는 paper 영역 그대로 유지, 우리 영역은 그 estimation 의 input 인 sample selection 영역만. layer 분리 (paper layer + 우리 layer + evidence) 일관 강조.

3 phase 흐름: Phase 1 분포 인지 stratification (offline) + Phase 2 sample 추출 (online) + Phase 3 결합 minimal (산술 평균 $\alpha=0.5$). 데이터셋 4 type 분류 (small single / medium single / large single / large multi 224-288d / large multi 864d) + Type 별 best sample selection method dynamic 자동 선택. 사용 16 method (Pareto Top 5 + paradigm rep 11) × 7 paradigm covering. 폐기 40 method narrative 미언급.

핵심 evidence: paired CaseB < B1 = **92.5%** (455/492, $p < 1e-45$) + Cliff's δ large better 63.0% + Hedges' g large 55.7% + one-sided $p < 0.05$ outperform 45.3%. Pareto Top 5 fit_time 11.9× range (sparse_rp 3.67s ~ hilbert_real 43.50s). Type 1 small sf=1 best chao_weighted $K=20$ -14.11% / Type 4b multi 864d best Centroid tuple -7.37%. selectivity-dependent paradox (sel=0.01 narrow σ_j) 정직 disclosure. 측정 portfolio = 약 2039 file (B1 9 + CaseB ~2030, REPORT v11 + chain v6-v9). 5/27 발표 D-5 시점 risk = chain 진행 의존 + 박광현 자문으로 mitigation.

A. v11 framing 변경 영역

Q1. v10 → v11 framing 변경 — 박세은 단순화 의도 + paper layer vs 우리 layer 명확 분리?

답변: 5/15 카톡 + 5/16 00:18 박세은 단순화 의도 정리에 따라 v10 → v11 framing reframing을 진행했습니다. 박세은의 핵심 통찰은 "우리는 추가 method 통해서 Q-error만 보완하면 되는 게 아니냐. 카디널리티 추정은 알아서 할거고"입니다. 이전 v10 framing이 "cardinality 추정"을 우리 contribution으로 혼재 표현한 부분을 정정하여, v11에서는 layer 분리를 명확히 합니다 — **paper 영역 (그대로 유지) = §V-A ECQO + §V-B Adaptive Eq 1-6 + cardinality 추정 mechanism 자체, 우리 영역 (sample selection augment) = Phase 1 분포 인지 stratification + Phase 2 sample 추출 + Phase 3 결합 minimal, evidence = "sample selection 영역 우리 method가 random Bernoulli 대비 Q-error paired Δ% 92.5% 개선"**. 이 분리가 학부 capstone 이론 검증 자세 일관성과 paper Exqutor 본인 contribution 인정 양면에서 정직합니다.

reference: [_internal/handoff/active/handoff_v31_5_16_세션마무리_chain진행중_20260516_0020.md](#) §2.2 박세은 framing 단순화 의도 + [submission/_drafts/속도는벡터_5_27_키노트_prompt_v11_part1_framing_20260516_0050.md](#) §0.1-0.3.

Q2. cardinality 추정 영역 paper 영역 → 우리 영역 sample selection 영역만 — narrative arc 정확하게?

답변: narrative arc 영역은 Phase 1+2+3로 명시됩니다. **Phase 1 (offline, 1회) = 분포 인지 stratification** — 데이터셋 진입 시 row 수 / structure / dimension 영역 profile + Type 판별 (Type 1/2/3/4a/4b 中 결정) + Type 별 best method 자동 선택 + K=20 stratum sample selection. **Phase 2 (online, 매 query) = sample 추출** — paper Eq 1 sample budget N=385 verbatim 그대로 + 각 stratum 비례 추출 + est_method 계산. **Phase 3 (online, 매 query) = 결합 minimal** — est_b1 (paper Bernoulli) + est_method (우리 sample selection) → est_final = (est_b1 + est_method) / 2.0 산술 평균 minimal augmentation + paper Adaptive Eq 1-6 보정 그대로 유지. 이 흐름에서 cardinality 추정 mechanism 자체 (Eq 2 estimator + Eq 3-6 momentum 보정)는 paper 영역에 100% 위임이며, 우리 contribution은 그 estimator의 input인 sample 영역의 quality 개선 한정입니다.

reference: [submission/_drafts/속도는벡터_5_27_키노트_prompt_v11_part1_framing_20260516_0050.md](#) §5 slide 5 우리 영역 3 phase 흐름 + [submission/_drafts/속도는벡터_본연구_narrative_최종정리_v5_draft.md](#) §0 main theme 영역.

B. 측정 portfolio + dynamic 할당 영역

Q3. Pareto Top 5 + paradigm rep 11 = 16 method 영역 dynamic 할당 영역 evidence 충분?

답변: 측정 portfolio = 약 2039 file (B1 대조군 9 + CaseB 실험군 약 2030, REPORT v11 691 file + chain v6-v9 1348 file). 사용 16 method = Pareto Top 5 (sparse_rp / chao_weighted / hyperloglog / pca1d / hilbert_real) + paradigm rep 11 (P1 minibatch_partial / gmm / faiss_ivf, P2 zorder_morton / skilling_hilbert, P4 rsvd / ica_fastica, P5 cum_sqrtf / lavallee_hidirolou, P6 rabbitq_strat / mhist2). 7 paradigm covering 영역 = Cluster (3) + Spatial (3) + Streaming (1) + DimReduction (4) + QMC (2) + Quantization (2) + InfoTheoretic (1). dynamic 할당 evidence는 cell × method best 매핑으로 직접 회수 — Type 1 chao_weighted K=20 -14.11% / Type 3 chao_weighted/sparse_rp K=20 -11~-12% / Type 4b Centroid tuple -7.37%. 폐기 40 method (정합성 위반 10 + audit drop 23 + 측정 미커버 7) 영역은 narrative 미언급 (사용자 결정).

reference: [_internal/handoff/active/handoff_v32_5_16_v10chain진행중_20260516_0116.md](#) §3 사용 16 method 확정 + [_internal/MASTER_README.md](#) 측정 portfolio.

Q4. Q-error paired $\Delta\%$ 92.5% 영역 sample selection 영역만 — paper review-grade 통계 결과?

답변: 본 evidence는 paper review-grade 통계 결과입니다. **paired CaseB < CaseA = 92.5% (455/492, $p < 1e-45$) + Cliff's δ large better = 63.0% (311/494) + Hedges' g large = 55.7% (275/494) + one-sided BH-FDR $\alpha=0.05$ outperform = 45.3% (224/494).** Cliff's δ + Hedges' g는 effect size 영역 large threshold (Cliff's $\delta \geq 0.474$ / Hedges' $g \geq 0.8$) 영역 직접 충족. BH-FDR (Benjamini-Hochberg False Discovery Rate) $\alpha=0.05$ 영역 multiple comparison 보정 후 통계 유의 outperform 비율. negative control은 CaseA 단독 대체 모드의 outperform = 0/493 = 0% (large worsening 37.1%) 영역 — 단독 대체 가설 영역 폐기 + augment 영역만 valid. paper Fig 12 mean qe_trim 1.618 vs paper 1.69 = -4.3% 재현으로 paper exact 정합성도 동시 확보.

reference: [_internal/MASTER_README.md](#) §RQ3 통계 + [submission/_drafts/속도는벡터_본연구_narrative_최종정리_v5_draft.md](#) §4.2 결합 (CaseB) 결과.

C. 결합 영역 정당성

Q5. Phase 3 결합 minimal (산술 평균 $\alpha=0.5$) 영역 정당성?

답변: Phase 3 결합 영역의 minimal 정당성은 두 영역에서 나옵니다. **첫째, paper §V-B Adaptive Eq 1-6 영역은 그대로 100% 유지** — sample budget $N=385$ (Eq 1) + estimator Σ matching $\times (1-\text{ratio})$ (Eq 2) + Q-error δ (Eq 3) + momentum η update (Eq 4-6) hyperparam 7건 ($m=0.9$, $\eta_0=0.1$, $\alpha=50$, $\beta=1.5$, $\gamma=0.99$, $P=50$) verbatim. paper exact violate X. **둘째, 결합 영역만 minimal augmentation** — $\text{est_final} = (\text{est_b1} + \text{est_method}) / 2.0$ 산술 평균만 ($\alpha=0.5$ fix). 통계적 정당성은 bias-variance trade-off에서 — random Bernoulli (est_b1)는 bias 0이지만 variance 큼, sample selection (est_method)는 분포 가정 시 variance 낮음. 두 estimator 산술 평균은 한 쪽이 fail해도 다른 쪽이 보완하는 robust 구조. α sweep 측정 evidence: 4 method 中 3 (sparse_rp / chao_weighted / hilbert_real)이 $\alpha=0.5$ 에서 best. 가장 평균 ($\alpha \cdot \text{est_b1} + (1-\alpha) \cdot \text{est_method}$) + query-conditional routing은 §6.2 Future work 명시.

reference: [submission/_drafts/속도는벡터_본연구_narrative_최종정리_v5_draft.md](#) §4.3 4 component framework + [submission/_drafts/속도는벡터_5_27_키노트_prompt_v11_part1_framing_20260516_0050.md](#) §0.3 narrative 표현 통일.

Q6. selectivity-dependent paradox 영역 explanation?

답변: $\text{sel}=0.01$ 영역 paradox 양상은 외형상 paper §V-B 이론 (Neyman optimal allocation σ -weighted)을 위배하는 듯 보이지만, 실제로는 boundary case의 자연 결과입니다. 본 데이터셋 root cause 영역은 두 영역: **(1) σ_j range 1.3-1.6 $\times$ narrow** — DEEP/SIFT/SSN $\text{sf}=100$ KM20 cluster의 cluster 내 sigma는 $[0.18, 0.29]$ 범위 영역 (Cochran 1977 §5.5 Neyman 가정 미만족). **(2) $N_i \text{ CV}=0$** — KM20 cluster size 균등. 두 가정 미만족 영역에서 σ -weighted Neyman alloc $\text{cos_sim } 0.99$ (L1 diff 21-39 sample / 385 budget) $\rightarrow$ budget=385 hit count noise ($\sim 50/\text{seed}$ @ $\text{sel}=0.1$) $>$ Neyman signal (~ 3 hits 차이) 영역 boundary case. $\text{sel}=0.10$ 영역 큰 budget에서는 classical Neyman 정합 (Neyman 1.1076 $<$ Anti 1.1101 $<$ Prop 1.1135). **selectivity-dependent paradox 영역 학술 contribution = "분포 알면 prop allocation이 답이며, σ range 큰 cluster imbalance 영역 (RQ3 추정 framework)에서 Neyman 우위 재검증 필요"의 honest finding** — RQ2 $\rightarrow$ RQ3 자연 전환 narrative 정당화.

reference: [submission/_drafts/속도는벡터_본연구_narrative_최종정리_v5_draft.md](#) §5.1 Neyman selectivity-dependent paradox + 부록 §A-7 정정 룰.

D. 발표 + 보고서 일정 영역

Q7. 5/27 발표 D-5 영역 risk 분석 + mitigation?

답변: 5/22 시점 D-5 영역 핵심 risk 3건. **risk 1 = chain 진행 의존** — v6_caseB ✓ COMPLETE / v7_extras ✓ COMPLETE / v6v7_fix 진행 중 (18 file, ETA 04:00-05:00) / v10_full16 진행 중 (129 file, ETA 02:30) / v9_sel_sweep 대기 (680 file, 5/17 ~ 5/18 새벽 COMPLETE 예상). 5/22 시점 v9 영역까지 100% 회수 후 분석 단계 진입 가능 (1주 buffer). **risk 2 = deck v11 paste + 검토** — claude.ai/design Keynote_Capstone project 영역 prompt v11 (3 part) paste 대기. 본 미팅 전 paste 완료 + 박광현 자문 receive 후 v12 update 가능. **risk 3 = narrative v6 본문 재구성** — narrative v5 base + v11 prompt framing 통일 영역 v6 draft 준비 (5/24-5/26). mitigation 영역 = 박광현 자문으로 framing layer 분리 영역 confirm + 측정 결과 paired Δ% 92.5% 영역 학술 validation receive.

reference: [_internal/handoff/active/handoff_v32_5_16_v10chain진행중_20260516_0116.md](#) §4.1 chain 현재 상태 + [submission/_drafts/속도논벡터_5_27_키노트_prompt_v11_part3_slide16_25_20260516_0050.md](#) §사용자 직접 paste 영역.

Q8. 6/11 보고서 영역 narrative scope?

답변: 6/11 보고서 outline v3 update plan은 16 chapter 영역 구성됩니다. **§1 Introduction** (VAQ + Exqutor base 소개) / **§2 Related Work** (sampling-based cardinality estimation survey) / **§3 Methodology** (3 phase + 4 type + dynamic 할당 mechanism) / **§4 Experimental Setup** (paper exact 측정 방법) / **§4.1 측정 portfolio** (~2039 file matrix) / **§4.2 단독 대체 (CaseA) 결과** + negative control / **§4.3 결합 (CaseB) 결과** + paired Δ% / **§4.4 4 component framework** / **§4.5 Type 별 best method 매핑** / **§5 Findings** (5 finding 자세히) / **§5.1 분포 catch speed** / **§5.2 정확도 evidence** / **§5.3 plan robustness** / **§5.4 Pareto frontier** / **§5.5 Limitations 18종 honest disclosure** / **§6 Conclusion + Future Work** + appendix (정정 룰 7 + paper §V-B verbatim). 분담 영역 = 박세은 통합 + 조현빈 §3+§4.1+§4.5 + 이동욱 §2+§4.2 + 강재현 §4.3+§4.4. 5/29-6/10 W5-W6 sprint 분담 가이드.

reference: [plans/6_11_보고서_outline_v3_update_plan_20260511.md](#) + [plans/최종보고서_outline_v2_20260508.md](#).

E. cross-engine + venue 영역

Q9. 박광현 input 4 엔진 통합 POC 영역 cross-engine 일반화 검증 영역 plan?

답변: 박광현 5/15 미팅 input 4 ("4 엔진 통합 POC")는 5/27 발표 후 6/11 보고서 영역 post-narrative 영역에 포함될 future work입니다. **plan 영역:** PostgreSQL pgvector + DuckDB + Exqutor vector.c PG 영역 + 추가 엔진 4 영역. 본 연구의 sample selection mechanism은 엔진 독립적 (Phase 1 분포 인지 stratification + Phase 2 sample 추출 + Phase 3 결합 minimal 영역 모두 vector 영역 처리만 의존) 영역 cross-engine 일반화 검증 가능. 검증 영역 = 동일 16 sample selection method × 동일 4 type cell × 4 엔진 영역 paired Δ% 회수 + 엔진별 fit_time 비교 + 엔진별 production deployment 권고. 본 POC는 5/27 발표 영역 slide 24 "post-narrative" 영역 + 6/11 보고서 §6 Future Work 영역에 명시. EDBT venue 영역 본 paper 영역 후속 형식 영역 가능성 영역 (박광현 연구실 BDAI 영역 Exqutor 본 paper 흐름 직접 후속).

reference: [submission/_drafts/속도는벡터_5_27_키노트_prompt_v11_part3_slide16_25_20260516_0050.md](#) slide 24 + [_internal/handoff/active/handoff_v31_5_16_세션마무리_chain진행중_20260516_0020.md](#) §9 보류 영역.

Q10. EDBT 또는 SIGMOD 영역 venue 영역 본 연구 publish 영역 가능성?

답변: 본 연구의 venue 영역 가능성은 두 영역. (1) **EDBT (Extending Database Technology)** — vector range query cardinality estimation 영역 EDBT short paper / industrial paper 영역 fit. paper Exqutor (arXiv:2512.09695v2) 영역 EDBT submission 후속 형식 영역 align. 본 연구의 9 paradigm × 56 method (사용 16) × paired Δ% 92.5% evidence는 short paper 4 page 영역 fit. (2) **SIGMOD / VLDB short paper / demo** — full paper 영역은 더 넓은 cross-engine 일반화 (POC 4 엔진) + production deployment 영역 진행 후 가능. 단 본 연구는 학부 capstone scope 영역 — venue submission 영역은 박광현 교수님 + 임채림 연구원 영역 협의 영역 + post-narrative 영역 결정. 발표 영역은 venue 영역 언급 × (capstone 학부 톤 일관 + 박세은 framing 단순화 의도 영역 일관).

reference: [reference/papers/](#) Exqutor arXiv:2512.09695v2 + [_internal/handoff/active/handoff_v32_5_16_v10chain진행중_20260516_0116.md](#) §10 환각 회피 룰.

F. 추가 학술 질문 영역

Q11. Honest limitation 18종 영역 disclosure 충분?

답변: 본 연구 §5.3 Limitations 18종은 학술 정직성 (honest disclosure) 원칙 영역 base 입니다. 핵심 limitation: **L1 single-table → multi-table 일반화 한계** (paper §V-B 자체 single-table 가정, 우리 multi-table 측정은 자연 이동). **L2 ★3 hilbert PCA-2D-lex sort alias 정정** (Faloutsos 1989 진짜 Hilbert curve 영역 X). **L3 ★4 sparse_rp Li-Hastie-Church 2006 reference 정정** (Achlioptas 2003 영역 정정). **L4 측정 미커버 9 카테고리 정직 분류** — algorithm audit drop 23 / 자원 한계 7 / paper §V-A scope 외 / wrapper timeout / 사용자 결정. **L5 byte-identical duplicates 7쌍 disclosure**. **L6 selectivity-dependent paradox 영역 boundary case explanation**. **L7-L18 추가** — $\alpha=0.5$ fix sweep / query-conditional routing 미측정 / cross-engine 미검증 / production deployment 미수행 / EDBT venue 영역 학부 scope 한계 등. 모든 limitation 영역 §5.3에 명시 + 본문 §3.6 측정 매트릭스 caveat 영역 cross-reference.

reference: `_internal/method_audit/` + `submission/_drafts/속도논벡터_본연구_narrative_최종정리_v5_draft.md` 부록 §A 정정 룰 7.

Q12. 폐기 40 method 영역 narrative 미언급 영역 정당성?

답변: 폐기 40 method (정합성 위반 10 + reference audit drop 23 + 측정 미커버 7) 영역의 narrative 미언급 영역은 사용자 결정 영역 (5/15 22:51 framing 확정)입니다. **정당성:** 발표 30 min + 보고서 20 page 영역 scope 영역에서 폐기 method 영역 disclosure 영역이 narrative 명료성을 저해 + 본 연구 핵심 contribution (사용 16 method × dynamic 할당 mechanism × Q-error paired $\Delta\%$ 92.5%) 영역 dilute. 폐기 영역 detail은 부록 영역 + `_internal/method_audit/` 영역 detail 보존 + paper review reviewer 요청 시 disclosure 가능. **단 학술 정직성 영역 충돌 X** — 폐기 method 영역 측정 결과 영역은 byte-identical SHA-256 + paradigm rollup 영역 사용 X (사용 16 method 영역만 paradigm rollup base). future work 영역 영역 폐기 method 영역 audit + rectify 영역 영역 가능 영역 명시 (slide 24 post-narrative + §6.2 Future Work).

reference: `_internal/handoff/active/handoff_v31_5_16_세션마무리_chain진행중_20260516_0020.md` §3 사용 16 method 확정 + `_internal/METHOD_REGISTRY.md`.

Q13. paper §V-B Adaptive Eq 1-6 영역 100% verbatim 영역 정합성 검증 방법?

답변: paper §V-B Eq 1-6 + hyperparam 7건 영역 100% verbatim 정합성은 두 영역으로 검증되었습니다. **(1) 코드 line-by-line 100% 일치 확인** — 5/10 paper 정독 agent 영역 결과 $m=0.9$, $\eta_0=0.1$, $\alpha=50$, $\beta=1.5$, $\gamma=0.99$, $\text{update_period}=50$, $N_{\text{init}}=385$, $\text{HNSW } M=16$, $\text{ef_search}=400$ 영역 line-by-line 일치. paper §V-B Eq 1-6에 sample size 영역 min/max clamping 명시 X 영역 우리 영역도 bound X. **(2) paper Fig 12 mean Q-error 재현** — 8 cells (DEEP/SIFT/SSN × $\text{sf}=100$, YFCC $\text{sf}=10$, DEEP+WIKI cross $\text{sf}=10$, DEEP scale $\text{sf}=1/10/100$) 평균 trim Q-error 1.6180 vs paper 보고값 1.69 = **-4.3% 재현** (measurement variance 범위 내 일치). 4 cells × 10 trials × 7 fields = 280/280 fields가 SHA-256 byte-identical로 deterministic 일치 (seed `trial_idx × 13 + 7` 일관). 미세 mismatch 4건 ($q_{\text{error cap}}=100$ / size round / $\text{sel}=0.001$ calibration parquet 부재 fallback / Bernoulli budget) 영역 모두 §5.3 Limitation에 명시.

reference: `MEMORY.md feedback_paper_exact_principle.md` + `submission/_drafts/속도논벡터_본연구_narrative_최종정리_v5_draft.md` §1 paper Fig 12 재현.

G. 미팅 후 follow-up

미팅 confirm 결과를 다음 자료에 즉시 반영:

- `submission/_drafts/속도는벡터_5_27_키노트_prompt_v12_*.md` (v11 → v12 update, 박광현 5/22 자문 결과 반영)
 - `submission/_drafts/속도는벡터_본연구_narrative_최종정리_v6_draft.md` (v5 → v6 본문 재구성)
 - `plans/6_11_보고서_outline_v3_update_plan_*.md` (16 chapter detail 정합성 점검)
 - `_internal/handoff/active/handoff_v33_*.md` (5/22 미팅 결과 + chain v6v7_fix + v9_sel_sweep 100% 회수 후 분석 단계)
-

부록 — Q&A 진행 영역 톤 가이드

- **응답 톤:** 한국어 학술 산문 + peer-to-peer (박광현 영역 BDAI 연구실 PI 영역 학술 review 자리, "교수님" 호칭 ✓ 영역만 + 응답 본문은 학부 capstone 톤 일관)
- **표현 통일** (v11 framing 일관 검증):
- ✕ 사용 금지: "cardinality 추정 우리 영역 contribution" / "estimation algorithm 우리 영역 개선"
- ✓ 사용 강조: "sample selection 영역 우리 영역" / "분포 인지 sample 추출" / "Q-error 영역 paired $\Delta\%$ 개선"
- **수치 인용 영역 정확성:** 모든 수치 영역 측정 file 영역 reference 명시 ([_internal/MASTER_README.md](#) 영역 측정 portfolio)
- **불확실 영역 honest 영역:** 모르는 영역 영역 명시 + 측정 결과 base 영역 추정 영역 명시 (예측 영역 답변 ✕)

작성: 2026-05-16 KST · v11 framing reframing 완전 반영 + 박세은 5/15 20:49 정리 + 박광현 5/15 D-Day 미팅 input
종합 + handoff v32 + narrative v5 + ~2039 file 측정 portfolio 종합 · 5/27 발표 D-5 시점 사전 review 자료.