
속도는 벡터

벡터 분석 쿼리의 카디널리티 추정을 위한
분포 인지 표본 선택

박세은 · 강재현 · 조현빈 · 이동욱

속도는 벡터

박광현 교수
연세대학교 · 지도교수

왜 카디널리티 추정이 중요한가



조건을 만족하는 행의 수를 잘못 추정하면 →
잘못된 실행 계획 → 느린 쿼리

33%


pgvector — 늘 전체의 33%로 가정

100%

DuckDB — 늘 100%로 가정

기존 벡터 데이터베이스는 이 값을 데이터와 무관하게 고정 비율로 어렵한다

논문이 푼 것, 우리가 바꾼 것



논문 **Exqutor**의 추정 알고리즘은 그대로 인정한다

표본 뽑는 방식만 — 무작위 → 분포 반영

연구가 걸어온 길



1단계

연구 시작



논문의 무작위 표본 추출



2단계

중간 발표



한 가지 분포 인지
표본 추출 방법 검증



3단계 · 오늘

최종 발표



16가지 방법 · 세 방식
모든 데이터셋 · 조건에서 검증


논문 기준점

한 방법 · 한 가지 검증

16가지 · 세 방식 · 모든 조건

단계마다 측정 범위가 넓어지며, 초점이 "특정 방법"에서 "표본 선택 단계 개입의 효과"로 분명해졌다

분포를 반영해 표본을 뽑는 세 단계




추정 알고리즘과 표본 크기 보정 과정은 **논문 그대로**

세 가지 방식을 같은 조건으로 비교했다

비교의 기준


기존 방식



논문 그대로의 무작위 표본 추출로 추정.

우리 표본만 사용

완전 대체



무작위 표본을 우리 표본으로 통째 교체해 추정.

두 추정값 평균

결합



논문 추정값과 우리 추정값을 평균 내어 함께.

한 번의 측정에서 세 방식을 똑같은 데이터·똑같은 조건으로 동시 비교 → 차이가 방식 때문임을 분명히

무엇을, 어떤 조건으로 측정했는가



데이터셋

9종 · 96~1024 차원

차원과 도메인을 폭넓게



데이터 규모

10만 · 100만 · 1000만

데이터가 커질 때 효과 변화



선택도

0.1% · 1% · 10%

쿼리 조건이 좁을 때부터 넓을 때까지



표본 선택 방법

16가지

7가지 접근을 고루 대표



계층 수

10 · 20 · 30 개


논문 기본값 20 중심으로 적을 때·많을 때

다섯 축을 빠짐없이 교차


→ **1508번 측정**

측정한 데이터셋

단일 벡터 데이터셋



다중 벡터 데이터셋




96차원부터 1024차원까지 — 단일 벡터와 다중 벡터를 아우른다

데이터가 쏠려 있을 때, 무작위는 쏠린 곳만 뽑는다

기존 방식 · 무작위


표본이 봉우리에 집중



드문 영역 — 표본 없음

분포 인지 표본 추출

전 영역에서 골고루



드문 영역도 표본에 들어온다

분포를 반영하면 드문 영역까지 표본에 들어와 추정이 정확해진다


16가지 방법, 7가지 접근



공간 곡선

고차원을 한 줄로 펼쳐 균등 구간으로 자른다

Hilbert 곡선 · Z-order 곡선 · 고차원 Hilbert 곡선 · IVF 클러스터링



차원 축소

정보가 가장 많은 축으로 압축해 구간을 나눈다

주성분 분석 · 독립성분 분석 · 랜덤 SVD · 희소 랜덤 투영



통계적 총화

각 구간에 데이터가 같은 양씩 담기게 자른다

누적 제공근 총화 · Lavallée–Hidiroglou 총화



양자화

짧은 코드로 바꿔 같은 코드끼리 묶는다

RaBitQ 양자화 · 다차원 히스토그램



클러스터링

비슷한 것끼리 군집으로 묶는다

미니배치 K-means · 가우시안 혼합 모델(GMM)



스트리밍 표본 추출

데이터를 한 번 훑으며 표본을 골라낸다

가중 표본 추출



정보 이론 기반

해시로 데이터 분포를 적은 메모리에 요약한다

HyperLogLog

일곱 가지 접근에서 **대표 방법 16가지**를 골라 모두 측정했다

결합 방식이 추정 오차를 89.1%에서 줄였다

89.1%

결합 방식이 기존 방식보다 추정 오차를 줄인 비율

1508번의 측정 중 **1344번** 더 정확
추정 오차 중앙값 약 **4.4%** 감소

신호의 견고함

통계적으로 의미 있는 개선


65%

개선 폭이 큰 경우

72%

완전 대체는 불안정하다 — 결합이 답이다

완전 대체



기존 방식보다 나은 경우

35.2%

결합



기존 방식보다 나은 경우

89.1%

결합 vs 완전 대체 직접 비교 — 결합이 **96.5%**에서 우월

표본을 통째로 바꾸면 우리 방법이 강할 때만 좋고 약할 때 크게 나빠진다 → 두 추정값을 **결합**하면 논문 방식이 안전망이 되어 안정적으로 개선

16가지 방법 중 13가지가 기존 방식을 안정적으로 이긴다


13 / 16

모든 조건에서 안정적으로 우월

공간 곡선·차원 축소·총화 계열이 견고하게 우월.

가우시안 혼합 모델·미니배치 K-means·IVF 클러스터링 세 가지는
측정에서 불안정해 권장에서 제외.

■ 권장 13 ■ 제외 3



개선 폭의 중앙값(%) — 음수가 개선

선택도·데이터 구조·계층 수 — 모든 조건에서 일관되게 우월

선택도

조건이 넓을수록
더 우월



데이터 구조

단일·다중
거의 동일




계층 수

20개 계층이
최적



세 패널 수치는 모두 **결합 방식이 기존 방식을 이긴 비율** — 조건이 달라져도 개선이 일관된다

정확도와 분포 파악 시간의 균형



균형 — 권장

가중 표본 추출

11초 · 최고 정확도 (-6.2%)

가장 빠름

희소 랜덤 투영

2.9초 · 분포 파악 최단

권장 제외

가우시안 혼합 모델

느리고 부정확

데이터 유형을 보고 방법을 자동으로 고른다

1 데이터가 들어온다



2 데이터 유형 판별
크기 · 구조 · 차원



3 유형에 맞는 표본 선택 방법 자동 선택



4 결합 방식으로 카디널리티 추정

사람이 매번
방법을 고르지 않고,
데이터 유형에 따라
자동으로

측정 결과를 종합해 만든 우리의 제안 — 추정 알고리즘은 그대로 두고, **표본 선택 방법만** 데이터에 맞춰 바꾼다

결론

1

분포를 반영한 표본 선택이
추정 오차를 **89.1%에서** 줄였다



2

통째 교체는 불안정 —
두 추정값의 **결합**이 답이다



3

선택도·데이터 구조·계층 수
모든 조건에서 **일관되게** 우월



4

데이터 유형에 따라
방법을 자동으로 고르는 방식을 제안



추정 알고리즘은 그대로 두고, 표본을 뽑는 방식만 바꾸는 것만으로 추정이 더 정확해진다

한계와 다음 단계

⚠ 정직하게 남기는 점

검증 과정에서 마주한 두 가지 한계

비교 기준의 결함을 발견해 바로잡았다

검증 중 비교 기준(기존 방식)의 측정에서 작은 결함을 발견해 바로잡았다 — 개선 수치는 더 보수적이지만 더 엄정한 기준 위의 값

가장 큰 규모 다중 벡터는 일부만 측정

가장 큰 규모의 다중 벡터 데이터는 일부 조합만 측정 — 전수 조합은 보고서에서 보강

🏢 산업 적용

다른 데이터베이스 엔진으로 확장

pgvector·DuckDB·PostgreSQL의 데이터와 무관한 33%·100% 고정값 → 데이터 분포 기반 추정으로

📄 논문 적용

Exqutor 논문 프레임워크에 통합

논문의 추정 알고리즘 + 우리의 표본 선택 — 별도 논문이 아닌 자연스러운 확장으로

추정 알고리즘은 그대로 두고 표본 선택 단계만 바꾸는 방식이므로, 기존 엔진·기존 논문에 최소 수정으로 적용할 수 있다

감사합니다

질의응답