

속도는 벡터


벡터 분석 쿼리의 카디널리티 추정을 위한
분포 인지 표본 선택

박세은 · 강재현 · 조현빈 · 이동욱
지도교수 박광현 교수



1 연구 배경

데이터베이스는 쿼리를 실행하기 전, 조건을 만족하는 행이 몇 개일지 — 카디널리티 — 를 추정한다. 이 추정이 틀리면 잘못된 실행 계획으로 쿼리가 느려진다.



33%

pgvector

늘 전체의 33%로 가정

100%

DuckDB

늘 100%로 가정

기존 벡터 데이터베이스는 데이터 분포를 보지 않고 데이터와 무관한 고정 비율로 어렵한다 — 추정이 크게 어긋날 수밖에 없다.

2 우리 방법

논문 Exquator의 추정 알고리즘은 그대로 두고, 표본을 뽑는 방식 하나만 바꾼다. 데이터가 한쪽으로 쏠려 있을 때, 무작위는 쏠린 곳만 뽑지만 분포를 반영하면 골고루 뽑는다.

기존 방식 · 무작위



표본이 봉우리에만 몰린다

분포 인지 표본 추출



드문 곳까지 골고루 들어온다

01

분포 파악

데이터를 비슷한 것끼리
20개 그룹으로 나눈다



→

02

표본 추출

각 그룹에서 표본을
골고루 뽑는다



→

03

결합

논문 추정값과 우리 추정값을
평균 낸다



3 측정 설계

세 가지 방식을 똑같은 데이터·조건으로 한 측정에서 동시에 비교하고, 다섯 축을 교차해 측정했다.

기존 방식

논문 그대로의 무작위
— 비교의 기준

완전 대체

무작위를 우리 표본으로
통째 교체

결합

두 추정값을 평균 — 우리가 제안하는 방식



데이터셋

9종 / 96-1024차원



데이터 규모
10만·100만·1000만행



쿼리 조건

0.1 · 1 · 10%



표본 선택 방법

16가지



그룹 수

10 · 20 · 30개

다섯 축을 빠짐없이 교차 —
단일 벡터와 다중 벡터를 아우른다.

1508 번 측정

4 핵심 결과

89.1%

결합 방식이 기존 방식보다 추정이 정확한 비율

1344 / 1508

더 정확한 측정 수

약 4.4%

추정 오차 중앙값 감소

65%

통계적으로 의미 있는 개선

72%

개선 폭이 큰 경우

완전 대체는 불안정 — 결합이 답

완전 대체 35.2%

결합 89.1%

통째 교체는 우리 방법이 약할 때 크게 나뉠진다. 결합하면 논문 방식이 안전
만이 되어 — 완전 대체와 직접 맞붙어도 96.5%에서 우월, 16가지 방법 중
13가지가 안정적으로 우월하다.

조건이 달라져도 일관되게 우월

쿼리 조건

83.3 87.6 97.5
0.1% 1% 10%

데이터 구조

89.1 89.2
단일 다중

그룹 수

83.6 89.8 85.9
10개 20개 30개

세 축의 수치는 모두 결합 방식이 기존 방식을 이긴 비율(%)

5 결론

1 분포를 반영한 표본 선택이 추정 오차를 89.1%에서 줄였다.

89.1%

2 통째 교체는 불안정 — 두 추정값의 결합이 답이다.

35.2

89.1


3 선택도·데이터 구조·그룹 수, 모든 조건에서 일관되게 우월하다.



4 데이터 유형에 따라 표본 선택 방법을 자동으로 고르는 방식을 제안한다.



→ 다음 단계 — 다른 데이터베이스 엔진에서도 같은 효과가 있는지 검증해 나간다.



▶ 소개 영상 보기

QR 코드를 스캔하면 속도는벡터 팀의 연구 소개 영상을 보실 수 있습니다.

※ 동영상 업로드 후 QR이 삽입됩니다.