


벡터 분석 쿼리의 카디널리티 추정을 위한 분포 인지 표본 선택

박세은 · 강재현 · 조현빈 · 이동욱 · 지도교수 박광현 교수

① | 연구 배경

데이터베이스는 쿼리를 실행하기 전, 조건을 만족하는 행이 몇 개일지 — **카디널리티** — 를 추정한다. 이 추정이 틀리면 잘못된 실행 계획으로 쿼리가 느려진다.



기존 벡터 데이터베이스는 데이터 분포를 보지 않고 데이터와 무관한 **고정 비율**로 어렵한다 — 추정이 크게 어긋날 수밖에 없다.


② | 우리 방법

논문 Exqutor의 추정 알고리즘은 그대로 두고, **표본을 뽑는 방식** 하나만 바꾼다. 데이터가 한쪽으로 쏠려 있을 때, 무작위는 쏠린 곳만 뽑지만 분포를 반영하면 골고루 뽑는다.




③ | 측정 설계

세 가지 방식을 똑같은 데이터·조건으로 한 측정에서 동시에 비교하고, 다섯 측을 교차해 측정했다.



④ | 핵심 결과




⑤ | 결론

- 1 ↗
분포를 반영한 표본 선택이 추정 오차를 89.1%에서 줄였다.

2 ♡
통째 교체는 불안정 — 두 추정값의 결합이 답이다.

3 📊
선택도 · 데이터 구조 · 그룹 수, 모든 조건에서 일관되게 우월하다.

4 ⌚
데이터 유형에 따라 표본 선택 방법을 자동으로 고르는 방식을 제안한다.



➡ 다음 단계 다른 데이터베이스 엔진에서도 같은 효과가 나오는지 검증해 나간다.