

분포 인지형 stratification 으로 Exqutor 보강하기

Skew-Aware Stratification for Vector Cardinality Estimation

TEAM

속도는벡터

박세은 · 강재현 · 조현빈 · 이동욱

ADVISOR

박광현 교수

BDAI 연구실

BASE PAPER

Exqutor

arXiv:2512.09695v2

01 배경

Exqutor 논문이 명시한 한계와 본 연구의 출발점

1. Exqutor 논문이 명시한 한계

03 / 20

// Adaptive Sampling estimator 의 정확도는
sampling 방식 자체의 **분포 의존성**에 제약된다.

원 논문 §V-B Adaptive Sampling 영역 – 인덱스 부재 시 Bernoulli random sampling 으로 카디널리티 추정.
sample budget $N=385$ + 모멘텀 기반 동적 조정 (Eq 1-6) 으로 paper 가 명시한 한계.

1. 우리가 잡은 주제

04 / 20

분포를 알 때 / 모를 때 **모두** 에서 더 정확한 sampling 방식을 찾는다

원 논문이 명시한 sampling 한계 → 분포 인지형 stratification 으로 보강 가능한가?

02

연구 질문

RQ1 · RQ2 · RQ3 — 분포 인지의 단계적 검증

2. 세 단계 연구 질문

BASELINE

RQ1

Random sampling 이 skew 데이터셋에서 얼마나 부정확한가?

Bernoulli 단일 vs KM20 stratified

KNOWN DISTRIBUTION

RQ2

분포를 알 때 어떤 allocation 이 최적인가?

Bernoulli / Equal / Proportional /
Neyman / Anti-Neyman

UNKNOWN DISTRIBUTION

RQ3

분포를 모를 때 어떤 알고리즘이 최적인가?

8 paradigm × 56 method

2. RQ1 — random sampling 의 부정확성

07 / 20

SIFT SF=100 SEL=0.10 · MAX GAP

-8.64%

random sampling 의 부정확성

Bernoulli qe_trim 1.230 → KM20 1.123
ratio **1.095×** 정확도 향상


4 CELLS BREAKDOWN

CELL	BERN	KM20	GAP
SIFT sel=0.10	1.230	1.123	-8.64%
DEEP sel=0.01	1.748	1.637	-6.35%
DEEP sel=0.10	1.161	1.117	-3.78%
SIFT sel=0.01	1.690	1.657	-1.90%
4 cells mean	1.456	1.385	-5.17%

random Bernoulli 의 부정확성은 selectivity / dataset 조합에 따라 최대 **8.64%** 확대 · KM20 stratification 의 안정성 정량 입증

2. RQ2 — 분포를 알면 Proportional 이 답

08 / 20



qe_trim = trimmed mean Q-error (10 trials max/min 제외, paper §VI 정의) · Q-error = $\max(\text{est}/\text{true}, \text{true}/\text{est})$, 1 에 가까울수록 정확

Bernoulli baseline = paper §V-B Adaptive Sampling 의 random sampling estimator · 분포 정보 활용 시 추정 안정성 정량 입증

2. RQ3 — 분포를 모를 때

09 / 20

실제 환경에서는 분포를 **모른다.**
→ 분포를 추정하는 알고리즘이 필요하다.

8 paradigm 측면에서 분포 추정 알고리즘 search · 56 method portfolio 비교

03

알고리즘 Portfolio

8 paradigm × 56 method · 각 paradigm 의 가정이 다름을 명시

3. 8 paradigm × 56 method · 각 paradigm 가정

밀도 추정 n=1 Parzen KDE kernel 함수 + bandwidth · 부드러운 PDF 추정	정보 이론 n=9 HyperLogLog hash uniform 분포 · distinct count log-memory	스트리밍 n=44 Chao 1982 weighted reservoir stream stationary · weight-proportional sampling	차원 축소 n=104 Sparse RP Johnson-Lindenstrauss 거리 보존 · 1/vD sparse
공간 분할 n=107 Hilbert + Z-order locality preservation · space-filling curve	균등 격자 n=62 QMC (Halton/Sobol/LHS) low discrepancy · deterministic	클러스터 n=87 k-means / MiniBatch cluster number K · intra-cluster homogeneity	양자화 n=53 Product Quantization codebook + sub-vector · 메모리 효율

각 paradigm 의 가정은 다르나, 모두 random sampling 의 분포 무시 한계를 다른 방식으로 보완 · CaseB 산술 평균 ensemble 로 결합 보강

04

실험 framework

Exqutor 재현 + 대체 (CaseA) vs 증강 (CaseB)

4. paper 재현 검증 anchor

13 / 20

-4.3%

paper Fig.12 mean qe_trim 1.69 → 1.618

Exqutor Adaptive Sampling 재현 · 8 cells · measurement variance 범위 내 일치
→ paper exact 100% 재현 입증 · 본 연구의 paper review-grade evidence anchor

4. 대체 vs 증강 — 두 가지 적용 방식

14 / 20

CASEA · REPLACE

대체

```
est_final = est_method
```

paper Bernoulli baseline 을 우리 method 로 **단독 교체**

CASEB · AUGMENT

증강

```
est_final = (est_b1 +  
est_method) / 2
```


paper Bernoulli + 우리 method **산술 평균 ensemble**

두 방식 모두 **single + multi cell** 전반에서 비교

AdaptiveState (Eq 1-6) + N=385 paper exact 보존 · SF=1/10/100 전 영역 측정 · multi cell 은 single KM20 cluster join carry-over

4. Paradigm rollup — CaseB 증강 효과

15 / 20



Bernoulli baseline qe_trim 1.748 → 5 paradigm 증강 시 1.540 ~ 1.651 · Q-error 28% ~ 16% 절감, 정확도 1.06× ~ 1.14× 향상

4. 왜 replace 만으로는 안 되는가

BUDGET

sample budget 공유

paper N=385 한정 budget 내에서 단일 estimator 가 분포 추정과 cardinality 추정을 동시에 수행 → 두 작업 모두 불충분 sample

ASSUMPTION

paradigm 가정 부정확

각 paradigm 가정은 데이터마다 만족 정도가 다름. 단독 사용 시 가정 위반 cell 에서 정확도 급락 → 통계 우위 확보 X

NEGATIVE CONTROL

실측 결과 무효

CaseA replace 측정 결과 493 cells 중 **outperform 0 cell**. paper baseline 을 우리 method 로 단독 교체 시 단 하나도 우위 X

CONSTRAINT

VARIANCE

EVIDENCE

→ **augment** (paper baseline + 우리 method 평균) 만이 통계적 우위 확보

4. 가장 우수 알고리즘 5선

밀도 추정

-11.93%

1.135× 정확도

Parzen KDE

PARZEN 1962

데이터 점 주변 kernel 함수로 PDF 추정
→ cluster 분포를 부드럽게 추정

정보 이론

-7.60%

1.082× 정확도

HyperLogLog

FLAJOLET 2007

hash leading-zero 분포로 distinct
count 추정 → 1.5KB cardinality

스트리밍

-6.63%

1.071× 정확도

Chao weighted

CHAO 1982

weighted reservoir sampling →
stream 환경에서 분포 비례 sample

차원 축소

-6.03%

1.064× 정확도

Sparse RP

LI · HASTIE · CHURCH 2006

1/vD 희소 random matrix → 고차원을
저차원으로 (JL 보장)

공간 분할

-5.57%

1.059× 정확도

Hilbert + Z-order

MORTON 1966

space-filling curve → 고차원 공간을
1D 로 보존, 인접성 유지

4. 대체 vs 증강 — 결정적 비교

18 / 20

CASEA · REPLACE

0 / 493

outperform 0 cell

Bernoulli 단독 교체 시 단 하나도 우위 X
→ 단독 대체 무효

CASEB · AUGMENT

92.5%

paired better (455 / 492)

증강이 거의 모든 cell 에서 paper baseline 우위
→ $p < 1 \times 10^{-45}$

단독 대체 **X** → 증강 적용 **만 유효**

paper review-grade evidence · Cliff's δ large 63.0% · Hedges' g large 55.7%

4. 측정 외 영역 — 정직한 한계

19 / 20

COST OVERHEAD

ensemble 비용

CaseB 증강의 **latency / memory overhead** 측정 X. paper §V-B 재현 scope 한정으로 **정확도 (qe_trim)** 만 측정.

JSON schema = qe_trim + final_size_mean only
cost-quality tradeoff = 측정 외 영역

MULTI-TABLE

multi-table carry-over

multi cell (A2-Fig7/Fig9) 의 stratification 은 **single table KM20 cluster** 의 **join carry-over**. 두 테이블 결합 후 별도 stratification 학습은 paper §V-A scope 외.

→ single 결과와 유사 패턴
multi-aware stratification = 측정 외 영역

감사합니다

질문 환영합니다