

[속도는벡터] 연구 진행 경과 보고 및 3차 자문 요청

멘토님 안녕하세요, 연세대학교 캡스톤 디자인 속도는벡터 팀입니다.

4월 20일 2차 자문에서 (1) 단일 테이블 시나리오로 범위를 좁힌 것의 타당성, (2) 비례 배분 효과와 공간 인식 효과를 분리한 Two-Level Decomposition의 학술적 가치, (3) 중간 발표의 메시지 방향에 대해 조언해 주셨습니다. 그 이후로 연구가 크게 진전되어, 5월 27일 최종 발표를 앞두고 경과를 공유드리고 세 가지 자문을 구하고자 합니다.

연구 경과

중간 발표까지는 두 가지 질문을 다루었습니다 — 무작위 표본 추출이 한쪽으로 쏠린 데이터에서 얼마나 부정확한지, 그리고 데이터 분포를 알고 있을 때 어떤 표본 추출 방식이 가장 정확한지입니다. 이후 최종 발표를 향해 세 번째 질문 — 데이터 분포를 사전에 모를 때 어떤 표본 선택 방식이 가장 좋은지 — 를 본격적으로 측정했습니다.

측정 대상을 넓혔습니다. 중간 발표까지 쓰던 한 가지 표본 추출 방식(k-means 기반 계층화)을, 공간 곡선·차원 축소·양자화·클러스터링 등 일곱 가지 접근을 대표하는 16가지 방법으로 확장했습니다. 논문 Exquitor에서 저희가 손대는 지점은 '표본을 뽑는 단계' 하나로 일관되게 한정했고, 카디널리티 추정 알고리즘과 표본 크기 보정 과정은 논문 그대로 두었습니다.

세 가지 방식을 같은 조건으로 비교했습니다. 2차 자문 때 말씀드린 '분포 인지 표본 대 무작위 표본'의 대조를 발전시켜, 한 번의 측정에서 세 가지 방식을 똑같은 데이터·똑같은 조건으로 동시에 비교하는 설계를 적용했습니다. 세 방식은 ① 기존 방식(논문의 무작위 표본 추출), ② 완전 대체(논문의 표본을 저희 방법으로 통째 교체), ③ 결합(논문의 추정값과 저희 방법의 추정값을 평균)입니다. 모든 데이터셋과 모든 조건(선택도·데이터 규모·단일과 다중 구조·계층 수)에 걸쳐 1508번을 측정했습니다.

핵심 결과입니다. 결합 방식은 기존 방식과 비교해 1508번 중 89.1%에서 추정 오차를 줄였습니다(개선 폭 중앙값 약 4.4%). 반면 완전 대체 방식은 35.2%에서만 더 나아, 저희 방법으로 논문의 표본을 통째 바꾸는 것은 불안정함을 확인했습니다. 완전 대체는 효과가 없을 수도 있는 방식을 일부러 측정해 본 것으로, 개선의 원천이 새 방법 자체가 아니라 논문 방식과의 '결합'에 있음을 거꾸로 보여 줍니다.

측정 공간도 능동적으로 넓혔습니다. 공개된 단일 벡터 데이터셋 다섯 종에 더해, 서로 다른 두 데이터셋의 벡터를 이어 붙인 다중 벡터 데이터를 직접 만들어 측정 범위를 확장했습니다.

검증 과정에서 문제를 발견해 바로잡았습니다. 측정을 검증하던 중, 비교 기준이 되는 기존 방식의 표본 추출 구현에 미묘한 결함을 발견했습니다 — 데이터를 두 단계로 나눠 표본을 뽑던 구조가 일부 조건에서 기준값의 오차를 부풀리고 있었습니다. 이를 데이터 전체에서 한 번에 뽑는, 논문에 더 충실한 방식으로 바로잡았습니다. 그 결과 개선 수치는 수정 전보다 다소 보수적이 되었으나, 더 엄정한 기준 위에서 나온 값이 되었습니다.

자문 요청

세 가지에 대해 멘토님의 판단을 여쭙고 싶습니다.

첫째, 연구를 설명하는 틀의 변화와 Two-Level Decomposition의 위치입니다. 2차 자문에서 멘토님은 비례 배분 효과와 공간 인식 효과를 분리한 Two-Level Decomposition을 본 연구의 핵심이자 독창성으로 평가해 주셨습니다. 이후 측정을 16가지 방법으로, 세 방식 비교로 확장하면서 저희는 연구를 설명하는 틀을 "논문의 표본 선택 단계를 분포 인지 방식으로 바꿨을 때의 효과를, 모든 데이터셋과 모든 조건에 걸쳐 검증한다"로 단순하게 통일했습니다. 이 변화가 학술적으로 타당한지, 그리고 최종 발표와 보고서에서 Two-Level Decomposition을 어떻게 둘지 — 별도의 핵심 기여로 남길지, 결합 방식이 무작위 표본을 이기는 이유를 설명하는 근거로 흡수할지 — 의견을 듣고 싶습니다.

둘째, 비교 기준의 측정 결함을 발견하고 수정한 일을 최종 발표에서 어떻게 제시할지입니다. 1차 자문에서 멘토님이 강조해 주신 '비교 기준 설정'과 직결되는 사안입니다. 위에 적은 대로, 검증 과정에서 기존 방식의 표본 추출 결함을 발견해 바로잡았고 그 결과 개선 수치가 보수적으로 약해졌습니다. 저희는 이를 "측정의 엄정성을 끝까지 검증한 끝에 비교 기준의 결함까지 찾아 정직하게 바로잡았다"는 강점으로 제시하려 합니다. 이 제시가 설득력이 있는지, 평가하시는 교수님과 학우들에게 '결과가 나빠졌다'는 후퇴로 보이지 않으려면 발표를 어떻게 구성해야 할지 조언 부탁드립니다.

셋째, 최종 발표의 핵심 메시지와 연구 기여를 규정하는 방식입니다. 2차 자문에서 멘토님은 "왜 기존 방식이 안 되는가 → 무엇을 발견했는가 → 그래서 무엇을 했는가"의 흐름을 권해 주셨습니다. 이번 결과로 이 흐름을 구성할 때, 최종 발표의 핵심 메시지를 (1) "분포를 반영한 표본 선택이 추정 오차를 89.1%에서 줄였다"는 수치, (2) "무작위 → 완전 대체(불안정) → 결합(답)"이라는 비교의 흐름, (3) 데이터 유형에 따라 표본 선택 방법을 자동으로 고르는 방식 가운데 무엇으로 잡는 것이 학부 캡스톤 최종 발표에 가장 설득력이 있을지 여쭙고 싶습니다. 아울러 본 연구를 '새로운 알고리즘 제안'이 아니라 '표본 선택 단계의 개입이 주는 효과를 모든 조건에 걸쳐 검증한 연구'로 규정하는 것이 최종 평가 기준에서 적절한 자리매김인지도 의견 부탁드립니다.

앞으로의 일정

5월 27일 최종 발표(약 25분 발표와 질의응답)와 6월 11일 최종 보고서 제출이 남아 있습니다. 이번 자문에 대한 회신을 5월 24일경까지 주실 수 있다면 최종 발표 자료에 충분히 반영하겠습니다. 필요하시면 현재까지 작성한 발표 자료와 연구 설명 초안을 함께 보내드리겠습니다.

감사합니다.

속도는벡터 팀 드림