

속도는 벡터

Distribution-aware Sample Selection for VAQ Cardinality Estimation · based on Exqutor §V-B Adaptive Sampling
(arXiv:2512.09695v2)

TEAM

속도는 벡터

박세은 (팀장) · 강재현 · 조현빈 · 이동욱

ADVISOR

박광현 교수

BDAI 연구실

DECK

FINAL v13

5/27 발표 · 27 slide

Distribution-aware Sample Selection

for VAQ Cardinality Estimation

BASE PAPER

Exqutor arXiv:2512.09695v2 §V-B Adaptive Sampling — cardinality 추정 알고리즘은 그대로 둔다.

본 연구 개입

paper의 unstratified Bernoulli random 자리에 **분포 인지 표본 추출**을 더한다 — 추정 알고리즘이 아니라 그 입력만 교체.



§V-A · WITH INDEX

ECQO

HNSW range query
정확 cardinality · 1-2 ms

인덱스가 있을 때
본 발표 대상 아님

§V-B · WITHOUT INDEX · ★ 본 연구 ANCHOR

Adaptive Sampling

- Eq 1 $N = \lceil z^2 \cdot \hat{P}(1-\hat{P})/e^2 \rceil = 385$
- Eq 2 $\hat{C} = \sum \text{matching} \times (1 - \text{ratio})$
- Eq 3 $\delta = \max(Q\text{-err}, 1/Q\text{-err})$
- Eq 4 $\eta \leftarrow m \cdot \eta + (1-m) \cdot \delta / \alpha \quad (m=0.9)$
- Eq 5 $N_{t+1} \leftarrow N_t \cdot (1 + \eta \cdot \beta \cdot \text{sign}) \quad (\beta=1.5)$
- Eq 6 $\eta \leftarrow \eta \cdot \gamma \quad (\gamma=0.99)$

인덱스 없을 때 · Bernoulli random N=385 + Eq 1-6 momentum 보정
period P=50 query 마다 Eq 4-6 update

1. 본 연구 3 phase 흐름 – sample selection 단계 교체

PHASE 1 · OFFLINE · 1회

분포 인지
stratification

① Type 판별 (rows / structure / dim)

② Type별 권장 method 자동 선택

③ K=20 stratum 분할 row → sid 0..K-1

★ 본 연구 개입

PHASE 2 · ONLINE · 매 QUERY

표본 추출
균등 배분

① budget **N=385** (Eq 1 verbatim)

② 균등 배분 (equal_alloc · N/K씩)

③ est_method 계산 ★ **NEW**

★ 본 연구 개입

PHASE 3 · ONLINE · 매 QUERY

결합
minimal

① est_b1 (paper Bernoulli)

② est_method (본 연구)

③ **est_final = (b1 + method) / 2**

④ paper Eq 2-6 보정 (그대로)

산술 평균만 추가

3 MODE가 PHASE에 대응하는 방식

MODE	PHASE 1-2 분포 인지 + 표본 추출	PHASE 3 결합
B1 · 대조군	— (paper Bernoulli random)	—
CaseA · 완전 대체	적용	생략 (est = est_method)
CaseB · 결합	적용	적용 (산술 평균)

1,508

3-way matched 측정

한 측정이 B1 · CaseA · CaseB 동시 산출
통합 row = 1,508 × 3 mode = 4,524

MEASURE_3WAY · PAIRED

AXIS	차원	구성
Dataset	5+	DEEP · SIFT · SSN · WIKI · YFCC + concat multi-vector
Scale factor	3	sf = 1 / 10 / 100
Selectivity	3	sel = 0.001 / 0.01 / 0.10
Method	16	7 paradigm 대표 (P1 / P2 / P3 / P4 / P5 / P6 / P9)
Strata K	3	K = 10 / 20 / 30
Mode	3	B1 · CaseA · CaseB matched
총 측정	—	1,508건 · 통합 4,524 row

2. 측정 공간을 직접 확장하다 — 공개 데이터셋 + 직접 concat

단일 벡터 데이터셋

SIFT 128d · SimSearchNet++ 256d · DEEP 96d · WIKI 768d · YFCC 192d

★ 우리가 직접 CONCAT한 MULTI-VECTOR

DEEP+SIFT
224 d

DEEP+YFCC
288 d

DEEP+WIKI
864 d

두 데이터셋의 벡터를 차원 방향으로 직접 concat → 측정 공간 능동 확장

TYPE	정의	차원	측정 수	비고
Type 1	소규모 단일 · sf=1	96 - 768	272	0.1 M
Type 2	중규모 단일 · sf=10	96 - 768	224	1 M
Type 3	대규모 단일 · sf=100	96 - 256	464	10 M
Type 4a	대규모 다중 · 224-288 d ★ 우리 concat	224 - 288	372	10 M
Type 4b	대규모 다중 · 864 d ★ 우리 concat	864	176	10 M

2. 16개 sample selection method – 7 paradigm 분류

P1 · CLUSTER cluster based 2 minibatch_partial gmm	P2 · SPATIAL space-filling curve + IVF 4 hilbert_real zorder_morton skilling_hilbert faiss_ivf	P3 · STREAMING weighted reservoir 1 chao_weighted ★	P4 · DIMREDUCE dimension reduction 4 sparse_rp pca1d rsvd ica_fastica	P5 · QMC stratification 2 cum_sqrtf lavallee_hidirogrou	P6 · QUANTIZE bit / hist quantize 2 rabbitq_strat mhist2	P9 · INFOtheo cardinality sketch 1 hyperloglog ★
--	--	---	---	---	--	--

P1.1

minibatch_partial

Sculley 2010 — KDD · `partial_fit` on sub-batches

- 1 MiniBatchKMeans 초기화 ($K=20$ clusters)
- 2 batch $t \rightarrow \text{partial_fit} \rightarrow$ centers update
- 3 최종 centers 도출
- 4 cluster id $\rightarrow$ `stratum_id`

시간 $O(\text{batch} \times K \times d)$ per batch · 단계별 학습 streaming-친화

P1.2

gmm

Dempster-Laird-Rubin 1977 — JRSS · EM Gaussian Mixture

- 1 초기 μ_k, Σ_k, π_k
- 2 **E-step** $P(z=k | x)$ 계산
- 3 **M-step** $\mu_k \cdot \Sigma_k \cdot \pi_k$ update
- 4 $\text{argmax } P(z | x) \rightarrow \text{stratum_id}$

`covariance_type='diag'` · `reg_covar=1e-2`
SIFT 128d / SSN 256d cholesky fail 회피

P2.1
hilbert_real

Faloutsos 1989 — PODS

- 1 PCA → 2D / 3D projection
- 2 Hilbert curve → 1D scalar
- 3 K=20 quantile 분할
- 4 bin → stratum_id

정확도 상위 · fit 느림

P2.2
zorder_morton

Morton 1966 — IBM

- 1 PCA → low-D projection
- 2 dim별 binary 추출
- 3 bit interleaving Z-order
- 4 quantile 분할 → sid

$O(n \cdot d \cdot \log d)$ bit ops

P2.3
skilling_hilbert

Skilling 2004 — AIP 707

- 1 unit cube 정규화
- 2 state-machine high-D Hilbert
- 3 1D scalar 계산
- 4 quantile 분할 → sid

true high-D 곡선

P2.4 · IVF
faiss_ivf

Johnson-Douze-Jégou 2017 — FAISS

- 1 coarse quantizer K-means K=20
- 2 nearest cluster center
- 3 cluster id → stratum_id

train $O(n \cdot K \cdot d)$ · assign
 $O(n \cdot \log K)$

P3.1 · ★ 정확도 1위

chao_weighted

Chao 1982 — Biometrika · A general purpose unequal probability sampling plan

- 1 vector에 weight 부여 (norm 또는 anomaly score)
- 2 priority queue (size K=20) weighted random
- 3 단일 pass streaming 처리
- 4 K stratum 분포 인지 부여 → stratum_id

시간 $O(n \cdot \log K)$ priority queue · 메모리 $O(K)$ compact

16 METHOD 중 정확도 1위

-6.22%

paired Δ% 중앙값 · better 100.0%

fit_time 11.0 s · reservoir memory 0(K)

모든 측정 cell에서 대조군을 이김

3. P4 · DimReduction — 저차원 projection → quantile

P4.1 sparse_rp Li-Hastie-Church 2006 — KDD 1 sparse matrix RP density $\sim 1/\sqrt{d}$ 2 projected vector 3 quantile 분할 → sid 분포 파악 2.9 s 최단	P4.2 pca1d Pearson 1901 — Phil. Mag. 1 covariance matrix SVD 2 1st PC → 1D scalar 3 quantile 분할 → sid $O(n \cdot d^2) + O(d^3)$ SVD	P4.3 rsvd Halko-Martinsson-Tropp 2011 1 random Gaussian sketch 2 power iteration 3 truncated SVD → 1D → sid large-scale PCA	P4.4 ica_fastica Hyvärinen 1999 — IEEE TNN 1 centering + whitening 2 fixed-point iter max non-Gaussianity 3 indep. comp → sid $O(n \cdot d^2)$ iteration
---	---	--	--

저차원 1D projection → quantile 분할 → stratum_id 부여 (4 method 모두 동일한 골격)

P5.1

cum_sqrtf

Dalenius-Hodges 1959 — JASA · Minimum Variance Stratification

- 1 vector → 1D projection (예: PCA 1st PC)
- 2 cumulative vfrequency 계산
- 3 cum vf → K=20 등간격 분할
- 4 분할 bin → stratum_id

classical stratification 정통 (JASA 1959 verbatim)

P5.2

lavallee_hidiroglou

Lavallée-Hidiroglou 1988 — Survey Methodology · take-all + Neyman

- 1 vector magnitude 정렬 (descending)
- 2 top-N take-all stratum (큰 값 전수)
- 3 나머지 → Neyman allocation 분할
- 4 분할 bin → stratum_id

skew long-tail 데이터셋에 효과 (Survey Methodology 1988 verbatim)

3. P6 · Quantization — bit / histogram

14 / 27

P6.1

rabitq_strat

Gao-Lin 2024 — VLDB Best Paper · RaBitQ sign quantization

- 1 vector → random Gaussian projection
- 2 dim별 sign(>0) → 1 / sign(≤0) → 0
- 3 binary code → K=20 quantile 분할
- 4 분할 bin → stratum_id

2024 VLDB Best Paper anchor

P6.2

mhist2

Poosa^{la} 1997 — VLDB · multi-dimensional histogram

- 1 d-D multi-dim histogram bucket
- 2 max variance split iteration
- 3 bucket id → stratum_id

histogram-based real alternative (VLDB 1997 verbatim)

P9.1 · ★ 정확도 상위

hyperloglog

Flajolet-Fusy-Gandouet-Meunier 2007 — AofA · HyperLogLog sketch

- 1 hash function → uniform random bit
- 2 leading zero count
- 3 register (m bucket) max update
- 4 harmonic mean → stratum 부여 → stratum_id

시간 $O(n)$ hash · 메모리 $O(m \cdot \log \log n)$ 매우 compact

PAIRED Δ% 중앙값 · BETTER 100%

-4.58%

주의 — HyperLogLog는 본 연구에서 cardinality 추정값이 아닌 표본 stratum 부여 입력으로만 활용.

AofA 2007 verbatim · memory 가장 compact

대규모 데이터셋에서 강점

4. method별 정확도 순위 — paired Δ% 중앙값 (음수가 개선)

정확도 상위 5


chao_weighted ·
hilbert_real ·
skilling_hilbert ·
ica_fastica · pca1d

모두 -5.5%대 이하 · Spatial·Streaming·DimReduction
paradigm. 대조군보다 못한 method는 P1 Cluster의 gmm 하나.

중앙값 사용 이유 — minibatch_partial의 864d concat 이상치가
평균을 왜곡하므로 robust한 중앙값으로 순위

METHOD	PARADIGM	MEDIAN Δ%	BETTER%
chao_weighted	P3 Streaming	-6.22	100.0
hilbert_real	P2 Spatial	-5.91	98.9
skilling_hilbert	P2 Spatial	-5.75	100.0
ica_fastica	P4 DimReduction	-5.69	100.0
pca1d	P4 DimReduction	-5.55	97.9
zorder_morton	P2	-4.89	98.9
hyperloglog	P9	-4.58	100.0
cum_sqrtf	P5	-4.53	97.9
lavallee_hidiroglou	P5	-4.40	—
sparse_rp	P4	-4.37	—
rsvd	P4	-4.10	—
minibatch_partial	P1	-3.58	—
rabitq_strat	P6	-3.56	—
mhist2	P6	-3.41	—
faiss_ivf	P2	-2.70	—
gmm	P1 Cluster	+2.68	40.4

4. dynamic 할당 mechanism — sample selection 단계만 dynamic



CONTRIBUTION

sample
selection
단계만
dynamic

paper Adaptive Eq 1-6
= 그대로 유지 (dynamic X)

PAIRED Δ% · 3-WAY MATCHED 1,508건


89.1%

CaseB가 B1 대비 Q-error 개선

1,344 / 1,508 · 중앙값 Δ% -4.38% · 평균 -3.06%
(이상치 2건 제외 시 평균 -4.09%)


★ 본 연구 핵심 evidence

신호 건고성 — 효과크기 · 통계 유의



평균(-3.06%)은 minibatch_partial의 concat 이상치 2건이 끌어올린 수치 — 신뢰 가능한 headline은 better 89.1% · 중앙값 -4.38%


5. 완전 대체는 불안정하다 – 결합이 답 · negative control



비교	BETTER%	평균 Δ%	중앙값 Δ%
CaseA_vs_B1 · 완전 대체 vs 대조군	35.2	+12.90	—
CaseB_vs_B1 · 결합 vs 대조군	89.1	-3.06	-4.38
CaseA_vs_CaseB · CaseB가 우월	96.5	—	—

핵심 메시지

완전 대체는 신뢰할 수 없다. 개선의 원천은 method 단독이 아니라 paper Bernoulli와의 결합에 있다.



chao_weighted 균형점

- chao_weighted — 11.0 s · -6.22% (정확도+속도)
- sparse_rp — 2.9 s · 분포 파악 최단
- hilbert_real — 40.7 s · 정확도 최대 · fit 느림
- gmm — 두 축 모두 나쁨 · 쓸 이유 없음

정확도 축 = median Δ% (평균은 minibatch_partial 이상치에 왜곡)
frontier · sparse_rp + chao_weighted


83.3 → 87.6
→ 97.5%

selectivity가 0.001 → 0.01 → 0.10으로 올라갈수록 CaseB가 B1을 이기는 비율이 단조 증가. 0.10에서는 측정 432건 중 421건이 개선.

sel=0.001에서 83.3%가 상대적으로 낮은 이유 - hit 수 자체가 작아 어떤 전략 이든 표본 분산이 커지기 때문. 그래도 중앙값 Δ%는 -4.39%로 명확히 음수.



5. 단일·다중·concat 전 구조에서 우월 일관




유형	설명	N	BETTER%	평균 Δ%	중앙값 Δ%
single	단일 벡터 데이터셋	960	89.1	-3.42	-4.38
multi	cross-table 다중	212	89.6	-4.18	-4.61
concat ★	우리가 직접 연결한 다중 (224 · 288 · 864 d)	336	89.0	+0.92 (이상치 2건)	-4.31

concat의 평균이 +0.92인 것은 864d concat에서 minibatch_partial이 낸 이상치 2건 탓 - 중앙값은 -4.31로 다른 구조와 일관

K = 20 최적점

strata가 너무 적으면 분포의 다봉성을 분리하지 못하고, 너무 많으면 stratum당 표본이 얇아진다. paper default인 K=20이 그 균형점이고, 이제 측정으로 뒷받침된다.

v12까지는 K=10 대조군 B1에 구조적 결함이 있어 K 비교가 어려웠다. v13에서 B1을 1단계 측정으로 통일해 결함을 해소 — B1 qe_trim이 K=10/20/30 전부 정상 범위(1.16~1.66).



견고한 METHOD

14 / 16

P2 Spatial · P3 Streaming · P4 DimReduction · P5 QMC · P6 Quantization · P9 InfoTheoretic 모두 견고

견고 = 모든 측정 조건에서 better 84% 이상

비일관 paradigm = P1 Cluster 하나

P1 CLUSTER의 약점

gmm

중앙값 +2.68% • better 40.4%

대조군보다 못함 - 권장 제외

minibatch_partial

중앙값 -3.58% / 평균 +14.06%

864d concat 같은 극단 조건에서 불안정 - 평균 왜곡의 원인

클러스터링 계열만 비밀관 – Type 4b 같은 고차원 concat에서 불안정. 본 연구는 P1 Cluster를 권장 method에서 제외한다.

분포 인지 표본 선택의 정량 가치 + dynamic 할당 mechanism

FINDING 1 ★

분포 인지 표본 선택이 Q-error를 일관 개선

89.1%

CaseB better · 중앙값 -4.38%

FINDING 4

단일·다중·concat 전 구조에서 일관

89.1 · 89.6 · 89.0%

single · multi · 우리가 만든 concat

FINDING 2 ★

완전 대체는 불안정 · 결합이 답

베르누이 → 완전 대체 → 결합

CaseA 35.2% · CaseB 89.1% · negative control

FINDING 5

16 method 중 14 견고 · P1 Cluster만 약함

14 / 16

정확도 상위가 분포 파악 비용도 합리적

FINDING 3

selectivity가 높을수록 우월 비율 단조 증가

83.3 → 87.6 → 97.5%

sel = 0.001 / 0.01 / 0.10

FINDING 6

strata 수는 K=20 (paper default)이 최적

K = 20

83.3 / 89.6 / 85.4% (K=10/20/30)

검증 과정에서 찾아 바로잡은 것

대조군 측정 결함을 찾아 바로잡았다

- v12 B1의 2단계 표본 추출 결함을 1단계 측정으로 정정
- headline 92.2% → 89.1% — 측정 품질 하락이 아니라 **더 엄정해진 baseline**의 결과
- concat sf=100은 DEEP+SIFT 1종으로 제한 측정
- 평균을 끌어올린 concat 이상치 2건은 중앙값으로 보정

한계는 핵심 finding의 신뢰성을 훼손하지 않는다 — headline은 검증된 1,508건 전수에서 산출

다음 단계

6/11 최종보고서 + cross-engine POC

TRACK 1 · 보고서

6/11 최종보고서 — 6 finding 상세 + appendix

TRACK 2 · 박광현 교수 INPUT

cross-engine POC — PostgreSQL pgvector + DuckDB로 표본 선택 단계 일반화 검증

TRACK 3 · 후속

arXiv preprint 준비 · 7월 target

감사합니다.

Q & A 속도는벡터 · 박세은 · 강재현 · 조현빈 · 이동욱 · 연세대학교 캡스톤 디자인 2026-1 · BDAI 연구실 박광현 교수 지도