
title: 속도논벡터 × 박광현 교수 미팅 (5/15) — Form 1 review form subtitle: 본 연구 fix 결정 + paper Exqutor §V-B
후속 + review 요청 항목 date: 2026-05-15 14:00 KST team: 속도논벡터 (박세은 · 강재현 · 조현빈 · 이동욱)

0. TL;DR — 본 연구 결정 fix

main theme (fix, 변경 X 까지 fix):

**Streaming-aware Distribution-Conscious Cardinality Estimation for Vector-augmented Analytical Queries:
Extending Exqutor's §V-B Framework**

paper §V-B (Adaptive Sampling) 의 "**without vector index**" 가정 안에서 Bernoulli random sample 추출만
distribution-aware reservoir + online cluster maintenance 로 대체. paper §V-A ECQO 영역은 본 연구 outside.

4 측면: 대체 (Bernoulli random → stratified reservoir) / 보완 (paper §VI-D SelNet only → 3-way framework) / 개선
(paper §V-B Eq 5 sampling_size scalar → group-aware) / 추가검증 (paper §VI-B shifting workloads 정량)

1. paper §V-B 영역 anchor (Form 1 의 존재 의의)

paper p.5 좌단 §V 도입부 verbatim:

"For VAQs with vector indexes, Exqutor employs Exact Cardinality Query Optimization (ECQO)... **For VAQs without index**, Exqutor uses a **sampling-based approach** to approximate selectivity (subsection V-B)."

paper p.5 우단 §V-B 첫 단락 verbatim:

"When a VAQ **lacks a vector index**, ... Exqutor adopts a **sampling-based cardinality estimation approach specifically for KNN queries**."

→ paper 자체가 ECQO (with index) vs §V-B (without index) 영역 명확 분리. **Form 1 = §V-B 영역 한정 후속 연구.**

2. Form 1 Component A+B+C+D

Comp	영역	base reference	본 contribution
A Stratified Reservoir Sampling	cluster 별 reservoir R_j (Vitter 1985 Algorithm R)	Al-Kateb-Lee-Wang ISJ 2014 SRS / SSDBM 2010	vector similarity domain 발현
B BIRCH CF-tree online cluster maintenance	(N_j, LS_j, SS_j) tuple incremental	Zhang-Ramakrishnan-Livny 1996 SIGMOD	paper period $P=50$ align
C paper Eq 2-6 통합 + Eq 5 group-aware augment	scalar new_size $\rightarrow$ cluster 별 분배	paper §V-B Eq 1-6 verbatim 100% 정합	$n_{inc,j} \propto N_j$ (Proportional 권장)
D Distribution-aware stratification	Equal/Prop/Neyman/Anti-Neyman + L2-L4 axis	RQ2 5-way baseline	Proportional default (sel=0.01 paradox 인정)

본 연구 의역 step-wise pseudo-code = paper Eq 1-6 verbatim **10 step** + 본 augment **7 step** = **17 step**. (paper 자체에는 algorithm pseudo-code 없음, Eq 1-6 + 산문 + hyperparam 7종 $m=0.9/\eta_0=0.1/\alpha=50/\beta=1.5/\gamma=0.99/\text{period}=50/N=385$)

3. paper 한계 보완 (L1+L5+L6)

ID	paper verbatim	본 보완
L1	§VI-B "sample size trajectory varies depending on the dataset" + "shifting workloads"	Component B+C distribution shift augment
L5	§VI-D SelNet only 비교 (CE4HD VLDB 2024 미비교)	3-way framework (Bernoulli + SelNet + 본 Form 1) — 5/27 phase 1
L6	§VII paper differentiation = sampling overhead 동적 axis (vs Lipton-Naughton 1990)	Component A+B streaming-aware base

4. 측정 plan

phase	scope	file	cost
5/27 phase 1	3-way 비교 (Bernoulli + SelNet + 본) + streaming workload simulation sf=100	1080 file	52-87h
6/11 phase 2	+ CE4HD partial + Ada-ef paper level + sf=10 streaming + drift 4 시나리오	+ 2100 file	+ 30-50h
post-6/11 future	+ Form 1 measurement 5 영역 full + multi-table + RELOAD align	+ 3000h	post-paper-grade

1001 file (기존 batch axis) = baseline + design 근거 (사전 학습 완료된 baseline framing). 폐기 X, complementary 영역.

5. timeline

- 5/14 18:00 회의 narrative v3 폐기 + Form 1 fix
- 5/15 (D-1) 14:00 박광현 미팅 (본 form)
- 5/27 (D-13) 발표 phase 1
- 6/11 (D-29) 보고서 phase 1 full + phase 2 partial
- post-6/11: EDBT short paper 10월 deadline (paper-grade publication 시도)

co-author: 박광현 corresponding + 임채림 first + 학부생 4명 (박세은 / 강재현 / 조현빈 / 이동욱)

6. ★ review 요청 항목 (12 영역)

박세은 9:09 + 9:27 영역 6 (이미 자체 답변 form 작성 + Form 1 통합) + 박광현 자문 6 = **12 항목**:

박세은 영역 (사전 답변 완료, 박광현 추가 review 요청):

1. (★★★ critical) "분포 알면 ECQO 가능?" → paper §V 도입부 verbatim ("without index" 가정) anchor. Form 1 = §V-B 영역 한정. 박광현 의견?
2. "RQ3 = 쿼리 실행 전 학습 필요" → 1001 file = 사전 학습 batch baseline framing. Form 1 streaming axis = 진짜 online incremental. 박광현 의견?
3. "0.1~0.5초 매 query 런타임?" → fit time SF=1 한정. 매 query fit X (paper period P=50 가정). Form 1 = per-tuple amortized. 박광현 의견?
4. "분포 안다" L1/L2/L3 분리 + paper §V-B 영역 = L_index outside. 박광현 의견?
5. "AS = single-table 不可" wording 정정 (구조 X = 구현 한계). 정확 framing 권장?
6. "Neyman paradox" → sel=0.01 한정 (sel=0.1 = Neyman best classical theory 정합). 정확 framing 권장?

박광현 자문 6 영역:

7. Form 1 main theme (Streaming-aware Distribution-Conscious) 학술 정당성?
 8. Component A+B+C+D framework axis novelty 평가 (개별 component 자체 신규 X — SRS/BIRCH/Cochran 1996–2014 reference 존재. framework 통합 novel)?
 9. 5/27 phase 1 timeline 52-87h 가능성?
 10. paper-grade publication venue 추천 (EDBT short / VLDB short / ICDE position 中)?
 11. 박광현 본업 영역 (RELOAD / CANNON / DFLOP) align 가능성?
 12. SelNet impl 8-12h cost + Q-error 재현 risk 10-20% — 5/27 phase 1 risk mitigation 권장?
-

6.5 ★ K granularity SF=1/10/100 추가 측정 결과 (5/14 22:00 완료, 박세은 8:50 후속)

박세은 8:50 발견 (회의 PDF v2 §2.5 SF=1 미측정) → 사용자 옵션 B 결정 → 추가 측정 완료. A5-scale-sf{1,10,100} (DEEP single, 3 cells) × K=10/30 × 4 anchor (sparse_rp/chao_weighted/hilbert_real/hyperloglog) × CaseA/CaseB = **48 file** 추가.

Method	K-pattern	SF=1 K=20 Δ%	SF=10 K=20 Δ%	SF=100 K=20 Δ%
sparse_rp	U-shape (K=10 +50~+90% 약화, K=20 sweet)	-11.70%	-6.58%	-11.20%
chao_weighted	K=20 sweet spot 모든 SF 일관	-14.11%	-6.00%	-12.20%
hilbert_real	K-robust + K=30 slight edge	-11.02% (K=30 -12.25%)	-6.07% (K=30 -6.96%)	-10.91% (K=30 -11.81%)
hyperloglog	K-robust + K=30 slight edge	-10.19% (K=30 -12.57%)	-5.15% (K=30 -6.01%)	-10.54% (K=30 -11.62%)

→ SF=1 영역 K=20 best 여부 = **method-dependent**. sparse_rp/chao_weighted = K=20 sweet spot.
hilbert_real/hyperloglog = K=30 slight edge.

→ SF=10 영역 **약한 효과 (-5~-7%)** = data size U-shape 가능성, paper §VI-B "shifting workloads" 정합. future work.

→ 회의 PDF v2 §2.5 "SF=1 영역 K=20 미측정" wording 정정 가능: **SF=1+10+100 axis 모두 측정 완료**, method-dependent K best 패턴 일관.

상세 분석: [experiments/results/analysis/km_granularity_sf_axis_SF1_SF10_SF100_20260515.md](#)

6.6 박세은 9:42 + 9:54 영역 — Neyman selectivity-dependent + over-statement 정정

박세은 9:42: "neyman 이 propotional 보다 좋은 건 sel=0.1 영역에서 맞음" (selectivity-dependent confirmed) 박세은 9:54: "전 q error 10% 감소 결과가 bernoulli 대비 neyman 이라고 생각했었어요..."

RQ2 5-way csv (rq2_DEEP_sf100_5way_allocation.csv + rq2_SIFT_sf100_5way_allocation.csv) 직접 aggregate verify:

dataset	sel	Neyman vs Bernoulli Δ%
DEEP	0.01	-7.64%
DEEP	0.1	-4.59%
SIFT	0.01	-2.58%
SIFT	0.1	-9.16% (가장 가까움)
POOL	0.01	-5.16%
POOL	0.1	-6.94%

→ "Bernoulli → Neyman -10%" narrative = over-statement (실제 -5~-9% 범위, 가장 큰 단일 cell = SIFT sel=0.1 의 -9.16%).

→ 회의 PDF v2 §3.2 line 532-533 "Proportional -9.61% / Neyman -8.75%" wording = csv 직접 aggregate (POOL Proportional -6.76% / Neyman -5.16%) 와 일치 X. 출처 source verify 필요.

→ RQ2 5-way 측정 = SF=100 (DEEP+SIFT) 한정. SF=1/SF=10/SSN 미측정.

6.7 박세은 9:09 #2 영역 (block + row hybrid) + 본문 답변 form 압축

박세은 9:09 #2 영역 (5/14 카톡): "block 단위 추출이 아니라 block + row hybrid 일 가능성?"

paper §V-B Eq 1 ($N=385$ 초기 sample budget) 이 unstratified random row 추출이고, Eq 5 ($\text{sampling_size}_{\{t+1\}}$ 동적 update) 가 row 단위. block sample 영역은 paper §V-B 자체 명시 X (paper §IV.6 row group block 영역과 영역 다음 — §IV.6 = HDF 데이터 layout, §V-B = sampling allocation). **본 연구 contribution scope = 추출 방식 random → stratified 정정, block/row 구조 outside.** paper source code level verify 미완 (정직 disclosure #9).

박광현 정확 framing 권장?

박세은 9 영역 답변 form 압축 (agent_J §1 base, full form 47.9 KB 자세 contents =

`_internal/handoff/active/agent_J_박세은_6영역_통합대응_답변form_20260515_0500.md`):

1. (★★★) 분포 알면 ECQO? → paper §V "without index" anchor. ECQO = HNSW (data graph, fit $O(n \log n)$ + memory $\text{base} \times 1.x \sim 2x$), 본 = K-means $K=20$ 메타 (15KB). cost 2-3 order 차이. complementary scenario (high-frequency stable = ECQO / ad-hoc/shifting = Form 1, paper §VI-B align).
2. RQ3 사전 학습 → 1001 file = batch baseline (cold start 1 회 fit 0.1-0.5초 + query ms). Form 1 streaming axis = per-tuple incremental online maintenance.
3. 0.1~0.5초 매 query? → fit time $SF=1$ 한정, cold start 1 회. 매 query fit X (paper period $P=50$ 가정). Form 1 = per-tuple amortized.
4. L1/L2/L3 → L1 (global skew flag, HHI) / L2 (cluster centroid, K-means $K=20$) / L3 ($+\sigma_j$ Neyman). RQ2 = L3 oracle 가정. L_index = paper §V-A 영역 (Form 1 outside).
5. AS single-table 不可 → 구조 X = 구현 코드 한계 (paper §V-B 자체는 OK). 임채림 자문 base (5/14 회의 14:57).
6. Neyman paradox → sel=0.01 한정 (Anti 1.540 < Prop 1.580 < Neyman 1.595). sel=0.1 = Neyman best (classical theory 정합, §6.6 표).

6.8 박세은 10:15 영역 (Anti-Neyman > Neyman = Neyman 가설 무효?)

박세은 10:15 카톡: "anti-neyman 이| neyman 보다 좋으면 neyman 가설 자체가 무효 아닌가?"

Neyman 가설 ($n_j \propto N_j \times \sigma_j$ 가 분산 최소) 자체 = 유효 (Neyman 1934 + Cochran 1977 §5.5 partial). 본 측정 데이터셋이 **Neyman 가정 (cluster 간 σ_j range 다양 + N_i CV $\neq 0$) 불만족 + selectivity-dependent:**

- **sel=0.01:** σ_j range 1.3-1.6× narrow + N_i CV=0 (cluster size uniform) → Neyman 의 σ -가중 효과 약함 → Anti-Neyman 1.540 > Proportional 1.580 > Neyman 1.595 (paradox)
- **sel=0.1:** σ_j range 더 확보 (sample size 증가 → variance 더 spread) + N_i CV $\neq 0$ → Neyman 본래 가설 정합 → Neyman best (SIFT sel=0.1 -9.16% = csv 가장 큰 단일 cell)

→ "Neyman 가설 무효" 영역 = **데이터셋 가정 위반 + selectivity-dependent 의 결과**. 가설 자체 무효 X. **σ_j oracle 가정 + 직접 측정 추가 검증 필요** (현재 RQ2 = L3 oracle, 본 측정 자체 σ_j 직접 estimate X).

박광현 정확 해석 권장? Cochran 1977 §5.5 (stratification with unequal variance) 추가 reference 가능성?

7. 정직 disclosure 14 영역 (cherry-picking 회피, 사전 명시)

(Agent A-J 7 + 박세은 6 통합)

1. paper §V-B 자체 algorithm pseudo-code 없음 (Eq 1-6 + 산문 + hyperparam 7종만). "14-step" 등은 본 연구 의역
2. framework axis novelty 한정 (각 component 자체 신규 X)
3. CE4HD VLDB 2024 github 미공개 — 5/27 폐기, 6/11 paper level 인용 only
4. Ada-ef arxiv 2512.06636 layer 다름 (HNSW ef search, cardinality estimation X)
5. SelNet [74] Q-error 재현 risk 10-20% (paper Fig.12 Q-error 5.53)
6. BIRCH CF σ_j^2 5-15% drift vs offline KMeans
7. batch axis (1001 file) vs streaming axis (Form 1 360 file) boundary
8. paper §V-B single-table 不可 = 구현 코드 한계 (구조 X). source code level verify 미완
9. paper §V-B sampling = block + row hybrid (block only X). source code level verify 미완
10. "분포 안다" L1/L2/L3 multi-layer 분리. RQ2 = L3 oracle (직접 측정 미완)
11. paper §V-B 영역 = "without index" 가정 — paper p.5 verbatim 명시 (Form 1 anchor)
12. RQ3 = 사전 학습 batch baseline. Form 1 streaming axis = phase 1 measurement 미완
13. 0.1~0.5초 fit time = SF=1 (1M rows) 한정. SF=10/100 미측정 (선형 scale-up SF=10 $\approx$ 1~5s, SF=100 $\approx$ 10~50s 추정)
14. **Anti-Neyman > Neyman $\neq$ Neyman 가설 무효** — Neyman 가설 ($n_j \propto N_j \times \sigma_j$ 가 분산 최소) 자체 유효 (Neyman 1934 + Cochran 1977 §5.5 partial). 본 측정 데이터셋이 Neyman 가정 (cluster 간 σ_j range 다양 + N_i CV $\neq 0$) 불만족 + selectivity-dependent (sel=0.01 paradox / sel=0.1 정합). σ_j oracle 가정 + 직접 측정 추가 검증 필요

8. fix 영역 vs 변경 가능 영역 (박광현 review 후)

영역	fix (변경 X)	변경 가능 (박광현 추천 적용)
main theme	✓ Streaming-aware Distribution-Conscious	
4 측면 (대체/보완/개선/추가검증)	✓	
paper §V-B "without index" 가정 anchor	✓ paper verbatim	
Component A+B+C+D 영역	✓	구현 detail 변경 가능
17-step pseudo-code 영역	✓ paper Eq 1-6 + 본 7 augment	
측정 plan 우선순위		△ SelNet / streaming workload / drift / CE4HD 우선순위
phase 1 / phase 2 timeline 분담		△ 5/27 / 6/11 / post-6/11 timeline
paper-grade publication venue		△ EDBT short / VLDB short / ICDE position
박광현 본업 align		△ RELOAD / CANNON / DFLOP 영역 통합 가능성

부록 — 본 form 작성 base

- Agent A (paper 재정독) + Agent B (검증, Agent A 신뢰도 78%) + Agent C (8 옵션 deep dive + Cochran 1977 §5.5 발견) + Agent D (paper §VI 한계 + 경쟁 paper + 박광현 BDAI 본업) + Agent E (Form 1 구체화) + Agent F (측정 plan + code plan) + Agent G (paper Eq 1-6 verbatim + 17-step + SelNet/CE4HD/Ada-ef reuse) + Agent H (1001 file batch baseline 재해석 + Form 1 통합) + Agent I (5/27 20 slide + 6/11 §별 세부) + Agent J (박세은 6 영역 답변 form) = **10 agent 호출 종합**
- 정정 룰 list 10 영역 (Agent 발견 2 + 박세은 발견 8, mass update 일괄 적용)
- K granularity 추가 측정 진행 중 ($A5\text{-}sf1+sf10+sf100 \times K=10/30 \times 4 \text{ anchor} \times 2 \text{ mode} = 48 \text{ file, server tmux}$)
- handoff v20 작성 예정

작성: 2026-05-14 21:50 KST · 5/14 18:00 회의 narrative v3 폐기 후 Form 1 fix + 박세은 6 영역 사전 대응 + 박광현 미팅 D-1 1-2 page review form