

연구 지도 확인서 (10 회차)

2026-1학기 종합설계프로젝트 — 속도는벡터 2026-05-24 작성 (10 회차, 5/22 ~ 5/28 sprint)

항목	내용
팀명	속도는벡터 (인종설)
소속	연세대학교 컴퓨터과학과
연구 주제	Exqutor 기반 단일 테이블 벡터 범위 쿼리에서의 분포 인지 표본 추출 단계 통제 실험 검증
원논문	Exqutor — Extended Query Optimizer for Vector-augmented Analytical Queries (arXiv:2512.09695v2)
작성일	2026-05-24 (10 회차)
제출자	박세은 (팀장)
지도 석사	임채림
지도 교수	박광현

1. 5/22 박광현 교수님 미팅 이후 5/24 까지의 진행 사항

지난 5월 22일 박광현 교수님 미팅 (실제 엔진 적용 검증 결과 보고) 이후 5월 24일까지 사흘간, 본 연구의 결과 정합성 audit + 사전 등록 통제 측정 전수 + 3-multi-AI 검증 + 발표자료·보고서·연구실 전달 자료 정정 sprint 를 진행하였습니다.

5월 23일 자체 audit (Codex 적대 검증) 평결 결과 본 연구의 89.1% 결합 우위가 분포 인지 효과로 단순 귀속될 수 없음이 확인되어, 5월 22일 미팅에서 박광현 교수님이 제안하신 narrative (#3 모든 변동을 분포 차이로 귀속) 를 reject 하고 "음성 · 방법론적 결과 (negative + methodological finding)" 로 재프레이밍하였습니다. 89% 우위의 진짜 메커니즘은 두 독립 추정량 평균의 분산 감소 효과 (일반 앙상블 효과) 가 지배적이며 분포 인지 method 는 그 위에 양의 효과를 더하지 못한다는 점이 사전 등록 dual-Bernoulli ensemble 통제 측정 (9 셀) 으로 입증되었습니다.

5월 24일 오전, 위 결론의 측정 공간 전수 검증을 위해 $25 \text{ 셀} \times 3 \text{ selectivity} \times 3 \text{ K} = 95 \text{ (cell} \times \text{sel} \times \text{K) tuple}$ 전수에 대해 dual-Bernoulli ensemble 측정을 수행하여 $95/95 = 100\%$ 가 결합 방식보다 더 정확함을 확정 (median $\Delta\%$ -5.98%), 박광현 교수님 회의 후 발표 deck 을 3-way 단순화 (베이스라인·단독 대체·결합) 로 재구성하기로 결정하였습니다.

5월 24일 오후 ~ 밤, Claude · Codex (GPT-5.5 xhigh effort) · Gemini (3.1 Pro) 3 모델로 본 연구의 정보 측정 수치·통계 검정·문헌 정합성을 적대 cross-check 진행 (종합 신뢰도 ~87/100, conditional pass). 검증 결과 발견된 정정 항목 15 건을 모두 발표 자료 · 보고서 · 본 자료에 반영하였습니다. 그 중 두 항목은 학술 정직성 차원에서 critical 입니다 — (1) 본 연구 16 method 중 8 method 의 명칭이 학술 알고리즘과 부분 불일치하여 rename 진행 (`hilbert_real` → `pca2d_hilbert_xy2d` 등), (2) §4.4 method ranking 1·2위 (구 `hilbert_real` · `skilling_hilbert`) 의 우위는 고차원 공간 곡선 효과가 아니라 PCA 환원 + 후속 알고리즘 hybrid 의 효과로 재해석.

본 확인서는 5/22 미팅 이후 sprint 의 누적 결과와 5/26 발표 deck 제출·6/11 최종 보고서 마감 직전 단계의 정합성 audit 결과를 보고드리는 자료입니다.

2. 5/22 ~ 5/24 sprint 결과 종합

2.1 실제 엔진 적용 검증 — 결합 방식의 plan 회복 robustness 확정

본 연구의 결합 카디널리티 추정값을 Exqutor patched pgvector 의 SeqScan 카디널리티 자리에 주입하여 측정한 $12 \text{ 셀} \times 16 \text{ variant} \times 15 \text{ 회 반복} = 2,880 \text{ measurement}$ 결과, 정답 plan oracle 의 평균 가속이 기본 pgvector 대비 5.67× (보고서 §5.2 verbatim, range 2.93×~7.40×) 로 견고하게 확정되었습니다 (paired Wilcoxon 검정 anchor=baseline 180/180 = 100% 유의 + 100% large effect).

특히 결합 13 method 가 정답 plan 으로 회복한 비율이 148/156 = **94.9%** 로 베이스라인 단독 (7/12 = 58.3%) 대비 plan 회복 robustness 가 큰 폭으로 향상되었으나, 베이스라인 · 결합 · oracle 세 inject 의 latency 자체는 paired Wilcoxon (anchor=B1, 168 비교) 결과 13/168 = 7.7% 만 유의 · 86.9% 가 small effect 로 사실상 동등함이 확인되었습니다. 변동 분해 (3 조건 모델, n=2,250, R²=0.83) 에서 조건 (B1·CaseB·oracle) % SS = 0.00% · p = 0.945 로 latency 동등성이 통계적으로 확정됩니다. 즉 추정 정확도 향상이 plan 회복 robustness 로 변환되지만 latency 추가 가속으로 직결되지 않는 구조적 한계가 본 연구의 핵심 finding 입니다.

2.2 사전 등록 통제 측정 — 89% 우위 메커니즘 규명

본 연구의 1,508 셀 3-way matched 측정에서 결합 (CaseB) 이 베이스라인 (B1) 을 89.1% (1,344/1,508) 에서 이긴다는 결과 (median Δ% -4.38%) 가 분포 인지 효과인지 일반 통계 효과인지 검증하기 위해 method 자리에 또 다른 독립 무작위 베르누이를 둔 dual-Bernoulli ensemble 통제군 (CaseC) 측정을 두 단계로 수행하였습니다.

5월 23일 v14 사전 등록 9 셀 측정 (mean qe_trim = 1.3729, 9/9 셀 모두 결합보다 우월, Δ% vs B1 = -13.32%, Δ% vs CaseB = -6.75%) 으로 1차 입증한 후, **5월 24일 오전** v16 95 tuple 전수 측정 (mean = 1.3060, 95/95 = 100% better, median Δ% vs B1 = -11.32%, vs CaseB = -5.98%) 으로 측정 공간 전수에서 통제 측정 결론이 강하게 재확인되었습니다. 두 독립 베르누이 추정량 평균이 분포 인지 결합보다 일관되게 더 정확하다는 점 — 즉 **89% 우위의 메커니즘은 분포 인지 효과가 아니라 두 독립 추정량 평균의 분산 감소 효과가 지배적이며, 분포 인지 method 는 그 위에 양의 효과를 더하지 못한다** — 이 negative · methodological 결과의 측정 전수 검증입니다.

2.3 3-multi-AI 검증 — 정보 수치·통계·문헌·method 명칭 cross-check

5월 24일 오후 본 연구의 모든 정보 수치·통계 검증·문헌 정합성·method 명칭 학술 정직성을 Claude (자체 정보 raw 직접 read·재계산) · Codex (적대 코드 read·통계 재계산) · Gemini (학술 reference·naming convention·paradigm taxonomy) 3 모델로 적대 cross-check 진행하였습니다. 종합 신뢰도 ~87/100, conditional pass 판정. 발견된 정정 항목 15 건을 모두 반영:

(1) **수치 drift 10 건** — 발표자료 storyline 에서 잘못 carry 된 trim mean 1.944/1.984/1.477 → 정정 1.4582/1.6359/1.4019 (1,508 셀 raw 재계산), 가속 배수 4.43×/4.46×/4.54× → 5.77×/5.70×/5.65× (12 셀 mean gain), v14 9 셀 평균 1.5843·1.4734 → 1.5838·1.4723 (drift 정정) 등

(2) **표기 정정 3 건** — 보고서 §5.4 Hedges' g 보정식 $j = 1 - 3/(4n - 9)$ → $j = 1 - 3/(4n - 5)$ (paired df = n - 1, code analyze_latency.py 는 정확), 보고서 §5.5 variance decomposition "Type-III SS 분해" → "Type-I 순차 % + Type-III partial p" (Codex T4 fix carry 명시), plan 분포 source "168 paired-cell" → "700 paired-cell (3 평면 통합)" 등

(3) **method 명칭 정직성 8 건** — Codex (code 직접 read) + Gemini (학술 reference) 양 모델 일치 발견, 본 연구 16 method 중 8 method 의 명칭과 실제 구현 사이 부분 불일치. 학술 사기 (fraud) 위험 우려로 즉시 정정:

이전 명칭	정정 후	사유
hilbert_real	pca2d_hilbert_xy2d	PCA 2D 환원 후 Hilbert (고차원 X)
skilling_hilbert	pca4_skilling_hilbert_approx	PCA 4D 환원 + approx
zorder_morton	pca2d_zorder_morton	PCA 2D 환원 명시
mhist2	pca2d_equi_depth_grid	MaxDiff 미사용 (equi-depth)
hyperloglog	md5_prefix_hash_bucket	카디널리티 estimator 미사용
lavallee_hidiroglou	takeall_cumsqrtf	Neyman σ _h 미적용
rabitq_strat	rabitq_1bit_bucket	1-bit sign only
sparse_rp (carry)	reference 정정 only	Li-Hastie-Church 2006 정보 (Achlioptas 2003 → 정정)

핵심 narrative 정정: 본 연구 ranking 1·2위 (구 hilbert_real·skilling_hilbert) 의 우위는 **고차원 공간 곡선의 효과가 아니라 PCA 분산 요약 + 공간 채움 곡선 hybrid 의 효과** 로 재해석. paradigm 분류도 P9 InfoTheoretic 폐지·P5b Hashing 신설, P5 QMC → Classical Stratification 으로 정정.

(4) **paradigm 재분류 2 건** — 위와 같이 P9·P5 라벨 정정 + PCA 환원 prefix 명시

2.4 산출물 정정 반영 완료

본 검증 결과는 다음 4 산출물 모두에 반영하였습니다: - 보고서 6/11 정보 (§3.6 paradigm 표 · §4.3 method ranking · §4.7 honest limitation · §5.4 Hedges 식 · §5.5 variance text · §6.1 권장 표) - storyline v3 (5/27 발표 deck base, slide 8 paradigm grid 정정 + 수치 10 건) - 임채림 연구원 전달용 구체적 데이터 (v2 재구성분, 처음 본 사람도 이해 가능한 본연 의미 중심) - 본 연구지도확인서 10 회차 (학교 표준 양식)

3. 향후 일정 (5/25 ~ 6/11)

일자	작업
5/25 (일)	발표 deck PPTX 시안 생성 (Claude Design + Gemini Ultra Nano Banana Pro brief 기반) · 리허설
5/26 (월) 23:59	★ 5/27 발표 슬라이드 LearnUs 제출 마감 · 본 연구지도확인서 10회차 동반 제출
5/27 (수) 15:00 D504호	1차 최종 발표 (10 분 + 5 분 Q&A)
5/28 (목) 12:00	포스터 (900×1200 mm PDF) + 소개영상 (YouTube unlisted/public + QR 코드) LearnUs 제출 마감
5/29 (금) 15:00 D504호	2차 최종 발표
6/3 (화)	임시공휴일 (선거)
6/5 (금) 9:00-18:00	전시회 (제3공학관 로비, 학생 모임 15:00 504호)
6/10 (수)	박광현 교수님 마지막 세미나
6/11 (목) 23:59	★ 최종 보고서 (compact 15p) + 상호평가 결과 LearnUs 제출 마감

4. 본 연구의 contribution (5/24 update)

- (1) **표본 선택 단계의 controlled verification experiment** — Exqutor 논문 \$V-B\$ 적응적 표본 추출의 hyperparam·식 1-6·표본 예산 \$N=385\$ 는 모두 carry 한 채 표본 선택 단계 하나만 통제 변인으로 분리하여 5 데이터셋 × 5 조작 변인 × 16 method × 3 mode matched = 1,508 측정으로 전수 검증한 것이 본 연구의 가장 큰 contribution 입니다. 새 알고리즘 제안이 아닌 정량 검증입니다.
- (2) **89% 결합 우위 메커니즘 규명 (분포 인지 효과 X · 양상불 분산 감소 효과 지배)** — v13 (1,508 셀, 3-way matched) · v14 (9 셀 사전 등록 통제 측정) · v16 (95 tuple 전수 검증) 의 3 단계 측정으로 결합 우위의 진짜 메커니즘이 분포 인지 효과가 아니라 두 독립 추정량 평균의 분산 감소 효과 (일반 양상불 효과) 가 지배적임을 입증. 분포 인지 method 가 dual-Bernoulli ensemble 위에 양의 효과를 더하지 못한다는 점이 본 연구의 negative · methodological 결과의 핵심.
- (3) **plan 회복 robustness vs latency 동등 의 분리** — 결합 13 method 정답 plan 회복 148/156 = 94.9% (베이스라인 7/12 = 58.3% 대비 큰 폭 향상) · paired Wilcoxon (anchor=B1, 168 비교) 13/168 = 7.7% 만 유의 · 86.9% small effect · 변동 분해 조건 % SS = 0.00% (p=0.945) — 본 결과는 plan 회복과 latency 의 의미를 분리해 해석해야 함을 보여주며, 결합 방식의 실제 가치가 latency 추가 가속이 아니라 plan 회복 robustness 자체에 있다는 finding 입니다.
- (4) **method 명칭 학술 정직성 audit 및 정정** — 본 연구 16 method 의 명칭과 실제 알고리즘 구현 사이 부분 불일치 8 건을 3-multi-AI cross-check 로 발견하여 정정. 특히 ranking 상위 method 의 우위가 고차원 공간 곡선·정보 이론 등 paradigm 본질의 효과가 아니라 PCA 환원 + 후속 알고리즘 hybrid 의 효과임을 학술 정직성 차원에서 명시. 본 finding 은 추후 후속 연구에 본 연구의 method baseline 활용 시 misleading 위험을 사전 차단하는 가치를 가집니다.
- (5) **engine layer · pre-processing layer 분리** — 본 연구는 PostgreSQL Exqutor patched pgvector 의 GUC 카디널리티 주입 (engine layer) + 표본 추출 단계 (pre-processing layer) 분리 측정 framework 로, 두 layer 의 효과·한계를 독립적으로 정량화한 것이 후속 연구를 위한 framework 가치입니다.

5. Limitation 자기 점검 (5/24 update)

- (1) **측정 공간 한정**: 본 연구의 1,508 측정 portfolio 는 의도된 구조화 분할 (의도 max 3,600 대비 41.9%) 이며 완전 요인 설계가 아닙니다. \$K=20\$ · sel=0.01 중심으로 측정 밀도를 두텁게 두었고, A2-Fig8 (DEEP+CC3M sf=10, 1024d) 은 16 method 중 4 method 만 측정한 최소 cell 입니다. 실제 엔진 측정은 sf=10 환경 (DEEP·SIFT·SSN·YFCC 4 데이터셋, 56 셀) 에 한정되었습니다.
- (2) **WIKI sf=10 실제 엔진 측정 불가**: 768d SeqScan 이 statement_timeout (180 초) 초과 — 본 한계는 측정 자체의 불가능이며 honest exception 으로 명시합니다.
- (3) **scale factor sf=1·100 실제 엔진 측정 부분/미진행**: sf=1 은 작은 테이블이라 IndexScan 경로 선택 → 카디널리티 주입 미발동 (plan-invariant), sf=100 은 향후 작업의 carry-over 입니다.

(4) **타 엔진 미측정**: VBASE · DuckDB-vss · Milvus 는 본 연구 scope 외 (Future Work 의 첫 갈래).

(5) **method 명칭 정직성 한계** (5/24 audit 결과 반영): 본 연구의 16 method 중 8 method 의 명칭과 실제 구현 사이 부분 불일치를 발견하여 정정하였습니다. ranking 상위의 PCA 환원 hybrid method 의 우위는 고차원 paradigm 본질의 효과가 아닌 PCA + 후속 알고리즘 hybrid 의 효과로 해석해야 합니다 (보고서 §4.7 verbatim carry).

(6) **통계 검정 floor**: trial 10 회로 한쪽 꼬리 Wilcoxon 최소 p값 $1/1024 \approx 0.001$ 에 물리는 한계가 있어 method · paradigm 우열은 p값보다 $\Delta\%$ · 효과 크기 (Hedges' g · Cliff's δ) 로 판단합니다.

(7) **89% 우위 vs 메커니즘 narrative 의 분리**: "결합이 베이스라인을 89% 이김" 은 측정 사실이나, 이를 "분포 인지 method 의 효과" 로 단순 귀속하면 잘못된 결론입니다. 본 연구의 통제 측정 (v14-v16) 이 분포 인지 효과의 부재 + 앙상블 분산 감소 효과의 지배를 입증하므로, 발표·보고서·외부 공유 자료에서 메커니즘 표현을 엄격히 분리합니다.

6. 검토 요청 사항

박광현 교수님 · 임채림 연구원께 다음 사항에 대한 검토 의견을 요청드립니다.

(1) **3-way 발표 단순화의 narrative 적절성** — 5/22 미팅 이후 결정한 5/27-5/29 발표 deck 3-way (베이스라인 · 단독 대체 · 결합) 단순화 + 사전 등록 통제 측정 (CaseC) 은 보고서 6/11 만 carry · 발표에선 제외하는 narrative 결정이 학부 캡스톤 10 분 발표 청자 기준에서 적절한지의 검토.

(2) **method 명칭 정정 8 건의 정정 권고** — 본 연구의 ranking 상위 (구 hilbert_real · skilling_hilbert · zorder_morton · mhist2 등) 가 PCA 환원 hybrid method 임이 audit 으로 발견되어 명칭 정정 (`pca2d_hilbert_xy2d` 등) · paradigm 재분류 (P9 InfoTheoretic 폐지 등) 진행한 결과의 학술적 권고. 특히 채림님께 본 연구 method baseline 의 정직한 알고리즘 정합성 명시가 후속 연구 활용 시 misleading 위험을 사전 차단하는 가치가 있다고 판단합니다.

(3) **89% 우위 메커니즘 narrative 의 보수적 표현** — "분포 인지 method 가 우월" 이 아니라 "두 독립 추정량 평균의 분산 감소 효과가 지배적" 으로 표현 강도를 보수적으로 낮추는 narrative 가 학술 정직성 차원에서 적절한지의 권고.

(4) **plan 회복 robustness 의 발표 강조 정도** — 본 연구의 latency 효과는 음성 (베이스라인·결합·oracle 동등) 이나 plan 회복 robustness 는 결합의 강한 contribution (94.9% vs 58.3%) 으로 분리. 발표에서 plan 회복의 가치를 어느 정도로 강조하는 것이 적절한지 권고.

(5) **Future Work 두 갈래 narrative** — (a) 검증 범위 확장 (sf·타 엔진·산업 자원) (b) history-aware adaptive sampling (유사 query 의 과거 selectivity feedback 누적으로 sampling cost 감소 + latency 개선 가능성) 두 방향을 발표 slide 11 + 보고서 §6.4 에 carry. 본 두 방향의 학술·산업 가치 우선순위에 대한 권고.

7. 첨부 자료

- 보고서 6/11 정본 (정정 후): `submission/_drafts/속도는벡터_6_11_최종보고서_20260523_215000.{md,pdf}`
- 5/27 발표 storyline v3 (정정 후 정본): `submission/_drafts/속도는벡터_5_27_최종발표_storyline_v3_3way_20260524_220405.{md,pdf}`
- 임채림 연구원 전달용 구체적 데이터 (v2 재구성본): `submission/_drafts/속도는벡터_채림님_전달용_구체적_데이터_v2_재구성_20260524_233327.{md,pdf}`
- 5/22 실제 엔진 적용 검증 실험 정리: `submission/_drafts/속도는벡터_엔진적용검증_실험정리_20260522_173533.{md,pdf}`
- 측정 정본 raw 데이터: `_internal/cache/rq3/aggregated_v13_full.parquet` (1,508 셀 × 3 mode matched, 4,524 행) · `_internal/cache/rq3/aggregated_v14.parquet` (9 셀 사전 등록 통제군) · `_internal/cache/rq3/paper_exact_v16_summary_20260524_122419/v16_full95_paired.parquet` (95 tuple 전수)
- 실제 엔진 측정 raw + 통계: `_internal/cache/rq3/latency/{phase2,phase3,phase4_extension,poc_6_4,poc_6_4_extended}/`

- 3-multi-AI 검증 prompt + 결과: `_internal/state/multimodel_verification_{codex,gemini}_prompt_20260524_*.md` · `_internal/state/method_naming_verification_{codex,gemini}_prompt_20260524_*.md`
- 서버 측정 raw 백업 (NPY 제외, 474 MB · 2,507 파일): `experiments/server_backup_20260524_223129/`

본 확인서를 통해 보고드린 5/22 미팅 이후 *sprint* 의 누적 결과 (실제 엔진 적용 검증 + 사전 등록 통제 측정 전수 + 3-multi-AI 검증 + *method* 명칭 정직성 정정) 를 토대로 5/26 23:59 발표 *deck* 제출 · 5/28 12:00 포스터·소개영상 제출 · 6/11 23:59 최종 보고서 제출의 *critical path* 를 안전하게 진행하겠습니다. 검토 의견을 회신해 주시면 발표·보고서에 반영하겠습니다. 감사합니다.

— 속도는벡터 일동