

# 속도는벡터 중간발표 슬라이드 구조 v2

발표일: 2026-04-28 (화) — D-11

팀: 속도는벡터 (박세은, 강재현, 조현빈, 이동욱)

주제: Exqutor 기반 벡터 증강 분석 쿼리의 단일 테이블 사각지대 개선

발표 시간: 10분(발표) + 5분(Q&A) 가정

본 문서의 역할: 발표자(팀원 분담 예정)가 참조할 구조 md. 각 장(슬라이드)은 ## 로 구분, 화면 본문 + 발표자 스크립트 + 예상 Q&A를 포함.

v2 업데이트: 4/16~17 보강 측정 반영 — 5-seed CI 3 데이터셋, Two-Level Decomposition, HHI/CV 정량, RQ3 7-way 설계안

기반 문서: `submission/속도는벡터\_중간보고서\_20260417\_0000.md`, `experiments/results/RQ1\_RQ2 실험 결과 정리.md`, `plans/RQ3설계안\_20260416\_213500.md`

## Slide 1 — 표지


**제목:** Exqutor 벡터 카디널리티 추정의 단일 테이블 사각지대와 Skew-Aware Sampling **부제:** Pivot A BERNOULLI 교체 + Pivot C KM20 Stratified + 3 데이터셋 5-seed CI 검증 **팀명:** 속도는벡터 **소속:** 연세대학교 컴퓨터과학과 2026-1 캡스톤 디자인 **발표자:** 박세은 / 강재현 / 조현빈 / 이동욱 **날짜:** 2026-04-28

**발표자 스크립트 (15초)**

안녕하세요. 속도는벡터 팀입니다. Exqutor 논문의 Adaptive Sampling 이 단일 테이블 벡터 범위 쿼리에서 사각지대를 가진다는 발견과, 이를 두 단계로 해소한 결과, 그리고 3 데이터셋 교차 검증까지 발표하겠습니다.

## Slide 2 — 실험 타임라인 (Flow Diagram)

화면 본문



- 파란색 = 확정 결과, 주황색 = boundary condition, 별표 = 유효 anchor
- v2 의 4/16~17 보강 branch 가 외적 타당성 결손을 해소

#### 발표자 스크립트 (20초)

4월 3일 교수님 합의에서 출발해 4월 17일까지의 실험 흐름입니다. 원래 가설은 기각되었지만 Exqutor의 구조적 사각지대를 발견했고, 두 가지 개선을 네이티브로 구현했습니다. 4월 16~17일의 보강 측정에서 5-seed 신뢰구간과 3 데이터셋 교차 검증으로 외적 타당성을 확보했으며, Two-Level 분해로 "공간 인식" 기여를 정량화했습니다.

## Slide 3 — 연구 배경: Exqutor 와 벡터 카디널리티 추정 문제

**화면 본문** - pgvector / VBASE / DuckDB 는 벡터 조건의 선택도를 **고정 비율** 로 추정 (33.3% / 50% / 100%) - 실제 선택도는 query 에 따라 **0.001% ~ 90%** 까지 다양 - → 옵티마이저가 잘못된 실행 계획 선택 (nested loop vs hash join, index 사용 여부) - **Exqutor** (arXiv:2512.09695v2, 2024) 의 두 해법 - **ECQO**: HNSW 인덱스가 있을 때 range query 를 직접 실행해 1~2 ms 로 정확 카디널리티 - **Adaptive Sampling**: 인덱스가 없을 때 모멘텀 기반 동적 샘플링 - pgvector 최대 1000 배, VBASE 10000 배, DuckDB 1.5~37 배 성능 향상 달성

**figure placeholder**: Exqutor 논문 Figure 1 또는 본 팀이 제작성한 "추정 vs 실제 선택도" 개념도

#### 발표자 스크립트 (35초)

Exqutor 는 벡터 데이터베이스 카디널리티 추정 정확도 문제의 최신 해법입니다. 기존 시스템은 고정 비율 추정이라 옵티마이저의 실행 계획이 잘못되는 경우가 많았고, Exqutor 는 두 가지 해법 — ECQO 와 Adaptive Sampling — 로 이를 해소했습니다. 본 연구는 Adaptive Sampling 의 정확도 개선 여지를 공략 합니다.

**예상 Q&A** - Q: ECQO 와 Adaptive Sampling 중 어느 쪽을 다루나요? → A: Adaptive Sampling 만. ECQO 는 인덱스가 있을 때의 정확 해법이므로 개선 여지가 적습니다.

## Slide 4 — 연구 질문 (RQ1 / RQ2 / RQ3)

**화면 본문 - RQ1 (Motivation):** Exqutor Adaptive Sampling 은 실제로 정확도 한계를 가지는가? 한계의 구조는? - **RQ2 (Distribution-Aware):** 분포를 알 때, stratified sampling 이 카디널리티 추정 정확도를 얼마나 개선하는가? - **RQ3 (Distribution-Agnostic):** 분포를 모를 때, 사전 학습 없이 KM20 의 공간 인식 효과를 얼마나 회수할 수 있는가? - Recovery Rate = (방법X - RANDOM20) / (KM20 - RANDOM20) - 3 패러다임 (Offline Partition / Online Query-Adaptive / Weight-based) × 7 가지 방법 - 4/3 교수님 미팅 확정. **본 발표 범위:** RQ1 Motivation + RQ2 본선 구현 + 5-seed CI + RQ3 설계안


**발표자 스크립트 (25초)**

연구 질문은 3 단계입니다. RQ1 에서 정확도 한계를 정량 측정하고, RQ2 에서 분포를 알 때의 개선을 측정하며, RQ3 에서 분포를 모를 때 공간 인식 효과를 얼마나 회수할 수 있는지를 Recovery Rate 프레임워크로 비교합니다. 오늘은 RQ1 과 RQ2 의 결과와 RQ3 의 설계안까지 다루고, RQ3 실험은 최종발표에서 보고합니다.

## Slide 5 — 4/14 실험 1단계: H1 기각과 글로벌 skew 지표의 무효화

**화면 본문 - 실험:** `partsupp_deep_10` 1M subset, 96d DEEP, 100 query × 6 selectivity × 5 seed = 3000 Adaptive Sampling 측정 - **가설 H1 (4/3):** Fisher  $\gamma$  큰 그룹의 Q-error 가 작은 그룹 대비 2 배 악화 - **결과:** 12 조합 모두 ratio  $\approx 1.0$ , 24 조합 모두 `!Spearman  $\rho$`  < 0.2 - 100 query 전부 Fisher  $\gamma$  < 0 (left-skewed), tail ratio P99/P50  $\in [1.07, 1.17]$  좁은 범위 → **고차원 거리 집중** - 추가 검증: **로컬 4 지표도 전수 무효** (k-NN entropy, PCA EVR1, KDE modality, NN clustering) - 글로벌 4 + 로컬 4 = **8 지표 전수 검증 후 query-conditional layer 정의 사전 식별 불가능**

Figure 6 — Phase 5 Local skew 24 조합 Spearman  $\rho$  (negative result: 모두  $|\rho| < 0.2$ )



#### 발표자 스크립트 (50초)

4월 14일 1 차 실험에서 원래 가설을 기각했습니다. Fisher  $\gamma$  등 글로벌 4 지표 모두 Q-error 와의 Spearman 상관이 0.2 미만이었고, 로컬 4 지표까지 확인했지만 24 조합 모두  $|\rho| < 0.2$  로 무효화되었습니다. 학술적 의미는 "고차원 벡터에서 query-side feature 로 layer 를 사전 정의하는 것이 불가능하다" 는 정량 negative result 이며, 이는 본 연구 motivation 의 한 축이 됩니다.

**예상 Q&A** - Q: Spearman  $|\rho| < 0.2$  라는 threshold 는 어디서 왔나요? → A: 설계안 pre-specified. Cohen (1988) 의 small effect size 0.10 을 넘는 선에서 설정. - Q: 100 query 가 모두 left-skewed 라는 건 query 선택 편향 아닌가요? → A: DEEP 벡터 전체에서 무작위 추출한 결과로 데이터셋 자체의 성질입니다.

## Slide 6 — Exqutor Design Constraint 발견 (본 연구의 새 motivation 첫 줄)

**화면 본문** - 4/14 오후 Phase 3 옵션 A 네이티브 검증 시도에서 발견 - (i) Hook Trigger 사각지대: `vector.c` line 243 `if (table_count > 2)` — 단일 테이블 vector range query 는 Exqutor hook 경로에서 배제 - 모든 query 가 PG default selectivity 1/3 (= 333,333 행) 로 fall-through - (ii) Plan Replacement 부작용: hook 을 `>= 1` 로 우회하면 outer query 의 plan-tree 가 `Sample Scan` 으로 교체 - true = 100,000 query 의 `SELECT count(*)` 가 sample 안 부분 카운트 32 로 격하 - 본 두 finding 은 Exqutor 원논문 본문에 명시되지 않음. 소스 검증으로 첫 정량 확인 - → 단일 테이블 vector range query (이미지 검색 / 추천 / RAG retrieval) 는 Exqutor 의 명시되지 않은 사각지대

**figure placeholder:** `vector.c` line 243 의 소스 코드 스니펫 + EXPLAIN ANALYZE 의 Sample Scan 노드 출력 (2 column)

## 발표자 스크립트 (1분)

저희는 Python 재구현과 Exqutor 네이티브의 동치성을 검증하려는 과정에서 두 가지 design constraint 를 발견했습니다. 첫째, Exqutor 의 Adaptive Sampling hook 이 `table_count > 2` 조건으로 단일 테이블 vector range query 를 경로에서 배제합니다. 둘째, hook 을 한 줄 우회해도 outer query 의 plan-tree 가 `Sample Scan` 으로 교체되어 outer query 결과 자체가 부분 카운트로 격하됩니다. 두 finding 은 Exqutor 가 multi-table join 시나리오를 가정한 해법임을 보여주며, 단일 테이블 vector range query — 이미지 검색, 추천, RAG retrieval 같은 실무 시나리오 — 는 명시적으로 배제된 사각지대입니다. 본 두 발견 이 저희 연구의 새 motivation 첫 줄입니다.

**예상 Q&A** - Q: 왜 `table_count > 2` 조건인가요? → A: Exqutor 논문이 multi-table join + vector range filter 를 본선 시나리오로 가정했기 때문. 저자가 본선 시나리오에서만 hook 이 활성화되도록 설계한 의도로 추정. - Q: `>= 1` 로 바뀌어서 실험한 건 Exqutor 와 다른 시스템이 되는 것 아닌가요? → A: 네. 본 팀의 측정은 `>= 1` 수정 상태에서 수행되었고, 두 모드 (BERN, STRAT) 비교는 모두 같은 plan replacement 경로 위에서 이뤄지므로 상대값 비교는 유효합니다. 변경된 `vector.c` 와 원본 백업을 모두 보존.

## Slide 7 — 수정 노선: Pivot A + Pivot C 병합 (4/14 17:35 KST 확정)

**화면 본문** - Pivot A — Block sampling bias 제거 - `vector.c` L889 의 `TABLESAMPLE SYSTEM(%f)` → `TABLESAMPLE BERNOULLI(%f)` (한 줄 교체) - Fair baseline 도구: 단독 기여가 아닌 Pivot C 의 측정 단위 - Pivot C — Data-side k-means K=20 stratified sampling - `vector.c` +228 줄: GUC 3 개 + stratum\_sizes 캐시 + `estimate_cardinality_with_stratified_sampling` - numpy mini-batch k-means K=20 으로 data-side partition (seed=42) - `stratum_id smallint` 컬럼 + index 사전 부여 → query 시점 overhead 0 - per-stratum `ORDER BY random() LIMIT sample_size/K` + Horvitz-Thompson 가중 추정  $est = \sum (n_i \cdot cnt_i / s_i)$  - 두 Pivot 은 직교적 → SYSTEM / BERNOULLI / STRATIFIED × dataset × selectivity 의 ablation matrix 로 각 기여 분리

## 발표자 스크립트 (50초)

본 두 finding 위에서 두 가지 sanitize 를 병합한 수정 노선을 확정했습니다. Pivot A 는 Exqutor 의 `TABLESAMPLE SYSTEM` 을 `BERNOULLI` 로 한 줄 교체해 block sampling bias 를 제거하는 fair baseline 도 구입니다. Pivot C 는 data-side k-means K=20 으로 데이터를 partition 한 후 stratified sampling 을 native 로 구현합니다. 두 Pivot 은 직교적이므로 ablation matrix 로 각 기여를 분리 측정합니다.


## Slide 8 — Phase 4 결과: Pivot A (BERNOULLI) Native 검증 ★

화면 본문 - 측정: 100 query × 6 selectivity × 1 seed × 2 mode = 1200 query, Exqutor 네이티브 PG 55436 - paired Wilcoxon (alt: SYSTEM > BERNOULLI)

| selectivity  | SYS median | BERN median | diff%        | p                 | 유의         |
|--------------|------------|-------------|--------------|-------------------|------------|
| 0.001        | 2.597      | 2.597       | +0.0         | 0.596             | —          |
| 0.010        | 1.558      | 1.299       | +20.0        | 0.240             | —          |
| <b>0.050</b> | 1.203      | 1.195       | <b>+0.7</b>  | <b>0.0009</b>     | <b>★★</b>  |
| <b>0.100</b> | 1.212      | 1.132       | <b>+7.0</b>  | <b>&lt; 0.001</b> | <b>★★★</b> |
| <b>0.300</b> | 1.210      | 1.079       | <b>+12.0</b> | <b>&lt; 0.001</b> | <b>★★★</b> |
| <b>0.500</b> | 1.153      | 1.052       | <b>+9.6</b>  | <b>&lt; 0.001</b> | <b>★★★</b> |

- 4 selectivity 구간에서  $p < 0.001$  — block sampling bias 는 통계적으로 유의한 구조적 약점
- `vector.c` 한 줄 교체로 Exqutor 카디널리티 추정 개선 경로 확보

SYSTEM vs BERNOULLI paired Q-error — 유의 구간 4 panel (s=0.001 tie, s=0.010 n.s. 제외)



### 발표자 스크립트 (55초)

Pivot A 의 정량 검증입니다. 네이티브에서 4 selectivity 구간 — s=0.05, 0.1, 0.3, 0.5 — 모두 paired Wilcoxon  $p < 0.001$  로 SYSTEM 의 q-error 가 BERNOULLI 보다 통계적으로 유의하게 큼니다. s=0.5 에서 median 기준 약 9.6% 개선으로 가장 큰 효과를 보였습니다. `TABLESAMPLE SYSTEM` 에 block 단위 샘플링의 구조적 bias 가 존재하며, 한 줄을 `BERNOULLI` 로 교체하는 것만으로 제거할 수 있다는 것이 native 로 직접 확인되었습니다.

**예상 Q&A** - Q:  $s=0.001$  에서 SYS 와 BERN 이 같은 이유는? → A: 두 모드 모두 sample 안 matching count 가 0 에 가까워 Exqutor 의 `cnt=0 → 1` clamp 가 발동. 이 영역은 sampling method 와 무관하게 구조적으로 변별 불가능.

## Slide 9 — Phase 6 Step 4 결과: Pivot C (KM20) + 5-seed 신뢰구간




**화면 본문** - 측정: 100 query × 5 selectivity × **5 seed** × 2 mode (BERN + STRAT KM20), native 경로 - `vector.c` +228 줄 구현: GUC 3 개 + stratum\_sizes 캐시 + stratified SPI SQL + HT 가중 추정 - data-side: `partsupp_deep_10_subset_1m` 에 `stratum_id smallint` 컬럼 + index 사전 부여

**DEEP 1M 5-seed 결과 (95% CI 하한 양수 확정)**

| selectivity | 5-seed 평균 | 95% CI         | 유의한 seed            |
|-------------|-----------|----------------|---------------------|
| 50%         | +1.64%    | [+1.11, +2.18] | 5/5                 |
| 30%         | +2.62%    | [+1.45, +3.80] | 5/5 ( $p < 0.001$ ) |
| 10%         | +4.19%    | [+0.72, +7.66] | 5/5 ( $p < 0.004$ ) |
| 5%          | +1.85%    | (단일)           | 3/5                 |
| 1%          | +8.93%    | (단일)           | 4/5                 |

- **$s=0.500$  1-seed**:  $p = 4.01e-05$  (Bonferroni 유일 생존)
- **5-seed 재현**: mean +1.64%, CI [+1.11, +2.18] — **하한 양수로 real effect 확정**
- 50%/30%/10% 세 구간 모두 CI 가 0 을 포함하지 않음

Figure 2 — Phase 6 Step 4 BERNOULLI vs STRATIFIED (KM20, native, 100 query)



#### 발표자 스크립트 (1분 10초)

Pivot C의 핵심 결과입니다. `vector.c`에 +228 줄의 stratified sampling을 직접 구현하고 5 seed 반복으로 측정했습니다.  $s=0.500$ 에서 mean +1.64%, 95% 신뢰구간 [+1.11, +2.18]로 하한이 양수로 확정되었습니다. 30%와 10% 구간도 각각 [+1.45, +3.80], [+0.72, +7.66]로 CI 하한 양수입니다. 3 구간 모두 5/5 seed가 유의하며,  $p=4.01e-05$ 의 단일 seed 수치가 확률적 우연이 아닌 real effect임이 통계적으로 확정되었습니다. +1.64%가 작아 보이지만 이미 좋은 시스템 (Exquitor BERNOULLI) 위에서의 추가 개선입니다.

**예상 Q&A** - Q: 왜 KM20 인가요? 다른 K 값은? → A: Phase 6 Step 3'에서 PCA decile, KM10, KM20을 동시에 비교했고 KM20이 가장 넓은 적용 범위를 가졌습니다. Layer sweep ( $K=30/40/50$ )은 W5에서 진행. - Q: per-stratum `ORDER BY random() LIMIT`의 비용은? → A: BERN 대비 약 11 배. 최종발표 W5에서 per-stratum `TABLESAMPLE BERNOULLI` 최적화로 2 배 이내 감축 목표.

## Slide 10 — External Validity I: SIFT 1.5M에서 효과 2배 (★ 신규)


**화면 본문** -  $D_{target}$ 을 각 데이터셋별로 재계산 → setseed 0.1~0.5의 5 seed 반복 측정 - SIFT 1.5M (128d): DEEP 대비 더 쏠린 분포 → KM20 효과 2 배 확대



| selectivity | KM20 5-seed 평균 | 95% CI         | 유의한 seed           |
|-------------|----------------|----------------|--------------------|
| 50%         | +3.07%         | [+2.66, +3.48] | 5/5 ( $p < 1e-8$ ) |
| 5%          | +4.39%         | [+2.63, +6.15] | 5/5                |
| 1%          | -0.53%         | [-3.18, +2.11] | 1/5                |

- DEEP 1M CI [+1.11, +2.18] 과 SIFT CI [+2.66, +3.48] 겹치지 않음 → 통계적 구별
- 데이터셋 쓸림 정량 (HHI / CV): DEEP CV 0.234 vs SIFT CV **0.394** (68% 높음)
- SIFT 최대 클러스터 14.8 만 (기대값 7.5 만의 2 배), 상위 2 클러스터 전체의 19%

Figure 8 · 외적 타당성 — 3 데이터셋에서 KM20  $s=0.500$  효과 (95% CI)



주: DEEP 1M/8M의 CI는 겹침(외적 재현 CONSISTENT). SIFT의 CI는 DEEP과 겹치지 않아 통계적으로 구별. 쓸림도(CV)가 큰 데이터일수록 공간 인식 샘플링의 이점이 더 크게 발현됨.

발표자 스크립트 (55초)

두 번째 신규 기여는 외적 타당성입니다.  $D_{target}$  을 각 데이터셋별로 재계산한 뒤 SIFT 1.5M 과 DEEP 8M 을 5 seed 로 재측정했습니다. SIFT 에서  $s=0.500$  의 KM20 개선이 mean +3.07%, CI [+2.66, +3.48] 로 DEEP 의 [+1.11, +2.18] 과 겹치지 않아 **효과가 약 2 배로 확대됨**이 통계적으로 구별됩니다. 쓸림도 CV 가 DEEP 0.234 대비 SIFT 0.394 로 68% 높으며, SIFT 최대 클러스터가 기대값의 2 배에 달합니다. "데이터가 더 쏠려 있을수록 공간 인식 샘플링의 가치가 크다" 는 본 연구 가설이 HHI/CV 정량 지표와 Q-error 개선폭 사이의 일관된 단조 관계로 뒷받침됩니다.

**예상 Q&A** - Q: DEEP 8M 은? → A:  $s=0.500$  에서 +1.76% [+0.65, +2.86] 으로 1M 의 [+1.11, +2.18] 과 CI 가 겹쳐 CONSISTENT. 규모를 8 배 늘려도 같은 효과 크기가 재현됨을 확인. - Q: SIFT  $s=0.010$  은 왜 음수? → A: sample\_size=385 대비 true\_card 1.5 만의 비율로 hook estimation 양자화 (BERN median 1.4435 로 5 seed 동일) 발생. 층화 샘플링 효과 하한  $s \geq 0.050$  을 실험적으로 확정.


## Slide 11 — External Validity II: KM20 vs RANDOM20 + Two-Level 분해 (★ 신규)

**화면 본문** - 개선의 원인이 "20 등분" 이 아니라 "공간 구조를 아는 분할" 임을 증명 - KM20 (공간 인식) vs RANDOM20 (무작위 분할) 5 selectivity 대조

| selectivity | KM20 (CI)     | RANDOM20 (CI)  | 격차 (Level 2)   |
|-------------|---------------|----------------|----------------|
| 50%         | +1.64%        | +2.20%         | ~0             |
| 30%         | +2.62%        | +0.26%         | <b>+2.4%p</b>  |
| 10%         | +4.19%        | +1.74%         | <b>+2.5%p</b>  |
| 5%          | +1.85%        | +0.79%         | +1.1%p         |
| <b>1%</b>   | <b>+8.93%</b> | <b>-10.67%</b> | <b>+19.6%p</b> |

- **Two-Level Decomposition:** KM20 개선 = Level 1 (비례 배분) + Level 2 (공간 인식)
- $s=0.010$  에서 **Level 2 단독 +19.60%p** (Level 1 -10.67%, Total +8.93%)
- selectivity 가 좁아질수록 공간 인식이 지배적

Figure 7 · DEEP 1M Selectivity Gradient — KM20 vs RANDOM20 (95% CI)



주: KM20은 모든 selectivity에서 양의 개선. RANDOM20은  $s=0.01$ 에서 -10.67%로 악화.  
 격차가 클수록 공간 인식의 가치가 큼 (좁은 쿼리일수록 KM20 우위 확대).  
 $s=0.05$ ,  $s=0.01$ 은 단일 측정(Phase 6)이라 CI 없음 — 보통 5-seed 재측정은 최종보고서 예정.

## 발표자 스크립트 (1분)

세 번째 신규 기여는 Two-Level Decomposition 입니다. 같은 층화 샘플링 코드를 KM20 (공간 인식) 과 RANDOM20 (무작위 분할) 두 파티션으로 비교하여, 개선 원인이 "20 등분" 이 아니라 "공간 구조를 아는 분할" 임을 증명했습니다.  $s=0.010$  에서 KM20 은 +8.93% 개선, RANDOM20 은 -10.67% 악화로 격차가 19.6%p 에 달합니다. 이를 수학적으로 분해하면 Level 1 (비례 배분 효과, RANDOM20 개선분) 과 Level 2 (공간 인식 효과, KM20-RANDOM20 격차) 로 나뉩니다.  $s=0.010$  에서 Level 2 단독으로 +19.60%p 를 기여하여 KM20 의 공간 인식이 개선의 원동력임이 수학적으로 입증되었습니다.

**예상 Q&A** - Q:  $s=0.500$  에서는 Level 1 이 오히려 더 큰데요? → A: 넓은 쿼리 ( $s=0.500$ ) 에서는 결과 행이 모든 클러스터에 고르게 분포하므로 파티션 품질이 불필요합니다. 비례 배분 (Level 1) 만으로 충분하며, Level 2 는 거의 0. - Q: SIFT 에서도 Two-Level 분해 결과는? → A: SIFT 는 더 쏠린 분포라  $s=0.500$  부터 이미 Level 2 가 +2.06% 로 유의. DEEP 대비 더 이른 selectivity 에서 Level 2 가 지배적.

## Slide 12 — Phase 7: 외적 확장 시도와 후속 해소

**화면 본문 - Phase 7 (4/15 오전):** 8M / sift 128d 에서 1M derive D\_target 그대로 적용 → actual selectivity 0.0001 로 이동 - **초기:** plan\_rows 기반 → STRAT 9.60 vs BERN 20810 (8M, 2168×) 라는 극단 수치 - **검증:** STRAT plan\_rows 100/100 query 에서 정확히 20 = **stratum LIMIT 상수 artifact - 철회 + hook\_est 기반 재 분석:** STRAT -26.5% (8M), -325% (sift) → 극극소 selectivity boundary - **후속 해소 (4/16):** D\_target 재계산 후 §4.8 에서 정상 selectivity 재확인 (Slide 10) - **충화 샘플링의 안정 하한  $s \geq 0.050$  을 정량 확정**

**figure:** Figure 4 — Phase 7 artifact 검증 요약 → Figure 8 cross-dataset 으로 대체 해소

**발표자 스크립트 (35초)**

Phase 7 의 초기 외적 확장 시도에서는 D\_target 을 재계산하지 않아 actual selectivity 가 극극소 영역으로 이동했고, 초기 plan\_rows 기반 분석에 artifact 가 있음을 발견하여 철회했습니다. 이후 D\_target 을 각 데이터셋별로 재계산한 §4.8 의 후속 측정에서 DEEP 8M 은 1M 과 CONSISTENT, SIFT 는 2 배 효과로 정상 selectivity 영역의 외적 타당성이 회복되었습니다. 남은 경계 조건은  $s \geq 0.050$  에서만 충화 샘플링 효과가 안정적으로 발현된다는 것이며, 이는 Exqutor 기본 sample\_size=385 의 구조적 하한의 결과로 정량적으로 확정되었습니다.

**예상 Q&A - Q:** artifact 를 발견한 계기는? → **A:** 3 축 심층 딥리뷰에서 plan\_rows 분포의 이상을 지적, parquet 직접 조회로 확정. 측정 엄밀성의 증거.

## Slide 13 — 한계와 남은 작업 / 최종발표 로드맵

**화면 본문 - 중간발표까지의 한계 (honest report)** - (a) 단일 dataset family — 96~128d 의 좁은 영역 (wiki 768d 는 W5 검증) - (b) SIFT mid-selectivity ( $s=0.10/0.30$ ) CI 결손 — 서버 `unrecognized node type` 오류 디버깅 필요 (W5) - (c) **boundary condition**:  $s \geq 0.050$  에서만 KM20 효과 안정 (W5 의 sample\_size sensitivity 로 하한 완화 탐색) - (d) `vector.c` hook 우회 수정의 reviewer 관점 위험 — 자문 회신 후 narrative 조정 (단, SYS/BERN 양쪽 arm 동일 적용이므로 paired 비교의 상대값은 불변) - (e)  $n=5$  seed 는 seed-variance 검출용 — 출판 급 검정력은 W6 의 10 seed  $\times$  500 query 에서 확보 - **최종발표 로드맵 (5/27)** — 5 개 W5 보충 실험 전수 나열 - **W5** (4/28~): (i) per-stratum `TABLESAMPLE BERNOULLI` 최적화 + (ii) Layer sweep  $K=30/40/50$  + (iii) wiki 768d 검증 + (iv) SIFT mid-sel ( $s=0.10/0.30$ ) 보충 + (v) sample\_size sensitivity 로 boundary  $s \geq 0.050$  완화 탐색 - **W6** (5/5~): 3 dataset  $\times$  3 mode  $\times$  6 sel  $\times$  **10 seed  $\times$  500 query** 전면 ablation (270k 추정) + BH-FDR 다중비교 보정 + TOST 등가성 검정 - **W7** (5/12~): **RQ3 Recovery Rate 7-way 비교** — 3 패러다임 (Offline / Online / Weight-based), Hilbert Curve 공간 DB 기법 최초 적용, H (Importance Sampling) 는  $2 \times 2$  factorial 로 allocation/estimator 효과 분리 - **W8** (5/19~): 최종보고서 + 포스터 + 전시회 데모 + 리허설

### 발표자 스크립트 (40초)

현재 네 가지 한계를 인지하고 있습니다: 단일 dataset family, SIFT mid-selectivity CI 결손,  $s \geq 0.050$  boundary, `vector.c` 우회 수정의 reviewer 위험. 이를 4 주 로드맵으로 해소합니다. W5 에 최적화와 wiki 검증, W6 에 3 데이터셋  $\times$  500 query  $\times$  10 seed 전면 ablation, W7 에 RQ3 Recovery Rate 7-way 비교, W8 에 최종보고서와 포스터를 완성합니다. 특히 RQ3 는 세 패러다임의 7 가지 방법 — LSH, Random Projection, Hilbert Curve, Mini-batch KM, Distance-Shell, KDE-pilot, Importance Sampling — 을 체계적으로 비교하며, 공간 DB 의 Hilbert Curve 기법을 벡터 카디널리티 추정에 최초로 적용합니다.

## Slide 14 — 결론

화면 본문 - 기여 1 — 구조적 발견: Exqutor 의 단일 테이블 사각지대 (Hook trigger + plan replacement + 5 design constraint) + **query-side feature 사전 식별 불가능성** (8 지표 × 24 조합 전수  $|p| < 0.2$ ) - 기여 2 — 방법론 구현: Block bias 1 줄 교체 (Pivot A) + **data-side KM20 stratified sampling native 구현** (+228 줄, Pivot C) — Python counterfactual 검증 → native 재현의 2 단계 validation pipeline - 기여 3 — 정량 효과 (복수 유효 anchor): - Phase 4 SYSTEM→BERNOULLI: 4 selectivity 구간  $p < 0.001$  - Phase 6 Step 4 KM20 native:  $s=0.500$   $p=4.01e-05$  Bonferroni 유일 생존 + **5-seed CI [+1.11, +2.18]** - 3 데이터셋 외적 재현: DEEP 1M/8M CONSISTENT, SIFT 2 배 효과 (CI 분리) - **Two-Level 분해**: Level 2 단독 +19.60%p ( $s=0.010$ ) - **HHI/CV 정량**: CV 68% 격차가 KM20 효과 2 배 격차의 직접 원인 - 기여 4 — 경계 조건:  $s \geq 0.050$  안정 하한 확정 (Phase 7 boundary negative finding 의 학술적 가치)

발표자 스크립트 (30초)

결론입니다. 본 연구의 기여는 네 가지입니다. Exqutor 의 사각지대 발견, data-side KM20 stratified 의 native 구현, 5-seed CI + 3 데이터셋 + Two-Level 분해의 복수 유효 anchor, 그리고  $s \geq 0.050$  boundary 조건의 정량 확정입니다. 더 쏠린 SIFT 에서 KM20 효과가 DEEP 의 2 배로 확대됨을 HHI/CV 정량 지표로 인과적으로 설명했습니다. 최종발표에서 wiki 768d 검증과 RQ3 Recovery Rate 7-way 비교로 완성하겠습니다. 감사합니다.

## Slide 15 (부록) — Appendix: 추가 Design Constraint, 기술적 발견, RQ3 7-way

화면 본문 (Q&A 대응용)

추가 Design Constraint (iii~v) - (iii) q-error inf 발산: single-table hook 우회 시 이중 sampling 으로 첫 sample 매칭 0 건 - (iv) sample\_size NaN 발산: 50 query 시퀀스 중 Adaptive update 가 NaN 으로 발산 - (v) Adaptive update path SIGSEGV: `update_sample_size = off` GUC 로 회피 - 셋 모두 Adaptive Sampling loop 가 multi-table only design intent 를 가정한 결과

RQ3 Recovery Rate 프레임워크 — 7 가지 방법

| 방법                     | 패러다임         | 기대 Recovery | 사전 학습    |
|------------------------|--------------|-------------|----------|
| C. Random Projection   | Offline      | 10~40%      | 사영 1회    |
| A. LSH                 | Offline      | 30~60%      | 해시 1회    |
| E. Hilbert Curve       | Offline      | 20~60%      | index 1회 |
| F. Mini-batch K-means  | Offline      | 75~95%      | 1~5% 데이터 |
| G. Distance-Shell      | Online       | 25~50%      | 불필요      |
| B. KDE-pilot           | Online       | 50~80%      | 불필요      |
| H. Importance Sampling | Weight-based | 30~70%      | 불필요      |

Recovery Rate = (방법X – RANDOM20) / (KM20 – RANDOM20). 1.0 = KM20 동등, 0.0 = RANDOM20 동등.

**발표자 스크립트** (부록 사용 시)

부록 슬라이드입니다. Design constraint 5 가지 중 본문에 담지 못한 3 가지는 모두 Adaptive Sampling loop 의 수치 안정성 관련 기술 발견이며, 본 연구는 `update_sample_size = off` 로 `sample_size=385` fixed 한 채 sampling method 효과만 분리 측정했습니다. RQ3 의 7 가지 방법은 세 패러다임으로 분류되며, Recovery Rate 지표로 사전 학습 없이 KM20 의 공간 인식 효과를 얼마나 회수하는지 정량 비교합니다.

## 슬라이드 제작 메모

- 본 md 를 기반으로 .pptx 변환 시 **별도의 PPT 변환 경로 필요** (파워포인트 수작업 또는 theme-factory skill)
- 발표 시간 10 분 기준 분배:
- S1 (0:15) + S2 (0:20) + S3 (0:35) + S4 (0:25) + S5 (0:50) + S6 (1:00) + S7 (0:50) + S8 (0:55) + S9 (1:10) + S10 (0:55) + S11 (1:00) + S12 (0:35) + S13 (0:40) + S14 (0:30) = **9:40**, Q&A 5 분 여유
- 발표자 분담 (4/17 확정):
- **강재현 — 주 발표자 (S1~S15 전체)**
- 조현빈 — Q&A 기술 백업: 발표자용 기술 맥락 문서, 예상 Q&A 답변지, 실험 수치 재현 responsibility
- 박세은 (팀장) — 전체 조율 + 자문 회신 관련 Q&A 대응
- 이동욱 — 슬라이드 검토 + 리허설 피드백

- 팀 리뷰 라운드: 4/22~4/24 (최소 2 회), 리허설 4/24~4/26 (최소 2 회)
- 자문 회신에 따른 수위 조정: (c) 의 기본 결정은 "(a) 첫째·둘째만 본문" — 멘토 회신 후 수정 가능
- **v2 업데이트 (4/17)**: Slide 9 에 5-seed CI 편입, Slide 10/11 신규 (SIFT 2배 + Two-Level), Slide 12 톤 전환, Slide 13 RQ3 7-way, Slide 15 부록 RQ3 표

## 참고 figure 매핑

| Slide   | Figure 파일                                                                         | 상태        |
|---------|-----------------------------------------------------------------------------------|-----------|
| 5       | <code>experiments/figures/rq1_motivation/figure_6_phase5_heatmap.png</code>       | ✅ 생성 완료   |
| 6       | <code>vector.c</code> 코드 스니펫 (수작업)                                                | 발표자 직접    |
| 8       | <code>experiments/figures/rq1_motivation/figure_1_phase4_scatter.png</code>       | ✅         |
| 9       | <code>experiments/figures/rq1_motivation/figure_2_phase6_box.png</code>           | ✅         |
| 10      | <code>experiments/figures/rq2_aware/figure_8_cross_dataset_bar.png</code>         | ✅ 신규 (v2) |
| 11      | <code>experiments/figures/rq2_aware/figure_7_selectivity_gradient.png</code>      | ✅ 신규 (v2) |
| 11 (보조) | <code>experiments/figures/rq2_aware/figure_9_two_level_decomposition.png</code>   | ✅ 신규 (v2) |
| 10 (보조) | <code>experiments/figures/rq2_aware/figure_10_cluster_skew.png</code>             | ✅ 신규 (v2) |
| 부록      | <code>experiments/figures/rq1_motivation/figure_3_phase6_layer_compare.png</code> | ✅         |
| 부록      | <code>experiments/figures/rq1_motivation/figure_5_python_native_table.png</code>  | ✅         |

## 파생 산출물 + cross-link

본 구조 md 는 중간보고서 v2 ( `submission/속도는벡터_중간보고서_20260417_0000.md` ) 의 요약 버전이다. Slide 5~11 의 화면 본문 + 발표자 스크립트는 중간보고서 §4.2 ~ §4.10 와 1:1 대응되며, Slide 10~11 의 신규 내용은 보고서 §4.8~§4.10 의 상세 분석에 근거한다. 발표자가 더 자세한 narrative 가 필요할 때 중간보고서의 해당 절을 참조한다.