

자문 이메일 v2 — 2026-04-16 발송 예정

발신: 속도는벡터 팀 (연세대학교 캡스톤 디자인, 조현빈)

수신: 멘토님 (2차 자문)

참조: 팀원 전원 + 지도 교수님 (선택)

제목: [캡스톤 속도는벡터] "데이터 쏠림 → uniform 성능 저하 → 공간 인식 sampling 개선" 실험적 확인 보고와 자문 요청

본문

멘토님, 안녕하세요.

연세대학교 캡스톤 디자인 속도는벡터 팀의 조현빈입니다. 3월 25일 1차 자문에서 멘토님께서 데이터셋 선정, 대조군 설정, 평가 지표 구체화의 세 가지를 강조해주셨고, "EXPLAIN ANALYZE에 익숙해지는 것이 첫걸음"이라고 조언해주셨습니다. 이후 연구가 상당히 구체화되어 진행 경과와 함께 2차 자문을 요청드립니다.

0. 1차 자문 이후 연구 진행 경로

수행계획서 단계 (3월): Cascaded Vector Similarity Decomposition — D_loose 임계값으로 쿼리를 2단계 분리하여 카디널리티 추정 오차를 구조적으로 최소화하는 방향을 제안했습니다.

1차 자문 반영 (3/25): 멘토님 피드백에 따라 ① 데이터셋을 TPC-H SF10 + DEEP 96d / SIFT 128d 벡터로 선정, ② EXPLAIN ANALYZE 기반 Q-error를 핵심 평가 지표로 확정, ③ paired Wilcoxon 통계 검정을 대조군 비교 방법으로 채택했습니다.

교수님 지도 (4/3): Exqutor 논문(arXiv:2512.09695v2)을 기반으로, 카디널리티 추정의 핵심 문제를 "sampling 자체의 개선"으로 좁혔습니다. 교수님께서 제시하신 프레이밍은 다음과 같습니다:

"데이터가 일반적(균일)일 때와 한쪽으로 쏠려있는 경우 사이의 성능 차이. Exqutor는 쏠린 상황에서도 기존과 똑같은 uniform sampling을 사용하니, 그런 케이스에서 성능이 떨어지고, 따라서 샘플링 개선을 통해서 이를 해결하자."

이 프레이밍에 맞추어 아래 3단계 실증 구조를 설계했습니다.

1. 연구의 3단계 구조

교수님 프레이밍에 대응하는 3단계 실증 구조입니다.

단계	질문	실험	결과
Step 1	데이터가 쏠려있는가?	KM20 cluster 분석	cluster 크기 26K~81K (3.1배), Gini=0.13
Step 2	쏠림 때문에 uniform이 나빠지는가?	RANDOM20 대조 실험	s=0.010에서 19.6%p 차이 (아래 §3)
Step 3	공간 인식 sampling으로 해결되는가?	KM20 stratified vs BERN	+1.64% CI [1.25, 2.02] (5-seed)

2. 실험 경위 요약

멘토님 조언대로 EXPLAIN ANALYZE를 집중 활용하여 Exqutor 내부 동작을 분석했고, 그 과정에서 당초 예상과 다른 방향으로 진행되었습니다.

RQ1 Motivation (Phase 1~5): "skewness 지표가 Q-error를 예측한다"는 가설을 8개 지표(글로벌 4 + 로컬 4) × 6 selectivity = 48 조합에서 전수 검증한 결과, 전부 Spearman $|p| < 0.2$ 로 기각되었습니다. 고차원 distance concentration으로 글로벌 skewness 지표의 변별력이 평탄화된 것으로 해석됩니다. 이 과정에서 Exqutor 논문 본문에 명시되지 않은 **5가지 design constraint**를 소스 코드 검증([vector.c](#))으로 발견했으며, 이것이 연구의 방향 전환 계기가 되었습니다.

RQ2 개선 (Phase 4~6): 가설 기각 후, "query-level 지표로 쏠림을 예측"하는 대신 "data-side partition으로 쏠림을 직접 반영"하는 방향으로 전환했습니다.

- **Pivot A:** Exqutor의 [TABLESAMPLE SYSTEM](#) (block 단위) → [BERNOULLI](#) (row 단위) 1줄 교체. Block sampling bias 제거로 +3.8~9.6% 개선 (4 구간 $p < 0.001$). 이것이 1차 자문에서 강조하신 **대조군 설정**의 기초가 됩니다.
- **Pivot C:** k-means K=20(KM20) 기반 stratified sampling을 [vector.c](#) 에 +228줄 구현. 각 cluster에서 비례 배분하여 Horvitz-Thompson 추정.
- **Multi-seed 결과:** s=0.500에서 KM20 stratified가 BERN 대비 **+1.64%, 95% CI [1.25, 2.02]** (5 seed, paired Wilcoxon 전 seed $p < 0.004$).

3. ★ 핵심 결과 — RANDOM20 대조 실험

Step 2 "쏠림 때문에 나빠지는가?"를 직접 증명하기 위해, 같은 stratified sampling 코드를 두 가지 partition으로 비교했습니다.

조건	partition 방식	Gini 계수
KM20	k-means로 공간 구조 반영	0.13 (비균일)
RANDOM20	무작위 20개 라벨 배정	0.003 (균일)

결과 — selectivity에 따른 그래디언트:

selectivity	KM20 vs BERN	RANDOM20 vs BERN	차이	해석
s=0.500 (넓은 범위)	+1.64%	+2.20%	~0	공간 인식 불필요
s=0.050 (중간)	+1.85%	+0.79%	+1.1%p	공간 인식 시작
s=0.010 (좁은 범위)	+8.93%	-10.67%	+19.6%p	공간 인식 지배

이 그래디언트의 의미:

- **s=0.500**: query 결과가 모든 cluster에 고르게 분포 → 어떤 partition이든 비슷 → 개선은 proportional allocation(표본 크기 안정화)에서 비롯
- **s=0.010**: query 결과가 소수 cluster에 집중 → **공간 구조를 아는 KM20만 개선 (+8.93%)**, 모르는 RANDOM20은 오히려 악화 (-10.67%)
- s=0.010에서 KM20 CI [6.59, 10.95] vs RANDOM20 CI [-15.26, -6.51] → **CI 완전 분리 (유의미)**

결론: 개선의 원인이 "데이터의 공간적 쏠림"임을 직접 증명. 쏠림이 심한 영역(저selectivity)에서만 공간 인식이 중요하며, 쏠림이 약한 영역(고selectivity)에서는 proportional allocation만으로 충분합니다.

4. Two-Level Decomposition

RANDOM20 실험으로 stratified sampling의 개선 메커니즘을 두 수준으로 분해할 수 있었습니다.

Level 1 — Proportional Allocation (보편적, partition 품질 무관): - BERNOULLI는 각 행을 독립적으로 선택 → 표본 크기가 확률 변수 - Stratified는 각 stratum에서 정확히 비례 배분 → 표본 크기 확정 → 추정 분산 감소 - 어떤 partition이든 성립 (survey sampling 이론의 고전적 결과)

Level 2 — Spatial Awareness (selectivity-dependent): - query 결과가 소수 cluster에 집중될 때, 해당 cluster를 아는 partition이 추가 이점 제공 - s=0.010에서만 KM20과 RANDOM20의 차이가 극대화 → Level 2 효과 발현

5. Phase 7 negative finding

Phase 6의 1M 결과를 8M DEEP / 1.5M SIFT로 외적 확장을 시도했으나, D_target 재계산 미비로 actual selectivity가 ≈ 0.0001 영역으로 이동하여 측정 artifact가 발생했습니다. 이를 정직하게 검증·철회하고, 극극소 selectivity에서 KM20의 효과가 없음을 negative finding으로 보고합니다. 현재 8M의 D_target을 재계산 완료했으며(actual_sel=0.5001), 정상 selectivity에서의 외적 타당성 재측정을 예정하고 있습니다.

6. 남은 로드맵

4/16~17 자문 회신 대기 + 중간보고서 v3 편집
4/18~21 8M 외적 타당성 재측정 + per-selectivity HHI 정량화
4/22 1차 팀 리뷰
4/24 2차 리뷰 + 리허설
4/28 * 중간발표 + 중간보고서 제출

최종발표까지 (5/27):

W5~W6 3 dataset 전면 ablation + per-stratum 최적화
W7 RQ3: KDE-pilot / LSH-bucket 분포 무인지 경로
W8 최종보고서 + 포스터 + 전시회

7. 자문 요청 사항

(a) **시나리오 전환의 학술적 정당성**. 4/3 합의의 multi-table join 시나리오에서 단일 테이블 vector range query 사각지대로 좁혔습니다. Hook trigger 사각지대 등 4가지 design constraint가 전환의 충분 근거인지 멘토님의 판단을 구합니다.

(b) **Two-Level Decomposition의 학술적 기여 가치**. RANDOM20 대조 실험으로 proportional allocation 효과와 spatial awareness 효과를 분리한 것이 학술적 기여로 인정될 수 있는지 멘토님의 판단을 구합니다. 본 팀의 입장은 "기존 연구에서 이 두 효과를 벡터 데이터 카디널리티 추정 맥락에서 분리한 사례가 없으므로, 분해 자체가 기여"입니다.

(c) **중간발표 narrative 구성**. 핵심 결과를 "RANDOM20 selectivity gradient"로 잡고, 교수님의 "쓸림→성능저하→개선" 프레임에 직결하는 구성이 적절한지 멘토님의 판단을 구합니다. 대안으로는 Phase 6 Step 4의 +1.64%를 headline으로, RANDOM20은 보조 증거로 배치하는 구성이 있습니다.

8. 회신 요청

4월 18일(금)~4월 20일(일) 사이 회신을 받을 수 있으면 4/22 팀 리뷰에 반영 가능합니다. 회신이 늦어질 경우 기본 결정대로 진행 후 추후 반영하겠습니다.

첨부: 1. [submission/속도는벡터_중간보고서.md](#) — 전체 종합 보고서 2. [plans/연구재설계안_20260415.md](#) — "쓸림→성능저하→개선" 재설계안 3. [experiments/results/rq1_motivation/random20_selectivity_gradient.md](#) — RANDOM20 결과 분석

감사합니다.

속도는벡터 팀 조현빈 드림 2026년 4월 15일