

# Exqutor 벡터 카디널리티 추정의 단일 테이블 사각지대와 Skew-Aware Sampling

Pivot A BERNOULLI 교체 + Pivot C KM20 Stratified — 3 데이터셋 5-seed CI 검증

3

데이터셋

DEEP 1M / 8M · SIFT 1.5M

5-seed

신뢰구간

외적 타당성 통계 보장

+19.6%p

Level 2

공간 인식 단독 효과

8/8

negative

skew 지표  $|p| < 0.2$

# Table of Contents

---

01

Problem

벡터 카디널리티 추정의 사각지대

02

Background

Exqutor 의 두 해법과 한계

03

Our Approach

Skew-Aware Sampling 의 차별성

04

Experiments

RQ1 · RQ2 · RQ3 설계와 결과

05

Plan

현재 진행 상황 및 향후 계획

# 1. 해결하고자 하는 문제

벡터 조건의 선택도를 시스템마다 "고정 비율"로 추정한다

기존 시스템 — 고정 비율 추정

**pgvector**

**33.3%**

PostgreSQL operator default

**VBASE**

**50.0%**

fixed estimator

**DuckDB**

**100%**

scan all rows

실제 — 0.001% ~ 90%의 광범위한 분포

- 실제 선택도는 query에 따라 0.001% ~ 90%의 광범위한 분포
- 옵티마이저가 잘못된 실행 계획 선택 → nested loop ↔ hash join, index 사용 여부
- 이미지 검색 / 추천 / RAG retrieval 등 단일 테이블 vector range query에서 빈번

"기술적으로 좋은 추정" vs "실행 계획에 진짜 도움 되는 추정" — 이 간극을 어떻게 메울 것인가?

## 2-1. 기존 연구의 현황 — Exqutor 의 두 보완책

arXiv:2512.09695v2 (2024) · 4/3 교수님 미팅에서 본 논문 채택

### ECQO

HNSW 인덱스가 있을 때

HNSW range query 를 직접 실행해 1~2ms 로 정확 카디널리티 산출

**1~2 ms**

정확 카디널리티

### Adaptive Sampling

인덱스가 없을 때

모멘텀 기반 동적 샘플링 — sample size 를 점진 확장하며 분산 수렴 판정

**1000×**

pgvector 대비 최대

→ pgvector 1000×, VBASE 10000×, DuckDB 1.5~37× 성능 향상 (논문 보고)

## 2- II . Adaptive Sampling 의 한계 — 사각지대

본 팀 4/14 소스 검증으로 첫 정량 확인

#1

### Hook Trigger 사각지대

vector.c L243 · `if (table_count > 2)`

단일 테이블 vector range query 가 hook 경로에서 배제 → 모든 query 가 PG default selectivity 1/3 로 fall-through

#2

### Plan Replacement 부작용

hook 우회 시 outer query plan-tree → Sample Scan

true=100,000 query 의 SELECT count(\*) 가 sample 안 부분 카운트 32 로 격하

#3

### Skew 지표 8 종 전수 negative

Phase 1·5 — 글로벌 4 + 로컬 4 = 8 지표

Fisher  $\gamma$ , k-NN entropy, PCA EVR1 등 모든 지표 vs Q-error · Spearman  $|\rho| < 0.2$  (4 지표 × 6 selectivity = 24 조합)

### vector.c — Hook Trigger 사각지대 (line 243)

#### vector.c (Exqutor adaptive sampling hook)

Pivot A — Hook trigger (line 243)

```
- if (table_count > 2)
+ if (table_count >= 1)
# 2-way join 부터 hook 활성화 → 단일 테이블 query 에도 주입
```

Pivot B — Sampling method (line 889)

```
- TABLESAMPLE SYSTEM(%f)
+ TABLESAMPLE BERNOULLI(%f)
# 블록 단위 SYSTEM → 행 단위 BERNOULLI 로 교체 (skew 내성 +)
```

Pivot C — Stratified sampling branch

```
- (no stratification logic)
+ +228 lines: KM20 strata read -> per-stratum BERNOULLI -> HT aggregate
# skew 을 명시적으로 활용하는 층화 추정 경로 추가 (합산/분산 추정 포함)
```

3 surgical edits — SYSTEM 의 block skew bias 제거 + 층화 경로 활성화

vector.c L243 — `table_count > 2` hook trigger 사각지대

★ 단일 테이블 vector range query (이미지 검색·추천·RAG) 는 Exqutor 가 **\*\*명시적으로 배제한\*\*** 사각지대

### 3. 차별성 및 제안 연구의 중요성

Skew-Aware Sampling — 분포 정보를 사용한 두 단계 보강

Pivot A

#### Block-bias 제거

vector.c L889 의 TABLESAMPLE SYSTEM(%f) → BERNOULLI(%f) 한 줄 교체

fair baseline 도구

**+9.6%**

s=0.500, p<0.001

Pivot C

#### Data-side k-means K=20

vector.c +228 줄 native 구현 — stratum\_id 사전 부여 + Horvitz-Thompson 가중 추정

공간 인식 sampling


**+1.64%**

DEEP 1M, 5-seed CI [+1.11, +2.18]

◆ 두 Pivot 은 직교적 — SYSTEM × BERNOULLI × STRATIFIED 의 ablation matrix 로 각 기여 분리

#### 본 연구의 핵심 기여

- RQ1: 8 지표 negative 로 query-side feature 의 사전 layer 정의 불가능성을 정량 증명
- RQ2: KM20 stratified 가 BERNOULLI 위에서 추가 개선 — 5-seed CI 하한 양수
- RQ3 설계: 분포 미지 시 KM20 의 "공간 인식 효과" 를 Recovery Rate 프레임워크로 측정



Two-Level Decomposition — Level 1 (비례) + Level 2 (공간 인식) 분해

# 4- I . RQ1 — Skew 지표는 Q-error 를 예측하지 못한다

Phase 1 (글로벌) + Phase 5 (로컬) = 8 지표 전수 검증, 총 3000 측정


## 실험 셋업

|          |                                                     |
|----------|-----------------------------------------------------|
| 데이터셋     | DEEP 1M subset · 96d                                |
| 쿼리       | 100 query × 6 selectivity × 5 seed = 3000           |
| 지표 (글로벌) | Fisher $\gamma$ , tail ratio, P99/P50, skewness     |
| 지표 (로컬)  | k-NN entropy, PCA EVR1, KDE modality, NN clustering |

## 주요 발견 (Phase 1 + Phase 5)

- ① 12 조합 모두 Q-error ratio  $\approx 1.0$  (skewed/non-skewed 그룹 차이 없음)
- ② 24 조합 모두 Spearman  $|\rho| < 0.2$  (Cohen 1988 small-effect 미달)
- ③ 100 query 전부 Fisher  $\gamma < 0$  (left-skewed) — 고차원 거리 집중 현상

## Phase 5 Local Skew × Selectivity Spearman $\rho$



Phase 5 — 로컬 4 지표 × 6 selectivity = 24 조합 모두  $|\rho| < 0.2$

→ 고차원 벡터에서 query-side feature 로 layer 를 사전 정의하는 것은 불가능 — 본 연구의 Motivation 첫 줄


# 4- II . RQ2 (1) — BERNOLLI 가 SYSTEM 의 block-bias 를 제거

100 query × 6 selectivity × 1 seed × 2 mode = 1200 측정 · paired Wilcoxon

| selectivity | SYS median | BERN median | diff% | p-value | 유의  |
|-------------|------------|-------------|-------|---------|-----|
| 0.001       | 2.597      | 2.597       | +0.0  | 0.596   | —   |
| 0.010       | 1.558      | 1.299       | +20.0 | 0.240   | —   |
| 0.050       | 1.203      | 1.195       | +0.7  | 0.0009  | ★★  |
| 0.100       | 1.212      | 1.132       | +7.0  | <0.001  | ★★★ |
| 0.300       | 1.210      | 1.079       | +12.0 | <0.001  | ★★★ |
| 0.500       | 1.153      | 1.052       | +9.6  | <0.001  | ★★★ |

## Takeaways

- ① 4 selectivity 구간 (s=0.05~0.5) 에서  $p < 0.001$  — block sampling bias 는 통계적으로 유의한 구조적 약점
- ② vector.c 한 줄 교체로 Exqutor 카디널리티 추정 개선 경로 확보
- ③ 단, 이는 Pivot C 의 fair baseline 도구이지 단독 기여가 아님






## 4-III. RQ2 (2) — KM20 Stratified 가 BERNOLLI 위에서 추가 개선

5-seed 신뢰구간으로 외적 타당성 확보 · vector.c +228 줄 native 구현

| selectivity | 5-seed 평균 | 95% CI         | 유의 seed       |
|-------------|-----------|----------------|---------------|
| 50%         | +1.64%    | [+1.11, +2.18] | 5/5           |
| 30%         | +2.62%    | [+1.45, +3.80] | 5/5 (p<0.001) |
| 10%         | +4.19%    | [+0.72, +7.66] | 5/5 (p<0.004) |
| 5%          | +1.85%    | 1-seed (W5 보충) | 3/5           |
| 1%          | +8.93%    | 1-seed (W5 보충) | 4/5           |

BERNOULLI vs STRATIFIED (KM20)




Phase 6 Step 4 — BERNOLLI vs STRATIFIED (KM20) 100 query boxplot

- ① 50% / 30% / 10% 세 구간 모두 95% CI 가 0 을 포함하지 않음 — real effect 통계적 확정
- ② s=0.500 1-seed p=4.01e-05 (Bonferroni 통과) → 5-seed 재현으로 우연 가능성 배제
- ③ BERNOLLI 위에서 추가 개선 — 누적 vs SYSTEM 은 +12.5% (s=0.500)

vector.c +228 줄 native · GUC 3 개 · stratum\_id 사전 부여 · Horvitz-Thompson 가중 추정

## 4-IV. External Validity — 3 데이터셋 교차 검증

DEEP 1M · DEEP 8M · SIFT 1.5M — D\_target 데이터셋별 재계산



외적 타당성 — DEEP 1M / 8M / SIFT 1.5M, KM20  $s=0.500$  효과 95% CI

### 주요 발견 + 시사점

- ① DEEP 1M ↔ 8M : CI 겹침 (CONSISTENT) — 8 배 규모에서 동일 효과 재현
- ② SIFT 1.5M : CI 가 DEEP 과 겹치지 않음 (~2 배 효과) — 통계적 구별
- ③ 쓸림도 (CV) DEEP 0.234 vs SIFT 0.394 (68% 높음) — 쓸림 ↑ ⇒ 공간 인식 가치 ↑

### DEEP 1M (96d)

CI [+1.11, +2.18] · CV 0.234

**+1.64%**

### DEEP 8M (96d)

CI [+0.65, +2.86] · CV 0.234

**+1.76%**

### SIFT 1.5M (128d)

CI [+2.66, +3.48] · CV 0.394

**+3.07%**


# 4-V. 결과 해석 — 데이터 쓸림과 공간 인식 효과

Two-Level Decomposition + 클러스터 쓸림도 (HHI / CV) 정량

■ KM20 개선 = Level 1 (비례 배분) + Level 2 (공간 인식)

| selectivity | KM20   | RANDOM20 | 격차 (Level 2) | 지배 요인      |
|-------------|--------|----------|--------------|------------|
| s = 50%     | +1.64% | +2.20%   | ~0           | 비례만        |
| s = 30%     | +2.62% | +0.26%   | +2.4%p       | Level 2    |
| s = 10%     | +4.19% | +1.74%   | +2.5%p       | Level 2    |
| s = 5%      | +1.85% | +0.79%   | +1.1%p       | Level 2    |
| s = 1%      | +8.93% | -10.67%  | +19.6%p      | ★ 공간 인식 단독 |

■ 데이터셋 쓸림도 — DEEP CV 0.234 vs SIFT CV 0.394 (68% 높음)



클러스터 쓸림도 — DEEP CV 0.234 vs SIFT CV 0.394 (HHI 정량)

- SIFT 최대 클러스터 14.8 만 (기대값 7.5 만의 2 배)
- 상위 2 클러스터가 전체 19% 점유
- KM20 효과 SIFT +3.07% (DEEP +1.64% 의 약 2 배)

★ 쓸림 ↑ ⇒ Level 2 (공간 인식) 단독 효과 ↑ — 본 가설 단조 관계 재확인

# 4-V. RQ3 (설계) — 분포를 모를 때의 Recovery Rate 프레임워크

3 패러다임 × 7 방법 — W5~W7 실험 예정

$$\blacksquare \text{ Recovery Rate} = (\text{방법X} - \text{RANDOM20}) / (\text{KM20} - \text{RANDOM20})$$

## P1 Offline Partition

- Random K=20 grid
- Subspace decile
- Hash partition (LSH)

1회 사전 처리 — KM20 와 비용 동등

## P2 Online Query-Adaptive

- Cluster-on-the-fly
- Active reservoir

Query 도착 시점 학습 — D\_target 의존성 제거

## P3 Weight-based

- Importance sampling
- Stratified weight

Sample 후 재가중 — partition 자체 불필요

### 평가 조건

→ DEEP 1M · 8M · SIFT 1.5M 3 데이터셋 × 5 seed × 5 selectivity 동일 조건

★ 최소 1 방법이  $RR \geq 0.5$  → 분포 미지 시에도 KM20 의 절반 효과 회수

## 5- I . 현재 진행 상황 (W1~W4)

| W1 ✓                                                                                                                                                                                | W2 ✓                                                                                                                                                                                         | W3 ✓                                                                                                                                                                                                      | W4 ▶                                                                                                                                                                                           |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 3/2~4/4<br><b>Scope · 환경 세팅</b> <ul style="list-style-type: none"><li>· 주제 확정 (3/3)</li><li>· Exqutor 채택 (4/3)</li><li>· 서버 수령 + Docker (4/14)</li><li>· 코드·데이터 수령 (4/7~)</li></ul> | 4/11~4/15<br><b>RQ1 Motivation</b> <ul style="list-style-type: none"><li>· Phase 1 가설 H1 기각 (4/14)</li><li>· Phase 5 로컬 4 지표 negative (4/15)</li><li>· Design Constraint 발견 (4/14)</li></ul> | 4/15~4/16<br><b>RQ2 Aware</b> <ul style="list-style-type: none"><li>· Phase 4 Pivot A native (4/14~15)</li><li>· Phase 6 Step 4 KM20 1-seed (4/15)</li><li>· 5-seed CI · DEEP 1M/8M/SIFT (4/16)</li></ul> | 4/17~4/28<br><b>보강 + 발표</b> <ul style="list-style-type: none"><li>· Two-Level 분해 +19.6%p (4/16)</li><li>· HHI/CV 정량 (4/17)</li><li>· RQ3 7-way 설계 (4/16)</li><li>· 중간보고서 + 발표 (4/28)</li></ul> |

✓ RQ1 + RQ2 본선 + 5-seed 외적 타당성 + RQ3 설계 — 학기 중간 시점 완료

## 5- II . 향후 계획 (W5~W10)

|     |           |                         |                                                         |
|-----|-----------|-------------------------|---------------------------------------------------------|
| W5  | 4/29~5/6  | RQ3-A Offline Partition | Random K=20, Subspace decile, LSH 3 방법 — DEEP 1M 1-seed |
| W6  | 5/7~5/13  | RQ3-A 5-seed            | 선별된 1~2 방법 5-seed × 3 데이터셋 — Recovery Rate 산출           |
| W7  | 5/14~5/20 | RQ3-B + Layer K sweep   | Online + Weight 패러다임 + K=10/20/30/50 sweep              |
| W8  | 5/21~5/27 | 심화 + 최종발표 준비            | per-stratum BERN 최적화, sample_size sensitivity           |
| W9  | 5/28~6/4  | 최종발표 + 전시회              | 5/27~29 발표, 6/5 전시회                                     |
| W10 | 6/5~6/11  | 최종보고서 작성                | RQ1 + RQ2 + RQ3 통합 + 실험 재현 가이드                          |

산출물

최종발표 PDF (5/27~29) · 전시회 포스터 (6/5) · 최종보고서 PDF (6/11)

## 5-Ⅲ. 팀원별 역할 분담

| 이름  | 역할     | 담당                                       |
|-----|--------|------------------------------------------|
| 박세은 | 팀장     | 전체 일정 관리 · 자문 회신 정리 · 발표·보고서 총괄          |
| 강재현 | 주 발표자  | 중간발표 주 발표 · 슬라이드 검수 · Q&A 사회             |
| 조현빈 | 실험·문서화 | RQ1/RQ2 실험 · vector.c native 구현 · 보고서 작성 |
| 이동욱 | 분석·작도  | 통계 분석 (CI · Two-Level) · 그림 작성 · RQ3 설계  |

▣ Q&A 응답 — 통계·CI 는 이동욱, 실험 디테일은 조현빈, 일정·체크포인트는 박세은 분담 (4 인 합의 후 진행)

---

# 감사합니다

질문 부탁드립니다

속도는벡터

박세은 (팀장) · 강재현 · 조현빈 · 이동욱