

속도는벡터 중간발표 슬라이드 구조

발표일: 2026-04-28 (화) — D-13

팀: 속도는벡터 (박세은, 강재현, 조현빈, 이동욱)

주제: Exqutor 기반 벡터 증강 분석 쿼리의 단일 테이블 사각지대 개선

발표 시간: 10분(발표) + 5분(Q&A) 가정

본 문서의 역할: 발표자(팀원 분담 예정)가 참조할 구조 md. ppt 변환 전 초안 정렬에 사용. 각 장(슬라이드)은 ## 로 구분, 화면 본문 + 발표자 스크립트 + 예상 Q&A를 포함.

기반 문서: `plans/수정 연구 설계안\_20260415\_001500.md` (v4), `experiments/results/rq1\_motivation/summary.md` (\$V~IX), `experiments/results/rq1\_motivation/direction\_pivot\_rationale.md`, `submission/속도는벡터\_자문이메일\_20260415.md`

발표 수위 기본 결정 (자문 회신 전): (a) design constraint 중 첫째(Hook trigger 사각지대) + 둘째(plan replacement 부작용) 만 motivation 본문 노출. 나머지 3개(q-error inf, sample_size NaN, Adaptive SIGSEGV)는 부록 슬라이드 또는 Q&A 대응.

Slide 1 — 표지

제목: Exqutor 벡터 카디널리티 추정의 단일 테이블 사각지대와 Skew-Aware Sampling **부제:** Pivot A BERNOULLI 교체 + Pivot C KM20 Stratified 병합 노선 **팀명:** 속도는벡터 **소속:** 연세대학교 컴퓨터과학과 2026-1 캡스톤 디자인 **발표자:** (팀 내부 분담 예정 — 박세은 / 강재현 / 조현빈 / 이동욱) **날짜:** 2026-04-28

발표자 스크립트 (15초)

안녕하세요. 속도는벡터 팀입니다. Exqutor 논문의 Adaptive Sampling 이 단일 테이블 벡터 범위 쿼리에서 사각지대를 가진다는 발견과, 이를 두 단계로 해소한 결과를 발표합니다.

Slide 2 — 목차

본문 1. 연구 배경: Exqutor 와 벡터 카디널리티 추정 문제 2. 연구 질문 (RQ1 / RQ2 / RQ3) 3. 4/14 RQ1 1차 실험: 가설 H1 기각 4. Exqutor Design Constraint 발견 5. 수정 노선: Pivot A + Pivot C 병합 6. Phase 4 결과: Pivot A (BERNOULLI) native 검증 7. Phase 6 Step 4 결과: Pivot C (KM20) native 검증 8. 외적 타당성: Phase 7 sf10 + sift 9. 한계와 남은 작업 / 최종발표 로드맵 10. 결론 및 Q&A

발표자 스크립트 (20초)

10장으로 구성됩니다. 배경과 RQ 소개 후 4월 14일 하루에 걸친 실험 결과를 차례로 보여드리고, 마지막에 최종발표까지의 로드맵을 공유합니다.

Slide 3 — 연구 배경: Exqutor 와 벡터 카디널리티 추정 문제

화면 본문 - pgvector / VBASE / DuckDB 는 벡터 조건의 선택도를 **고정 비율** 로 추정 (33.3% / 50% / 100%) - 실제 선택도는 query 에 따라 **0.001% ~ 90%** 까지 다양 - → 옵티마이저가 잘못된 실행 계획 선택 (nested loop vs hash join, index 사용 여부) - **Exqutor** (arXiv:2512.09695v2, 2024) 의 두 해법 - **ECQO**: HNSW 인덱스가 있을 때 range query 를 직접 실행해 1~2 ms 로 정확 카디널리티 - **Adaptive Sampling**: 인덱스가 없을 때 모멘텀 기반 동적 샘플링 - pgvector 최대 1000 배, VBASE 10000 배, DuckDB 1.5~37 배 성능 향상 달성

figure placeholder: Exqutor 논문 Figure 1 또는 본 팀이 재작성한 "추정 vs 실제 선택도" 개념도 (1 장)

발표자 스크립트 (45초)

Exqutor 는 벡터 데이터베이스의 카디널리티 추정 정확도 문제를 해결한 최신 논문입니다. 기존 시스템은 벡터 조건의 선택도를 고정 비율로 추정해 왔는데, 이 때문에 옵티마이저가 잘못된 실행 계획을 선택하는 경우가 많았습니다. Exqutor 는 두 가지 해법 — ECQO 와 Adaptive Sampling — 로 이를 해소했고, pgvector 에서 최대 1000 배까지 성능 향상을 보고했습니다. 본 연구는 이 Adaptive Sampling 의 정확도 개선 여지를 공략합니다.

예상 Q&A - Q: Exqutor 의 ECQO 와 Adaptive Sampling 중 어느 쪽을 다루나요? → A: Adaptive Sampling 만. ECQO 는 인덱스가 있을 때의 정확 해법이므로 개선 여지가 적습니다.

Slide 4 — 연구 질문 (RQ1 / RQ2 / RQ3)

화면 본문 - **RQ1 (Motivation)**: Exqutor Adaptive Sampling 은 실제로 정확도 한계를 가지는가? 한계의 구조는? - **RQ2 (Distribution-Aware)**: 분포를 알 때, stratified sampling 이 카디널리티 추정 정확도를 얼마나 개선하는가? - **RQ3 (Distribution-Agnostic)**: 분포를 모를 때, pilot sample + KDE 로 자동 총화하면 얼마나 개선되는가? - 4/3 교수님 미팅 확정. **본 발표의 범위**: RQ1 Motivation + RQ2 본선 구현 (중간발표 β)

figure placeholder: RQ1~RQ3 의 3 단계 구조도 (베이스라인 → Aware → Agnostic)

발표자 스크립트 (30초)

연구 질문은 3 단계입니다. 먼저 RQ1 에서 Exqutor 의 정확도 한계를 정량 측정합니다. 그 다음 분포를 알 때의 개선 가능성을 RQ2 에서, 분포를 모를 때의 실용적 해법을 RQ3 에서 다룹니다. 오늘 발표는 RQ1 과 RQ2 까지를 다루고, RQ3 는 최종발표에 포함됩니다.

Slide 5 — 4/14 실험 1단계: H1 기각과 글로벌 skew 지표의 무효화

화면 본문 - 실험: `partsupp_deep_10` 1M subset, 96d DEEP, 100 query $\times$ 6 selectivity $\times$ 5 seed = 3000 Adaptive Sampling 측정 - **가설 H1 (4/3)**: Fisher γ 큰 그룹의 Q-error 가 작은 그룹 대비 2 배 악화 - **결과**: 12 조합 모두 ratio ≈ 1.0 , 24 조합 모두 `!Spearman p | < 0.2` - 100 query 전부 Fisher $\gamma < 0$ (left-skewed), tail ratio $P99/P50 \in [1.07, 1.17]$ 좁은 범위 $\rightarrow$ **고차원 거리 집중** - 추가 검증: **로컬 4 지표도 전수 무효** (k-NN entropy, PCA EVR1, KDE modality, NN clustering) - 글로벌 4 + 로컬 4 = **8 지표 전수 검증 후 query-conditional layer 정의 사전 식별 불가능**

figure placeholder: Figure 6 — Phase 5 local skew 24 조합 Spearman ρ heatmap (negative result, [experiments/figures/rq1_motivation/figure_6_phase5_heatmap.png](#))

발표자 스크립트 (1분)

4월 14일 오전 1 차 실험에서 저희는 원래 가설 — skew 가 크면 Q-error 도 증가한다 — 을 기각했습니다. Fisher γ 등 글로벌 4 지표 모두 Q-error 와 Spearman 상관 ρ 가 0.2 미만으로 사실상 신호가 없었고, 그룹 비교도 12 조합 모두 ratio 가 1.0 근처였습니다. 더 나아가 로컬 4 지표까지 추가로 검증했지만 역시 24 조합 모두 $|\rho| < 0.2$ 로 무효화되었습니다. 이 결과의 학술적 의미는 "고차원 벡터 데이터에서 query-side feature 로 layer 를 사전 정의하는 것이 불가능하다" 는 **정량 negative result** 입니다. 이것 자체가 본 연구 motivation 의 한 축이 됩니다.

예상 Q&A - Q: Spearman $|\rho| < 0.2$ 라는 threshold 는 어디서 왔나요? $\rightarrow$ A: 설계안 pre-specified. Cohen (1988) 의 small effect size 0.10 을 넘는 선에서 설정. - Q: 100 query 가 모두 left-skewed 라는 건 query 선택 편향 아닌가요? $\rightarrow$ A: 100 query 를 DEEP 벡터 전체에서 무작위 추출했기 때문에 데이터셋 자체의 성질입니다.

`DISTINCT ON (ps_partkey)` 로 결정론적 재현 가능.

Slide 6 — Exqutor Design Constraint 발견 (본 연구의 새 motivation

첫 줄)

화면 본문 - 4/14 오후 Phase 3 옵션 A 네이티브 검증 시도에서 발견 - (i) Hook Trigger 사각지대: `vector.c` line 243 `if (table_count > 2)` — 단일 테이블 vector range query 는 Exqutor hook 경로에서 배제 - 본 팀이 직접 확인: 모든 query 가 PG default selectivity 1/3 (= 333,333 행) 로 fall-through - Exqutor Adaptive Sampling 함수 자체에 도달하지 못함 - (ii) Plan Replacement 부작용: hook 을 `>= 1` 로 우회하면 outer query 의 plan-tree 가 `Sample Scan` 으로 교체 - true = 100,000 query 의 `SELECT count(*)` 가 sample 안 부분 카운트 32 로 격하 - hook 이 단순 estimation 이 아니라 plan execution 자체를 sample scan 으로 격하 - **본 두 finding 은 Exqutor 원논문 본문에 명시되지 않음**. 본 팀이 소스 검증으로 첫 정량 확인 - → 단일 테이블 vector range query (이미지 검색 / 추천 / RAG retrieval) 는 **Exqutor 의 명시되지 않은 사각지대**

figure placeholder: `vector.c` line 243 의 소스 코드 스니펫 + EXPLAIN ANALYZE 의 Sample Scan 노드 출력 (2 column 레이아웃)

발표자 스크립트 (1분 10초)

원래 가설이 기각된 것을 받아들이고, 저희는 Exqutor 네이티브 경로로 Python 재구현의 동치성을 검증하려고 했습니다. 그 과정에서 Exqutor 논문 본문에 명시되지 않은 두 가지 design constraint 를 발견했습니다. 첫 번째는 Exqutor 의 Adaptive Sampling hook 이 `table_count > 2` 조건으로 **단일 테이블 vector range query** 를 경로에서 배제 한다는 것입니다. 즉 `SELECT count(*) FROM t WHERE (vec <-> q) < D` 형태의 가장 단순한 vector range query 는 Exqutor 에 도달조차 하지 못합니다. 두 번째는 이 조건을 한 줄 우회해도 outer query 의 plan-tree 가 `Sample Scan` 으로 교체되어 outer query 결과 자체가 sample 안 부분 카운트로 격하된다는 것입니다. 이 두 finding 은 Exqutor 가 multi-table join 을 가정한 해법임을 보여주며, 단일 테이블 vector range query — 이미지 검색, 추천, RAG retrieval 같은 실무 시나리오 — 는 Exqutor 가 명시적으로 배제한 사각지대입니다. **본 두 발견이 저희 연구의 새 motivation 첫 줄입니다.**

예상 Q&A - Q: 왜 `table_count > 2` 로 조건을 걸었을까요? → A: 본 팀의 추정은 Exqutor 논문이 multi-table join + vector range filter 를 본선 시나리오로 가정했기 때문. 저자가 본선 시나리오에서만 hook 이 활성화되도록 설계한 의도 반영. - Q: 그래서 `>= 1` 로 바꿔서 실험한 건가요? 그럼 Exqutor 와 다른 시스템이 되는 것 아닌가요? → A: 네, 본 팀의 Pivot A/C 측정은 `>= 1` 수정 상태에서 수행. 두 모드 (BERN, STRAT) 비교는 모두 같은 plan replacement 경로 위에서 이뤄지므로 **상대값 비교** 는 유효 (절대값은 plan replacement 부작용으로 해석 주의). 변경된 `vector.c` 와 원본 백업을 모두 보존.

Slide 7 — 수정 노선: Pivot A + Pivot C 병합 (4/14 17:35 KST 확정)

화면 본문 - Pivot A — Block sampling bias 제거 - `vector.c` L889 의 `TABLESAMPLE SYSTEM(%f)` → `TABLESAMPLE BERNOULLI(%f)` (한 줄 교체) - Fair baseline 도구: 단독 기여가 아닌 Pivot C 의 측정 단위 - Pivot C — Data-side k-means K=20 stratified sampling - `vector.c` +228 줄: GUC 3 개 + stratum_sizes 캐시 + `estimate_cardinality_with_stratified_sampling` - 데이터 자체에 numpy mini-batch k-means K=20 으로 partition (seed=42) - `stratum_id smallint` 컬럼 + index 사전 부여 → query 시점 overhead 0 - per-stratum `ORDER BY random() LIMIT sample_size/K` + Horvitz-Thompson 가중 추정 $est = \sum (n_i \cdot cnt_i / s_i)$ - 두 Pivot 은 직교적 → SYSTEM / BERNOULLI / STRATIFIED × dataset × selectivity 의 ablation matrix 로 각 기여 분리

figure placeholder: 두 Pivot 의 효과를 보여주는 개념도 — (왼쪽) SYSTEM → BERNOULLI 의 block bias 제거, (오른쪽) data-side KM20 partition

발표자 스크립트 (1분)

본 두 finding 위에서 저희는 두 가지 sanitize 를 병합한 수정 노선을 확정했습니다. 첫째, Pivot A 는 Exqutor 가 사용하는 `TABLESAMPLE SYSTEM` 을 `BERNOULLI` 로 한 줄 교체해 block sampling bias 를 제거합니다. 이것은 단독 기여가 아니라 fair baseline 구축 도구입니다. 둘째, Pivot C 는 data-side k-means K=20 으로 데이터 자체를 partition 한 후 stratified sampling 을 native 로 구현합니다. 두 Pivot 은 직교적이므로 ablation matrix 로 각 개선의 기여를 분리 측정할 수 있습니다. 슬라이드 8 과 9 에서 두 Pivot 의 정량 결과를 보여드립니다.

Slide 8 — Phase 4 결과: Pivot A (BERNOULLI) Native 검증 ★

화면 본문 - 측정: 100 query × 6 selectivity × 1 seed × 2 mode = 1200 query, Exqutor 네이티브 PG 55436 - paired Wilcoxon (alt: SYSTEM > BERNOULLI)

selectivity	SYS median	BERN median	diff%	p	유의
0.001	2.597	2.597	+0.0	0.596	—
0.010	1.558	1.299	+20.0	0.240	—
0.050	1.203	1.195	+0.7	0.0009	★★
0.100	1.212	1.132	+7.0	< 0.001	★★★
0.300	1.210	1.079	+12.0	< 0.001	★★★
0.500	1.153	1.052	+9.6	< 0.001	★★★

- 4 selectivity 구간에서 $p < 0.001$ — block sampling bias 는 통계적으로 유의한 구조적 약점
- `vector.c` 한 줄 교체로 Exqutor 카디널리티 추정 개선 경로 확보

figure placeholder: Figure 1 — Phase 4 SYSTEM vs BERNOULLI paired scatter, 6 selectivity grid, 대각선 $y=x$

발표자 스크립트 (1분 10초)

Pivot A 의 정량 검증은 Phase 4 에서 완주했습니다. 100 query × 6 selectivity 를 SYSTEM 모드와 BERNOULLI 모드 각각 네이티브에서 측정한 결과입니다. 4 selectivity 구간 — $s=0.05, 0.1, 0.3, 0.5$ — 에서 모두 paired Wilcoxon $p < 0.001$ 로 SYSTEM 의 q-error 가 BERNOULLI 보다 통계적으로 유의하게 큼니다. 가장 큰 효과는 $s=0.5$ 에서 median 기준 약 9.6% 개선입니다. 즉 Exqutor 가 사용하는 `TABLESAMPLE SYSTEM` 에는 block 단위 샘플링으로 인한 구조적 bias 가 존재하며, `vector.c` 한 줄을 `BERNOULLI` 로 교체하는 것만으로 이를 제거할 수 있다는 것이 native 경로에서 직접 확인되었습니다.

예상 Q&A - Q: `s=0.001` 에서 SYS 와 BERN 이 같은 이유는? → A: 두 모드 모두 sample 안 matching count 가 0 에 가까워 Exqutor 의 `cnt=0 → 1` clamp 가 발동. 이 영역은 sampling method 와 무관하게 구조적으로 변별 불가능.

Slide 9 — Phase 6 Step 4 결과: Pivot C (KM20) Native 검증 ★★★

화면 본문 - 측정: 같은 100 query × 6 selectivity × 1 seed × 2 mode (BERN v2 + STRAT KM20), native 경로
 - `vector.c` +228 줄 구현: GUC 3 개 + stratum_sizes 캐시 + stratified SPI SQL + HT 가중 추정 - data-side: `partsupp_deep_10_subset_1m` 에 `stratum_id smallint` 컬럼 + index 사전 부여 (Option B 안전) - paired Wilcoxon (alt: STRAT < BERN)

selectivity	BERN median	STRAT median	diff%	p	유의
0.001	2.581	2.581	+0.00	0.451	—
0.010	1.292	1.387	-7.41	0.797	—
0.050	1.211	1.143	+5.62	0.0068	★★
0.100	1.110	1.108	+0.12	0.045	★
0.300	1.062	1.052	+0.94	0.102	—
0.500	1.053	1.034	+1.81	4.01e-05	★★★

- 3 selectivity 구간에서 $p < 0.05$, 최강 신호 $s=0.500$ 에서 $p = 4.01e-05$ (Phase 4~6 전체 최강)
- Python counterfactual (Phase 6 Step 3') 과 일치성 검증: 3 구간 유의 영역 재현, 방향 일치, 효과 크기 한 자리 % 내 일치

figure placeholder: Figure 2 — Phase 6 Step 4 KM20 native $s=0.500$ BERN vs STRAT boxplot ([figure_2_phase6_box.png](#))

발표자 스크립트 (1분 20초)

Pivot C 의 정량 검증은 Phase 6 Step 4 에서 완주했습니다. 저희는 `vector.c` 에 +228 줄의 stratified sampling 분기를 직접 구현하고, 데이터에 KM20 로 학습된 stratum_id 컬럼을 미리 부여했습니다. Native 경로에서 $100 \text{ query} \times 6 \text{ selectivity} \times 2 \text{ mode}$ 를 측정한 결과, 3 selectivity 구간 — $s=0.05, 0.1, 0.5$ — 에서 paired Wilcoxon $p < 0.05$ 로 stratified 가 bernoulli 대비 통계적으로 유의하게 우위입니다. **가장 강력한 신호는 $s=0.500$ 에서 $p = 4.01e-05$ 로 본 연구 전체의 최강 유의 구간입니다.** 이 결과는 Python 재구현으로 먼저 확보한 결과와 방향이 일치하며, 효과 크기도 한 자리 퍼센트 내에서 일치합니다. 즉 data-side k-means $K=20$ 기반 stratified sampling 은 Exqutor 의 정확도를 측정 가능한 수준으로 개선하는 유효한 경로임을 native 로 직접 확인했습니다.

예상 Q&A - Q: 왜 KM20 인가요? 다른 K 값은 시도했나요? → A: Phase 6 Step 3' 에서 PCA decile, KM10, KM20 4 layer 를 동시 비교. KM20 이 가장 넓은 적용 범위 (3 selectivity ★) + 새 영역 $s=0.100$ 확보. Layer sweep ($K=30/40/50$) 은 최종발표 W5 에서. - Q: `s=0.010` 에서 STRAT 가 BERN 보다 -7% 열세인데 이유는? → A: $K=20$ 의 per-stratum sample budget (`sample_size/K ≈ 19`) 이 작은 selectivity 구간에서 variance 증폭. fine-grained partition 의 trade-off 로 honest 보고. - Q: per-stratum `ORDER BY random() LIMIT` 의 비용은? → A: BERN 대비 11 배 느림 (83 초 → 908 초). 최종발표 W5 에서 per-stratum `TABLESAMPLE BERNOULLI` 최적화로 2 배 이내 감소 목표.

Slide 10 — 외적 타당성: Phase 7 확장 (sf10 8M + sift 128d) ★★★★★

화면 본문 - Phase 7-1: sf10 8M 재현 완주 ([partsupp_deep_10_phase7_8m_subset](#)) - Setup 17 분 (8M COPY + KM20 학습 5.2초 + UPDATE 347.8초 + VACUUM 400.4초) - Measurement 23 분 (BERN 7 분, STRAT 17 분, total) - Phase 7-2: sift 128d 확장 완주 ([customer_sift_10_phase7_noidx_subset](#) , HNSW 우회) - Setup 3 분 (vanilla→Exquitor transfer 2분 33초 + KM20 + UPDATE) - Measurement 7 분 (BERN 1 분, STRAT 4 분, total)

Dataset	Mode	median Q-error	improvement	paired p (alt: STRAT < BERN)
deep 96d (1M, Phase 6)	BERN	1.0529		—
deep 96d (1M, Phase 6)	STRAT	1.0339	1.018×	4.01e-05 ***
— 같은 1M, s=0.001 영역	BERN	2.5806		—
—	STRAT	2.5806	1.0× (동률)	0.451
deep 96d (8M, Phase 7-1)	BERN	20810.21		—
deep 96d (8M, Phase 7-1)	STRAT	9.60	2,168×	1.95e-18 ****
sift 128d (1.5M, Phase 7-2)	BERN	3875.34		—
sift 128d (1.5M, Phase 7-2)	STRAT	9.48	409×	1.95e-18 ****

- **부수적 발견:** Phase 7 두 실험의 actual selectivity 는 의도한 0.500 이 아니라 약 0.0001 영역. 1M subset 에서 derive 된 D_target 이 8M 원본 / 128d sift 의 거리 분포 dense 효과로 작은 selectivity 영역으로 이동.
- 이 actual selectivity 영역은 Phase 6 Step 4 에서 BERN/STRAT 동률이었던 cnt-clamp fallback 영역 과 동일 — 그러나 8M 규모 / 128d 차원에서는 같은 영역에서 STRAT 가 압도 (100/100 query, $p < 1e-18$).
- 안전 경로: 원본 테이블 보존, 별도 테이블 COPY 후 [stratum_id](#) 부여 (Option B)

figure: Figure 4 — Phase 7 dataset × mode heatmap ([experiments/figures/rq1_motivation/figure_4_phase7_heatmap.png](#))

발표자 스크립트 (1분 10초)

Phase 7 의 두 외적 타당성 확장 실험은 8M 원본 deep 과 1.5M sift 128d 에서 KM20 stratified 의 효과를 측정했습니다. 의도한 selectivity 0.5 가 1M→8M 의 거리 분포 dense 효과로 actual 0.0001 영역으로 이동했지만, 이 영역은 Phase 6 Step 4 에서 BERN 과 STRAT 가 동률이었던 cnt-clamp fallback 영역과 정확히 같습니다. 그런데 8M 규모와 128d 차원에서는 같은 영역에서 STRAT 가 BERN 의 1/2168 (deep 8M) 와 1/409 (sift 128d) 의 q-error 를 보입니다. 두 dataset 모두 100 query 모두에서 STRAT win, paired Wilcoxon p 가 1e-18 미만으로 본 연구 전체의 단일 최강 통계적 신호입니다. 이는 Pivot C 의 효과가 정상 selectivity 영역 (Phase 6 Step 4 의 1.018x 정량 우위) 과 small selectivity 영역 (Phase 7 의 409~2168 배 정성 개선) 양쪽에서 보완적으로 확인됨을 의미합니다.

예상 Q&A - Q: 8M 전체에 k-means 를 재학습해야 하나요? → A: 네, numpy mini-batch k-means (K=20, seed=42, 100 iter, 4096 batch) 로 5.2 초. 8M 의 centroid 는 1M subset centroid 와는 다르지만 데이터 자체가 다르므로 정상. - Q: sift 의 HNSW 인덱스는 어떻게 처리하나요? → A: `customer_sift_10_phase7_noidx_subset` 별도 테이블에 HNSW 없이 minimal transfer (c_custkey + c_embedding 만, 838 MB, 2 분 33 초). Sampling 경로 강제. - Q: 왜 actual selectivity 가 의도한 것과 다른가요? → A: 1M subset 에서 거리 분포 quantile 0.5 로 결정된 D_target 을 8M 원본에 적용했을 때, 8M 의 dense 한 거리 분포 (더 많은 nearby vectors) 때문에 같은 거리 threshold 에서 매칭 행 수가 줄어들었습니다. 이는 1M→8M 의 자연스러운 결과이며, paired 비교는 같은 D_target 위에서 valid. - Q: 2168 배 같은 이상한 ratio 는 plan_rows 기반인가 hook 기반인가? → A: plan_rows (EXPLAIN 의 Plan Rows) 기반. hook estimate (서버 로그 parsing) 는 EXPLAIN ANALYZE 의 hook call 횟수 align 이 깨져서 garbage. plan_rows 는 query 와 1:1 대응 이 보장되므로 robust.

Slide 11 — 한계와 남은 작업 / 최종발표 로드맵

화면 본문 - 중간발표까지의 한계 (honest report) - (a) 1M × 96d DEEP 단일 dataset, 100 query × 1 seed (β 확장 중) - (b) s=0.010 에서 STRAT 가 BERN 대비 -7% 열세 (fine-grained partition 의 sample budget trade-off) - (c) `vector.c` 의 단일 테이블 hook 우회 수정은 Exqutor 원 동작과 다름 (상대값 비교만 유효) - (d) Phase 5 의 query feature 사전 식별 불가능성은 DEEP 96d 의 성질 — 다른 차원 / 데이터에서 재검증 필요 - **최종발표 로드맵 (5/27)** - **W5**: per-stratum `TABLESAMPLE BERNOULLI` 최적화 + Layer sweep (K=30/40/50) + wiki 768d 검증 - **W6**: 3 dataset × 3 mode × 6 selectivity × 10 seed × 500 query 전면 ablation - **W7**: RQ3 KDE-pilot 구현 (1D distance KDE + quantile 경계, 고차원 k-means 재학습 회피) - **W8**: 최종보고서 + 포스터 + 전시회 데모 + 리허설

figure placeholder: W5~W8 의 간트 차트 (주차별 핵심 작업 bar + 의존 관계)

발표자 스크립트 (1분)

현재까지의 결과는 네 가지 한계를 가지고 있습니다. 단일 데이터셋이라는 제약, 작은 selectivity 에서의 열세, hook 우회 수정이 Exqutor 원 동작과 다르다는 점, 그리고 Phase 5 의 negative result 가 DEEP 96d 의 성질일 가능성입니다. 이 한계들을 최종발표까지 4 주 로드맵으로 해소합니다. W5 에는 속도 최적화와 Layer sweep, W6 에는 3 데이터셋 전면 ablation, W7 에는 RQ3 KDE-pilot 구현, W8 에는 최종보고서와 포스터를 완성합니다. 특히 RQ3 는 고차원 k-means 재학습을 회피하는 경량 경로 — 1D distance KDE + quantile 경계 — 로 설계해 본 연구의 기술적 리스크를 낮춥니다.

Slide 12 — 결론

화면 본문 - 기여 1: Exqutor Adaptive Sampling 의 단일 테이블 **vector range query** 사각지대 를 직접 소스 검증 + EXPLAIN ANALYZE 로 정량 확인 (Hook trigger 사각지대 + plan replacement 부작용) - **기여 2:** query-side feature 8 지표 전수 검증으로 **사전 식별 불가능성 정량 확인** (글로벌 4 + 로컬 4, 24 조합 모두 $|p| < 0.2$) - **기여 3:** Block sampling bias 의 한 줄 교체 **sanitize** (Pivot A, `vector.c` L889) — 4 selectivity 구간 $p < 0.001$ - **기여 4:** **Data-side k-means K=20 기반 stratified sampling 의 native 구현** (Pivot C, +228 줄) — 두 영역에서 보완적 효과: (i) 정상 selectivity 영역 (Phase 6 Step 4, 1M deep $s=0.500$) 1.018× 정량 개선 + $p=4.01e-05$, (ii) small selectivity 영역 (Phase 7, 8M deep + 1.5M sift) **409~2168 배** 정성 개선 + $p<1e-18$, **100/100 query win** - **기여 5 (최종발표):** 1D distance KDE + quantile 경계 기반 **distribution-agnostic 경량 대안** — 고차원 k-means 재학습 회피

발표자 스크립트 (40초)

결론입니다. 본 연구의 기여는 다섯 가지로 정리됩니다. Exqutor 의 사각지대 발견, query feature 사전 식별 불가능성의 정량 확인, 두 가지 직교적 sanitize — BERNOULLI 한 줄 교체와 data-side KM20 stratified — 의 native 구현과 정량 효과, 그리고 최종발표까지 완성할 distribution-agnostic 경량 대안입니다. 본 연구 RQ2 본선의 양대 anchor 는 정상 selectivity 영역의 Phase 6 Step 4 ($s=0.500$ $p=4.01e-05$) 와 small selectivity 영역의 Phase 7-1 deep 8M (ratio 2168 배, $p<1e-18$, 100/100 query win) 입니다. 두 영역에서 모두 STRAT 가 BERN 을 압도하며, 보완적 결과로서 Pivot C 의 강건성을 입증합니다. 감사합니다. 질문 받겠습니다.

Slide 13 (선택/부록) — Appendix: 추가 Design Constraint 와 기술적 발견

화면 본문 (질문 대응용) - (iii) q-error inf 발산: single-table hook 우회 시 이중 sampling (plan-time SPI + ExecutorRun) 으로 첫 sample 매칭 0 건 → $q_error = inf$ - **(iv) sample_size NaN 발산:** 50 query 시퀀스 중 $q[25]$ 부근에서 Adaptive update 가 NaN 으로 발산 → `TABLESAMPLE SYSTEM(NaN)` parser 에러 - **(v) Adaptive update path SIGSEGV:** Phase 4 첫 sanity check 에서 $q3$ ($s=0.050$) 실행 중 PG 가 signal 11 로 종료. `update_sample_size = off` GUC 로 회피 - 셋 모두 **Adaptive Sampling loop 가 multi-table only design intent 를 가정** 한 결과. 본 연구의 Phase 4~6 측정은 `update_sample_size = off` 로 $sample_size=385$ fixed 한 채 sampling method 만 분리 측정.

발표자 스크립트 (부록 사용 시)

부록 슬라이드입니다. 본 팀이 발견한 design constraint 는 총 5 가지입니다. 본문 슬라이드에는 가장 중요한 두 가지만 담았고, 나머지 세 가지는 Adaptive Sampling loop 의 수치 안정성 관련 기술적 발견이므로 부록으로 따로 정리했습니다. 세 finding 모두 multi-table only design intent 로부터 파생된 것이며, 본 연구는 `update_sample_size = off` GUC 로 Adaptive update 경로를 차단하고 sampling method 자체의 효과만 분리 측정했습니다.

슬라이드 제작 메모

- 본 md 를 기반으로 .pptx 변환 시 `scripts/md2pdf.py` 가 아닌 **별도의 PPT 변환 경로 필요** (파워포인트 수작업 또는 theme-factory skill)
- 발표 시간 10 분 기준 분배: S1 (0:15) + S2 (0:20) + S3 (0:45) + S4 (0:30) + S5 (1:00) + S6 (1:10) + S7 (1:00) + S8 (1:10) + S9 (1:20) + S10 (1:10) + S11 (1:00) + S12 (0:40) = **10:10**, Q&A 5 분 여유 (S10 + S12 가 Phase 7 결과 반영으로 살짝 늘어남)
- 발표자 분담 (제안):
- 박세은 (팀장): S1~S4 + S12 (배경 + 결론)
- 조현빈: S5~S9 (실험 결과)
- 강재현 or 이동욱: S10~S11 (외적 타당성 + 로드맵)
- 팀 리뷰 라운드: 4/22~4/24 (최소 2 회), 리허설 4/24~4/26 (최소 2 회)
- 자문 회신에 따른 수위 조정: (c) 의 기본 결정은 "(a) 첫째·둘째만 본문" — 멘토 회신 후 수정 가능
- **Phase 7 수치 업데이트 완료 (4/15 08:31 KST)** — Slide 10 + Slide 12 결론 모두 반영됨

참고 figure 매핑

Slide	Figure 파일	상태
5	<code>experiments/figures/rq1_motivation/figure_6_phase5_heatmap.png</code>	✅ 생성 완료
6	<code>vector.c</code> 코드 스니펫 (수작업)	발표자 직접
8	<code>experiments/figures/rq1_motivation/figure_1_phase4_scatter.png</code>	✅
9	<code>experiments/figures/rq1_motivation/figure_2_phase6_box.png</code>	✅
10	<code>experiments/figures/rq1_motivation/figure_4_phase7_heatmap.png</code>	✅
부록 (Slide 5 대체 가능)	<code>experiments/figures/rq1_motivation/figure_3_phase6_layer_compare.png</code>	✅
부록 (Slide 9 대체 가능)	<code>experiments/figures/rq1_motivation/figure_5_python_native_table.png</code>	✅

파생 산출물 + cross-link

본 구조 md 는 중간보고서 Section 4 (연구 내용) 의 1 차 초안 역할을 겸했다. `submission/속도는벡터_중간보고서.md` v1 (350 줄, 8 섹션) 이 작성 완료되었으며, 본 슬라이드의 Slide 5~10 화면 본문 + 발표자 스크립트는 중간보고서 §4.2 ~ §4.7 와 정확히 1:1 대응된다. 슬라이드 발표자는 더 자세한 narrative 가 필요할 때 중간보고서의 해당 절을 참조하면 된다.