

속도는벡터 — 중간발표 스크립트 (10 분 분량 · 17 슬라이드)

발표자: 강재현 (주 발표자) **일시:** 2026-04-29 (수) 15:00 / 또는 4-30 (목) 19:00 — **택일 시간 배분:** 10 분 발표 + Q&A 5 분 **총 발표 분량:** 약 620 초 (평균 35 초/슬라이드, 핵심 슬라이드 60 초까지 가변, 페이스에 따라 600 초로 단축 가능) **톤:** 학술 발표체 (~합니다 / ~이다), 1 인칭 "저희" 사용

시간 배분 매트릭스

슬라이드	제목	시간 (초)	누적 (초)	비고
S1	표지	25	25	인사 + 제목
S2	목차	20	45	5 섹션 흐름 안내
S3	1. 문제 정의	40	85	카디널리티 추정 문제
S4	2. 기존 연구 — Exqutor 보완책	40	125	ECQO + Adaptive Sampling
S5	2'. Exqutor 의 한계 — 단일 테이블 사각지대	45	170	Hook trigger blind spot
S6	3. 차별성 — 두 단계 sanitize	45	215	Pivot A + Pivot C
S7	4- I . RQ1 — 8 지표 negative	55	270	RQ1 핵심 발견
S8	4- II . RQ2 (1) — Pivot A BERNOULLI	55	325	+9.6% paired Wilcoxon
S9	4- III. RQ2 (2) — KM20 Stratified	65	390	5-seed CI 외적 타당성
S10	4- IV. RQ2 외적 타당성	50	440	3 데이터셋 cross-check
S10B	4- V. RQ2 해석 — Two-Level + HHI/CV	35	475	+19.6%p 단독 기여
S11	4- VI. RQ3 (설계) — 7 way Recovery Rate	35	510	5 월 비교 실험 plan
S12	5- I . 현재 진행 상황 (W1~W9)	30	540	진행률 요약
S13	5- II . 향후 계획 (W10~W15)	25	565	5/27 발표 + 6/11 보고서
S14	5- III. 팀원별 역할 분담	25	590	4 인 분담
S15	결론 — 4 핵심 발견	25	615	wrap-up
S16	감사 인사	5	620	"감사합니다"
총		620 초 / 10 분 20 초		5~10 초 여유 — 발표 페이스에 따라 가감

S1. 표지 (25 초)

안녕하세요. 연세대학교 캡스톤디자인 **속도는벡터** 팀의 강재현입니다. 저희 팀은 박세은 팀장, 그리고 조현빈, 이동욱 학우와 함께 4 인이 한 학기 동안 진행해 온 연구를 발표드리겠습니다. 발표 제목은 **"Skew-Aware Stratified Sampling 을 이용한 벡터 카디널리티 추정 정확도 개선 연구"** 입니다. 지도교수님은 박광현 교수님, 지도 연구원은 임채림 석사이십니다.

S2. 목차 (20 초)

발표는 5 개 섹션으로 구성됩니다. ① 문제 정의, ② 기존 연구의 한계, ③ 저희 연구의 차별성, ④ RQ1 부터 RQ3 까지의 실험·설계 결과, 마지막으로 ⑤ 진행 상황과 향후 계획입니다. 핵심 메시지는 **데이터 분포의 스킨이 클수록 공간 인식 sampling 의 가치가 크다** 는 것입니다.

S3. 1. 문제 정의 (40 초)

벡터 데이터베이스에서 가장 흔한 형태의 쿼리는 **거리 기반 조건** 이 들어간 SELECT 입니다. 예를 들어 **WHERE (v <-> q) < D** 와 같이 임베딩 벡터 v 와 쿼리 벡터 q 의 거리가 임계 D 이하인 행을 찾는 쿼리입니다. 이런 쿼리에서 옵티마이저가 잘못된 plan 을 선택하지 않으려면 **카디널리티(cardinality)**, 즉 **결과 행 수의 정확한 추정** 이 필수입니다. 그러나 pgvector 는 33.3 %, VBASE 는 50 %, DuckDB 는 100 % 라는 **고정 비율** 만을 사용하기 때문에 추정 오차가 크고, 이로 인해 잘못된 실행 계획이 선택되는 경우가 많습니다.

S4. 2. 기존 연구 — Exqutor 의 두 보완책 (40 초)

작년 발표된 Exqutor (arXiv:2512.09695v2) 는 이 문제를 두 가지 방식으로 보완합니다. 첫째, ECQO 는 벡터 인덱스가 있을 때 옵티마이저의 plan 수립 단계에서 가벼운 range query 를 직접 실행하여 **정확한 카디널리티** 를 얻는 방식이고, 둘째, Adaptive Sampling 은 인덱스가 없을 때 TABLESAMPLE 절로 일부 행을 추출하여 결과 비율로 카디널리티를 근사하는 방식입니다. 원논문은 두 방법으로 pgvector 에서 최대 약 1,000 배, VBASE 에서 최대 약 1 만 배 의 속도 향상을 보고합니다.

S5. 2'. 한계 — 단일 테이블 사각지대 (45 초)

그런데 저희가 Exqutor 의 소스 코드를 직접 분석하면서 한 가지 사실을 발견했습니다. vector.c 의 line 243 에 `if (table_count > 2)` 라는 조건문이 있는데, 이는 Adaptive Sampling 의 핵심 hook 이 호출되기 위한 진입 조건입니다. 따라서 테이블이 두 개 이하인 단일 테이블 쿼리 는 이 조건을 통과하지 못하고 PostgreSQL 의 default selectivity 1/3 으로 fall-through 됩니다. 즉, 가장 일반적인 형태의 vector range query 가 Exqutor 의 보완 효과를 받지 못합니다. 저희는 이 영역을 Exqutor 가 자신의 multi-table only design intent 로 배제한 사각지대(blind spot) 로 정의하고, 본 연구의 출발점으로 삼았습니다.

S6. 3. 차별성 — 두 단계 sanitize (45 초)

이 사각지대를 보완하기 위해 저희는 두 가지 직교적인 sanitize 패치 를 설계했습니다. Pivot A — Block-bias 제거: vector.c line 889 의 TABLESAMPLE SYSTEM(%f) 한 줄을 TABLESAMPLE BERNOULLI(%f) 로 교체합니다. 이는 fair baseline 도구 로, paired Wilcoxon 검정에서 +9.6 %p 개선 (s=0.500, p<0.001) 을 확인했습니다. Pivot C — Data-side k-means K=20: stratum_id 를 사전 부여하고 Horvitz-Thompson 가중 추정을 수행하는 228 줄의 native 구현 으로, DEEP 1M 5-seed CI [+1.11 %, +2.18 %] 에서 양수 하한이 확정되었습니다. 두 Pivot 은 직교적 이므로 SYSTEM × BERNOULLI × STRATIFIED 의 ablation matrix 로 각 기여를 분리해서 측정할 수 있습니다.

S7. 4- I . RQ1 — 8 지표 negative + Phase 5 (55 초)

RQ1 의 목표는 Adaptive Sampling 이 단일 테이블 쿼리에서 **정말로** 한계를 가지는지를 직접 검증하는 것입니다. 저희는 4 가지 글로벌 skewness 지표 (Fisher γ , log-Fisher γ , tail ratio P99/P50, Bowley skew) 와 4 가지 로컬 skewness 지표 (KDE modality, k-NN entropy, k-NN PCA EVR1, NN clustering coef) 의 총 **8 지표 $\times$ 6 selectivity = 48 조합** 을 96 차원 DEEP 1M subset 의 6,000 측정으로 검증했습니다. 결과는 **48 조합 모두 절대값 0.2 미만** 으로 가설이 강하게 기각되었으며, 100 query 모두가 Fisher $\gamma < 0$ (left-skewed) 이고 tail ratio 도 좁은 범위에 모여 있었습니다. 즉, **고차원 벡터의 거리 집중 현상** 이 글로벌 지표의 변별력을 평탄화시켰고, query 시점에 분포를 사전 식별하는 단순 휴리스틱이 작동하지 않음을 의미합니다. 이는 본 연구가 RQ2 (distribution-aware) 와 RQ3 (distribution-agnostic) 두 트랙을 모두 다루어야 하는 핵심 근거가 됩니다.

S8. 4- II . RQ2 (1) — Pivot A BERNOULLI (55 초)

RQ2-1 은 SYSTEM 과 BERNOULLI 만을 변화시킨 **paired Wilcoxon 검정** 으로 block bias 제거의 효과를 측정합니다. 표 1 을 보시면, **Selectivity 0.050 이상의 4 개 구간 모두 $p < 0.001$** 로 SYSTEM 의 Q-error 가 BERNOULLI 보다 통계적으로 유의하게 크게 나타났습니다. 가장 큰 효과는 **s = 0.500 에서 78 / 100 의 SYSTEM 불리, median 기준 9.6 %p 개선** 이었으며, 이는 **vector.c** 한 줄 교체만으로 카디널리티 추정 정확도가 측정 가능한 수준으로 개선됨을 보여 줍니다. 우측 scatter 의 4 panel 은 각 selectivity 에서 BERNOULLI 보다 SYSTEM 의 Q-error 가 더 큰 점들이 대각선 위에 집중적으로 분포함을 직관적으로 보여 줍니다.

S9. 4-III. RQ2 (2) — KM20 Stratified (65 초, 핵심 슬라이드)

RQ2-2 는 KM20 stratified sampling 의 BERNOULLI 대비 **추가** 효과를 5 개 seed 의 반복 측정으로 검증합니다. 측정은 모두 native `vector.c` 의 STRAT 분기에서 수행되었고, q-error 는 hook 이 elog 로 서버 로그에 기록한 hook_est 를 기준으로 합니다. 좌측 표를 보시면 **selectivity 0.500 / 0.300 / 0.100 세 구간 모두 95 % 신뢰구간의 하한이 양수** 로 확정됐습니다 (+1.64 %, +2.62 %, +4.19 %). 좁은 selectivity 구간 ($s = 0.050$, $s = 0.010$) 에서는 단일 seed 측정이지만 +1.85 %, +8.93 % 로 효과가 더 커지는 경향이 명확하고, $s = 0.500$ 의 1-seed Wilcoxon p-value 는 **4.01e-05 (Bonferroni 통과)** 로 5-seed 재현이 우연 가능성을 배제합니다. 우측 box plot 의 별표는 통계적 유의성 등급(★, ★★, ★★★)을 나타내며, KM20 의 박스가 BERNOULLI 보다 일관되게 아래로 이동한 것이 시각적으로 확인됩니다.

S10. 4-IV. RQ2 외적 타당성 — 3 데이터셋 (50 초)

이 효과가 DEEP 1M 에만 국한되는 것이 아닌지 확인하기 위해 저희는 두 가지 외적 타당성 검증을 수행했습니다. 첫째, **DEEP 8M 으로 데이터 규모를 8 배 확대** 한 결과, $s = 0.500$ 신뢰구간 [+0.65, +2.86] 이 1M 의 [+1.11, +2.18] 과 **겹쳐 일치** 합니다. 즉 데이터 규모가 달라져도 효과가 유지됩니다. 둘째, **SIFT 1.5M 으로 도메인을 변경** 한 결과, $s = 0.500$ 신뢰구간 [+2.66, +3.48] 은 DEEP 의 신뢰구간과 **겹치지 않으며** 효과가 약 2 배로 커집니다. 즉 더 쏠린 분포에서는 KM20 의 효과가 더 크게 발현됩니다 — 이는 본 연구의 출발 가설을 직접적으로 검증하는 결과입니다.

S10B. 4-V. RQ2 해석 — Two-Level + HHI/CV (35 초)

그러면 KM20 의 개선이 **단순한 표본 안정화** 때문인지 **공간 인식 자체** 때문인지를 분리해야 합니다. 저희는 두 수준으로 분해했습니다 — Level 1 은 무작위 $K=20$ 분할 (RANDOM20) 의 표본 안정화 효과, Level 2 는 KM20 과 RANDOM20 의 격차로 정의되는 공간 인식 추가 이득입니다. DEEP 1M selectivity 0.010 에서 **Level 2 가 단독으로 +19.6 %p 를 기여** 합니다. 또한 SIFT 의 cluster 크기 CV (변동계수) 가 0.394 로 DEEP 의 0.234 보다 약 68 % 더 쏠려 있는데, 이러한 쏠림 격차가 KM20 효과의 약 2 배 격차와 일치합니다 — 즉 **HHI / CV 로 효과를 사전 예측** 할 수 있습니다.

S11. 4-VI. RQ3 (설계) — Recovery Rate (35 초)

RQ3 는 분포를 **사전에 모르는** 상황에서 RQ2 의 공간 인식 효과를 어느 정도 회수할 수 있는지를 측정하는 단계입니다. 평가 지표는 **Recovery Rate = (방법 X – RANDOM20) / (KM20 – RANDOM20)** 로 정의하고, **Recovery Rate ≥ 0.5 이면 KM20 의 절반 효과를 회수 한 것으로 판정합니다.** 비교 baseline 은 3 패러다임 7 방법입니다 — Offline Partition (LSH·Random Projection·Hilbert·Mini-batch K-means), Online Query-Adaptive (Distance-Shell·KDE-pilot Neyman), Weight-based (Importance Sampling). 실제 측정은 5 월의 W10 ~ W12 비교 실험 단계에서 동일한 측정 파이프라인으로 수행하여 최종보고서에 서 보고합니다.

S12. 5- I . 현재 진행 상황 (30 초)

일정은 보고서 표 4 와 일치하는 W1 ~ W9 체계로 정리됩니다. **W1 ~ W6 (3/2 ~ 4/12):** 환경 셋업 — 주제 확정, Exqutor 채택, 코드·데이터 수령, 서버 권한. **W7 (4/13 ~ 4/19):** RQ1 motivation — H1 가설 기각 + Phase 5 로컬 4 지표 negative + Design Constraint 발견. **W8 (4/20 ~ 4/26):** RQ2 Aware — Phase 4 Pivot A + Phase 6 Step 4 KM20 + 5-seed CI cross-dataset. **W9 (4/27 ~ 5/3):** 보강 + 발표 — Two-Level 분해, HHI/CV 정량, RQ3 7 way 설계, 중간보고서·발표. RQ1 + RQ2 본선 + 5-seed 외적 타당성 + RQ3 설계까지 학기 중간 시점 모든 산출물이 확보되었습니다.

S13. 5- II . 향후 계획 (25 초)

5 월에는 RQ3 비교 실험에 집중합니다. W10 ~ W12 (5/4 ~ 5/24): 7 가지 sampling 방법을 동일한 파이프라인에서 비교하고 Recovery Rate 를 산출합니다. W13 ~ W15 (5/25 ~ 6/14): **5/27 ~ 5/29 최종발표, 6/5 전시회, 6/11 최종보고서 제출** 로 마무리합니다.

S14. 5-III. 팀원별 역할 분담 (25 초)

4 인의 역할 분담은 다음과 같습니다. **박세은 팀장**: 전체 일정 관리, 자문 회신 정리, 4 인 합의 주재. **강재현** (저, 주 발표자): 중간발표 슬라이드 검수, 리허설 진행, Q&A 사회. **조현빈** (실험·문서화): RQ1/RQ2 실험 구현, vector.c native 228 줄 구현, 보고서 작성. **이동욱** (분석·작도): 통계 분석 (CI · Two-Level 분해), 그림 8 종 작성, RQ3 설계.

S15. 결론 — 4 핵심 발견 (25 초)

본 발표의 4 가지 핵심 발견을 정리하겠습니다. 첫째, **RQ1 negative**: 글로벌·로컬 8 지표 모두에서 query feature 의 사전 layer 정의가 불가능함을 정량 증명했습니다. 둘째, **RQ2 외적 타당성**: KM20 stratified 가 BERNOULLI 위에서 추가 개선을 보이며, 5-seed CI 의 하한이 양수로 확정되었습니다. 셋째, **Two-Level 분해**: Level 2 가 단독으로 +19.6 %p 를 기여하며, **공간 인식이 단독 메커니즘** 임이 확인되었습니다. 넷째, **RQ3 설계**: 분포 미지 시 KM20 의 공간 인식 효과를 회수할 수 있는지를 Recovery Rate 프레임워크로 평가하는 7 way 비교 baseline 이 모두 확정되었습니다.

S16. 감사 인사 (5 초)

발표를 들어 주셔서 감사합니다. Q&A 받겠습니다.

Q&A 분담 가이드 (참고)

발표 후 5 분 Q&A 에서는 4 인이 분야별로 답변을 분담합니다.

분야	1 차 응답자	2 차 응답자
통계 분석 (CI, paired Wilcoxon, Bonferroni, Two-Level 분해)	이동욱	조현빈
실험 구현 디테일 (vector.c, hook_est, 5-seed setseed)	조현빈	이동욱
일정·체크포인트·자문 회신	박세은	강재현
발표·슬라이드 흐름·전체 메시지	강재현	박세은

원칙: 모든 답변은 4 인 합의 후에 진행합니다. 답변 자신 없는 질문은 "확인 후 회신드리겠습니다" 로 회피.

발표 페이스 점검 체크리스트

- [] 리허설 1 (4/24 금요일): 전체 흐름 점검 + 시간 측정 (목표 9 분 30 초 ~ 10 분 30 초)
- [] 리허설 2 (4/26 일요일): 슬라이드 6, 7, 9, 10 의 핵심 메시지 30 초 이내 전달 가능 확인
- [] D-1 (4/28 화요일): LearnUs 업로드 후 마지막 1 회 시뮬레이션
- [] 발표 당일 (4/29 또는 4/30): 슬라이드 9 (KM20 5-seed CI) 와 슬라이드 10B (Two-Level +19.6 %p) 가 가장 임팩트 강한 부분 — 천천히, 강조해서 발표

비고

- **발음 주의어:** stratified (스트래티파이드), Bernoulli (베르누이), Wilcoxon (윌콕슨), Bonferroni (본페로니), Horvitz-Thompson (호르비츠-툼슨), Hilbert (힐버트), Neyman (네이만)
- **숫자 강조:** +9.6 %, +1.64 %, +19.6 %p, [+1.11, +2.18], 4.01e-05 — 이 다섯 숫자가 본 발표의 핵심 결과
- **시간 부족 시 단축 우선순위:** S2 (목차) → 10 초 / S12·S13 (진행 상황) → 각 20 초 / S16 → 0 초 (자연 종료)
- **시간 여유 시 확장 우선순위:** S9 (KM20) → 70 초 / S10 (외적 타당성) → 60 초 / S10B (Two-Level) → 50 초