

속도는벡터 중간 발표 스크립트

발표자: 강재현

발표 시간: 10 분 (질의응답 5 분 별도)

일시: 2026 년 4 월 30 일 (목) 19:00, 인증 A428

대상: 캡스톤 디자인 중간 발표 청중

작성 시점: 2026 년 4 월 28 일 (v2)

슬라이드별 진행 (10 분)

S01 표지 (10 초)

"안녕하십니까, 캡스톤 팀 속도는벡터 입니다. 저희 팀의 중간 보고를 시작하겠습니다. 발표는 제가 맡았고, 팀장 박세은, 팀원 이동욱, 조현빈 이렇게 네 명입니다."

S02 목차 (15 초)

"오늘 보고는 다섯 줄기로 진행합니다. 우리가 다루는 문제, 기존 연구의 한계, 차별성, 연구 방법, 그리고 진행 상황과 향후 계획입니다."

S03 해결하고자 하는 문제 (50 초)

"저희가 다루는 영역은 벡터 데이터베이스 입니다. 이미지·텍스트·음성처럼 의미가 중요한 데이터는 글자 그대로 비교하기 어렵습니다. 그래서 임베딩이라는 절차로 의미가 가까운 두 항목이 벡터 공간에서도 가까이 놓이도록 숫자 벡터로 바꿉니다. 이 벡터를 빠르게 검색하는 시스템이 벡터 데이터베이스이고, 챗봇 검색 보강(RAG), 추천 시스템, 이미지 검색의 핵심에 자리합니다."

저희가 묻는 질문은 단순합니다. 벡터 거리 조건의 카디널리티 — 즉 결과 행의 개수 — 를 얼마나, 어떻게 더 정확히 추정할 수 있는가? 옵티마이저가 이 추정을 잘못하면 실행 계획이 어긋나고, 그 한 번의 어긋남이 실행 시간을 1 만 배까지 늘립니다."

S04 기존 연구 — Exqutor 의 두 보완책 (50 초)

"기존 시스템은 카디널리티를 고정 비율로 추정합니다. pgvector 는 33.3 %, VBASE 는 50 %, DuckDB 는 100 %. 그러나 실제 비율은 0.001 % 부터 100 % 까지 변동하니, 이 고정값은 거의 항상 틀립니다.

최근 발표된 Exqutor 시스템 (2025)이 이 한계를 두 갈래로 풀었습니다. 인덱스가 있을 때는 *ECQO* 가 가벼운 검색을 한 번 실행해 정확한 카디널리티를 얻고, 인덱스가 없을 때는 *Adaptive Sampling* 이 일부 행을 추출해 비율로 추산합니다. 이 두 보완으로 VBASE 에서 최대 1만 배 이상의 실행 시간 개선을 보고합니다."

S05 단일 테이블 사각지대 (60 초)

"저희가 코드를 직접 읽어 확인한 사실은 이렇습니다. *Adaptive Sampling* 의 진입 조건문이 테이블이 두 개를 넘을 때만 켜지도록 짜여 있습니다. 한 줄짜리 조건문이 단일 테이블 검색을 가로막고 있어, 오히려 더 느린 PostgreSQL 의 기본값인 1/3 로 떨어집니다.

문제는 단일 테이블 검색이 이미지 검색·추천·RAG 의 핵심 형태라는 점입니다. 이 사실은 Exqutor 원논문 본문에 명시되지 않았고, 저희는 이를 *단일 테이블 사각지대* 라 부르며 본 연구의 빈자리로 보았습니다."

S06 차별성 및 중요성 (50 초)

"저희 연구의 차별성은 두 갈래입니다. 첫째, *단일 테이블 시나리오에 집중* 합니다. Exqutor 가 의도적으로 비워 둔 영역이며, 동시에 실무 응용의 핵심 쿼리 형태입니다. 둘째, *새 알고리즘이 아닌 단계적 보완의 효과를 분리해* 측정 합니다. 정확도 저하의 원인이 되는 두 메커니즘 — 추출 단위 편향과 공간 구조 쏠림 — 을 직교적으로 분리해 짚니다.

이 분리 측정은 단순히 '좋아졌다' 가 아니라 '어떤 메커니즘이 얼마나 기여했는가' 라는 *인과적 설명* 을 가능케 합니다."

S07 RQ1 — 사각지대의 구조적 한계 (50 초)

"RQ1 은 사각지대를 코드 검증으로 기록하는 단계입니다. Exqutor 의 보완은 단일 테이블에서 작동하지 않습니다. 단순히 조건만 풀어서 강제로 켜면 다른 부작용이 따라옵니다. 옵티마이저가 일부 행만 본 결과를 외부 쿼리의 답으로 격하시켜, 100,000 행이 나와야 할 결과가 32 행으로 줄어듭니다.

또 쿼리만 보고 분포 쓸림 정도를 미리 알아낼 수 있는지를 8 가지 지표로 검증했지만, 모든 조합에서 의미 있는 상관이 나타나지 않았습니다. 이는 분포를 알 때(RQ2) 와 모를 때(RQ3) 두 갈래를 모두 다뤄야 하는 직접 근거가 됩니다."

S08 RQ2 (1) — 행 단위 추출의 효과 (75 초)

"RQ2 는 데이터의 분포를 알 수 있을 때 두 갈래의 보완을 *직교적으로* 측정합니다. 첫째 갈래는 추출 단위가 만드는 편향을 없애는 것입니다.

PostgreSQL 의 기본 추출은 8KB 페이지 *블록 단위* 라서, 같은 블록 안 행들이 함께 뽑히거나 함께 빠집니다. 저희는 이를 *베르누이 추출* — 각 행을 동전 던지듯 독립으로 뽑는 방식 — 으로 바꿨습니다. 코드 한 줄 교체입니다.

DEEP 1M 데이터셋, 100 개 쿼리, 6 개 selectivity 구간에서 paired Wilcoxon 검정을 돌렸습니다. selectivity 0.5 에서는 100 개 중 78 개 쿼리에서 베르누이가 우세했고, 중앙값 9.6 % 의 개선이 통계적으로 유의했습니다 ($p < 0.001$). 0.05 이상의 네 구간 모두 동일한 방향입니다."

S09 RQ2 (2) — 공간 인식 총화 표본 (75 초)

"둘째 갈래는 데이터의 *공간 구조* 를 활용합니다. *k-means* 로 데이터를 $K = 20$ 개 영역으로 나누고, 각 영역에서 균등하게 표본을 뽑은 뒤 영역 크기에 비례한 가중치로 합칩니다. 이를 *총화 표본* 이라 부릅니다.

세 데이터셋 (DEEP 1M, DEEP 8M, SIFT 1.5M) 의 selectivity 0.5 에서 5-seed 95 % 신뢰구간을 잡았습니다. DEEP 1M 은 +1.64 %, DEEP 8M 은 +1.76 %, SIFT 1.5M 은 +3.07 % 의 추가 개선을 보였습니다. 신뢰구간이 모두 양수로 확정됐고, 데이터 규모가 달라져도 효과가 유지됨을 확인했습니다."

S10 외적 타당성 (40 초)

"DEEP 1M 과 8M 의 신뢰구간이 겹쳐 같은 데이터의 규모 변화에 영향받지 않음을 확인했고, SIFT 의 신뢰구간은 DEEP 의 것과 겹치지 않으면서 더 큰 효과를 만들었습니다. 더 쏠린 분포에서 총화 표본의 효과가 약 두 배로 커지는 것이 관찰되었습니다."

S11 인과 관계 — Two-Level 분해와 데이터셋별 격차 (75 초)

"효과가 어디서 오는지 분해해 봤습니다. 같은 $K = 20$ 으로 나누되 무작위 로 나누는 경우와 거리 기반 으로 나누는 경우를 비교한 것입니다. 좁은 selectivity 0.01 에서 무작위 분할은 오히려 -10.67 % 로 악화된 반면 거리 기반 분할은 +8.93 % 를 유지했습니다. 공간 인식 효과가 단독으로 19.6 %p 를 기여한 셈입니다. 데이터셋 사이의 격차도 같은 경로 설명됩니다. 클러스터 크기 분포의 변동계수 — DEEP 0.234, SIFT 0.394 — 가 68 % 더 쏠려 있고, 이 쏠림 격차가 효과 격차의 두 배와 함께 커집니다. 즉 데이터의 쏠림이 클수록 공간 인식 표본의 가치가 크다는 본 연구의 출발 가설을 데이터에서 직접 확인했습니다."

S12 RQ3 (탐색 단계) (60 초)

"RQ3 는 분포를 미리 모를 때 RQ2 의 효과를 어디까지 회복할 수 있는가를 묻는 단계입니다. 본 보고서 시점에는 측정 전이며, 어떤 방법들이 가능한지 폭넓게 조사한 결과만 정리했습니다."

Exqutor 의 Adaptive Sampling 과 결합한 하이브리드는 메모리 오류와 정확도 역전 때문에 후보에서 제외했고, 트리 분할·Latin Hypercube·Coreset 같은 변형들도 비용·파이프라인 적합성에서 떨어져 나갔습니다. 살아남은 후보는 세 갈래 — 데이터를 미리 나누는 방향, 쿼리마다 그때그때 나누는 방향, 영역 없이 가중치만으로 보정하는 방향입니다. 5 월에 동일 조건에서 비교 실험할 계획입니다."

S13 진행 상황 (50 초)

"4 월 첫째 주는 환경 세팅, 둘째 주에는 사각지대 발견과 RQ1·RQ2 측정, 셋째 주에는 외적 타당성과 통계 보강을 마쳤습니다. 자문위원으로부터 단일 테이블 시나리오로 좁힌 점과 두 보안을 분리해 낸 설계가 적절하다는 회신을 받았습니다."

S14 향후 계획 (40 초)

"5 월은 RQ3 의 후보 방법들을 동일 파이프라인에서 비교하는 데 집중합니다. 6 월에 최종 발표·전시회·최종 보고서로 마무리합니다."

S15 역할 분담 (20 초)

"박세은 팀장이 일정·자문 정리, 제가 발표·리허설, 조현빈이 실험·코드·문서, 이동욱이 통계 분석·작도·RQ3 설계를 맡았습니다."

S16 결론 (40 초)

"정리하면 네 가지입니다. 첫째, 단일 테이블 사각지대를 코드로 확인했습니다. 둘째, 추출 단위 한 줄 교체로 9.6 %의 정확도 개선을 통계적으로 확인했습니다. 셋째, 공간 인식 층화 표본으로 1.6 ~ 4.4 %의 추가 개선을 확보했습니다. 넷째, 분포가 쓸릴수록 공간 인식의 가치가 커진다는 인과 관계를 데이터에서 직접 확인했습니다. 5 월의 RQ3 비교 실험으로 분포 무인지 환경에서의 회복 가능성을 쟀 뒤 최종 보고서에서 종합하겠습니다."

S17 감사합니다 (5 초)

"발표를 마칩니다. 질문 받겠습니다."

예상 질문 대비

Q. RQ1 의 Sample Scan 부작용은 multi-table 시나리오에서도 발생하지 않습니까? A. multi-table 에서는 base table 의 sample scan 결과가 join 결과에 부분적으로만 영향을 줍니다. 단일 테이블에서는 outer query 의 의미 자체가 깨집니다. 이는 Exqutor 가 multi-table 가정 위에서 design intent 를 잡았기 때문입니다.

Q. K = 20 은 어떻게 정한 값입니까? A. RQ2 본 측정의 baseline 으로 K = 20 을 채택했습니다. K 값에 대한 sensitivity 는 RQ3 단계에서 sweep 으로 함께 조사할 계획입니다.

Q. RQ3 의 7 가지 후보 중 가장 기대되는 방법은? A. 미니배치 군집화 (데이터의 1 ~ 5 % 만 보고 근사) 가 비용 대비 효과 측면에서 가장 자연스러운 후보로 보입니다. 다만 이는 사전 예측이며, 실제 회복률은 5 월 비교 실험에서 정합니다.

Q. 1 만 배 이상이라는 표현이 과장 아닙니까? A. Exqutor 원논문이 보고한 시나리오별 변동을 그대로 옮긴 것입니다. 시나리오에 따라 더 큰 격차도 가능하며, "1 만 배" 가 상한이라는 의미가 아닙니다.

Q. 두 보완의 효과가 작아 보이는데? A. 보고된 1.6 ~ 9.6 % 는 추정 정확도(Q -error 중앙값)의 개선폭입니다. 실행 시간 영향은 그 정확도가 옵티마이저의 plan 선택에 미치는 효과로 별도 평가되며, plan 선택 한 번이 1 만 배 차이를 만든다는 점에서 정확도 1 % 의 의미가 작지 않습니다.

발표 시 유의 사항

- **발음:** 카디널리티(*카-디-날-리-티*), 베르누이(*베르-누-이*), 임베딩(*임-베-딩*) 천천히.
- **속도:** 10 분 안에 들어가야 하므로 슬라이드별 시간 배분을 지킵니다.
- **숫자 강조:** 9.6 %, 1.6 ~ 4.4 %, 19.6 %p, 1 만 배 — 이 네 숫자가 청중이 가져갈 핵심.
- **질문 시간:** 5 분. 위 4 가지 예상 질문은 10 초 안에 답할 수 있도록 준비.