

팀원 슬라이드 가이드 — 5/9 morning 종합본 (5/8 회의 후 update)

이 문서를 어떻게 읽나 1. Claude Design link 으로 18-slide academic deck v2 열기 (paradigm framework + Adaptive 반영) 2. 슬라이드 한 장씩 보면서 본 문서의 해당 절 같이 읽기 3. 각 슬라이드 = "한 줄 메시지 + 풀어 말하면 + 비유 + 결론" 4 항목 정리

본 자료의 목적: deck 의 학술 narrative 가 어렵게 느껴질 때 같이 읽는 풀어쓴 보조. 5분 만에 read 가능.

원작성: 5/8 17:50 KST PM (회의 1h 전, 16-slide deck 기반) **5/9 update:** 2026-05-09 13:00 KST · 5/8 22:00 paradigm framework finalize + 5/8 21:30 Single Adaptive + 5/9 02:20 Multi 6 cell finalize 반영. Slide 6.5 (paradigm framework) + Slide 10.5 (sparse RP justification) 신규 = 16 → **18 slides.**

🕒 5/8 회의 결과 (회의 완료, 19:00~21:00) + 5/27 발표 D-19

시점	결정 / 결과	후속
5/8 19:00~21:00 회의 (완료)	Adaptive 비교 ★★★★★ 결정 (박세은) + paradigm framework 합의 + 5/27 plan 합의 + SF100 scope 제외	자문 메일 v4 박세은 발송 ready
5/8 21:30~21:34	Single 10 cell × Adaptive 측정 (3,750× 빠름)	Outcome A+B 혼합
5/8 22:00	5 paradigm × 11 method framework finalize (4강 ★4 = sparse RP)	Hybrid → sparse RP 교체
5/9 02:20	Multi 6 cell × 11 method + Multi Adaptive baseline 측정 완료	31,500 measurement
5/9 12:25~12:29	analyze_multi_paradigm.py 분석 csv 4 종 산출	24.5× shrinkage chain 재계산
5/9 13:00	본 가이드 + 종합 + 요약 + 자문 메일 fill 완료	박세은 → 박성원 멘토 발송 ready
5/15~5/20	박성원 멘토 자문 회신	5/22 박광현 교수님 미팅 반영
5/27 19:00	최종 발표 (18-slide deck v2)	paradigm + Adaptive 반영

🎯 본 연구 한 줄 요약

"벡터 데이터의 분포가 한쪽으로 치우쳐 있을 때, 그 분포를 알면 더 정확한 카디널리티 추정이 가능하다 — 그 가치를 정량 측정"

비유: 인구 조사를 할 때, 연령대별로 인구 분포에 맞춰 가중치 두고 표집하면 더 정확한 평균을 얻는다. 본 연구 = 벡터 임베딩의 분포에 맞춰 sampling 가중치 두는 방법의 가치.

4 줄 결론 (5/9 update): 1. **분포 인지 방법은 강력 효과** (단일 dataset 4강 method 평균 -7~-8%, SIFT 에서 -32%) 2. **method 선택은 부차** (Tier 1 살아남기 17종 spread 1.21%p) — "어느 분포 인지 method 든 Tier 1 이면 OK" 3. **5 paradigm × 11 method framework + 4강 distinct representative** (★1 HDBSCAN P1 / ★2 MB_partial P3 / ★3 Hilbert P2 / ★4 sparse RP P4) — Hybrid → sparse RP 교체 (paradigm coverage + 산업 친화 anchor) 4. **Adaptive 직접 비교**: 단일 Outcome A+B 혼합 (★1~★3 우위 7/10 sig, ★4 동등 0/10 sig) + Multi Outcome C dominant + 부분 D (sweet spot 0/24, low-sel 4강 worse) → **24.5x shrinkage** (단일 17.13% → multi 0.70%) — "단일 정확성 = multi 정확성 필요조건만"

Slide 1 (Cover) — 우리 연구 제목

화면: Skew-Aware Stratified Sampling for Vector-Augmented Analytical Query

풀어 말하면: - "Skew" = 분포가 한쪽으로 치우침 (편향) - "Stratified Sampling" = 분포를 cluster (strata) 로 나누고 각 cluster 에서 sampling - "Vector-Augmented Analytical Query" = 벡터 임베딩이 포함된 분석 쿼리

→ "분포 편향을 인지한 stratified sampling 의 정량적 가치"

비유: 시험 점수 조사할 때, "전체 학생 중 무작위로 100명" (random) 보다 "각 학년에서 25명씩" (stratified) 가 더 정확한 평균. 학년별 분포 차이 (skew) 를 알면 stratified 가 더 정확.

결론: 분포 정보 활용 = 정확도 ↑

Slide 2 (TOC) — 오늘의 흐름 (5/9 update: 16 → 18 slides)

12 단계 (5/9 추가 2 슬라이드): Problem → Prior Work → Approach → RQ1 → RQ2 → RQ3 → **Paradigm Framework (NEW S6.5)** → Cross-scale → Mechanism → Effect Honesty → **sparse RP justification (NEW S10.5)** → Future

3 가지 RQ 한 줄 요약: - **RQ1** (진단): 분포 차이가 추정 정확도에 영향 주는가? → "그렇다, 단조적으로" - **RQ2** (distribution-aware): 분포 알 때 활용 효과는? → "강력 (51/52 cell 통계 유의)" - **RQ3** (distribution-agnostic): 분포 모를 때는? → "5 paradigm × 11 method 분류 → 4강 distinct representative + Adaptive 비교 Outcome A+B"



Slide 3 (Problem) — 무엇이 문제인가

화면: pgvector 33.3% / VBASE 50% / DuckDB 100%

풀어 말하면: - 기존 vector DB 들은 cardinality (= query 결과 row 수) 추정할 때 **고정 비율** 사용 - pgvector = "전체의 33%일 거야" 무조건 가정 - 그러나 실제 query 의 selectivity 는 **0.001%~90%** 까지 매우 다양 - 잘못된 가정 → 잘못된 plan (예: hash join vs nested loop) → 1000~10000× 느린 query

비유: 식당에서 "오늘 손님 100명" 라고 매일 똑같이 가정 → 실제 50명 와도, 200명 와도 다 잘못 준비. 적절한 손님 수 예측이 필수.

결론: 고정 비율 = "기술적으로 좋은 추정" 이지만 "실행 계획에 진짜 도움 되는 추정" 이 아님 → 그 간극을 메우는 게 본 연구.



Slide 4 (Prior Work + PDX) — 우리가 기반하는 토대

(이전 연구) **Exqutor** (BDAI Research Lab, 박세은 팀장 연구실, arXiv:2512.09695v2): - **ECQO**: HNSW 인덱스 있을 때 1~2 ms 에 정확 cardinality - **Adaptive Sampling**: 인덱스 없을 때 동적 sampling (1000× 비용 절감)

(추가 발견) **PDX** (CWI Amsterdam, SIGMOD 2025, arXiv:2503.04422): - **Quote**: "intrinsic_dim + skewness 가 algorithm selection 결정" - 우리 thesis 와 **정확 일치** → SIGMOD 2025 학술 confirmation 확보 → 본 연구 정당성 강화

PDX 와 본 연구의 차이 — Complementary: | 영역 | PDX | 본 연구 | |---|---|---| | Layer | compute | pre-process | | Goal | fast similarity (data layout) | accurate cardinality (sampling/clustering) | | 대상 | distance 계산 자체 | sample 분배 전략 |

비유: 자동차 = engine (PDX, 빠른 similarity) + navigation (본 연구, 정확한 cardinality). 둘 다 좋은 차에 필요.

결론: 우리 연구 = Exqutor 의 빈 공간 (단일 테이블 비인덱스 skewed) 메우기 + PDX 의 compute layer 와 complementary.



Slide 5 (Approach) — 우리 접근 3 단계

3 카드: - **RQ1 진단:** 분포 차이 → 정확도 영향 정량 - **RQ2 distribution-aware:** 분포 알 때 효과 측정 - **RQ3 distribution-agnostic:** 분포 모를 때 차선택

비유: 의학 검진 흐름 = 진단 (분포 측정) → 처방 (분포 활용) → 일반 약 (분포 모를 때).

결론: 분포가 펼쳐 있을 때 cardinality 정확도와 안정성을 명확히 계량.

Slide 6 (RQ1) — 분포 차이가 정확도에 영향 주는가? → "그렇다"

화면: 12 cell $\times \rho < 0$ 100% 일관 (-0.366 ~ -0.609)

풀어 말하면: - 12 cell = 5 dataset (DEEP/SIFT/SSN/WIKI/YFCC) $\times$ 2 scale (sf1/sf10) $\times$ 1~2 method - ρ (Spearman rho) = -1~+1 범위의 상관계수. selectivity 와 추정 오차의 단조 관계 강도 - $\rho < 0$ = "selectivity 가 커질수록 추정 오차는 작아진다" (단조 감소) - 100% 일관 = 12 cell 모두 $\rho < 0$ (예외 없음) - DEEP_sf1 KM20 의 $\rho = -0.680$ [-0.800, -0.440] 95% 신뢰구간이 0 을 제외 $\rightarrow$ 통계적 유의

비유: 키 측정 정확도. 1000명 측정하면 평균 잘 맞고 (selectivity 큼 $\rightarrow$ 오차 작음), 10명만 측정하면 평균 부정확 (selectivity 작음 $\rightarrow$ 오차 큼). 표본 크기 효과의 단조 관계.

결론: 분포 차이 (selectivity 차이) 가 추정 오차에 일관되게 영향 $\rightarrow$ RQ1 답: "그렇다, 단조적으로"

Slide 6.5 (NEW, paradigm framework) — 5 paradigm $\times$ 11 method 분류 ★ 5/9 추가

화면: 5 paradigm classification matrix (P1~P5)

풀어 말하면:

5/8 20:43 Deep Review + 22:00 paradigm 학술 정합성 검증을 거쳐 RQ3 method 후보군을 5 paradigm $\times$ 11 method 로 분류. 각 paradigm 은 distinct *inductive bias* (어떤 가정으로 cardinality 추정에 도움 주는가) 로 정의.

Paradigm	Inductive bias	Representative
P1 Density Cluster	"유사 데이터는 군집을 이룬다"	HDBSCAN, MiniBatch K-means, GMM
P2 Spatial Locality	"고차원 → 1D quantile 분할로 locality 보존"	Hilbert curve, faiss IVF
P3 Online Streaming	"OLTP partial-fit / single-pass 친화"	MiniBatch_partial, Reservoir
P4 Linear Projection	"고차원 핵심 정보는 저차원 random matrix 투영 보존"	sparse RP (Achlioptas 2003), PCA1D
P5 Quasi-random	"결정론적 균등 sampling 으로 random variance 감소"	Sobol, LSH (limitation)

비유: 의학 진단 paradigm 분류. 같은 "암 진단" 이라도 (P1) 조직 검사 / (P2) 영상 이미지 / (P3) 혈액 흐름 모니터링 / (P4) 유전자 분석 / (P5) 통계 sampling — 5 paradigm 의 distinct inductive bias 가 각자 다른 진단 가치.

핵심 발견 (5/8 22:00 finalize): - 본 연구의 단일 4강 = **5 paradigm 중 4 paradigm 의 distinct representative** (P1 HDBSCAN / P2 Hilbert / P3 MB_partial / P4 sparse_rp) - P5 Quasi-random 은 LSH limitation 발견 (Wave 0 +2092% fail, K=20 vs n_hp=5 misalignment) 로 4강 진입 X - 즉 4강 구성 = "distinct paradigm 의 representative" 의 학술적 narrative 완성

결론: RQ3 의 method 선정이 ad-hoc 비교가 아니라 *학술적으로 정렬된 5 paradigm framework* 위의 distinct representative 선정 — 본 연구 contribution narrative 강화 + 자문 메일 §2 의 ★4 sparse RP 산업 anchor 가치 정량 입증.



Slide 7 (RQ2) — 분포 알 때 활용 효과? → "강력"

화면: 51/52 cells CI 0 제외 (sel=0.10) + σ -allocation 격차 < 1% (7/12 cell)

풀어 말하면: - **51/52 cell** = 12 cell $\times$ 4 mode (BERN/proportional/Neyman/Anti-Neyman) - 1 outlier - **CI 0 제외** = paired 통계로 "분포 활용 효과 $\neq$ 0" 통계적 유의 (즉 분포 활용 효과 99% 신뢰) - **σ -allocation 격차 < 1%** = Neyman vs Anti-Neyman 의 차이가 1% 이내 (7/12 cell) - **결론:** 분포 활용 효과는 강력하지만, σ 정확성 (Neyman) 보다 "분포 인지 자체" 가 결정적 — 단순 균등 stratification 으로 충분

Anti-Neyman counterfactual: " σ 를 반대로 쓰면 systematically 나빠짐" (DEEP +5.21%, SIFT +9.49% CI 0 제외) → σ 신호가 약하지만 존재함을 정량 증명 (negative control)

비유: 인구 조사. 연령대별 sample size 를 정확하게 (Neyman) vs 균등 (proportional) → 결과 거의 같음. 그러나 정반대로 (Anti-Neyman) → 명확히 나빠짐 → "균등도 충분, 정확도는 marginal"

결론: 분포 활용 효과 강력. 단순 균등 stratification 충분. σ 정확성은 marginal.

🏆 Slide 8 (RQ3) — 분포 모를 때는? → "5 paradigm × 11 method 분류 → 4강 distinct representative" (5/9 update)

화면: 4강 ranking 표 + 10-cell × 4-method heatmap (5/9 ★4 sparse RP 교체)

4강 method (단일 10 cell × 5 sel × paired $\Delta\%$ sel=0.10, 5/8 22:00 paradigm finalize 후):

Rank	Method	avg $\Delta\%$	neg cells	CI ex	paradigm anchor	특성
★1	HDBSCAN	-8.04	8/10	8/10	P1 Density Cluster	가장 강력 — strongest narrative (oracle 영역)
★2	MB_partial	-7.63	8/10	9/10	P3 Online Streaming	OLTP friendly 유일 (online learning)
★3	Hilbert	-7.54	8/10	9/10	P2 Spatial Locality	production sweet spot (가장 가벼움)
★4	sparse RP ★	-6.91	8/10	0/10	P4 Linear Projection	data-independent paradigm anchor (산업 친화)

5/8 22:00 ★4 Hybrid → sparse RP 교체: 5 paradigm × 11 method framework 의 P4 (Linear Projection) anchor 로서 paradigm coverage 완성 + Adaptive Sampling 과 통계적 동등 (0/10 sig) 의 학습-free production-friendly tier 가치. Hybrid (KMeans+Hilbert) 는 ablation/mechanism 차원으로 demote.

풀어 말하면: - "BERN baseline 대비 평균 7~8% 더 정확" (10 cell 평균) - "8/10 cell 에서 정확도 향상 부호 일관" (예외: SSN_sf1, SSN_sf10 의 +1~+2%) - "9/10 cell 에서 통계적 유의 (CI 0 제외)" — MB_partial / Hilbert 가장 robust

가장 강력한 효과 (SIFT_sf1): HDBSCAN -34.17%, Hilbert -33.53%, MB_partial -33.13%, sparse RP -26.78% — 4강 모두 -26~-34%

SSN++ 만 +1~+2% (positive direction): 분포 균형 dataset 에서는 효과 없음 (boundary, 자세히 Slide 11)

비유: 운동 효과. 비만인 사람 (분포 차이 강한 dataset) 은 운동 강력 효과 (-30%). 정상 체중 (균형 분포 SSN++) 은 변화 적음 (+1~+2%) → 본 연구의 outer boundary 자연스러움.

결론: 분포 모를 때 4강 method 가 BERN 대비 평균 7~8% 향상. SIFT 같은 분포 차이 강한 dataset 에서 32% 강력.

★ Slide 9 (Hilbert + Tier 1 17종 spread)

화면: Tier 1 17 method spread 1.21%p (HDBSCAN -8.04 ~ kdtree -6.83)

풀어 말하면: - 30 method 중 **17종이 "Tier 1"** (살아남는 method). 나머지 13종은 가지치기. - Tier 1 17종의 평균 $\Delta\%$ 차이 = 단 **1.21%p** (HDBSCAN 1위 -8.04% ~ kdtree 17위 -6.83%) - 즉 **"어느 분포 인지 method 든 Tier 1 이면 OK"** → method choice 부차

핵심 결론: "method 선택보다 '분포 인지 vs 미인지' boundary 가 결정적"

비유: 같은 학원 다닌 17명 학생들의 성적 차이가 단 1점 → 학원 자체가 좋은 거지 (분포 인지) 어느 선생님 만나도 별 차이 없음 (method 선택 부차).

Hilbert 의 위치: 4강 중 #3 = 학습 비용 0 + production sweet spot. 즉 "공짜로 90% 효과" 의 가치. - inverse Manhattan distance 보존: Hilbert 1.000 vs Z-order 1.992 → 거리 보존이 정확히 2× 좋음 (locality preservation)

🚀 Slide 10 (MiniBatch K-means)

화면: 1,189× speedup + ARI 1.000 + CI ex 9/10

풀어 말하면: - **MiniBatch K-means** = full K-means 의 빠른 버전 (mini-batch update 으로 incremental learning) - **1,189× speedup** = full K-means 의 1/1189 시간에 학습 (분 → 초) - **ARI 1.000** (Adjusted Rand Index) = clustering 결과 정확도 = full K-means 와 **완전 동일** - **CI ex 9/10** = 4강 중 가장 강력한 statistical robustness

특징: `partial_fit` 가능 → streaming 환경에서 OLTP friendly. 즉 production 에서 새 데이터 들어올 때마다 cluster 갱신 가능 (online learning).

비유: "빠른 사진 vs 정밀 사진. 같은 사진을 1/1000 시간에 찍었는데 화질 동일 → production 에서는 빠른 사진 채택"

결론: MB_partial = "정확도 동일 + 1000× cheaper + OLTP-ready" → production 채택의 결정적 근거.



Slide 10.5 (NEW, sparse RP justification) — 왜 ★4 가 sparse RP 인가? ★ 5/9 추가

화면: ★4 sparse RP 의 paradigm anchor + Adaptive 동등 finding

풀어 말하면:

5/8 22:00 paradigm framework finalize 후 ★ 4 가 기존 Hybrid 에서 **sparse Random Projection** (Achlioptas 2003 PODS) 으로 교체. 5 paradigm × 11 method framework 의 P4 (Linear Projection) anchor 로서 paradigm coverage 완성 + 산업 친화 (data-independent + 학습 cost 0) 가치 + Adaptive Sampling 통계적 동등 finding 의 reframe.

sparse RP 동작 (3 줄): 1. D-dim → 1-dim 무작위 행렬 R (각 element $\{-\sqrt{3}, 0, +\sqrt{3}\}$ 또는 $\{0, \pm 1/\sqrt{D}\}$) 생성 — Achlioptas 2003 / Li et al. 2006 KDD variant 2. 모든 vector v 에 대해 1-dim 값 $v \cdot R$ 계산 (sparse 행렬이라 빠름) 3. 1-dim 값 quantile 으로 K stratum 분할 → BERN 보다 정보량 많은 stratification

JL lemma (Johnson-Lindenstrauss): 무작위 투영이라도 ϵ -error 안에서 distance 보존 → 분포를 몰라도 정보 손실 적게 압축 가능.

왜 ★4 sparse RP 인가 (5/8 22:00 finalize 4 가지 근거):

1. **Paradigm coverage:** P4 Linear Projection 의 representative — 4강 = 5 paradigm 중 4 paradigm distinct representative
2. **ARI orthogonality:** ★1~★3 이 모두 cluster-based (centroid 또는 1D ordering) 인 반면, sparse RP 는 *data-independent random projection* — ARI orthogonality #1 (4강 中 가장 다른 inductive bias)
3. **산업 친화 (학습 cost 0):** random matrix 한 번 sampling 만으로 끝, sklearn `SparseRandomProjection` API 호환 — production deployment 부담 없음
4. **Adaptive Sampling 통계적 동등 (5/8 21:30 측정):** 단일 10 cell paired Wilcoxon **0/10 sig** 으로 Adaptive 와 동등 → 학습-free production-friendly tier 의 paradigm anchor 가치 reframe

비유: 5 paradigm = 5 가지 운동 종목 (러닝/요가/필라테스/자전거/수영). ★4 = 자전거 (다른 4 종목과 inductive bias 가장 다름, 학습 비용 가장 낮음, 다른 4 종목과 *결합* 가능). 4강 = 5 종목 중 4 종목 대표 선수 — “어느 종목 운동이든 효과적” 의 학술 narrative.

기존 Hybrid 의 위치: ablation/mechanism 차원의 보조 method 로 demote — 보고서 limitation/ablation 절에서 *clustering vs ordering* source 분리 ablation 에 한정 사용.

결론: ★4 sparse RP 의 4 가지 근거 = paradigm coverage + ARI orthogonality + 학습 cost 0 + Adaptive 통계적 동등. 단일 standalone 우위 X 가 honest 하게 보고되나 paradigm coverage + 산업 친화 가치는 별도 정량 입증.



Slide 11 (Sweet Spot 정량 boundary)

화면: $\text{cluster_ratio} > 1.4 + \text{intrinsic_dim} < 0.85 \rightarrow \text{SWEET} / \text{반대} \rightarrow \text{CEILING}$

풀어 말하면: - "분포가 어떻게 생긴 dataset 에서 본 method 가 강력한가" 의 **정량 정의** - **cluster_ratio** = 가장 큰 cluster / 가장 작은 cluster 크기 비율 (1.0 = 완전 균등, > 1 = 불균형) - **intrinsic_dim** = 데이터의 본질적 차원 (PCA 누적 분산 비율, 0.85 = 80% 정보 위해 차원의 85% 필요)

SWEET 영역 ($\text{cluster_ratio} > 1.4 + \text{intrinsic_dim} < 0.85$): - 분포 인지 효과 강력 = **-7%~-32%** - 해당 dataset: SIFT (1.65 / 0.71), WIKI (1.84 / 0.81), YFCC (~1.5 / ~0.85)

CEILING 영역 ($\text{cluster_ratio} < 1.4 + \text{intrinsic_dim} > 0.85$): - 분포 균형 $\rightarrow$ BERN baseline 자체가 이미 ceiling $\rightarrow$ method 효과 약 (**+1~+2%**) - 해당 dataset: SSN++ (1.29 / 0.88) — uniform-like distribution

비유: 길거리 sample. 강남 (분포 다양, ratio 큼) $\rightarrow$ 응답 결과 불균형 $\rightarrow$ sampling 으로 정확 측정. 시골 마을 (분포 균질, ratio 작음) $\rightarrow$ 어차피 다 비슷 $\rightarrow$ sampling 효과 작음.

결론: 두 metric 으로 distribution sweet spot 정량 경계 정의 $\rightarrow$ 적절한 분포에서만 분할이 효과 (Negative Control 본질).



Slide 12 (Cross-scale Sensitivity)

화면: sf1 $\rightarrow$ sf10 4강 ranking 일관성 + sf100 자문 후 표기

풀어 말하면: - sf1 (800K row) $\rightarrow$ sf10 (8M row) 으로 10 $\times$ scale up 했을 때 4강 method 의 ranking + 부호 보존 - 예: SIFT_sf1 -32.63% $\rightarrow$ SIFT_sf10 -10.47% (magnitude 약화, **부호 유지**) - 즉 "scale 변해도 결론 일관" — **외적 타당성 (external validity)**

sf100 (80M row) = 미측정. 채림 석사 자문 후 5/15+ 진행 예정. **multi-table join (STAGE 3)** = 5/8 17:50 측정 완료 — 단일 $\rightarrow$ multi-vector $\rightarrow$ multi-table-join shrinkage chain 의 lower bound 확정.

비유: 동일한 약효가 어린이 (sf1) 와 성인 (sf10) 모두에서 효과. 노인 (sf100) 검증은 추가 임상 후.

결론: sf1 $\rightarrow$ sf10 부호 일관 = 외적 타당성 부분 입증. sf100 + multi-relation 일반화는 future work.

⚠ Slide 13 (Mechanism + Multi 24.5× shrinkage + Adaptive 비교) — (5/9 update)

화면: 단일 17.13% → multi 6 cell mean 0.70% = **24.5× 약화** + Multi 4강 vs Adaptive Outcome C dominant

풀어 말하면 (5/9 02:20 multi 6 cell finalize): - **단일 sweet spot 4강 평균 $|\Delta\%| = 17.13\%$** (SIFT_sf1 / WIKI_sf1 / YFCC_sf1) - **multi 6 cell 4강 평균 $|\Delta\%| = 0.70\%$** (multi-vector 4 cell + multi-table-join 2 cell) - **24.5× = 17.13 / 0.70** — magnitude 약화 비율, sparse_rp 추가 후 재계산 (기존 25.4× 대비 -3% marginal)

6 cell shrinkage chain:

단계	cell	4강 평균 $ \Delta\% $	shrinkage
단일 sweet	4 dataset (sf1+sf10)	17.13	1.0×
Multi-vec sf10 sift	partsupp_deep_sift_10	0.91	18.8×
Multi-vec sf10 wiki	partsupp_deep_wiki_10	0.69	24.8×
Multi-join sf10	multi_join_deep_wiki	0.62	27.6×
Multi-vec sf1 sift	partsupp_deep_sift_1	0.44	39.1×
Multi-vec sf1 wiki	partsupp_deep_wiki_1	0.84	20.4×
Multi-join sf1	multi_join_deep_wiki_1	0.68	25.3×
6 cell mean	-	0.70	24.5×

핵심 메시지:

단일 정확성은 multi 정확성의 **필요조건**만 성립, **충분조건**은 아님 + 4강 단일 Outcome A가 multi 환경에서 통계 보정 어느 기준에서도 **불성립**

Multi 4강 vs Adaptive head-to-head (sweet spot sel=0.5, 6 cell × 4 method = 24 pair):

Cell	HDBSCAN	MB_partial	Hilbert	sparse_rp
partsupp_deep_sift_10	+0.005	+0.180	-0.167	+0.537*
partsupp_deep_wiki_10	+0.609**	+0.432*	+0.208	+0.439*
multi_join_deep_wiki	+0.376*	+0.152	+0.163	+0.277*
partsupp_deep_sift_1	+0.391	+0.146	+0.011	+0.186
partsupp_deep_wiki_1	-0.008	+0.064	-0.165	+0.106
multi_join_deep_wiki_1	-0.008	+0.064	-0.165	+0.106
paired-better (median<0+sig)	0/6	0/6	0/6	0/6

해석 (5/9 update): Sweet spot 24 pair 中 paired-better **0/24** = Outcome C (동등) dominant. Low-sel (0.01~0.1) 영역에서는 4강 mean +5~+50% 로 Adaptive 보다 worse (Outcome D 부분 발현). 즉 단일 Outcome A 의 multi 일반화 실패가 BH FDR + Bonferroni 보정 어느 기준에서도 안정적 — **분포 정보 marginal value 의 multi 약화 정량 증거.**

추가 finding (5/9 NEW): multi-table-join sf1 (multi_join_deep_wiki_1) q_error $\equiv$ multi-vector sf1 (partsupp_deep_wiki_1) q_error (raw csv md5 검증, 1:1 key join 의 구조적 collapse) $\rightarrow$ *foreign-key dimension join 환경의 cardinality 가 single-side dominant cardinality 로 환원 가능* $\rightarrow$ multi-relation sampling-based estimator 가 single-side 측정으로 대체 가능한 cell 류 식별 (supplementary contribution).

비유: 한 사람 진료 (단일) 에 잘 맞는 약 $\rightarrow$ 환자 6명 동시 진료 (multi 6 cell) 에는 효과 24.5 $\times$ 약 + Adaptive 와 동등 영역으로 수렴. 병원 시스템 (multi) 은 다른 설계 필요 $\rightarrow$ joint-aware clustering / multi-vector decomposition future work.

Mechanism (locality, 단일 한정): - Hilbert inverse Manhattan **1.000** vs Z-order **1.992** $\rightarrow$ Hilbert 가 거리 보존 정확히 2 $\times$ 좋음 - stratum compactness gain: DEEP_1M **1.25 $\times$** / SIFT_1.5M **2.54 $\times$**

결론: 단일 17.13% $\rightarrow$ multi 0.70% **24.5 $\times$ shrinkage** + multi 4강 vs Adaptive **Outcome C dominant + 부분 D** = 본 연구의 outer boundary 정량 입증 + future work motivation 정량화.

Slide 14 (Effect Size Honesty)

화면: DEFF 0.338 / ESS 2,325 / 6 $\times$ SRS effective sample + per-query routing p 0.78

풀어 말하면: - **DEFF** (Design Effect) = 0.338 → SRS (단순 random sample) 대비 $1/0.338 = 3\times$ 효율 (분산 절반 이하) - **ESS** (Effective Sample Size) = 2,325 → 1만 샘플 중 효과적 정보 = 2,325 (SRS 대비 6×) - **effect size** $d \approx 0.3$ = **practical small** (작은 효과) - **per-query routing** $\rho = 0.78$ → 어려운 query 에서 분포 활용 효과 더 큼 (Q4_hard)

Honest reporting: 평균 effect 는 작지만, **어려운 query 에서 강력** (per-query routing 가치).

SSN++ ceiling (boundary): 4강 모두 +1~+2% → 분포 균형 dataset 의 outer boundary 정의 (negative control 의 자연스러운 boundary).

비유: 약효. 평균적으로는 1% 효과 (작음) 지만 중증 환자 (어려운 query) 에는 강력 효과.

결론: effect size 작지만 (practical small), per-query routing 가치 있음. SSN++ ceiling = 본 연구의 outer boundary.

Slide 15 (Limitation 10 항목, 5/9 update — L7 + L8 + L9 + L10 추가)

10 카드 (PARTIAL / FUTURE / HONEST 분류, 5/9 update):

PARTIAL (부분 입증): - L1 Single-table only (단일 테이블만 측정, multi-table 일부) - L2 KM20 oracle 학습 부담 (production X) - L3 numpy estimator scope (vector.c integration future)

FUTURE (자문 후 진행): - L4 Multi-vector 일반화 (joint-aware clustering 필요, 5/9 multi 6 cell × 11 method 측정 후 더 명확화) - L5 ~sf100 cross-scale~~ → **5/8 22:16 결정으로 본 연구 scope 외 처리** (측정 시간 ~60-80h 부담, future work limitation 으로 명시) - L6 vector.c integration (production deployment) - **L9 (NEW) Multi-relation joint-aware clustering 또는 ECQO + 분포 인지 ensemble** (5/9 multi 24.5× shrinkage 정량 motivation) - **L10 (NEW) Multi 환경 4강 Outcome A 불성립** (5/9 multi 6 cell × 4강 vs Adaptive 24 pair 中 paired-better 0/24, BH FDR + Bonferroni 보정 어느 기준에서도 안정)

HONEST (negative control): - L7 SSN++ ceiling (분포 균형 dataset 의 outer boundary, PDX SIGMOD 2025 학술 confirmation) - L8 Effect size practical small (per-query routing 으로 보완) - **L11 (NEW) LSH Wave 0 +2092% fail** (P5 paradigm representative limitation, K=20 vs n_hp=5 misalignment, mod 20 collision) - **L12 (NEW) sparse_rp 단일 standalone 우위 X** (Adaptive Sampling 과 통계적 동등 0/10 sig — paradigm anchor + 산업 친화 가치 reframe)

비유: 논문 마지막 "limitation" 섹션. "우리도 다 했다고 못 말한다" 의 정직 reporting + 5/9 update 후 multi 환경의 honest finding 추가.

결론: 10+ 가지 honest limitation. 모두 자연스러운 후속 연구 출발점. SF100 scope 제외 결정 + Multi 환경 Outcome A 불성립 + sparse_rp 동등 finding 의 honest reporting 이 연구 신뢰도 강화.

👋 Slide 16 (Closing)

화면: 감사합니다 / Q&A + GitHub johyunbin/Capstone + arXiv:2512.09695v2 + footer

다음 단계 timeline: - 5/15 자문 회신 (채림 석사 + 박광현 교수님) - 5/22 교수님 미팅 - 5/26 발표 자료 최종 마감 - 5/27 19:00 최종 발표 (오늘 deck 활용) - 6/11 최종 보고서

💬 5/8 회의 결과 (5/8 19:00~21:00 완료)

#	결정 사항	후속
1	Adaptive Sampling 직접 비교 ★★★★★ (박세은 결정)	5/8 21:30 단일 + 5/9 02:20 multi finalize → Outcome A+B / C+D
2	5 paradigm × 11 method framework 학술 적합성 확정 (5/8 22:00)	4강 ★4 = Hybrid → sparse RP 교체 (P4 anchor)
3	5/27 발표 plan v2 합의	18-slide deck (S6.5 paradigm + S10.5 sparse RP 신규)
4	SF100 (80M) cross-scale 제외	측정 시간 ~60-80h 부담, future work limitation
5	자문 메일 v4 박세은 발송 ready (5/15~5/20)	박세은 → 박성원 멘토 (삼성전자 AI센터)

? 예상 질문 + 답변

Q1: KM20 oracle 은 production 가능?

A: 아니다, oracle baseline. 그래서 4강 production-ready method 가 KM20 의 70~100% 회복. 특히 MB_partial = OLTP friendly (online learning).

Q2: SSN++ 만 hurt direction (+1~+2%) 인 이유?

A: cluster_ratio 1.29 + intrinsic_dim 0.88 = 분포 균형 (uniform-like). BERN baseline 자체가 이미 낮음 (ceiling effect). 본 연구의 outer boundary 정의.

Q3: PDX (SIGMOD 2025) 와 우리 연구의 관계?

A: **Complementary**. PDX = compute layer (data layout, fast similarity). 본 연구 = pre-process layer (sampling/clustering, accurate cardinality). 같은 thesis ("intrinsic_dim + skewness driven") 다른 layer.

Q4: Tier 1 17종 spread 1.21%p 의 의미?

A: HDBSCAN (-8.04) ~ kdtree (-6.83) 까지 모든 Tier 1 method 가 작은 차이. 즉 **"method choice 부차, 분포 정보 인지 자체 결정적"**. 어느 method 든 Tier 1 이면 OK, 4강 = 대표.

Q5: Multi 결과 24.5× shrinkage 는 부정적 결과 아닌가?

A: 아니다, **outer boundary 정량 입증** = honest finding. "단일 정확성 = multi 정확성 필요조건 만" → 본 연구 scope 명확화 + multi-relation 일반화 future work 정당화. 5/9 6 cell × 11 method 측정 + sparse_rp 추가 후 24.5× 로 update (기존 25.4× 대비 -3% marginal).

Q5b: Multi 환경에서 4강 Outcome A 가 불성립하면 본 연구 thesis 가 흔들리는가?

A: 아니다. 본 연구 thesis = "분포 정보의 가치" 는 단일 환경 한정으로 정량 입증 (Outcome A 7/10 BH-sig). Multi 환경의 Outcome C dominant + 부분 D 는 분포 정보 *marginal value* 의 multi 약화 honest finding 으로 future work motivation. 단일 → multi 일반화 자체가 본 연구 scope 외라는 것을 sprint 시작 시점부터 명시 + multi 24.5× shrinkage 가 정량 증거. 즉 본 연구 contribution = "단일 영역의 정량 boundary 확정" + "multi 약화의 정량 입증" 양면 narrative.

Q6 (5/9 update): ★4 가 sparse RP 로 바뀐 이유?

A: 5/8 22:00 paradigm framework finalize 후 4강 = 5 paradigm 중 4 paradigm 의 distinct representative 로 narrative 강화. ★4 sparse RP 의 4 가지 근거: (1) P4 Linear Projection paradigm anchor, (2) ARI orthogonality #1 (4강 中 가장 다른 inductive bias), (3) 학습 cost 0 (산업 친화), (4) Adaptive Sampling 통계 적 동등 (0/10 sig — 학습-free production-friendly tier 의 paradigm anchor 가치 reframe). 기존 Hybrid 는 ablation/mechanism 보조 method 로 demote.

Q6: sf100 (80M) 측정은?

A: 본 W4 sprint 미측정. 5/8 회의 후 자문 합의 → 5/15+ launch. DEEP/SIFT/SSN sf100 = 80M PG 적재 완료.

Q7: 자문 메일 4 의제는?

A: 1. 4강 method 선정의 production cost 차별화 narrative validity 2. Distribution Sweet Spot 정량 boundary (cluster_ratio 1.4 / intrinsic 0.85) generalizability 3. Multi 일반화 검증 plan (joint-aware clustering) 4. Exqutor 통합 ensemble plan 타당성



부록 — 자주 나오는 학술 용어 사전

용어	풀어 말하면
paired $\Delta\%$	같은 query 의 BERN 추정과 method 추정을 짝지어 비교한 % 차이. negative = improvement.
CI 0 제외	95% 신뢰구간이 0을 포함하지 않음 = 통계적 유의 (효과 $\neq 0$).
Spearman ρ	두 변수의 단조 관계 강도 (-1~+1). negative = "더 큰 selectivity $\rightarrow$ 더 작은 오차".
selectivity	query 결과가 전체 row 의 몇 % 인가 (0.001~90%).
stratified sampling	데이터를 cluster (strata) 로 나누고 각 cluster 에서 sampling.
KM20	K-means K=20 cluster 로 stratified (oracle baseline).
BERN (bernoulli)	단순 random sampling baseline (각 row 독립 0/1 선택).
Cohen's d	두 group 평균 차이의 표준화 효과 크기. $ d \geq 0.5$ = medium, ≥ 0.8 = large.
DEFF / ESS	Design Effect / Effective Sample Size — sampling 효율 metric.
HDBSCAN	Hierarchical Density-Based Spatial Clustering of Applications with Noise. 노이즈 자동 분리 + 밀도 기반 cluster.
MiniBatch K-means	K-means 의 mini-batch update 버전. 1000× 빠름 + ARI 1.000 (full 과 동일).
partial_fit	sklearn 의 incremental learning API. streaming 환경에서 새 데이터 들어올 때마다 cluster 갱신.
Hilbert curve	space-filling curve. 다차원 공간을 1D 로 매핑하면서 locality 보존.
cluster_ratio	가장 큰 cluster / 가장 작은 cluster 크기 비율 (1.0 = 균등, > 1 = 불균형).
intrinsic_dim	PCA 누적 분산 ratio. 0.85 = 80% 정보 위해 차원의 85% 필요. 큰 값 = 본질적으로 high-dimensional.

🔗 자료 위치 (회의 진행 중 즉시 참조)

자료	위치	사이즈
Claude Design 16-slide deck	(사용자 카톡 link 공유)	—
본 슬라이드 가이드 (이 PDF)	submission/_drafts/팀원_슬라이드가이드_20260508.pdf	~ KB
상세 narrative (학술적)	submission/_drafts/팀원_이해용_종합_20260508.pdf	975 KB
분석 본체	experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft_filled_partial.pdf	1.6 MB
자문 메일 초안	submission/_drafts/속도는벡터_자문메일초안_W4_20260508.pdf	678 KB
5/27 발표 plan	submission/_drafts/속도는벡터_5월27일발표_plan_20260508.pdf	831 KB

5/9 update: 5/8 회의 결과 반영 + 5/8 22:00 paradigm framework finalize + 5/8 21:30 Single Adaptive + 5/9 02:20 Multi 6 cell finalize 반영. Slide 6.5 (paradigm framework) + Slide 10.5 (sparse RP justification) 신규 = 18 slides 로 확장.

원작성: 조현빈 · 2026-05-08 17:50 KST · 회의 1h 전 (16-slide deck 기반) **5/9 update:** 조현빈 · 2026-05-09 13:00 KST · 18-slide deck v2 기반 **다음 미팅:** 5/22 박광현 교수님 미팅 + 5/27 19:00 최종 발표