

팀원 이해용 종합 — 5/8 19:00 회의 준비 자료

작성: 조현빈 · 2026-05-08 10:18 KST · 회의 ~9 시간 전 **대상:** 박세은(팀장), 강재현, 이동욱 **목적:** 5/8 19:00 비대면 회의에 들어오기 전, 팀원이 W4 sprint (5/6~5/8) 의 측정 결과를 *완벽히* 이해하고 같은 단어로 토의할 수 있도록, 핵심을 학부생 수준으로 풀어쓴 가이드. 학술 용어는 영어 원어 그대로 병기한다.

5/8 10:18 narrative 재정의 (사용자 결정): - **메인 = 10 cell** (5 dataset × sf1/sf10) — Exqutor 매칭 - YFCC = 채림 적재본 단일 정본 (`partsupp_yfcc_{1,10}`) - `build_yfcc.py` 다운로드 결과 폐기 — 자체 build YFCC_DL 적재본 본 연구에서 사용하지 않음 - **multi 3 cell = 부록 추가 자료**

읽기 시간: 약 25 분. 회의 직전 마지막 §9 (한 페이지 요약) 만이라도 훑어주면 토론은 가능하다.

§1. 우리 연구의 큰 그림 — 왜 이걸 하고 있나

1-1. 출발점: Exqutor 논문의 빈 공간

본 연구의 모든 출발점은 Exqutor 논문 (BDAL-Research, arXiv:2512.09695v2) 이다. 이 논문은 한 줄로 말하면 "벡터 + 분석 쿼리에서 카디널리티 (cardinality, 결과 row 의 개수) 를 정확히 추정해서, 데이터베이스가 더 좋은 실행 계획을 세우게 하자" 이다.

기존 시스템들은 카디널리티를 매우 단순하게 추정한다.

시스템	추정 방식	한계
pgvector	고정 33.3% 가정	작은 sel 에 매우 부정확
VBASE	고정 50% 가정	마찬가지
DuckDB	100% (전체 스캔)	비효율 (작은 sel 일 때 낭비)

Exqutor 는 이 문제를 두 가지 방식으로 해결한다.

- ECQO (Extended Cost-based Query Optimizer):** 인덱스 (HNSW) 가 있을 때, range query (거리 r 이하의 점 개수) 를 직접 실행해 1~2 ms 안에 정확한 카디널리티를 얻는 방법.
- Adaptive Sampling:** 인덱스가 없을 때, 동적으로 sample size 를 늘려가며 추정값이 "수렴" 할 때까지 sampling 하는 방법 (momentum 기반).

여기서 우리가 노린 빈 공간은 **Adaptive Sampling 의 전 단계** 이다. Adaptive Sampling 은 "얼마나 많이 sample 할까" 를 동적으로 정하지만, "어떻게 sample 을 분배할까" (proportional vs Neyman vs distribution-aware) 는 다루지 않는다. 그리고 Exqutor 의 momentum 방식은 분포가 한쪽으로 치우친 데이터 (skewed distribution) 에서 **정확도가 떨어진다**. 이 두 빈틈이 우리의 연구 영역이다.

1-2. 비유: 카디널리티 추정 = "전체 인구 중 몇 명이 키 180 이상일까"

비유로 풀면 이해가 쉽다. 우리가 한 도시 (table = 800만 명) 에서 "키 180 이상인 사람의 비율" 을 알고 싶다고 하자.

- **pgvector 방식**: "33% 일 거야" 그냥 가정 → 틀릴 가능성 높음.
- **DuckDB 방식**: 800만 명 전부 키 재 봄 → 정확하지만 너무 오래 걸림.
- **Random sampling (BERN 베이스라인)**: 무작위 1만 명 뽑아 평균 → 운에 따라 $\pm 5\%$ 부정확.
- **분포 정보 활용 (KM20 등 우리 method)**: 도시를 동네 (cluster) 로 나누고 각 동네에서 균형 있게 sample → 정확도 ↑.

이 마지막 단계의 가치를 정량화하는 것이 우리의 연구 contribution 이다.

1-3. 우리의 핵심 contribution 다섯 가지

본 연구가 새로 발견한 것 (5/8 시점 W4 sprint 결과 기준):

1. **분포 정보 활용 sampling 의 정량 가치 입증** — random 대비 최대 -32% 정확도 개선 (SIFT_sf1).
2. **Selectivity Gradient** — sel 이 작을수록 random 의 부정확이 단조 증가 (5 dataset 100% 부호 일관).
3. **4강 method 발견** — Hilbert / Hybrid / MiniBatch_partial / HDBSCAN 이 10 cell 메인 중 7 cell 일관 우위.
4. **Recovery Rate Framework** — "분포를 모를 때, 우리 method 가 oracle (KM20) 의 몇 %를 회복하는가" 평가 틀.
5. **(NEW, 5/7 발견) SSN++ ceiling 효과** — 우리 method 가 *적용되지 않는* 영역 (well-spread + balanced distribution) 의 정량 boundary.

마지막 다섯 번째가 가장 큰 honest reporting 의 핵심이다. "우리 method 가 만능이 아니다" 를 정량적으로 보여주는 것이 오히려 연구의 신뢰도를 높인다.

§2. 측정 매트릭스 — 10 cell 메인 + multi 3 cell (부록)

2-1. 무엇을 측정했나

5/6 ~ 5/8 W4 sprint 기간 동안 측정한 cell 매트릭스이다. "cell" 한 개 = (dataset, scale) 한 조합 = method 25 중 모두 측정.

Dataset	dim	sf1 (800K row)	sf10 (8M row)	비고
DEEP	96	✓	✓	Exqutor 본 논문 동일
SIFT	128	✓	✓	Exqutor 본 논문 동일
SSN++	256	✓	✓	Facebook SimSearchNet++
WIKI	768	✓	✓	text embedding
YFCC	192	✓	✓	채림 정보 단일 (5/8 10:18 build_yfcc 폐기)

→ 단일 10 cell × 30 method × RQ1/2/3 = 100% 측정 완료 (5/8 14:13 KST) → 3 multi cell 부록 측정 완료 (5/8 17:50 KST, multi-vector × 2 + multi-table join × 1) → 총 단일 1500 measurement (10 cell × 30 method × 5 sel) + multi 부록 (4강 × 3 cell × 5 sel = 60 measurement)

5/8 10:18 build_yfcc 다운로드 폐기 결정: 우리가 직접 다운로드해서 sklearn PCA 로 build 한 YFCC_DL 적재본은 채림 석사님 정보와 PCA basis 가 완전히 달라서 (cosine ≈ 0, 직교) 본 연구에서 사용하지 않기로 결정. YFCC narrative 는 채림 정보 단일 source 로 통일.

2-2. 왜 두 scale 인가 (sf1 vs sf10)

sf 는 TPC-H 의 scale factor 를 따른 것으로, sf1 = 800K row, sf10 = 8M row 이다. 두 scale 을 모두 측정하는 이유는:

- **scale invariance 검증:** 어떤 method 가 sf1 에서 좋아도 sf10 에서 안 좋다면, production 에 못 쓴다. 두 scale 에서 부호 일관 (improve direction 동일) 한 method 만 final winner 가 될 수 있다.
- **5/27 발표의 narrative:** "sf1 + sf10 cross-scale 일관성" 이라는 강력한 robustness 주장 가능.

2-3. 23 method 분류 (16 base + 7 NEW + 보강)

학기 초~5/7 까지 측정한 method 가 23 중. 분류는 다음과 같다.

Base 16 (chain_unified.py base set): - KM20 (oracle): K-means K=20 - MiniBatch K-means: K-means의 빠른 변형 - MiniBatch_partial: K-means partial_fit (점진적 학습, OLTP friendly) - Hilbert curve: 공간 채우기 곡선 (자세히는 §3-1) - Z-order curve: Hilbert ablation - Hybrid: KMeans + Hilbert 결합 (§3-2) - HDBSCAN: density-based clustering (§3-4) - BIRCH, LSH, Random Projection, Sparse Random Projection, PCA 1D, KDtree, PQ, IS, Sobol

NEW9 (W4 추가, 9 종): - DBSCAN, OPTICS, Agglomerative, Hierarchical KMeans, Faiss IVF, PCA-KMeans, KMeans++, Coresets, Spectral

이 23~25 method를 "tier elimination"으로 4단계 거쳐 → 최종 4-6 winner를 도출하는 것이 RQ3의 narrative.

§3. 4강 method 직관적 설명 — 비유로 이해하기 (production criteria 결정)

이번 섹션은 회의에서 method 이름이 나올 때 팀원이 즉각 "그게 뭐였더라?" 고민하지 않도록 비유로 풀었다. 5/8 11:40 가지치기 결과 confirm 후 4강은 **production criteria** (cell 별 1위 횟수 + cost 차별화 + interpretability) 기준 결정되었으며, 각 method가 차별화된 narrative 역할을 담당한다.

3-1. ★2 Hilbert curve — "공간을 한 줄로 휘어서 펴는 곡선" (production sweet spot)

상상해보자. 8M 개의 점이 96차원 공간에 흩어져있다. 이걸 한 줄로 정렬해야 한다. 가장 단순한 방법은 첫 번째 좌표 기준 정렬이지만, 그러면 두 번째~세 번째 좌표는 무시된다.

Hilbert curve는 공간을 휘어서 한 줄로 만드는 곡선이다. 핵심 성질: **공간상에서 가까운 점은 곡선 위에서도 가깝다.** 즉, 96차원 공간을 1차원 곡선으로 펼쳐도 "이웃 관계"가 잘 보존된다.

이걸 sampling에 활용하면, 곡선을 따라 균등 간격으로 sample을 뽑으면 → 공간상에서도 잘 분산된 sample이 된다. 이 균형이 분포 정보 활용의 본질이다.

왜 4강 ★3 인가: avg_Δ% -7.54, SIFT_sf1 -33.53% 강력 + YFCC_sf10 -5.21% (단일 100% 마지막 cell). 학습 비용이 거의 0 (Hilbert index는 한 번 계산하면 끝, 수 초). **production에서 가장 가벼운 method** — KM20 oracle처럼 무거운 학습 없이도 oracle의 효과 일부를 회복. CI 9/10 완벽 강력. 4강 역할 = **production sweet spot**.

3-2. ★4 Hybrid — "MiniBatch K-means으로 클러스터 찾고, Hilbert curve으로 분배" (mechanism narrative)

Hybrid는 두 method의 장점을 합친 방법이다.

1. 먼저 MiniBatch K-means 로 K=20 개 클러스터 빠르게 찾음 (몇 분).
2. 각 클러스터 안에서 Hilbert curve 로 균형 있게 sample 분배.

이렇게 하면 KM20 oracle 의 "분포 정보" + Hilbert 의 "공간 균형" 두 효과가 결합된다. avg_Δ% -7.13, balanced cost.

왜 4강 ★4 인가: Hilbert 효과 분리 ablation 의 핵심 — clustering vs ordering 어느 source 가 효과 driver 인지 정량 분리 가능. 4강 역할 = **mechanism narrative (ablation)**.

3-3. ★3 MiniBatch_partial — "K-means 의 점진적 학습 버전 (OLTP friendly)" (OLTP narrative 유일)

K-means 의 표준 fit 은 전체 데이터를 메모리에 올린 뒤 한 번에 학습한다 (~30분 / 8M row). 이건 OLTP 환경 (트랜잭션이 계속 들어오는 운영 환경) 에서 부적합하다.

MiniBatch_partial (sklearn 의 `partial_fit`) 은 작은 batch 씩 점진적으로 학습한다. 새로운 row 가 들어와도 기존 모델 위에 증분 학습 가능. **production-ready** 하다는 의미가 이것.

왜 4강 ★2 인가: avg_Δ% -7.63, CI excludes 0 in 9/10 cell 강력 일관. 4강 中 유일한 online learning method — pre-computed cluster 없이 stream 으로 partial_fit 가능. 4강 역할 = **OLTP narrative 유일**.

3-4. ★1 HDBSCAN — "밀도 기반 클러스터링, 노이즈 자동 분리" (strongest narrative, oracle 영역)

K-means 와 달리 HDBSCAN 은 클러스터 개수 K 를 사전에 정하지 않는다. 대신 "밀도가 높은 영역 = 클러스터, 낮은 영역 = 노이즈" 로 자동 판별한다.

왜 좋은가: 데이터 분포가 균일하지 않을 때 (skew 가 심할 때) K-means 가 만든 동일 크기 클러스터보다 자연스러운 클러스터링이 가능.

왜 4강 ★1 인가: avg_Δ% -8.04 (4강 중 가장 강력) + 8/10 cell sign + 8/10 cell CI excludes 0 + SIFT_sf1 -34.17% / YFCC_sf1 -8.40% 1위. 단점: fit time 무거움 (~4313s) → oracle 영역 (production X) — KM20 oracle 과 동일 한계. 4강 역할 = **strongest narrative (가장 강한 magnitude + avg 1위)**.

§4. 핵심 측정 결과 — 10 cell × 4강 method paired Δ% 표

4-1. 핵심 표 (회의 narrative 의 절대 기준) — 10 cell 메인

paired Δ% = (4강 method 의 q_error 평균) – (BERN baseline 의 q_error 평균), sel=0.10 기준. 음수일수록 개선, 양수면 hurt.

Cell	Hilbert	Hybrid	MB_partial	HDBSCAN	해석
DEEP_sf1	-1.07%	-1.71%	-1.99%	-2.48%	약한 improve (DEEP 는 L2 normalized, 분포 활용 여지 적음)
DEEP_sf10	-1.98%	-2.73%	-2.87%	-2.51%	sf10 에서 sf1 보다 약간 더 큰 improve
SIFT_sf1	-33.53%	-30.46%	-33.13%	-34.17%	Sweet spot — 모든 method 30%+ 개선
SIFT_sf10	-12.02%	-11.48%	-11.63%	-11.79%	sf10 에서 효과 1/3 수준 (skew 약해짐)
SSN_sf1	+1.69%	+0.64%	+1.02%	+0.84%	⚠ Outlier — random 이 더 정확 (ceiling 효과)
SSN_sf10	+1.38%	+0.56%	+1.35%	+0.67%	sf10 에서도 동일 outlier (consistent hurt)
WIKI_sf1	-10.92%	-8.99%	-11.30%	-11.29%	text embedding 768d, 적당한 개선
WIKI_sf10	-5.70%	-5.43%	-3.77%	-5.54%	sf10 에서 효과 1/2 수준
YFCC_sf1	-8.07%	-6.98%	-8.37%	-8.40%	채림 정보 단일
YFCC_sf10	-5.21%	-4.78%	-5.62%	-5.77%	단일 100% 마지막 cell, 채림 정보 단일 일관 improve

(단일 10 cell × 4강 method 100% 측정 완료, 5/8 14:13 KST)

5/8 10:18 build_yfcc 다운로드 폐기: 이전에 측정한 YFCC_DL_sf1 / YFCC_DL_sf10 결과는 본 연구 narrative 에서 사용하지 않음. YFCC narrative 는 채림 정보 단일 (`partsupp_yfcc_{1,10}`).

4-2. 한 문장 요약: 10 cell 메인 중 8 cell 일관 improve

위 표의 핵심 발견을 한 문장으로 압축하면:

"단일 10 cell × 4강 method 100% 측정 완료. 8 cell 에서 4강 method 모두 BERN baseline 대비 *paired Δ%* 가 음수 (improve direction). 나머지 2 cell (SSN_sf1, SSN_sf10) 만 양수 — 이는 측정 bug 가 아니라 SSN++ 데이터의 분포가 너무 균형 잡혀있어서 우리 method 가 더 개선할 여지가 없는 ceiling 효과."

이 결론이 5/8 회의 + 5/27 발표 + 자문 메일의 narrative 핵심이다.

4-3. 가장 강한 결과: SIFT_sf1 -32%

SIFT_sf1 에서 4강 method 가 모두 -28% ~ -33% 개선. 왜 SIFT_sf1 만 이렇게 강한가?

- SIFT 의 norm CV 0.0932 (DEEP 0 / SSN 0.0049 의 19~∞ 배)
- SIFT 의 cluster size ratio 4.67 (DEEP 2.97 / SSN 1.25 의 1.5~3.7 배)
- SIFT 의 intrinsic dim ratio 0.6406 (DEEP 0.6771 / SSN 0.8828 보다 낮음 = 한쪽으로 편중)

3 가지 분포 특성 모두 우리 method 의 sweet spot 에 위치. 즉 SIFT 는 vector norm 이 흩어져 있고, cluster 크기가 불균형하며, 정보가 일부 dim 에 집중된 데이터. 이런 데이터에서 분포 정보 활용 sampling 이 가장 빛난다.

4-4. 가지치기 결과 직관 설명 — "method choice 미미, 분포 인지가 핵심"

5/8 14:13 단일 100% 가지치기 결과 (master_v6 §10) 의 직관 풀이:

30 method 측정 → 가지치기 5 partition (10 cell 100% 기준): - Wave 0 outlier 3종 (dbscan / lsh / random_proj): variance explosion (+261245% 등) → 측정 instability outlier (즉시 제외) - **Tier 1 살아남기 17 종:** avg_Δ% -8.04 ~ -6.78 (강력 일관). 모두 10 cell 中 8 cell improve, CI 7~9/10 통과 - **Tier 2 boundary 2 종** (birch -6.33 / kde_pilot -3.03): T1 boundary - **Tier 3 특수 1종** (pq -2.15): sign 절반 - **Pruned 7종** (sobol / hammersley / halton / spectral / distance_shell / optics / importance_sampling): magnitude 약 OR sign 반대

핵심 메시지 (회의에서 강조해야 할 narrative):

"Tier 1 내부 spread 1.21%p (-8.04 ~ -6.83) 만이라는 점이 결정적. 즉 **Tier 1 어느 method 든 강력 일관하다는 의미** — method 이름은 부차적이고, 분포 정보를 인지하느냐 vs 안 하느냐 (BERN baseline) 의 boundary 가 결정적이다. 4강은 그 중 production 차별화 (★1 hdbscan oracle / ★2 minibatch_partial OLTP / ★3 hilbert 빠름 / ★4 hybrid ablation) 의 대표 4종."

이 메시지는 5/27 발표 S8/S9 에서 funnel chart (30 → 19 살아남기 → 4강 → production-friendly 1) 와 함께 시각화된다.

4-5. Distribution Sweet Spot 정량 boundary

본 연구의 4강 method 가 적용되는 distribution 영역의 정량 boundary (master_v6 §10.5):

- **Sweet (강력 improve, -7~-32%):** cluster_ratio > 1.4 AND intrinsic_dim < 0.85
- SIFT (1.65 / 0.71), WIKI (1.84 / 0.81), YFCC (~1.5 / ~0.85), DEEP (1.43 / 0.78 — boundary smaller magnitude)
- **Ceiling (effect 약, ±2%):** cluster_ratio < 1.4 AND intrinsic_dim > 0.85
- SSN++ (1.29 / 0.88) — uniform-like distribution, BERN 자체가 이미 낮음

→ 본 연구 method 가 어떤 dataset 에서 빛나는지 정량 정의. 회의에서 "우리 method 는 모든 distribution 에서 universal improve 하지 않는다, 정량 boundary 까지 입증했다" 는 honest framing 이 핵심.

4-6. Exqutor 미작동 영역 정량화

본 연구의 contribution 위치 — Exqutor 본 논문이 미해결한 영역의 정량화:

Method category	적용 영역	정확도	Cost
Exqutor ECQO	indexed range query	1~2ms 정확	인덱스 필수
Exqutor Adaptive Sampling	non-indexed	모멘텀 기반 동적	skewed 분포에서 정확도 ↓
본 연구 (분포 인지)	non-indexed, single-table	+3~+32%p improve over BERN	사전 계산 cluster (one-time)

→ **Exqutor 미작동 영역** = single-table non-indexed skewed distribution. 본 연구의 정량화 (단일 10 cell 100%): SIFT sf1 -34%p / WIKI sf1 -11%p / YFCC sf1 -8%p / DEEP -2.5%p improvement.

§5. SSN++ ceiling 효과 — 가장 중요한 honest finding

5-1. 직관적 비유

SSN++ 의 ceiling 효과는 비유로 풀면 명확하다.

"이미 너무 잘 정리된 책장에는 더 정리할 여지가 없다."

SSN++ 데이터는 Facebook 의 SimSearchNet++ embedding 으로, 사전 훈련 + L2 normalization 으로 *O/M* 균형 잡힌 분포를 가진다. 우리 method 가 분포 정보를 활용해 stratification 하려 해도, 이미 모든 stratum 이 거의 동일한 모양 → stratified vs random 이 거의 같음 → 오히려 method 의 학습 noise (cluster fitting 부정확) 때문에 +1.4 ~ +2.3% 약간 hurt.

5-2. 4 가지 정량 증거 (HIGH confidence)

이게 측정 bug 가 아닌 진짜 distribution 특성이라는 증거 4 가지:

증거 1 — Vector norm CV (변동계수)


```
DEEP      : 0.0000 (L2 normalized, 모든 norm = 1)
SIFT      : 0.0932 (norm 이 흩어져 있음)
SSN_sf1   : 0.0049 (norm 이 거의 동일, 1778.52 ± 8.78)
SSN_sf10  : 0.0049 (sf1/sf10 동일)
```

SSN++ 의 norm CV 는 SIFT 의 1/19. 즉 모든 vector 가 거의 같은 sphere shell 위.

증거 2 — Intrinsic dim ratio (PCA 90% 설명 dim / declared dim)

```
DEEP_sf1 (96d) : 0.6771 (~65 dim 으로 90% 설명)
SIFT_sf1 (128d): 0.6406 (~82 dim 으로 90%)
SSN_sf1 (256d) : 0.8828 (~226 dim 으로 90%) ← 거의 모든 dim 사용
```

SSN++ 는 거의 모든 dim 이 의미 있는 정보를 운반 → near-isotropic, 어느 방향에서 봐도 비슷.

증거 3 — KMeans (K=20) cluster size CV

```
DEEP_sf1 : 0.2368 (max/min ratio = 2.97)
SIFT_sf1 : 0.3432 (4.67)
SSN_sf1   : 0.0551 (1.25) ← 모든 cluster 가 거의 동일 크기
```

KMeans 가 SSN++ 를 거의 동일 크기로만 자른다 → 분할의 차별 효과 = 0.

증거 4 — BERN baseline 자체 q_error 가 이미 낮음

```
sel=0.10 BERN q_error:
SSN_sf10: 1.1394 (8 cell 중 최저)
SSN_sf1  : 1.1401
DEEP_sf10: 1.1521
SIFT_sf1  : 1.7612 (가장 큼)
```

SSN++ 는 BERN 이 이미 충분히 정확. KM20 oracle 이 BERN 대비 단 0.49% 만 개선 가능 (headroom 0.49%) — 이는 SIFT_sf1 의 headroom 34.46% 의 1/70.

5-3. 의의 — 본 연구의 boundary 정의

SSN++ ceiling 의 발견은 본 연구의 *honest limitation* 으로 narrative 에 포함된다.

"본 연구의 4강 method 는 모든 distribution 에서 universal improve 하지 않는다. cluster_size_ratio < 1.3 + intrinsic_dim_ratio > 0.85 영역 (예: SSN++) 에서는 BERN ceiling 으로 method 의 net Δ 가 +0~+2% hurt 으로 표시되는 것이 자연스럽다 — 본 연구 method 의 적용 boundary 를 정량 입증한 negative control."

회의에서 이 발견을 *약점이 아니라 contribution* 으로 frame 하는 것이 중요하다. "우리는 우리 method 가 *어디* 서 작동하는지 정량 boundary 까지 입증했다" 는 narrative 가 5/27 발표의 신뢰도를 높인다.

5-4. 학술 confirmation — PDX (SIGMOD 2025) 의 동일 결론

본 SSN++ ceiling 가설은 우리만의 단독 결론이 아니다. SIGMOD 2025 (top-tier DB conference) 의 **PDX 논문** [Kuffo, Krippner, Boncz, CWI Amsterdam, *PDX: A Data Layout for Vector Similarity Search*, arXiv:2503.04422] 이 NYTimes/GloVe/SIFT/GIST/DEEP/MSong/Contriever/arXiv/OpenAI 등 10 benchmark dataset 에서 정확히 동일한 결론을 학술 confirmation 했다.

PDX 핵심 결론 (Section 5): - "two types of value distributions — normal vs skewed" - "normally distributed datasets are more challenging to prune than skewed datasets" - "intrinsic dimensionality and skewness metrics should govern algorithm selection rather than fixed parameter tuning"

→ PDX 의 skewness + intrinsic_dim metric 과 본 연구의 cluster_ratio + intrinsic_dim_ratio metric 이 **정확 일치**. 즉 본 SSN++ ceiling 가설은 SIGMOD 2025 학술 robust 결론이며, 5/27 발표에서 "우리는 우리 method 가 어디서 작동하는지 정량 boundary 까지 입증했고, 이 boundary 는 SIGMOD 2025 PDX 와 일치한다" 라는 narrative 가 완성된다.

비유: PDX 논문 (SIGMOD 2025) 도 우리와 같은 결론 — 분포가 균형 잡힌 dataset 은 method 효과 약함. 즉 우리 SSN++ ceiling 가설은 학술 인정.

→ **complementary contribution:** PDX 는 vector similarity search 의 **compute** layer (data layout) 를 분포 인지로 최적화. 본 연구는 **pre-process** layer (sampling/clustering) 를 분포 인지로 최적화. 두 contribution 은 정확 complementary. 5/27 발표 future work 에 PDX 통합 (end-to-end skewness-aware pipeline) 명시.

§6. YFCC source 결정 — 채림 정보 단일 (5/8 10:18 build_yfcc 폐기)

6-1. 비유로 이해하기

같은 YFCC100M 사진 데이터셋에서 시작했지만 두 가지 적재본이 만들어졌다. 비유로 풀면:

"같은 YFCC100M 사진 → 채림은 BigANN 챌린지가 미리 만든 192d uint8 (raw 픽셀 강도) 적재본을 받았고, 우리는 raw 1280d 받아서 직접 sklearn PCA 했음. 그래서 좌표축이 완전히 달라서 cosine ≈ 0 (90도 직교)."

적재본	출처	형태	norm
YFCC (<code>partsupp_yfcc_{1,10}</code>) = 채림 정보	BigANN 챌린지 base.10M.u8bin (사전 PCA)	192d uint8 (0~255 raw 픽셀)	≈ 1819 ($\sqrt{(192 \cdot 150^2)}$)
~~YFCC_DL (<code>partsupp_yfcc_pca_{1,10}</code>)~~ = build_yfcc 폐기	우리 자체 다운로드 raw + sklearn PCA	192d float32 (centered + normalize)	≈ 0.73 ($\sqrt{(192 \cdot \text{var})}$)

6-2. 측정 결과 (5/8 09:44, agent M 분석)

`compare_yfcc_distributions.py` 결과:

```
YFCC (채림 정보) norm 평균: 1819 (BigANN base.10M.u8bin 기반)
YFCC_DL (우리 build) norm 평균: 0.73 (sklearn PCA random_state=42)
cosine similarity: -0.0006  $\approx 0$  (완전 직교)
norm 비율: 2,508x
```

→ 두 적재본은 완전히 다른 임베딩 공간 (출처 자체가 다름: BigANN 사전 PCA vs sklearn 자체 PCA). 좌표축이 완전히 다른 dataset 처럼 다름.

6-3. 5/8 10:18 사용자 결정 — build_yfcc 폐기

본 연구는 5/8 10:18 build_yfcc.py 자체 다운로드/build chain 폐기 + YFCC 채림 정보 단일 source 결정을 했다. 이유:

1. PCA basis 일관성 자동 보장: 단일 source 통일하면 sf1/sf10/sf100 모두 동일 PCA basis 위에서 측정 가능
2. 다운로드 부담 회피: 자체 build raw 다운로드는 ~40GB, sf100 = 410GB 추가 부담 (incomplete)

3. **sf100 plan**: BigANN `base.80M.u8bin` (1.5GB 추정, 빠름, 채림 정보 동일 source) 권장

→ 이전에 측정한 YFCC_DL_sf1 / YFCC_DL_sf10 결과는 narrative 에서 사용하지 않음. 5/27 발표는 YFCC = 채림 정보 단일 source 로 reporting.

6-4. 회의 자문 의제 (4종으로 갱신)

- **의제 1 (YFCC 정보 합의)**: 채림 정보 단일 source 결정 합의 + build_yfcc 폐기 보고
- **의제 2 (sf100 다운로드)**: BigANN base.80M.u8bin 권장 (채림 정보 동일 source) — 회의 후 진행
- **의제 3 (PCA basis caveat)**: 단일 source 통일 narrative 의 적합성
- **의제 4 (SSN++ ceiling 검증)**: 4-pillar 분석 외부 자문

§7. 5/8 19:00 회의 의제 — 풀어쓴 의사결정

회의 9 시간 전. 다음 3 가지 의제가 핵심.

7-1. 의제 1 — sf100 측정 priority (5 dataset 중 어디부터?)

상황: sf100 (80M row) 은 W4 sprint 미측정. 5/8 회의 후 자문 합의 후 진행 예정. 5/27 발표 narrative 에 추가하려면 필수.

경로 A (즉시 측정 가능): - DEEP_sf100, SIFT_sf100, FB_sf100 (= SSN_sf100) — 이미 PG 적재 완료 (`partsupp_<DS>_100` row 80M). - 측정 시간: 5 method × 5 sel × 5 seed × 100 query = ~3-4 hour / cell.

경로 B (build/적재 필요): - WIKI_sf100 — `build_wiki.py` 으로 80M row PCA + extract 필요. 적재 + 측정: ~6-10 hour / cell. - YFCC_sf100 — BigANN base.80M.u8bin 다운로드 권장 (채림 정보 동일 source). build_yfcc 자체 다운로드는 5/8 10:18 사용자 결정으로 폐기.

의사결정: - 자문 회신 (~5/15) 전까지 무엇부터 시작할 것인가? - 회신 후 우선순위가 바뀔 수 있는가?

7-2. 의제 2 — sf100 YFCC source 합의 (build_yfcc 폐기 결정 보고)

상황: 5/8 10:18 사용자 결정으로 build_yfcc.py 자체 다운로드/build chain 폐기. 이유는 §6 의 직교 PCA basis 발견.

sf100 YFCC plan: - **권장**: BigANN `base.80M.u8bin` 다운로드 (~1.5GB 추정, 빠름) — 채림 정보 동일 source 통일 - **대안**: 채림 석사님 vanilla_sf100 의 partsupp_yfcc_100 적재 여부 확인 (있으면 즉시 측정)

의사결정: - BigANN 80M.u8bin 다운로드 launch 시점 (5/15 자문 회신 후?) - 단일 source 통일 narrative 가 충분히 honest 한가?

의견 출발점: 채림 정보 단일 source 통일 결정으로 PCA basis 일관성 자동 보장 + 다운로드 부담 회피 + sf100 측정 가능. 410GB 자체 build 는 폐기.

7-3. 의제 3 — 추가 method 가지치기 기준

상황: 5/27 최종 발표에서 25 method 중 몇 개를 살릴 것인가?

Tier elimination 결과 (5/8 09:50 master_v6 기준):

Tier	통과 method	개수
Tier 1 (통계 robust, $\geq 5/10$ cell CI 0 제외)	KM20, MiniBatch, MiniBatch_partial, Hilbert, Z-order, Hybrid, HDBSCAN, KDtree, PCA1D, BIRCH, Faiss IVF, Hierarchical KMeans	~12
Tier 2 (production cost $\leq$ KM20)	MiniBatch_partial, Hilbert, Z-order, Hybrid, HDBSCAN, KDtree, PCA1D, BIRCH	~8
Tier 3 (sf1↔sf10 부호 일관)	MiniBatch_partial, Hilbert, Hybrid, HDBSCAN	~4
Tier 4 (5 dataset robust, final winner)	MiniBatch_partial, Hilbert, Hybrid, HDBSCAN	4

의사결정: - 5/27 발표 main slide 에서 표시할 method = 4강 (Tier 4) 만으로 충분? - 부록 (appendix) 에 표시할 method 는 어디까지? - "살아남는 method" 표현이 청중에게 직관적인가?

§8. 한계 (Limitation) 와 향후 작업 (Future Work)

본 연구의 honest limitation 9 가지. 회의 + 자문 메일 + 발표에서 정직 reporting 의 핵심.

8-1. KM20 oracle 의 production 적용성

한계: KM20 (K-means K=20) 은 *oracle baseline* 으로 학습 시간 ~30 분 (8M row 기준). production 환경에서 매 query 마다 학습 불가능.

보완: 4강 production-ready method (Hilbert / MiniBatch_partial / Hybrid / HDBSCAN) 가 KM20 oracle 의 70-100% 회복 (Recovery Rate). MiniBatch_partial 은 점진적 학습 가능 → OLTP friendly.

8-2. 사전 계산 one-time cost

한계: 4강 method 도 처음 한 번은 학습 필요 (예: MiniBatch K-means 의 K=20 cluster 학습, Hilbert curve index 계산). 이 cost 가 production 에 부담?

보완: one-time cost (한 번만, 결과 저장 가능). query time cost 는 수 ms. 분기 단위로 retrain 하면 충분.

8-3. OLTP 범위 외 (HNSW UPDATE 매우 느림)

한계: pgvector 의 HNSW index 는 INSERT/UPDATE/DELETE 가 매우 느림 (특히 UPDATE 가 ms 가 아닌 초 단위). 본 연구는 read-heavy + 정적 데이터 가정.

향후 작업: 동적 데이터 (실시간 업데이트) 환경에서 분포 정보 활용 sampling 의 효과 검증.

8-4. 단일 → 멀티 일반화 (5/8 17:50 4강 multi 일반화 측정 STAGE 1+2+3 finalize)

핵심 발견: 단일 정확성은 multi 정확성의 **필요조건만 성립, 충분조건 X**.

정량 결과 (5/8 STAGE 1+2+3 완료, multi-vector 2 cell + multi-table-join 1 cell × 4강 method × sel=0.10): - 단일 sweet spot 4강 평균 $|\Delta\%| = 17.13\%$ (SIFT_sf1 / WIKI_sf1 / YFCC_sf1) - multi-vector 4강 평균 $|\Delta\%| = 0.67\%$ (sift+wiki 평균) - multi-table-join 4강 평균 $|\Delta\%| = 0.68\%$ (partsupp_deep_10 ⋈ part_wiki_10, 8M JOIN) - → **25.2x 약화** (magnitude shrinkage chain: 단일 17.13% → multi-vector 0.67% → multi-join 0.68%) - 부호 일관성 (sel=0.10): 6/12 negative · 6/12 positive boundary ($|\Delta|$ 모두 < 1.5%); sel=0.50 11/12 negative.

진행 상황: - ☒ multi-vector partsupp_deep_sift_10 (DEEP+SIFT 한 행, 96+128 dim) × 4강 method 측정 완료 - ☒ multi-vector partsupp_deep_wiki_10 (DEEP+WIKI 한 행, 96+768 dim) × 4강 method 측정 완료 - ☒ multi-table join (partsupp_deep_10 ⋈ part_wiki_10, FK 4-to-1, 8M JOIN rows) × 4강 method 측정 완료

multi-table-join 4강 paired $\Delta\%$ (vs bernoulli, sel=0.10 / 0.50): | Method | sel=0.01 | sel=0.05 | sel=0.10 | sel=0.30 | sel=0.50 | |---|---|---|---|---| | hdbscan | +19.09% | +0.47% | +0.29% | -0.66% | -0.15% | | hilbert | +12.06% | -0.26% | -0.85% | -0.45% | -0.28% | | hybrid | +14.88% | -0.59% | -0.22% | -0.09% | -0.24% | | mb_partial | +17.94% | +2.47% | +1.38% | -0.55% | -0.25% |

해석: multi 환경에서 4강 method 의 ranking 도 노이즈 수준으로 와해 (multi-join sel=0.10: hilbert > hybrid > hdbscan > mb_partial — 단일과 거의 역순). **shrinkage 의 발생 지점 = "vector 수 증가" 단계**, table join 단계는 추가 약화 없음 (multi-vector 0.67% ≈ multi-join 0.68%). multi-relation 일반화는 **joint-aware clustering** 또는 **multi-vector decomposition** 별도 설계 필요 → future work.

기존 §multi-1 (KM20 mode ablation: emb1/emb2/concat/product) 결과는 master_v6 §multi line 645~676 에 별도 보존 (보조 자료).

8-5. σ_i Neyman 신호 약함

한계: Neyman allocation 의 핵심인 σ_i (cluster 별 표준편차) 신호가 5 dataset 에서 약함. Anti-Neyman 만 systematic hurt (즉 σ_i 정보를 *반대로* 쓰면 systematically 나빠짐 → σ_i 신호는 존재하나 약함).

해석: σ_i 신호의 *비결정적 가치*/honest reporting. RQ2 narrative 의 honest 한 부분.

8-6. K-sweep upper bound K=200

한계: $K \in \{10, 20, 50, 100, 200\}$ 까지만 sweep. WIKI 768d / SSN++ 256d high-dimensional 환경에서 K_{optimal} 이 $K > 200$ 영역일 수 있음.

향후 작업: $K=500, 1000$ 영역 추가 측정.

8-7. sf100 deferred → cross-scale 부분 입증

한계: 본 W4 sprint 는 sf1 + sf10 2-scale 만 측정. sf100 (80M) 은 자문 합의 후 진행 예정.

보완: sf1 ↔ sf10 부호 일관성 (12 cell 중 10 cell improve direction) 으로 cross-scale invariance 부분 입증.

8-8. dataset 별 effect size 격차

한계: SIFT_sf1 -32% / DEEP_sf1 -0.4% / SSN_sf1 +2.3% — 같은 method 라도 dataset 마다 effect size 격차 큼.

의의: 이는 limitation 이 아니라 distribution sweet spot 의 정량 입증 (§5 SSN++ ceiling 참조). 본 연구의 contribution 중 하나.

8-9. SSN++ ceiling — 본 연구의 distribution boundary

한계: 4강 method 는 well-spread + balanced distribution ($\text{cluster_ratio} < 1.3 + \text{intrinsic_dim_ratio} > 0.85$) 영역에서는 net hurt direction.

의의: §5 에서 풀어 쓴 ceiling 효과. 본 연구의 honest reporting 핵심.

§9. 한 페이지 요약 (회의 직전 5 분 만에 훑기)

회의 직전 5분 만에 핵심을 훑을 사람을 위해 한 페이지로 압축.

9-1. 우리가 한 일 (3 줄)

1. **W4 sprint (5/6~5/8)**: 5 dataset $\times$ sf1/sf10 = 10 단일 cell $\times$ 30 method $\times$ RQ1/2/3 = **100% 측정 완료** (5/8 14:13 KST).
2. **30 method $\times$ paired bootstrap CI** (16 base + 9 NEW9 + Wave 1 7종): 분포 정보 활용 sampling 의 정량 가치 평가. analyze_10cell_w4.py 재계산 (query_id paired alignment).
3. **honest reporting**: SSN++ ceiling 효과로 본 연구 method 의 적용 boundary 까지 정량 입증.

9-2. 핵심 발견 (4 줄, 5/8 14:13 단일 100% finalize)

1. **4강 method = production criteria 결정** (★1 hdbscan oracle / ★2 minibatch_partial OLTP / ★3 hilbert production / ★4 hybrid ablation): avg_Δ% -8.04 ~ -7.13, CI 7~9/10 일관.
2. **Tier 1 살아남기 17종, spread 1.21%p** — method choice 의 차이는 작음. **분포 정보 인지 vs 미인지 boundary 가 결정적** (RQ3 의 답).
3. **SIFT_sf1 -34% (sweet spot) vs SSN_sf1 +1.7% (ceiling)** — 분포 특성에 따라 method 효과 갈림. 정량 boundary: cluster_ratio > 1.4 AND intrinsic_dim < 0.85. **학술 confirmation**: SIGMOD 2025 PDX [Kuffo et al., CWI Amsterdam, arXiv:2503.04422] 가 동일 hypothesis ("normally distributed datasets are more challenging to prune than skewed datasets") 를 10 benchmark 에서 입증 → 본 ceiling 가설은 top-tier DB conference 학술 robust 결론.
4. **Exqutor 미작동 영역 정량화**: single-table non-indexed skewed → SIFT sf1 -34%p / WIKI sf1 -11%p / YFCC sf1 -8%p / DEEP -2.5%p.

9-3. 회의 의제 4 가지

1. **4강 method 선정 confirm** (★1 hdbscan / ★2 minibatch_partial / ★3 hilbert / ★4 hybrid)
2. **Tier 1 = 17종 narrative 합의** (RQ3 의 답 = "어느 분포 인지 method 든 Tier 1 이면 OK, 4강 = 대표")
3. **sf100 측정 priority + YFCC sf100 source** (DEEP/SIFT/SSN 즉시 가능, WIKI build 필요, YFCC 채림 정보 요청)
4. **Multi 일반화 future work 합의** (4강 $\times$ 3 multi cell, 측정 진행 중 ~14:00~15:30 ETA)

9-4. 5/27 까지 D-19 일정

일정	마감
5/8 19:00 회의	자문 메일 합의
~5/15	자문 회신 (채림 + 지도교수)
~5/21	발표자료 초안
5/22	교수님 미팅
5/26	발표자료 최종
5/27	★ 최종 발표
6/11	★ 최종 보고서

9-5. 우리의 contribution 다섯 가지 (한 줄씩)

1. Normal/Skew × Block/Row 정량 비교
2. Selectivity Gradient (DEEP_sf1 19.6%p, 5 dataset 100% 부호 일관)
3. Two-Level Decomposition (분할 + 분배)
4. Recovery Rate Framework (oracle 의 몇 % 회복) + **method choice 부차성 메시지** (Tier 1 spread 1.24%p, 분포 인지 boundary 결정적)
5. **SSN++ ceiling 효과 + Distribution Sweet Spot 정량 boundary** (cluster_ratio > 1.4 / intrinsic_dim < 0.85) — 본 연구 method 의 적용 boundary 정량 정의 + Exqutor 미작동 영역 정량화 (SIFT -34%p / WIKI -11%p / YFCC -8%p / DEEP -2.5%p) + **PDX (SIGMOD 2025) 학술 confirmation** (CWI Amsterdam, 동일 hypothesis 10 benchmark 입증) + complementary contribution (PDX = compute layer / 본 연구 = pre-process layer, 통합 framework future work)

§10. 참고 자료 위치

회의 + 자문 메일 + 발표 작성 시 참조할 파일.

측정 자료

- master_v6 종합 doc: `/Users/hyunbin/Capstone/experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft_filled_partial.md` (623 lines, 42KB)

- W4 partial summary CSV: `/Users/hyunbin/Capstone/_internal/_w4_partial_summary.csv` (1235 rows)
- multi 3 cell paired CI JSON: `/Users/hyunbin/Capstone/_internal/multi_w4_recovered.json` (11 KB)
- RQ1 13 cell Spearman: `/Users/hyunbin/Capstone/_internal/rq1_monotone_recovered.json` (25 KB)
- RQ2 5mode 13 cell: `/Users/hyunbin/Capstone/_internal/rq2_5mode_recovered.json` (91 KB)

회의 자료

- PPTX (15 slide, 양식 99%): `/Users/hyunbin/Capstone/submission/_drafts/속도는벡터_5월8일회의_v1.pptx` (468KB)
- 차트 5장 (S6/S8/S10/S11/S14): `/Users/hyunbin/Capstone/experiments/figures/native_pptx_charts/`
- W4 partial figures (13 PNG): `/Users/hyunbin/Capstone/experiments/figures/w4_partial/`
- PPT outline: `/Users/hyunbin/Capstone/submission/_drafts/속도는벡터_5월8일회의_PPT_outline.md`
- 자문 메일 초안 (W4): `/Users/hyunbin/Capstone/submission/_drafts/속도는벡터_자문메일초안_W4_20260507.md`

handoff 인계 (작성자 내부용, 팀원 무시 OK)

- v9 (5/8 09:50): `/Users/hyunbin/Capstone/_internal/handoff_v9_session_20260508_AM.md`
- v8 (5/7 22:41): `/Users/hyunbin/Capstone/_internal/handoff_v8_session_20260507_2241.md`

마무리

이 문서는 회의 9 시간 전 (5/8 09:55 KST) 시점의 W4 sprint 측정 결과 종합이다. 회의 도중 측정값 변경 시 master_v6 가 우선이며, 본 doc 은 이해 보조 자료로만 활용한다.

회의에서 풀리지 않은 의제는 자문 메일 (~5/15 회신) 후 재검토. 5/27 최종 발표 narrative 의 최종 측정값은 회의 결과 + 자문 회신 + sf100 측정 결과를 모두 통합한 후 fix.

질문 있으면 카톡 (조현빈) 또는 회의에서 직접.

작성: 조현빈 · 2026-05-08 09:55 KST · W4 sprint 결과 팀원 이해용 종합 **선행 doc:** master_v6 + handoff_v9 + handoff_v8 **다음 회의:** 5/8 19:00 KST 비대면 (전원)