

속도는벡터 — 프로젝트 사용설명서

작성 시점: 2026 년 4 월 28 일 v2 (PDF 제출 마감일, 중간 발표 4 월 30 일)

대상: 팀원·자문위원·외부 검토자

목적: 보고서와 발표 자료를 처음 보는 사람도 내용을 정확히 이해하고, 필요할 때 자신 있게 수정·보완할 수 있도록 돕는다.

본 문서는 학술 논문이 아니다. 우리가 무엇을 했는지, 보고서의 어느 줄이 어떤 실험에서 나온 수치인지, 그리고 어떤 부분을 수정해도 괜찮고 어떤 부분은 손대면 다른 곳이 흔들리는지를 평이하게 풀어 쓴 안내서다.

1. 우리 프로젝트가 다루는 것 — 5 분 안에 이해하기

1.1 한 줄 요약

벡터로 된 데이터를 SQL 쿼리로 다룰 때, 옵티마이저가 "결과 행이 몇 개 나올지" 를 더 정확히 추정하도록 만든다. 그 정확도가 1 % 좋아지면 잘못된 실행 계획이 줄고, 잘못된 실행 계획 한 번이 실행 시간을 1만 배까지 늘릴 수 있기 때문이다.

1.2 벡터·임베딩이 왜 필요한가

이미지·텍스트·음성처럼 의미가 중요한 데이터는 글자 그대로 비교하기 어렵다. "고양이" 와 "야옹이" 는 같은 의미지만 글자는 다르고, 같은 사람의 사진 두 장도 픽셀값은 매번 다르다. 그래서 이런 데이터를 *임베딩* 이라는 절차로 96 차원이나 1024 차원의 숫자 벡터로 바꾼다. 의미가 가까운 두 항목은 벡터 공간에서도 가까이 놓인다는 약속을 학습으로 만들어낸 것이다.

이 벡터를 저장·검색하는 시스템이 *벡터 데이터베이스* 다. 챗봇의 검색 보강(RAG), 멀티모달 검색, 추천 시스템, 이상 탐지 같은 응용에서 벡터 유사도 검색은 핵심 연산이 되었다.

1.3 카디널리티 추정 문제

옵티마이저는 SQL 쿼리를 실행하기 전에 "이 조건을 만족하는 행이 몇 개나 나올까?" 를 미리 짐작한다. 그 짐작값을 *카디널리티* 추정 이라고 부른다. 짐작이 맞으면 옵티마이저가 빠른 실행 계획을 고른다. 짐작이 어긋나면 잘못된 계획을 골라 실행 시간이 폭발한다.

문제는 벡터 거리 조건의 카디널리티 추정이 어렵다는 데 있다. pgvector 는 33.3 %, VBASE 는 50 %, DuckDB 는 100 % 의 고정 비율로 추정한다. 실제 비율은 0.001 % 부터 100 % 까지 변동하니, 고정 비율은 거의 항상 틀린다.

1.4 Exqutor 가 한 일과 우리가 발견한 빈자리

Exqutor (arXiv:2512.09695v2) 는 이 한계를 두 갈래로 풀었다. 인덱스가 있을 때는 *ECQO* — 가벼운 검색을 한번 실제로 돌려서 정확값을 얻는다. 인덱스가 없을 때는 *Adaptive Sampling* — 일부 행만 추출해 임계값을 만족하는 비율을 계산하고 그 비율을 곱해 추산한다.

우리가 코드를 직접 읽어 확인한 사실은 이렇다. *Adaptive Sampling* 의 진입 조건문이 테이블이 두 개를 넘을 때만 켜지도록 짜여 있다. 이미지 검색·추천·RAG 의 핵심에 자리하는 단일 테이블 검색은 이 조건을 통과하지 못해, 옵티마이저가 PostgreSQL 의 기본값(전체의 약 1/3) 으로 떨어진다. Exqutor 원논문은 이 사실을 명시하지 않았고, 우리는 이를 *단일 테이블 사각지대* 라고 부른다. 이 빈자리에서 우리가 무엇을 할 수 있는지가 본 연구의 주제다.

1.5 우리가 한 보완 — 두 갈래

쏠린 데이터에서 추정 정확도가 떨어지는 원인은 두 가지가 섞여 있다.

첫째, 추출 단위가 만드는 편향이다. PostgreSQL 의 기본 추출은 8KB 페이지 블록 단위라서, 같은 블록 안 행들이 함께 뽑히거나 함께 빠진다. 우리는 추출 단위를 *베르누이*(각 행을 동전 던지듯 독립으로 뽑는 방식) 로 바꾸어 이 편향을 없앴다. 코드 한 줄 교체로 가장 큰 selectivity 구간에서 100 개 쿼리 중 78 개가 우세, 중앙값 9.6 % 개선이 통계적으로 유의하게 나왔다.

둘째, 데이터의 공간 구조가 한쪽으로 쏠려 있을 때 균일 추출이 작은 영역을 빠뜨리는 문제다. 우리는 *k-means* 로 데이터를 $K = 20$ 개의 영역으로 나눈 뒤 영역별로 균등하게 표본을 가져와 가중 합산하는 *층화 표본* 방식을 코드 안에 새로 추가하였다. 이 방식은 베르누이 위에서 1.6 ~ 4.4 % 의 추가 개선을 만든다.

두 보완은 결이 다르므로 직교적으로 분리해 측정할 수 있다. 그래서 보고서가 RQ2 를 RQ2-1, RQ2-2 두 갈래로 나눠 본 것이다.

2. 보고서를 읽는 법

보고서는 캡스톤 공식 양식의 6 항목을 따른다. 각 항목이 어떤 역할을 하는지 정리한다.

섹션	분량	역할	핵심 메시지
1. 해결하고자 하는 문제	약 2 p	처음 읽는 사람을 위한 배경	벡터·임베딩 → 카디널리티 추정의 중요성 → 우리의 질문
2. 기존 연구의 현황 및 한계점	약 1.5 p	Exqutor 까지의 흐름과 그 빈 자리	고정 비율 한계 → Exqutor 두 보완 → 단일 테이블 사각지대
3. 차별성 및 중요성	약 1.5 p	우리가 무엇을 다르게 했는가	단일 테이블 집중 + 단계적 보완의 효과 분리 측정
4. 연구 및 실험 방법	약 6 p	RQ1·RQ2·RQ3	사각지대 확인 + 두 단계 직교 측정 + 분포 무인지 탐색
5. 진행 상황·향후 계획	약 1 p	어디까지 왔고 어디로 가는가	4 월의 4 주차 흐름 + 5~6 월 계획
6. 팀원별 역할 분담	약 0.5 p	누가 무엇을 했는가	표 4

2.1 표가 보여주는 것

표 1 (selectivity 별 Q-error 중앙값 비교) 은 베르누이 추출 한 줄 교체 의 효과만 본다. 두 열의 차이가 그 효과의 크기다. selectivity 0.500 에서 0.0519 차이는 +9.6 % 의 중앙값 개선으로 환산된다. 이 표의 모든 수치는 DEEP 1M 데이터셋에서 100 개 쿼리에 대해 paired Wilcoxon 검정으로 산출되었으며, 행 단위가 우세한 쿼리 개수와 그 통계적 유의성(p-value) 도 함께 적혀 있다.

표 2 (총화 표본의 추가 개선율) 은 베르누이 위에서 총화 표본이 추가로 얼마를 더 개선하는지 본다. 표 1 과 비교 하지 말고 표 2 안에서 신뢰구간이 양수로 확정된 셀과 노이즈 영역(괄호 표시) 을 구분해 읽는다. 신뢰구간 [+1.11, +2.18] 처럼 양수만 들어 있으면 효과가 통계적으로 유의하다.

표 3 (향후 일정) 은 5 월 이후의 계획이다. RQ3 의 비교 실험이 W10 ~ W12 에 들어가 있다.

표 4 (역할 분담) 은 보고서 전반에 걸친 책임 분배다.

2.2 그림이 보여주는 것

그림	위치	보여주는 것
그림 1	§3.3	코드의 어느 부분을 어떻게 바꿨는지 — 진입 조건 한 줄, 추출 단위 한 줄, 총화 분기 추가
그림 2	§4.2.1	같은 쿼리에서 베르누이가 블록 단위 추출보다 우세한 사례를 산점도로 시각화
그림 3	§4.2.2	DEEP 1M 의 6 개 selectivity 구간에서 베르누이와 총화 표본의 분포 차이
그림 4	§4.2.2	세 데이터셋에서 selectivity 0.500 의 총화 표본 효과 (95 % 신뢰구간)
그림 5	§4.2.2	selectivity 가 좁아질수록 총화 표본 효과가 어떻게 바뀌는지
그림 6	§4.2.3	표본 안정화(L1) 와 공간 인식(L2) 의 분리 — Level 2 가 단독으로 +19.6 %p
그림 7	§4.2.3	DEEP 과 SIFT 의 클러스터 쏠림 격차(CV 0.234 vs 0.394)

2.3 RQ1 / RQ2 / RQ3 의 역할 차이

- **RQ1** 은 "사각지대가 실제로 있다" 를 코드 검증으로 기록 하는 단계다. 추정값을 얼마나 개선했다는 수치가 RQ1 에서 직접 나오지는 않는다.
- **RQ2** 는 "있는 사각지대를 두 단계 보완으로 메꿨더니 정확도가 이만큼 좋아졌다" 를 측정 하는 단계다. 본 연구의 정량적 산출물 대부분이 여기서 나온다.
- **RQ3** 는 "분포를 모를 때도 RQ2 의 효과를 어느 정도 회복할 수 있는가?" 를 5 월에 비교 실험할 계획 이다. 본 보고서 시점에는 측정 결과가 없으므로, "탐색 단계" 라고 표현했다.

3. 발표 자료를 읽는 법

발표 자료는 17 슬라이드 구성이다. 발표 시간은 10 분, 질의응답 5 분이다.

슬라이드	제목	보고서 어느 절과 매칭되나
S01	표지	—
S02	목차	—
S03	해결하고자 하는 문제	§1
S04	Exqutor 의 두 보완책	§2.2
S05	Adaptive Sampling 의 단일 테이블 사각지대	§2.3
S06	차별성 및 제안 연구의 중요성	§3
S07	RQ1 — 단일 테이블 사각지대의 구조적 한계	§4.1
S08	RQ2 (1) — 행 단위 추출이 블록 편향 제거	§4.2.1, 표 1
S09	RQ2 (2) — 공간 인식 증화 표본 추가 개선	§4.2.2, 표 2
S10	외적 타당성 — 3 데이터셋 교차 검증	§4.2.2, 그림 4
S11	데이터 쏠림과 공간 인식 효과의 인과 관계	§4.2.3, 그림 6·7
S12	RQ3 (탐색 단계) — 회복률 프레임워크	§4.3
S13	진행 상황 (W1 ~ W9)	§5.1
S14	향후 계획 (W10 ~ W15)	§5.2, 표 3
S15	팀원별 역할 분담	§6, 표 4
S16	결론	—
S17	감사합니다	—

발표 동선은 *문제 → 빈자리 → 우리의 해법 → 측정 결과 → 인과 설명 → 다음 단계*의 흐름이다. 각 슬라이드의 핵심 한 줄이 곧 발표자가 말로 설명할 한 문장이라고 보면 된다.

4. 자주 묻는 질문

Q1. 카디널리티가 정확히 무엇인가요?

쿼리 결과로 나오는 *행의 개수*를 옵티마이저가 미리 짐작한 값이다. "이 조건을 만족하는 행이 100 만 개쯤 될 것이다" 라는 식이다. 이 숫자가 옵티마이저로 하여금 nested loop 와 hash join 사이에서 한 쪽을 고르게 만든다.

Q2. 베르누이 추출은 왜 더 좋나요?

PostgreSQL 의 기본 추출은 8KB 페이지 *블록 단위*다. 같은 블록 안 행들은 함께 뽑히거나 함께 빠진다. 한 블록에 비슷한 행만 모여 있으면 추정 분산이 커진다. 베르누이는 *각 행을 독립적으로* 뽑으니 이 편향이 사라진다. 코드 한 줄 교체로 selectivity 0.5 구간에서 100 개 중 78 개 쿼리에서 우세, 중앙값 9.6 % 개선이 통계적으로 유의했다.

Q3. 왜 단일 테이블 검색에 집중했나요?

이미지 검색·추천 시스템·RAG 의 검색 단계가 모두 단일 테이블에서 벡터 거리 조건을 거는 형태다. Exqutor 의 두 보완책은 *두 개를 넘는 테이블*을 가정하고 짜여 있어 이 시나리오에서는 작동하지 않는다. 즉 실무적으로 가장 자주 쓰이는 형태가 그대로 빈자리로 남아 있다.

Q4. RQ3 가 왜 산문으로만 적혀 있나요? 표가 빠진 이유는?

RQ3 는 본 보고서 시점(중간 발표) 에서 *측정이 끝나지 않은* 단계다. 어떤 방법이 좋을지 아직 정해지지 않았으므로, 표로 후보를 나열하면 마치 결정된 듯한 인상을 줄 우려가 있다. 그래서 회의 피드백을 따라 "어떤 방법들이 가능한지 조사한 결과" 로 톤을 낮추고 산문으로 풀어 적었다. 폐기한 후보(예: Exqutor Adaptive 와의 하이브리드, 트리 기반 분할, Latin Hypercube, Coreset, 그래프 분할) 도 함께 적어 *탐색의 흔적*을 남겼다.

Q5. 회복률(Recovery Rate) 이란?

분포를 알 때 가능한 *총화 표본*의 효과를 100, 무작위 분할의 효과를 0 으로 두었을 때, 분포를 모르는 새 방법이 그 사이 어디에 위치하는지 표시한 단일 척도다. 100 에 가까울수록 분포를 몰라도 분포를 알 때와 비슷한 효과가 난다는 뜻이다. 다만 일부 데이터셋·selectivity 조합에서는 *총화 표본 ~ 무작위 분할*이라 분모가 작아져서 회복률이 불안정해진다. 이런 셀에서는 절대 개선폭으로 따로 보고하기로 정해 두었다.

Q6. "VBASE 에서 최대 1만 배 이상" 이라는 표현이 정확한가요?

Exqutor 원논문이 보고한 수치는 시나리오에 따라 변동이 크므로, *최소 1만 배 이상이 가능*하다는 뜻으로 해석해야 한다. 1 만 배가 상한이라는 의미가 아니다. 이 표현은 발표 자료에서도 동일하게 유지하기로 회의에서 합의했다.

Q7. 8 지표 전수 검증이란?

쿼리만 보고 데이터의 쓸림 정도를 미리 알아낼 수 있는지를 확인한 검증이다. **글로벌** 4 지표(Fisher γ , log-Fisher γ , P99/P50 tail ratio, Bowley skew)와 **로컬** 4 지표(k-NN distance entropy, k-NN PCA EVR1, KDE modality count, NN clustering coefficient)를 모두 동원하여 쿼리별 추정 오차와의 상관관계를 보았다. 모든 조합에서 |Spearman ρ | < 0.2 였다. 즉 단순 휴리스틱으로 분포 쓸림을 미리 잡아내는 길은 닫혀 있고, 이는 RQ2 (분포를 알 때)와 RQ3 (분포를 모를 때) 두 갈래를 모두 다뤄야 하는 직접 근거가 된다.

Q8. "직교적으로 측정"이라는 표현은 무슨 뜻인가요?

두 효과가 서로 겹치지 않으니, 한쪽을 고정해 둔 채 다른 한쪽만 켜볼 때의 차이가 그 한쪽의 단독 효과가 된다는 의미다. 보고서에서는 베르누이를 켜 둔 상태에서 총화 표본을 추가로 켜는 식으로, 두 보완의 효과를 분리해서 켜다.

Q9. Two-Level 분해는 왜 했나요?

총화 표본의 개선분이 어디서 오는지를 알기 위해서다. 같은 $K = 20$ 으로 나누되 (a) 무작위로 나누는 것과 (b) 거리 기반(k-means)으로 나누는 것의 차이를 보면, 거리 기반 분할만 가지는 **공간 인식** 효과의 크기를 알 수 있다. DEEP 1M selectivity 0.010 에서 그 격차가 19.6 %p 였고, 이는 본 연구의 출발 가설 — **쓸림이 클수록 공간 인식의 가치가 크다** — 의 인과 관계를 데이터에서 확인해 주는 결과다.

5. 수정·보완 시 참고 사항

5.1 보고서 수정 시 — 어디를 손대도 안전하고, 어디는 흔들리는가

자유롭게 손봐도 되는 부분 - §1.1 ~ §1.3 의 배경 설명 — 더 친절한 표현으로 바꾸어도 좋다. 다른 섹션과 직접 연동되지 않는다. - §3.2 (중요성) 의 마지막 단락 — 임팩트 강조 문구는 발표 흐름과 맞춰 약간 달리 써도 무방하다. - §6 의 마지막 단락 — 일정 마무리 문구.

손대면 다른 곳이 흔들리는 부분 - 표 1, 표 2 의 모든 수치 — 본문에서 인용된 +9.6 %, +1.64 % 등의 숫자가 표와 정확히 맞아야 한다. 값을 바꾸려면 본문 수치도 함께 갱신. - §4.2.3 의 19.6 %p, +8.93 %, -10.67 % — 그림 6 의 주석과 연동. 셋이 함께 바뀌어야 일관성이 유지된다. - §4.2.3 의 CV 0.234 / 0.394 — 그림 7 과 연동. - 그림 캡션 — 본문과 함께 읽히므로, 본문 표현이 바뀌면 캡션도 함께 점검.

바꾸지 말 것 - "Exquitor (arXiv:2512.09695v2)" 라는 인용 형식 — 원논문 식별자. - 데이터셋 이름·차원(DEEP 1M 96 d, DEEP 8M 96 d, SIFT 1.5M 128 d). - 5-seed, paired Wilcoxon, 95 % 신뢰구간 같은 통계 메타.

5.2 발표 자료 수정 시

PowerPoint 에서 슬라이드별 텍스트는 자유롭게 수정 가능하다. 다만 다음에 유의한다.

- **제목 슬라이드(S01)** — 팀명·팀원·지도교수 정보는 보고서와 일치해야 한다.
- **목차(S02)** — 본문 슬라이드 제목과 일치해야 한다. S07 의 제목을 바꾸면 S02 도 함께 고친다.
- **표·수치 슬라이드(S08, S09)** — 보고서 표 1·2 와 같은 숫자를 쓴다. 한쪽만 바뀌면 모순이 생긴다.
- **결론 슬라이드(S16)** — 본 보고서가 말하는 4 가지 산출물 — 사각지대 확인, 베르누이 효과, 층화 표본 효과, RQ3 탐색 — 의 요약. 발표 동선의 마지막 인상이므로 메시지를 바꿀 때는 보고서 §3 (차별성·중요성) 과 함께 점검.

5.3 PDF 재생성 워크플로

작업본은 docx 와 pptx 다. 제출본은 PDF 다.

보고서: Word 에서 docx 를 열고 *파일* → *다른 이름으로 저장* → *PDF*. 파일명은 **속도는벡터_중간보고서.pdf** (timecode 없음, 캡스톤 공식 제출 양식).

발표 자료: PowerPoint 에서 pptx 를 열고 *파일* → *내보내기* → *PDF*. 또는 Keynote 로 열어 *파일* → *내보내기* → *PDF*. 파일명은 **속도는벡터_중간발표.pdf**.

작업 중 백업본은 **submission/_drafts/archive/** 에 시간 스탬프와 함께 보관되어 있다.

6. 회의에서 합의된 주요 톤·표현 — 잊지 말 것

다음은 4 월 25 일 카톡 피드백과 4 월 27 일 회의에서 합의된 표현 원칙이다. 본 보고서·발표 자료에 모두 반영되어 있으며, 추후 수정 시에도 유지한다.

1. **분량 축소** — 보고서는 14 페이지, 발표 자료는 17 슬라이드. 더 늘리지 말 것.
2. **High-level 우선** — 처음 보는 사람이 따라올 수 있는 흐름을 유지. low-level 디테일은 그림 1 과 한두 단락에 압축.
3. **한국어 우선** — **vector.c**, **TABLESAMPLE SYSTEM/BERNOULLI**, **table_count > 2** 같은 코드 식별자는 첫 등장 후에는 "추출 단위", "한 줄 조건문" 같은 한국어 표현으로 부드럽게.
4. **용어 풀이** — 카디널리티(쿼리 결과 행 수), 베르누이(각 행을 동전 던지듯 뽑는 방식), Adaptive Sampling(표본을 늘려 가며 추정), 임베딩(의미 거리 보존 숫자 벡터) 첫 등장 시 풀이 유지.
5. **VBASE 1 만 배 이상** — "최대 1 만 배" 가 아니라 "최대 1 만 배 이상" 으로 유지.
6. **RQ1 분량 1/4** — 두 단락 정도가 적정. 더 늘리면 RQ2 의 비중이 흐려진다.
7. **RQ2 분리 동기 서술** — "쫄린 분포를 다루는 두 보완은 결이 다르다" 가 분리 동기의 핵심 문장.

8. **RQ3 탐색 톤** — "탐색 단계", "조사한 결과", "검토 중", "5월에 측정". 표로 후보를 줄세우지 말 것.
9. **진행 상황 주 단위** — "4월 14일에"가 아니라 "4월 둘째 주에".
10. **AI 흔적 줄임** — "본 연구는"의 반복 자제. 같은 어미 연속 자제. 평어체 일관.

7. 산출물 위치

파일	경로
보고서 (제출용 PDF)	submission/_drafts/속도는벡터_중간보고서.pdf
보고서 (작업본 docx)	submission/_drafts/속도는벡터_중간보고서.docx
보고서 (md 원본)	submission/_drafts/속도는벡터_중간보고서_20260428_120000.md
발표 자료 (제출용 PDF)	submission/_drafts/속도는벡터_중간발표.pdf
발표 자료 (작업본 pptx)	submission/_drafts/속도는벡터_중간발표.pptx
본 사용설명서	submission/_drafts/속도는벡터_프로젝트_사용설명서_20260428_120000.md
작업 백업	submission/_drafts/archive/

본 사용설명서는 4월 27일 20시 기준으로 작성되었다. 보고서·발표 자료가 더 수정되면 본 문서의 §2.1, §3, §6도 함께 갱신한다.