

속도는벡터 중간발표 예상 질문 + 답변 (v2 — 4/29 리허설용)

발표 일시: 2026-04-30 (목) 19:00 / 인종 A428

대상: 지도교수 박광현 / 지도연구원 임채림 / 청중 (캡스톤 동급생)

버전: v2 (1차 + 사실 보강 + 카테고리 H~J 신설 + 막혔을 때 fallback)

📖 사용 가이드

각 질문은 30초 답 (핵심)과 60초 답 (자세히)으로 구성됩니다. Q&A 평균 1답변 30~60초가 적절합니다.

- 🎯 30초 답: 첫 응답. 청중이 흐름 잡기 위해 짧게.
- 📖 60초 답: 청중이 더 묻거나, 시간 여유 있을 때 자세히.
- 🆘 fallback: 답이 막혔을 때 시간 버는 멘트 + 우회 멘트.

답변 일반 원칙: 1. 첫 문장은 짧게 — 결론 → 부연 순. 2. 숫자는 구체적으로 — "약간"이 아닌 "+1.64%, CI [+1.11, +2.18]". 3. 모르면 솔직히 — "이 부분은 W6에 추가 실험할 예정입니다" 로 약점을 향후 계획으로 연결. 4. 시간 — 1답변 30~60초. 길어지면 "더 자세한 건 보고서 §4.2에 정리되어 있습니다" 로 우회.

A. 연구 범위·동기

A1. 왜 새로운 알고리즘이 아니라 비교·검증인가요?

🎯 30초 답:

캡스톤 범위에서 의미 있는 결과를 위해 **체계적 비교**를 우선했습니다. Exqutor의 Adaptive Sampling은 uniform sample 가정에 의존하므로, 분포 인지 보정의 **정량 효과**를 외부에서 측정하는 것 자체가 가치 있는 결과입니다.

📖 60초 답:

... (위 30초 답 + 다음) RQ3에서는 분포를 모를 때 KM20 효과를 회수하는 **7가지 방법**을 동일 조건에서 비교하는데, 이는 후속 연구의 design space 정의로 이어집니다. 새 알고리즘 발명은 단일 방법을 깊이 파지만, 본 연구는 **paradigm 단위**로 폭을 확보합니다.

 **fallback:** "이는 캡스톤 형식의 제약과 후속 연구 가능성 사이의 trade-off였고, 박광현 지도교수님과 임채림 지도연구원님의 조언으로 비교 우선으로 정했습니다."

A2. RQ3 7-way는 너무 많지 않나요? 산만하지 않나요?

 30초 답:

7개를 모두 깊게 가는 것이 아니라, **W5 first-pass로 후보를 줄이고 W7~W8에 선별 1~2개를 심화하는 funnel 구조**입니다.

 60초 답:

... 3 paradigm (Offline / Online / Weight-based)을 빠짐없이 다루기 위해 paradigm당 2~3개씩 선정했고, W5 offline pilot에서 **Recovery Rate 기준 통과한 것만** W6 본 측정으로 진행합니다. 즉 7개 모두 5-seed × 3 데이터셋을 도는 것이 아니라, paradigm 1개당 2~3개 후보 중 1개를 선별합니다.

 **fallback:** "선별 기준은 W5에 정량화할 예정이고, 이번 발표 단계에서는 design space를 전부 보여드리는 데 의미를 두었습니다."

A3. 왜 인덱스 없는 경로(AS)에 한정했나요? 인덱스 있는 ECQO도 같이 봐야 하지 않나요?

 30초 답:

인덱스가 있으면 ECQO가 1~2 밀리초 안에 **정확한 카디널리티**를 산출하므로 sampling 자체가 불필요합니다. 본 연구의 표적은 sampling이 실제로 작동해야 하는 — 인덱스 없는 경로입니다.

 60초 답:

... 또한 운영 환경에서는 새 데이터 인입 후 인덱스 빌드 전 윈도우, 또는 인덱스 없는 워크로드(예: ETL 중간 결과)에서 sampling이 빈번하게 호출됩니다. 즉 ECQO가 다루지 못하는 영역이 적지 않으며, 본 연구는 그 영역을 다룹니다.

 **fallback:** "ECQO 영역 연구는 별도 기여가 가능한 영역으로, 본 캡스톤 범위 외에서 다룰 가치가 있습니다."

A4. 단일 테이블 vector range query — 너무 좁은 시나리오 아닌가요?

 30초 답:

단일 테이블이 base case이고, 여기서 sampling이 작동해야 multi-table join에도 일관되게 적용됩니다. **Exquor 원논문은 multi-table만 다루었고**, 단일 테이블에서는 hook이 작동하지 않는 설계 제약 5종을 RQ1에서 발견했습니다.

 60초 답:

... 따라서 본 연구는 multi-table에 가기 전 **단일 테이블의 구조적 한계 자체를 확인하고 보정**하는 단계입니다. multi-table join은 sampling layer가 join order를 결정하는 추가 변수가 들어가서 효과를 분리하기 어렵습니다.

 **fallback:** "단일 테이블 결과가 다중 테이블 join에서도 유지되는지는 별도 검증이 필요한 흥미로운 후속 연구입니다."

B. 방법론·통계

B1. 5-seed 반복은 충분한가요? 검정력이 약하지 않나요?

 30초 답:

중간 단계에서 5-seed 95% CI로 유의성을 확인했고, 최종 단계에서 10-seed × 500 query + BH-FDR + TOST + Cohen's d로 출판급 검정력을 확보할 계획입니다. W6 보강 일정에 포함되어 있습니다.

 60초 답:

... 5-seed에서도 $t(4, 0.975) = 2.776$ 의 보수적 critical value로 CI를 산출했고, DEEP 1M $s=0.500$ 의 CI $[+1.11, +2.18]$ 은 좁고 양수 확정으로 신뢰할 만합니다. 다만 $s=0.010$ 같은 low-cardinality 영역은 noise 대비 신호가 약해 표본 크기 확대가 효과적입니다.

 **fallback:** "검정력 분석은 W6 보강 실험에서 정량화할 예정이고, 현 단계 결론은 5-seed CI의 보수성을 인정한 위에서 도출되었습니다."

B2. Q-error 외에 다른 지표는 안 보나요? 실행 시간은?

 30초 답:

옵티마이저 입장에서 카디널리티 정확도 = Q-error가 1차 지표입니다. 보조로 median, mean, p95, query 단위 paired ranking을 봅니다. end-to-end 실행 시간은 W8 민감도 분석에서 일부 selectivity 구간에서 측정 예정입니다.

 60초 답:

... Q-error가 1차인 이유는 plan choice가 cardinality 추정값에 직접 binding되기 때문입니다. 실행 시간 차이는 plan choice 변화의 결과라 sampling 효과를 직접 측정하지 못합니다. 다만 ground truth로서 실행 시간 비교를 일부 selectivity에서 추가하면 결론의 실용성을 보강할 수 있습니다.

 **fallback:** "실행 시간 측정은 환경 변동성이 커서 별도 통계 설계가 필요한 영역으로, 최종 보고서에서 정량화하겠습니다."

B3. 왜 paired Wilcoxon test인가요? t-test나 다른 검정은?

 30초 답:

Q-error는 정규분포가 아닙니다 — heavy-tail. 그래서 mean을 비교하는 t-test보다 분포 가정 없이 rank로 비교하는 paired Wilcoxon이 적절합니다. 또한 같은 100개 query에 대해 두 방법을 적용하므로 paired 설계가 자연스럽습니다.

 60초 답:

... 추가로 Wilcoxon은 outlier에 robust해서 low-selectivity의 large Q-error 같은 극단값이 결과를 왜곡하지 않습니다. 5-seed × 100 query 데이터에 paired Wilcoxon + bonferroni 같은 다중검정 보정도 W6에서 BH-FDR로 추가 적용 예정입니다.

 **fallback:** "분포 가정과 outlier robustness 두 측면에서 Wilcoxon이 안전한 선택이었습니다."

B4. p-value 표기를 0.0009와 <0.001 두 가지로 섞은 이유는?

 30초 답:

$\alpha=0.05$ 구간만 유효 자릿수 보존을 위해 0.0009로 정확히 적었고, 그 외에는 검정력이 충분해 <0.001로 일괄 보고했습니다. 최종 단계에서 BH-FDR 다중검정 보정을 적용할 예정입니다.

 **fallback:** "이는 표기 일관성보다 정보 가독성을 우선한 선택이었으며, 최종 보고서에서 통일하겠습니다."

B5. 95% CI 산출은 t-distribution과 percentile bootstrap 어느 쪽인가요?

 30초 답:

본 보고서는 **t-distribution 기반** — $\text{mean} \pm t(4, 0.975) \times \text{std} / \sqrt{5}$. raw json에는 percentile bootstrap CI도 함께 산출되어 있고, 두 방식 모두 valid하나 결과 해석은 t-기반으로 통일했습니다.

 60초 답:

... t-기반은 5-seed 같은 작은 표본에서 보수적이라 유의성 판단이 안전합니다. percentile bootstrap은 분포 가정이 약해 noise 영역에서 더 robust하지만, 양자화 현상이 있는 영역(예: SIFT $s=0.010$)에서는 둘 다 한계가 있습니다.

 **fallback:** "최종 보고서에서 두 방식을 함께 보고할 예정입니다."

C. KM20 vs BERN 핵심 결과

C1. KM20의 +1.64%는 실용적으로 의미 있는 개선인가요?

 30초 답:

median Q-error가 1을 향해 더 가까워지고 CI 하한이 +1.11로 양수 확정입니다. 옵티마이저는 임계값 근방에서 plan flip을 일으키므로 **방향과 안정성**이 절대값보다 중요합니다.

 60초 답:

... 또한 SIFT에서는 +3.07%, 가장 skewed한 1% selectivity에서는 +8.93%까지 — 데이터가 더 skewed 될수록 효과가 비례적으로 커집니다. 즉 +1.64%는 lower bound이고, 실제 운영 워크로드의 skewness에 따라 효과는 더 클 수 있습니다.

 **fallback:** "+1.64% 자체보다는 양수 CI 확정과 다른 데이터셋에서의 일관된 방향이 핵심 메시지입니다."

C2. KM20을 운영 환경에 적용하려면 클러스터링 비용이 부담스럽지 않나요?

 30초 답:

KM20은 **MiniBatch k-means** — 1M 데이터에 약 1~2분, 일·주 단위 갱신 주기에는 충분히 감당됩니다. 분포를 사전에 모르거나 갱신 주기가 짧은 환경 — 이것이 정확히 **RQ3가 해결하려는 시나리오**입니다.

 60초 답:

... 추가로 KM20은 한 번 클러스터링하면 그 결과를 메타데이터로 저장해두고 모든 쿼리가 공유합니다. 즉 amortized 비용으로 보면 쿼리당 거의 0에 수렴합니다. 운영 비용 모델은 W8에서 sample_size sensitivity와 함께 정량화 예정입니다.

 **fallback:** "비용 vs 정확도 trade-off는 W8에서 정량화하여 최종 보고서에 반영하겠습니다."

C3. 왜 K=20인가요? 다른 K는 비교 안 했나요?

 30초 답:

초기 grid search에서 K=10·20·30·50을 비교했고 K=20이 안정적 효과를 보였습니다. W8에서 K sweep = 10/20/30/50을 5-seed로 정량화할 예정입니다.

 60초 답:

... K가 너무 작으면(<10) Two-Level 분해의 L2 효과가 약해지고, 너무 크면(>50) 클러스터당 표본이 부족해져 추정 분산이 커집니다. K=20은 selectivity 0.010~0.500 전 구간에서 양수 효과를 보인 sweet spot이지만, 데이터 크기와 차원에 따라 최적 K가 변할 수 있어 sensitivity 분석이 필요합니다.

 **fallback:** "K 선택은 sample_size, 데이터 규모, skewness가 모두 영향을 주는 다변수 문제로, W8에서 정량 검증할 예정입니다."

C4. RANDOM20이 1% selectivity에서 -10.67%로 KM20과 19.6%p 차이 나는 이유는?

 30초 답:

좁은 selectivity 쿼리는 결과 행이 **소수 클러스터에 집중**됩니다. RANDOM20은 무작위 분할이라 해당 클러스터를 정확히 잡지 못하고, KM20은 vector space 구조를 반영해서 정확히 잡습니다. **이 격차가 곧 spatial-aware의 가치**입니다.

 60초 답:

... Two-Level 분해로 보면 $s=0.010$ 에서 $L1 = -10.67\%$ (RANDOM20의 안정화 효과), $L2 = +19.60\%$ (KM20의 spatial-aware 효과)로 분리됩니다. 즉 좁은 쿼리에서는 안정화 효과는 오히려 마이너스(분할이 noise를 키움)지만, spatial-aware 효과가 그것을 압도해서 +8.93%의 net 개선을 만듭니다.

 **fallback:** "이 결과가 본 연구의 가장 강력한 정량적 evidence입니다 — 보고서 §4.2.3 표 3에 자세히 정리되어 있습니다."

D. 용어·정의

D1. "계층적 표본"과 "stratified sampling"은 같은 의미인가요?

 30초 답:

네, 동일 개념의 한국어/영어 표기입니다. 보고서 본문은 한국어 기조라 "계층적", 표·캡션·발표는 학술 용어 "stratified"로 — 일부 혼용은 최종보고서에서 통일할 예정입니다.

 fallback: "캡스톤 보고서가 한국어 기반이라 발생한 trade-off로, 가독성을 우선한 결정이었습니다."

D2. Recovery Rate의 정확한 정의는?

 30초 답:

$\text{Recovery Rate} = (\text{방법X} - \text{RANDOM20}) / (\text{KM20} - \text{RANDOM20})$. RANDOM20을 0%, KM20을 100%로 두고, 분포-비인지 방법이 KM20 효과를 얼마나 회수하는지를 비율로 표현합니다.

 60초 답:

... 100%면 KM20 효과를 완전 회수, 0%면 무작위 분할 수준, 그 사이는 spatial-aware 효과의 부분 회수. 단 분모인 (KM20 - RANDOM20)이 0에 가까운 selectivity (예: DEEP 1M $s=0.500$)에서는 비율이 불안정해서 — 이런 영역은 분모 붕괴 규칙으로 별도 처리합니다.

 fallback: "분모 붕괴 케이스 처리는 W6 본 측정에서 명시화하고, 최종 보고서에 분모 임계값 기준을 정량화하겠습니다."

D3. "block-level bias"는 무엇이고 왜 BERN이 제거하나요?

 30초 답:

PostgreSQL 기본 표본은 **page (block) 단위** — 한 block 안의 행들이 함께 추출되거나 함께 제외됩니다. 이로 행 간 독립성이 깨져서 추정 분산이 커집니다. **BERN은 행 단위 Bernoulli sampling**으로 행 간 독립을 회복합니다.

 **60초 답:**

... 정량적으로 보면 SYSTEM은 page당 평균 100~200 행을 함께 추출하므로 effective sample size가 표본 수의 1/100 정도로 감소합니다. 반면 BERN은 행마다 독립 Bernoulli trial이라 effective = nominal sample size. 따라서 같은 sample_size에서 추정 분산이 BERN이 훨씬 작습니다.

 **fallback:** "이는 데이터베이스 sampling 이론의 표준 결과로, 본 연구가 처음 발견한 것은 아니나 vector range query에 적용된 사례는 본 연구가 첫 정량 보고입니다."

D4. Two-Level 분해가 정확히 무엇인가요?

 **30초 답:**

KM20 효과를 두 경로로 분리합니다. **L1 (안정화):** RANDOM20처럼 무작위로 나뉘도 얻는 표본 크기 안정화. **L2 (공간 인식):** KM20이 RANDOM20보다 추가로 얻는, 벡터 공간 구조 반영의 효과. **L1 + L2 = KM20 total.**

 **60초 답:**

... 정량적으로 DEEP 1M $s=0.010$ 에서 $L1 = -10.67\%$ (분할이 noise 증가), $L2 = +19.60\%$ (KM20만의 추가). 합쳐서 $+8.93\%$. 즉 좁은 selectivity일수록 L2가 dominant. 50% selectivity에서는 $L2 \approx 0$ 이고 L1만 효과를 만듭니다. 이 분해가 "**왜 KM20이 효과적인가**"의 직접적 evidence입니다.

 **fallback:** "보고서 §4.2.3 그림 5에 시각적으로 정리되어 있습니다."

E. 실험 검증

E1. DEEP과 SIFT 외 다른 데이터셋은? wiki는?

 30초 답:

DEEP은 ImageNet feature, SIFT는 image local descriptor — 차원·분포 특성이 다른 두 데이터셋입니다. wiki 768d 보충 실험은 W6 일정에 포함 — 텍스트 임베딩으로 일반화 검증 예정입니다.

 60초 답:

... DEEP(96d)/SIFT(128d)는 vision domain이고, wiki(768d)는 NLP domain. 차원 증가에 따른 효과의 일반화도 검증하고자 합니다. 추가로 W7 이후에 GLOVE 같은 word embedding도 후보로 검토 중입니다.

 **fallback:** "데이터셋 다변화는 외적 타당성의 핵심 요소로 W6~W7에서 단계적으로 보강하겠습니다."

E2. $p < 0.001$ 셀이 많은데 p-hacking 우려는?

 30초 답:

가설 검정 전에 selectivity 6 구간 × 데이터셋 3개를 사전에 결정하고 일괄 측정했습니다. 사후에 selectivity 구간을 골라낸 것이 아니므로 multiple comparison 보정 (BH-FDR)을 적용해도 결론은 유지됩니다.

 60초 답:

... pre-registration 형식으로 selectivity grid와 데이터셋을 사전 정의했고, raw json은 모두 archive에 보관됩니다. W6에서 BH-FDR과 TOST equivalence test를 추가하여 다중검정 보정 후에도 +1.64% 등 핵심 결과가 유의함을 정량화할 예정입니다.

 **fallback:** "BH-FDR은 W6 일정에 명시되어 있으며 최종 보고서에는 보정된 p-value 표를 함께 제시하겠습니다."

E3. Q-error gradient가 단조롭지 않은데 ($s=0.10 +4.19\% \rightarrow s=0.05 +1.85\%$) 왜?

 30초 답:

두 구간이 **다른 시점에 측정**되어 발생한 방법론적 차이가 일부 영향을 미쳤을 가능성이 있습니다. $s=0.05$ 는 Phase 6 SQL 이진 탐색 기반, $s=0.10/0.30$ 은 Phase 7 numpy 기반이라 D_{target} 계산의 부동소수점 정밀도가 미세하게 달랐습니다.

 60초 답:

... 다만 **gradient의 전체 추세 ($50\% \rightarrow 1\%$)는 견고**하고, 인접 구간(특히 $10\% \rightarrow 5\%$)의 정확한 차이 해석에만 주의가 필요합니다. SIFT mid-selectivity 보충 실험이 W6에 완료되면 교차 검증으로 이 비단조성이 측정 artifact인지 본질인지 판별 가능합니다.

 **fallback:** "이는 본 연구의 한계로 솔직히 보고하고, W6 보충 실험으로 해소할 예정입니다."

E4. DEEP 8M $s=0.010$ 에서 KM20이 -0.71% 로 음수인데 어떻게 해석 하나요?

 30초 답:

8M에서 $\text{sample_size}=385$ 는 $s \geq 0.050$ 기준으로 설계되어, $s=0.010$ ($\text{true_card} \sim 8\text{만}$)에서는 표본이 절대적으로 부족합니다. CI $[-21.13, +19.70]$ 으로 0을 포함 — noise 지배 영역으로 해석됩니다.

 60초 답:

... 동일한 sample_size에서도 selectivity가 50배 떨어지면 effective sample efficiency가 1/50로 줄어 Q-error가 6~8배까지 급증합니다. 이는 모든 sampling 방식의 공통 한계이지 KM20의 결함은 아닙니다. W8에서 sample_size sensitivity 실험으로 이 selectivity-sample_size 관계를 정량화할 예정입니다.

 **fallback:** "이런 영역은 sampling 자체의 한계로, RQ3에서 online 방식 (Distance-Shell)으로 대응 가능한지를 검증할 예정입니다."

E5. SIFT $s=0.010$ 에서 KM20이 -0.53%인데 양자화 현상이라는 건 무슨 뜻인가요?

 30초 답:

SIFT 1.5M의 $s=0.010$ (true_card ~1.5만)에서는 hook estimation 함수가 5-seed 모두 동일한 1.4435를 반환합니다. 즉 seed 간 분산이 0 — 추정값이 양자화(quantize)되어 있습니다.

 60초 답:

... 이는 sample_size가 너무 작아 hook의 모멘텀이 첫 추정에서 수렴해버린 케이스입니다. 결과적으로 KM20과 BERN 둘 다 같은 값을 반환해서 차이가 없거나 미세 음수. 단, **RANDOM20의 -12.11% 악화는 방어**해서 KM20이 worst case에서도 안전성을 제공한다는 의미는 있습니다.

 **fallback:** "양자화 영역의 정확한 원인은 W6 sample_size 변경 실험으로 hook 모멘텀의 작동 조건을 검증하면 명확해집니다."

F. 향후 계획·일정

F1. 5/27까지 RQ3를 마칠 수 있나요? 일정이 빠듯하지 않나요?

 30초 답:

W5 offline pilot에서 빠른 first-pass로 후보를 줄이고, W6에 선별 1~2개를 5-seed × 3 데이터셋으로 본 측정 — Recovery Rate 산출. W7 online-weight-based, W8 민감도 + 발표 준비. 4주 funnel 구조로 5/27 마감에 맞도록 설계되어 있습니다.

 60초 답:

... 만약 W6에서 후보 선별이 어려운 경우, paradigm당 1개로 좁히고 Recovery Rate가 의미 있는 경우만 W7로 넘기는 fallback이 있습니다. 일정 risk는 W8 후반부로 buffer를 확보해두었습니다.

 fallback: "일정 risk 관리는 W6 mid-point에 박광현 지도교수님과 점검할 계획입니다."

F2. 최종 산출물은 정확히 무엇인가요?

 30초 답:

최종발표 PDF (5/27~29), 전시회 포스터 (6/5), 최종보고서 PDF (6/11). 추가로 실험 재현 가이드 — Exqutor branch + 데이터셋 + 스크립트 — 다른 연구자가 재현 가능하도록 정리할 예정입니다.

 fallback: "재현 가능성은 본 연구의 가치를 좌우하는 요소로 W10에 반드시 포함하겠습니다."

F3. 최종 보고서가 중간 보고서와 어떻게 다를 예정인가요?

 30초 답:

세 가지 추가가 핵심입니다. (1) RQ3 7-way 본 측정 결과, (2) K sweep / sample_size sensitivity 등 민감도 분석, (3) 10-seed × 500 query + BH-FDR + TOST로 출판급 검정력. 또한 wiki 768d 텍스트 임베딩으로 일반화 검증을 추가합니다.

 **fallback:** "중간 보고서가 RQ1/RQ2 closure라면, 최종은 RQ3 + 민감도 + 일반화로 evidence body를 두 배로 키우는 단계입니다."

G. 한계·일반화

G1. 본 연구의 가장 큰 한계는?

 30초 답:

세 가지를 솔직히 말씀드립니다. (1) 인덱스 없는 sampling 경로에 한정 — ECQO 영역 정확도 향상은 다루지 않습니다. (2) 단일 테이블 vector range query 범위 — multi-table join은 향후 연구. (3) K=20 고정 — 다른 K 일반화는 W8에서 추가 검증.

 **fallback:** "한계 인정은 후속 연구의 출발점이 되며, 최종 보고서에 명시할 예정입니다."

G2. 다른 vector DB (Milvus, Weaviate, Pinecone)에서도 같은 효과가 있을까요?

 30초 답:

본 연구는 PostgreSQL + pgvector + Exqutor branch에서 측정했습니다. 다른 시스템은 표본 추출 방식이 다를 수 있어 (예: Milvus segment 단위) 직접 일반화는 어렵습니다. 다만 block bias와 spatial skew의 두 보정 측은 시스템 독립적인 통찰입니다.

 60초 답:

... 즉 다른 시스템에서도 동일한 분석 패러다임 — block bias 측정 + spatial skew 측정 — 을 적용할 수 있고, 효과의 정량은 시스템마다 다를 수 있지만 방향성은 보존될 가능성이 큼니다. 이는 본 연구가 제공하는 transferable methodology입니다.

 **fallback:** "Cross-system 비교는 별도 연구 규모의 작업이라 본 캡스톤 범위 외입니다."

G3. KM20의 효과가 SIFT에서 두 배라면, 본 결과가 SIFT에 over-fit된 건 아닌가요?

 30초 답:

반대입니다. SIFT는 DEEP보다 더 skewed (CV 0.394 vs 0.234)한 데이터로, KM20 효과가 큰 것이 자연스러운 결과입니다. 즉 데이터 skewness가 KM20 효과를 예측한다는 일반화 가능한 패턴이 발견된 것입니다.

 60초 답:

... DEEP 1M (skew 적음, +1.64%) → DEEP 8M (동일 skew, +1.76% scale invariant) → SIFT 1.5M (더 skewed, +3.07%) — 이 monotonic 관계가 over-fit의 반대 증거입니다. wiki 768d 같은 다른 domain에서도 같은 monotonic 관계가 유지된다면 더 강한 일반화가 가능합니다.

 **fallback:** "Over-fit 우려에 대한 검증은 데이터셋 다변화 (W6 wiki) + K sweep (W8)으로 추가 보강하겠습니다."

H. 디버깅·재현 가능성 (NEW)

H1. vector.c에서 발견한 5종 설계 제약은 구체적으로 무엇인가요?

 30초 답:

단일 테이블 vector range query에서 (1) sampling hook이 활성화 안 되는 경로, (2) Adaptive Sampling branch가 비활성화된 케이스, (3) Forced hook 적용 시 Sample Scan 부작용, (4) sample_size update 로직의 offset 버그, (5) hook node type 미스매칭 다섯 가지입니다.

 60초 답:

... 이는 Exqutor 원논문이 multi-table 전제로 설계되어, single-table vector range query에는 적용되지 않는 코드 경로가 다수 있어서입니다. 본 연구는 이 경로를 단일 테이블에 적용 가능하도록 +228줄의 직접 수정을 했고, 이 수정 패치가 본 연구의 실용적 산출물 중 하나입니다.

 **fallback:** "이 패치는 최종 보고서의 재현 가이드와 함께 공개할 예정입니다."

H2. Phase 6와 Phase 7의 차이는 정확히 무엇이고, 왜 영향을 줬나요?

 30초 답:

Phase 6은 **D_target (거리 임계값)** 계산을 SQL 이진 탐색으로, Phase 7은 **numpy 기반**으로 했습니다. 두 방식은 부동소수점 정밀도가 다르고, 실제 selectivity 달성 정도에 미세한 차이가 생깁니다.

 60초 답:

... 구체적으로 SQL 이진 탐색은 PostgreSQL 내부 float8 precision을 사용하고, numpy는 IEEE 754 double precision. selectivity 0.050 같은 좁은 영역에서는 이 미세 차이가 측정값의 $\pm 0.5\%$ 이상 흔들 수 있습니다. 이것이 $s=0.05 \rightarrow s=0.10$ gradient 비단조성의 한 원인입니다.

 **fallback:** "Phase 6 결과를 Phase 7 방식으로 재측정하는 것이 정합성 보강의 가장 직접적인 방법이며, W6에 포함되어 있습니다."

H3. 본 연구는 재현 가능한가요? 다른 사람이 같은 결과를 얻을 수 있나요?

 30초 답:

네, W10에 실험 재현 가이드를 별도 산출물로 정리할 예정입니다. Exqutor branch (수정 patch +228줄), 데이터셋 다운로드 스크립트, 실험 실행 스크립트, raw json (5-seed × 100 query × 6 selectivity × 3 데이터셋) 모두 공개합니다.

 60초 답:

... 환경: PostgreSQL 16 + pgvector 0.5 + Exqutor branch (특정 commit). 서버 사양: 165.132.140.240 (HDD0). seed: 42, 43, 44, 45, 46. 모든 step이 명시되어 있고, 다른 연구자가 다른 서버에서 같은 패턴 (skewness ↑ → KM20 효과 ↑)을 재현할 수 있도록 합니다.

 **fallback:** "재현 가능성은 본 연구의 학술적 신뢰도 핵심이며, 최종 산출물에 우선순위로 포함됩니다."

I. 적용 범위·산업 응용 (NEW)

I1. 이 연구가 실제 운영 환경에서 어떤 가치를 만들 수 있나요?

 30초 답:

세 가지 영역에서 가치가 있습니다. (1) 벡터 검색 서비스 (RAG, semantic search)의 옵티마이저 정확도 향상, (2) 데이터 인입 직후 인덱스 빌드 전 윈도우의 query 성능 개선, (3) 인덱스 없는 ETL 중간 결과 sampling 정확도. KM20 클러스터링 비용은 amortized로 쿼리당 무시 가능합니다.

 **fallback:** "구체적인 산업 응용 사례는 본 연구의 학술 contribution을 넘어서는 영역이지만, 이론적 가치가 명확하다면 자연스럽게 산업으로 확장 가능합니다."

12. RAG (Retrieval Augmented Generation)에 적용할 수 있을까요?

 30초 답:

RAG의 retrieval 단계는 정확히 본 연구가 다루는 vector range query입니다. RAG 응답 품질은 retrieved chunks의 적합성에 의존하고, 그 적합성은 옵티마이저의 plan choice — 즉 카디널리티 추정의 정확도에 좌우됩니다. KM20을 RAG 시스템에 적용하면 retrieval 효율 향상이 가능합니다.

 60초 답:

... 다만 RAG에서는 query latency가 추가 제약이 되어, KM20의 클러스터링이 query에 추가 cost를 유발하면 안 됩니다. 본 연구의 KM20은 **offline 클러스터링**이라 query latency에는 영향이 없습니다. 즉 RAG 적합성이 높습니다. 다만 chunk 갱신 주기가 짧은 경우 RQ3의 online 방법이 더 적합할 수 있습니다.

 **fallback:** "RAG 적용은 본 캡스톤 범위 외이지만, 매우 promising한 application으로 후속 연구에서 검증하고 싶습니다."

J. 메타·캡스톤 형식 (NEW)

J1. 4명 팀원의 역할 분담은 어떻게 했나요?

 30초 답:

박세은 팀장이 일정·산출물·자문을 주도하고, 강재현이 본 발표·실험 분석을, 조현빈이 보고서·실험 코드·실험 인프라를, 이동욱이 시스템 환경·데이터셋 인입을 담당했습니다. 모든 결정은 4인 합의로 진행했습니다.

 **fallback:** "역할 분담의 자세한 history는 보고서 표 6에 정리되어 있습니다."

J2. 캡스톤 형식의 한계 안에서, 본 연구의 학술적 contribution은?

 30초 답:

세 가지로 정리합니다. (1) vector range query에서 block bias와 spatial skew의 분리 측정 — Two-Level 분해 방법론. (2) KM20 stratified sampling의 정량 효과 + skewness와의 monotonic 관계. (3) RQ3 design space — 분포 비인지 환경에서의 7-way comparison framework.

 60초 답:

... 이 세 contribution은 캡스톤 형식이라도 후속 연구의 명확한 출발점이 됩니다. 특히 (1) Two-Level 분해 방법론은 다른 sampling 연구에 transferable하고, (3) RQ3 framework는 distribution-agnostic vector cardinality estimation의 design space를 정의합니다.

 **fallback:** "학술적 contribution의 정확한 평가는 최종 보고서와 별도 연구 publication 논의에서 이루어질 것입니다."

까다로운 질문 (비판적)

K1. "stratified를 KM20 한 가지로 한정했는데 다른 stratification은?"

 30초 답:

KM20은 vector-space 기하적 구조를 직접 반영하는 가장 자연스러운 stratification으로 설정했습니다. 다른 stratification (Random Projection, Hash partition LSH)은 RQ3에서 Recovery Rate 비교로 다룹니다.

 60초 답:

... 즉 본 발표 단계에서는 'stratification 자체의 효과'를 검증하기 위해 가장 명확한 KM20을 선택했고, RQ3에서 더 가벼운 분포 비인지 stratification들과 비교합니다. 이 순서가 design space를 점진적으로 채우는 자연스러운 흐름입니다.

 **fallback:** "다른 stratification 방식의 정량 비교는 RQ3 본 측정에서 답변드릴 수 있습니다."

K2. "RANDOM20이 더 나쁘다는 걸로 KM20의 효과를 주장하는데, 왜 RANDOM20이 baseline인가요?"

 30초 답:

RANDOM20은 '표본을 여러 그룹으로 나누는 안정화 효과'만 측정하는 ablation입니다. KM20과 RANDOM20의 차이가 곧 k-means가 벡터 공간 구조를 반영해서 추가로 얻는 효과 — 이를 분리해서 측정한 것이 핵심 기여입니다.

 60초 답:

... 즉 baseline은 BERN이고, RANDOM20은 KM20의 성분을 분해하기 위한 ablation입니다. Two-Level 분해는 $KM20 = L1 \text{ (RANDOM20과 같은 안정화 효과)} + L2 \text{ (KM20만의 spatial-aware 추가)}$. RANDOM20을 baseline이라 부르는 게 아니라, 분해의 reference point로 사용합니다.

 **fallback:** "이 분해 framework는 본 연구의 핵심 방법론으로 보고서 §4.2.3에 자세히 설명되어 있습니다."

K3. "DEEP 1M에서 +1.64%인데 절대값이 너무 작지 않나요?"

 30초 답:

median Q-error 자체가 이미 1.052로 1에 가까운 영역입니다 — 추가 1.64%는 작아 보이지만 1로의 수렴 효과로 봐야 합니다. 실제로 절대 분산이 큰 SIFT (CV 더 큼)에서는 +3.07%로 skewness에 비례해 효과가 커집니다.

 60초 답:

... 또한 selectivity 0.010 같은 좁은 쿼리에서는 +8.93%까지 올라갑니다. 즉 +1.64%는 **most-favorable case의 lower bound**가 아니라 **most-stable region의 안정적 개선**으로 해석해야 합니다. 실제 운영 워크로드의 skewness와 selectivity 분포에 따라 효과는 더 클 수 있습니다.

 **fallback:** "절대값보다 방향과 안정성이 중요하다는 건 옵티마이저 plan flip을 다루는 cardinality estimation 연구의 표준 시각입니다."

호의적 질문 (응용)

L1. 이 연구를 자신의 회사·연구실에 적용한다면 어디서부터?

 30초 답:

두 가지부터 시작하시면 됩니다. (1) 워크로드의 skewness 정량 측정 — k-means 20 클러스터로 나눠 CV 산출. (2) TABLESAMPLE SYSTEM을 BERNOULLI로 교체 — 단일 줄 변경으로 +9.6% 개선 가능. KM20 stratified는 그 다음 단계입니다.

 **fallback:** "이 두 단계는 본 연구의 BERN 결과만으로도 즉시 시도해보실 수 있습니다."

L2. RQ3 결과가 어떻게 나오면 가장 흥미로울까요?

 30초 답:

가장 흥미로운 시나리오는 — **Online query-adaptive 방법 (Distance-Shell)**이 **Recovery Rate 80% 이상**을 달성하는 경우입니다. 이는 분포를 사전에 모르는 환경에서도 KM20에 가까운 효과를 얻을 수 있다는 의미로, 산업 응용 가능성을 크게 넓힙니다.

 **fallback:** "RQ3 결과는 W6 본 측정 후 명확해질 텐데, 결과의 함의에 대해서도 함께 정리하겠습니다."

답변 시 일반 원칙

시간 관리

답변 길이	사용 케이스
15~30s 짧은 답	간단 명료한 질문, 시간 부족
30~60s 표준 답	대부분의 질문
60~90s 긴 답	깊이 있는 답변 요청, 시간 여유
90s+	보통 길어지면 자르고 "더 자세한 건 보고서에" 우회

답변 구조 (4단계)

1. **수용 (1초):** "예", "좋은 질문입니다", 끄덕임.
2. **결론 (5~10초):** 답변의 핵심 1문장.
3. **부연 (15~30초):** 정량 데이터 + 이유.
4. **연결 (5초):** "더 자세한 건 ..." 또는 "RQ3에서 ..." 같은 후속 연결.

막혔을 때 1초 reaction (시간 벌기)

- "네, 좋은 지적입니다."
- "그 부분은 두 가지 측면에서 답변드릴 수 있는데..."

- "정확한 수치는 잠시만 — 이 부분의 통계는..."
- "발표에서 시간상 줄였는데, 보고서 §4.2에는..."

절대 하지 말 것

- ❌ "잘 모르겠습니다" (단독 사용 금지). 항상 "이 부분은 W6/W8에서 추가 실험할 예정입니다" 식으로 향후 계획 연결.
- ❌ 머뭇거림 (3초 이상 침묵). 막히면 reaction 멘트로 시간 벌기.
- ❌ 청중 외면. 답변 중에도 시선 청중 70%.
- ❌ 숫자 추측. 헛갈리면 "정확한 통계는 보고서 §4.2.2에" 우회.

팀원별 답변 분담

영역	1차 응답	2차 보강	비고
본 결과·통계 (RQ2-1, RQ2-2)	강재현	조현빈	강재현이 발표자라 자연스럽게
데이터셋·외적 타당성 (DEEP/SIFT)	조현빈	이동욱	실험 인프라 담당
RQ3 설계·Recovery Rate	박세은	강재현	일정 + 산출물 담당
시스템 환경 (Exqutor / pgvector / vector.c)	이동욱	조현빈	시스템 담당
일정·산출물·팀 운영	박세은	—	팀장
통계·검정·재현 (Phase 6/7, BH-FDR)	강재현	조현빈	실험 분석 담당

Cross-check 룰: 한 사람이 답변 후 30초 안에 다른 팀원이 "보충하자면..." 으로 cross-validation. 청중에게는 팀 협업의 신호.

공통 답변 패턴 (어떤 질문에도 통하는)

패턴 1: 정량 → 정성 → 향후

"현재 측정값으로는 [정량]이고, 이는 [정성적 의미]를 보여줍니다. W6에 [추가 검증]을 통해 보강할 예정입니다."

패턴 2: 한계 인정 → 분리 → 향후

"이 부분은 본 연구의 한계 중 하나로 솔직히 말씀드립니다. [한계 명시]. 다만 [분리된 결론은 견고]하고, [향후 W6/W8에 보강]하겠습니다."

패턴 3: 분해 → 강조 → 연결

"이 결과는 [Two-Level / RANDOM20 / Recovery Rate] 분해로 보면 명확합니다. [핵심 분리]. 이것이 [본 연구의 contribution]이며, 보고서 §4.2.3에 자세히 정리되어 있습니다."

발표 직후 Q&A 체크리스트

- [] 첫 질문 받기 전 1초 침묵 + 미소.
- [] 답변 시작 전 1초 reaction (시간 벌기).
- [] 답변 30~60초 안에 마무리.
- [] 답변 후 "추가 질문 있으신가요?" 자연스럽게.
- [] 막힐 때 fallback 멘트 사용 (위 참조).
- [] 팀원 cross-check 자연스럽게 활용.
- [] 마지막 질문에 답변 후 "감사합니다" 마무리.