

한글의 자음과 모음 구조에 기반한 3-Channel LLM 워터마킹

3-Channel LLM Watermarking for Hangul Jamo Structure

TEAM룸

1. 연구 배경: 생성형 AI의 명과 암



대규모 언어 모델(LLM)이 생성한 AI 콘텐츠 급증

- 가짜 뉴스(Fake News) 대량 생산
- 지식 재산권 및 저작권 분쟁
- 교육/학술적 무결성 훼손

The New York Times

The Times Sues OpenAI and Microsoft Over A.I. Use of Copyrighted Work

Millions of articles from The New York Times were used to train chatbots that now compete with it, the lawsuit said.

Share full article



1.3K



A lawsuit by The New York Times could test the emerging legal contours of generative A.I. technologies. Sasha Maslov for The New York Times

| LLM 워터마킹이란?

특정 텍스트가 AI에 의해 생성되었는지를 판별하는 기술



워터마크 생성

모델이 토큰을 생성할 때
특정 단어 선택 확률을
미세하게 높임
(Kirchenbauer et al.)




탐지 수행

탐지기가 텍스트 내의
통계적 패턴을 분석하여
AI 생성 확률을 계산

2. 기존 기술의 한계: 영어 중심 설계

데이터셋과 토큰나이저

- 영어권 언어에 최적화된 토큰나이저
- 영어 데이터셋을 기준으로 설계



```
https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct/raw/main/tokenizer.json

{"GcontentType": 33203,
"Gfid": 33204,
"_alt": 33205,
"NSIndexPath": 33206,
"-pl": 33207,
"âĬk": 33208,
"Gantibiot": 33209,
"tables": 33210,
"acial": 33211,
"GRegistry": 33212,
"Golive": 33213,
"igers": 33214,
"Gsubscriber": 33215,
"_pres": 33216,
"GSyntax": 33217,
"Glovers": 33218,
".Byte": 33219,
"olders": 33220,
"_forward": 33221,
"always": 33222,
"Caption": 33223,
"Priv": 33224,
"GTampa": 33225,
"isateur": 33226,
"-labelledby": 33227,
"GToString": 33228,
"GîH~": 33229,
"Ginitiated": 33230,
```

2. 기존 기술의 한계: 영어 중심 설계

```
ksenv) mirulili@miluui-MacBookPro somefile % python ./test_decode_1.py
```

```
모델 : meta-llama/Meta-Llama-3.1-8B-Inst
```

```
입력 텍스트 : 안녕하세요, 반갑습니다.
```

테스트를 위해 코드에 입력한 문자열

```
-----  
토큰화 분석 결과 :
```

```
Hugging Face 토큰 문자열 (모델 내부 표현) : ['ìkĪ', 'ëhķíķlìH,ìlK', ',,', 'Ġë°l', 'ê°j', 'ìĬμëĭĬëĭμ', '.']
```

```
토큰 ID 리스트 : [101193, 124409, 11, 64857, 115072, 39331, 13]
```

```
사람이 읽을 수 있는 토큰 리스트 : ['안', '녕 하 세 요', ',,', '반', '갑', '습 니 다', '.']
```

실제 토큰

```
-----  
중 디코딩 결과 (전체 문장) : 안녕하세요, 반갑습니다.
```

각 토큰을 다시 문자열로 변환

| 2. 기존 기술의 한계: 영어 중심 설계

데이터셋과 토크나이저

- 영어권 언어에 최적화된 토크나이저
- 영어 데이터셋을 기준으로 설계

Tokenization Bias

English: “un” + “believ” + “able”

의미 단위 보존이 비교적 잘 됨

Korean: “안” + “녕하세요”

의미와 무관한 불규칙한 분절 발생

| 한계점: 교착어(Agglutinative) 특성 미반영

교착어란?

한국어처럼 어간에 조사나 어미가 붙어 문법적 기능을 수행하는 언어
예: '경복궁' + '을', '경복궁' + '에'

기존 토큰라이저의 문제점

조사의 미세한 차이를 인식하지 못함

임의 토큰 단위로 잘라 인식

- 예: '경복궁으' + '로'

결과

문맥적 유사성을 무시

워터마크 삽입 시 불규칙성을 초래

→ Perplexity(품질) 저하를 유발

| 한계점: Token ID 기반의 제약

“

온전한 음절 혹은 단어 형태의 **Token ID**만을 이용

→ **한글 음절의 구조적 특성**을 활용하지 못함

”

| 3. 한글의 구조적 특성

초성: 자음 (ㄱ, ㄴ, ㄷ...)

중성: 모음 (ㅏ, ㅑ, ㅓ...)

종성: 받침 자음 (ㄱ, ㄴ, ㅇ... 혹은 없음)

음소 단위의 결합 = 음절

초성(Initial), 중성(Medial), 종성(Final) 세 가지 음소가 모여 하나의 글자를 이루는 독창적인 구조

연구 가설

"음절보다 더 작은 단위인 **음소(자모)**를 활용한다면?"

기존
(Syllable)

1-Channel



제안
(Phoneme)

3-Channel

- 워터마크 정보 저장 용량(Capacity)을 획기적으로 증대
- 변형에 대한 내성(Robustness) 높임

| 4. 제안 방법: 3-Channel Jamo Watermarking



분해 (Decomposition)

토큰을 그대로 사용하지 않고,
마지막 음절을
초성, 중성, 종성으로
실시간 분해



독립 채널화

분해된 3개의 자모를
각각 독립적인 정보 채널로
간주하여 비트를 삽입



미세 패턴 삽입

- 더 작은 단위에 정보를 숨김
- 텍스트 품질 저하 최소화
 - 보안성 강화

| 왜 자음과 모음 단위인가?

정보 밀도 향상


하나의 토큰(음절)에서 1비트만 처리하는 방식 (X)

3비트(초/중/종)까지 처리 (O)

강건성 (Robustness)

단어가 삭제되거나 변형된 경우

- 분산되어 있는 남은 자모의 패턴 존재
- 워터마크 보존 확률 증가



| 5. 핵심 메커니즘

- LogitsProcessor 단계 실시간 개입
- 유니코드 산술분해로 음절 분리

Target = 마지막 음절

예:

볶음밥

- 오버헤드 감소
- 효율성 확보

| 분해 공식 (The Formula)

- 유니코드 상에서 한글 '가'(0xAC00)를 기준으로 인덱스를 계산
- 유니코드 산술식을 역산하여 각 자모의 인덱스를 추출


초성 (19개)

중성 (21개)

종성 (28개)


$$\text{Index} = (\text{초성} \times 588) + (\text{중성} \times 28) + \text{종성}$$

| 알고리즘 파이프라인




**LogitsProcessor
단계 개입**

다음 토큰 예측 시점




자모 분해

Top-k 후보 분해



해싱 & 매칭

Payload 비트 비교



편향(Bias) 주입

Logit 값 증가

| 생성 1단계: 자모 분해 및 채널 선택

Top-k 후보 분해

모델이 예측한 상위 k개의 토큰들
→ 각 마지막 글자를 분해

Round Robin 채널 선택

워터마크를 삽입할 채널(초/중/종)을
매 단계(Step t)마다 순차적으로 변경

Step 1: 초성 → Step 2: 중성 → Step 3: 종성
→ ...

| 생성 2단계: 해싱 및 비트 매칭

Hashing

선택된 채널(예: 중성)의 인덱스를 해시 함수 계산

→ 0 또는 1의 비트 값으로 변환

Payload (메시지):

"ABC"



67 68 69



0100 0001 0100 0010...

| 생성 2단계: 해싱 및 비트 매칭

Hashing

선택된 채널(예: 중성)의 인덱스를 해시 함수 계산

→ 0 또는 1의 비트 값으로 변환

Matching

현재 삽입해야 할 워터마크 Payload의 비트와 해시 값을 비교

값이 일치하면 해당 토큰은 **편향을 적용**

TARGET: 01

이번 단계에 선택할 음소: 초성

Selected!

후보 1: "인공지능" Prob: 0.28 → 0.65

L
Index: 1

-

○

9 mod 4 = 01 (Match!)

후보 2: "학습" Prob: 0.22

人
Index: 7

-

日

7 mod 4 = 11 ✕

| 생성 3단계: 편향(Bias) 부여



매칭된 토큰의 Logit 값에 편향값 더함
→ 모델이 자연스럽게 해당 토큰을 선택하도록 유도

| 생성 3단계: 편향(Bias) 부여

--- 1. Watermark Generation Phase ---

Original Message: 'yonsei'

Step 0 Success: 를

Step 1 Success: 논 의

Skip (Mismatch)

Skip (Mismatch)

Skip (Mismatch)

Skip (Mismatch)

Skip (Mismatch)

Skip (Mismatch)

Skip (Mismatch)

Skip (Mismatch)

Skip (Mismatch)

Skip (Mismatch)

Step 2 Success: 움

Skip (Mismatch)

Skip (Mismatch)

Step 3 Success: 시

Step 4 Success: 인 과

Skip (Mismatch)

Skip (Mismatch)

Skip (Mismatch)

| 탐지 단계 (Detection)

Non-blind Detection

워터마크 키를 알고 있는 상태에서 검증을 수행

1. **재토큰화:** 입력 텍스트를 생성 모델과 동일한 토큰나이저로 분리
2. **역순 검증:** 각 토큰의 마지막 음절을 분해하여 비트값 추출
3. **복원:** 추출된 비트열을 모아 원본 메시지와 대조

Message Recovery



Bits: 01001...



Bytes conversion



"LLM"

6. 실험 환경

Model	KoGPT2-base-v2 (한국어 특화 경량 모델)
Bias	5.0 (실험적 최적값)
Token Length	200개
Watermark	"yonsei" (ASCII 변환 비트열)

목표: 편향값과 토큰 길이에 따른 복원율(Accuracy)과 품질 검증

| 실험 결과 1: 복원율 (Accuracy)

[Generated Watermarked Text]

인공지능은 인류의 삶을 어떻게 바꿀 것인가?를 논의하는 것에 존재론적이라는 말이 있다.
윤대녕 옮김. 시인과 고고학은 뱀을 주제로 현대의학 개념을 암시, 암시, 상호 작용 이론으로 설명한다.
물론 양국강국사 (각전 옮김)도 비슷한 문제의식이며 이 책의 내용이다.
소중한 문화유산이 무엇인지, 앞으로 어떻게 가야 할지 구체적인 이야기가 나온다.
저자가 제시하는 또 하나의 관점은 시인을 고전에서 찾으려 했음에도 그의 말들이 모두 새기려구나 싶다.
그래서 책 제목만 보면 그냥 탈시가 나온다.
나무 위의 시선을 잃고 거대한 인간이 되기 위해 공룡알 한마리만을 보기 위한 평화와 영웅을 눈으로 본다는 표현이 과 동일하다.
시인과 달리 시인의 등장이 불가리아 된다.
옛말로는 영혼의 세계에 욕심 내지 본능을 끌어들이려 내 집착을 극복하고 그들에게 영혼을 위탁하는 경우, 영혼은 본능이자 몸이며 시간이 있다는 단서들을 제시하고 있다.
특히 시적 그대로이다.
길천에서 침몰한 암세포를 발견하고 생존해 있을 순간이다. 고래의 회복을 꿈꾸고 계속 불타오르면 싸워서 이기는 싸움은 정말이지 대조

--- 2. Watermark Detection Phase ---

Extracted Payload (bits): '011110010110111101101110011100110110010101101001'

Accuracy: 100.0%

Z-Score: 8.49

Recovered Message: 'yonsei'

--- 3. Verification ---

[Verification Success] Watermark Confirmed.

[Recover Success] Original message was successfully verified.

Bias 5.0에서 완벽 복원

편향값이 낮을수록 워터마크가 충분히 삽입되지 않아

복원 실패율이 높았음

Bias 5.0 설정 시, 200 토큰 길이 내에서 메시지를

100% 정확도로 복원하는 데 성공

| 실험 결과 1: 복원율 (Accuracy)

--- 2. Watermark Detection Phase ---

Extracted Payload (bits): '011110010110111101101110011100110110010101101001'

Accuracy: 100.0%

Z-Score: 8.49

Recovered Message: 'yonsei'

--- 3. Verification ---

[Verification Success] Watermark Confirmed.

[Recover Success] Original message was successfully verified.

실험 결과 1: 복원율 (Accuracy)

[Generated Watermarked Text]

산에서 우는 작은 새야, 쫓꾸는 진귀한 새끼, 그리고 쫓꾸는 사오라기 꿈을 닮아서 그렇게 되었다.
그래서 진달래꽃밭이나 노적산 등등 온통 진드 권장 제목이다.
지금까지도 그 알 만한 사람들은 진달래를 목격하지 못했다는 말들이 가슴에 남아 있다.
그러나 이 백일몽만한 진달래. 그것은 진심으로 자기 생각하고 자꾸 번득이는 꿀밤이었던 듯싶다.
진짜 진달래밭과 흰 진달래밭으로 가려면 꼭 진달래꽃숲과 노적산과 같은 진달래밭으로 가려면 꼭 노적산, 흰 진달래숲과 노적산 등등 진달래꽃을 보기 위해 가는 곳마다 산과 꽃 사이를 산책해야 한다는 것이다.
물론 이 진달래밭과 노적산도 결국 진달래숲과 진달래밭이라는 자연의 맛을 생생하게 체험할 수 있는 하나의 생태숲으로 꾸며져 있어야 한다.
진달래꽃은 덤불을 수 놓을 줄 아는 매의 속성인 것이다.
꽃을 숨아 낼 수도 있는 것은 들을 수 있는 겨를이 없는 벼신이다.
꽃밭에 비 오는 날

--- 2. Watermark Detection Phase ---

Extracted Payload (bits): '010100100110010101100000101100100001000000100110101100101001000000100100101100110001000000101100101101110110100100000010000110110000101101110'

Accuracy: 100.0%

Z-Score: 14.70

Recovered Message: 'Read Me If You Can'

--- 3. Verification ---

[Verification Success] Watermark Confirmed.

[Recover Success] Original message was successfully verified.

| 실험 결과 2: 강건성 (Robustness)

공격 시나리오: 텍스트 내에서 임의 단어 삭제하여 문맥 훼손시킴



공격 후 복원율

> 50%

핵심 메시지 복원 성공

```
Skip (Mismatch)
Skip (Mismatch)
Step 11 Success: 것
Generated: 인공지능은 우리 삶에서 꼭 필수적이다.
그것은 인공지능이 가져다준 인간의 창의력이 발터 벤...
```

```
=====
[Robustness Test: Deletion Attack]
=====
```

```
Original Text Length: 523
Attacked Text Length: 517
Removed Word: '인공지능이'
```

```
[Verification Result after Attack]
```

```
Log: 0111001001101111011000
Accuracy: 91.7%
Z-Score : 5.33
```

```
Success: Watermark survived deletion attack.
```

| 실험 결과 2: 강건성 (Robustness)

공격 시나리오: 텍스트 내에서 임의 단어 삭제하여 문맥 훼손시킴



공격 후 복원율

> 50%

핵심 메시지 복원 성공

워터마크 분산 효과

자음 모음 단위로 텍스트 전반에 분산되어 저장됨

→ 일부 단어가 삭제되어도 남은 토큰들의 자모 패턴을 통해
메시지의 핵심 부분 복구가 가능함을 입증

| 실험 결과 3: 문맥 품질 (Perplexity)

```
> Watermarked: 딥러닝의 미래는 아직 불투명하다고 봅니다.  
각사들의 지식은 사람이 살아가...  
> Normal:      딥러닝의 미래는 3D 프린팅과 빅데이터 기술 발전에 달렸다고 강조했다.  
...
```

```
=====  
Perplexity (Normal):      17.6105  
Perplexity (Watermarked): 40.6143  
=====
```

문맥의 자연스러움

워터마크가 적용된 텍스트 vs. 적용되지 않은 텍스트

| 7. 결론 및 시사점

독창성 (Originality)

기존 Token ID 기반에서 탈피,
한국어 자모 구조라는 언어적
특성을 시스템 설계에 반영한
새로운 패러다임 제시

구현 (Implementation)

Transformers 라이브러리를
커스터마이징하여 실시간으로 생성
파이프라인에 개입하는
End-to-End 워터마킹 시스템
구축

확장성 (Scalability)

영미권 중심 AI 기술 흐름 속에서,
비영어권 언어의 특성을 살린
신뢰성 있는 보안 솔루션을 확보

감사합니다.