

속도는벡터 — 박광현 교수 / 임채림 석사 5/15 사전 보고 요약

수신: 박광현 교수 / 임채림 석사 (BDAI 연구실)

발신: 속도는벡터 (박세은·강재현·조현빈·이동욱)

일시: 2026-05-12 작성, 5/15 (금) 14:00 미팅 사전 배포

목적: 캡스톤 5/27 최종 발표 직전 의미 있는 실험·기법·성능 개선 1-2 page 서면 요약 (구두 보고 보완)

0. 한 문장 요약

본 연구는 Exqutor 논문(arXiv:2512.09695v2) §V-B Adaptive Sampling 영역을 paper exact 재현하고, 그 위에 분포 인지형 stratification estimator 를 산술 평균으로 결합 보강(CaseB ensemble) 한 결과 **paired comparison 92.5% (455/492 cells, $p < 10^{-45}$)** 로 paper Bernoulli baseline 대비 통계적 우위를 paper review-grade evidence 수준으로 입증하였다.

1. 의미 있는 실험 (3건)

1.1 paper §V-B 100% 정확 재현 — 검증의 출발점

paper의 모든 hyperparam($m=0.9$ / $\eta_0=0.1$ / $\alpha=50$ / $\beta=1.5$ / $\gamma=0.99$ / period=50 / $N_{\text{init}}=385$) + query 정의 + threshold + trim 통계를 코드 line-by-line verbatim 재현하였다. 본 재현의 정합성은 paper Fig.12 영역 8 cells(DEEP/SIFT/SimSearchNet++ × sf=100 + 부분 영역) 의 mean trim Q-error 가 **1.618 vs paper 1.69 = -4.3%** 즉 measurement variance 범위 내 일치로 입증된다. 동일 seed 4 cells × 10 trials × 7 fields = 280/280 fields SHA-256 byte-identical reproducibility 도 확인되었다.

1.2 분포 인지형 56 method × 9 cells × 2 modes 비교 측정

8 paradigm 56 method 를 9 cells (DEEP/SIFT/SimSearchNet++ × sf=1/10/100 + selectivity 변화) × 2 modes (CaseA 단독 대체 / CaseB 결합 보강) 매트릭스에서 총 1001 file paper exact 측정 을 수행하였다. measurement portfolio: B1 baseline 9 cells + CaseA 495 + CaseB 496 = 1001 file. REPORT v11 (1362 line) 으로 paired $\Delta\%$ + effect size + statistical significance 산출.

1.3 결합 보강(CaseB) vs 단독 대체(CaseA) paired comparison

본 연구의 핵심 contribution. paper §V-B Bernoulli estimator(est_{b1} , bias 0 high variance) 와 우리 method KM20 stratified estimator(est_{method} , distribution-aware low variance) 의 산술 평균 $est_{final} = (est_{b1} + est_{method}) / 2.0$ 가 baseline 단독 대체보다 안정적임을 paired $\Delta\%$ 로 입증한다. AdaptiveState (Eq 1-6) 와 sample budget $N=385$ 는 paper exact 그대로 보존.

2. 사용한 기법 (5 paradigm anchor)

#	Paradigm	Anchor method	학술 reference
1	밀도 추정 (Density)	Parzen KDE	Parzen 1962 <i>Ann. Math. Stat.</i>
2	정보 이론 (InfoTheoretic)	HyperLogLog	Flajolet-Fusy-Gandouet-Meunier 2007 <i>AofA</i>
3	스트리밍 (Streaming)	Chao 1982 weighted reservoir + Thompson sampling	Chao 1982 <i>Biometrika</i>
4	차원 축소 (DimReduction)	Sparse Random Projection	Li-Hastie-Church 2006 <i>KDD</i>
5	공간 분할 (Spatial)	Hilbert curve (Wikipedia xy2d 표준) + Z-order Morton	Morton 1966 <i>IBM Tech Rep</i> / Wikipedia

추가 학술 정직 정정 4건: ★3 hilbert 가 코드상 PCA 2D + 사전식 정렬 alias 로 구현된 사실 self-disclosure 후 진짜 Wikipedia 표준 Hilbert(`hilbert_real`)로 별도 9 cells 재측정 / ★4 sparse_rp reference Achlioptas 2003 ✗ → Li-Hastie-Church 2006 $1/\sqrt{D}$ variant ○ 정정.

3. 성능 개선 (실측 REPORT v11, 5/12 02:50)

3.1 paradigm rollup mean $\Delta\%$ (CaseB ensemble vs Bernoulli baseline)

Paradigm	mean $\Delta\%$	n	1/(1+ Δ) 환산 ($\approx$ 개선 배수)
밀도 추정 (P10)	-11.93%	1	1.135x (caveat: anchor n=1)
정보 이론 (P9)	-7.60%	9	1.082x ★ paper review-grade
스트리밍 (P3)	-6.63%	44	1.071x
차원 축소 (P4)	-6.03%	104	1.064x
공간 분할 (P2)	-5.57%	107	1.059x
균등 격자 (P5 QMC)	+1.47%	62	— (개별 method 4건 정합성 위반 폐기)
클러스터 (P1)	+2.04%	87	— (결합 효과 없음)
양자화 (P6)	+8.44%	53	— (미세 악화)

→ 5 paradigm (P10/P9/P3/P4/P2) 통계 압도. qe_trim 1.06x ~ 1.14x 평균 정확도 개선.

3.2 핵심 climax — paired CaseB < CaseA

지표	값	의미
paired CaseB < CaseA	92.5% (455/492)	결합 보강이 단독 대체보다 거의 모든 cell 에서 우위
Cliff's δ large better	63.0% (311/494)	non-parametric effect size large 비율
Hedges' g large	55.7% (275/494)	parametric standardized mean diff large 비율
one-sided $p < 0.05$ outperform	45.3% (224/494)	BH-FDR 통계 유의 cell 비율
paired test p-value	$< 10^{-45}$	paper review-grade evidence

3.3 Negative Control — 단독 대체 무효 입증

CaseA 단독 대체 (Bernoulli baseline 을 우리 method 로 통째 교체) 결과 493 cells 중 outperform 0 cell (0%). 반대로 large worsening 은 37.1% (183/493). 즉 단독 대체는 무효, 결합 보강만 유효. 이 negative control 이 본 연구 결론의 핵심 buffer.

4. 학술 정직 한계 (Honest Limitation)

본 연구는 측정 미커버 + 정합성 위반 method 를 학술 정직성 차원에서 발표 자료에서 **완전히 폐기** (future work 처리 X). 폐기 사유 명시:

분류	Method	사유
정합성 위반 (paper N=385 budget 위반)	halton, sobol, lhs, hammersley (P5 QMC) / dense_rp, random_projection (P4) / dbscan (P1) / ccsketch, lsh, ams_count_sketch (P3)	A1-SSN CaseA $\Delta\%$ +4,000% ~ +500,000% 폭증, sample budget 폭증
측정 미커버 (자원 한계 + 사용자 정책)	dirichlet, kernelpca, neuocard, birch, hdbscan (Tier 2 5건) + kde_parzen 추가 측정 (1건)	50-200GB RSS / 80GB NPY fetch 37-88분 / KMeans fallback 등가
Algorithm audit drop	vinecopula $\times$ SF=100 (rank+PCA1D alias) / kdtree leaf-index (random hash 등가)	5/10 8-agent 정독 audit 학술 정직성 위반
Byte-identical duplicates	pca1d $\equiv$ cca1d $\equiv$ adaptive_bucket_probing / epsilon_net $\equiv$ kdpp / lsh $\equiv$ ams_count_sketch / kdtree = reservoir fallback	paradigm comparison caveat 표명

추가 정직 disclosure: paper §V-A multi-table (A2-Fig8 multi-vector, A3-TPCDS) 영역은 본 연구 §V-B sampling 영역과 별개로 paper main result 그대로 인정.

5. 5/15 미팅 confirm 요청 사항

미팅에서 교수님·채림님께 다음 6건 confirm 요청:

1. **climax stat 92.5% / Cliff's δ 63.0% / negative control 0/493** — paper review-grade anchor 적절성
2. **paradigm rollup 8 (P5 QMC paradigm-level 만 보고, method 4건 폐기)** — 학술 정직성 충분성
3. **정합성 위반 9 method 폐기 (paper N=385 budget 위반)** — 폐기 사유 충분성
4. **byte-identical duplicates 7쌍 caveat 표명** 적절성
5. **★3 hilbert PCA alias self-disclosure + Wikipedia 표준 Hilbert 재측정** — 학술 정직성 처리
6. **사용자 정책: 측정 미커버 method 완전 폐기 (future work X)** — 학술 적절성

6. 첨부 자료 (서버 또는 GitHub)

- **REPORT v11 1362 line** (paired $\Delta\%$ table + paradigm rollup + drop list 9 카테고리): 서버
`/mnt/hdd0/home/capstone2026/cache/rq3/paper_exact/REPORT_paper_exact.md` 또는 local
`/tmp/REPORT_v11.md`
- **상세 slide draft** (20 KB md / 670 KB PDF, 부록 A-E 포함): `submission/_drafts/박광현_5월15일_미팅/속도는벡터_박광현미팅_5월15일_slide_draft_20260511.{md,pdf}`
- **예상 질문 + 답변 가이드**: `submission/_drafts/박광현_5월15일_미팅/박광현_미팅_예상질문_답변_가이드_20260511.{md,pdf}`
- **5/27 발표 deck update plan**: `submission/_drafts/박광현_5월15일_미팅/5_27_deck_update_plan_post_5월15일미팅.{md,pdf}`
- **GitHub**: <https://github.com/johyunbin/Capstone>

7. END

작성: 2026-05-12 12:40 KST

배포: 5/15 (금) 14:00 박광현 교수 미팅 D-3 사전 배포

다음 단계: 5/15 미팅 confirm 결과 → 5/27 발표 deck minor 정정 → 5/26 finalize → 5/27 19:00 최종 발표 (D-15)