

속도는벡터 — 박광현 교수 / 임채림 석사 사전 보고 (1 page 요약)

수신: 박광현 교수 · 임채림 석사 (BDAI 연구실)
발신: 속도는벡터 (박세은·강재현·조현빈·이동욱)
일시: 2026-05-12 작성, 5/15 (금) 14:00 미팅 사전 배포

한 줄 결론

Exqutor 논문 §V-B Adaptive Sampling 영역에 분포 인지형 stratification 을 결합 보강(augment) 한 결과, paper Bernoulli baseline 대비 92.5% paired cell 우위 ($p < 10^{-45}$) 로 paper review-grade evidence 수준 정량 개선을 입증하였다.

1. 의미 있는 실험 3건

#	실험	정합성 / scope
1	paper §V-B 100% 정확 재현	paper Fig.12 영역 8 cells mean qe_trim 1.618 vs paper 1.69 = -4.3% (measurement variance 범위 내)
2	8 paradigm × 56 method × 9 cells × 2 modes 비교 측정	총 1001 file paper exact (B1 9 + CaseA 495 + CaseB 496)
3	대체(CaseA) vs 증강(CaseB) paired comparison	단독 대체 vs ensemble augment 두 방식 정량 비교

2. 사용한 기법 — 5 paradigm anchor

paradigm	anchor method	참조
밀도 추정 (Density)	Parzen KDE	Parzen 1962
정보 이론 (InfoTheoretic)	HyperLogLog	Flajolet 2007
스트리밍 (Streaming)	Chao 1982 weighted reservoir	Chao 1982
차원 축소 (DimReduction)	Sparse Random Projection	Li-Hastie-Church 2006
공간 분할 (Spatial)	Hilbert curve + Z-order	Morton 1966 / Wikipedia

3. 최종 성능 개선

3.1 paradigm rollup (CaseB 증강 vs Bernoulli baseline)

paradigm	mean $\Delta\%$	정확도 향상 배수
밀도 추정	-11.93%	1.135x
정보 이론	-7.60%	1.082x
스트리밍	-6.63%	1.071x
차원 축소	-6.03%	1.064x
공간 분할	-5.57%	1.059x

→ 5 paradigm 통계 압도 · qe_trim 정확도 1.06x ~ 1.14x 향상

3.2 결정적 비교 — 대체 vs 증강

적용 방식	결과	의미
CaseA · 단독 대체	0 / 493 (0%) outperform	단독 대체는 무효
CaseB · 증강 적용	455 / 492 (92.5%) paired better	증강 적용 만 유효

→ paper Bernoulli baseline 을 우리 method 로 단독 교체하면 무효, 산술 평균 ensemble 로 증강하면 paper review-grade 우위 ($p < 10^{-45}$, Cliff's δ large 63.0%, Hedges' g large 55.7%)

4. 결론

원 논문이 명시한 sampling 한계는 분포 인지형 stratification 의 ensemble augment 로 보강 가능하다. 8 paradigm 비교 search 에서 5 paradigm (밀도 추정·정보 이론·스트리밍·차원 축소·공간 분할) 이 paper baseline 대비 통계적으로 압도하며, 단독 대체가 아닌 증강 적용 만이 유효 함을 negative control 로 입증한다.

5. 추가 finding (5/13 03:00 강재현 피드백 반영)

5/12 23:00 ~ 5/13 03:00 강재현의 추가 피드백 두 가지에 대한 정량 검증을 수행하였다. 첫째, cluster 수 K 변화 ($K=10/20/30$) 의 sensitivity 가 method 의존적임을 확인하였다 — **sparse_rp** 는 $K=20$ **sweet spot** 결정적 ($K=10$ +5% / $K=20$ -10.6% / $K=30$ -6.8% U-shape), Hilbert / HyperLogLog / Chao 의 3 anchor 는 K -robust ($K=10/20/30$ 거의 동일). 둘째, paradigm rollup 평균이 outlier method (wavelet_hist +68%, lp_bound +16%) 에 의해 왜곡됨을 paradigm 내 분산 분석으로 입증하였다. **진짜 contribution 은 paradigm 우위가 아닌 12 anchor method 의 일관성** (cell 전반 -9~-10% 개선, std 2-3 안정). 본 finding 은 5/27 발표 deck v5 정정에 cluster granularity sensitivity slide + paradigm 내 method-level breakdown 형태로 반영 예정이다.

6. RQ1 narrative 정량 보강 (5/13 12:09 박세은 결정 반영)

RQ1 의 "random sampling 의 부정확성" 정량화를 위해 PostgreSQL 의 두 표본추출 방식 — **TABLESAMPLE SYSTEM (block-level random) vs BERNOULLI (row-wise random)** — 을 5 selectivity $\times$ 2 dataset (SIFT / DEEP) $\times$ 5 seed $\times$ 100 query paired 비교 수행하였다. 가장 극단 case 인 SIFT $s=0.05$ 에서 SYSTEM 이 BERN 보다 **MAX +17.32% 더 부정확** 하였으며, 5 selectivity 전 구간에서 SIFT 가 DEEP 보다 격차가 더 크고 (cross-dataset 격차 +1.40 ~ +5.61%p), 좁은 selectivity ($s=0.01$) 에서 격차가 가장 컸다. paired Wilcoxon $p \leq 1 \times 10^{-49}$ (BH-FDR 보정 robust) 로 paper review-grade 수준 통계 확보가 완료되었다. 본 결과는 5/27 발표 deck S7 의 RQ1 narrative 를 기존 "Bernoulli vs KM20 (8.64% max)" 에서 "SYSTEM vs BERN (17.32% max)" 로 재배치하는 v5 정정에 반영된다 — skew dataset 에서 random sampling 자체의 부정확성이 어떻게 증폭되는가를 dataset cross-comparison 으로 입증하는 narrative arc 의 출발점.

7. multi-join re-stratification + Centroid tuple cheap 근사 측정 결과 (★ 5/13 19:57 8+8/8 finalize)

강재현의 5/13 0:20 + 14:27 두 피드백에 따라 두 단계의 정량 검증을 수행하였다. 첫 단계는 두 벡터 테이블 (partsupp_deep_10 $\bowtie$ part_wiki_10) 의 multi-join 후 별도 stratification 학습 (864 차원 concat KM20 fresh, expensive) 의 sensitivity 검증으로 5/13 16:13 회수 완료하였으며, 두 번째 단계는 강재현의 후속 cheap 근사 hypothesis 검증으로 Centroid tuple cheap 근사 (두 single-table KM20 + (s_A, s_B) tuple folding, 학습 비용 0 추가) 측정을 5/13 19:57 회수 완료하였다. 두 측정 모두 4 paradigm anchor method $\times$ A2-Fig9 multi-table cell $\times$ 2 mode (CaseA / CaseB) = 각 8 measurement scope 이다.

첫 단계 multi-join re-stratification (expensive) 의 핵심 finding 은 **시나리오 A.5 (Hybrid) — Quality-sensitivity 패턴** 이다. Quality-sensitive 2 method (sparse_rp + chao_weighted) 가 CaseA 단독 대체 모드에서 multi-jn 우위 (-3.55%p, -2.63%p), Quality-robust 2 method (hilbert_real + hyperloglog) 는 거의 동등 (+0.32%p, -0.26%p). CaseB 증강 모드는 4 method 모두 일관 동등 (mean diff -0.12%p) — 본 연구 핵심 contribution 인 ensemble augment 의 robustness 가 입증되었다.

두 번째 단계 Centroid tuple cheap 근사 의 핵심 finding 두 가지가 도출되었다. 첫째, **CaseB 증강 모드에서 Centroid tuple 이 모든 4 method 에서 multi-jn 보다 일관 우위** (mean ct-vs-mj diff -0.84%p, mean ct-vs-carry diff -0.96%p) — 본 연구 핵심 contribution 영역에서 **0 학습 비용 추가로 더 좋은 ensemble 정확도** 라는 best of both worlds 결과. 둘째, CaseA 단독 대체 모드는 method-conditional — chao_weighted (-3.60%p ★★, 본 측정 최대) 과 hyperloglog (-2.29%p) 는 cheap 근사 큰 효과 (multi-jn 보다는 우위), sparse_rp 는 marginal (+0.19%p), hilbert_real 은 harmful (+3.19%p). chao_weighted 의 weighted reservoir sampling 과 hyperloglog 의 hash distinct count 메커니즘이 cheap stratum 의 sparse 분포를 정확도 향상으로 활용하는 반면, hilbert_real 의 Hilbert curve spatial locality 는 imperfect (s_A, s_B) folding 으로 fragmentation 손실된다.

본 두 측정은 본 연구의 anchor method 분류에 세 axis 의 본질적 메커니즘 axis 의 존재를 입증한다 — K-sensitivity (부록 F), Quality-sensitivity (부록 G multi-jn), **Cheap 근사 친화도 (본 §7 Centroid tuple)**. 세 axis 는 paradigm 분류와 다르고 부분적으로 correlate 하지만 method 별로 독립 분기를 보인다. 본 연구 핵심 CaseB ensemble augment 영역에서는 Centroid tuple cheap 근사를 보편 적용하는 design (학습 비용 0 + 모든 method 우위) 이 권장되며, CaseA 단독 대체 영역은 method-aware 적용 (또는 limitation 명시) 으로 처리한다.

상세 자료: - [submission/_drafts/박광현_5월15일_미팅/속도는벡터_박광현미팅_5월15일_slide_draft_20260511.pdf](#) (20 KB md, 741 KB PDF — 2 slide 학술 산문 + 부록 A~F) - [submission/_drafts/박광현_5월15일_미팅/박광현+임채림_5월15일_사전보고_요약_20260512.pdf](#) (2 page 상세) - **REPORT v11** (1362 line): 서버 또는 GitHub [experiments/results/](#) - 분석 file 4 건: [_internal/analysis/{method_level_breakdown, km_granularity_sensitivity_3way_K10_K20_K30, km_granularity_sensitivity_K10_vs_K20, multi_cell_km_based_learning_comparison}_20260513.md](#)

작성: 2026-05-12 14:15 KST · 5/13 12:50 update — §6 RQ1 narrative 보강 + §7 multi-join 측정 in-flight 추가 · 5/15 (금) 14:00 미팅 D-2