

속도는벡터 — 박광현 교수 / 임채림 석사 사전 보고 (1 page 요약)

수신: 박광현 교수 · 임채림 석사 (BDAI 연구실)
발신: 속도는벡터 (박세은·강재현·조현빈·이동욱)
일시: 2026-05-12 작성, 5/15 (금) 14:00 미팅 사전 배포

한 줄 결론

Exqutor 논문 §V-B Adaptive Sampling 영역에 분포 인지형 stratification 을 결합 보강(augment) 한 결과, paper Bernoulli baseline 대비 92.5% paired cell 우위 ($p < 10^{-45}$) 로 paper review-grade evidence 수준 정량 개선을 입증하였다.

1. 의미 있는 실험 3건

#	실험	정합성 / scope
1	paper §V-B 100% 정확 재현	paper Fig.12 영역 8 cells mean qe_trim 1.618 vs paper 1.69 = -4.3% (measurement variance 범위 내)
2	8 paradigm × 56 method × 9 cells × 2 modes 비교 측정	총 1001 file paper exact (B1 9 + CaseA 495 + CaseB 496)
3	대체(CaseA) vs 증강(CaseB) paired comparison	단독 대체 vs ensemble augment 두 방식 정량 비교

2. 사용한 기법 — 5 paradigm anchor

paradigm	anchor method	참조
밀도 추정 (Density)	Parzen KDE	Parzen 1962
정보 이론 (InfoTheoretic)	HyperLogLog	Flajolet 2007
스트리밍 (Streaming)	Chao 1982 weighted reservoir	Chao 1982
차원 축소 (DimReduction)	Sparse Random Projection	Li-Hastie-Church 2006
공간 분할 (Spatial)	Hilbert curve + Z-order	Morton 1966 / Wikipedia

3. 최종 성능 개선

3.1 paradigm rollup (CaseB 증강 vs Bernoulli baseline)

paradigm	mean $\Delta\%$	정확도 향상 배수
밀도 추정	-11.93%	1.135x
정보 이론	-7.60%	1.082x
스트리밍	-6.63%	1.071x
차원 축소	-6.03%	1.064x
공간 분할	-5.57%	1.059x

→ 5 paradigm 통계 압도 · qe_trim 정확도 1.06x ~ 1.14x 향상

3.2 결정적 비교 — 대체 vs 증강

적용 방식	결과	의미
CaseA · 단독 대체	0 / 493 (0%) outperform	단독 대체는 무효
CaseB · 증강 적용	455 / 492 (92.5%) paired better	증강 적용 만 유효

→ paper Bernoulli baseline 을 우리 method 로 단독 교체하면 무효, 산술 평균 ensemble 로 증강하면 paper review-grade 우위 ($p < 10^{-45}$, Cliff's δ large 63.0%, Hedges' g large 55.7%)

4. 결론

원 논문이 명시한 sampling 한계는 분포 인지형 stratification 의 ensemble augment 로 보강 가능하다. 8 paradigm 비교 search 에서 5 paradigm (밀도 추정·정보 이론·스트리밍·차원 축소·공간 분할) 이 paper baseline 대비 통계적으로 압도하며, 단독 대체가 아닌 증강 적용 만이 유효 함을 negative control 로 입증한다.

5. 추가 finding (5/13 03:00 강재현 피드백 반영)

5/12 23:00 ~ 5/13 03:00 강재현의 추가 피드백 두 가지에 대한 정량 검증을 수행하였다. 첫째, cluster 수 K 변화 ($K=10/20/30$) 의 sensitivity 가 method 의존적임을 확인하였다 — **sparse_rp** 는 $K=20$ **sweet spot** 결정적 ($K=10$ +5% / $K=20$ -10.6% / $K=30$ -6.8% U-shape), Hilbert / HyperLogLog / Chao 의 3 anchor 는 K -robust ($K=10/20/30$ 거의 동일). 둘째, paradigm rollup 평균이 outlier method (wavelet_hist +68%, lp_bound +16%) 에 의해 왜곡됨을 paradigm 내 분산 분석으로 입증하였다. **진짜 contribution 은 paradigm 우위가 아닌 12 anchor method 의 일관성** (cell 전반 -9~-10% 개선, std 2-3 안정). 본 finding 은 5/27 발표 deck v5 정정에 cluster granularity sensitivity slide + paradigm 내 method-level breakdown 형태로 반영 예정이다.

6. RQ1 narrative 정량 보강 (5/13 12:09 박세은 결정 반영)

RQ1 의 "random sampling 의 부정확성" 정량화를 위해 PostgreSQL 의 두 표본추출 방식 — **TABLESAMPLE SYSTEM (block-level random) vs BERNOULLI (row-wise random)** — 을 5 selectivity $\times$ 2 dataset (SIFT / DEEP) $\times$ 5 seed $\times$ 100 query paired 비교 수행하였다. 가장 극단 case 인 SIFT $s=0.05$ 에서 SYSTEM 이 BERN 보다 **MAX +17.32% 더 부정확** 하였으며, 5 selectivity 전 구간에서 SIFT 가 DEEP 보다 격차가 더 크고 (cross-dataset 격차 +1.40 ~ +5.61%p), 좁은 selectivity ($s=0.01$) 에서 격차가 가장 컸다. paired Wilcoxon $p \leq 1 \times 10^{-49}$ (BH-FDR 보정 robust) 로 paper review-grade 수준 통계 확보가 완료되었다. 본 결과는 5/27 발표 deck S7 의 RQ1 narrative 를 기존 "Bernoulli vs KM20 (8.64% max)" 에서 "SYSTEM vs BERN (17.32% max)" 로 재배치하는 v5 정정에 반영된다 — skew dataset 에서 random sampling 자체의 부정확성이 어떻게 증폭되는 가를 dataset cross-comparison 으로 입증하는 narrative arc 의 출발점.

7. multi-join re-stratification 측정 결과 (★ 5/13 16:20 8/8 finalize)

강재현의 5/13 0:20 피드백에 따라 두 벡터 테이블 (partsupp_deep_10 × part_wiki_10) 의 multi-join 후 별도 stratification 학습 — 본 연구의 기존 single-table KM20 carry-over 방식과 대비되는 **fresh re-stratification** — 의 sensitivity 정량 검증을 5/13 12:25 KST launch + 13:30 wrapper v2 fix + re-launch 후 5/13 16:13 KST 회수 완료하였다. scope 는 4 paradigm anchor method (sparse_rp / hilbert_real / hyperloglog / chao_weighted) × A2-Fig9 multi-table cell × 2 mode (CaseA / CaseB) = 8 measurement 이며, 864 차원 concat vector 위 KM20 학습 후 96 차원 query space (partsupp_deep 측) 만 stratified estimator 의 vector pool 로 사용하는 wrapper v2 design 이 적용되었다.

핵심 finding 은 **시나리오 A.5 (Hybrid) — method-specific sensitivity** 가 확정된 것이다. **Quality-sensitive 2 method (sparse_rp + chao_weighted)** 가 CaseA 단독 대체 모드에서 multi-join re-strat 우위를 보였으며 (carry-over +4.52% / +6.14% → re-strat +0.97% / +3.51%, **-3.55%p / -2.63%p 개선**), 두 method 의 stratification 학습 메커니즘이 stratum 내부 통계 구조에 강하게 의존하기 때문이다. 반면 **Quality-robust 2 method (hilbert_real + hyperloglog)** 는 거의 동등 (+0.32%p / -0.26%p, 모두 ±0.5%p 이내) 으로 stratification 학습 방식 변화에 robust 하다. **CaseB 증강 모드** 는 4 method 모두 일관 동등 (mean diff -0.12%p) — 본 연구의 핵심 contribution 인 Bernoulli + stratified 산술 평균 ensemble 의 robustness 가 multi-join cell 의 stratification 학습 방식 변화에도 입증되었다. 본 finding 은 5/13 03:00 부록 F 의 cluster granularity sensitivity 패턴과 method 별 완벽 일치하여, "stratification quality 의존도" 라는 새 method classification axis 의 존재를 입증한다. 강재현이 후속으로 제시한 cheap 근사 방향 (14:27 카톡) 은 method-specific selective application + Centroid tuple 근사 (학습 비용 0 으로 multi-join 결합 정보 활용) 가 5/16 이 후 추가 측정 영역 우선 후보로 결정되었다.

상세 자료: - [submission/_drafts/박광현_5월15일_미팅/속도는벡터_박광현미팅_5월15일_slide_draft_20260511.pdf](#) (20 KB md, 741 KB PDF — 2 slide 학술 산문 + 부록 A~F) - [submission/_drafts/박광현_5월15일_미팅/박광현+임채림_5월15일_사전보고_요약_20260512.pdf](#) (2 page 상세) - **REPORT v11** (1362 line): 서버 또는 GitHub [experiments/results/](#) - 분석 file 4 건: [_internal/analysis/{method_level_breakdown, km_granularity_sensitivity_3way_K10_K20_K30, km_granularity_sensitivity_K10_vs_K20, multi_cell_km_based_learning_comparison}_20260513.md](#)

작성: 2026-05-12 14:15 KST · 5/13 12:50 update — §6 RQ1 narrative 보강 + §7 multi-join 측정 in-flight 추가 · 5/15 (금) 14:00 미팅 D-2