

박광현 교수님 5/15 (금) 14:00 미팅 — 예상 질문 + 답변 가이드

이 자료의 목적: 박광현 교수님 미팅 30분 (slide 2장 + Q&A) 중 Q&A 영역에서 예상되는 질문과 답변 narrative 사전 준비. 박세은 / 강재현 / 이동욱 / 조현빈 모두 같은 깊이로 답변 가능 수준 정리.

작성: 2026-05-11 19:40 KST · slide draft + 5/27 deck plan + paper exact 측정 종합 narrative 기반.

A. 측정 정합성 영역 (paper exact 재현 검증)

Q1. paper Fig 12 mean Q-error 1.69를 정확히 재현했는가?

답변: 8 cells (DEEP/SIFT/SimSearchNet++ × sf=100, YFCC sf=10, DEEP+WIKI cross sf=10, DEEP scale sf=1/10/100) 평균 trim Q-error 1.6180으로 paper 보고값 1.69 대비 -4.26%, measurement variance 범위 내 일치입니다. 4 cells × 10 trials × 7 fields = 280/280 fields가 SHA-256 byte-identical로 deterministic 일치 (seed `trial_idx × 13 + 7` 일관)도 확인되었습니다.

Q2. paper Eq 1-6 + hyperparam 8건 정확 재현?

답변: 코드 line-by-line 100% 일치 확인했습니다. $m=0.9$, $\eta_0=0.1$, $\alpha=50$, $\beta=1.5$, $\gamma=0.99$, $\text{update_period}=50$, $N_{\text{init}}=385$, HNSW $M=16$, $\text{ef_search}=400$. paper §V-B Eq 1-6에 sample size에 대한 min/max clamping은 명시되지 않으므로 우리도 bound를 두지 않습니다 (5/10 paper 정독 결정). 미세 mismatch 4건 (q_error cap=100 / size round / sel=0.001 calibration parquet 부재 fallback / Bernoulli budget)은 모두 numerical robustness 영역으로 §5.3 Limitation에 명시되어 있습니다.

Q3. paper Fig 5/6의 query 집합을 정확히 재현했는가?

답변: 5/10 agent paper 정독에서 발견한 핵심 정정사항을 반영했습니다. DEEP/SIFT는 Q3,10,12 (3 queries) / SimSearchNet++ (=FB=SSN)는 **Q3,9,10** (3 queries)로 dataset 별로 다릅니다. 이전 추정 "Q3,9,10,12 모든 dataset 동일"은 paper 정독으로 정정되었습니다. YFCC는 Fig 7의 Q3,5,8,9,10,11,12,20 (8 queries), DEEP+WIKI cross는 Fig 9의 동일 8 queries.

B. CaseB ensemble augment 학술적 위치

Q4. CaseB ensemble의 산술 평균 구조의 학술적 정당성?

답변: 본 연구의 ensemble 구조는 paper §V-B Bernoulli estimator (est_1)과 우리 method KM20 stratified estimator (est_2)의 단순 산술 평균 ($est_final = (est_1 + est_2) / 2.0$)입니다. AdaptiveState (Eq 1-6 sample size 동적 조정)와 sample budget (Eq 1 N=385)은 paper exact 그대로 유지하며, 두 estimator가 budget을 공유합니다. 통계적 정당성은 bias-variance trade-off에서 나옵니다 — random sampling은 bias 0이지만 variance 큼, stratified는 분포 가정 시 variance 낮음. 두 estimator 산술 평균은 한 쪽이 fail해도 다른 쪽이 보완하는 robust 구조이며, 5/11 측정에서 paired CaseB > CaseA 92.9% (404/435) + Cliff's δ large better 63.5%로 통계 압도가 입증됩니다.

Q5. 가중 평균 ($\alpha \cdot est_1 + (1-\alpha) \cdot est_2$) 또는 query-conditional routing은 검토했는가?

답변: 현재 산술 평균 ($\alpha=0.5$)만 측정하였으며, 가중 평균과 query-conditional routing은 §6.2 Future work 6번 항목에 명시되어 있습니다. 본 연구의 contribution은 paper-friendly augment 구조 (paper §V-B 자체 변경 없음)의 정량적 가치 검증이며, α 최적화는 추가 연구 영역입니다.

Q6. CaseA 단독 대체가 무너졌는데, paper §V-B 자체가 robust하다는 의미인가?

답변: 그렇습니다. CaseA mode (우리 method가 paper Bernoulli sampling step을 단독으로 대체)는 one-sided BH-FDR $\alpha=0.05$ outperform이 0/437 (0.0%)로 통계 무효였으며, Cliff's δ large worsening 36.8%가 large better 14.4%를 압도합니다. 이는 paper §V-B Adaptive Sampling이 momentum 기반 동적 sample size 조정 (Eq 3-6) + Q-error feedback loop를 통해 자체 robustness를 확보하기 때문입니다. 본 연구의 contribution은 paper §V-B를 대체하는 것이 아니라 ensemble augment로 보완하는 것입니다.

C. ★3 hilbert defect rectify 학술 contribution

Q7. ★3 Hilbert가 Faloutsos 1989 Hilbert curve indexing이 아니라 PCA 2D lex sort라는 발견은 어떻게 했는가?

답변: 5/10 8 agent algorithm audit (각 paradigm 별 reference 표명 vs 코드 implementation 검증)에서 발견했습니다. 코드 line 449에서 PCA(2) → 2D lex sort로 구현되어 있으며, Faloutsos 1989 SIGMOD의 진짜 Hilbert curve indexing의 locality 효과가 아니라 PCA proxy 효과를 측정했었습니다. 학술 정직성 기준에서 issue로 분류하고 alias `pca2d_lex` 로 정직 명명했습니다.

Q8. ★3 hilbert를 그냥 폐기하지 왜 alias로 보존했는가?

답변: 5/8 시점 4강 narrative의 ★3 Hilbert 측정 결과 (CaseA -7.54%, CaseB -8.30%)를 paradigm rollup 산출 시 honest comparison을 위해 보존하되, 학술 정직성 기준에서 alias 명명 (pca2d_lex)으로 reference 정정합니다. 진짜 Hilbert curve의 paradigm anchor는 M6 zorder_morton (Morton 1966) + M7 skilling_hilbert (Skilling 2004 conditional swap simplification 1줄 disclosure) + hilbert_real (Wikipedia xy2d 표준) 3건의 추가 측정으로 보강되며, 이 4건 비교가 "PCA proxy locality vs 진짜 Hilbert locality 분리 검증"의 학술 contribution입니다.

Q9. paper review에서 reviewer가 "★3 hilbert defect를 본문에 포함시킨 이유" 질문 시?

답변: 본 연구의 학술 정직성 (honest disclosure) 원칙입니다. 5/8 시점 측정 결과를 5/10 audit에서 발견된 reference 정정과 함께 보고하며, paradigm rollup 시 alias로 명시하여 "★3 hilbert가 진짜 Hilbert curve가 아닙니다"는 사실을 본문에서 명확히 합니다. 이는 ★3 hilbert defect rectify (M6/M7/hilbert_real 4건 paradigm anchor 추가)의 학술 contribution narrative와 일관됩니다.

D. RQ2 Neyman/Anti paradox honest finding

Q10. Anti < Prop < Neyman paradox는 paper §V-B 이론 위배인가?

답변: 외형상 paper §V-B 이론 (Neyman optimal allocation σ -weighted)을 위배하는 양상이지만, 실제로는 boundary case의 자연 결과입니다. Root cause는 σ_j range 1.3-1.6 $\times$ 좁음 (DEEP/SIFT/SSN sf=100 KM20 cluster의 cluster 내 sigma는 [0.18, 0.29] 범위) + N_i CV=0 (KM20 cluster 균등 size) $\rightarrow$ σ -weighted Neyman alloc cos_sim 0.99 (L1 diff 21-39 sample / 385 budget) $\rightarrow$ budget=385 hit count noise (~50/seed @ sel=0.1) > Neyman signal (~3 hits 차이)로, PartSupp PK가 uniform stratum density 분포로 σ -weighted optimization의 변별력이 marginal이 되는 boundary case입니다.

Q11. 이 paradox가 어떤 학술 contribution이 되는가?

답변: "분포 알면 prop allocation이 답이며, σ range 큰 cluster imbalance 영역 (RQ3 추정 framework)에서 Neyman 우위 재검증 필요"의 honest finding으로, RQ2 $\rightarrow$ RQ3 자연 전환 narrative를 정당화합니다. 또한 Phase 4 11 method 중 M9 kmeans_neyman / M11 idistance_neyman의 학술 contribution narrative를 "RQ2 plug-in 직접 강화"가 아니라 "분포 정보 추정 방식 $\times$ Neyman σ allocation 2D ablation — KM20 oracle 가 정 한계 발견"의 honest finding으로 정정하는 학술 기여가 됩니다.

E. 9 paradigm framework + drop list

Q12. 9 paradigm × 56 method framework의 학술적 정합성?

답변: 5/8 RQ3 paradigm framework (5 paradigm × 11 method)에서 출발하여 5/10 8 agent audit + 5/11 Phase 4 측정으로 신규 paradigm P9 InfoTheoretic (HyperLogLog Flajolet 2007) + P10 Density (Parzen 1962 KDE) 2건을 추가하였습니다. ACM Comput Surv 2024 clustering taxonomy + UWisconsin Wu et al. sampling-based cardinality estimation survey + PDX SIGMOD 2025와 cross-check하여 학술 정합성을 확보했습니다. P7 Subspace clustering (CLIQUE 1998) + P8 Graph-based (Leiden 2019, Bao et al. VLDB 2025)는 future work으로 명시합니다.

Q13. 23 method 폐기/rename은 학술적으로 적절한가?

답변: 5/10 8 agent algorithm audit에서 reference fraud 또는 algorithm misrepresentation으로 분류된 23 method (예: vinecopula = rank+PCA1D / neuram = PCA1D 100% 동일 / kdtree = idx % n_strata random hash 등가 / ams_count_sketch = lsh line-by-line 동일)는 학술 정직성 기준에서 폐기/rename 권고됩니다. 단 측정 결과는 paradigm rollup의 honest comparison을 위해 보존되며, §5.3 Limitation에서 honest disclosure 됩니다.

Q14. 측정 미커버 233 cells (20.5%) 9 카테고리 disclosure 충분한가?

답변: 본 연구는 측정 미커버 사례를 9 카테고리로 정직 분류합니다. (1) algorithm audit drop 23 method, (2) 자원 한계 (birch CFNode tree 50-200GB RSS, A1-SSN 80GB NPY fetch 37-88분), (3) paper §V-A scope 외 (A2-Fig8 multi-vector, A3-TPCDS ECQO PG segfault), (4) wrapper timeout 부재 (Q1+Q4 batch hung), (5) 사용자 결정 (★1 hdbscan sklearn KMeans fallback 등가). §5.3 Limitation L12 + 본문 §3.6 측정 매트릭스 caveat에 명시됩니다.

F. Future Work

Q15. P8 Graph-based future work에서 Bao et al. VLDB 2025를 인용하는 이유?

답변: Bao et al. VLDB 2025는 Exqutor §V-A의 HNSW 인덱스를 §V-B sampling step의 분포 정보 추출 용도로 재활용하는 cross-paradigm contribution입니다. 본 연구의 P8 Graph-based future work이 Exqutor 논문의 paradigm 통합 (ECQO + Adaptive Sampling)과 자연스럽게 연결되며, 박광현 교수님 연구실 (BDAI)의 이전 연구 흐름과 align됩니다.

Q16. Future work 우선순위 8건 중 가장 중요한 것?

답변: P7 Subspace clustering (CLIQUE 1998) + P8 Graph-based (Leiden 2019 + Bao et al. VLDB 2025)의 paradigm 추가가 본 연구의 9 paradigm framework를 11 paradigm으로 확장하는 직접 학술 기여이며, multi-table aware ensemble은 단일 → 멀티 일반화의 본 연구 한계 (§5.3 L1) 극복으로 가장 중요합니다. SF=100 cross-scale full validation은 본 세션 5/11 19:19 launch 후 며칠 long-running 진행 중으로 5/16~5/20 부분 회수 가능합니다.

G. 발표 자료 + 보고서

Q17. 5/27 발표 16-slide deck (Academic v3, 5/8 base)는 어떻게 update할 계획인가?

답변: [submission/_drafts/박광현_5월15일_미팅/5_27_deck_update_plan_post_5월15일미팅.pdf](#) 에 slide-by-slide 정정 영역 11종 + 신규 figures 6 통합 + 신규 slide S6.5/S10.5/S15.5 검토 + Phase 1-3 sprint plan (5/16~5/26)이 명시되어 있습니다. 핵심 정정: S6 RQ1 narrative paper exact +3.74%, S7 RQ2 paradox, S8 RQ3 4강 → paradigm rollup 9, S9 ★3 Hilbert → ★3 alias + M6/M7/hilbert_real, S11 Negative Control → CaseB ensemble climax, S15 Limitation 8 → 18.

Q18. 6/11 최종 보고서 outline v2 (5/8 base) → v3 update plan?

답변: [plans/6_11_보고서_outline_v3_update_plan_20260511.md](#) 에 v2 → v3 update plan이 명시되어 있으며, §3 Methodology + §4.4 CaseB climax + §5.3 Limitations 18종 + §1 Introduction + §6 Conclusion + Future Work의 본문 sketch 5건이 5/29~6/10 W5~W6 sprint 4 팀원 분담 가이드로 작성되었습니다. 박세은 통합 + 조현빈 §3+§4.1+§4.5 + 이동욱 §2+§4.2 + 강재현 §4.3+§4.4.

H. 산업 + 응용

Q19. Production deployment 권고는?

답변: OLTP 환경은 minibatch_partial M2 (P3 Streaming, Sculley 2010 partial_fit) 또는 hilbert_real (P2, learning-free Wikipedia xy2d 표준)를 권고합니다. OLAP 학습 비용 회피 영역에서는 KDE Parzen (P10 Density)이 textbook anchor이며, skewed dataset (SIFT-like)에서는 분포 인지 stratification이 paper §V-B Bernoulli baseline 대비 9-11% 개선 효과를 보입니다 (Cliff's δ large better 63.5%, paper review-grade 통계).

Q20. 본 연구의 산업 응용 가능성?

답변: 본 연구는 vector range query의 cardinality estimation 정확도 개선이 직접적인 산업 가치이며, query plan 선택 (hash join vs nested loop) 정확도 향상으로 1000-100000× 빠른 query 실행이 가능합니다. PDX SIGMOD 2025 (intrinsic_dim + skewness driven algorithm selection)와 학술 align되며, 박광현 교수님 연구실 (BDAI)의 Exqutor 본 논문 연구 흐름의 직접 후속입니다.

미팅 후 follow-up

미팅 confirm 결과를 다음 자료에 즉시 반영: - [5_27_deck_update_plan_post_5월15일미팅.md](#) (Phase 1-3 sprint plan 정합성 점검) - [submission/_drafts/속도는벡터_자문메일_박성원멘토_20260511_v6.md](#) (자문 요청 4건 narrative 정정) - [plans/5_27_storyline_draft_20260511_1410.md](#) (storyline v3 작성, 만약 변경 사항 있으면) - [plans/6_11_보고서_section_*.md](#) (5 sketch 정합성 점검)

작성: 2026-05-11 19:40 KST

다음: 미팅 직전 5/14 PDF 변환 + 강재현/박세은/이동욱 검토 + 5/15 13:50 박세은 사전 인사 + 13:55 자리 안내 + 14:00 미팅 시작