

박광현 교수님 미팅 — 속도는벡터 (Exqutor §V-B 측정 보고)

일시: 2026-05-15 (금) 14:00 **참석:** 박광현 교수님 / 박세은(팀장) / 강재현 / 조현빈 / 이동욱 **소요:** ~30분
(slide 2장 + Q&A) **준비:** paper exact 측정 완료 보고 + honest limitation disclosure + 5/27 발표 storyline confirm

Slide 1 (10분) — Exqutor §V-B Adaptive Sampling 영역 paper exact 재현 측정 완료 보고

1. 측정 정합성

본 연구는 Exqutor 논문(arXiv:2512.09695v2)의 §V-B Adaptive Sampling 영역, 즉 vector index 부재 시 Bernoulli random sampling과 모멘텀 기반 동적 sample size 조정(Eq 1-6)에 대해 paper의 모든 hyperparam, query 정의, threshold, trim 통계를 verbatim으로 재현하였다. 측정 자체의 정합성은 4측에서 paper review-grade로 검증된다. 첫째, Reproducibility 검증에서 4 cells × 10 trials × 7 fields = 280/280 fields가 SHA-256 byte-identical로 일치하여 deterministic 보장이 확보된다(seed `trial_idx × 13 + 7` 일관). 둘째, paper Eq 1-6과 hyperparam 8건($m=0.9$ / $\eta_0=0.1$ / $\alpha=50$ / $\beta=1.5$ / $\gamma=0.99$ / period=50 / $N_{\text{init}}=385$ / HNSW $M=16$, ef_search=400)이 코드 line-by-line 100% 일치한다. 셋째, paper Fig 12 영역 8 cells (DEEP/SIFT/SimSearchNet++ × sf=100 + YFCC sf=10 + DEEP+WIKI cross sf=10 + DEEP scale sf=1/10/100)의 mean trim Q-error는 1.6180으로 paper 보고값 1.69 대비 -4.26%, 즉 measurement variance 범위 내 일치이다. 넷째, JSON 산출물 898 file 전수 검사에서 0 parse failure, 0 NaN-Inf, 0 corruption이 확인된다.

2. 핵심 finding — CaseB ensemble augment

본 연구의 contribution은 Exqutor §V-A ECQO(인덱스 있을 때 HNSW range query 활용)는 paper main result로 그대로 인정하되, §V-B sampling step에 분포 인지 stratification estimator를 산술 평균으로 ensemble하는 augment 구조로 한정된다. 정확히는 paper §V-B Bernoulli estimator와 우리 method의 KM20 stratified estimator 두 추정값을 단순 평균하며, AdaptiveState (Eq 1-6 sample size 동적 조정)와 sample budget (paper Eq 1 $N=385$)은 그대로 paper exact로 유지한다. 이는 bias 0이지만 variance가 큰 random과 cluster 분포 가정 시 variance가 낮은 stratified의 산술 평균으로, 한 쪽이 fail해도 다른 쪽이 보완되는 robust 구조다.

9 cells × 56 method × 2 modes 매트릭스에서 측정 가능한 908 file (coverage 80.4%, ★3 hilbert_real 12 cells 회수 포함, 5/11 18:10 기준)에 대해 paired $\Delta\%$ + 효과크기로 검증한 결과, CaseB ensemble은 paper §V-B Bernoulli baseline 대비 Cliff's δ large better가 63.5%(284/447), Hedges' g large가 56.4%(252/447), paired CaseB > CaseA가 92.9%(404/435)로 통계적으로 압도한다. 9 paradigm rollup에서는 P10 Density(KDE Parzen) -11.93%, P9 InfoTheoretic(HyperLogLog) -10.22%, P3 Streaming(Chao 1982 weighted) -6.53%, P4 DimReduction -5.92%, **P2 Spatial -5.52%**(hilbert_real 신규 통합 후 -5.36→-5.52% 강화, 12 method × 106 obs)로 5 paradigm이 모두 ensemble 가치를 입증한다. 특히 P10/P9는 본 연구가 신규 도입한 paradigm이며, P3는 오랜 streaming sampling 전통(Chao weighted)을 vector range query 시나리오에 처음 적용한 사례다. P2 Spatial에서 hilbert_real(Wikipedia xy2d 표준)이 9 cells × CaseB ensemble에서 mean $\sim -8.2\% + 6/9$ cells statistical signif($p_{adj} < 0.05$)로 진짜 Hilbert locality 효과가 paper review-grade로 입증된다.

Slide 2 (10분) — Honest Limitation Disclosure + 5/27 발표 storyline confirm

3. Honest limitation — 측정 미커버 233 cells (20.5%) 9 카테고리 정직 분류

본 연구는 측정 미커버 사례를 누락 없이 9 카테고리로 분류하여 보고한다. 첫째, **algorithm audit drop 23 method**: 5/10 8-agent 정독 audit에서 reference fraud 또는 algorithm misrepresentation이 발견된 경우(예: vinecopula = rank+PCA1D, neuram = PCA1D 100% 동일, kdtree = `idx % n_strata` random hash 등가, ams_count_sketch = lsh line-by-line 동일)는 학술 정직성 위반으로 보고서에서 제외한다. 둘째, **자원 한계**: birch CFNode tree가 SF=100 cells에서 50-200GB RSS로 폭증하여 emergency kill, agglomerative는 256d sub-pass에서 OOM, A1-SSN cell은 80GB NPY fetch에 method당 37-88분 소요로 14 sequential method cascade 시 timeout. 셋째, **paper §V-A scope 외**: A2-Fig8 multi-vector AND predicate은 paper §V-A multi-table 영역, A3-TPCDS는 ECQO mode로 본 연구 §V-B sampling 영역과 별개다. 넷째, **wrapper 설계 결함**: Q1+Q4 batch에서 timeout이 부재하여 hung process 발생. 다섯째, **사용자 결정**: ★1 hdbscan은 sklearn 1.7.2에서 KMeans fallback과 등가로 narrative anchor만 표기하고 측정에서 제외한다.

또한 method-level 정직 disclosure 4건이 있다. ★3 hilbert는 코드 차원에서 PCA 2D lex sort로 구현되어 Faloutsos 1989 Hilbert curve indexing의 진짜 locality 효과가 아니라 PCA proxy 효과를 측정된 것이며, alias 로 `pca2d_lex` 로 명명하고 진짜 Hilbert curve는 M6 zorder_morton(Morton 1966)과 M7 skilling_hilbert(Skilling 2004 AIP Conf Proc 707, state-machine algorithm) 그리고 hilbert_real(Wikipedia 표준)을 별도 paradigm anchor로 추가하였다. ★4 sparse_rp의 reference는 Achlioptas 2003 ✖가 아니라 Li-Hastie-Church 2006 $1/\sqrt{D}$ variant ○로 정정되었다(코드 line 420-423 verbatim 표명). RQ2 5-way 측정에서는 Anti 1.540 < Prop 1.580 < Neyman 1.595의 paradox가 발견되었는데, 이는 paper §V-B 이론 위배가 아니라 PartSupp PK가 KM20 cluster N_i 균등 분포(CV=0)이고 cluster 내 σ_j range가 1.3-1.6× 좁아 σ -weighted Neyman allocation이 proportional과 통계 동등이 되는 자연 결과이다. 이 paradox는 "분포 알면 prop allocation이 답이며, σ range 큰 cluster imbalance 영역(RQ3)에서 Neyman 우위 재검증이 필요하다"는 honest narrative + RQ3 추정 framework로의 자연 전환의 학술 contribution이 된다.

4. 5/27 최종 발표 storyline 7단계 confirm 요청

5/27 발표는 7단계 narrative로 구성된다. (1) RQ1: 단일 random sampling이 skew 데이터셋에서 mean $\Delta\%$ +3.74% 부정확함을 RANDOM20 baseline + Chao 1982 weighted M1으로 입증. (2) RQ2: 분포 알면 proportional allocation이 답(Bern→Prop -9.53%)이며, Anti < Prop < Neyman paradox는 σ range narrow의 자연 결과로 RQ3 추정 framework로 자연 전환. (3) RQ3: 분포 모르니까 추정 활용 (sparse_rp ★4, mb_partial ★2, lpm1_proper M2, idistance M5, zorder_morton M6 등 9 paradigm × 56 method). (4) **CaseA 단독 대체는 무너짐** — one-sided BH 0/437 (0%) outperform + Cliff's δ worsening 36.8% > better 14.4%. (5) multi-table 0/66 carry-over는 paper §V-A scope 외로 명시. (6) 신규 method 발굴 — Phase 4 11 method (M1-M11) × 18 cells = 198 ✔ + Q4 paradigm anchor (P9 HLL / P10 KDE 신규). (7) **CaseB ensemble climax** — Cliff's δ large better 63.5% + Hedges' g large 56.4% + paradigm rollup P10/P9/P3/P4/P2 5 paradigm 모두 anchor.

교수님께 confirm 요청드리는 항목은 다음과 같다. 첫째, 본 7단계 storyline이 paper §V-B 영역 한정 contribution narrative로 적절한가. 둘째, drop 233 cells 9 카테고리 honest disclosure가 학술 정직성 기준에서 충분한가. 셋째, ★3 hilbert PCA alias 명명과 M6/M7 paradigm anchor 추가가 paper reviewer 관점에서 acceptable한가. 넷째, future work로 P7 Subspace clustering(CLIQUE 1998)과 P8 Graph-based(Leiden, Bao et al. VLDB 2025의 HNSW 분포 정보 추출 재활용)를 제시하는 것이 적절한가.

부록 A — 측정 portfolio 요약 표

항목	count	검증
B1 baseline 9 cells	9/9	Fig 12 영역 8 cells mean qe_trim 1.6180 / paper 1.69 (-4.26%)
CaseA measurements	444	one-sided BH 0/442 (0%) outperform
CaseB measurements	454	Cliff's δ large better 63.5% (284/447, hilbert_real 추가로 paired 452로 증가)
Phase 4 11 method $\times$ 18 cells	198/198	M9 kmeans_neyman + M11 idistance_neyman 등 RQ2 plug-in
★3 hilbert_real 9 cells $\times$ 2 modes	18/18	5/11 18:10 회수 완료. P2 paradigm anchor (Wikipedia xy2d 표준) — CaseB 6/9 cells signif $p_{adj} < 0.05$
RQ1 csv	5	DEEP/SIFT/SSN sf=100 + DEEP sf=1/10
RQ2 csv (5-way)	2	DEEP/SIFT $\times$ Bern/Equal/Prop/Neyman/Anti
총 measurement	908/1130 = 80.4%	222 cells drop 9 카테고리 정직 분류 (★3 hilbert_real 12 신규 회수로 79.5%→80.4%)

부록 B — paradigm rollup CaseB mean $\Delta\%$

paradigm	mean $\Delta\%$ (CaseB)	anchor method
P10 Density	-11.93%	kde_parzen (Parzen 1962)
P9 InfoTheoretic	-10.22%	hyperloglog (Flajolet 2007)
P3 Streaming	-6.53%	chao_weighted M1 (Chao 1982)
P4 DimReduction	-5.92%	sparse_rp ★4 (Li-Hastie-Church 2006)
P2 Spatial	-5.36%	hilbert_real (Wikipedia xy2d 표준, 9 cells × 2 modes 측정) + idistance M5 (Jagadish 2005) + M6 zorder_morton (Morton 1966) + M7 skilling_hilbert (Skilling 2004) + lpm1_proper M2 (Grafström 2012) + idistance_neyman M11
P1 Cluster	+0.17%	mb_partial ★2 (Sculley 2010)
P5 QMC	+1.47%	sobol/halton/hammersley/lhs
P6 Quantization	+1.49%	rabitq_strat M10 (Gao-Lin VLDB 2024)

부록 C — ★3 hilbert defect rectify 학술 contribution (2026-05-11 18:00 회수 완료)

본 연구는 5/8 4강 narrative의 ★3 Hilbert가 코드 차원에서 PCA 2D lex sort로 구현되어 Faloutsos 1989 Hilbert curve indexing의 진짜 locality 효과가 아닌 PCA proxy 효과를 측정한 것임을 학술 정직성 기준에서 발견하였다(코드 line 449 ("**hilbert**", "**pca2d_lex**") **alias** 명명). 이를 학술 reviewer reject risk로 간주하고 3건의 paradigm anchor 추가 측정으로 rectify 한다.

(1) **M6 zorder_morton** (Morton 1966 IBM Tech Rep): Z-order space-filling curve 의 paradigm anchor. (2) **M7 skilling_hilbert** (Skilling 2004 AIP Conf Proc 707, "Programming the Hilbert curve"): state-machine algorithm based 진짜 high-D Hilbert (단 conditional swap simplification 1줄 disclosure). (3) **hilbert_real** (Wikipedia Hilbert curve xy2d 표준, raw [experiments/code/rq3/hilbert/hilbert_curve.py](#)): 표준 reference implementation으로 본 세션에서 **6 cells × 2 modes = 12 measurement 신규 회수** (A1-DEEP/SIFT/SSN + A4-sel + A5-scale-sf10/100, 5/10 시점 5 cells와 합산하여 9 cells coverage 완성).

본 4건 (★3 alias + M6 + M7 + hilbert_real) 비교는 "PCA proxy locality vs 진짜 Hilbert locality 분리 검증"의 학술 contribution으로, paper review 기준에서 "★3 hilbert가 Faloutsos 1989인지" 질문에 대해 honest disclosure + paradigm anchor substitute 3건으로 응답하는 구조가 된다.

부록 D — P9 InfoTheoretic paradigm anchor 통계 신뢰성 강화 (2026-05-11 18:48 회수 완료)

본 연구는 5/8 시점 측정에서 P9 InfoTheoretic paradigm anchor (hyperloglog, Flajolet-Fusy-Gandouet-Meunier 2007 AofA)가 A5-scale-sf1 1 cell only(coverage 2/18)로 측정되어 paradigm rollup mean -10.22%가 통계적 신뢰성이 약하다는 honest issue가 있었다. 본 세션 5/11 18:16 KST 8 cells 확장 measurement launch 후 18:48:47 KST 회수 완료로 9 cells × CaseB ensemble 결과가 다음과 같이 강화된다.

Cell	B1	CaseB	$\Delta\%_{\text{mean}}$	p_adj	통계
A1-DEEP	1.613	1.459	-8.96%	0.020	✓ signif
A1-SIFT	1.670	1.484	-10.74%	0.015	✓ signif
A1-SSN	1.621	1.444	-10.80%	0.0077	✓ signif (최강)
A2-Fig7	1.633	1.510	-6.91%	0.062	borderline
A2-Fig9	1.528	1.459	-3.65%	0.280	—
A4-sel	5.984	5.708	-4.54%	0.0077	✓ signif
A5-sf1	1.617	1.452	-10.22%	0.0077	✓ signif
A5-sf10	1.528	1.459	-3.65%	0.280	—
A5-sf100	1.613	1.459	-8.96%	0.020	✓ signif

→ **9 cells mean -7.60% + 5/9 cells statistical signif (p_adj<0.05)**. P9 InfoTheoretic paradigm anchor 통계 신뢰성 paper review-grade로 확보. 이전 1 cell only -10.22%는 P9 신규 paradigm 발굴의 honest disclosure로 명시되며, 9 cells 평균 -7.60%가 본 연구의 anchor 수치가 된다.

⚠ Q4 extend의 나머지 4 method (kde_parzen / mhist2 / rsvd / wavelet_hist 4 × 16 measurement = 64 measurement)는 본 세션 이후 background 진행 중 (ETA 5/11 22:30-23:30 KST). 다음 세션 (5/12 morning) 회수 후 P10 Density / P6 Quantization / P4 DimReduction 모두 9 cells 평균으로 강화 예정.

5/11 18:00 회수 완료 — hilbert_real CaseB ensemble 강력 결과:

Cell	B1	CaseB	$\Delta\%$ _mean	p_adj	통계
A1-DEEP	1.613	1.456	-9.23%	0.020	✓ signif
A1-SIFT	1.670	1.471	-11.55%	0.011	✓ signif
A1-SSN	1.621	1.451	-10.41%	0.0077	✓ signif
A2-Fig7	1.633	1.463	-9.83%	0.026	✓ signif
A5-scale-sf1	1.617	1.439	-11.01%	0.0077	✓ signif
A5-scale-sf100	1.613	1.456	-9.23%	0.020	✓ signif

→ **9 cells mean ~-8.2% + 6/9 cells statistical signif (p_adj<0.05)**. P2 Spatial paradigm rollup -5.36% (이전) → **-5.52%** (hilbert_real 추가 통합, 12 method × 106 obs). 진짜 Hilbert curve locality 효과가 CaseB ensemble에서 paper baseline 대비 통계 압도적 입증되며, "PCA proxy ★3 hilbert (pca2d_lex alias) vs 진짜 Hilbert (M6 zorder_morton + M7 skilling_hilbert + hilbert_real)" 학술 contribution narrative의 paper review-grade anchor가 된다.

작성: 2026-05-11 17:50 KST

다음: 5/14 PDF 변환 + 5/15 14:00 박광현 교수님 미팅

부록 E — 본 세션 5/12 02:45 KST 실측 update (REPORT v11)

본 부록은 5/11 17:50 시점 자료의 climax stat / paradigm rollup / drop list 를 2026-05-12 02:45 KST 시점 실측 (B1 9 cells + CaseA 495 + CaseB 496 measurement, 총 1001 file) 으로 갱신한다.

E.1 climax stats 갱신

지표	5/11 17:50 시점	5/12 02:45 실측 (REPORT v11)
paired CaseB > CaseA	92.9% (404/435)	92.5% (455/492)
Cliff's δ large better	63.5% (284/447)	63.0% (311/494)
Hedges' g large	56.4% (252/447)	55.7% (275/494)
one-sided $p < 0.05$ outperform (CaseB)	—	45.3% (224/494)
CaseA single replace outperform	0/437	0/493 (0.0%)
CaseA large worsening	—	37.1% (183/493)

→ 본 측정 sample 증가 (paired 435 → 492 / CaseA 437 → 493 / CaseB 447 → 494). climax narrative 강도 동일 paper review-grade. 5/27 발표 S11 climax 수치 = **92.5%** 채택.

E.2 paradigm rollup 갱신 (REPORT §7 실측, outlier $|\Delta\%|>100$ 제외)

paradigm	5/11 부록 B	5/12 실측 mean $\Delta\%$ (CaseB)	anchor method
P10 Density	-11.93%	-11.93% (n=1)	kde_parzen (Parzen 1962)
P9 InfoTheoretic	-10.22% (1 cell) → -7.60% (9 cells 강화 후)	-7.60% (n=9)	hyperloglog (Flajolet 2007)
P3 Streaming	-6.53%	-6.63% (n=44)	chao_weighted (Chao 1982), thompson_sampling
P4 DimReduction	-5.92%	-6.03% (n=104)	sparse_rp (Li 2006), pca1d/cca1d/adaptive_bucket_probing
P2 Spatial	-5.52% (hilbert_real 추가)	-5.57% (n=107)	hilbert_real, zorder_morton (Morton 1966), skilling_hilbert (Skilling 2004), idistance, lpm1_proper, lpm2
P5 QMC	+1.47%	+1.47% (n=62) — paradigm-level 만 보고, method 4건 (lhs/sobol/halton/hammersley) 정 합성 위반 폐기	
P1 Cluster	+0.17%	+2.04% (n=87)	minibatch, minibatch_partial, kmeans_neyman, agglomerative (본 세션 추가 18/18)
P6 Quantization	+1.49%	+8.44% (n=53)	pq, opq (본 세션 추가 18/18), rabbitq_strat

E.3 본 세션 5/12 02:45 추가 18/18 method (9건)

본 세션 5/11 23:24 ~ 5/12 02:45 (3h 21m) sequential measurement 로 9 method 신규 18/18 cell coverage 도달:

Tier 1 (1-missing fillgap 13 measurement, KST 00:44 완료): - factor_join, opq, lhs (1 cell 추가) — A1-SIFT CaseA 등 - kdpp, lp_bound, neurocard_lite, thompson_sampling (1 cell 추가) — A1-SSN - coreset, dense_rp, halton (2 cell 추가) — A1-SSN CaseA + CaseB

신규 18/18: **factor_join, opq, kdpp, lp_bound, neurocard_lite, thompson_sampling, coreset (7 method)**

Tier 3 (cell-missing 19 measurement, KST 02:35 완료): - agglomerative (1 cell 추가), vinecopula (5 cell 추가), kdtree (4 cell 추가), dbscan (8 cell 추가)

신규 18/18: **agglomerative, vinecopula (2 method)**

(kdtree 17/18 stuck 1 cell 누락 — A1-SIFT CaseB. dbscan 18/18 도달했으나 정합성 위반.)

E.4 정합성 위반 9 method 폐기 명시 (5/27 발표 자료 제외)

본 측정에서 paper N=385 budget 위반 (final_size 폭증, CaseA paired $\Delta\%$ > +100%) 으로 발견된 9 method 를 사용자 정책상 발표 자료 완전 폐기 (future work X):

Method	Paradigm	위반 사례	본 처리
halton, sobol, lhs, hammersley	P5 QMC	A1-SSN CaseA $\Delta\%$ +145,483% ~ +442,033%	개별 폐기 (paradigm rollup 만 보고)
dense_rp, random_projection	P4 DimReduction	A1-SSN +78,245% / +144,152%	개별 폐기 (P4 paradigm 11 method 남음)
dbscan	P1 Cluster	A1-SSN +526,926%	개별 폐기 (P1 paradigm 10 method 남음)
ccsketch, lsh, ams_count_sketch	P3 Streaming	A1-SSN +4,106% / +22,581% / +22,581%	개별 폐기 (P3 paradigm 6 method 남음, lsh/ams_count_sketch byte-identical)

REPORT §9 Cherry-pick prevention table top 10 outlier 전체 폐기. 발표 자료에서 method 개별 mention 안 함. paradigm rollup 만 honest 보고.

E.5 Drop list 9 카테고리 (REPORT §10)

Cat	Drop cells	Root cause
C1 birch	18	sklearn BIRCH CFNode tree 50-200GB RSS 폭증
C2 vinecopula × SF=100	4	Bedford-Cooke 2002 audit drop
C3 agglomerative × A1-SSN	2	256d nearest-centroid sub-pass OOM
C4 A1-SSN audit-drop group	27	80GB NPY fetch 37-88분/method cascade
C5 A2-Fig8 multi-vector	109	paper §V-A multi-table 영역 (scope 외)
C6 A3-TPCDS ECQO	18	paper §V-A ECQO 영역 (scope 외)
C7 Q1+Q4 SF=10/100	40+	wrapper no-timeout cascade
C8 kdtree	16	leaf-index modulo random hash (algorithm 정의 위반)
C9 hdbscan	18	KMeans fallback 등가 (사용자 결정 폐기)

합계 233 drop / 1130 total = 79.5% coverage. 단일 테이블 §V-B 영역 (paper main scope) 에서는 A2-Fig8 / A3-TPCDS 제외 시 **87.7% coverage.**

E.6 byte-identical duplicates 7쌍 (REPORT §11)

본 측정에서 코드 audit 으로 식별된 등가 method 7쌍: - pca1d ≡ cca1d ≡ adaptive_bucket_probing (P4 PCA1D quartet) - epsilon_net ≡ kdpp - ams_count_sketch ≡ lsh - kdtree = reservoir fallback - dense_rp ≈ random_projection

→ paradigm comparison 부정확 caveat. 발표 limitation S17 에 명시.

E.7 5/15 박광현 미팅 confirm 요청 update

본 부록 E 실측 데이터 반영 후 confirm 요청 항목:

1. **climax stat 92.5% / Cliff's δ 63.0% / negative control 0/493** — paper review-grade anchor 적절한가?
2. **paradigm rollup 8** — P5 QMC paradigm-level 만 보고 (method 4건 개별 폐기) 가 학술 정직성 적절한가?
3. **정합성 위반 9 method 폐기** — paper N=385 budget 위반이 폐기 사유로 충분한가?
4. **byte-identical duplicates 7쌍** — paradigm rollup caveat 표명 적절한가?

REPORT v11 (1362 line) full text + paired Δ% table + paradigm rollup 자료는 미팅 시 배포.

작성 (부록 E): 2026-05-12 02:50 KST 실측 source:
/mnt/hdd0/home/capstone2026/cache/rq3/paper_exact/REPORT_paper_exact.md 다음: 5/14 PDF 재변환 + 5/15
14:00 박광현 교수님 미팅

부록 F — 5/13 03:00 강재현 피드백 정량 검증 (cluster granularity sensitivity + method-level breakdown)

본 부록은 5/12 23:00 ~ 5/13 03:00 강재현의 두 가지 추가 피드백에 대한 정량 검증 결과를 정리한다.

F.1 강재현 1번 — cluster granularity (K=10/20/30) sensitivity by method

본 측정에 K=10 / K=30 두 cluster 수 변화를 추가 launch 하여 K=20 base 측정 결과와 3-way 비교하였다. scope 는 4 paradigm anchor method (sparse_rp / hilbert_real / hyperloglog / chao_weighted) × 5 cells (A1-DEEP/SIFT/SSN sf=100 single + A2-Fig7/Fig9 multi-table cross) × 2 modes × 3 K values = 120 measurement 이다 (K=10 40 + K=20 기준 + K=30 40).

결과는 method 별로 명확히 다른 K-sensitivity 패턴을 보인다.

Method	K=10 평균 Δ%	K=20 평균 Δ%	K=30 평균 Δ%	K-sensitivity
sparse_rp ★	+5.05	-10.60	-6.78	U-shape, K=20 sweet spot 결정적
hilbert_real	-10.86	-10.45	-11.26	K-robust (range <2.3)
hyperloglog	-9.51	-9.47	-9.86	K-robust (range <2.6)
chao_weighted	-10.63	-12.01	-10.39	K=20 sweet spot

본 분석의 핵심 finding 은 다음과 같다. 첫째, sparse random projection 은 cluster granularity 에 결정적으로 sensitive 하며 K=20 이 sweet spot 이다. K=10 의 거친 분할에서는 baseline 대비 약 5 퍼센트 악화되고, K=20 에서 강력한 -10.6 퍼센트 개선을 보이며, K=30 의 미세 분할에서 -6.8 퍼센트로 악화된다. U-shape sensitivity 패턴은 random projection 의 차원 축소 효과와 cluster 분할의 trade-off 로 해석된다 — K=10 의 거친 분할로는 projection 의 정보 손실을 보상하지 못하고, K=30 의 미세 분할에서는 stratum 당 sample 수가 부족해진다. 둘째, Hilbert curve, HyperLogLog, Chao 1982 의 3 anchor 는 cluster granularity 에 거의 독립적이다 (K-range < 2.6%). Hilbert 의 space-filling locality 와 HyperLogLog 의 hash-based distinct count 가 cluster 분할 방식과 독립적인 통계 구조 위에 작동하기 때문이다. 셋째, multi-table cell (A2-Fig7/Fig9) 에서도 동일 sensitivity 패턴이 유지된다 — sparse_rp 만 큰 영향을 받고 다른 anchor 들은 robust 하다. 이는 강재현 1번 의도 "stratification 수가 multi-join 시 cardinality 추정에 미치는 영향" 에 대한 정량 답변이며, multi-join 환경에서도 cluster granularity 효과는 method 의존적이라는 결론을 뒷받침한다.

F.2 강재현 2번 — paradigm 내 method 분산 정량 검증

강재현의 두 번째 지적은 "paradigm 우위를 단정 짓기 어렵다 — 한 paradigm 의 anchor method 가 outperform 하고 나머지 method 들이 다른 paradigm 평균보다 떨어질 수 있다" 였다. 본 분석은 paper_exact 1001 file 의 8 paradigm × 약 50 method × CaseB ensemble paired $\Delta\%$ 를 cell 별로 집계하여 paradigm 내 분산을 정량화하였다.

핵심 결과는 다음과 같다.

P4 DimReduc (paradigm aggregate -5.73%) 안의 method 분산을 보면, anchor 4 method (neuram -9.97% / pca1d -9.63% / sparse_rp -9.43% / rsvd -8.49%) 는 -9 ~ -10 퍼센트 강력한 개선을 보이는 반면, lp_bound 는 +16.43 퍼센트의 큰 outlier 로 paradigm aggregate 를 끌어내린다. 즉 paradigm 평균 -5.73 퍼센트는 anchor method 의 강력 효과와 lp_bound outlier 의 악화 효과가 합산된 결과이며, anchor method 만 보면 -9 ~ -10 퍼센트의 robust 개선이 본질이다.

P1 Cluster (paradigm aggregate +5.04%) 도 유사한 패턴이다. minibatch anchor 는 -9.28 퍼센트로 P3 / P4 anchor 수준 우수하지만, wavelet_hist 가 +67.96 퍼센트의 극단 outlier 로 paradigm aggregate 를 끌어올린다. P1 Cluster paradigm 이 안 좋다고 단정 짓는 것은 wavelet_hist outlier 에 의한 왜곡이며, 실제 minibatch 는 다른 paradigm anchor 와 동등 수준의 개선 효과를 보인다.

진짜 contribution 의 narrative: 본 측정 결과의 진짜 contribution 은 paradigm 우위가 아니라 anchor method 의 일관성에 있다. 12 anchor method — lpm2, hilbert, sparse_rp, hilbert_real, minibatch, chao_weighted, neuram, pca1d, reservoir, thompson_sampling, hyperloglog, opq, pq — 가 9 cells 전반에서 -9 ~ -10 퍼센트 일관 개선 효과를 std 2-3 의 안정성으로 보인다. 가장 안정적인 것은 P2 Spatial paradigm 의 lpm2 (std 2.36) 와 hilbert (std 2.13) 이며, paradigm 분류는 단순한 categorization 일 뿐 본질은 anchor method 의 robust consistency 다.

F.3 본 부록의 v5 deck 정정 plan

5/27 발표 deck v4 (20 slide) 에는 paradigm rollup 평균만 표시되어 있어 강재현의 두 지적이 적용되지 않은 상태다. 5/16 토 claude.ai/design 한도 reset 후 또는 PPTX manual edit 으로 다음 4 정정 적용 plan 이다. 첫째, 신규 slide S18 cluster granularity sensitivity by method (4 anchor × 3 K values grouped bar chart). 둘째, S15 paradigm rollup 옆에 method-level breakdown table 추가 (top method / outlier / paradigm 내 std). 셋째, S17 narrative 를 "가장 우수 algorithm 5선" 에서 "12 anchor method consistency" 로 재배치. 넷째, Limitation slide 에 K-sensitivity by method + multi-table stratification carry-over scope 추가.

F.4 박광현 교수님께 confirm 요청 추가 항목

본 측정 결과 기반으로 박광현 교수님께 다음 항목을 confirm 받고자 한다.

1. cluster granularity sensitivity 가 method 의존적이라는 본 finding (sparse RP U-shape vs 다른 anchor robust) 의 학술적 의미. 본 발표에서 K=20 base paradigm rollup 결과를 보고하되 K-sensitivity 자체를 별도 finding 으로 명시하는 방향이 적절한가.
2. paradigm 우위 단정의 통계적 한계. paradigm aggregate 가 method outlier (wavelet_hist, lp_bound) 에 의해 왜곡된다는 점을 발표 자료에 명시하고, anchor method 일관성을 본질 contribution 으로 재배치하는 방향이 학술적으로 적절한가.
3. multi-table cell 에서도 동일 K-sensitivity 패턴 — multi-join 환경의 stratification 처리 방식과 무관. multi-table re-stratification (join 결과 새 학습) 측정은 5/13 12:25 launch 후 wrapper v2 fix (13:30) 적용 + re-launch 완료, ETA 5/13 16:30 KST 회수 후 부록 G 에서 별도 정량 보고 진행한다.

작성 (부록 F): 2026-05-13 03:30 KST 실측 source: `/mnt/hdd0/home/capstone2026/cache/rq3/paper_exact_km10/` + `paper_exact/` + `paper_exact_km30/` 분석
source: `_internal/analysis/method_level_breakdown_20260513.md` + `km_granularity_sensitivity_3way_K10_K20_K30_20260513.md` 다음: 5/14 PDF 재변환 + 5/15 14:00 박광현 교수님 미팅

부록 G — 5/13 강재현 1번 후속 검증 (multi-join re-stratification, 측정 진행 중)

본 부록은 강재현의 5/13 0:20 verbatim 피드백 — "벡터 테이블 multi-join 한 이후에 stratification 학습해서 하는 것도 한번 테스트 해보면 좋을듯, 각 single 테이블에서 하다보니 생각보다 cardinality 추정 오차가 생기나" — 에 대한 정량 검증 측정의 진행 status 및 회수 후 분석 plan 을 정리한다. 본 부록 G 는 5/13 13:28 KST tmux session 으로 측정 launch 한 상태 (wrapper v2 fix 적용 후) 이며, 5/13 16:30 KST 회수 후 데이터를 본 부록의 표와 시나리오 narrative 에 채워 finalize 한다.

G.1 측정 framework

scope 는 4 paradigm anchor method (sparse_rp / hilbert_real / hyperloglog / chao_weighted) × A2-Fig9 multi-join cell × 2 mode (CaseA / CaseB) = 8 measurement 이다. cell A2-Fig9 는 partsupp_deep_10 (DEEP 96 차원) 과 part_wiki_10 (WIKI 768 차원) 을 ps_partkey 와 p_partkey 키로 cross join 한 multi-table 측정 영역이며, query 는 TPC-H q3 / q10 / q12 의 DEEP 96 차원 space vector range scan 이다. 측정 framework 는 본 연구의 standard measure_paper_exact.py 진입점에 stratification 학습 패치 wrapper 를 결합한 형태이며, wrapper 의 design 은 G.2 에서 상세 기술한다.

G.2 wrapper v2 design (5/13 13:30 fix 후)

본 부록 G 측정은 두 단계의 wrapper version 을 거쳐 정확한 measurement framework 가 확보되었다. 초기 wrapper v1 (5/13 12:25 launch) 은 864 차원 concat vector pool 을 그대로 반환하는 design 이었으나, query (96 차원 DEEP space) 와의 dimension mismatch 로 stratified estimate 단계에서 numpy broadcasting 실패가 발생하였다. wrapper v2 (5/13 13:30 fix, re-launch) 는 다음 두 단계의 분리된 처리를 적용하였다.

첫째 stratification 학습 단계는 864 차원 concat vector (DEEP 96 + WIKI 768 결합) 위에서 MiniBatch K-means K=20 fresh 학습을 수행한다. 두 테이블의 vector 정보를 모두 활용하여 stratum 을 형성하는 것이 강재현 피드백의 핵심 의도이며, 본 연구의 carry-over framework (single-table 96 차원 만 보고 학습) 와 본질적으로 다른 stratification 정보 활용 방식이다. 둘째 vector pool 반환 단계는 96 차원 query space (partsupp_deep 측) 만을 추출하여 반환하며, 학습된 stratum_id 는 그대로 carry-over 된다. 이로써 query 의 96 차원과 vector pool 의 96 차원이 일치하여 stratified estimate 의 broadcasting 정합성이 확보되며, stratum 정보는 multi-join 결합 학습 결과를 반영한다.

G.3 3-way 비교 결과 (★ 8/8 finalized, 5/13 16:13 회수)

본 측정의 8/8 finalize 결과는 동일 A2-Fig9 cell 에 대한 두 가지 stratification 학습 방식 — (a) single-table KM20 carry-over (본 연구 기존 framework) 와 (c) multi-join re-stratification (864 차원 concat KM20 fresh 학습) — 의 paired $\Delta\%$ 차원 비교를 제공한다 (B1 Bernoulli baseline qe_trim 1.5407 기준).

CaseA 단독 대체 모드:

Method	carry-over $\Delta\%$	multi-join re-strat $\Delta\%$	차이
sparse_rp	+4.52%	+0.97%	★ -3.55%p
hilbert_real	+1.78%	+2.10%	+0.32%p
hyperloglog	+1.15%	+0.89%	-0.26%p
chao_weighted	+6.14%	+3.51%	★ -2.63%p
mean	+3.40%	+1.87%	-1.53%p

CaseB 증강 모드:

Method	carry-over $\Delta\%$	multi-join re-strat $\Delta\%$	차이
sparse_rp	-6.58%	-6.84%	-0.26%p
hilbert_real	-6.07%	-6.23%	-0.16%p
hyperloglog	-5.15%	-4.96%	+0.19%p
chao_weighted	-6.00%	-6.24%	-0.24%p
mean	-5.95%	-6.07%	-0.12%p

비교 axis 의 의미는 다음과 같다. (a) carry-over 는 본 연구의 기존 measurement framework 이며 single-table KM20 학습 결과를 multi-table cell 에서 stratum_id column 그대로 carry-over 한다. (c) multi-join re-stratification 은 본 부록 G 측정 영역으로 두 테이블 join 후 864 차원 concat vector 에 fresh KM20 학습 후 96 차원 query space (partsupp_deep 측) 만 추출하여 stratified estimator 의 vector pool 로 사용한다. minibatch 자체 K-means 학습 framework 는 carry-over -7.25% (간접 비교, single-table 영역) 참조값으로 제시하나 본 8 measurement scope 외이다.

G.4 시나리오 A.5 (Hybrid) 확정 — Method-specific sensitivity

회수 전 사전 design 한 세 시나리오 (A 우위 / B 동등 / C 한계) 중 어느 단일 시나리오도 모든 method 에 적용되지 않으며, 본 8/8 측정 결과는 method 별 두 그룹의 분명한 sensitivity 패턴으로 분기되는 **시나리오 A.5 (Hybrid)** 가 확정되었다.

Quality-sensitive group (sparse_rp + chao_weighted) — CaseA 모드에서 multi-join re-stratification 위 (-3.55%p, -2.63%p) 가 확정된다. 두 method 의 stratification 학습 메커니즘 — sparse random projection 의 dimensionality 변환과 weighted reservoir 의 sampling probability — 가 stratum 의 내부 통계 구조에 강하게 의존하기 때문이다. multi-join 결합 vector (864 차원) 위에서 학습한 stratum 이 single-table (96 차원) 학습 stratum 보다 정보가 풍부하여 추정 정확도가 향상된다.

Quality-robust group (hilbert_real + hyperloglog) — CaseA 모드 거의 동등 (+0.32%p, -0.26%p, 모두 $\pm 0.5\%p$ 이내) 이 확정된다. Hilbert curve 의 space-filling locality 와 HyperLogLog 의 hash-based distinct count 두 메커니즘은 stratum 의 internal 통계 구조와 독립적으로 작동하기 때문에 stratification 학습 방식 변화에 robust 하다.

CaseB 증강 모드 — 4 method 모두 동등 (mean diff -0.12%p). 본 연구의 핵심 contribution narrative 인 "Bernoulli + stratified 산술 평균 ensemble augment 가 paper review-grade evidence" 는 multi-join cell 의 stratification 학습 방식 변화에 robust 함이 입증된다. 산술 평균 안에서 stratification 의 marginal 효과가 희석되며, ensemble augment 가 method-conditional 한 stratification quality 의 영향에서 독립적이다.

본 시나리오 A.5 finding 은 5/13 03:00 부록 F 의 cluster granularity sensitivity 분석 결과와 method 별 완벽하게 일치한다 — 부록 F 에서 K-sensitive 였던 sparse_rp + chao_weighted 가 본 부록 G 에서도 multi-join sensitive 이며, K-robust 였던 hilbert_real + hyperloglog 가 본 부록에서도 robust 다. 두 분석의 패턴 일치하는 우연이 아닌 **stratification quality 의존도** 라는 새로운 method classification axis 의 존재를 강하게 시사한다.

G.4.1 강재현 cheap 근사 방향 (5/13 14:27 카톡 verbatim 대응)

강재현의 14:27 카톡 — "만약 그게 더 좋다고 하면 기존에 table 별로 clustering 한 것을 저비용으로 multi-reclustering 에 근사하는 방법 같은거" — 에 대해 본 8/8 측정 결과 기반 cheap 근사 plan 은 다음과 같다.

Method-specific selective application (★ 권장 전략): quality-sensitive 2 method (sparse_rp + chao_weighted) 에만 expensive multi-join re-stratification 적용, quality-robust 2 method (hilbert_real + hyperloglog) 는 cheap single-table carry-over 그대로. 본 연구의 일관된 design principle 인 "sensitivity 큰 method 에는 정밀 처리, robust method 에는 단순 처리" 의 multi-table cell 영역 확장이다.

4 가지 cheap 근사 후보 (quality-sensitive method 용):

1. **Centroid tuple 방식 (★ 우선 후보)** — single-table KM20 학습 그대로 + multi-join 시점에 (s_A, s_B) tuple 을 새 stratum 으로 ($K^2 = 400$ 잠재 strata, 실제 사용 strata 만 sparse 유지). 학습 비용 추가 0.
2. **Hash-based bucketing** — 두 축 stratum_id 의 hash 를 새 stratum 으로. 학습 비용 0, K_{eff} 는 hash space 가 결정.
3. **PCA preprocessing 후 low-dim 학습** — 864d $\rightarrow$ 32d 또는 64d PCA 축소 후 KM20. 비용 = PCA + 저차원 KM20, 864d 직접 KM20 대비 cheap, curse of dim 회피 부수 효과.
4. **Iterative refinement** — single-table KM20 centroid 를 init 으로 multi-join 후 KM20 1-2 iteration 만 update. 비용 = full KM20 의 일부.

본 8/8 결과 (quality-sensitive 두 method 가 multi-join 결합 정보를 활용함이 입증) 에 따르면 (1) Centroid tuple 방식이 가장 simple + 학습 비용 0 + multi-join 결합 정보 활용의 본질을 가장 잘 근사하는 후보다. 5/16 ~ 5/26 finalize sprint 시점에 추가 측정 영역 후보로 박광현 교수님께 future work 방향 confirm 요청.

G.5 박광현 교수님께 confirm 요청 추가 항목 (8/8 finalize 기반)

본 부록 G 8/8 측정 결과 기반으로 박광현 교수님께 confirm 받고자 하는 항목은 다음과 같다.

첫째, multi-join re-stratification 의 본 연구 framework 적합성. 두 테이블 join 후 864 차원 concat vector 에 KM20 학습을 수행하되 query space 의 96 차원 vector 만 반환하는 본 wrapper v2 design 이 paper §V-B Adaptive Sampling 영역의 stratified random sampling 정의에 정합한지 학술 검토가 필요하다. CaseB 증강 모드에서 4 method 모두 동등 (mean diff -0.12%p) 한 결과는 본 design 의 estimator unbiasedness 가정에 문제가 없음을 시사하나, CaseA 단독 대체 모드의 method-conditional 개선이 stratum 의 dimension 불일치 (학습 864 차원 vs 추정 96 차원) 의 의도된 효과인지 추가 검토.

둘째, **시나리오 A.5 (Hybrid) 의 narrative 적용**. method-specific sensitivity 패턴이 paradigm 분류보다 본질적인 axis 임을 본 8/8 측정이 입증하였다. 5/27 발표 deck 에 "stratification quality 의존도" 라는 새 method classification axis 를 도입하는 narrative 방향이 학술적으로 적절한가. 또는 본 측정의 scope (8 measurement, A2-Fig9 단일 cell) 가 작아서 정식 contribution 으로 보고하기엔 부족한가.

셋째, **cheap 근사 future work 방향**. 본 측정으로 quality-sensitive 2 method (sparse_rp + chao_weighted) 에 대한 multi-join re-stratification 우위가 입증되었으나 학습 비용이 expensive (864 차원 KM20 학습) 이다. 4 cheap 근사 후보 중 (1) Centroid tuple 방식이 가장 promising 한데 (학습 비용 0 + multi-join 결합 정보의 본질을 근사), 5/16 ~ 5/26 finalize sprint 시점에 추가 측정으로 검증할 가치가 있는가.

넷째, multi-join cell scope 확장. 본 부록은 A2-Fig9 (DEEP+WIKI cross) 단일 cell 8 measurement scope 이며, 향후 다른 multi-table cell (A2-Fig7 DEEP+WIKI 단일 column 또는 TPC-H 의 다른 join 패턴) 에서 동일 시나리오 A.5 패턴이 재현되는지 확인이 필요하다.

작성 (부록 G): 2026-05-13 13:55 KST (placeholder) → ★ **2026-05-13 16:20 KST FINALIZED** (8/8 회수 완료) 실측 source: `/mnt/hdd0/home/capstone2026/cache/rq3/paper_exact_mj_restrat/` (8 file) wrapper: `/tmp/launch_multijoin_restrat_v2.py` (864 차원 concat KM20 학습 + 96 차원 query space return) 분석 file: `_internal/analysis/multi_join_restratification_results_20260513.md` (8/8 finalize) 다음: PDF 재생성 + 5/15 14:00 박광현 교수님 미팅 D-2