

박광현 교수님 미팅 — 속도는벡터 (Exqutor §V-B 측정 보고)

일시: 2026-05-15 (금) 14:00 **참석:** 박광현 교수님 / 박세은(팀장) / 강재현 / 조현빈 / 이동욱 **소요:** ~30분
(slide 2장 + Q&A) **준비:** paper exact 측정 완료 보고 + honest limitation disclosure + 5/27 발표 storyline confirm

Slide 1 (10분) — Exqutor §V-B Adaptive Sampling 영역 paper exact 재현 측정 완료 보고

1. 측정 정합성

본 연구는 Exqutor 논문(arXiv:2512.09695v2)의 §V-B Adaptive Sampling 영역, 즉 vector index 부재 시 Bernoulli random sampling과 모멘텀 기반 동적 sample size 조정(Eq 1-6)에 대해 paper의 모든 hyperparam, query 정의, threshold, trim 통계를 verbatim으로 재현하였다. 측정 자체의 정합성은 4측에서 paper review-grade로 검증된다. 첫째, Reproducibility 검증에서 4 cells × 10 trials × 7 fields = 280/280 fields가 SHA-256 byte-identical로 일치하여 deterministic 보장이 확보된다(seed `trial_idx × 13 + 7` 일관). 둘째, paper Eq 1-6과 hyperparam 8건($m=0.9$ / $\eta_0=0.1$ / $\alpha=50$ / $\beta=1.5$ / $\gamma=0.99$ / period=50 / $N_{\text{init}}=385$ / HNSW $M=16$, ef_search=400)이 코드 line-by-line 100% 일치한다. 셋째, paper Fig 12 영역 8 cells (DEEP/SIFT/SimSearchNet++ × sf=100 + YFCC sf=10 + DEEP+WIKI cross sf=10 + DEEP scale sf=1/10/100)의 mean trim Q-error는 1.6180으로 paper 보고값 1.69 대비 -4.26%, 즉 measurement variance 범위 내 일치이다. 넷째, JSON 산출물 898 file 전수 검사에서 0 parse failure, 0 NaN-Inf, 0 corruption이 확인된다.

2. 핵심 finding — CaseB ensemble augment

본 연구의 contribution은 Exqutor §V-A ECQO(인덱스 있을 때 HNSW range query 활용)는 paper main result로 그대로 인정하되, §V-B sampling step에 분포 인지 stratification estimator를 산술 평균으로 ensemble하는 augment 구조로 한정된다. 정확히는 paper §V-B Bernoulli estimator와 우리 method의 KM20 stratified estimator 두 추정값을 단순 평균하며, AdaptiveState (Eq 1-6 sample size 동적 조정)와 sample budget (paper Eq 1 $N=385$)은 그대로 paper exact로 유지한다. 이는 bias 0이지만 variance가 큰 random과 cluster 분포 가정 시 variance가 낮은 stratified의 산술 평균으로, 한 쪽이 fail해도 다른 쪽이 보완되는 robust 구조다.

9 cells × 56 method × 2 modes 매트릭스에서 측정 가능한 908 file (coverage 80.4%, ★3 hilbert_real 12 cells 회수 포함, 5/11 18:10 기준)에 대해 paired $\Delta\%$ + 효과크기로 검증한 결과, CaseB ensemble은 paper §V-B Bernoulli baseline 대비 Cliff's δ large better가 63.5%(284/447), Hedges' g large가 56.4%(252/447), paired CaseB > CaseA가 92.9%(404/435)로 통계적으로 압도한다. 9 paradigm rollup에서는 P10 Density(KDE Parzen) -11.93%, P9 InfoTheoretic(HyperLogLog) -10.22%, P3 Streaming(Chao 1982 weighted) -6.53%, P4 DimReduction -5.92%, **P2 Spatial -5.52%**(hilbert_real 신규 통합 후 -5.36→-5.52% 강화, 12 method × 106 obs)로 5 paradigm이 모두 ensemble 가치를 입증한다. 특히 P10/P9는 본 연구가 신규 도입한 paradigm이며, P3는 오랜 streaming sampling 전통(Chao weighted)을 vector range query 시나리오에 처음 적용한 사례다. P2 Spatial에서 hilbert_real(Wikipedia xy2d 표준)이 9 cells × CaseB ensemble에서 mean $\sim -8.2\% + 6/9$ cells statistical signif($p_{adj} < 0.05$)로 진짜 Hilbert locality 효과가 paper review-grade로 입증된다.

Slide 2 (10분) — Honest Limitation Disclosure + 5/27 발표 storyline confirm

3. Honest limitation — 측정 미커버 233 cells (20.5%) 9 카테고리 정직 분류

본 연구는 측정 미커버 사례를 누락 없이 9 카테고리로 분류하여 보고한다. 첫째, **algorithm audit drop 23 method**: 5/10 8-agent 정독 audit에서 reference fraud 또는 algorithm misrepresentation이 발견된 경우(예: vinecopula = rank+PCA1D, neuram = PCA1D 100% 동일, kdtree = `idx % n_strata` random hash 등가, ams_count_sketch = lsh line-by-line 동일)는 학술 정직성 위반으로 보고서에서 제외한다. 둘째, **자원 한계**: birch CFNode tree가 SF=100 cells에서 50-200GB RSS로 폭증하여 emergency kill, agglomerative는 256d sub-pass에서 OOM, A1-SSN cell은 80GB NPY fetch에 method당 37-88분 소요로 14 sequential method cascade 시 timeout. 셋째, **paper §V-A scope 외**: A2-Fig8 multi-vector AND predicate은 paper §V-A multi-table 영역, A3-TPCDS는 ECQO mode로 본 연구 §V-B sampling 영역과 별개다. 넷째, **wrapper 설계 결함**: Q1+Q4 batch에서 timeout이 부재하여 hung process 발생. 다섯째, **사용자 결정**: ★1 hdbscan은 sklearn 1.7.2에서 KMeans fallback과 등가로 narrative anchor만 표기하고 측정에서 제외한다.

또한 method-level 정직 disclosure 4건이 있다. ★3 hilbert는 코드 차원에서 PCA 2D lex sort로 구현되어 Faloutsos 1989 Hilbert curve indexing의 진짜 locality 효과가 아니라 PCA proxy 효과를 측정한 것이며, alias 로 `pca2d_lex` 로 명명하고 진짜 Hilbert curve는 M6 zorder_morton(Morton 1966)과 M7 skilling_hilbert(Skilling 2004 AIP Conf Proc 707, state-machine algorithm) 그리고 hilbert_real(Wikipedia 표준)을 별도 paradigm anchor로 추가하였다. ★4 sparse_rp의 reference는 Achlioptas 2003 ✖가 아니라 Li-Hastie-Church 2006 $1/\sqrt{D}$ variant ○로 정정되었다(코드 line 420-423 verbatim 표명). RQ2 5-way 측정에서는 Anti 1.540 < Prop 1.580 < Neyman 1.595의 paradox가 발견되었는데, 이는 paper §V-B 이론 위배가 아니라 PartSupp PK가 KM20 cluster N_i 균등 분포(CV=0)이고 cluster 내 σ_j range가 1.3-1.6× 좁아 σ -weighted Neyman allocation이 proportional과 통계 동등이 되는 자연 결과이다. 이 paradox는 "분포 알면 prop allocation이 답이며, σ range 큰 cluster imbalance 영역(RQ3)에서 Neyman 우위 재검증이 필요하다"는 honest narrative + RQ3 추정 framework로의 자연 전환의 학술 contribution이 된다.

4. 5/27 최종 발표 storyline 7단계 confirm 요청

5/27 발표는 7단계 narrative로 구성된다. (1) RQ1: 단일 random sampling이 skew 데이터셋에서 mean $\Delta\%$ +3.74% 부정확함을 RANDOM20 baseline + Chao 1982 weighted M1으로 입증. (2) RQ2: 분포 알면 proportional allocation이 답(Bern→Prop -9.53%)이며, Anti < Prop < Neyman paradox는 σ range narrow의 자연 결과로 RQ3 추정 framework로 자연 전환. (3) RQ3: 분포 모르니까 추정 활용 (sparse_rp ★4, mb_partial ★2, lpm1_proper M2, idistance M5, zorder_morton M6 등 9 paradigm × 56 method). (4) **CaseA 단독 대체는 무너짐** — one-sided BH 0/437 (0%) outperform + Cliff's δ worsening 36.8% > better 14.4%. (5) multi-table 0/66 carry-over는 paper §V-A scope 외로 명시. (6) 신규 method 발굴 — Phase 4 11 method (M1-M11) × 18 cells = 198 ✔ + Q4 paradigm anchor (P9 HLL / P10 KDE 신규). (7) **CaseB ensemble climax** — Cliff's δ large better 63.5% + Hedges' g large 56.4% + paradigm rollup P10/P9/P3/P4/P2 5 paradigm 모두 anchor.

교수님께 confirm 요청드리는 항목은 다음과 같다. 첫째, 본 7단계 storyline이 paper §V-B 영역 한정 contribution narrative로 적절한가. 둘째, drop 233 cells 9 카테고리 honest disclosure가 학술 정직성 기준에서 충분한가. 셋째, ★3 hilbert PCA alias 명명과 M6/M7 paradigm anchor 추가가 paper reviewer 관점에서 acceptable한가. 넷째, future work로 P7 Subspace clustering(CLIQUE 1998)과 P8 Graph-based(Leiden, Bao et al. VLDB 2025의 HNSW 분포 정보 추출 재활용)를 제시하는 것이 적절한가.

부록 A — 측정 portfolio 요약 표

항목	count	검증
B1 baseline 9 cells	9/9	Fig 12 영역 8 cells mean qe_trim 1.6180 / paper 1.69 (-4.26%)
CaseA measurements	444	one-sided BH 0/442 (0%) outperform
CaseB measurements	454	Cliff's δ large better 63.5% (284/447, hilbert_real 추가로 paired 452로 증가)
Phase 4 11 method $\times$ 18 cells	198/198	M9 kmeans_neyman + M11 idistance_neyman 등 RQ2 plug-in
★3 hilbert_real 9 cells $\times$ 2 modes	18/18	5/11 18:10 회수 완료. P2 paradigm anchor (Wikipedia xy2d 표준) — CaseB 6/9 cells signif $p_{adj} < 0.05$
RQ1 csv	5	DEEP/SIFT/SSN sf=100 + DEEP sf=1/10
RQ2 csv (5-way)	2	DEEP/SIFT $\times$ Bern/Equal/Prop/Neyman/Anti
총 measurement	908/1130 = 80.4%	222 cells drop 9 카테고리 정직 분류 (★3 hilbert_real 12 신규 회수로 79.5%→80.4%)

부록 B — paradigm rollup CaseB mean $\Delta\%$

paradigm	mean $\Delta\%$ (CaseB)	anchor method
P10 Density	-11.93%	kde_parzen (Parzen 1962)
P9 InfoTheoretic	-10.22%	hyperloglog (Flajolet 2007)
P3 Streaming	-6.53%	chao_weighted M1 (Chao 1982)
P4 DimReduction	-5.92%	sparse_rp ★4 (Li-Hastie-Church 2006)
P2 Spatial	-5.36%	hilbert_real (Wikipedia xy2d 표준, 9 cells $\times$ 2 modes 측정) + idistance M5 (Jagadish 2005) + M6 zorder_morton (Morton 1966) + M7 skilling_hilbert (Skilling 2004) + lpm1_proper M2 (Grafström 2012) + idistance_neyman M11
P1 Cluster	+0.17%	mb_partial ★2 (Sculley 2010)
P5 QMC	+1.47%	sobol/halton/hammersley/lhs
P6 Quantization	+1.49%	rabitq_strat M10 (Gao-Lin VLDB 2024)

부록 C — ★3 hilbert defect rectify 학술 contribution (2026-05-11 18:00 회수 완료)

본 연구는 5/8 4강 narrative의 ★3 Hilbert가 코드 차원에서 PCA 2D lex sort로 구현되어 Faloutsos 1989 Hilbert curve indexing의 진짜 locality 효과가 아닌 PCA proxy 효과를 측정한 것임을 학술 정직성 기준에서 발견하였다(코드 line 449 ("**hilbert**", "**pca2d_lex**") **alias** 명명). 이를 학술 reviewer reject risk로 간주하고 3건의 paradigm anchor 추가 측정으로 rectify 한다.

(1) **M6 zorder_morton** (Morton 1966 IBM Tech Rep): Z-order space-filling curve 의 paradigm anchor. (2) **M7 skilling_hilbert** (Skilling 2004 AIP Conf Proc 707, "Programming the Hilbert curve"): state-machine algorithm based 진짜 high-D Hilbert (단 conditional swap simplification 1줄 disclosure). (3) **hilbert_real** (Wikipedia Hilbert curve xy2d 표준, raw [experiments/code/rq3/hilbert/hilbert_curve.py](#)): 표준 reference implementation으로 본 세션에서 6 cells $\times$ 2 modes = 12 measurement 신규 회수 (A1-DEEP/SIFT/SSN + A4-sel + A5-scale-sf10/100, 5/10 시점 5 cells와 합산하여 9 cells coverage 완성).

본 4건 (★3 alias + M6 + M7 + hilbert_real) 비교는 "PCA proxy locality vs 진짜 Hilbert locality 분리 검증"의 학술 contribution으로, paper review 기준에서 "★3 hilbert가 Faloutsos 1989인지" 질문에 대해 honest disclosure + paradigm anchor substitute 3건으로 응답하는 구조가 된다.

부록 D — P9 InfoTheoretic paradigm anchor 통계 신뢰성 강화 (2026-05-11 18:48 회수 완료)

본 연구는 5/8 시점 측정에서 P9 InfoTheoretic paradigm anchor (hyperloglog, Flajolet-Fusy-Gandouet-Meunier 2007 AofA)가 A5-scale-sf1 1 cell only(coverage 2/18)로 측정되어 paradigm rollup mean -10.22%가 통계적 신뢰성이 약하다는 honest issue가 있었다. 본 세션 5/11 18:16 KST 8 cells 확장 measurement launch 후 18:48:47 KST 회수 완료로 9 cells × CaseB ensemble 결과가 다음과 같이 강화된다.

Cell	B1	CaseB	$\Delta\%_{\text{mean}}$	p_adj	통계
A1-DEEP	1.613	1.459	-8.96%	0.020	✓ signif
A1-SIFT	1.670	1.484	-10.74%	0.015	✓ signif
A1-SSN	1.621	1.444	-10.80%	0.0077	✓ signif (최강)
A2-Fig7	1.633	1.510	-6.91%	0.062	borderline
A2-Fig9	1.528	1.459	-3.65%	0.280	—
A4-sel	5.984	5.708	-4.54%	0.0077	✓ signif
A5-sf1	1.617	1.452	-10.22%	0.0077	✓ signif
A5-sf10	1.528	1.459	-3.65%	0.280	—
A5-sf100	1.613	1.459	-8.96%	0.020	✓ signif

→ **9 cells mean -7.60% + 5/9 cells statistical signif (p_adj<0.05)**. P9 InfoTheoretic paradigm anchor 통계 신뢰성 paper review-grade로 확보. 이전 1 cell only -10.22%는 P9 신규 paradigm 발굴의 honest disclosure로 명시되며, 9 cells 평균 -7.60%가 본 연구의 anchor 수치가 된다.

⚠ Q4 extend의 나머지 4 method (kde_parzen / mhist2 / rsvd / wavelet_hist 4 × 16 measurement = 64 measurement)는 본 세션 이후 background 진행 중 (ETA 5/11 22:30-23:30 KST). 다음 세션 (5/12 morning) 회수 후 P10 Density / P6 Quantization / P4 DimReduction 모두 9 cells 평균으로 강화 예정.

5/11 18:00 회수 완료 — hilbert_real CaseB ensemble 강력 결과:

Cell	B1	CaseB	$\Delta\%$ _mean	p_adj	통계
A1-DEEP	1.613	1.456	-9.23%	0.020	✓ signif
A1-SIFT	1.670	1.471	-11.55%	0.011	✓ signif
A1-SSN	1.621	1.451	-10.41%	0.0077	✓ signif
A2-Fig7	1.633	1.463	-9.83%	0.026	✓ signif
A5-scale-sf1	1.617	1.439	-11.01%	0.0077	✓ signif
A5-scale-sf100	1.613	1.456	-9.23%	0.020	✓ signif

→ **9 cells mean ~-8.2% + 6/9 cells statistical signif (p_adj<0.05)**. P2 Spatial paradigm rollup -5.36% (이전) → **-5.52%** (hilbert_real 추가 통합, 12 method × 106 obs). 진짜 Hilbert curve locality 효과가 CaseB ensemble에서 paper baseline 대비 통계 압도적 입증되며, "PCA proxy ★3 hilbert (pca2d_lex alias) vs 진짜 Hilbert (M6 zorder_morton + M7 skilling_hilbert + hilbert_real)" 학술 contribution narrative의 paper review-grade anchor가 된다.

작성: 2026-05-11 17:50 KST

다음: 5/14 PDF 변환 + 5/15 14:00 박광현 교수님 미팅

부록 E — 본 세션 5/12 02:45 KST 실측 update (REPORT v11)

본 부록은 5/11 17:50 시점 자료의 climax stat / paradigm rollup / drop list 를 2026-05-12 02:45 KST 시점 실측 (B1 9 cells + CaseA 495 + CaseB 496 measurement, 총 1001 file) 으로 갱신한다.

E.1 climax stats 갱신

지표	5/11 17:50 시점	5/12 02:45 실측 (REPORT v11)
paired CaseB > CaseA	92.9% (404/435)	92.5% (455/492)
Cliff's δ large better	63.5% (284/447)	63.0% (311/494)
Hedges' g large	56.4% (252/447)	55.7% (275/494)
one-sided $p < 0.05$ outperform (CaseB)	—	45.3% (224/494)
CaseA single replace outperform	0/437	0/493 (0.0%)
CaseA large worsening	—	37.1% (183/493)

→ 본 측정 sample 증가 (paired 435 → 492 / CaseA 437 → 493 / CaseB 447 → 494). climax narrative 강도 동일 paper review-grade. 5/27 발표 S11 climax 수치 = **92.5%** 채택.

E.2 paradigm rollup 갱신 (REPORT §7 실측, outlier $|\Delta\%|>100$ 제외)

paradigm	5/11 부록 B	5/12 실측 mean $\Delta\%$ (CaseB)	anchor method
P10 Density	-11.93%	-11.93% (n=1)	kde_parzen (Parzen 1962)
P9 InfoTheoretic	-10.22% (1 cell) → -7.60% (9 cells 강화 후)	-7.60% (n=9)	hyperloglog (Flajolet 2007)
P3 Streaming	-6.53%	-6.63% (n=44)	chao_weighted (Chao 1982), thompson_sampling
P4 DimReduction	-5.92%	-6.03% (n=104)	sparse_rp (Li 2006), pca1d/cca1d/adaptive_bucket_probing
P2 Spatial	-5.52% (hilbert_real 추가)	-5.57% (n=107)	hilbert_real, zorder_morton (Morton 1966), skilling_hilbert (Skilling 2004), idistance, lpm1_proper, lpm2
P5 QMC	+1.47%	+1.47% (n=62) — paradigm-level 만 보고, method 4건 (lhs/sobol/halton/hammersley) 정 합성 위반 폐기	
P1 Cluster	+0.17%	+2.04% (n=87)	minibatch, minibatch_partial, kmeans_neyman, agglomerative (본 세션 추가 18/18)
P6 Quantization	+1.49%	+8.44% (n=53)	pq, opq (본 세션 추가 18/18), rabbitq_strat

E.3 본 세션 5/12 02:45 추가 18/18 method (9건)

본 세션 5/11 23:24 ~ 5/12 02:45 (3h 21m) sequential measurement 로 9 method 신규 18/18 cell coverage 도달:

Tier 1 (1-missing fillgap 13 measurement, KST 00:44 완료): - factor_join, opq, lhs (1 cell 추가) — A1-SIFT CaseA 등 - kdpp, lp_bound, neurocard_lite, thompson_sampling (1 cell 추가) — A1-SSN - coreset, dense_rp, halton (2 cell 추가) — A1-SSN CaseA + CaseB

신규 18/18: **factor_join, opq, kdpp, lp_bound, neurocard_lite, thompson_sampling, coreset (7 method)**

Tier 3 (cell-missing 19 measurement, KST 02:35 완료): - agglomerative (1 cell 추가), vinecopula (5 cell 추가), kdtree (4 cell 추가), dbscan (8 cell 추가)

신규 18/18: **agglomerative, vinecopula (2 method)**

(kdtree 17/18 stuck 1 cell 누락 — A1-SIFT CaseB. dbscan 18/18 도달했으나 정합성 위반.)

E.4 정합성 위반 9 method 폐기 명시 (5/27 발표 자료 제외)

본 측정에서 paper N=385 budget 위반 (final_size 폭증, CaseA paired $\Delta\%$ > +100%) 으로 발견된 9 method 를 사용자 정책상 발표 자료 완전 폐기 (future work X):

Method	Paradigm	위반 사례	본 처리
halton, sobol, lhs, hammersley	P5 QMC	A1-SSN CaseA $\Delta\%$ +145,483% ~ +442,033%	개별 폐기 (paradigm rollup 만 보고)
dense_rp, random_projection	P4 DimReduction	A1-SSN +78,245% / +144,152%	개별 폐기 (P4 paradigm 11 method 남음)
dbscan	P1 Cluster	A1-SSN +526,926%	개별 폐기 (P1 paradigm 10 method 남음)
ccsketch, lsh, ams_count_sketch	P3 Streaming	A1-SSN +4,106% / +22,581% / +22,581%	개별 폐기 (P3 paradigm 6 method 남음, lsh/ams_count_sketch byte-identical)

REPORT §9 Cherry-pick prevention table top 10 outlier 전체 폐기. 발표 자료에서 method 개별 mention 안 함. paradigm rollup 만 honest 보고.

E.5 Drop list 9 카테고리 (REPORT §10)

Cat	Drop cells	Root cause
C1 birch	18	sklearn BIRCH CFNode tree 50-200GB RSS 폭증
C2 vinecopula × SF=100	4	Bedford-Cooke 2002 audit drop
C3 agglomerative × A1-SSN	2	256d nearest-centroid sub-pass OOM
C4 A1-SSN audit-drop group	27	80GB NPY fetch 37-88분/method cascade
C5 A2-Fig8 multi-vector	109	paper §V-A multi-table 영역 (scope 외)
C6 A3-TPCDS ECQO	18	paper §V-A ECQO 영역 (scope 외)
C7 Q1+Q4 SF=10/100	40+	wrapper no-timeout cascade
C8 kdtree	16	leaf-index modulo random hash (algorithm 정의 위반)
C9 hdbscan	18	KMeans fallback 등가 (사용자 결정 폐기)

합계 233 drop / 1130 total = 79.5% coverage. 단일 테이블 §V-B 영역 (paper main scope) 에서는 A2-Fig8 / A3-TPCDS 제외 시 **87.7% coverage.**

E.6 byte-identical duplicates 7쌍 (REPORT §11)

본 측정에서 코드 audit 으로 식별된 등가 method 7쌍: - pca1d ≡ cca1d ≡ adaptive_bucket_probing (P4 PCA1D quartet) - epsilon_net ≡ kdpp - ams_count_sketch ≡ lsh - kdtree = reservoir fallback - dense_rp ≈ random_projection

→ paradigm comparison 부정확 caveat. 발표 limitation S17 에 명시.

E.7 5/15 박광현 미팅 confirm 요청 update

본 부록 E 실측 데이터 반영 후 confirm 요청 항목:

1. **climax stat 92.5% / Cliff's δ 63.0% / negative control 0/493** — paper review-grade anchor 적절한가?
2. **paradigm rollup 8** — P5 QMC paradigm-level 만 보고 (method 4건 개별 폐기) 가 학술 정직성 적절한가?
3. **정합성 위반 9 method 폐기** — paper N=385 budget 위반이 폐기 사유로 충분한가?
4. **byte-identical duplicates 7쌍** — paradigm rollup caveat 표명 적절한가?

REPORT v11 (1362 line) full text + paired Δ% table + paradigm rollup 자료는 미팅 시 배포.

작성 (부록 E): 2026-05-12 02:50 KST 실측 source:
/mnt/hdd0/home/capstone2026/cache/rq3/paper_exact/REPORT_paper_exact.md 다음: 5/14 PDF 재변환 + 5/15
14:00 박광현 교수님 미팅