

Skew-Aware Stratified Sampling for Vector-Augmented Analytical Query

벡터 카디널리티 추정에서 distribution-aware stratified sampling 의 정량적 가치

Single → Multi-vector: 25.4× magnitude shrinkage

TEAM

속도논벡터

박세은 · 강재현 · 조현빈 · 이동욱

ADVISOR

박광현 교수

BDAI Research Lab

REFERENCE

arXiv:2512.09695v2

Exqutor · PDX (SIGMOD'25)

DATE

2026.05.27

Final Presentation

01 Problem 문제 정의	02 Prior Work Exqutor + PDX	03 Approach Skew-Aware Sampling	04 RQ1 · Diagnostic 12-cell $p<0$ 일관	05 RQ2 · Aware 51/52 CI 0 제외
06 RQ3 · 4강 10-cell paired $\Delta\%$	07 Cross-Scale sf1 → sf10	08 Mechanism multi 25.4× shrinkage	09 Effect Honesty SSN++ ceiling	10 Limitation 8 open questions

기존 시스템의 고정 비율 추정

PGVECTOR

33.3%

fixed ratio

VBASE

50.0%

fixed ratio

DUCKDB

100%

fixed ratio

세 시스템 모두 query별 selectivity 분포를 단일 비율로 처리.
정확도와 안정성을 동시에 잃는다.

실제 SELECTIVITY 분포

0.001 ~ 90 %

- 5 orders of magnitude 광범위 분포
- query마다 분포가 다르다
- 고정 비율은 underestimate / overestimate 동시 발생

PGVECTOR

1000×

plan cost
gap

VBASE

10000×

plan cost
gap

DUCKDB

1.5-37×

plan cost
gap

기술적으로 좋은 추정 ⇔ 실행 계획에 진짜 도움 되는 추정 — 그 사이 간극을 메운다.

A

ECQO

빠른 카디널리티 견적

HNSW 보조 인덱스로 1~2 ms 안에 견적 — 옵티마이저 비용 추정 시점에 사용 가능.

1-2

MS

B

ADAPTIVE
SAMPLING

균등 sampling 비용 절감

모멘텀 기반 동적 비율 — Sequential Scan 비용을 1000배 낮춤.

1000

×

PDX · SIGMOD
2025

CWI Amsterdam ·
arXiv:2503.04422

"intrinsic_dim + skewness가 algorithm selection 결정" — 우리 thesis 와 정확 일치 → 학술적 정당성 확보.

PDX

compute layer
fast similarity

본 연구

pre-process layer
accurate cardinality

비용 절감 + PDX compute layer 위에 — 분포 인지의 가치를 pre-process layer 로 보완.

RQ1

Diagnostic

Skew가 추정 오차에 영향을 주는가?

→ 12-cell $p < 0.100\%$ 일관

RQ2

Aware

분포를 알 때 어떤 분할이 최적인가?

→ 51 / 52 (sel=0.10) CI ex

RQ3

Agnostic

분포를 모를 때 채택 가능한 방법은?

→ 4강 method × 10 cell paired

DEEP_SF1 · KM20 (W1-A)

-0.680

95% CI [-0.800, -0.440] · 0 제외 ✓


12 CELL SIGN 일관성

12/12 $p < 0$
✓

range -0.609 ~ -0.366 — 5 dataset × 2 sf × 1~2 method.

n = 5 seeds × 5 selectivity bins · paired Spearman

12-CELL P RANKING · 모두 음수

12개 cell 전부 $p < 0$ — 단조성은 **dataset-method** 공통 현상.

12 CELL × 4 MODE = 48 + ANTI-NEYMAN

51/52

(sel = 0.10) CI excludes 0

분포 정보 활용 효과 강력 · 12 cell × 4 mode = 48 + anti-Neyman 4

ANTI-NEYMAN COUNTERFACTUAL

+5.21%

DEEP [+1.36,
+9.16]

+9.49%

SIFT [+4.66,
+11.75] Σ -ALLOCATION (NEYMAN VS ANTI-NEYMAN)

7/12

cells with gap <
1% σ 격차가 7/12 cell 에서 1% 이내 — 단순 균등 stratification 충분.

핵심 함의

 σ_i 신호 약함을 honest 입증 → RQ3 distribution-agnostic 추구의 정직 motivation.분포 정보 활용은 강력, σ 신호는 약함 — agnostic 추구의 motivation.

4강 RANKING (AVG Δ%)

★1	HDBSCAN	-8.04%	neg 8/10 CI ex 8/10
★2	MB_partial	-7.63%	neg 8/10 CI ex 9/10
★3	Hilbert	-7.54%	neg 8/10 CI ex 9/10
★4	Hybrid	-7.13%	neg 8/10 CI ex 8/10

★1 HDBSCAN density-based · ★2 MB_partial OLTP friendly 유일 · ★3 Hilbert production sweet spot

10 CELL × 4 METHOD · PAIRED Δ%

	DEEP_sf1	DEEP_sf10	SIFT_sf1	SIFT_sf10	SSN_sf1	SSN_sf10	WIKI_sf1	WIKI_sf10	YFCC_sf1	YFCC_sf10
HDBSCAN	-1.8	-1.8	-32.6	-10.5	+1.6	+1.4	-10.0	-4.3	-7.2	-5.8
MB_p	-1.4	-2.1	-31.6	-10.2	+1.7	+2.0	-9.9	-2.6	-7.2	-5.6
Hilbert	-0.4	-1.2	-32.1	-10.7	+2.3	+2.1	-9.6	-4.5	-6.9	-5.2
Hybrid	-1.1	-1.9	-28.9	-10.2	+1.4	+1.3	-7.7	-4.2	-5.7	-4.8

■ negative (improve) ■ SSN++ ceiling (+1~+2%)

4강 모두 paired Δ% -7~-8% avg · SIFT_sf1 -32% · SSN++ ceiling +1~+2%로 outer boundary 정의.



Contribution 1 — Hilbert · production sweet spot

LEARNING-FREE · TIER 1 SPREAD 1.21%P

속도는벡터 · STYLE A · ACADEMIC

09 / 16

HILBERT AVG Δ% · 4강 #3

-7.54%

neg 8/10 · CI ex 9/10 · SIFT_sf1 -33.53%

★ learning-free 1 위 deployment cost 0

INVERSE MANHATTAN

1.000 vs **1.992**
HILBERT Z-ORDER

TIER 1 (살아남기 17종) — SPREAD 1.21%P



SPREAD = 1.21%P (HDBSCAN ↔ KDTREE)

method choice 부차 — "분포 인지 vs 미인지" boundary가 결정적.

Hilbert는 학습 비용 0 · 17종 spread 1.21%p — 분포 인지 boundary 가 결정적.



Contribution 2 — MiniBatch K-means · OLTP friendly

PRODUCTION-READY · 4강 #2 · CI EX 9/10

속도는벡터 · STYLE A · ACADEMIC

10 / 16

MB_PARTIAL AVG Δ% · 4강 #2

-7.63%


neg 8/10 · CI ex 9/10 강력 · SIFT_sf1 -33.13%

★ OLTP friendly 유
일

partial_fit · 1,189×
speedup

- partial_fit ARI = **1.000** (full K-means 동일)
- OLTP streaming 환경 drop-in 가능

TRAINING TIME · LOG SCALE



SAME ACCURACY · 1000× CHEAPER · OLTP-READY

OLTP friendly 유일 4강 · 정확도 동일 + 1000× cheaper — production drop-in.



Contribution 3 — Distribution Sweet Spot 정량 boundary

CLUSTER_RATIO × INTRINSIC_DIM

SWEET 강력 IMPROVE 영역

`cluster_ratio > 1.4`
`intrinsic_dim < 0.85`

-7 ~ -32%

SIFT · WIKI · YFCC

cluster 구조 명확 + dim manifold 압축 → 분할이 분산을 직접 줄임.

CEILING EFFECT 약함 BOUNDARY

`cluster_ratio < 1.4`
`intrinsic_dim > 0.85`

+1 ~ +2%

SSN++ CEILING

cluster_ratio 1.29 · intrinsic_dim 0.88 → BERN 자체 ceiling.

SIFT_SF1 (SWEET)

-32.63%

DEEP_SF1 (MID)

-1.84%

SSN_SF1 (CEILING)

+1.56%

`cluster_ratio × intrinsic_dim` 두 축이 distribution sweet spot 의 정량 boundary 를 정의.

HDBSCAN PAIRED Δ% · SF1 VS SF10

	DEEP	SIFT	SSN	WIKI	YFCC
sf1	-1.84 %	-32.63 %	+1.56 %	-9.96 %	-7.23 %
sf10	-1.77 %	-10.47 %	+1.39 %	-4.30 %	-5.77 %

* SIFT_sf1 -32.63% → sf10 -10.47% (magnitude 약화, 부호 일관)

4강 RANKING 일관성

HDBSCAN · MB_partial · Hilbert · Hybrid — sf1 / sf10 모두 상위 4 유지.

SSN++ CEILING 부호 유지

sf1 +1.56 / sf10 +1.39 — outer boundary scale 무관.

SF100 측정

채림 석사 자문 후 보강 (5/15) · multi-table join STAGE 3 진행 중

SINGLE × 25.4 → MULTI · NECESSARY ≠ SUFFICIENT

LOCALITY (INVERSE MANHATTAN)

1.000 VS 1.992

HILBERT

Z-ORDER

SINGLE → MULTI SHRINKAGE

17.13% → 0.67%

SINGLE AVG |
Δ%|MULTI AVG |
Δ%|

25.4× 약화

3/8 negative · 5/8 positive · |Δ| < 1.5%

MULTI-VECTOR CELL × 4강 (SEL=0.10)

	HDBSCAN	Hilbert	Hybrid	MB_p
deep_sift_10	-1.02 %	-0.48 %	+0.31 %	-1.30 %
deep_wiki_10	+1.15 %	+0.06 %	+0.08 %	+0.99 %

해석: 단일 정확성은 multi 정확성의 필요조건만 성립 — 충분조건 X. joint-aware clustering / multi-vector decomposition 별도 설계 future work.

locality 이득은 단일에서 강력, multi에선 25.4× 약화 — multi-relation 일반화는 별도 design 필요.

HILBERT · ESS / SRS-EQUIVALENT

6x

SRS effective sample

DEFF

0.338

ESS

2,325

mean d

≈ 0.3

Q4_HARD SPREAD VS DIFFICULTY

 $\rho = 0.78$

per-query routing 가치 — 어려운 query 강한 양의 상관

SSN++
CEILINGHONEST
REPORTING

- cluster_ratio **1.29** + intrinsic_dim **0.88** = 분포 균형 dataset
- BERN baseline 자체가 ceiling — improve room 없음
- 4강 모두 +1 ~ +2% 미세 후퇴 (positive direction)

HDBS
+1.56%MB_p
+1.73%Hilb
+2.34%Hyb
+1.35%

본 연구 outer boundary 정의 — sweet spot 의 반대 극.

effect는 **practical small**이지만 honest — SSN++ ceiling 이 outer boundary 정의.

L1

PARTIAL

Single-table only

multi-table은 Exqutor main scope. 단일 정확성이 multi 필요조건 (3 STAGE 측정 진행).

L2

FUTURE

Multi-vector 일반화

25.4x shrinkage — joint-aware clustering / multi-vector decomposition 별도 설계 필요.

L3

FUTURE

sf100 cross-scale

sf1 → sf10 일관성 확정. sf100 측정 채림 식사 자문 후 (5/15 보강).

L4

PARTIAL

KM20 oracle 학습 부담

full K-means ~30분. partial_fit (OLTP) + Hilbert (learning-free) 가 production replacement.

L5

HONEST

SSN++ ceiling honest

cluster_ratio 1.29 + intrinsic_dim 0.88 → BERN ceiling. boundary 정의로 활용.

L6

HONEST

Effect size practical small

모든 RQ3 $|d| < 0.8$. 어려운 query routing 가치 (Q4 spread $\rho=0.78$).

L7

PARTIAL

numpy estimator scope

$\leq 10K$ row 캐시 + HT weight만 $N=1M$. 절대 q-error 인용 시 명시, 상대 비교 보존.

L8

FUTURE

vector.c integration

5/6 시도 → memory leak. Python 시물 본질 검증 + 5/15 채림 자문 후 진입.

감사합니다.

Q & A

GITHUB

github.com/johyunbin/Capstone

REFERENCE

[arXiv:2512.09695v2](https://arxiv.org/abs/2512.09695v2)

Exqutor · PDX (SIGMOD'25)

STAGE 3 보강 예정

multi-table join (deep×wiki) 측정 결과 회의 후
추가 보고