

속도는벡터 — 자주 묻는 질문 (Q&A)

대상: 팀원 + 박광현 교수님 미팅 + 5/27 발표 청중

목적: 발표 자료에서 사용되는 용어와 핵심 개념을 누구나 이해 가능한 수준으로 설명

본 자료의 사용 방법

발표 자료 (키노트 v4 PDF) 에는 학술 용어가 등장합니다. 처음 보는 분들이 슬라이드를 더 명확히 이해할 수 있도록, 자주 묻거나 헷갈리는 12 개 질문을 골라 답을 정리했습니다. 발표 자료를 읽기 전에 본 자료를 먼저 보면 슬라이드 내용이 더 직관적으로 와닿습니다.

Q1. Q-error 가 무엇인가요?

추정값이 실제 값에서 얼마나 벗어났는지를 측정하는 지표입니다. 정의는 $\max(\text{추정값}/\text{실제값}, \text{실제값}/\text{추정값})$ 으로, 1 에 가까울수록 정확하고 수치가 커질수록 오차가 크다는 의미입니다. 예를 들어 Q-error 가 1.748 이라면 평균 74.8 퍼센트의 오차가 있다는 뜻입니다. 본 연구에서는 paper §VI 정의를 따라 10 trial 중 최댓값과 최솟값 1 개씩을 제외한 평균값 (qe_trim, trimmed mean) 을 사용합니다. outlier 의 영향을 줄여 더 안정적인 비교를 가능하게 합니다.

Q2. Bernoulli baseline 이 우리 연구의 baseline 인가요, paper 의 baseline 인가요?

둘 다입니다. paper §V-B Adaptive Sampling 영역에서 paper 가 사용한 sampling 방식이 Bernoulli 무작위 sampling 입니다. PostgreSQL 의 `TABLESAMPLE BERNOULLI(p)` 명령으로 각 row 를 확률 p 로 독립 추출하는 방식입니다. 본 연구는 paper §V-B 영역을 한정해 다루므로 paper 의 baseline 을 그대로 본 연구의 baseline 으로 사용합니다. 따라서 모든 비교는 "Bernoulli baseline 1.748 대비 우리 방식이 얼마나 더 정확한가" 의 형태입니다.

paper §V-A 영역의 "block 단위 무작위 sampling" 은 인덱스가 있을 때의 다른 처리 방식이고 본 연구 영역 외입니다.

Q3. 왜 단독 대체가 아닌 증강 결합 (ensemble augment) 을 하나요?

비유로 설명하면, 두 의사가 같은 환자를 진단했을 때 한 의사의 진단만 따르기보다 두 진단의 평균을 사용하는 것이 더 안정적인 것과 같은 원리입니다.

paper Bernoulli 무작위 sampling 은 **bias 가 0** 이지만 **variance 가 큼**니다. 즉 평균적으로는 정확하지만 한 번의 추정값이 들쭉날쭉합니다. 반대로 분포 인지 stratified sampling 은 cluster 분포 가정이 맞으면 **variance 가 낮**지만, 가정이 틀리면 **bias 가 발생** 합니다. 두 방식의 산술 평균을 사용하면 한 쪽이 실패해도 다른 쪽이 보완하는 robust 구조가 됩니다.

본 측정에서 실제로 단독 대체는 493 cells 중 0 cell 에서만 paper baseline 보다 우위였고, 증강 결합은 492 cells 중 455 cells (92.5%) 에서 우위였습니다.

Q4. paradigm 이 8 개나 되는 이유는?

데이터 분포를 추정하는 방식이 통계학적으로 다양해서 어떤 방식이 본 sampling 시나리오에 가장 잘 맞는지 비교하기 위해서입니다. 각 paradigm 은 **서로 다른 작동 가정** 을 가집니다.

- **밀도 추정 (Parzen KDE)** — 데이터 점 주변에 kernel 함수를 배치해 부드러운 확률 밀도를 추정합니다
- **정보 이론 (HyperLogLog)** — hash 함수의 leading-zero 분포로 distinct count 를 근사합니다
- **스트리밍 (Chao 1982)** — stream 환경에서 분포 비례 sampling 을 보장합니다
- **차원 축소 (Sparse RP)** — 고차원을 저차원으로 압축하면서 거리 정보를 보존합니다 (Johnson-Lindenstrauss 정리 기반)
- **공간 분할 (Hilbert + Z-order)** — space-filling curve 로 고차원 공간을 1차원에 매핑하면서 인접성을 유지합니다

이외에 균등 격자 (QMC), 클러스터, 양자화 paradigm 도 비교했습니다. 본 측정 결과 다섯 paradigm — 밀도 추정 / 정보 이론 / 스트리밍 / 차원 축소 / 공간 분할 — 이 baseline 대비 통계적으로 압도했습니다.

Q5. paradigm rollup 의 "1.135 배 정확도 향상" 이 무슨 의미인가요?

baseline 의 Q-error 가 1.748, 밀도 추정 paradigm 증강 후 Q-error 가 1.540 으로 감소했을 때, 두 값의 비율 $1.748 / 1.540 = 1.135$ 가 정확도 향상 배수입니다. 다른 표현으로는 추정 오차가 28 퍼센트 절감되었다고도 말할 수 있습니다 ($1 - 1.540/1.748 \approx -11.9\%$).

본 연구의 다섯 paradigm 은 1.06 배 ~ 1.14 배 범위의 정확도 향상을 보입니다. baseline 1.748 → 결합 후 1.540 ~ 1.651 의 범위로 추정 오차가 일관되게 절감됩니다.

Q6. paper 100% 재현 -4.3% 가 무슨 의미인가요?

본 측정 자체가 paper Exqutor 의 결과를 정확히 재현할 수 있는지 검증한 결과입니다. paper Fig.12 영역의 8 cells 의 평균 Q-error 는 paper 보고값 1.69, 본 측정값 1.618 — 두 값의 차이가 -4.3 퍼센트로, 이 정도는 측정 변동 범위 (measurement variance) 내 정상 일치로 봅니다. 따라서 본 측정은 paper 의 결과를 정확히 재현하는 위에 본 연구의 contribution 을 추가한 구조이고, paper 와의 정합성이 보장된 상태에서 새 비교를 합니다.

Q7. RQ1 의 +3.74% 가 너무 작은 출발점 아닌가요?

좋은 지적입니다. 평균값은 작아 보이지만 cell 별 breakdown 으로 보면 가장 극단 case 가 8.64 퍼센트, ratio 로는 1.095 배 차이를 보입니다. 즉 무작위 sampling 의 부정확성은 selectivity 와 데이터셋 조합에 따라 변동이 크고, 평균값만으로는 한계를 충분히 드러내기 어렵습니다.

데이터셋	selectivity	격차
SIFT	0.10	-8.64% (1.095×) ★ MAX
DEEP	0.01	-6.35% (1.068×)
DEEP	0.10	-3.78%
SIFT	0.01	-1.90%
4 cells 평균		-5.17%

본 슬라이드는 평균 격차와 함께 MAX case 를 강조해 무작위 sampling 의 한계가 실제로 정량 측정 가능한 수준임을 보입니다.

Q8. RQ2 paradox (Anti < Prop < Neyman) 가 무엇인가요?

분포를 알 때 sample 을 어떻게 분배할지의 다섯 방식 비교에서 발생한 흥미로운 발견입니다. 이론적으로는 Neyman 분배가 가장 효율적이어야 합니다 (sample size 를 stratum 크기와 표준편차의 곱에 비례하게 배분). 그러나 본 측정에서는 Anti-Neyman (역방향) 이 1.540 으로 가장 낮고, 비례 분배가 1.580, Neyman 이 1.595 의 결과가 나왔습니다.

원인은 본 측정 환경에서 stratum 별 표준편차가 1.3 ~ 1.6 배 범위로 좁은 변동만 있고, stratum 크기 자체는 균등 분포 (변동계수 0) 라는 점입니다. 표준편차 신호가 약하면 Neyman 분배의 효과가 비례 분배와 통계적으로 동등 해지고, 데이터 특성에 따라 Anti-Neyman 이 우연히 낮은 값을 보일 수도 있습니다. 본 연구는 이를 "분포 알면 비례 분배가 답이며, 표준편차 신호가 큰 환경에서는 Neyman 우위가 재확인되어야 한다" 는 honest finding 으로 보고합니다.

Q9. 왜 단독 대체 (CaseA) 는 안 되는데 증강 (CaseB) 은 되나요?

세 가지 측면에서 분석됩니다 (slide 16 에서 자세히 다룸).

첫째, **sample budget 의 분배 문제**. paper sample budget $N=385$ 을 stratified 추정 단독으로 사용하면 20 개 stratum 평균 19 sample 씩 분배되어 stratum 내부 변동 추정이 불안정합니다.

둘째, **통계적 가정의 충돌**. paper 의 sample size 동적 조정 식 (Eq 1-6) 은 무작위 sampling 의 통계 분포 가정 위에 설계되어 있어 stratified 단독 적용 시 가정 위반입니다.

셋째, **실험적 입증**. 493 cells 중 단독 대체로 paper baseline 을 이긴 cell 이 0 cell, 효과 크기 large 수준 악화는 37.1 퍼센트입니다. 통계적으로 "단독 대체는 random 대체 불가능" 이 입증됩니다.

증강 결합은 paper Bernoulli 가 budget 전체를 사용하면서 stratified 가 보조 추정값을 제공하는 구조라 세 측면의 문제가 모두 해결됩니다.

Q10. multi-table cell 결과가 single 과 비슷한 이유는?

본 측정의 multi-table cell (A2-Fig7, A2-Fig9 cross-table) 의 stratification 학습 방식은 single table 에서 학습한 K-means 20 cluster 를 join 후 그대로 carry-over 하는 방식입니다. 두 테이블을 join 한 후 새로 stratification 학습을 하지 않습니다.

paper §V-A 의 multi-table 영역은 본 연구 §V-B sampling 영역과 별개로 paper main result 그대로 인정하고 본 연구 범위 외로 둡니다. 따라서 single 과 multi 의 결과가 유사한 경향을 보이는 것은 자연스러운 결과입니다.

Q11. ensemble augment 의 비용 (latency, memory) 은?

본 측정에는 포함되지 않았습니다. paper §V-B 재현 scope 에 정확도 측정만 포함되어 있어 비용 overhead 는 향후 측정 영역 (cost-quality tradeoff) 으로 한계를 명시합니다. 발표 자료의 Limitation 슬라이드에 명시되어 있습니다.

직관적으로는 두 estimator 를 동시에 운용하므로 latency 와 memory overhead 가 단독 방식보다 클 것으로 예상되지만, 정확한 정량 측정은 후속 연구 영역입니다.

Q12. "정합성 위반 9 method" 가 폐기된 이유는?

paper 의 sample budget 정의 ($N=385$) 를 위반하는 알고리즘들입니다. 본 측정에서 일부 알고리즘이 sample budget 을 폭증시켜 (final_size 가 $N=385$ 보다 수십 배 ~ 수만 배 증가) paper 정의와의 정합성을 보장할 수 없는 결과를 냈습니다. 균등 격자 paradigm 의 Halton / Sobol / LHS / Hammersley 와 차원 축소의 dense_rp / random_projection, 클러스터의 dbscan, 스트리밍의 ccsketch / lsh / ams_count_sketch 가 해당됩니다.

이 9 알고리즘은 발표 자료에서 완전히 폐기했습니다 (개별 mention X). paradigm rollup 단위에서만 보고하고 method 차원에서는 비교 대상에서 제외합니다. paper 정의 위반은 학술 정직성 차원에서 발표 자료에 포함시키지 않는 것이 맞다고 판단했습니다.

참고

본 자료는 5/15 박광현 교수님 미팅, 5/27 최종 발표, 5/28 임채림 박사 SAP 미팅에서 모두 활용 가능합니다. 추가 질문이나 보강이 필요한 항목은 팀 카톡 그룹에서 논의합니다.

작성: 2026-05-12 KST · 5/27 최종 발표 D-15 시점

관련 자료: 같은 폴더의 [한 페이지 요약](#) / [팀원 종합 가이드](#) / [발표 storyline 가이드](#) / 키노트 v4 deck PDF