

속도는벡터 — 팀원 종합 가이드

5/27 캡스톤 최종 발표를 앞두고 팀원 전체가 읽어두는 종합 자료

연세대학교 2026-1 학기 · 박광현 교수님 지도 · BDAI 연구실 · 임채림 석사 지도연구원

팀: 박세은(팀장) · 강재현(발표자) · 조현빈 · 이동욱

0. 이 문서가 무엇인지

5/27 최종 발표를 앞두고 팀원 누구나 읽어두면 발표 narrative 와 측정 결과를 같은 깊이로 이해할 수 있도록 정리한 종합 가이드입니다. 발표 슬라이드 (키노트 v4 PDF) 는 본문이 압축되어 있으니, 본 가이드를 먼저 읽고 슬라이드를 보면 맥락이 더 명확합니다.

분량은 A4 6-7 페이지이고 학술 산문 형태로 작성했습니다. 처음 보는 분도 이해할 수 있도록 전문 용어는 첫 등장시 풀어 썼습니다.

1. 우리가 푸는 문제 — 벡터 검색의 부정확한 카디널리티 추정

요즘 LLM 과 추천 시스템은 텍스트나 이미지를 **벡터** (수백 ~ 수천 차원의 숫자 배열) 로 변환해 데이터베이스에 저장합니다. 사용자가 어떤 텍스트로 검색하면 시스템은 그 텍스트도 벡터로 변환한 다음 데이터베이스 안에서 **유사한 벡터들을 빠르게 찾아** 응답합니다. 이런 데이터베이스를 벡터 데이터베이스라 부르고, 대표적인 오픈소스가 pgvector, VBASE, DuckDB 의 vector extension 등입니다.

문제는 검색 쿼리를 실행하기 전에 데이터베이스가 "이 검색 조건에 매칭될 데이터가 전체의 몇 퍼센트일까" 를 추정해야 한다는 점입니다. 매칭 비율 (selectivity) 에 따라 어떤 인덱스를 쓸지, 어떤 join 순서를 쓸지 결정되기 때문입니다. 그런데 pgvector 는 매칭 비율을 항상 33.3 퍼센트로, VBASE 는 50 퍼센트로, DuckDB 는 100 퍼센트로 가정합니다. 실제 매칭 비율은 0.001 퍼센트부터 90 퍼센트까지 큰 폭으로 변동하므로 이 고정값 가정은 자주 틀립니다. 틀린 추정은 잘못된 실행 계획으로 이어지고, 결과적으로 쿼리가 느려집니다.

본 연구의 기반 논문인 Exqutor (arXiv:2512.09695v2) 는 이 문제에 두 갈래로 접근합니다. 인덱스가 있을 때는 HNSW 범위 쿼리로 1-2 밀리초 안에 정확한 카디널리티를 얻고 (ECQO 영역), 인덱스가 없을 때는 무작위 sampling 으로 매칭 비율을 추정합니다 (Adaptive Sampling 영역). 두 영역 중 본 연구가 다루는 것은 후자 — Adaptive Sampling 입니다. 이 영역에서 원 논문이 사용한 sampling 방식은 **Bernoulli 무작위 sampling** 입니다.

2. 원 논문이 자체적으로 명시한 한계

Exqutor 논문은 자체 §V-B 절에서 Adaptive Sampling 의 한계를 명시하고 있습니다. 무작위 sampling 은 **데이터 분포에 의존적** 이라는 한계가 있습니다. 즉 데이터가 균등하게 분포되어 있을 때는 잘 작동하지만, 클러스터가 편향되어 있거나 일부 영역에 데이터가 집중되어 있을 때 추정값이 불안정해집니다.

본 연구는 이 한계를 출발점으로 잡았습니다. **데이터 분포를 인지하는 보조 추정 방식을 활용하면 sampling 의 정확도를 개선할 수 있을 것** 이라는 가설입니다. 이 가설을 검증하기 위해 다음 세 단계의 연구 질문을 단계적으로 풀었습니다.

3. 세 단계 연구 질문 (RQ1 / RQ2 / RQ3)

3.1 RQ1 — 무작위 sampling 이 실제로 얼마나 부정확한가

먼저 baseline 으로서 무작위 sampling 의 부정확함을 정량 측정했습니다. paper 정의 그대로 재현한 측정에서, DEEP / SIFT 데이터셋 $sf=100$ (scale factor 100) $\times$ selectivity 0.01 와 0.10 의 4 cells $\times$ 5 trials 결과를 보면 다음과 같습니다.

데이터셋	selectivity	무작위 sampling 평균 오차	분포 인지 평균 오차	격차
SIFT	0.10	1.230	1.123	-8.64% (1.095 $\times$)
DEEP	0.01	1.748	1.637	-6.35% (1.068 $\times$)
DEEP	0.10	1.161	1.117	-3.78%
SIFT	0.01	1.690	1.657	-1.90%
4 cells 평균				-5.17%

가장 극단적 case 인 SIFT sel=0.10 에서 무작위 sampling 의 오차가 분포 인지 방식보다 8.64 퍼센트 더 큼니다. 무작위 sampling 의 부정확성이 selectivity 와 데이터셋에 따라 변동되며, 이는 분포 인지 접근의 출발점을 제공합니다.

3.2 RQ2 — 분포를 알 때 어떤 분배 방식이 최적인가

분포 정보를 알고 있다고 가정했을 때 sample 을 어떻게 분배하는 것이 최적인지 비교했습니다. K-means 클러스터링으로 데이터를 20 개 그룹 (stratum) 으로 분할한 다음, 각 stratum 에 sample 을 어떻게 분배할지 다섯 가지 방식 — Bernoulli 무작위 / 균등 분배 / 비례 분배 (stratum 크기 비례) / Neyman 분배 (크기 $\times$ stratum 내 표준편차) / Anti-Neyman (역방향) — 을 비교했습니다.

분배 방식	평균 오차
Bernoulli (baseline)	1.748
균등	1.644
비례 (Proportional)	1.580
Neyman	1.595
Anti-Neyman	1.540

비례 분배가 baseline 대비 -9.53 퍼센트로 가장 안정적입니다. 이론적으로 Neyman 분배가 최적이어야 하지만 본 측정에서는 비례 분배가 Neyman 보다 약간 더 안정적이고, Anti-Neyman 이 가장 낮은 값을 보이는 paradox 가 발생했습니다. 원인은 본 측정 환경에서 stratum 별 표준편차의 변동이 1.3-1.6 배로 좁은 범위에 있고, stratum 크기 자체가 균등 분포 (변동계수 0) 이기 때문입니다. 표준편차 신호가 약하면 Neyman 분배의 효과가 비례 분배와 통계적으로 동등해집니다. 즉 분포를 알 때는 비례 분배가 답이며, 표준편차 신호가 큰 환경에서는 Neyman 이 더 유리할 수 있다는 의미입니다.

3.3 RQ3 — 분포를 모를 때 어떤 알고리즘이 최적인가

실제 환경에서는 데이터 분포를 미리 알 수 없습니다. 따라서 분포를 추정해주는 알고리즘이 필요합니다. 분포 추정 가능한 통계 paradigm 8 가지에서 56 개 알고리즘을 폭넓게 비교 측정했습니다. 결과는 §5 에서 자세히 다룹니다.

4. 알고리즘 portfolio — 8 paradigm $\times$ 56 method

본 연구가 비교한 8 paradigm 과 각 paradigm 의 대표 알고리즘은 다음과 같습니다.

Paradigm	대표 알고리즘	작동 가정
밀도 추정 (Density)	Parzen KDE (Parzen 1962)	데이터 점 주변에 kernel 함수를 배치해 부드러운 확률 밀도 추정
정보 이론 (InfoTheoretic)	HyperLogLog (Flajolet 2007)	hash 의 leading-zero 분포로 distinct count 근사
스트리밍 (Streaming)	Chao 1982 weighted reservoir	stream 환경에서 분포 비례 sampling
차원 축소 (DimReduction)	Sparse Random Projection (Li 2006)	고차원을 저차원으로 압축하면서 거리 정보 보존
공간 분할 (Spatial)	Hilbert curve + Z-order (Morton 1966)	space-filling curve 로 고차원 공간 → 1차원 매핑 + 인접성 보존
균등 격자 (QMC)	Halton / Sobol / Hammersley / LHS	low-discrepancy quasi-Monte Carlo sequence
클러스터 (Cluster)	k-means / MiniBatch	cluster 단위 sample 분배
양자화 (Quantization)	Product Quantization (Jegou 2011)	codebook 으로 벡터 압축 + 메모리 효율

각 paradigm 은 작동 가정이 서로 다릅니다. 예컨대 밀도 추정은 kernel 함수의 부드러움을, 정보 이론은 hash 함수의 균등성을 가정합니다. 본 연구는 어떤 가정이 본 sampling 시나리오에 가장 잘 맞는지를 측정으로 비교하는 접근입니다.

총 56 개 알고리즘을 9 개 측정 단위 (cell) 와 2 가지 적용 방식에 대해 paper 정의 그대로 측정했고, 산출 파일 1001 개를 확보했습니다.

5. 실험 framework — 대체 (CaseA) vs 증강 (CaseB)

본 연구의 핵심 framework 는 우리 method 를 paper Bernoulli baseline 에 **어떻게 적용할 것인가** 입니다. 두 가지 방식을 비교했습니다.

대체 (CaseA · replace): paper 의 Bernoulli baseline 을 우리 method 로 단독 교체합니다. 수식으로는 $est_final = est_method$ 입니다.

증강 (CaseB · augment): paper 의 Bernoulli baseline 과 우리 method 의 추정값을 산술 평균합니다. 수식으로는 $est_final = (est_b1 + est_method) / 2$ 입니다. 비유하자면 두 의사가 같은 환자를 진단했을 때 두 진단의 평균을 사용하는 방식입니다.

두 방식 모두 sample budget 은 paper 정의대로 $N=385$ 를 유지하며, sample size 동적 조정 식 (paper Eq 1-6) 도 그대로 보존합니다. 차이는 최종 추정값을 어떻게 계산하느냐에만 있습니다.

6. paper 100% 재현 검증

본 측정의 정합성은 paper Fig.12 영역의 8 cells (DEEP / SIFT / SimSearchNet++ $\times$ sf=100 + YFCC sf=10 + DEEP+WIKI cross sf=10 + DEEP scale sf=1/10/100) 의 평균 추정 오차로 확인됩니다. paper 보고값은 1.69 이고 본 측정값은 1.618 — 차이 -4.3 퍼센트로 측정 변동 범위 내 정확 일치입니다. paper 100 퍼센트 재현이 입증된 위에 본 연구의 contribution 이 추가된 구조입니다.

또한 동일 seed 로 4 cells $\times$ 10 trials $\times$ 7 fields = 280/280 fields 가 SHA-256 hash 기준 byte-identical 로 일치하여 deterministic 보장도 확인됩니다.

7. 핵심 결과 — 대체는 무효, 증강만 유효

7.1 paradigm 단위 결과

8 paradigm 의 증강 (CaseB) 효과를 baseline 추정 오차 1.748 대비 정렬하면 다음과 같습니다.

Paradigm	baseline → 증강 후	절감율	정확도 향상 배수
밀도 추정 (Parzen KDE)	1.748 → 1.540	-11.93%	1.135×
정보 이론 (HyperLogLog)	1.748 → 1.615	-7.60%	1.082×
스트리밍 (Chao 1982)	1.748 → 1.632	-6.63%	1.071×
차원 축소 (Sparse RP)	1.748 → 1.642	-6.03%	1.064×
공간 분할 (Hilbert + Z-order)	1.748 → 1.651	-5.57%	1.059×
균등 격자 (QMC)	1.748 → 1.774	+1.47%	—
클러스터 (k-means)	1.748 → 1.784	+2.04%	—
양자화 (Product Quantization)	1.748 → 1.896	+8.44%	—

다섯 paradigm 이 baseline 대비 통계적으로 압도하며, 추정 오차 6 ~ 14 퍼센트 절감, 정확도 1.06 배 ~ 1.14 배 향상 효과가 일관되게 나타납니다. 단일 알고리즘의 우연한 효과가 아니라 paradigm 차원에서 robust 한 개선임을 시사합니다.

7.2 결정적 비교 — 대체 vs 증강

본 연구의 핵심 발견은 **대체와 증강의 결과 차이**입니다.

대체 (CaseA) — paper 의 Bernoulli baseline 을 우리 method 로 **단독 교체** 한 경우 493 cells 중 paper baseline 보다 우위인 cell 은 **0 cell, 즉 0 퍼센트** 입니다. 반대로 large worsening (효과 크기 large 수준의 악화) 은 37.1 퍼센트입니다. 즉 단독 대체는 통계적으로 무효입니다.

증강 (CaseB) — paper Bernoulli 와 우리 method 를 **산술 평균 결합** 한 경우 492 cells 중 paper baseline 보다 우위인 cell 은 **455 cell, 즉 92.5 퍼센트** 입니다 ($p < 10^{-45}$). 효과 크기로 보아도 Cliff's δ 가 large 수준인 비율이 63.0 퍼센트, Hedges' g 가 large 수준인 비율이 55.7 퍼센트로, 다양한 비모수 / 모수 통계 지표가 동일 방향을 가리킵니다.

이 negative control 결과가 본 연구의 결론을 명확히 합니다. **단독 대체는 무효이며, 증강 결합만 유효합니다.**

8. 왜 대체는 안 되고 증강만 되는가

세 가지 측면에서 분석됩니다.

첫째, **sample budget 의 분배 문제** 입니다. paper $N=385$ sample budget 을 stratified 추정 단독으로 사용하면 20 개 stratum 평균 19 sample 씩 분배됩니다. stratum 마다 19 개의 sample 로는 stratum 내부 변동을 신뢰성 있게 추정하기 어렵습니다. 반면 결합 방식에서는 paper Bernoulli 가 budget 전체를 사용하면서 stratified 가 보조 추정값을 제공하므로 budget 활용이 효율적입니다.

둘째, **통계적 가정의 충돌** 입니다. paper 의 sample size 동적 조정 식 (Eq 1-6) 은 무작위 sampling 의 i.i.d. 와 asymptotic normal 분포 가정 위에 설계되어 있습니다. stratified 추정값은 부분 분포 (cluster 별) 정보를 활용하므로 통계 분포 자체가 다르고, 따라서 단독으로 paper Eq 1-6 에 넣으면 가정이 위반됩니다. 결합 방식에서는 Bernoulli 추정이 가정을 충족하면서 stratified 가 정보를 보강하는 구조라 충돌이 없습니다.

셋째, **실험적 입증** 입니다. negative control 결과 (493 cells 중 0 cell outperform) 가 두 방식의 본질적 차이를 실증합니다. 단순 비교가 아니라 paper review-grade evidence 로 입증됩니다.

결합 방식의 본질은 **무작위 sampling 의 bias=0 특성과 분포 인지 sampling 의 variance 안정성** 을 산술 평균으로 결합하는 것입니다. 한 쪽이 fail 해도 다른 쪽이 보완하는 robust 구조입니다.

9. 한계와 향후 영역

본 연구가 측정하지 않은 영역을 정직하게 명시합니다.

첫째, **paper §V-A 의 multi-table 영역** 은 본 연구 §V-B sampling 영역과 별개로 paper main result 그대로 인정합니다. 측정한 multi-table cell (A2-Fig7, A2-Fig9) 의 stratification 학습 방식은 single table 에서 학습한 KM20 cluster 를 join 후 carry-over 하는 방식이며, 두 테이블 join 후 별도 stratification 학습은 본 연구의 scope 외입니다.

둘째, **ensemble augment 의 비용 overhead** — latency 와 memory — 는 본 측정에 포함되지 않았습니다. paper §V-B 재현 scope 에 정확도 측정만 포함되어 있어 추후 측정 영역 (cost-quality tradeoff) 으로 한계를 명시합니다.

셋째, **paper N=385 budget 위반 알고리즘 9 가지** (균등 격자 paradigm 의 Halton/Sobol/LHS/Hammersley + 일부 다른 paradigm 알고리즘) 는 발표 자료에서 폐기했습니다. paper sample budget 정의 위반으로 정합성을 보장할 수 없기 때문입니다.

10. 발표 일정과 활용

- 5/15 (금) 14:00 — 박광현 교수님 미팅 (D-3)
- 5/27 (화) 19:00 — 캡스톤 최종 발표 (D-15)
- 5/28 (목) — 임채림 박사 SAP 미팅 (본 연구 결과 활용 예정)

발표 자료 (키노트 v4 PDF) 는 본 가이드의 §3 ~ §7 핵심 내용을 20 슬라이드로 구성한 것입니다. 발표자 (강재현) 는 별도의 **발표 storyline 가이드** 를 참조해 슬라이드 흐름과 청중 narrative 를 준비합니다.

본 가이드와 키노트 deck, 자주 묻는 질문 자료를 함께 읽으면 5/27 발표 청중과 5/15 박광현 교수님께 본 연구의 contribution 을 명확히 전달할 수 있습니다.

작성: 2026-05-12 KST · 5/27 최종 발표 D-15 시점

관련 자료: 같은 폴더의 **한 페이지 요약** / **발표 storyline 가이드** / **자주 묻는 질문** / 키노트 v4 deck PDF