

5월 15일 박광현 교수님 미팅 — 핵심 정리 (v2, 4차 정정)

수신: 박광현 교수님 · 임채림 석사 발신: 속도는벡터 (박세은·강재현·조현빈·이동욱) 일시: 2026-05-15 (금) 14:00 미팅 — 사전 배포용 (D-1) 작성: 2026-05-14 (5/13 v1 → 5/14 v2 4차 정정)

들어가는 말

이 글은 5월 15일 미팅 전에 본 연구의 현재 상태를 교수님과 임채림 석사님께 사전 공유드리기 위해 작성한 자료다. 4월 28일 중간 보고서 이후 5월 한 달 동안 우리가 진행한 측정과 분석의 핵심 결과를 정리했고, 미팅 자리에서 교수님께 확인 받고 싶은 항목을 마지막에 따로 모아 두었다. 분량을 3-4 페이지로 맞춰서, 미팅 직전에 빠르게 훑어보실 수 있게 했다.

전체 흐름은 청자가 따라올 수 있는 일곱 단계의 순차 흐름으로 잡았다. 먼저 문제를 정의하고, 분포 인지 방법 56개를 탐색하면서 어떤 것이 측정 가능한지 정리하고, 단독 대체 가능성을 분석한 다음, 결합 framework를 검토하고, 자원 효율을 함께 살펴본 뒤, 본 연구의 권장 design을 추출하고, 마지막에 method 메커니즘 분석을 부록으로 둔다.

본 v2의 핵심 보강 두 가지를 먼저 짚어 둔다. 첫째, 5월 14일 새벽까지 추가 측정 (가중치 변화 sweep 16 measurement + 저비용 결합 방식 4 후보 32 measurement)이 회수되어 본 연구의 narrative가 확정되었다 — **단독 대체 가능 method의 발견이 본 연구 main finding이고, 결합 framework의 가치는 "더 큰 개선"이 아니라 "안정성 보강 + 자원 효율"이라는 정직한 narrative.** 둘째, 박세은 5월 13일 12:13 카톡 피드백 ("method 개수가 너무 많아서 헷갈림" + "성능 수치 외에는 숫자/공식 최소화")을 반영해서 본문에서는 핵심 method 5개만 자세히 짚고, 폐기 method명 전체 list와 통계 검정 jargon은 부록으로 분리했다.

1. 문제 정의 — 우리가 들여다본 영역

Exquitor 논문 (arXiv:2512.09695v2)의 §V-B 적응적 샘플링 영역, 즉 인덱스가 없을 때 작동하는 베르누이 무작위 샘플링 부분을 본 연구의 범위로 잡았다. paper 본문이 사용한 베르누이 샘플링이 데이터가 한쪽에 몰린 (skew) 분포에서 얼마나 정확한지, 그리고 더 정확하게 만들 수 있는 방법이 무엇인지를 측정한다.

RQ1 (PostgreSQL TABLESAMPLE SYSTEM vs BERNOULLI) 결과로, 본 논문이 사용한 베르누이가 두 옵션 중 더 나은 쪽임을 정량 확인했지만 (SIFT 선택도 0.05 에서 SYSTEM 이 BERN 보다 최대 17.32% 더 부정확), 베르누이조차 분포에 따라 정확도가 달라진다는 출발점이 된다. RQ2 (5-way 할당) 결과로, 분포를 알면 비례 할당이 답이라는 한 줄 요약 (-9.53% 개선) 과 함께 Neyman 역설 (1.595 vs 1.580) 의 자연 원인 (PartSupp PK 의 좁은 분포 특성) 을 정리했다. RQ3 의 출발점은 "실제 운영에서는 분포를 모를 때가 많다" 는 점이다.

2. 분포 인지 방법 56 개의 탐색 — 폐기 분류와 측정 가능 method

RQ3 의 첫 단계로 분포 정보를 얻으려는 후보 method 56 개를 8 패러다임 (클러스터링, 공간 분할, 스트리밍, 차원 축소, 정보 이론, 양자화, 준 무작위, 밀도 추정) 으로 모아 9 cell 매트릭스에서 측정을 시도했다. 측정을 진행하면서 일부 method 는 그대로 둘 수 없는 문제가 발견되어 폐기했는데, 폐기 사유를 3 범주로 정리한다 (구체적인 method 명 list 는 부록 H 참조).

(1) 자원 한계 — 측정 서버의 메모리 한계로 실행이 불가능하거나, 한 cell 측정에 4 시간 이상의 timeout 이 필요해서 전체 portfolio 마감에 맞추기 어려웠던 method. 가장 대표적인 birch 는 클러스터를 트리 구조로 저장하는 부분이 50 ~ 200GB 메모리를 차지해서 실행 자체가 불가능했고, agglomerative 는 256 차원 데이터셋에서 모든 점 쌍의 거리를 한꺼번에 계산하다가 메모리 부족으로 실패했다. kde_parzen 은 한 cell 측정에 4 시간 이상의 timeout 이 필요해서 전체 portfolio 마감 안에 완성할 수 없었다.

(2) 알고리즘 구현 결함 — 5월 10일에 8-agent 정독 검토로 발견된 reference 위반이나 알고리즘 잘못 표기. 가장 인상적인 사례는 vinecopula 의 코드 구현이 rank 변환 + PCA 1 차원 정렬의 별칭으로 되어 있어서 Bedford-Cooke 1986 의 진짜 vine copula 가 아니라는 점, 그리고 neuram 이 코드 한 줄씩 검토한 결과 PCA1D 와 100% 동일하다는 점이다. kdtree 의 알고리즘 구현 코드를 보면 leaf 인덱스가 단순한 modular hash (`idx % n_strata`) 로 처리되어 있어서 무작위 표집과 거의 동등 — paper 가 의도한 kdtree 의 공간 분할 효과가 아니다.

(3) 적합성 위반 — 큰 데이터셋에서 추정값이 +145,483%, +213,065% 같은 외곽 값으로 나타나서 paper 가 정의한 sample budget 안에서 estimator 의 적합성을 보장하지 못하는 method.

2.1 남은 측정 가능 method 의 paradigm 평균

폐기를 거치고 남은 측정 가능한 method 43 개를 8 패러다임으로 묶어 평균 효과 (결합 모드) 를 보면, 다섯 개 paradigm 이 평균적으로 의미 있는 우위를 보인다.

paradigm	평균 개선폭	대표 anchor method
밀도 추정	-11.93% (n=1)	Parzen KDE
정보 이론	-7.60% (n=9)	HyperLogLog
스트리밍	-6.63%	Chao 1982 weighted reservoir
차원 축소	-6.03%	Sparse Random Projection
공간 분할	-5.57%	Hilbert curve, Z-order

paradigm 평균이 일부 method 의 극단값에 끌려가는 경우가 있어서 (클러스터링 안의 wavelet_hist +68%, 차원 축소 안의 lp_bound +16%), 본 연구는 이 표를 보조로 두고 method 단위 분석을 별도로 제시한다 (부록 A 참조).

3. 단독 대체 가능성 분석 — paper 의 베르누이를 우리 method 로 바꿔도 되는가 (★ 본 연구 main finding)

남은 43 method 의 추정값을 본 논문의 베르누이 대신 그대로 갈아 끼우는 단독 대체 모드 (CaseA) 의 측정 결과를 정직하게 풀어 정리한다.

- **평균 우위 약 40%:** 56 방법 중 약 40% 가 평균적으로는 베르누이 기준선보다 정확.
- **통계 일관 우위 7.6% (15/197):** 같은 method 라도 데이터셋과 cell 마다 효과의 편차가 컸다. 통계 검정에서 cell 전반에서 안정적으로 베르누이를 우위로 누른 method 는 7.6% 정도.
- **15 method 의 평균 개선폭 -5 ~ -12%:** 단독 대체로 통계 일관 우위인 15 method 의 평균 개선폭은 -5 ~ -12% 다. 이는 paper 자체 재현 시 발생하는 측정 변동 (-4.3%) 보다 1.2 ~ 3 배 큰 의미 있는 개선이다. 즉 **단독 대체로도 noise floor 를 넘는 실제 개선이 가능한 method 가 존재.**
- **단독 best:** 본 측정 portfolio 의 단독 best 는 minibatch_partial 의 -10.17% 개선이다. 결합 best (-7.37%) 보다도 큰 개선폭으로 본 연구의 단독 대체 가능 발견이 핵심 contribution 이다.

★ 단독 대체 가능 method 후보 6 개 (5/14 정리, narrative v1 §11 과 통일): - **minibatch_partial:** 클러스터링 기반 (Sculley 2010). 단독 best (-10.17%). - **sparse_rp:** 차원 축소 기반 (Li-Hastie-Church 2006). 학습 0.1초 (최단) + 평균 -5 ~ -12% 개선. - **chao_weighted:** 스트리밍 기반 (Chao 1982). 학습 0.5초 + 메모리 매우 적음 + 안정 정확도. - **hilbert_real:** 공간 분할 기반 (Faloutsos 1989, ★3 정정 후 진짜 Hilbert curve). 학습 cheap + 정확도 강력. - **hyperloglog:** 정보 이론 기반 (Flajolet 2007). std 2.73 으로 가장 안정적. - **reservoir:** 스트리밍 기반 (Vitter 1985). 메모리 O(1) 로 자원 가장 적음.

본 6 단독 대체 후보의 자원 효율 분석은 5 장에서 다룬다. 별도의 자세한 알고리즘 메커니즘 + 이론적 근거 + 실측 결과는 [속도논벡터_본연구_narrative_최종정리_v1.md](#) §11 참조.

다만 단독 대체는 cell 별 spread 가 커서 산업 적용 보장에는 안정성 부족 — 이 안정성 부족이 결합 framework 검토의 motivation 이다.

4. 결합 framework 검토 — 산술 평균이 효과적인가

단독 대체의 안정성 부족을 보완하기 위해 검토한 다음 방향이 두 추정값을 결합 (combine) 하는 framework 다. 가장 단순한 결합 방식 — 산술 평균 (0.5 / 0.5) — 으로 측정을 진행했다.

산술 평균 결합 모드의 측정 결과: 베르누이 추정값과 우리 method 추정값을 단순 평균한 결과, 492 짝지어 비교한 측정 중 92.5% (455) 에서 베르누이 단일 baseline 보다 더 정확. 통계 검정에서도 분명한 차이 (p-value 매우 작은 값). 12 anchor method 는 cell 전반에서 -9 ~ -10% 의 일관된 개선과 안정적인 spread.

왜 산술 평균이 효과적인가: 베르누이 무작위 샘플링은 편향이 0 이지만 분산이 크다. 클러스터 기반 계층적 표집 추정량은 분포 가정이 맞을 때는 분산이 작지만, 가정이 빗나가면 편향이 생길 수 있다. 두 추정값을 산술 평균하면 한 쪽이 실패할 때 다른 쪽이 보완해 주는 안정적인 구조가 된다. 즉 "단일 추정량의 안정성 한계를 결합으로 보강한다" 가 본 연구의 결합 framework narrative 다.

4.1 가중치 sweep 결과 (5/14 새벽 회수, 16 measurement)

산술 평균 외 다른 가중치도 측정해 봤다. 베르누이 가중치 0.3 / 0.4 / 0.5 / 0.6 / 0.7 다섯 값으로 가중 평균을 측정한 결과:

- 4 anchor method 중 3 개가 가중치 0.5 (산술 평균) 에서 best.
- 가중치 0.3 (우리 method 가중) 과 0.7 (베르누이 가중) 양쪽 극단에서 효과 감소.

→ 산술 평균이 결합 방식 중 best 이며, 가중치 변화로 더 큰 개선 어렵다 라는 확정 결과. 이 결과는 본 연구의 결합 framework 의 정확한 위치를 드러낸다.

4.2 저비용 결합 방식 4 후보 결과 (5/14 새벽 회수, 32 measurement)

산술 평균 외 다른 결합 방식 후보 — Centroid tuple (5/13 강재현 14:27 카톡 제시) / Hash bucketing / PCA preprocessing / Iterative refinement — 의 32 measurement 회수 결과:

- Centroid tuple 만 결합 모드 4 method 모두에서 보편 우위 (평균 -0.84%p 추가 정확도). 학습 비용 추가 0 + 더 좋은 정확도의 "더 싸고 더 좋은" 패턴.
- 나머지 3 후보 (Hash / PCA / Iterative) 는 method × mode 별로 spread 크거나 일부 영역에서 marginal/harmful.

4.3 결합 framework 의 진짜 위치 — 정직 disclosure

가중치 sweep + 4 cheap 근사 후보 측정을 종합한 결과 본 연구의 결합 framework 의 정확한 위치가 드러난다:

- 단독 best (-10.17% minibatch_partial) > 결합 best (-7.37% sparse_rp Centroid tuple)
- 결합으로 단독 best 능가 불가 — 이것이 본 연구의 정직한 disclosure
- 결합의 진짜 가치 = method 선택 robustness + cell spread 줄임 ("더 큰 개선" 이 아님)

이 정직한 위치 입증이 본 연구 narrative 의 강점이며, "결합으로 단독 best 능가" 라는 잘못된 주장을 회피한다.

더 좋은 결합 방식이 있는가: 가중치 sweep + 4 cheap 근사 후보 측정으로 본 연구의 결합 framework 가 산술 평균 + Centroid tuple 의 정확도 sweet spot 임이 확정되었다. 추가 결합 방식 (기하 평균, 분산 기반 등) 비교는 future work 다. 미팅에서 교수님께 결합 방식 비교 우선순위를 자문 받고 싶다.

5. 자원 효율 분석 — 학습 비용을 고려하면 어떤 method 가 실용적인가 (★ 산업 적용 핵심)

성능 (정확도) 만으로는 산업 적용을 결정할 수 없다. 학습 시간, 메모리 사용, 차원 한계가 method 마다 다르기 때문이다.

5.1 Pareto frontier 분석

학습 시간 (fit elapsed) 과 정확도 개선폭의 두 axis 로 Pareto frontier 를 도출하면 다음 5 method 가 frontier 상에 위치한다.

Method	학습 시간	정확도 개선	메모리
sparse_rp	0.1초	-9.43%	$O(D \cdot k)$ ~MB
chao_weighted	0.5초	-9.60%	$O(K)$ ~KB (최저 영역)
neuram	0.5초	-9.97% (최고)	$O(K \cdot D)$ bounded
pca1d	0.5초	-9.63%	$O(N)$
hilbert / hilbert_real	0.1-0.5초	-9.27 ~ -9.41%	$O(N)$

이 5 method 는 anchor 일관성 12 명단과도 일치한다. 학습 시간 0.1-0.5 초의 매우 적은 비용으로 anchor 수준 정확도 개선을 제공한다.

5.2 산업 적용 3 영역 추천

본 자원 효율 분석을 바탕으로 산업 적용 3 영역의 method 추천:

영역 A — Best of Both Worlds (일반 OLAP server): sparse_rp 또는 chao_weighted. 학습 0.1-0.5초 cheap + 정확도 anchor 수준 + 메모리 작음. 본 연구의 가장 균형 잡힌 권장 method.

영역 B — Quality-First (정확도 우선): neuram. 학습 0.5초이지만 본 측정 portfolio 정확도 최고 (-9.97%). 정확도 절대 우선 application 영역.

★ **영역 C — Resource-First (모바일/embedded/streaming):** reservoir. 학습 0.1초 + 정확도 anchor 수준 (-9.25%) + **메모리 O(1) — 본 측정 portfolio 최저**. 자원 제약이 매우 큰 환경 (메모리 < 100MB, 학습 시간 < 100ms) 에 가장 적합. 이 발견이 본 연구의 가장 강력한 산업 적용 finding 이다.

5.3 cheap 근사 — Centroid tuple 의 "더 싸고 더 좋은" 패턴

multi-table cell (예: DEEP + WIKI cross) 에서 계층적 표집을 어떻게 할지의 문제가 있다. 두 가지 후보가 있다.

- **비싼 multi-join 재학습:** 두 벡터를 864 차원으로 합친 후 KM20 을 처음부터 다시 학습. 학습 시간이 single-table 의 2 배 + 추가 disk I/O.
- **cheap 근사 (Centroid tuple, 강재현 5/13 14:27 카톡 제시):** 두 single-table 의 클러스터 결과를 (s_A, s_B) tuple 로 합쳐서 그대로 사용. 학습 비용 0 추가.

8 measurement 결과를 비교하면, 결합 모드에서 4 method 모두 (sparse_rp, chao_weighted, hilbert_real, hyperloglog) cheap 근사가 비싼 재학습보다 평균 -0.84%p 정확도가 더 좋다. "더 싸고 더 좋은" best of both worlds 결과로, multi-table 영역 확장의 cheap 근사 가능성을 보여 준다.

5.4 단독 대체 vs 결합의 자원 비교

단독 대체는 우리 method 만 사용하므로 학습 비용 = 우리 method 학습 비용. 결합은 베르누이와 우리 method 두 estimator 의 합인데, paper 의 sample budget 을 두 estimator 가 공유하므로 query 시 추가 시간은 거의 없다. 학습 단계에서도 우리 method 만 학습하면 되므로 단독 대체와 동일. 즉 결합의 자원 추가 부담은 무시 가능.

6. 성능과 자원 사이의 경계 — 본 연구의 권장 design

성능 (단독 대체 -5 ~ -12% + 결합 92.5% 안정성) 과 자원 (cheap 근사로 0 학습 비용 추가) 사이의 균형 영역에서 본 연구가 권장하는 design 을 추출한다. 본 v2 의 핵심 narrative 갱신은 단독 대체 우선 + 결합 보조의 흐름이다.

1. **단독 대체 적용 우선** — 15 단독 대체 가능 method 중 산업 환경에 맞는 method 선택 후 paper 베르누이를 우리 method 의 추정값으로 갈아 끼우는 가장 단순한 방식. 평균 -5 ~ -12% 의 의미 있는 정확도 개선 가능.

2. **결합 framework 보조 사용** — 단독 대체의 cell 별 spread 가 산업 적용에 부담될 때, 산술 평균 결합으로 안정성 보강. 92.5% 짝지어 비교 우위로 cell spread 줄어듦고 method 선택 robustness 확보. multi-table 영역에서는 Centroid tuple 저비용 결합 방식이 학습 비용 추가 0 으로 추가 정확도 개선 제공.

3. **method-aware 선택적 적용** — 12 anchor method 중에서도 cell 별 K-민감도와 quality-민감도 패턴이 다르므로, sparse_rp 와 chao_weighted (quality-sensitive group) 에는 정밀 처리, Hilbert curve 와 HyperLogLog (quality-robust group) 에는 단순 처리.

산업 적용 영역은 두 가지. (1) PostgreSQL pgvector 의 default sampling 메커니즘에 우리 method 의 stratified estimator 를 단독 대체 또는 산술 평균 결합으로 추가. (2) Exqutor 의 \$V-B 모듈에 우리 안 (단독 대체 우선 + 결합 보조 + cheap 근사 + method-aware) 을 통합.

7. paper 재현 정합성

본 연구는 Exqutor 논문의 \$V-B 영역 — vector index 가 없을 때 베르누이 무작위 샘플링과 모멘텀 기반 동적 sample size 조정 — 에 대해 paper 의 모든 hyperparameter, query 정의, threshold, 절사 (trim) 통계를 그대로 재현했다. 정합성은 네 축에서 확인했다.

첫째, 결정론적 재현성 검증에서 전 항목이 byte-identical 으로 일치. 둘째, paper 의 동적 sample size 조정 식과 모든 hyperparameter 가 코드 한 줄씩 일치. 셋째, paper Fig 12 영역의 절사 평균 Q-error 가 본 측정 vs paper 보고값으로 -4.3% 차이, 측정 변동 범위 안에서 일치. 넷째, JSON 산출물 전수 검사에서 결손 없음.

이 정합성은 우리 결과가 "paper 재현으로서 충분한 baseline" 임을 보장한다. 이후 우리가 추가한 계층적 표집 산술 평균의 효과는 이 baseline 위에서 짝지어 비교로 측정된다.

8. 한계 — 측정 미커버 9 카테고리 정직 분류

본 연구는 측정 portfolio 9 cells × 56 method × 2 modes 매트릭스에서 본 비교 실험군에 해당하는 method 는 모두 9 cells × 2 modes 완료. 미커버 영역을 9 카테고리 정직하게 분류한다.

가장 큰 비중은 자원 한계 (birch CFNode tree 의 50-200GB 메모리 폭증, agglomerative 의 256d OOM) 와 알고리즘 정독 검토로 폐기한 23 method 다. 5월 10일에 8-agent 정독 검토로 reference 위반이나 알고리즘 잘못 표기가 발견된 method 들은 학술 정직성 위반이므로 보고서에서 제외한다. 그리고 paper \$V-A multi-table 영역은 우리 연구의 \$V-B 샘플링 영역 범위 외다.

또한 method 단위로 정직하게 짚어 둘 부분이 두 건 있다. 첫째, hilbert method 가 코드에서 실제로는 PCA 2D 정렬로 구현된 것이라서 Faloutsos 1989 의 진짜 Hilbert curve 효과가 아닌 PCA 대용 (proxy) 효과를 측정한 것이다. 이를 별칭으로 `pca2d_lex` 라고 명명하고, 진짜 Hilbert curve 는 Wikipedia 표준의 hilbert_real (9 cells × 2 modes 별도 측정) 로 paradigm 대표 방법을 따로 두었다. 둘째, RQ2 의 5-way 측정에서 Neyman 할당이 비례 할당보다 약간 부정확한 역설이 발견되었는데, 이는 PartSupp PK 의 클러스터 균등 분포 (변동 계수 = 0) 이고 클러스터 내 분산 범위가 좁아서 (1.3 ~ 1.6 배) σ -가중 Neyman 이 proportional 과 통계적으로 동등이 되는 자연스러운 결과다.

부록 A — Method 메커니즘 분석 (도메인 전문가 자문 영역)

본 부록은 본 연구의 핵심 주장 중에서도 학술적 정밀도가 가장 필요한 부분으로, 박광현 교수님께 자문 받고 싶은 영역이다. 미팅 본문 시간에 자세히 다루기 어렵지만, 본 연구가 paradigm 평균보다 더 본질적인 method 분류 axis 를 발견했다고 보는 근거를 정리한다.

A.1 paradigm 평균의 한계

8 paradigm 평균을 보면 paradigm 안의 일부 method 가 극단값 (예: wavelet_hist +68%, lp_bound +16%) 으로 평균을 끌어 올리거나 끌어 내릴 수 있다. 이런 극단값을 제외하면 paradigm 안의 각 대표 방법 (anchor method) 들은 -9 ~ -10% 의 일관된 개선과 안정적인 spread 를 보인다.

A.2 12 anchor method 의 일관성

본 연구가 제안하는 12 anchor (lpm2, hilbert, sparse_rp, hilbert_real, minibatch, chao_weighted, neuram, pca1d, reservoir, thompson_sampling, hyperloglog, opq, pq) 는 9 cells 전반에서 -9 ~ -10% 의 일관된 개선과 안정적인 spread 를 보인다. "어떤 method 가 다양한 환경에서 모두 비슷한 정도로 개선한다" 의 일관성 (consistency) 이다.

A.3 3-axis sensitivity 분석 (2 axis 일치 + 1 axis 다른 분류)

본 연구는 팀원 강재현이 5월 13일 0:20 및 14:27 카톡으로 제기한 후속 가설 두 가지 — multi-table 재계층화의 정확도 영향과 저비용 근사 가능성 — 를 정량 검증하였다. 5월 12 ~ 13일에 진행한 세 가지 추가 측정 결과가 method 별 민감도 패턴을 보인다.

(1) **K granularity 민감도**: 클러스터 개수 K 의 민감도가 method 마다 다르다. K 를 10, 20, 30 으로 바꿔 보았을 때 sparse_rp 는 K=20 에서 sweet spot 의 U 모양, Hilbert curve / HyperLogLog / Chao 의 세 method 는 K 값에 거의 영향 없음.

(2) **multi-join 재학습 — quality-sensitive vs quality-robust 분기**: 두 개의 벡터 테이블을 join 한 multi-join 상황에서 계층적 표집 학습 방식을 바꾸면 어떻게 되는가? 비싼 multi-join 재학습 8 measurement 결과, sparse_rp 와 chao_weighted 는 CaseA 모드에서 추가 개선, Hilbert curve 와 HyperLogLog 는 거의 차이 없음. CaseB 결합 모드에서는 4 method 모두 차이 없음 — 우리 핵심 기여인 결합 모드는 학습 방식 변경에 안정적.

(3) **Centroid tuple cheap 근사**: 비싼 multi-join 재학습을 single-table 클러스터 결과의 tuple folding 으로 저비용 근사. 결합 모드에서 4 method 모두 비싼 재학습보다 오히려 정확도 더 좋음 (평균 -0.84%p 추가 개선).

A.4 세 축 분석이 시사하는 본질적 분류 — 2 axis 일치 + 1 axis 다른 패턴

3-axis 분류 매트릭스로 정리하면 다음과 같다.

Method	K granularity	Multi-jn	Cheap 근사 친화도
sparse_rp	K-sensitive (U-shape)	sensitive	Indifferent
chao_weighted	K=20 sweet	sensitive	Friendly
hilbert_real	K-robust	robust	Hostile (CaseA harmful)
hyperloglog	K-robust	robust	Friendly

K granularity 변화와 multi-table 재계층화 두 측정에서 method 별 민감도 패턴이 일치 (sparse_rp + chao_weighted sensitive vs hilbert_real + hyperloglog robust). 그러나 저비용 근사 친화도는 다른 분류 패턴 (Friendly: hyperloglog + chao_weighted). 즉 method 의 내부 메커니즘이 측정 영역에 따라 다른 영향을 미친다. 2 axis 일치는 method-level consistency 의 evidence 이지만, 1 axis 다른 분류는 method 의 메커니즘 차이가 단순 sensitivity 분류로 환원되지 않음을 시사한다.

이 부분이 학술적으로 어떻게 표현되어야 적절한지 (논문 리뷰어 관점에서 paradigm 평균을 핵심으로 가는 게 적절한지, method-level consistency 와 3-axis 분석 을 핵심으로 가는 게 적절한지) 가 박광현 교수님께 자문 받고 싶은 영역이다.

9. 향후 연구 방향

본 연구는 산술 평균이라는 가장 단순한 결합 방식부터 측정을 시작하여 결합 framework 자체의 효과를 baseline 수준에서 입증하였다. 실제 산업 적용을 위해서는 데이터셋의 분포 특성, 차원, 질의 선택도에 따라 결합 방식이 동적으로 결정되는 data-aware ensemble framework 가 필요하다. 본 연구의 산술 평균 결과는 그 framework 의 출발점이며, 향후 연구는 두 그룹으로 나뉜다.

9.1 Data-aware ensemble framework — 핵심 5 영역

1. **Distribution-aware ensemble** — skew / dense 데이터셋에 따라 결합 가중치 동적 결정
2. **Dimensionality-aware ensemble** — 차원 별 결합 방식 선택
3. **Estimator-confidence-aware** — 각 estimator 의 분산 추정 기반 분산 최소화 가중치
4. **Query-aware ensemble** — 선택도 별 결합 방식 변경
5. **Meta-learning adaptive ensemble** — 측정 환경 특성으로 결합 가중치 학습

9.2 일반 확장 5 영역

1. **다른 데이터셋 일반화** — YFCC, GLOVE 등에서 동일 패턴 검증
2. **이론적 분산 분해** — Cochran 1977 §11.10 composite estimator 적용
3. **논문 동적 framework 와의 완전 정합** — Q-error 신호 source 명시
4. **실제 시스템 적용** — pgvector 또는 Exqutor prototype 통합
5. **다른 결합 방식 추가 비교** — 본 연구의 가중치 sweep + 4 cheap 근사 후보 외 다른 결합 방식

10. 교수님께 확인 요청드리는 항목

미팅 자리에서 교수님께 확인 받고 싶은 항목은 다음과 같다.

첫째, "본 연구의 기여가 paper §V-B 적응적 샘플링 영역에 한정된 산술 평균 보강이라는 narrative" 가 논문 리뷰 관점에서 적절한가? 우리는 §V-A ECQO 는 paper main result 로 그대로 인정하고, §V-B 영역의 베르누이 단계에 계층적 표집을 산술 평균으로 결합하는 부분만 우리 기여로 좁혔다.

둘째, 본 v2 에서 narrative 가 단독 대체 우선 + 결합 보조의 흐름으로 갱신되었다 — **단독 대체 가능 method 15 발견이 main finding 이고, 결합 framework 의 가치는 "더 큰 개선" 이 아닌 "안정성 보강 + 자원 효율" 이라는 정직한 narrative.** 가중치 sweep + 4 cheap 근사 후보 측정으로 "결합 best (-7.37%) < 단독 best (-10.17%)" 임이 정량 입증되었다. 이 정직한 narrative 가 학술적 발표 흐름으로 적절한가?

셋째, paradigm 평균과 method 단위 일관성 중에서 어느 쪽을 핵심 narrative 로 가는 게 적절한가? 우리는 부록 A 의 method-level consistency 와 3-axis sensitivity 분석을 본 연구의 진짜 main contribution 으로 잡고, paradigm 평균을 보조 표로 두는 방향을 선호한다.

넷째, 자원 효율 axis 분석의 **reservoir O(1) memory + anchor 수준 정확도 finding** 이 본 연구의 가장 강력한 산업 적용 narrative 라고 보는데, 이 산업 적용 강조가 학술적 contribution 으로 적절한가? Pareto frontier 의 Top 5 method (sparse_rp / chao_weighted / neuram / pca1d / hilbert) 는 anchor 일관성 12 명단과 일치한다.

다섯째, 5월 27일 발표와 6월 11일 보고서 사이의 한 달 동안 추가 측정 영역 우선순위는? 우리가 후보로 보는 것은 (1) YFCC 등 다른 데이터셋에서의 안정성 검증, (2) multi-table 영역의 Centroid tuple cheap 근사 확장 측정, (3) BLUE estimator 의 분산 최소화 가중치 추가 비교 — 이 세 가지.

11. 상세 자료

미팅 자리에서 더 자세히 보실 수 있는 자료는 다음과 같다.

- 박광현 5월 15일 미팅 슬라이드 초안 (2 slide 학술 산문 + 부록)
- 본 핵심 정리 v2 (본 문서, 3-4 page)
- 측정 REPORT v11 (서버 또는 GitHub [experiments/results/](#))
- 분석 file 7 건 ([_internal/analysis/](#))

미팅 시간이 짧을 경우 본 문서만 보셔도 핵심 내용은 모두 포함되어 있다. 부록 A 의 method 메커니즘 분석은 Q&A 에서 필요할 때 참조한다.

부록 H — 폐기 method 전체 list (박세은 5/13 12:13 피드백 반영)

본문에 핵심 method 만 짚고 폐기 method 명 전체 list 는 이 부록으로 분리.

자원 한계 폐기 7 종: birch, agglomerative, hdbscan, kde_parzen, dirichlet, kernelpca, neuocard.

알고리즘 구현 결함 폐기 23 종: 5월 10일 8-agent code audit 발견. 주요 사례 — kdtree ([idx % n_strata](#) 와 등가), vinecopula (rank+PCA1D 별칭), neuram (PCA1D 100% 동일), ams_count_sketch (lsh 와 한 줄씩 동일) 등.

정합성 위반 폐기 9 종: halton, sobol, lhs, hammersley, dense_rp, random_projection, dbscan, ccsketch, lsh, ams_count_sketch.

작성: 2026-05-14 KST · 미팅 D-1 · v2 4차 정정 (5/14 새벽 측정 회수 반영 + 박세은 피드백 반영)