

속도는벡터 — 5/8 회의 RQ 진행 종합 정리

작성: 조현빈 · 2026-05-07 12:00 KST **대상:** 박세은 · 강재현 · 이동욱 **범위:** 5/7 W1 sprint 보강 작업 종합 — 모든 데이터셋·변수에 대한 측정 진행 검증 포함 **다음:** 5/8 19:00 비대면 회의 D-1 / 5/27 발표 D-20 / 6/11 보고서 D-35

1. 프로젝트 큰 그림

1.1 데이터셋별 진행 상황 (5/7 11시 기준)

데이터셋	분포	차원	측정 method 수	비고
DEEP 1M	Normal	96	22개 ✓	RQ1·RQ2·RQ3 1차 baseline
SIFT 1.5M	Skew	128	22개 ✓	RQ1·RQ2·RQ3 skew 비교
DEEP 8M	Normal	96	19개 ✓	RQ3 cross-scale (KM20 X)
멀티 테이블 join	—	—	future work	Exqutor main scope

1.2 측정 cell 검증 종합

각 RQ에서 실제 측정된 cell 수와 기대치 비교 (5/7 직접 parquet 검증 결과).

RQ	변수 구성	기대 cell	실제 cell	상 태
RQ1 (phase 6 layer)	100q × 5sel × 4mode × 2ds × 3 layer	12,000	12,000	✓
RQ1 (numpy remeasure)	100q × 5sel × 2 seed avg	1,000 / sel	1,000 / sel × 5 sel	✓
RQ1 (SIFT mid-sel)	100q × 3 sel × 5 seed × 2 mode	3,000	3,000	✓
RQ1 (RANDOM20 baseline)	100q × 6 sel	600 / mode × 2 mode	600 + 600	✓
RQ2 (5-mode alloc)	5 mode × 5sel × 5seed × 100q × 2ds	25,000	25,000	✓
RQ2 (size sensitivity)	5 sel × 4 ssize × 2 mode × 5 seed × 100q × 2 ds	40,000	40,000	✓
RQ3 1M (22 method)	5 sel × 5 seed × 100q × 2 ds = 5,000 / method	110,000	132,000 (variants 5종 IS 포함)	✓
RQ3 8M (19 method)	2 sel × 5 seed × 100q = 1,000 / method	19,000	25,000 (variants 포함)	✓

누락 cell: 0건 (모든 RQ × 데이터셋 × selectivity × seed 조합 측정 완료)

알려진 caveat: - RQ3 IS (Importance Sampling) NaN 18.9% (1M) / 1.1% (8M) — narrative에 명시 (estimator unstable) - RQ3 PQ NaN 2.6%, Spectral 1.6%, Sobol 1.5% — failure mode 자체가 narrative 결과 (negative control) - σ table DEEP 1M / SIFT wiped (8M σ 만 잔존) — W2 권고 (측정 시점에는 valid, narrative 영향 없음)

1.3 알아두면 좋은 용어

용어	의미
selectivity (sel)	쿼리 조건에 맞는 행이 전체의 몇 % (예: 0.01 = 1%)
q_error	추정 행 수 vs 실제 행 수의 비율. 1.0 완벽, 클수록 부정확
BERN (BERNOULLI)	행 단위 무작위 추출
KM20	K-means 알고리즘으로 데이터를 20개 클러스터로 사전 분할 (oracle)
RANDOM20	데이터를 20개로 무작위 분할 (공간 구조 무시)
Stratified	그룹별로 일정 비율씩 추출하는 층화 추출
Spearman ρ	단조성 통계 — -1~+1, 0이면 단조 X
Cohen's d	effect size — 절댓값 < 0.2 negligible, 0.2~0.5 small, 0.5~0.8 medium, > 0.8 large

2. RQ1 — random sampling이 skew 데이터에서 얼마나 부정확?

2.1 동기와 가설

벡터 DB는 쿼리 실행 전 "이 조건에 맞는 행이 대략 몇 개?"를 추정. 이 추정이 정확해야 좋은 실행 계획. Exqutor는 이 추정을 위해 **데이터 일부 무작위 sampling**.

문제는 데이터가 **한쪽에 쏠려 있을 때 (skew) random sampling이 제대로 작동하는가?**

- **H1:** 데이터가 더 skew일수록 random sampling의 q_error가 더 부정확
- **H2:** selectivity가 낮을수록 (rare query) 더 부정확

2.2 실험 설계

항목	값
비교 방식	BERN (random) vs KM20 (분포 아는 oracle) vs RANDOM20 (무작위 분할)
데이터셋	DEEP 1M (Normal, 96차원) + SIFT 1.5M (Skew, 128차원)
selectivity	5단계: 0.01 / 0.05 / 0.10 / 0.30 / 0.50
seed	5개 (재현성)
query	100개 pool
측정 환경	Phase 6 (SQL D_target + vector.c hook, production-near)

2.3 측정 진행 검증

산출	위치	rows	상태
Phase 6 layer compare (3 layer × 4 mode)	<code>phase6_layer_compare_runs.parquet</code>	12,000	✓
Phase 6 strat PCA runs	<code>phase6_strat_pca_runs.parquet</code>	6,000	✓
RANDOM20 BERN baseline	<code>random20_bern_all_sel.parquet</code>	600	✓
RANDOM20 strat baseline	<code>random20_strat_all_sel.parquet</code>	600	✓
Stage 5 분석 통합	<code>stage5_analysis.parquet</code>	6,000	✓

모든 5 selectivity × 100 query × 5 seed cell 측정 완료.

2.4 결과

2.4.1 KM20 vs RANDOM20 (DEEP 1M) — 공간 구조를 아는 것의 가치

sel	KM20 개선	RANDOM20 개선	격차
0.50 (50%)	+1.31%	+2.20%	~0
0.30	+2.62%	+0.26%	2.4%p
0.10	+4.19%	+1.74%	2.5%p
0.05	+1.85%	+0.79%	1.1%p
0.01 (1%)	+8.93%	-10.67%	19.6%p

→ 좁은 쿼리 ($s=1\%$)에서 격차 19.6%p. 쿼리 범위가 좁아질수록 "공간 구조를 아는 것"이 점점 더 중요.

2.4.2 단조성 통계 검정 (per-seed Spearman ρ , $n=25$)

비교	ρ	95% CI	결론
DEEP-KM20	-0.680	[-0.800, -0.440]	0 제외, 단조 감소 확정
DEEP-RAND	+0.560	[+0.320, +0.840]	0 제외, reverse-monotonic 확정

2.4.3 SIFT (skew) vs DEEP (normal) 격차

SIFT의 SYSTEM-BERN 격차가 모든 sel에서 DEEP보다 크다 (HHI 0.058 vs 0.053, CV 0.394 vs 0.234, 약 1.7 배 더 skew). 통계 검정 paired Wilcoxon $p \leq 1e-4 \sim 1e-49$.

2.5 결론

- ✓ Selectivity Gradient 단조성 입증 — gradient 19.6%p (KM20 +8.93% vs RANDOM20 -10.67%, $s=0.01$)
- ✓ H1, H2 모두 정량 확인
- 5/27 발표 핵심 narrative

3. RQ1 Phase 6/7 측정 환경 보강 (5/7 W2 발견)

3.1 의문

위 결과는 Phase 6 (SQL D + vector.c hook 환경, production-near) 측정. 그러면 **Phase 7 (numpy 시뮬레이션 D 환경)** 으로도 같은 단조성이 나오는가? 측정 방식 차이가 결과에 영향?

3.2 보강 실험 설계

같은 query, 같은 sel, 같은 seed → **D_target** 계산 driver만 변경 (SQL → numpy).

항목	값
데이터셋	DEEP 1M
selectivity	5단계 동일
seed	5개 동일
변경	D_target 계산 path: vector.c hook (SQL) → numpy estimator (캐시 ≤10K + HT weight)

3.3 측정 진행 검증

산출	rows	상태
deep_s0.01_numpy_remeasure.parquet	1,000	✓
deep_s0.05_numpy_remeasure.parquet	1,000	✓
deep_s0.10_numpy_remeasure.parquet	1,000	✓
deep_s0.30_numpy_remeasure.parquet	1,000	✓
deep_s0.50_numpy_remeasure.parquet	1,000	✓

3.4 결과 — 격차 큼

sel	Phase 6 (SQL D, production-near)	Phase 7 (numpy D, simulation)	Δ
0.01	+8.93%	+3.33%	-5.60%p
0.05	+1.85%	-2.60%	-4.45%p
0.10	-2.06%	-1.31%	-0.75%p
0.30	-3.11%	-0.99%	-2.12%p
0.50	-10.67%	-1.23%	-9.44%p
per-seed p	-0.680 [-0.800, -0.440] CI 0 제외 ✓	+0.240 [-0.061, +0.480] CI 0 포함 ✗	—

5-cell 격차가 큼 ($s=0.01 \Delta=-12.26\%p$, $s=0.50 \Delta=-9.44\%p$). Phase 7은 단조성 검정력 약화.

3.5 결론 — 옵션 2 정직 reporting 채택 (5/8 회의 합의 안건)

- ✓ Phase 6 핵심 인용 (production-near, vector.c hook 환경)
- ✓ Phase 7 honest 별도 보고 (simulation의 한계)
- ✓ 5-cell 격차 자체를 *measurement methodology robustness* sub-contribution으로 격상

원인 두 가지 (자문 사항):

1. numpy estimator는 $\leq 10K$ row 캐시에서 추출 + HT weight만 $N=1M$ 적용 → SQL `tablesample` (full table) 과 sampling-population scope 다름
2. vector.c hook 환경의 측정 path가 numpy 시뮬레이션과 다름

4. RQ2 — 분포를 알 때 어떤 allocation이 최적?

4.1 동기와 가설

KM20 (K-means $K=20$) oracle 가정. 5가지 방식 중 어느 게 가장 좋을까?

방식	의미
BERN	random (baseline)
Equal	클러스터마다 같은 수
Proportional	클러스터 크기 비례
Neyman	분산 σ_i 비례 (이론상 최적)
Anti-Neyman	σ_i 반대 (negative control)

- **H3:** 모든 stratified > BERN
- **H4:** Neyman > Proportional (분산 활용 가치)
- **H5:** Anti-Neyman 가장 나쁨

4.2 실험 설계

항목	값
데이터셋	DEEP 1M + SIFT 1.5M
mode	5종 (BERN / Equal / Prop / Neyman / Anti-Neyman)
selectivity	5단계 (0.01 / 0.05 / 0.10 / 0.30 / 0.50)
seed	5개
query	100개
추가	sample size sensitivity (4 ssize $\times$ 2 mode $\times$ 5 sel $\times$ 5 seed $\times$ 100 query $\times$ 2 ds)
추가	DEEP 8M cross-scale (Anti-Neyman)

4.3 측정 진행 검증

산출	기대 rows	실제 rows	상태
<code>rq2_alloc.parquet</code> (5 mode 통합)	$5 \times 5 \times 5 \times 100 \times 2 = 25,000$	25,000	✓
<code>rq2_size_sensitivity.parquet</code> (3 sel × 4 ssize)	24,000	24,000	✓
<code>rq2_size_sensitivity_5sel.parquet</code> (5 sel × 4 ssize)	40,000	40,000	✓
<code>rq2_alloc_DEEP_8M.parquet</code> (cross-scale)	8M × 2 sel	측정 ✓	✓

4.4 결과

4.4.1 모든 stratified > BERN ✓

DEEP -1.3~-7.0%, SIFT -3.7~-10.5%, paired Wilcoxon $p \leq 1e-7 \sim 1e-50$ (BH-FDR 보정 후 유의).

4.4.2 KM20 sample-size robust ✓

40 cell (4 ssize × 2 dataset × 5 sel) 모두 KM20 우위. sample size에 무관한 안정성.

4.4.3 Neyman vs Equal — 거의 차이 X (H4 일부 기각)

σ_i 신호 약함. Neyman의 이론상 우위가 측정에서 거의 안 나타남.

4.4.4 Anti-Neyman vs Proportional — 좁은 sel에서만 systematic hurt

데이터셋	s=0.01	CI
DEEP	+5.21%	[+1.36, +9.16] CI 0 제외
SIFT	+9.49%	[+4.66, +11.75] CI 0 제외

그러나 paired Wilcoxon $p > 0.5$, Cohen's $d < 0.1 \rightarrow$ 개별 query 수준은 random과 동치.

4.4.5 8M cross-scale 재현 ✓

Anti-Neyman s=0.1 $\Delta=+1.28\%$ [+0.28, +2.28] CI 0 제외 — 1M와 일관 방향.

4.5 결론

- ✓ KM20 oracle은 sample-size robust (단점: 학습 ~30분)
- ⚠ σ_i 신호 약함의 honest 입증 — median 수준에서만 detect, 개별 query는 random과 동치
- → RQ3 distribution-agnostic 추구의 motivation chain

5. RQ3 — 분포를 모를 때 어떤 방식이 KM20 oracle을 대체?

5.1 동기와 가설

학습 X, 결정론으로도 KM20 수준 회수 가능?

- H6: 학습 없는 stratification (Hilbert 등) 도 KM20과 같은 region 진입
- H7: 분할 자체가 가치 — 분할 X (online weight) 는 hurt

5.2 실험 설계 — 22 method (5 paradigm)

5/5 회의 초기 7-way → W1 16-method → 5/7 새벽 22-method 완성.

Paradigm	Method (개수)	학습 비용
Cluster (Offline)	KM20 (oracle) / MiniBatch / partial_fit / HDBSCAN / GMM / BIRCH / Spectral (7개)	학습 필요 (~30분)
Locality (curve)	Hilbert / Z-order / Hybrid (3개)	~수초 fit
Projection	Random Proj / Sparse RP / PCA-1D (3개)	즉시
Tree	KD-tree / PQ (2개)	즉시
Online weight	KDE-pilot / Distance-Shell / IS variants 4종 (4개)	즉시 (분할 X)

변수	값
데이터셋	DEEP 1M + SIFT 1.5M
selectivity	5단계 동일
seed	5개
query	100개

5.3 측정 진행 검증

22 method 모두 측정 완료. method당 기본 5,000 rows ($5 \text{ sel} \times 5 \text{ seed} \times 100 \text{ query} \times 2 \text{ ds}$).

Method	Rows	상태
KM20 (oracle)	10,000	✓ extra
MiniBatch	10,000	✓ extra
MiniBatch partial_fit	5,000	✓
HDBSCAN	5,000	✓
GMM	5,000	✓
BIRCH	5,000	✓
Spectral	5,000	✓ (NaN 1.6%)
Hilbert	10,000	✓ extra (W1-C ablation)
Z-order	5,000	✓
Hybrid (KMeans+Hilbert)	5,000	✓
Random Proj	10,000	✓ extra
Sparse RP	5,000	✓
PCA-1D	5,000	✓
KD-tree	5,000	✓
PQ	5,000	✓ (NaN 2.6%)
LSH	10,000	✓ extra
KDE-pilot	10,000	✓ extra
Distance-Shell	10,000	✓ extra
Importance Sampling	25,000 (5 variants)	✓ (NaN 18.9% — known caveat)
Sobol	5,000	✓ (NaN 1.5%)
RANDOM20 (DEEP)	5,000	✓
RANDOM20 (SIFT)	5,000	✓

총 132,000 cell (variants 포함). 모든 method × 5 sel × 5 seed × 100 query × 2 dataset 조합 완료.

5.4 결과

5.4.1 4강 ★ (paired bootstrap CI 0 제외 5/10 cell robust)

순 위	Method	핵심 수치	특징
★1	Hilbert (PCA 2D + 결정론 quantile)	mean Cohen's d = -0.156	학습 X, 결정론, ~수초 fit
★2	MiniBatch K-means partial_fit	ARI = 1.000 (batch 동등)	OLTP 적용 가능, 4 cell paired CI 0 제외
★3	HDBSCAN (5/7 NEW, density- based)	SIFT s=0.10 -3.99% [-5.34, -2.12]	모든 22 method 중 mid-sel best
★4	Hybrid (KMeans + Hilbert) (5/7 NEW)	SIFT 평균 rank 5.83 (Hilbert 5.85 보다 약간 우수)	SIFT s=0.10 -3.10% [-4.61, -1.19]

5.4.2 Negative Control — cluster 분할 자체의 가치 정량 증명

Method	수치	해석
PQ	DEEP s=0.01 +23.64% [+15.91, +31.80]	massive failure
Sobol	SIFT s=0.01 +33.62%	가장 큰 hurt
IS variants	d = +0.5~+0.7	medium hurt
Distance-Shell	d = +0.49	cluster X 한계

→ 4 negative control 모두 CI 0 제외 hurt → "cluster 분할 자체"가 결정적 가치 (H7 입증).

5.4.3 Hilbert mechanism 정량 분리 (W1-C 분석)

Metric	Hilbert	Z-order	해석
Inverse Manhattan	1.000 (perfect)	1.992 (50% jumps)	1D-2D continuity 보존도
Stratum compactness	4.77	12.12	Hilbert가 2.54x 더 compact
ARI orthogonality avg	0.316 (curve sibling)	0.314	둘이 정보 공유

→ Hilbert의 강한 결과는 PCA 효과가 아닌 curve 자체의 locality

5.4.4 Method orthogonality ranking (5 ARI CSV 통합)

직교성 ranking (avg ARI, 낮을수록 정보 직교):

1. **sparse_rp** (0.122) — 가장 직교
2. pca1d (0.277)
3. curve sibling Hilbert/Z-order (0.31)
4. tree (0.331)
5. cluster method 4종 (0.55+) — 정보 redundant

→ 본 연구의 22 method가 **정보적으로 5 region cover** → ablation 학술 정당성 ✓

5.5 결론

- ✓ **Hilbert + MiniBatch partial_fit** = production replacement (학습 X / OLTP 가능) — H6 입증
- ✓ **HDBSCAN** = SIFT skew 환경 추가 가치
- ✓ **Hybrid** = 양 paradigm 결합 (5/7 NEW)
- ✓ **모든 method $|d| < 0.8$** → "공간 인식의 limit" honest 명시 (Limitation 3)

6. 8M cross-scale 검증

6.1 동기

본 연구의 1M 결과가 large-scale (8M) 환경에서도 재현되는가? 외적 타당성 강화 목적.

6.2 실험 설계

항목	값
데이터셋	DEEP 8M (Normal, 96차원)
method	19개 (KM20 oracle 제외 — distribution-agnostic만)
selectivity	2단계 (0.10 / 0.30) — sensitivity 측정 (5단계 확장은 W2)
seed	5개
query	100개
추가	RQ2 Anti-Neyman cross-scale ($s=0.10$)

6.3 측정 진행 검증

19 method $\times$ 1,000 rows (2 sel $\times$ 5 seed $\times$ 100 query) 측정 완료. NaN 모두 0% (IS만 1.1%).

Method	rows	NaN
Hilbert / Z-order / Hybrid	1,000	0%
MiniBatch / partial / HDBSCAN / GMM / BIRCH / Spectral	1,000	0%
Random Proj / Sparse RP / PCA-1D	1,000	0%
KD-tree / PQ / LSH	1,000	0%
Sobol / Distance-Shell / KDE-pilot	1,000 / 2,000 / 2,000	0%
Importance Sampling	4,000 (variants 4)	1.1%

6.4 결과

- 18 method $\times$ 2 sel = **36 cell**
- **method ranking 1M/8M 동일** (외적 타당성 강화)
- 8M에서 sampling 자연 안정화 (random_proj -3.34% 가장 개선)
- KDE-pilot만 +5.27% deviation (adaptive estimator scale 한계)

- RQ2 8M Anti-Neyman $s=0.1$ $\Delta=+1.28\%$ [+0.28, +2.28] CI 0 제외 — 1M와 일관 방향 ✓

6.5 결론

- ✓ 본 연구 결과는 **scale에 robust** — large-scale (8M) 재현
- ⚠ 8M selectivity 5단계 확장 (현재 2단계), HDBSCAN/GMM/Sobol/Sparse_RP 8M 추가 측정 = **W2 보강 후보**

7. RQ2 vs RQ3 종합 비교 — 분포 알 때 vs 분포 모를 때

7.1 핵심 비교

구분	RQ2 (분포 알 때)	RQ3 (분포 모를 때)
baseline	KM20 oracle, 모든 40 cell BERN 우위	4강 (Hilbert / partial / HDBSCAN / Hybrid)
effect size	sample-size robust	KM20과 같은 region ($d \approx -0.15$)
학습 비용	KM20 ~30분	Hilbert ~수초 / partial_fit OLTP
production 적합	학습 가능 시	학습 X 또는 OLTP 환경

7.2 상황별 권장

상황	권장 방식	이유
분포 정확히 안다 + 학습 시간 OK	KM20 oracle	40/40 cell 일관
분포 안다 + OLTP 환경	MiniBatch partial_fit	ARI 1.000 batch 동등, streaming 지원
분포 모름 + 학습 X	Hilbert curve	~수초 fit, 결정론, inverse Manhattan 1.000
분포 모름 + SIFT 같은 skew	HDBSCAN	mid-sel best -3.99%, density-based

7.3 핵심 insight

분포 모르는 상황에서도 Hilbert / HDBSCAN이 KM20과 같은 region 진입 가능.

"공간 인식 자체가 가치" — 정확한 분포 모르더라도 그 공간 내 어디에 있는지만 알면 OK.

= production deployment 가능 (학습 부담 없이).

8. 향후 일정 + 추가 보강 후보

8.1 일정 (D-day)

마감	내용
5/8 (오늘) 19:00	비대면 회의 — narrative 합의 + 자문 합의
~5/15	자문 발송 (채림 + 지도교수)
5/22	교수님 미팅
★ 5/27	최종 발표 (D-20)
5/28	전시회 자료 마감
★ 6/11	최종 보고서 제출 (D-35)

8.2 추가 보강 후보

우선순위	작업	가치
W2	σ table 재계산 (DEEP 1M / SIFT σ wiped)	reproducibility 회복
W2	8M 5 sel 확장 + HDBSCAN/GMM/Sobol/Sparse_RP 8M 추가	cross-scale 외적 타당성 보강
W3	NMI / AMI metric (RQ3 ARI robustness)	16 method 정보 직교성 보강
W3	Real data ARI 16 method $\times$ 2 dataset	RQ3 narrative 강화
Future	Phase 6/7 root cause 정량 (vector.c integration)	RQ1 measurement methodology 완성
Future	멀티 테이블 join (Exqutor multi-relation)	본 연구 $\rightarrow$ multi 일반화

9. 5/8 회의 합의 안건

9.1 RQ1 narrative 옵션 2 (정직 reporting) 채택

- Phase 6 (production-near) 핵심 인용

- Phase 7 (simulation) honest 별도 보고
- 5-cell 격차 자체를 sub-contribution으로 격상

9.2 RQ3 contribution 5종 (HDBSCAN + Hybrid 추가) 격상

- 기존 3종: Hilbert / MiniBatch partial / Cluster 분할 가치
- 추가 2종: HDBSCAN (SIFT mid-sel best) / Hybrid (양 paradigm)

9.3 Limitations 6종 명시

L	항목
L1	단일 테이블 (multi는 future work)
L2	KM20 oracle 학습 부담
L3	Effect size practical small (모든 $ d < 0.8$)
L4	numpy estimator sampling-population scope
L5	RQ1 measurement methodology robustness (5/7 W2 NEW)
L6	σ_i 신호 약함 honest 입증

9.4 자문 메일 합의 (5/15 발송)

- 채림 석사: Hilbert mechanism + Phase 6/7 origin (5종 자문)
- 지도교수: contribution framing + multi 일반화 (6종 자문)

9.5 W2 분담 + 5/27 발표 분담

10. 회의 자료 위치

자료	위치
본 정리 PDF	<code>submission/_drafts/속도는벡터_5월8일회의_RQ진행정리_v1.pdf</code>
1page summary	<code>submission/_drafts/속도는벡터_5월8일회의_1page_summary_20260506.md</code>
종합 master (7 contribution + 6 Limitations)	<code>experiments/results/RQ1_RQ2_RQ3_종합_master.md</code>
5/27 발표 outline	<code>submission/_drafts/속도는벡터_5월27일발표_slide_outline_20260506.md</code>
자문 메일 채림석사	<code>submission/_drafts/속도는벡터_자문메일초안_채림석사_20260506.md</code>
자문 메일 지도교수	<code>submission/_drafts/속도는벡터_자문메일초안_지도교수_20260506.md</code>

GitHub 최신 commit: [984be3b](#) — 팀원 공유 PDF 스타일 정정.

질문 / 피드백 회의에서 부탁드립니다 🙏