

[팀원 공유용] RQ1/2/3 진행 정리 — 구어체 카톡 친화 버전

작성: 2026-05-07 11:35 KST · 5/8 회의 D-1 목적: 실험 처음 보는 사람도 바로 이해할 수 있게 핵심 단어 위주로 정리 사용: 카톡 단톡방 메시지 단위로 발송 (각 ——— 구분선이 메시지 경계)

메시지 1 — 한 줄 요약 + 데이터셋 진행 상황

W1 sprint 결과 정리 (5/7 11시 기준).

 데이터셋별 측정 진행

데이터셋	Normal/Skew	측정 method 수
DEEP 1M (96차원)	Normal	22개 ✓
SIFT 1.5M (128차원)	Skew	22개 ✓
DEEP 8M (96차원, 대용량)	Normal	16개 ✓
멀티 테이블 join	—	future work

5/8 19:00 비대면 회의 D-1.

5/27 발표 D-20, 6/11 보고서 D-35.

메시지 2 — RQ1: random sampling이 얼마나 부정확?

🔍 RQ1 – 기존 random sampling이 skew에서 얼마나 부정확?

[가설]

- 데이터가 한쪽에 쏠려있으면 (skew) random이 더 부정확
- 찾는 row가 적을수록 (selectivity 낮음) 더 부정확

[실험]

- 비교: BERN (random) vs KM20 (분포 아는 oracle)
- 데이터: DEEP 1M (Normal) + SIFT 1.5M (Skew)
- selectivity 5단계: 0.01 / 0.05 / 0.10 / 0.30 / 0.50

[기대 결과]

- 모든 cell에서 KM20이 더 정확
- skew(SIFT) > normal(DEEP) 격차 ↑
- selectivity 낮을수록 격차 ↑

[실제 결과] ✓ 모두 일치

- KM20 우위 모든 cell ✓
- SIFT-BERN 격차가 모든 sel에서 DEEP-BERN보다 크다 ✓
- DEEP-KM20: s=0.50 +1.31% → s=0.01 +8.93%
 - 단조 감소 통계 확정 (Spearman $\rho=-0.680$, CI [-0.800, -0.440] 0 제외)

[결론] selectivity gradient 단조성 입증.

gradient 19.6%p (KM20 +8.93% vs RANDOM20 -10.67%, s=0.01).

메시지 3 — RQ1 5/7 보강 의문 + 추가 실험

🔴 RQ1 보강 의문 (5/7 W2 발견)

[의문]

위 결과는 "vector.c hook + SQL D_target" 환경 (Phase 6).
그러면 "numpy 시뮬레이션 D_target" 환경 (Phase 7) 에서도
같은 단조성 결과가 나올까? 측정 방식 차이가 결과에 영향?

[보강 실험]

- 같은 query, 같은 sel, 같은 seed
- D_target 계산 driver만 변경 (SQL → numpy)

[기대]

methodology 차이 작으면 단조성 일관 유지

[실제 결과] 격차 큼!

- Phase 6 (SQL D, production-near): $p=-0.680$ CI 0 제외 ✓
- Phase 7 (numpy D, simulation): $p=+0.240$ CI 0 포함 ✗
- 5-cell 격차: $s=0.01$ $\Delta=-12.26\%$, $s=0.50$ $\Delta=-9.44\%$

[결론 – 옵션 2 정직 reporting 채택]

- ✓ Phase 6 핵심 인용 (production-near, vector.c hook 환경)
- ✓ Phase 7 honest 별도 보고 (simulation 의 한계)
- ✓ 5-cell 격차 자체를 "measurement methodology robustness"
sub-contribution 으로 격상

원인 두 가지 (자문 사항):

1. numpy estimator는 $\leq 10K$ row 캐시에서 추출 + HT weight만 $N=1M$ 적용
→ SQL tablesample (full table)과 sampling-population scope 다름
2. vector.c hook 환경의 측정 path가 numpy 시뮬레이션과 다름

메시지 4 — RQ2: 분포 알 때 5가지 allocation 비교

🔍 RQ2 – 분포 정확히 안다면 어떤 allocation이 최적?

[가설]

KM20 (K-means K=20) oracle 가정.

5가지 방식 중 어느 게 가장 좋을까?

- BERN: random (baseline)
- Equal: 클러스터마다 같은 수
- Proportional: 클러스터 크기 비례
- Neyman: 분산 σ_i 비례 (이론상 최적)
- Anti-Neyman: σ_i 반대 (negative control)

[실험]

- 데이터: DEEP 1M / SIFT 1.5M
- 5 mode $\times$ 5 sel $\times$ 5 seed $\times$ 100 query = 25,000 cell
- 추가: sample size 4단계 sensitivity (40 cell)
- 추가: 8M cross-scale 검증

[기대]

- KM20 oracle은 모든 stratified > BERN
- Neyman > Proportional (분산 활용 가치)
- Anti-Neyman 가장 나쁨

[실제 결과]

- ✓ 모든 stratified > BERN (DEEP -1.3~-7.0%, SIFT -3.7~-10.5%)
- ✓ KM20 sample-size robust (40/40 cell 일관)
- ⚠ Neyman vs Equal: 거의 차이 X
- ⚠ Anti-Neyman vs Proportional: 좁은 sel에서만 systematic hurt
(DEEP s=0.01 +5.21%, SIFT s=0.01 +9.49%, CI 0 제외)
- ✓ 8M에서도 1M와 일관 방향 재현

[해석 – σ_i 신호 약함의 honest 입증]

- σ_i 신호가 약해서 median 수준에서만 detect 가능
- 개별 query 수준은 random과 거의 동치
- 즉, "분포의 분산을 활용하는 것"의 한계 → 그냥 분포의 "위치"만 알아도 충분 → RQ3 distribution-agnostic 추구의 motivation chain

[결론]

- ✓ KM20 oracle은 baseline으로 강력 (단점: 학습 ~30분)
- ✓ Neyman의 추가 가치는 작음
- ✓ σ_i 약함 → RQ3로 자연스럽게 연결

메시지 5 — RQ3: 분포 모를 때 22 method 비교

🔍 RQ3 – 분포 모르면 어떤 방식이 KM20 oracle을 대체?

[가설]

학습 X , 결정론으로도 KM20 수준 회수 가능?

[실험]

- 22 method × DEEP 1M + SIFT 1.5M × 5 sel × 5 seed × 100 query
- 5/5 회의 초기 7-way → W1 16-method → 5/7 새벽 22-method 완성

[22 method 분류]

(1) Cluster – 7개

KM20(oracle) / MiniBatch / partial_fit / HDBSCAN / GMM /
BIRCH / Spectral

(2) Locality (공간 곡선) – 3개

Hilbert / Z-order / Hybrid (KMeans+Hilbert)

(3) Projection (차원 축소) – 3개

Random Proj / Sparse RP / PCA-1D

(4) Tree (분할 indexing) – 2개

KD-tree / PQ

(5) Online weight (분할 X , 가중치만) – 4개

KDE-pilot / Distance-Shell / IS variants 4종

메시지 6 — RQ3 4강 + Negative control + mechanism

🏆 RQ3 결과 – 4강 (paired bootstrap CI 0 제외 5/10 cell robust)

*1 Hilbert (PCA 2D + 결정론 quantile)

- 학습 X, 결정론, ~수초 fit
- mean Cohen's d = -0.156
- mechanism: inverse Manhattan = 1.000
(Z-order는 1.992, 50% 점프 발생)

*2 MiniBatch K-means partial_fit (OLTP 적용)

- batch와 ARI = 1.000 (perfect 회복)
- SIFT s=0.10 -2.36% [-4.15, -0.43] 등 4 cell CI 0 제외
- production OLTP 환경에 직접 적용 가능

*3 HDBSCAN (5/7 NEW, density-based)

- SIFT s=0.10 -3.99% [-5.34, -2.12]
- 모든 22 method 중 mid-sel 가장 강
- SIFT 의 더 큰 skew + density 클러스터 가치

*4 Hybrid (KMeans + Hilbert) (5/7 NEW)

- SIFT 평균 rank 5.83 (Hilbert 5.85 보다 약간 우수)
- SIFT s=0.10 -3.10% [-4.61, -1.19]
- 양 paradigm 결합

🚫 Negative control (CI 0 제외 hurt direction)

- PQ DEEP s=0.01 +23.64% (massive failure)
- Sobol SIFT s=0.01 +33.62% (가장 큰 hurt)
- IS variants d=+0.5~+0.7 (medium hurt)
- Distance-Shell d=+0.49 (cluster X 한계)
- "cluster 분할 자체"가 결정적 가치

메시지 7 — RQ3 추가 발견 + cross-scale

RQ3 추가 분석

[Method orthogonality (정보 직교성)]

sparse_rp 1위 (avg ARI 0.122)

→ pca1d (0.277) → curve sibling (0.31)

→ tree (0.331) → cluster method 4종 (0.55+)

→ 본 연구의 22 method 가 "정보적으로 5 region cover"

ablation 이 학술적으로 정당함

[Cross-scale 1M ↔ 8M 검증]

- 18 method × 2 sel = 36 cell

- method ranking 1M/8M 동일 (외적 타당성 강화)

- 8M에서 sampling 자연 안정화 (random_proj -3.34% 가장 개선)

[Effect size honest]

- 22 method 중 어떤 것도 $|d| > 0.8$ large effect 없음

- "공간 인식 의 limit" honest 명시 필요

- 어려운 query 에서 method routing 가치 강 (spread vs difficulty $p=0.78$)

메시지 8 — 분포 알 때 vs 모를 때 종합 비교

vs RQ2 (분포 알 때) vs RQ3 (분포 모를 때)

[핵심 비교]

RQ2 KM20 oracle : 모든 40 cell BERN 우위, sample-size robust
단점: 학습 ~30분 (production OLTP 부담)

RQ3 4강 : KM20과 effect size 같은 region ($d=-0.15$ 정도)
단, KM20 oracle보다 약간 약함

[상황별 권장]

상황	권장 방식
분포 정확히 안다 + 학습 시간 OK	KM20 oracle (40/40 일관)
분포 안다 + OLTP 환경	MiniBatch partial_fit (ARI 1.000 batch 동등)
분포 모름 + 학습 X	Hilbert (~수초 fit, 결정론)
분포 모름 + SIFT skew	HDBSCAN (mid-sel best -3.99%)

[핵심 insight]

분포 모르는 상황에서도 Hilbert / HDBSCAN이 KM20과 같은 region 진입 가능 → "공간 인식 자체"가 가치.

정확한 분포 모르더라도 그 공간 내 어디에 있는지만
알면 OK = production deployment 가능.

메시지 9 — 8M / 멀티 테이블 / 향후 실험

17 향후 실험 plan

[8M (DEEP 8M, 대용량 검증)]

- 현재: 16 method ✓ (sensitivity 5 + cross-scale 18)
- 추가 진행 후보 (W2 sprint, 5/8 회의 후):
 - 16 → 22 method 확장 (HDBSCAN/GMM/Sobol/Sparse_RP 추가)
 - SIFT 8M 측정 (현재 SIFT는 1.5M만)

[멀티 테이블 join (future work, 본 연구 scope X)]

- Exqutor 의 main scope = multi-relation join
- 본 연구는 단일 테이블 정확성 입증 → multi의 *필요조건*만 입증
- 6/11 보고서에 framing 명시:
 - "단일 정확성 → multi 일반화는 follow-up work"
- 자문 메일에 "multi-table 일반화" 가능성 자문 항목 포함

[추가 보강 후보]

1. σ table 재계산 (DEEP 1M / SIFT 1.5M σ wiped → reproducibility 회복)
 - W2 권고, 5/8 회의 후 dispatch
2. NMI / AMI metric (RQ3 ARI robustness check)
3. Real data ARI 16 method (RQ3 narrative 강화)
4. Phase 6/7 root cause 정량
(numpy estimator sampling-population 통일 + vector.c integration)

메시지 10 — 5/8 회의 안건 + 일정

 5/8 19:00 비대면 회의 D-1 안건

1. RQ1 narrative 옵션 2 (정직 reporting) 채택 합의
 - Phase 6 production-near 핵심 인용
 - Phase 7 honest 별도 보고
 - 5-cell 격차 자체를 sub-contribution 으로 격상
2. RQ3 contribution 5종 (HDBSCAN + hybrid 추가) 격상 합의
 - 기존: Hilbert / MiniBatch partial / Cluster 분할 가치
 - 추가: HDBSCAN (SIFT mid-sel best) / Hybrid (양 paradigm 결합)
3. Limitations 6종 명시 합의
 - L1: 단일 테이블 (multi는 future work)
 - L2: KM20 oracle 학습 부담
 - L3: Effect size practical small (모든 $|d| < 0.8$)
 - L4: numpy estimator sampling-population scope
 - L5: RQ1 measurement methodology robustness (5/7 W2 NEW)
 - L6: σ_i 신호 약함 honest 입증
4. 자문 메일 합의 (5/15 발송)
 - 채림 석사: Hilbert mechanism + Phase 6/7 origin (5종)
 - 지도교수: contribution framing + multi 일반화 (6종)
5. W2 분담 + 5/27 발표 분담

 다음 마감

- 5/8 (오늘) 19:00 비대면 회의
- ~5/15 자문 발송
- 5/22 교수님 미팅
- ★ 5/27 최종 발표 (D-20)
- 5/28 전시회 자료
- ★ 6/11 최종 보고서 (D-35)

메시지 11 — 회의 자료 위치

📁 5/8 회의 자료 (모두 ready)

1page summary:

submission/_drafts/속도는벡터_5월8일회의_1page_summary_20260506.md

종합 master (7 contribution + 6 Limitations):

experiments/results/RQ1_RQ2_RQ3_종합_master.md

5/27 발표 outline:

submission/_drafts/속도는벡터_5월27일발표_slide_outline_20260506.md

자문 메일 초안 2종:

submission/_drafts/속도는벡터_자문메일초안_채림석사_20260506.md

submission/_drafts/속도는벡터_자문메일초안_지도교수_20260506.md

GitHub 최신 commit:

1475814 5/7 메인 통합 manager → 5 worker 핸드오프

8d079d3 narrative 일관성 보강

1267b8a RQ2/3 디리뷰 보강

74d6aea narrative 옵션 2 정직 reporting

fc7e147 chain 운영 archive

질문/피드백 회의에서 부탁드립니다 🙏

📌 발송 가이드

카톡 단톡방 발송 순서 (메시지 1 → 11)

각 메시지 단위로 끊어서 발송. 너무 길면 메시지 5(RQ3 분류) + 메시지 6(RQ3 4강)을 나눠서 발송. 표/숫자 가독성을 위해 monospace 줄간격 유지.

PDF 변환 (옵션, 노션 첨부용)

```
python3 _internal/scripts/md2pdf.py "_internal/팀원공유_RQ진행정리_구어체_20260507.md"
```

회의 직전 추가 발송 권장

`_internal/카톡_5월8일직전_narrative_메시지_20260507.md` \$메시지1 (회의 직전 안건) — 본 메시지 11과 연속 발송.

작성: Claude (manager session, Opus 4.7 1M) · 2026-05-07 11:35 KST **기반:** master commit 8d079d3 + 1267b8a + 74d6aea + fc7e147 + 1475814