

속도는벡터 — 5/8 회의 RQ 진행 종합 정리

작성: 조현빈 · 2026-05-07 11:50 KST **대상:** 박세은 · 강재현 · 이동욱 **범위:** 5/7 새벽~오전 W1 sprint 보강 작업 종합 — 처음 보는 사람도 이해 가능한 수준 **다음:** 5/8 19:00 비대면 회의 D-1, 5/27 발표 D-20, 6/11 보고서 D-35

0. 큰 그림 — 데이터셋 진행 상황 (5/7 11시 기준)

데이터셋	분포	차원	측정 method 수
DEEP 1M	Normal	96	22개 ✓
SIFT 1.5M	Skew	128	22개 ✓
DEEP 8M (대용량)	Normal	96	16개 ✓ + cross-scale 18개 ✓
멀티 테이블 join	—	—	future work (Exqutor main scope)

알아두면 좋은 용어

용어	의미
selectivity (sel)	쿼리 조건에 맞는 행이 전체의 몇 % (예: 0.01 = 1%)
q_error	추정 행 수 vs 실제 행 수의 비율. 1.0 완벽, 클수록 부정확
BERN (BERNOULLI)	행 단위 무작위 추출
KM20	K-means 알고리즘으로 데이터를 20개 클러스터로 사전 분할 (oracle)
RANDOM20	데이터를 20개로 무작위 분할 (공간 구조 무시)
Stratified	그룹별로 일정 비율씩 추출하는 층화 추출
Spearman ρ	단조성 통계 — -1~+1, 0이면 단조 X
Cohen's d	effect size — 절댓값 < 0.2 negligible, 0.2~0.5 small, 0.5~0.8 medium, > 0.8 large

1. RQ1 — random sampling이 skew 데이터에서 얼마나 부정확?

(a) 동기

벡터 DB는 쿼리 실행 전 "이 조건에 맞는 행이 대략 몇 개?"를 추정. 이 추정이 정확해야 좋은 실행 계획. Exqutor는 이 추정을 위해 데이터 일부 무작위 sampling.

문제는 데이터가 한쪽에 쏠려 있을 때 (skew) random sampling이 제대로 작동하는가?

(b) 가설

- H1: 데이터가 더 skew일수록 random sampling의 q_error가 더 부정확
- H2: selectivity가 낮을수록 (rare query) 더 부정확

(c) 실험

- 비교: BERN (random) vs KM20 (분포 아는 oracle)
- 데이터: DEEP 1M (Normal) + SIFT 1.5M (Skew)
- selectivity 5단계: 0.01 / 0.05 / 0.10 / 0.30 / 0.50

(d) 실제 결과 — 가설 모두 적중 ✓

KM20 vs RANDOM20 (DEEP 1M) — 공간 구조를 아는 것의 가치

sel	KM20 개선	RANDOM20 개선	격차
0.50 (50%)	+1.31%	+2.20%	~0
0.30	+2.62%	+0.26%	2.4%p
0.10	+4.19%	+1.74%	2.5%p
0.05	+1.85%	+0.79%	1.1%p
0.01 (1%)	+8.93%	-10.67%	19.6%p

→ 좁은 쿼리 (s=1%)에서 격차 19.6%p. 쿼리 범위가 좁아질수록 "공간 구조를 아는 것"이 점점 더 중요.

단조성 통계 검정 (per-seed Spearman ρ , n=25):

- DEEP-KM20: $\rho = -0.680$, 95% CI $[-0.800, -0.440]$ → 0 제외, 단조 감소 확정
- DEEP-RAND: $\rho = +0.560$, CI $[+0.320, +0.840]$ → 0 제외, reverse-monotonic 확정

(e) 결론

- ✓ Selectivity Gradient 단조성 입증 — gradient 19.6%p (KM20 +8.93% vs RANDOM20 -10.67%, $s=0.01$)
- ✓ H1, H2 모두 정량 확인

2. RQ1 보강 의문 — 5/7 W2 발견

(a) 의문

위 결과는 Phase 6 (SQL D_target + vector.c hook 환경, production-near) 측정. 그러면 Phase 7 (numpy 시뮬레이션 D_target 환경) 으로는 같은 단조성이 나오는가? 측정 방식 차이가 결과에 영향?

(b) 보강 실험

같은 query, 같은 sel, 같은 seed → D_target 계산 driver만 변경 (SQL → numpy)

(c) 실제 결과 — 격차 큼!

sel	Phase 6 (SQL D, production-near)	Phase 7 (numpy D, simulation)	Δ
0.01	+8.93%	+3.33%	-5.60%p
0.05	+1.85%	-2.60%	-4.45%p
0.10	-2.06%	-1.31%	-0.75%p
0.30	-3.11%	-0.99%	-2.12%p
0.50	-10.67%	-1.23%	-9.44%p
per-seed p	-0.680 [-0.800, -0.440] CI 0 제외 ✓	+0.240 [-0.061, +0.480] CI 0 포함 ✗	—

5-cell 격차 자체가 큼 ($s=0.01 \Delta=-12.26\%$, $s=0.50 \Delta=-9.44\%$). Phase 7은 단조성 검정력 약화.

(d) 결론 — 옵션 2 정직 reporting 채택 (5/8 회의 합의 안건)

- ✓ Phase 6 핵심 인용 (production-near, vector.c hook 환경) ✓ Phase 7 honest 별도 보고 (simulation의 한계 명시) ✓ 5-cell 격차 자체를 *measurement methodology robustness* sub-contribution으로 격상

원인 두 가지 (자문 사항):

1. numpy estimator는 $\leq 10K$ row 캐시에서 추출 + HT weight만 $N=1M$ 적용 $\rightarrow$ SQL `tablesample` (full table) 과 sampling-population scope 다름
2. vector.c hook 환경의 측정 path가 numpy 시뮬레이션과 다름

3. RQ2 — 분포 알 때 어떤 allocation이 최적?

(a) 동기

KM20 (K-means $K=20$) oracle 가정. 5가지 방식 중 어느 게 가장 좋을까?

방식	의미
BERN	random (baseline)
Equal	클러스터마다 같은 수
Proportional	클러스터 크기 비례
Neyman	분산 σ_i 비례 (이론상 최적)
Anti-Neyman	σ_i 반대 (negative control)

(b) 가설

- KM20 oracle은 모든 stratified > BERN
- Neyman > Proportional (분산 활용 가치)
- Anti-Neyman 가장 나쁨

(c) 실험

- 데이터: DEEP 1M / SIFT 1.5M
- 5 mode $\times$ 5 sel $\times$ 5 seed $\times$ 100 query = **25,000 cell**
- 추가: sample size 4단계 sensitivity (40 cell), 8M cross-scale 검증

(d) 실제 결과

✓ 모든 stratified > BERN (DEEP $-1.3\sim-7.0\%$, SIFT $-3.7\sim-10.5\%$) ✓ KM20 sample-size robust — 40/40 cell 일관

⚠ **Neyman vs Equal**: 거의 차이 X (σ_i 신호 약함) ⚠ **Anti-Neyman vs Proportional**: 좁은 sel만 systematic hurt - DEEP $s=0.01 + 5.21\%$, SIFT $s=0.01 + 9.49\%$ (CI 0 제외) - 그러나 paired Wilcoxon $p > 0.5$, Cohen's $d < 0.1$ — 개별 query 수준은 random과 동치

✓ **8M cross-scale**: 1M와 일관 방향 재현 (Anti-Neyman $s=0.1 \Delta=+1.28\%$ CI 0 제외)

(e) 결론 — σ_i 신호 약함 honest 입증

- ✓ KM20 oracle은 sample-size robust (단점: 학습 ~30분)
- σ_i 신호는 median 수준에서만 detect 가능, 개별 query는 random과 동치
- → "분포 분산을 활용하는 것"의 한계, 분포의 "위치"만 알아도 충분
- → RQ3 distribution-agnostic 추구의 motivation chain

4. RQ3 — 분포 모를 때 어떤 방식이 KM20 oracle을 대체?

(a) 동기

학습 X, 결정론으로도 KM20 수준 회수 가능?

(b) 실험

- 22 method × DEEP 1M + SIFT 1.5M × 5 sel × 5 seed × 100 query
- 5/5 회의 초기 7-way → W1 16-method → 5/7 새벽 22-method 완성

(c) 22 method 분류 (5 paradigm)

Paradigm	Method	특징
Cluster (Offline)	KM20 (oracle) / MiniBatch / partial_fit / HDBSCAN / GMM / BIRCH / Spectral	K-means 기반, 학습 필요
Locality	Hilbert / Z-order / Hybrid	Space-filling curve
Projection	Random Proj / Sparse RP / PCA-1D	차원 축소
Tree	KD-tree / PQ	분할 indexing
Online weight	KDE-pilot / Distance-Shell / IS variants 4종	분할 X, 가중치만

(d) 결과 — 4강 ★ (paired bootstrap CI 0 제외 5/10 cell robust)

순 위	Method	수치	핵심
★1	Hilbert (PCA 2D + 결정론 quantile)	mean Cohen's d = -0.156	학습 X, 결정론, ~수초 fit
★2	MiniBatch K-means partial_fit	ARI = 1.000 (batch 동등)	OLTP 적용 가능, 4 cell paired CI 0 제외
★3	HDBSCAN (5/7 NEW, density- based)	SIFT s=0.10 -3.99% [-5.34, -2.12]	모든 22 method 중 mid-sel best
★4	Hybrid (KMeans + Hilbert) (5/7 NEW)	SIFT 평균 rank 5.83 (Hilbert 5.85 보다 약간 우수)	SIFT s=0.10 -3.10% [-4.61, -1.19]

(e) Negative Control — cluster 분할 자체의 가치 정량 증명

Method	수치	해석
PQ	DEEP s=0.01 +23.64% [+15.91, +31.80]	massive failure (분할 paradigm 미스매치)
Sobol	SIFT s=0.01 +33.62%	가장 큰 hurt (quasi-random 사용 불가)
IS variants	d = +0.5~+0.7	medium hurt (분할 X 한계)
Distance-Shell	d = +0.49	cluster X 한계 (online weight 만)

→ 4 negative control 모두 CI 0 제외 hurt → "cluster 분할 자체"가 결정적 가치

(f) Hilbert mechanism 정량 분리 (5/7 W1-C 분석)

Metric	Hilbert	Z-order	해석
Inverse Manhattan	1.000 (perfect)	1.992 (50% jumps)	1D-2D continuity 보존도
Stratum compactness	4.77	12.12	Hilbert가 2.54× 더 compact
ARI orthogonality avg	0.316 (curve sibling)	0.314	Z-order와 정보 공유

→ Hilbert의 강한 결과는 PCA 효과가 아닌 curve 자체의 locality

(g) Method orthogonality ranking (5 ARI CSV 통합 분석)

직교성 ranking (avg ARI, 낮을수록 정보 직교): - 1위 **sparse_rp** (0.122) — 가장 직교 - 2위 **pca1d** (0.277) - 3위 **curve sibling Hilbert/Z-order** (0.31) - 4위 **tree** (0.331) - 5위 **cluster method 4종** (0.55+) — 정보 redundant
→ 본 연구의 22 method가 **정보적으로 5 region cover** → ablation 학습 정당성 ✓

(h) Cross-scale 1M ↔ 8M 검증

- 18 method × 2 sel = 36 cell
- **method ranking 1M/8M 동일** (외적 타당성 강화)
- 8M에서 sampling 자연 안정화 (random_proj -3.34% 가장 개선)
- kde_pilot 만 +5.27% deviation (adaptive estimator scale 한계)

(i) 결론

✓ **Hilbert + MiniBatch partial_fit** = production replacement (학습 X / OLTP 가능) ✓ **HDBSCAN** = SIFT skew 환경 추가 가치 ✓ **Hybrid** = 양 paradigm 결합 (5/7 NEW) ✓ **모든 method $|d| < 0.8$** → "공간 인식의 limit" honest 명시

5. RQ2 vs RQ3 종합 비교 — 분포 알 때 vs 분포 모를 때

(a) 핵심 차이

구분	RQ2 (분포 알 때)	RQ3 (분포 모를 때)
baseline	KM20 oracle, 모든 40 cell BERN 우위	4강 (Hilbert / partial / HDBSCAN / Hybrid)
effect size	sample-size robust	KM20과 같은 region ($d \approx -0.15$)
학습 비용	KM20 ~30분	Hilbert ~수초 / partial_fit OLTP
production 적합	학습 가능 시	학습 X 또는 OLTP 환경

(b) 상황별 권장

상황	권장 방식	이유
분포 정확히 안다 + 학습 시간 OK	KM20 oracle	40/40 cell 일관
분포 안다 + OLTP 환경 (학습 시간 X)	MiniBatch partial_fit	ARI 1.000 batch 동등, streaming 지원
분포 모름 + 학습 X	Hilbert curve	~수초 fit, 결정론, inverse Manhattan 1.000
분포 모름 + SIFT 같은 skew 환경	HDBSCAN	mid-sel best -3.99%, density-based

(c) 핵심 insight

분포 모르는 상황에서도 Hilbert / HDBSCAN이 KM20과 같은 region 진입 가능.

"공간 인식 자체가 가치" — 정확한 분포 모르더라도 그 공간 내 어디에 있는지만 알면 OK.

= production deployment 가능 (학습 부담 없이).

6. 8M 진행 + 멀티 테이블 + 추가 보강 plan

(a) 8M (DEEP 8M, 대용량 검증)

- 현재 ✓: 16 method sensitivity + 18 method cross-scale 측정 완료
- W2 추가 후보:
- 16 → 22 method 확장 (HDBSCAN/GMM/Sobol/Sparse_RP 추가)
- SIFT 8M 측정 (현재 SIFT는 1.5M만)

(b) 멀티 테이블 join (future work, 본 연구 scope X)

- Exqutor의 main scope = multi-relation join
- 본 연구는 단일 테이블 정확성 → multi의 필요조건만 입증
- 6/11 보고서 framing: "단일 정확성 → multi 일반화는 follow-up work"
- 자문 메일 (지도교수)에 "multi-table 일반화" 가능성 자문 항목 포함

(c) 추가 보강 후보 (W2~W3 sprint)

우선순위	작업	가치
W2	σ table 재계산 (DEEP 1M / SIFT σ wiped)	reproducibility 회복
W2	8M 16 $\rightarrow$ 22 method 확장	cross-scale 외적 타당성 보강
W3	NMI / AMI metric (RQ3 ARI robustness check)	16 method 정보 직교성 보강
W3	Real data ARI 16 method $\times$ 2 dataset	RQ3 narrative 강화
Future	Phase 6/7 root cause 정량 (vector.c integration)	RQ1 measurement methodology 완성

7. 5/8 회의 합의 안건 (D-1, 오늘 19:00)

1. RQ1 narrative 옵션 2 (정직 reporting) 채택 합의

- Phase 6 (production-near) 핵심 인용
- Phase 7 (simulation) honest 별도 보고
- 5-cell 격차 자체를 sub-contribution으로 격상

2. RQ3 contribution 5종 (HDBSCAN + Hybrid 추가) 격상 합의

- 기존 3종: Hilbert / MiniBatch partial / Cluster 분할 가치
- 추가 2종: HDBSCAN (SIFT mid-sel best) / Hybrid (양 paradigm)

3. Limitations 6종 명시 합의

L	항목
L1	단일 테이블 (multi는 future work)
L2	KM20 oracle 학습 부담
L3	Effect size practical small (모든 $ d < 0.8$)
L4	numpy estimator sampling-population scope
L5	RQ1 measurement methodology robustness (5/7 W2 NEW)
L6	σ_i 신호 약함 honest 입증

4. 자문 메일 합의 (5/15 발송)

- 채림 석사: Hilbert mechanism + Phase 6/7 origin (5종 자문)
- 지도교수: contribution framing + multi 일반화 (6종 자문)

5. W2 분담 + 5/27 발표 분담

8. 향후 마감 일정

마감	내용
5/8 (오늘) 19:00	비대면 회의 — narrative 합의 + 자문 합의
~5/15	자문 발송 (채림 + 지도교수)
5/22	교수님 미팅
★ 5/27	최종 발표 (D-20)
5/28	전시회 자료 마감
★ 6/11	최종 보고서 제출 (D-35)

9. 회의 자료 위치

자료	위치
1page summary	<code>submission/_drafts/속도는벡터_5월8일회의_1page_summary_20260506.md</code>
종합 master (7 contribution + 6 Limitations)	<code>experiments/results/RQ1_RQ2_RQ3_종합_master.md</code>
5/27 발표 outline	<code>submission/_drafts/속도는벡터_5월27일발표_slide_outline_20260506.md</code>
자문 메일 채림석사	<code>submission/_drafts/속도는벡터_자문메일초안_채림석사_20260506.md</code>
자문 메일 지도교수	<code>submission/_drafts/속도는벡터_자문메일초안_지도교수_20260506.md</code>

GitHub 최신 commit: - `edbcfd3` 팀원 공유 자료 — PDF + Claude Design deck prompt - `592b022` 팀원 공유용 RQ 진행 정리 (구어체) - `1475814` 5/7 메인 통합 manager → 5 worker 핸드오프 - `8d079d3` narrative 일관성 보강 - `1267b8a` RQ2/3 디리뷰 보강 - `74d6aea` narrative 옵션 2 정직 reporting

질문 / 피드백 회의에서 부탁드립니다 🙏