

Skew-Aware Stratified Sampling for Vector-Augmented Analytical Query

W4 Sprint 결과 종합 — 4강 method (Hilbert / Hybrid / MiniBatch_partial / HDBSCAN) 의
5 dataset × 2 scale 일반화 검증, 분포 sweet spot 정리, 자문 메일 합의

TEAM

속도는벡터

박세은 · 강재현 · 조현빈 · 이동욱

ADVISOR

박광현 교수

BDAI Research Lab

REFERENCE

arXiv:2512.09695v2

Exqutor (BDAI)

DATE

2026.05.08

W4 Sprint Meeting

오늘의 구성

TABLE OF CONTENTS · 7 SECTIONS · 15 SLIDES · 30 MIN

01 Motivation Exqutor 보완 영역	02 Matrix 15 cell sprint	03 RQ1 · Diagnostic selectivity gradient	04 RQ2 · Aware KM20 + K-aware	05 RQ3 · Agnostic 25 method tier
06 4강 Heatmap 5 dataset 일관성	07 Distribution sweet spot	08 Multi-relation vector + join	09 Honesty limit · future	10 자문 · 일정 5/27 narrative

EXQUTOR (BDAI) · 본 논문 영역

ECQO — 인덱스가 있을 때 HNSW range query 로 정확한 카디널리티를 1~2 ms 안에 추정. multi-table query plan 까지 직접 다룸.

Adaptive Sampling — 인덱스 없는 단일 테이블 영역에서 momentum 기반 동적 sample size 조정으로 1.2~3.2× speedup. *그러나 분포 인지 sampling 의 가치는 미분 석.*

■ 인덱스 ✓ + multi-table ✓

covered

■ 인덱스 ✕ + 단일 테이블

partial — sample size 만

본 연구 · 보완할 영역

Adaptive Sampling 의 전 단계인 "어떻게 sample 을 분배할 것인가" 의 가치를 정량화.

01 분포 인지 stratification (KM20 oracle) 의 가치 정량 입증

02 분포 모를 때 production-ready 4강 method 도출

Hilbert / Hybrid / MiniBatch_partial / HDBSCAN

03 σ_i Neyman 신호 honest 한계 보고

필요조건 · 단일 테이블 정확성은 multi-table 정확성의 필요조건. 단일 → multi 일반화는 *future work*.

단일 테이블 매트릭스 (12 CELL)

DATASET	DIM	SF1 (800K)	SF10 (8M)	비고
DEEP	96	■	■	normal · 균형
SIFT	128	■	■	cluster ratio 9.41 — imbalanced
SSN++	256	■	■	balanced (ratio 1.29)
WIKI	768	■	—	high-dim text
YFCC	192	■	—	PCA from 1280d
YFCC_DL	192	■	■	분포 정합성 비교용

MULTI-RELATION 3 CELL

- partsupp_deep_sift_10 · 한 행 두 임베딩 (96 + 128)
- partsupp_deep_wiki_10 · dim 격차 (96 vs 768)
- partsupp_deep_10 ✕ part_wiki_10 · TPC-H natural join

chain_unified.py 로 cell 당 25 method × 5 sel × 5 seed × 100 query 일괄 측정.
 partsupp_<DS>_<sf> 일관 패턴.

sf100 (80M) 은 5/8 회의 후 자문 합의 후 별도 측정 (W4 의 future scope).

측정 - PER-SEED SPEARMAN P + BOOTSTRAP 95% CI

DATASET	SF1 P	SF10 P	부호 일관
DEEP	-0.680	-0.621	consistent
SIFT	-0.74	-0.66	consistent
SSN++	[TBD]	[TBD]	measuring
WIKI	[TBD]	—	measuring
YFCC	[TBD]	[TBD]	measuring

W1 sprint 확정 · DEEP-KM20 $\rho = -0.680$, 95% CI $[-0.800, -0.440]$ (bootstrap, 0 제외).
selectivity 가 절반이 되면 추정 오차가 단조 증가.

SIFT 1M SELECTIVITY 효과 - SEL 별 BERN 오차 (BASELINE)



RQ1 결론 · skewed 분포 + 좁은 selectivity 영역에서 BERN 은 systematic 으로 부정확. 분포 인지 sampling 의 동기 확보.

KM20 VS BERN - PAIRED $\Delta\%$ (SEL=0.10), 4 METHOD 일관

CELL	HILBERT	HYBRID	MB_PARTIAL	HDBSCAN
DEEP_sf1	-0.43	-1.06	-1.36	-1.84
DEEP_sf10	-1.20	-1.91	-2.07	-1.77
SIFT_sf1	-32.08	-28.95	-31.58	-32.63
SIFT_sf10	-10.72	-10.20	-10.22	-10.47
SSN_sf1	+2.34	+1.35	+1.73	+1.56
SSN_sf10	+2.06	+1.25	+2.04	+1.39
WIKI_sf1	-9.61	-7.69	-9.86	-9.96
YFCC_sf1	-6.88	-5.71	-7.15	-7.23

ANTI-NEYMAN ABLATION

 σ_i 신호 anti-direction 좁은 sel=0.01 측정.

DATASET	$\Delta\%$ VS PROP.
DEEP_sf10	+5.21%
SIFT_sf10	+9.49%
SSN/WIKI/YFCC	[TBD]

K-sweep $K \in \{10, 20, 50, 100, 200\} \rightarrow K=20$ default 가 5 dataset 일반화 robust.
 K_{optimal} 격차 [TBD].

Honest · Anti-Neyman vs Proportional Wilcoxon $p > 0.5$, Cohen's $d < 0.1 \rightarrow \sigma_i$ 신호 비결정적.

TIER ELIMINATION FLOW - 25 → 12 → 8 → 6 → 4

TIER 0 · ALL	25 method (16 base + 9 NEW)	25
TIER 1 · 통계	≥5/10 cell paired bootstrap CI 0 제외	~12
TIER 2 · COST	학습 < 5분 + memory < 10 GB + det.	~8
TIER 3 · SCALE	sf1 ↔ sf10 부호 일관성 ≥ 80%	~6
TIER 4 · WINNER	Hilbert · Hybrid · MB_partial · HDBSCAN	4

9 NEW method · DBSCAN, OPTICS, Agglomerative, Hierarchical KMeans, Faiss IVF, PCA-KMeans, KMeans++, Coresets, Spectral.

TIER 4 WINNER 4강 - PRODUCTION 특성

METHOD	학습	DET.	ONLINE
Hilbert	learning-free	✓	✓
Hybrid	~2 min	✓	partial
MB_partial	< 1 min	✓	✓
HDBSCAN	~5 min	✓	—

Negative control · IS NaN sel=0.01 80~95%, PQ +23.6%, Sobol +33.6%, Random_proj 큰 hurt → "분할 자체의 가치" narrative.


HEATMAP — PAIRED Δ% (SEL=0.10) · 음수 = IMPROVE / 양수 = HURT

CELL	HILBERT	HYBRID	MB_PARTIAL	HDBSCAN
DEEP_sf1	-0.43	-1.06	-1.36	-1.84
DEEP_sf10	-1.20	-1.91	-2.07	-1.77
SIFT_sf1	-32.08	-28.95	-31.58	-32.63
SIFT_sf10	-10.72	-10.20	-10.22	-10.47
SSN_sf1	+2.34	+1.35	+1.73	+1.56
SSN_sf10	+2.06	+1.25	+2.04	+1.39
WIKI_sf1	-9.61	-7.69	-9.86	-9.96
YFCC_sf1	-6.88	-5.71	-7.15	-7.23


CROSS-SCALE 부호 일관성

DATASET	SF1 → SF10
DEEP	consistent (-)
SIFT	consistent (-)
SSN++	consistent (+) hurt

4-강 method × cell heatmap (sel=0.10) — W4 partial




DATASET 별 효과 크기 RANKING — DISTRIBUTION SWEET SPOT



SSN++ honest 보고 · cluster ratio 1.29 (balanced) → 4강 method 가 기여하지 못하는 distribution. mild hurt 정직 reporting.

CLUSTER RATIO (MAX/MIN) 매핑

DATASET	RATIO	효과
SIFT	9.41	LARGE
WIKI 768d	[high]	LARGE
YFCC 192d	[mid]	MEDIUM
DEEP	~2	small
SSN++	1.29	HURT



→ distribution sweet spot — cluster ratio 가 효과 크기를 결정. SIFT (9.41) LARGE / WIKI/YFCC MEDIUM / DEEP small / SSN++ (1.29) HURT.

MULTI-VECTOR — 한 행 두 임베딩

- `partsupp_deep_sift_10` · DEEP (96d) + SIFT (128d) = 224d concat
- `partsupp_deep_wiki_10` · DEEP (96d) + WIKI (768d) = dim 격차 시나리오

CELL	KM20	HILBERT	MB_P	HYBRID	HDBSCAN
deep_sift_10	[TBD]	[TBD]	[TBD]	[TBD]	[TBD]
deep_wiki_10	[TBD]	[TBD]	[TBD]	[TBD]	[TBD]

핵심 질문 · 4강 method 의 multi-vector 일반화 성립 여부. 5/8 새벽 측정 완료 시 update.

MULTI-TABLE NATURAL JOIN

`partsupp_deep_10` ⋈ `part_wiki_10` · TPC-H natural foreign key (`ps_partkey` = `p_partkey`). 두 dataset 의 다른 dim (96 vs 768) 환경에서 4강 method 일반화.

METHOD	RECOVERY RATE
KM20	[TBD]
Hilbert	[TBD]
MB_partial	[TBD]
Hybrid	[TBD]
HDBSCAN	[TBD]

scope · 단일 정확성은 multi 의 필요조건만. 충분조건까지 일반화는 future work — Exqutor multi-table 영역 본격 통합은 차후 학기.

측정 METRIC — SF1 / SF10

METRIC	SF1	SF10
PCA correlation (192 comp avg)	[TBD]	[TBD]
KS test p-value	[TBD]	[TBD]
Energy distance	[TBD]	[TBD]
4강 recovery 일치도	[TBD]	[TBD]

방법 · 채림 적재본 (YFCC) vs 자체 추출 (build_yfcc.py — 1280d CLIP → PCA 192d → partsupp_yfcc_dl) 을 sf1/sf10 동일 row count 로 비교.

CAVEAT & HONEST REPORTING

- 두 PCA fit 은 다른 **sample** 으로 학습됨 — component 부호 sign-flip 가능
- component-wise correlation absolute 값으로 정합성 판단
- 일치하지 않을 시 → distribution shape 차이 별도 honest 보고
- 4강 recovery 일치 여부가 distribution-aware sampling 의 transferability 입증

가설 · 192d PCA 의 정보 보존이 충분하면 두 적재본의 4강 recovery 가 일치. 일치하지 않으면 PCA target dim 재검토 + distribution shift detection 으로 link.

- L1

단일 → multi-table generalization · 단일 정확성은 multi 의 필요조건. W4 partsupp_deep_sift / deep_10×part_wiki_10 부분 입증, 일반 multi-relation 영역은 future work.
- L2

NPY-only mode 의 RQ2 dependency · KM20 oracle 학습은 partsupp_<DS>_sf NPY 추출본 의존. 적재본 부재 시 RQ2 skip, RQ1/RQ3 만 가능.
- L3

YFCC PCA basis 검증 caveat · YFCC vs YFCC_DL 의 PCA fit 은 다른 sample 으로 학습됨. component-wise correlation [TBD] 1.0 미만 시 distribution shape 차이 honest 별도 보고.
- L4

σ_i 신호 약함 · Anti-Neyman vs Proportional CI 0 제외하지만 paired Wilcoxon $p > 0.5$, Cohen's $d < 0.1 \rightarrow \sigma_i$ 신호의 비결정적 가치 명시. SSN++ mild hurt 함께 보고.
- L5

IS NaN sel=0.01 발산 · Importance Sampling NaN 비율 80~95%. 분할 X + weight only 의 estimator invalid 를 negative control narrative 으로 활용.
- L6

K-sweep upper bound K=200 · K>200 (예: K=500/1000) 영역은 미측정. WIKI 768d / SSN++ 256d 고차원 환경에서 K_optimal 이 그 영역에 있을 가능성.
- L7

sf100 (80M) deferred · sf1↔sf10 2-scale 부호 일관성으로 W4 narrative 완성. sf100 cross-scale 일관성은 5/8 회의 후 자문 합의 결과를 반영하여 별도 측정 (W4 의 future scope).
- L8

Effect size dataset 별 격차 · DEEP small (~-1~-2%) / SIFT large (~-10~-32%) / WIKI/YFCC medium (~-7~-10%) / SSN++ mild hurt (+1~+2%). 5 dataset 별 effect size 별도 보고.

FUTURE WORK — 우선순위 6종

- 01 sf100 (80M) 5 dataset 측정**
5/8 자문 회신 후 launch (~5/15). chain_unified.py extension. 5/27 발표 narrative 에 cross-scale 추가.
- 02 Exqutor multi-table 영역 일반화**
충분조건까지 입증. 차후 학기.
- 03 vector.c C-level integration**
Phase 6 SQL D 영역 — Exqutor source code level merge.
- 04 K>200 K-sweep**
WIKI/SSN++ 고차원 영역. K_optimal 의 dim 의존성 정량.
- 05 Distribution shift detection**
online detection mechanism — 4강 method 의 자동 선택.
- 06 DuckDB native fixed-rate baselines**
pgvector 33% / VBASE 50% / DuckDB 100% 직접 통합.

TIMELINE · 5/8 → 6/11



sf100 측정 **estimated time** · 5 dataset × ~2-4 hour = ~10-20 hour overnight chain.
chain_unified.py extension 으로 한 번에 launch.

리스크 · 자문 회신 지연 시 sf100 launch deferred → 5/27 narrative 는 W4 only 로 자체 closure.
honest reporting.

채림 석사 — 이론 자문

01 YFCC PCA fit 의 sample 의존성

PCA fit 이 다른 sample 으로 학습된 두 적재본 (YFCC vs YFCC_DL) 의 distribution shape 검증 방법론. component-wise correlation + KS + energy distance 의 적정성.

02 multi-table natural join 영역의 sampling rate dependency

partsupp_deep ✕ part_wiki 환경에서 sampling rate 가 정확도에 미치는 영향. 단일 → multi-table 일 변화 caveat.

지도교수 — 발표 NARRATIVE + 자원

01 sf100 (80M) 측정의 시간 자원

5 dataset × 2-4 hour = ~10-20 hour overnight chain 자원 합의. tmux session 진행 plan.

02 W4 narrative 발표 정합성

4강 method (Hilbert/Hybrid/MB_partial/HDBSCAN) + 25 method tier elimination 의 5/27 발표 narrative flow 검토. SSN++ mild hurt honest reporting 의 수위.

발송 일정 · 5/9 ~ 5/12 메일 발송 → ~5/15 회신 ETA → 5/15 이후 sf100 측정 launch → 5/22 교수님 미팅에서 자문 결과 + sf100 진행 상황 공유.

5/27 발표 12-SLIDE MAPPING

- 01 표지 — 속도는벡터
- 02 Motivation — Exqutor + 본 연구
- 03 Matrix — 15 + 5 = 20 cell
- 04 RQ1 — selectivity gradient 5×2
- 05 RQ2 — KM20 + K-aware + Anti-Neyman
- 06 RQ3 — 25 method tier elimination
- 07 4강 일관성 heatmap
- 08 Multi-vector + Multi-table
- 09 YFCC 분포 정합성
- 10 Honest limitation
- 11 Future work

5/8 회의 DELIVERABLE

- 01 W4 결과 합의 — 4강 + tier + heatmap
- 02 Honest limitation 8종 합의 — 발표 시 수위
- 03 자문 메일 초안 합의 — 채림 + 지도교수
- 04 sf100 launch timing 결정 — 자문 회신 후
- 05 5/27 narrative flow 합의 — 12 slide mapping

본 W4 sprint 는 Exqutor 가 정량 처리한 인덱스 + multi-table 영역의 보완으로서, 단일 테이블 비인덱스 + 분포 인지 sampling 의 가치를 정량화한다.