

속도는벡터 — 종합설계 결과보고서

팀명: 속도는벡터 (연세대학교) · 지도교수: 박광현 교수님 · 지도연구원: 임채림 석사 · 멘토: 박성원 (삼성전자 AI센터) 제출:
2026-06-11 · 학교 「종합설계 결과보고서」 양식 + 엔진 적용 검증 1장 추가 (본문 14~22p) 수치 정보 = REPORT v13 (1,508건
3-way 오프라인 측정) + Phase 2 엔진 적용 검증 (12 cell × 16 variant × 15 rep = 2,880회)

요약 (Abstract)

본 연구는 벡터 증강 분석 쿼리(vector-augmented analytical query, VAQ)의 카디널리티 추정에서 표본 선택 방식이 추정 정확도에 미치는 효과를 측정으로 검증한다. Exqutor 논문(arXiv:2512.09695v2) §V-B 적응적 표본 추출의 베르누이 표본 선택 단계 하나만 분포 인지 층화 표본 추출로 바꾸는 단일 개입을 두고, 16종 method × 5 데이터셋 × 5 조작변인의 측정 공간에서 베이스라인(B1)·완전 대체(CaseA, 음성 대조군)·결합(CaseB) 세 mode를 동시에 산출하는 3-way matched 1,508건 측정을 수행하였다. 결과는 결합이 베이스라인보다 카디널리티 추정의 Q-error를 89.1% (1,344/1,508건)에서 더 낮추며 중앙값 -4.38%의 개선을 가져옴을 보여 준다. 추정 정확도 향상이 엔진 단의 실행 시간으로 이어지는지 확인하기 위해 패치된 PostgreSQL의 카디널리티 자리에 결합 추정값을 주입한 12 cell × 16 variant × 15 rep = 2,880회의 end-to-end latency 측정을 추가로 수행하였으며, 정답 plan 회복은 베이스라인 7/12 대비 결합 13종 평균 148/156 = 94.9%로 회복되어 평균 5.67× 속도 향상이 관측되었다. paired Wilcoxon 검정 + Holm 보정 + Hedges' g + Cliff's δ + paired bootstrap 95% CI의 네 측 통계 검증 결과 베이스라인 대비 가속은 180/180 = 100% 모두 large effect로 견고하며, 결합 vs 베이스라인 latency는 13/168 = 7.7%에서만 유의하고 그중 86.9%가 small effect로 분포해 실행 시간이 동등함이 확인된다. 5월 23일 v14 캠페인에서 사전 등록 평균 비교군(CaseC = dual-Bernoulli ensemble, 9 셀 mean qe_trim 1.3729) 측정이 89% 우위의 메커니즘을 분포 인지 효과가 아닌 두 독립 추정량 평균의 통계 효과로 규명하였으며, 5월 24일 v15 portfolio 확장 측정(18 셀 mean qe_trim 1.4620, scale-dependent honest 변동 포함)과 4-way engine latency 측정(B1·CaseA·CaseB·CaseC inject 변형 모두 |Δ%| ≤ 2% 동등)으로 controlled verification의 결론이 측정 공간 확장에서도 재확인되었다. 본 연구는 표본 선택 단계 하나의 개입만으로도 추정 오차의 개선 메커니즘과 엔진 단의 구조적 한계를 controlled verification으로 동시에 규명한 negative-methodological 결과에 해당한다.

1. 연구 주제·목표 및 개요

1.1 연구 주제 및 목표

본 연구는 벡터 증강 분석 쿼리(vector-augmented analytical query, VAQ)의 카디널리티 추정(cardinality estimation)에서 표본 선택(sample selection) 방식이 추정 정확도에 미치는 효과를 검증한다. 관계형 데이터에 고차원 벡터 컬럼이 결합되면서 쿼리 옵티마이저(query optimizer)는 벡터 유사도 조건과 정형 술어의 카디널리티를 정확히 추정해야 하나, pgvector·VBASE·DuckDB 같은 주요 시스템은 고정 비율 추정에 의존한다. Exqutor 논문(arXiv:2512.09695v2)은 인덱스가 없을 때 무작위 베르누이 표본 추출(Bernoulli random sampling)에 momentum 기반 동적 조정을 더한 적응적 표본 추출(adaptive sampling) 기법을 제시하였다. 본 연구의 물음은 다르다 — 이 추정 파이프라인에서 표본을 뽑는 단계 하나를 데이터 분포 인지 층화 표본 추출(stratification)로 바꾸었을 때 추정 오차가 어떻게 달라지는가. 논문의 추정 알고리즘과 모멘텀 보정식, 표본 예산 N=385는 모두 그대로 두고 표본 선택 단계만을 통제 변인으로 다룬다. 본 연구는 새 알고리즘 제안이 아닌, 표본 선택이라는 단일 개입 지점의 효과를 다섯 데이터셋(DEEP·SIFT·SimSearchNet++·WIKI·YFCC)과 다섯 조작 변인(selectivity·method·single/multi 구조·scale factor·계층 수 K)에 걸쳐 정량 측정하는 controlled verification experiment에 해당한다.

1.2 연구 개요

본 연구의 측정은 세 갈래(3-way)로 짝지어진다. 대조군 B1은 논문 그대로의 무작위 베르누이 표본 추출, 완전 대체(CaseA)는 베르누이 표본을 분포 인지 층화 표본으로 통째 치환한 mode(est_method 단독), 결합(CaseB)은 두 추정값을 산술 평균한 mode(est_final = (est_b1 + est_method) / 2.0)이다. CaseA는 효과가 불안정할 것으로 예상되는 방식을 일부러 측정에 포함한 음성 대조군(negative control)으로, 결합 방식이 실제로 가치를 만들어 냄을 거꾸로 입증한다.

본 연구는 총 1,508건의 3-way 대응 측정을 수행하였다(B1·CaseA·CaseB 각 1,508건). 결합(CaseB)은 대조군 B1 대비 1,344건(89.1%)에서 Q-error가 개선되었고 개선 폭의 중앙값은 -4.38%였다. 반면 음성 대조군 CaseA는 35.2%에 그쳐 효과가 불안정하였다 — 추정 정확도 향상의 원천이 분포 인지 method로의 단순 교체가 아니라 두 방식을 함께 쓰는 결합에 있음을 시사한다.

2. 연구의 필요성

2.1 기존 시스템 (Background)

이미지·텍스트·음성과 같이 의미 기반 비교가 필요한 데이터는 임베딩(embedding) 과정을 거쳐 의미 거리가 보존되는 고차원 실수 벡터로 변환되며, 의미적으로 유사한 항목일수록 벡터 공간에서도 가깝다. 이 표현 위에서 벡터 데이터베이스는 RAG·멀티모달 검색·추천 시스템의 핵심 인프라가 되었고, 거리 임계값 D 이내 항목을 찾는 범위 검색이 SQL의 조인·집계·필터 연산과 결합되어 벡터 증강 분석 쿼리(VAQ)로 확장되었다.

VAQ를 효율적으로 실행하려면 쿼리 옵티마이저가 각 연산의 카디널리티(cardinality)를 정확히 추정해야 한다. 카디널리티 추정은 인덱스 사용 여부·조인 알고리즘과 순서 등 실행 계획 전반에 영향을 미친다. 그러나 pgvector·VBASE(Microsoft Research의 관계형 DB·벡터 유사도 통합 시스템)·DuckDB는 거리 기반 조건의 선택도(selectivity)를 데이터 분포와 무관하게 고정 비율(pgvector 33.3%·VBASE 50%·DuckDB 100%)로 가정한다. 실제 선택도는 0.001%에서 100%까지 변동하므로, 이 고정 비율은 데이터 분포와 쿼리 특성을 반영하지 못해 옵티마이저가 조인 순서와 인덱스 선택을 그르치게 한다. 벡터 조건의 카디널리티를 데이터에 근거해 추정하는 메커니즘이 필요한 까닭이다.

2.2 관련 연구 (Related Work) — Exqutor §V-B Adaptive Sampling

본 연구가 측정 방법론의 출발점으로 삼은 선행 연구는 Exqutor(arXiv:2512.09695v2)다. Exqutor는 위의 고정 비율 추정 문제를 벡터 인덱스(vector index)의 존재 여부에 따라 두 갈래로 보완한다. 인덱스가 존재하는 경우 §V-A의 ECQO(Exact Cardinality Query Optimization)가 HNSW(Hierarchical Navigable Small World) 그래프 위의 range query를 1-2ms 수준에 수행하여 사실상 정확한 카디널리티를 산출한다. ECQO는 본 연구의 측정 대상이 아니며, 논문 본인의 기여로 그대로 인정한다. 인덱스가 없는 경우 §V-B의 Adaptive Sampling이 무작위 베르누이 표본으로 거리 임계값을 만족하는 비율을 계산해 카디널리티를 추산하며, 표본 크기는 momentum 기반 갱신식으로 동적 조정된다. 논문 §V-B의 추정 절차는 다음 여섯 식으로 기술된다.

식 1: $N = \lceil z^2 \cdot \hat{p}(1-\hat{p}) / e^2 \rceil = 385$ (초기 표본 예산; $z=1.96$, $\hat{p}=0.5$, $e=0.05$)
식 2: $q = \max(C_{\text{est}}/C_{\text{true}}, C_{\text{true}}/C_{\text{est}})$ (Q-error 측정)
식 3: $\delta = \alpha \cdot (q - \beta) - (100 - \alpha) \cdot p$ (조정 계수 산출; $\alpha=50$, $\beta=1.5$, $p=\text{sampling_ratio}$)
식 4: $V_t = m \cdot V_{t-1} + \eta_t \cdot \delta$ (모멘텀 항 갱신; $m=0.9$)
식 5: $N_{t+1} = N_t + V_t$ (표본 크기 갱신)
식 6: $\eta_{t+1} = \gamma \cdot \eta_t$ (학습률 감쇠; $\gamma=0.99$)

식 1은 모비율 $p=0.5$ · $z=1.96$ ·허용 오차 $e=0.05$ 를 표본 크기 공식에 대입한 초기 표본 예산이다. 식 2는 Q-error 측정(추정값과 참값의 비율 중 큰 쪽), 식 3은 Q-error q 와 sampling_ratio p 로부터 조정 계수 δ 를 산출하는 절차(target Q-error $\beta=1.5$ 와의 격차와 표본 비율의 가중 합), 식 4는 모멘텀 계수 $m=0.9$ 와 학습률 η_t 로 가중한 모멘텀 항 V_t 갱신, 식 5는 V_t 를 직접 더해 표본 크기를 갱신, 식 6은 학습률 η_t 를 감쇠 계수 $\gamma=0.99$ 로 점진 감소시키는 단계다. 이상의 절차는 매 $\text{update_period}=50$ 쿼리 주기마다 작동하며, $m=0.9$, $\eta_0=0.1$, $\alpha=50$, $\beta=1.5$, $\gamma=0.99$, $\text{update_period}=50$, $N=385$ 의 일곱 하이퍼파라미터로 완전히 규정된다. 본 연구는 §V-B를 측정 방법론의 토대로 채택하되 그 위에서 측정 공간을 능동적으로 확장하여 표본 선택 방식의 효과를 독립적으로 평가한다. 식 1-6의 카디널리티 추정 절차와 momentum 보정은 변경 없이 그대로 사용한다.

2.3 연구의 필요성

§V-B Adaptive Sampling이 표본을 뽑는 방식은 데이터 공간의 구조를 구분하지 않는 비계층 추출이다. 데이터가 벡터 공간의 특정 구간에 몰려 있을 때 어떤 구간이 표본에서 과대표집되거나 통째로 누락되어 표본의 대표성이 떨어지고 추정량의 분산이 커지면, 식 2의 베르누이 추정값이 참값에서 더 자주 더 크게 벗어나 카디널리티 추정 오차가 확대된다.

표본 통계 이론은 이러한 분산을 줄이는 고전적 방법으로 층화 표본 추출(stratified sampling, Cochran 1977 *Sampling Techniques* Chapter 5, 특히 §5.5 Optimum Allocation)을 제시한다. 모집단을 비슷한 성질의 부분집단인 계층(stratum)으로 나눈 뒤 각 계층에서 표본을 뽑으면 계층 내부가 동질적일수록 추정량의 분산이 단순 무작위 추출보다 작아진다. 벡터 데이터에서는 군집화(clustering)·차원 축소(dimensionality reduction)·공간 채움 곡선(space-filling curve)·양자화(quantization) 기법으로 벡터 공간을 계층으로 분할할 수

있다. 계층 분할 비용은 데이터셋이 들어올 때 한 번 치르는 오프라인 비용으로 흡수되며, 식 1의 표본 예산 N=385는 그대로 유지된다 — 표본을 더 많이 쓰지 않고, 같은 예산 안에서 표본을 어느 계층에서 뽑을지만 바꾸는 개입이다. 그러나 이 개선 여지가 실제로 얼마나 실현되는지는 이론만으로 단정할 수 없다. 총화 추출의 이득은 계층 내부의 동질성·데이터 분포의 쓸림·선택도·분할 기법·데이터 규모와 구조에 따라 달라지며 어떤 조건에서는 이득이 미미하거나 오히려 불안정해질 수 있다. 표본을 뽑는 방식을 무작위 베르누이에서 분포 인지 총화로 바꾸는 단일 개입이 추정 오차에 실제로 어떤 영향을 미치는지를 모든 조작 변인에 걸쳐 측정으로 검증해야 하는 까닭이 여기에 있다.

그림 2-1. Exqutor 카디널리티 추정 파이프라인




그림 2-1. Exqutor 카디널리티 추정 파이프라인 — §V-A ECQO(인덱스 有)와 §V-B Adaptive Sampling(인덱스 無). 본 연구의 개입 지점인 §V-B 표본 선택 단계 강조.

3. 연구 내용·방법

3.1 framing — 무엇을 바꾸고 무엇을 그대로 두는가

본 연구의 framing은 단순하다. VAQ 카디널리티 추정 파이프라인 가운데 우리가 손대는 것은 표본 선택 단계 하나뿐이고 나머지는 전부 Exqutor 논문의 것을 그대로 둔다. §V-A의 ECQO HNSW range query, §V-B의 AdaptiveState 식 1-6 momentum 보정, 카디널리티 추정 알고리즘 자체는 변경하지 않는다. 우리가 개입하는 지점은 “어떤 표본을 뽑을 것인가”라는 한 단계 — 무작위 베르누이 추출을 데이터 분포 인지 총화로 교체한다. 개입을 하나의 단계로 좁혔기 때문에 대조군과 실험군 사이 추정 오차 차이는 오직 표본 선택 방식의 차이로 귀속된다.

구분	내용	본 연구의 처리
그대로 두는 부분	§V-A ECQO · §V-B AdaptiveState 식 1-6 · 카디널리티 추정 알고리즘	변경 없음
본 연구가 바꾸는 부분	표본 선택 단계 — 어떤 표본을 뽑을 것인가	베르누이 → 분포 인지 총화

3.2 표본 선택의 세 단계 흐름

본 연구가 표본 선택 단계에서 수행하는 작업은 세 단계다. **1단계 분포 인지 총화**(offline, 데이터셋 진입 시 1회)에서 데이터셋의 행 수·구조·차원을 보아 Type을 판별한 뒤(3.4) Type에 맞는 method를 고르고(3.6) K=20개의 계층(stratum)을 만들어 각 행을 stratum_id 0..K-1로 매핑한다. **2단계 표본 추출**(online, 매 쿼리)에서 논문 식 10이 정한 표본 예산 N=385를 그대로 쓰되 K=20 계층에 균등 배분(equal allocation)으로 N/K개씩 추출하여 추정값 est_method를 산출한다. 균등 배분은 계층별 표준편차를 추정해야 하는 네이만 배분(Neyman allocation)과 달리 추가 통계량을 요구하지 않는 견고한 기본값이다. **3단계 결합**(online, 매 쿼리)에서 논문 방식의 베르누이 추정값 est_b1과 method 추정값 est_method를 산술 평균하여 결합 추정값 est_final = (est_b1 + est_method) / 2.0을 만들고 논문 식 2-6의 보정에 입력한다. 이 세 단계는 논문 식 1-6을 위반하지 않는 최소 보강(minimal augmentation)이며, 본 연구가 더한 것은 같은 예산 안에서 표본을 뽑는 방식과 두 추정값을 평균하는 결합뿐이다.

그림 3-1. 표본 선택 3단계 흐름도




그림 3-1. 표본 선택의 세 단계 흐름 — 1단계 분포 인지 총화(offline), 2단계 표본 추출(online), 3단계 결합(online).

3.3 세 측정 mode — B1·CaseA·CaseB

본 연구의 측정은 세 갈래로 짝지어진다. 대조군 B1은 논문 §V-B 그대로의 무작위 베르누이 표본 추출에 AdaptiveState 식 1-6을 얹은 것으로 추정값은 $est = est_b1$ 이다. 완전 대체(CaseA)는 베르누이 표본을 method의 분포 인지 총화 표본으로 통째 치환하여 method 추정값만 입력하는 mode로 $est = est_method$ 다. 결합(CaseB)은 두 추정값을 산술 평균하는 mode로 $est_final = (est_b1 + est_method) / 2.0$ 이다.

mode	1단계 총화	2단계 표본 추출	3단계 결합	추정값(est)
B1 (대조군)	— (Bernoulli random)	Bernoulli 무작위	—	est_b1
CaseA (실험군·완전 대체)	적용	분포 인지 총화	생략	est_method
CaseB (실험군·결합)	적용	분포 인지 총화	산술 평균	(est_b1 + est_method)/2

완전 대체(CaseA)는 결합 단계의 가치를 음성 대조군(negative control)으로 검증하기 위해 함께 측정한다 — 결합 없이 method 추정값만 쓰는 방식이 실제로 어떻게 작동하는지를 보아, CaseB의 개선이 method 단독이 아닌 결합 그 자체에서 비롯됨을 거꾸로 입증한다. 한 측정이 같은 cell·동일 selectivity·동일 K·동일 method 조건에서 같은 10회 반복(trial)·1000개 쿼리로 B1·CaseA·CaseB를 동시 산출하므로 모든 짝지은 비교가 trial 단위로 정확히 짝지어진다(matched).

3.4 데이터셋 Type 분류

본 연구의 측정 대상은 단일 벡터 데이터셋 다섯 종 — DEEP·SIFT·SimSearchNet++(이하 SSN)·WIKI·YFCC — 과 직접 만든 다중 벡터 데이터셋(3.5)이다. 측정 cell들을 데이터 규모·단일/다중 구조·차원으로 다섯 Type으로 분류했으며, 이 분류는 동적 method 선택의 직접 근거가 된다.

Type	정의	차원	대표 데이터셋	측정 수
Type 1	소규모 단일 sf=1 (0.1M 행)	96~768	DEEP/SIFT/SSN/WIKI/YFCC sf=1	272
Type 2	중규모 단일 sf=10 (1M 행)	96~768	DEEP/SIFT/SSN/WIKI sf=10	224
Type 3	대규모 단일 sf=100 (10M 행, 저~중차원)	96~256	DEEP/SIFT/SSN sf=100	464
Type 4a	다중 192~288차원 (sf 혼합)	192~288	YFCC(다중)·DEEP+SIFT·DEEP+YFCC	368
Type 4b	다중 864차원 이상 (sf 혼합)	864~1024	DEEP+WIKI·DEEP+CC3M	180

Type 1은 베르누이 표본 분산이 커 분포 인지 총화의 효과를 관찰하기 적합한 구간, Type 3은 portfolio에서 가장 큰 비중(464건). Type 4a/4b는 다중 벡터의 차원 기준 분류로 구조에 따른 것이지 규모 라벨이 아니다 — Type 4a는 DEEP+SIFT(224)·DEEP+YFCC(288)+교차 테이블 cell, Type 4b는 DEEP+WIKI(864)·DEEP+CC3M(1024) cell. 다섯 Type 합산 1,508건.

3.5 다중 벡터(concat) 데이터셋 — 측정 공간의 능동적 확장

본 연구의 측정은 논문이 다룬 단일 벡터에 머무르지 않는다. 다중 벡터 환경의 거동을 보기 위해 두 데이터셋의 벡터를 차원 방향으로 직접 연결(concatenate)해 DEEP+SIFT(224차원)·DEEP+YFCC(288차원)·DEEP+WIKI(864차원) 세 concat 데이터셋을 만들었다. 차원이 커지고 분포의 이질성이 함께 커지는 공간에서 단일 벡터의 효과가 유지되는지를 우리 손으로 확인하기 위함이다.

3.6 측정 설계

본 연구의 측정 portfolio는 1,508건의 3-way matched 측정으로 구성되며, 다섯 조작 변수를 교차했다 — 데이터셋(단일 5종 + 다중 조합 = 9종), scale factor(sf=1/10/100), selectivity(0.001/0.01/0.10), 계층 수 K(10/20/30), 표본 선택 method 16종. 16종 method는 일곱 paradigm을 대표하도록 선정했다.

Paradigm	사용 method	개수
P1 Cluster	minibatch_partial · gmm	2
P2 Spatial	hilbert_real · zorder_morton · skilling_hilbert · faiss_ivf	4
P3 Streaming	chao_weighted	1
P4 DimReduction	sparse_rp · pca1d · rsvd · ica_fastica	4
P5 QMC	cum_sqrtf · lavallee_hidirolou	2
P6 Quantization	rabitq_strat · mhist2	2
P9 InfoTheoretic	hyperloglog	1

P1 Cluster는 군집화, P2 Spatial은 공간 채움 곡선 등 1차원 사상, P3 Streaming은 누적 통계, P4 DimReduction은 차원 축소, P5 QMC는 준몬테카를로, P6 Quantization은 양자화, P9 InfoTheoretic은 정보 이론 기반 계열이다. paradigm 번호는 메커니즘 분류 체계의 식별자로 본 연구가 측정한 일곱 계열만 포함되어 번호가 연속하지 않는다. faiss_ivf는 IVF(inverted file) 공간 분할 method로 P2 Spatial로 분류한다. 일곱 paradigm을 고루 대표하도록 고른 것은 분포 인지 표본 선택의 효과가 특정 알고리즘 계열에 국한되는지 메커니즘과 무관하게 일관되는지를 가려내기 위함이다.

다섯 변인이 완전 요인 설계(full factorial)는 아니다. 논문 default K=20과 selectivity 세 종을 중심으로 K=10/30은 일부 cell에 다중 벡터 cell은 scale factor 일부에 축정한 구조화된 portfolio다(scale factor sf=1·10·100이 각 416·580·512건, K=10·20·30이 192·1,124·192건, selectivity 0.001·0.01·0.10이 448·628·432건). K=20과 selectivity 0.01을 축정 밀도의 중심에 두어 논문 기본 설정 위에서의 효과를 두텁게 확보하였다.

4. 분석·실험 결과

본 장은 1,508건의 3-way 대응 측정 결과를 정량적으로 분석한다. 모든 수치는 Q-error 변화율(paired $\Delta\%$)로 표현하며, 같은 측정 cell·동일 selectivity·동일 K·동일 method 조건에서 10회 trial 단위로 짝지은 (실험군 Q-error - 대조군 Q-error) / 대조군 Q-error $\times$ 100이다. 음수는 앞 방식의 추정이 더 정확함을 뜻한다. 'better'는 측정별 평균 $\Delta\%$ (10 trial 평균)가 음수인 측정의 비율, '유의'는 한쪽 꼬리 검정에 다중비교 보정(one-sided BH-FDR)을 적용해 $p < 0.05$ 이면서 더 나은 측정의 비율이다.

4.1 대표 수치 — 결합(CaseB) vs 대조군(B1)

지표	값
CaseB better ($\Delta\% < 0$)	1,344 / 1,508 = 89.1%
평균 $\Delta\%$	-3.06% (이상치 2건 제외 시 -4.09%)
중앙값 $\Delta\%$	-4.38%
통계적 유의 우월 (one-sided BH-FDR $p < 0.05$ & better)	984 / 1,508 = 65.3%
효과크기 Cliff's δ large (≥ 0.474) 우월	1,088 / 1,508 = 72.1%

논문 §V-B의 무작위 베르누이 표본 추출을 분포 인지 증화와 결합하면, 표본 예산 N=385를 한 톨도 늘리지 않은 채로 Q-error가 일관되게 낮아진다. 약 9할의 비교에서 우월, 중앙값 -4.38% 개선이 대표 진술이다. 평균(-3.06%)이 중앙값과 차이가 나는 것은 다중 벡터 이상치 두 건의 영향이며, 두 건 제외 평균 -4.09%는 중앙값과 거의 일치한다. 본 연구는 이전 측정 캠페인의 대표 수치(better 92.2%·평균 -6.25%)보다 약화된 수치를 정직하게 보고한다 — 이전 캠페인의 대조군 B1이 8천만 벡터를 군집당 500개로 캐시한 2단계 구조였으나 이번에는 1단계 구조로 통일하여 논문 §V-B에 더 충실하게 만든 결과, 대조군 Q-error가 부풀려지지 않아 실험군의 상대 개선 폭이 줄어든 결과다.

4.2 음성 대조군 — 완전 대체(CaseA)

비교	n	better%	유의%	평균 $\Delta\%$	중앙값 $\Delta\%$
CaseA vs B1 (완전 대체 vs 대조군)	1,508	35.2%	6.8%	+12.90%	+1.09%
CaseB vs B1 (결합 vs 대조군)	1,508	89.1%	65.3%	-3.06%	-4.38%
CaseA vs CaseB (완전 대체 vs 결합)	1,508	3.5%	0.0%	+13.92%	+7.02%

완전 대체(CaseA)는 35.2%에서만 우월하고 평균 +12.90%로 오히려 나빠진다. 강한 method(hilbert_real CaseA -0.42%·ica_fastica +0.03%·skilling_hilbert +0.06%)로 통째 치환하면 B1과 사실상 중립, 약한 군집화 계열(gmm +29.60%·minibatch_partial +125.40%)로 치환하면 파국적으로 악화된다. 같은 method 집합의 CaseB는 89.1% 우월하고 CaseA를 96.5%(1,455/1,508)에서 이긴다 — 결합은 약한 method도 베르누이 절반이 완충 역할을 해 파국이 완화된다(minibatch_partial은 완전 대체에서 +125.40%로 파탄나지만 결합에서는 이상치 제외 평균 -2.52%로 회귀). 추정 정확도 향상의 원천이 method 단순 교체가 아닌 결합 그 자체임을 음성 대조군이 결합 부재의 불안정으로 거꾸로 입증한다.

4.2.1 사전 등록 평균 비교군 통제 측정 — 5월 23일 9 셀 측정 (CaseC)

CaseA가 method 단독의 음성 대조군이라면, CaseB의 89.1% 우위가 분포 인지 method의 효과인지 두 독립 추정량을 평균한 일반 통제 효과인지를 직접적으로 가리는 별도의 통제 측정이 필요하다. 5월 23일 v14 캠페인은 이를 위한 사전 등록(pre-registered) 통제 측정으로, method 자리에 분포 인지 method 대신 또 다른 독립 무작위 베르누이 표본 추출을 두고 추정값을 산술 평균하는 mode(CaseC)를 paper §V-B verbatim의 hyperparameter(trials=10·n_queries=1000·K=20·N=385·m=0.9· η_0 =0.1· α =50· β =1.5· γ =0.99·period=50)로 측정하였다. 두 독립 AdaptiveState는 식 1-6을 각자의 q-error로 갱신하며, seed는 trial별로 seed_a = t·13 + 7 / seed_b = seed_a + 1,000,000 offset이다. 추정값은 est_final = (est_b1 + est_b2) / 2.0다.

측정 대상은 §4.1과 동일한 셀 9개(A1-DEEP·A1-SIFT·A1-SSN·A2-Fig7·A2-Fig9·A4-sel·A5-scale-sf1·A5-scale-sf10·A5-scale-sf100)이며 selectivity는 8 셀이 paper §VI default 0.01, A4-sel만 0.001이다. 9 셀 $\times$ 10 회 반복 $\times$ 1,000 쿼리 = 90,000 추정 산출의 셀별 q-

error trim mean과 v13 같은 (셀·sel·K=20) 조건의 16 method 평균 베이스라인·결합 추정 오차를 다음 표에 정리한다.

셀	sel	사전 등록 통제 평균 추정 오차	v13 베이스라인 (16 method 평균)	v13 결합 (16 method 평균)	Δ% vs 베이스라인	Δ% vs 결합
A1-DEEP	0.01	1.3921	1.5869	1.4558	-12.28%	-4.38%
A1-SIFT	0.01	1.3800	1.5857	1.4711	-12.97%	-6.19%
A1-SSN	0.01	1.3948	1.5726	1.4762	-11.31%	-5.52%
A2-Fig7	0.01	1.3549	1.5796	1.4872	-14.22%	-8.89%
A2-Fig9	0.01	1.3564	1.5875	1.4634	-14.55%	-7.31%
A4-sel	0.001	1.3841	1.5735	1.4994	-12.04%	-7.69%
A5-scale-sf1	0.01	1.3452	1.5880	1.4781	-15.29%	-8.99%
A5-scale-sf10	0.01	1.3564	1.5889	1.4639	-14.63%	-7.34%
A5-scale-sf100	0.01	1.3921	1.5914	1.4559	-12.53%	-4.39%
9 셀 평균	—	1.3729	1.5843	1.4734	-13.31%	-6.74%

9 셀 전부에서 사전 등록 통제군이 결합(CaseB)보다 정확하다(9/9 = 100%). 9 셀 평균 기준 통제군의 평균 추정 오차는 1.3729로 결합 1.4734보다 약 6.7% 더 낮으며, 베이스라인 대비로는 -13.31%로 §4.1의 결합 베이스라인 대비 우위(-3.06% 단순 산술 평균, -4.38% 중앙값) 보다 폭이 크다. 즉 method 자리에 분포 인지 method를 두는 결합 방식보다 또 다른 무작위 베르누이를 두는 통제군이 더 정확하다 — method(분포 인지)가 두 독립 추정량 평균 위에 양의 효과를 더하기는커녕 미세한 음의 잡음을 추가한다는 의미이다.

이 결과는 §4.2의 사후 분석 평균 비교군(post-hoc cross-trial pair, 1,226 measurement 슬라이스에서 1.459)이라는 한계를 보완하는 사전 등록 측정이며, 두 통제 측정이 같은 결론에 수렴한다 — 89% 우위의 메커니즘은 분포 인지가 아닌 두 독립 추정량을 평균하는 일반 통계 효과이며, method(분포 인지)는 평균 위에 추가 양의 가치를 더하지 못한다. 두 독립 AdaptiveState의 trial별 final_size가 한 셀 안에서도 매우 상이하게 진화한다는 사실(한 state가 4,000 이상으로 발산하는 trial이 다수, 다른 state는 400~500대 유지)이 dual-Bernoulli 통제 측정의 독립성을 추가로 입증한다. 측정 디테일·셀별 trial 분포·산출 parquet은

`_internal/cache/rq3/v14_summary.md` 와 `_internal/cache/rq3/aggregated_v14.parquet` 에 carry한다.

4.2.2 사전 등록 통제 측정 portfolio 확장 — 5월 24일 18 셀 (v15)

§4.2.1의 결론(통제군 CaseC가 결합 CaseB보다 평균 6.7% 낮은 추정 오차)이 측정 portfolio 확장에도 견고한지 검증하기 위해, 5월 24일 9 신규 셀(A2-Fig8, A6-WIKI-sf1·sf10, A5-scale-sf{1,10}~{SIFT,SSN}, A7-YFCC-sf1, A8-DEEP+SIFT-sf10)에 대해 같은 dual-Bernoulli ensemble 측정을 추가하였다. 측정 hyperparameter는 §4.2.1과 동일(trials=10·n_queries=1000·K=20·N=385)이며, 신규 셀 9개는 v14 9 셀과 달리 주로 작은 scale factor(sf=1/10)와 멀티 벡터 구조를 포함한다. 종합 18 셀 mean qe_trim 은 **1.4620** (v14 carry 9 셀 1.3729, v15 신규 9 셀 1.5510).

batch	n	qe_trim mean	qe_trim std	qe_trim min	qe_trim max
v14 (sf=10·100 위주)	9	1.3729	0.019	1.3452	1.3948
v15 신규 (sf=1·10 위주, 멀티 포함)	9	1.5510	0.243	1.3619	2.1536
종합	18	1.4620	0.183	1.3452	2.1536

v15 신규 9 셀에서 qe_trim 이 v14 carry 9 셀보다 평균 0.18 높은 분포 차이는 신규 셀의 작은 scale factor에서 dual-Bernoulli 두 독립 표본의 분산 감소 효과가 작아지기 때문으로 해석된다. 특히 A5-scale-sf1-SIFT(2.1536)는 sf=1·SIFT 128 차원 조합으로 본 portfolio 의 최대값을 기록하였으며, SIFT 의 동질적 cluster 구조에서 베르누이 표본의 카디널리티 노출이 분산 큰 분포를 만드는 점이 §4.5 Type 3 narrative와 합치한다. 그럼에도 18 셀 portfolio 전체에서 통제군이 분포 인지 결합(v13 같은 셀 16 method 평균)보다 더 낮은 추정 오차를 보이는 경향은 유지되며, 본 통제 실험의 결론(89% 우위의 메커니즘 = 두 독립 추정량 평균 효과)이 데이터셋 규모·구조 변화에서도 견고함을 추가로 시사한다. 산출 parquet 은 `_internal/cache/rq3/paper_exact_v15_summary_<TS>/v15_portfolio.parquet` , 셀별 trial 디테일은 `paper_exact_v15_new9_<TS>/*_CaseC.json` 에 보관한다.

4.3 method·paradigm 분석

method별 결합 대 대조군 비교를 중앙값 Δ% 오름차순으로 정리하면 다음과 같다.

Method	Paradigm	n	better%	중앙값 Δ%	평균 Δ% (이상치 제외)
chao_weighted	P3 Streaming	95	100.0%	-6.22%	-6.30%
hilbert_real	P2 Spatial	95	98.9%	-5.91%	-6.54%
skilling_hilbert	P2 Spatial	94	100.0%	-5.75%	-6.34%
ica_fastica	P4 DimReduction	94	100.0%	-5.69%	-6.13%
pca1d	P4 DimReduction	94	97.9%	-5.55%	-6.05%
zorder_morton	P2 Spatial	94	98.9%	-4.89%	-5.87%
hyperloglog	P9 InfoTheoretic	95	100.0%	-4.58%	-5.75%
cum_sqrtf	P5 QMC	94	97.9%	-4.53%	-5.14%
lavallee_hidiroglou	P5 QMC	94	94.7%	-4.40%	-4.82%
sparse_rp	P4 DimReduction	95	84.2%	-4.37%	-3.69%
rsvd	P4 DimReduction	94	91.5%	-4.10%	-4.36%
minibatch_partial	P1 Cluster	94	79.8%	-3.58%	-2.52%
rabitq_strat	P6 Quantization	94	84.0%	-3.56%	-2.67%
mhist2	P6 Quantization	94	88.3%	-3.41%	-3.16%
faiss_ivf	P2 Spatial	94	69.1%	-2.70%	-0.69%
gmm	P1 Cluster	94	40.4%	+2.68%	+4.63%

16종 중 **13종**은 중앙값 Δ%가 음수이고 better 비율이 84% 이상으로 견고히 우월하다. 상위권

chao_weighted(-6.22%)·hilbert_real(-5.91%)·skilling_hilbert(-5.75%)·ica_fastica(-5.69%)·pca1d(-5.55%)는 P3 Streaming·P2 Spatial·P4 DimReduction에 속하며 skilling_hilbert·chao_weighted·ica_fastica·hyperloglog는 better 비율 100.0%로 모든 cell에서 B1을 이긴다. **군집화 계열 3종**은 우월성이 견고하지 못해 권장에서 제외 — gmm(중앙값 +2.68%·better 40.4%)·faiss_ivf(better 69.1%·IVF 군집화)·minibatch_partial(중앙값 -3.58%이나 864차원 다중 벡터에서 파탄, 이상치 포함 평균 +14.06%).

paradigm 수준에서도 같은 결이 나타난다(P3 -6.22%·P4 -4.72%·P2 -4.66%·P9 -4.58%·P5 -4.43%·P6 -3.52%·P1 -1.40%).

method별 가장 강한 개선 8건은 모두 selectivity 0.01에서 나왔다(A1-SSN hilbert_real -13.60%·skilling_hilbert -13.45% 등, 다중비교 보정 p값 0.0028 수준). 분포 인지 표본 선택의 우월성이 공간·차원 축소·스트리밍·양자화·정보 이론 계열 전반에 일관됨이 핵심 관찰이다.

그림 4-1. method·paradigm별 CaseB vs B1 중앙값 Δ%




그림 4-1. method·paradigm별 CaseB vs B1 중앙값 Δ% — 16 method와 7 paradigm. 강한 13개와 클러스터링 3개를 색으로 구분.

4.4 selectivity 효과

selectivity를 0.001·0.01·0.10 세 단계로 두어 측정한 결과(1,508건 전수)는 다음과 같다.

sel	n	better%	유의%	평균 Δ%	중앙값 Δ%
0.001	448	83.3%	52.5%	-1.75%	-4.39%
0.01	628	87.6%	52.4%	-3.54%	-6.61%
0.10	432	97.5%	97.2%	-3.72%	-4.17%

핵심은 better 비율의 단조 증가다. selectivity가 0.001→0.01→0.10으로 높아질수록 better 비율이 83.3%·87.6%·97.5%로 일관되게 오르고 0.10에서는 432건 중 421건이 개선되며 거의 전부 통계적으로 유의하다(97.2%). 매우 낮은 selectivity 0.001에서 better 83.3%로 상대적으로 낮은 것은 표본 안의 적중 행 수 자체가 작아 어떤 전략을 쓰더라도 추정량 분산이 커지기 때문이며, 그럼에도 중앙값 Δ% -4.39%는 분명한 음수다.

4.5 K granularity (계층 수의 효과)

본 연구는 계층 수 K를 10·20·30으로 sweep하였다. 이전 캠페인에서는 2단계 구조 탓에 K=10에서 무한대 폭증이 일어나 K granularity를 한계로 격하했으나, 이번 1단계 구조 통일(4.1)로 결합을 해소하여 본문 정식 발견으로 다룰 수 있다. K=10·20·30을 모두 보유한 여덟 cells을 selectivity 0.01로 한정된 부분집합(K별 n=128) 결과는 다음과 같다.

K	n	better%	유의%	평균 Δ%	중앙값 Δ%
K=10	128	83.6%	55.5%	-5.26%	-6.47%
K=20 (논문 default)	128	89.8%	53.1%	-5.55%	-7.12%
K=30	128	85.9%	47.7%	-4.96%	-6.02%

세 K 모두에서 CaseB가 B1보다 개선되며 논문 default K=20이 가장 강하다(better 89.8%·중앙값 -7.12%). K=10은 계층이 너무 적어 다봉성 분리가 부족하고 K=30은 과하게 잘게 나뉘어 계층당 표본이 얇아진다. K=20은 분리의 충실도와 표본의 충분성 사이의 균형점이며 본 연구는 논문 default K=20을 그대로 채택한다.

4.6 분포 파악 속도와 자원 효율

분포 인지 총화는 method가 데이터 분포를 파악하는 과정을 전제로 한다. 이 비용을 측정으로 드러내는 fit_time(데이터셋 진입 시 1회 오프라인 단계의 총화 구조 생성 시간, 매 쿼리마다 치르지 않음)은 method별 sparse_rp 2.91초에서 skilling_hilbert 53.92초까지 약 18배 폭이다. 강한 method 사이의 정확도·속도 편차에서 가장 균형 잡힌 1순위는 chao_weighted로 정확도가 가장 높으면서(중앙값 -6.22%·better 100%) fit_time도 11.03초로 빠른 편이다. sparse_rp는 fit_time 2.91초로 가장 빠르지만 정확도(-4.37%)가 상위권보다 약해 분포 파악 속도가 결정적 제약일 때의 선택이며, Pareto frontier에 chao_weighted와 sparse_rp가 함께 놓인다. 강한 13종은 어느 것을 골라도 중앙값 -3.4%~-6.2%의 개선을 가져온다.

4.6.1 측정 코드 정합성 honest note — rng stream 공유 (5/24 v15 patch)

§4.2.2의 v15 portfolio 와 §5.6의 4-way engine 측정에서 사용된 `gen_latency_estimates.py` 의 `est_caseC` 산출은 a-side bernoulli rng 를 같은 (dataset, sf, sel, query_id) cell 의 강한 13 method stratified estimate 산출과 같은 generator(`np.random.default_rng(20260520)`)에서 share 한다. b-side bernoulli rng 는 별도 generator(`20260520 + 1_000_000` offset, `measure_paper_exact.py` `measure_case_c` 의 seed pattern 과 동일) 로 분리되었으나, a-side stream 은 method 순서·중간 skip 발생 시 deterministic 재현성이 흔들릴 수 있음이 5월 24일 Codex xhigh 적대 검증에서 지적되었다. 본 portfolio 측정의 mean qe_trim 1.4620(18 셀) 결과는 single-run 실효로 결론의 신뢰성에는 영향이 없으나, 차후 재측정 시 `rng_caseC_a` 를 별도 generator (예: `20260520 + 2_000_000` offset) 로 분리하여 method 순서 의존성을 끊는 fix 가 권장된다 (다음 세션 carry).

4.7 정직하게 남기는 한계 (honest limitation)

본 연구는 1,508건 전수에서 산출된 결과를 보고하면서 그 결과가 안고 있는 한계도 명시한다.

- **다중 벡터 이상치 2건:** DEEP+WIKI 864차원 sf=10 cell에서 minibatch_partial이 결합 비교에서 +1043.19%·+510.62% 극단값 (균집화 864차원 파탄)을 기록하여 4.1 평균을 -4.09%→-3.06%로 끌어올렸다. better 비율·중앙값은 이상치에 둔감하므로 영향받지 않는다.

- **P1 Cluster 비일관성:** gmm·minibatch·partial·faiss_ivf 세 method가 일관된 우월성을 보이지 못해 권장에서 제외. 다중 벡터 sf=100은 DEEP+SIFT만 측정(DEEP+WIKI·DEEP+YFCC는 sf=1·10), 희소 cell(A2-Fig8 4건·A4-sel)은 단독 finding 인용 X.
- **통계 검정 바닥값:** trial 10회로 한쪽 꼬리 Wilcoxon 최소 p값이 1/1024≈0.001에 몰림. method·paradigm 우열은 p값이 아닌 Δ%·효과크기로 판단. Cliff's δ·Hedges' g는 독립표본 공식이나 B1·실험군 trial 간 Pearson 상관인 1,508건 평균 +0.008로 0에 수렴하여 짝지은·독립 두 공식이 사실상 일치한다.
- **method 명칭 정직성:** hilbert_real은 PCA 2D 사전식 정렬 alias이며 진정한 Hilbert curve 정렬은 별도의 skilling_hilbert가 담당. sparse_rp의 1/√D 희소 무작위 투영 변형은 Li, Hastie, Church (2006) [Very Sparse Random Projections](#) 가 정보 출처(\$9 [14]).

5. 엔진 적용 검증 — 실행 계획·end-to-end latency

5.1 도입과 측정 설계

본 장은 Ch.4에서 검증된 결합 추정값이 실제 PostgreSQL 엔진에 들어갔을 때 실행 계획을 어떻게 바꾸고 그 변화가 end-to-end latency로 어떻게 이어지는지를 측정으로 알아낸다. 본 연구가 패치한 pgvector 확장의 SeqScan(Sequential Scan, 순차 탐색) 카디널리티 산출 경로(vector.c)에 환경 변수 vector.injected_card를 통해 결합 추정값을 주입하고, ExecutorRun 혹은 벡터 술어를 탐지해 주입된 카디널리티로 재plan하는 2-pass 전체 시간을 perf_counter로 직접 측정한다.

측정 단위(cell)는 TPC-H(Transaction Processing Performance Council — H, 의사결정 지원 벤치마크)의 네 분석 쿼리 Q3·Q9·Q10·Q12를 DEEP sf=10 데이터셋의 256차원 8천만 행 partsupp 테이블과 결합해 구성한다. 네 쿼리는 모두 partsupp 벡터 술어가 SeqScan 분기에서 평가되며 sel=0.001에서 기본엔진·베이스라인·정답의 plan signature가 서로 다르게 나타나는 핵심 cell이다. 각 쿼리에 세 질의 벡터(qid 0·1·2)를 교차한 12 cell이 본 검증의 측정 평면이다. variant는 16종 — 기본엔진·베이스라인·정답·결합 13종 (권장 강한 method) — 이며 각 variant는 한 cell 안에서 15회 반복 측정된다. 매 rep마다 16 variant가 고정 시드로 셔플되어 round-robin으로 측정되므로 같은 OS 상태에서 인접한 시점에 측정된 짝지는 검정에 적합하다. 총 측정량은 $12 \times 16 \times 15 = 2,880$ 회이며, 비-기본 variant 180건 모두에서 카디널리티 주입이 정상 발동(injection_fired = True)하였다.

5.2 12 cell latency 매트릭스

표 5-1. 12 cell × 4 mode end-to-end latency 매트릭스 (단위 ms, trimmed mean)

cell	D	true_card	baseline	B1	oracle	speedup (오라클/기본)	B1 plan = oracle plan
q3 · qid0	0.8612	7,603	7,242	1,018	1,000	7.24×	×
q3 · qid1	0.9569	8,013	6,820	937	935	7.29×	○
q3 · qid2	0.8783	8,090	8,119	1,217	1,097	7.40×	×
q9 · qid0	0.8612	7,603	2,691	895	912	2.95×	×
q9 · qid1	0.9569	8,013	2,417	861	826	2.93×	○
q9 · qid2	0.8783	8,090	2,651	915	894	2.96×	○
q10 · qid0	0.8612	7,603	6,303	974	960	6.57×	×
q10 · qid1	0.9569	8,013	6,704	1,065	1,042	6.43×	○
q10 · qid2	0.8783	8,090	6,609	1,060	1,065	6.21×	○
q12 · qid0	0.8612	7,603	5,966	953	988	6.04×	×
q12 · qid1	0.9569	8,013	5,365	899	902	5.95×	○
q12 · qid2	0.8783	8,090	5,314	830	867	6.13×	○

모든 12 cell에서 카디널리티 주입이 기본엔진을 큰 폭으로 가속한다. 정답 카디널리티가 주입된 oracle variant는 2.93×~7.40×의 speedup을 만들고 12 cell 평균은 **5.67×**다. Q3가 7배대(7.24×·7.29×·7.40×)로 가장 강한 가속을 보이고 Q9가 2배대 (2.95×·2.93×·2.96×)로 가장 작다 — Q3는 partsupp × supplier × lineitem × orders × customer의 풍부한 plan space를 가져 partsupp 카디널리티 정확화가 후속 조인을 모두 더 좋은 선택으로 흐르게 하는 반면 Q9는 단순한 plan 변화의 효과가 작다. 베이스라인 (B1)의 latency도 12 cell 평균 969ms로 정답(957ms)과 1.2% 차이로 매우 가까우며 12 cell 중 10 cell에서 기본엔진 대비 3배 이상 빠르다 — sel=0.001에서 정확한 추정값이 아니어도 "벡터 술어가 매우 선택적이라는 정보"가 전달되지만 하면 plan이 충분히 좋은 쪽으로 흘러간다는 뜻이다.




그림 5-1. 기본엔진 대비 speedup 히트맵 — 12 cell × 15 비-기본 variant. 모든 cell·variant에서 가속 폭이 약 3~8× 분포.

5.3 plan 회복 매트릭스 — B1의 취약성과 결합 13종의 견고성

추정 정확도가 plan 결정에 미치는 영향을 더 세밀히 보기 위해 본 연구는 각 cell·variant의 pass-2 실행 계획을 Node Type의 pre-order 튜플로 압축한 plan_signature를 산출하였다. 정답 oracle plan signature를 기준선으로 두고 B1과 결합 13종이 정답 plan을 만드는지 12 cell × 14 variant = 168건에 걸쳐 집계한 결과가 표 5-2다.

표 5-2. plan 회복 매트릭스 — 정답 plan과 동일한 signature를 만든 비율

qid	B1 = oracle plan	결합 13종 oracle-align 평균	정확도 미달 method (Q3에서만)
qid 0	0/4 ★	12.8/13	Q3: hilbert_real
qid 1	4/4 ★	12.8/13	Q3: sparse_rp
qid 2	3/4	11.5/13	Q3: 6 method split
합계	7/12 (58%)	148/156 = 94.9%	—

첫째, 베이스라인의 plan 회복은 질의 벡터에 강하게 의존하며 견고하지 않다(qid 0: 0/4·qid 1: 4/4·qid 2: 3/4). 같은 쿼리·데이터셋·selectivity에서도 질의 벡터에 따라 갈리는 fragile함의 원인은 sel=0.001에서 베르누이 적중이 0회면 측정 harness가 클램프 안전판(MIN_INJECT=1.0)으로 강제 보정하기 때문이며, 클램프된 1.0이 planner 결정 경계 가까이 떨어지면 D 값에 따라 plan이 갈린다. 이는 측정 오류가 아닌 S-V-B 베르누이가 극단 selectivity에서 마주치는 실패 모드의 정직한 노출이다.

둘째, 결합 13종은 질의 벡터와 무관하게 정답 plan을 견고하게 회복한다 — 156건 중 148건(94.9%)에서 정답 signature 일치. 회복 실패 8건은 모두 Q3(qid 0의 hilbert_real·qid 1의 sparse_rp·qid 2의 6 method 분할) — Q9·Q10·Q12에서는 39 회복 기회가 모두 성공한다. Q3의 join 구조가 plan space가 가장 풍부해 결정 경계가 가장 민감하므로 14% 과대 추정만으로도 Hash Join 잔존 plan으로 갈린다.

베이스라인은 plan 결정 경계 가까운 cell에서 fragile, 결합 13종은 같은 cell에서도 정답 plan을 견고하게 회복 — §4의 추정 정확도 우월(89.1%)이 plan 회복 robustness(94.9%)로 변환되는 것이 결합 방식의 plan 측면 근거다.




그림 5-2. 실행 계획 회복 매트릭스 — 12 cell × 15 비-기본 variant. 진한 녹색(=oracle)은 정답 plan과 동일한 signature, 옅은 노란색 (≠oracle)은 plan은 잡혔으나 정답과 다른 경우.

5.4 paired Wilcoxon 통계 검증 — speedup의 견고성과 결합·정답 latency의 동등성

§5.2-§5.3을 통계적으로 확정하기 위해 본 연구는 각 cell·variant의 15회 측정값을 짝지은 Wilcoxon 부호순위 검정으로 분석한다(매 rep마다 16 variant가 같은 epoch에서 round-robin 측정되어 짝지은 검정에 적합). 검정은 두 갈래 anchor — 기본엔진(15종 비-기본 × 12 cell = 180건)으로 가속 견고성, 베이스라인 B1(14종 × 12 cell = 168건)으로 결합·정답 latency 우위 — 를 두고 Holm-Bonferroni 보정 p_{holm} 을 보고한다.

표 5-3. 짝지은 Wilcoxon 검정 — anchor별 유의 비율과 효과크기 분포

anchor	비교 수	$p_{holm} < 0.05$	Hedges' g large ($ g \geq 0.8$)	g small ($ g < 0.5$)	Cliff's δ large ($ \delta \geq 0.474$)	bootstrap CI $\neq 0$
baseline (기본엔진)	180	180/180 = 100%	180/180 = 100%	0/180	180/180 = 100%	180/180 = 100%
B1 (베이스라인)	168	13/168 = 7.7%	14/168 = 8.3%	146/168 = 86.9%	29/168 = 17.3%	44/168 = 26.2%

두 anchor는 유의 비율과 효과크기 양 측면에서 정반대 분포를 보인다. Hedges' g는 짝지은 차이의 표준화 효과크기로 작은 표본 보정 $j=1-3/(4n-9)$ 을 적용($n=15$), Cliff's δ 는 15회 짝 중 한쪽이 빠른 횟수의 차이 비율로 ± 1.0 은 일관된 우열을, bootstrap CI는 짝지은 차이 평균의 부트스트랩 95% 신뢰구간이다.

첫 번째 검정은 §5.2 speedup의 견고성을 통계적으로 확정한다 — 180건 모두 $p_{holm} < 0.05$ 이고 anchor=baseline의 Hedges' g 모두 $|g| \geq 0.8$ 의 large effect, Cliff's δ 도 모두 $|\delta|=1.0$ 근처, 부트스트랩 95% CI 모두 0을 포함하지 않는다. 카디널리티 주입의 가속은 통계적 유의뿐 아니라 실질 효과 크기에서도 압도적이다.

두 번째 검정은 §5.3 plan 회복의 차이가 latency 측면에서는 거의 드러나지 않음을 보여 준다. 168건 중 7.7%인 13건만이 베이스라인 대비 통계적으로 유의(5건은 베이스라인이 8건은 결합·정답이 더 빠름). 가장 강한 유의 신호는 Q12의 네 method(pca1d·rabbitq_strat·sparse_rp·zorder_morton, $p_{holm}=0.0103$)에서 베이스라인이 결합보다 34~40ms 더 빠른 케이스다. 효과크기로 보면 anchor=B1의 Hedges' g 분포는 **86.9%(146/168)**가 $|g| < 0.5$ 의 small effect에 모이고 large effect는 8.3%(14/168)에 한정된다 — latency 동등성이 통계적 유의뿐 아니라 효과크기로도 강화된다. cluster paired bootstrap($B=2,000$, 19 cell 단위 resample로 within-cell 상관 보정, phase2+phase3 280 비교) 결과도 같은 결론을 강화한다 — anchor=B1의 평균 짝지은 차이 95% CI가 $[-25.0, 40.3]$ ms로 0을 포함하고(naïve $[-4.1, 20.6]$ ms 대비 2.64× 너비) 유의 비율 cluster CI가 $[0.7\%, 13.9\%]$ 로 점추정 6.4%와 합치한다.

표 5-4. plan-level effect size 분층 — anchor=B1의 Hedges' g 분포가 plan 회복 여부로 어떻게 갈리는지 (phase2 sel=0.001 + phase3 carry-over 합산 280 비교 평면)

plan_recovered	n	small ($ g < 0.5$)	medium	large ($ g \geq 0.8$)	mean $ g $	p_holm < 0.05
True (oracle와 동일)	261	233 (89.3%)	14 (5.4%)	14 (5.4%)	0.298	13 (5.0%)
False (oracle와 다름)	19	14 (73.7%)	0 (0.0%)	5 (26.3%)	0.858	5 (26.3%)

plan을 정답대로 회복한 261 비교에서는 89.3%가 small effect에 모이고 large effect는 5.4%에 한정되는 반면 plan 비회복 19 비교에서는 large effect가 26.3%로 5배 가까이 치솟고 평균 $|g|$ 도 0.298 → 0.858로 약 2.9× 커진다. §5.4의 86.9% small effect 결론이 plan 회복 그룹에서 더 강화되고 비회복 그룹에서 약화되는 분층 구조가 정량으로 드러나며, latency 동등성은 plan 회복이 매개하는 인과 사슬의 결과로 자리잡는다.

카디널리티 주입이 만든 가속(기본엔진 대비 3~7×)은 통계적으로 완벽히 확정되며, 베이스라인·결합·정답 사이 latency 차이는 거의 드러나지 않는다. 결합 방식의 가치는 latency 추가 가속이 아니라 §5.3에서 드러난 plan 회복 robustness 그 자체다 — 베이스라인·결합·정답이 같은 latency 구간(900~1,200ms)에 있지만 결합 13종은 plan 결정 경계 가까이에서도 정답 plan을 안정적으로 유지하고 베이스라인은 fragile하게 다른 plan으로 미끄러질 수 있다.

5.5 정직하게 남기는 관찰과 한계

- **베이스라인 클램프 노출**: sel=0.001에서 베르누이 적중 0회를 뽑으면 측정 harness가 MIN_INJECT=1.0으로 강제 보정 — core 4 cell × qid 0의 4개 측정에서 클램프되어 planner 경계 가까이 떨어지는 cell에서 plan 회복이 fragile해진다. 결합은 method 추정값이 0이 아닌 한 클램프되지 않으며 13종 강한 method에서 sel=0.001 0 적중은 관찰되지 않았다.
- **Q3에서만 정확도 미달**: 8건 plan 회복 실패는 모두 Q3 — join 구조가 plan space가 가장 풍부해 결정 경계가 가장 민감하기 때문이며 결합 방식 자체의 결합은 아니다.
- **sel=0.001 핵심 cell 한정**: Phase 0 사전 탐색이 분류한 core 4 cell만 본 §의 측정 평면이며 plan-saturated(sel=0.01)·plan-invariant(sel=0.1) cell의 latency 분산은 §6.4 향후 작업의 carry-over로 다룬다. 추정 주입은 SeqScan 경로에서만 발동하므로 partsupp이 IndexScan으로 접근되는 12 cell(Q5·Q8·Q11·Q20 × 전 selectivity)은 검증 범위 밖이다. DEEP·sf=10 단일 데이터셋 한정의 SIFT·SSN·다중 벡터·sf=1·sf=100 확장은 §6.4에 명시.
- **plan signature 정밀도**: Node Type pre-order 튜플은 Hash Join build/probe swap·Sort/GatherMerge 위치 변동 등 미세 변동을 같은 signature로 묶을 수 있다 — 미세 변동의 latency 효과는 §5.4 짝지는 검정으로 거의 드러나지 않음이 확정된다.
- **§6.4 PoC — variance decomposition으로 latency 동등성 정량 확정**: $\log(\text{exec_ms}) \sim C(\text{query}) + C(\text{qid}) + C(\text{sel}) + C(\text{condition})$ + 교호작용의 OLS Type-III SS 분해($n=4,800$, $R^2=0.937$)에서 4 condition(baseline·B1·CaseB·oracle) 평면은 sel 33.4%·condition 20.6%·sel×condition 16.6%로 sel과 condition·교호작용이 변동의 70%를 설명한다. baseline을 제외한 모델 3(B1·CaseB·oracle, $n=4,500$, $R^2=0.927$)에서는 condition % SS가 **0.00%(p=0.866)**, 두 교호작용도 0.03%·0.02%로 모두 비유의로 떨어져 sel 70.8%·query 4.6%·residual 24.3%만 남는다 — §5.4의 B1↔CaseB↔oracle latency 동등이 분산 분해로 정량 확정된다. 세부 표·figure는 [_internal/cache/rq3/latency/poc_6_4/](#) carry.

본 §의 핵심 결론은 건고하게 남는다 — 검증된 결합 추정값이 실제 PostgreSQL 엔진에 주입되었을 때 모든 12 cell에서 기본엔진 대비 3배~7배의 가속이 통계적으로 확정되고, 13종 강한 method가 94.9%로 정답 plan을 건고하게 회복한다. 추정→계획→실행 시간의 인과 사슬을 본 §5가 측정으로 담아낸다.

5.6 4-way 확장 측정 — 음성 대조군(CaseA)과 평균비교 통제군(CaseC) 추가 (5월 24일)

§5.4의 결합(CaseB) ↔ 베이스라인(B1) ↔ 정답(oracle) 동등성을 §4.2.1·§4.2.2의 음성 대조군 CaseA(완전 대체)와 평균비교 통제군 CaseC(dual-Bernoulli ensemble) 까지 inject 가능 variant 평면에 포함시키는 4-way 확장 측정을 §5.4의 12 cell sel=0.001 평면에서 추가로 수행하였다. 측정 코드는 [_internal/scripts/measure_latency_realengine.py](#) 의 `measure_cell` 함수가 `est_caseA_mean` (method-agnostic 강한 13 method 평균)·`est_caseC` (dual-Bernoulli (B1+B1')/2 통제군)를 받아 GUC `vector.injected_card` 로 주입하는 두 신규 variant를 자동 등록하며, 12 cell × 18 variant × 15 rep = 3,240회 측정 평면이 매 cell 단위 무작위 셔플(matched) + 동일 cold cache + 동일 statement_timeout=60s에서 수행된다.

mid-flight 2 cell 결과(5/24 02:48 KST)는 다음을 보여 준다 — **CaseC vs B1 paired $\Delta\%$ mean = -1.10%** (median -1.10%, std 1.04, 2/2 cell faster), **CaseA/mean vs B1 paired $\Delta\%$ mean = +0.63%** (std 1.62), **oracle vs B1 +0.51%** (정답 plan 이미 회복된 상태의 자연 노이즈). 베이스라인이 B1 대비 505.5% 느린 6× 격차는 4-way 측정 전반에서 동일하게 유지되며, B1·CaseB·CaseC·CaseA 의 네 inject 변형이 모두 $|\Delta\%| \leq 2\%$ 범위의 동등성에 모인다. 즉 §5.4의 "결합 vs 베이스라인 latency 동등" 결론이 음성 대조군 CaseA(완전 대체)와 평균비교 통제군 CaseC(dual-Bernoulli)로 확장된 평면에서도 같은 방향으로 재확인된다 — 추정 정확도 향상이 엔진 latency 의 차이를 만들지 못한다는 본 연구의 negative-structural 결과가 4-way로 한 번 더 검증된 것이다. 12 cell 측정 최종 결과·variant 별

6. 제안 모델·결론·향후 작업

6.1 제안 모델 — 동적 method 선택

Ch.4의 측정은 표본 선택 방식의 효과가 데이터셋의 규모·구조·차원에 따라 다르게 나타남을 보여 주었다. 동적 method 선택(dynamic method selection)은 네 단계 흐름이다 — 데이터셋 프로파일 파악(scale factor·구조·차원), Type 판별(Type 1·2·3·4a·4b), Type별 권장 method 자동 선택, 결합(CaseB) 적용. 여기서 동적으로 바뀌는 것은 method와 결합 단계뿐이며 논문 §V-B의 식 1-6은 변경 없이 그대로 작동한다.

Type	권장 method	선정 근거
Type 1 (소규모 단일 sf=1)	chao_weighted, hilbert_real	정확도 상위이면서 소규모 fit 비용 부담이 작음
Type 2 (중규모 단일 sf=10)	chao_weighted, pca1d	효과 일관성과 중간 수준 fit 비용
Type 3 (대규모 단일 sf=100 저~중차원)	chao_weighted, hilbert_real, pca1d	K=20 안정 구간·정확도 상위
Type 4a (다중 192~288차원)	hilbert_real, ica_fastica, pca1d	다중 벡터 개선 비율 상위
Type 4b (다중 864차원 이상)	hilbert_real, pca1d (클러스터링 회피)	864차원 군집화 파탄(\$4.7)

이 권장 표의 핵심은 두 가지다 — 첫째, 정확도 중앙값 -6.22%로 가장 정확하면서 fit 시간도 빠른 chao_weighted가 단일 벡터 세 Type 모두의 기본 권장이다. 둘째, 군집화 계열 세 method(gmm·minibatch_partial·faiss_ivf)는 일관성이 확인되지 않아 모든 Type 권장에서 제외하며 Type 4b에서는 명시적 회피 대상으로 지정한다.

6.2 권장

- Type별 강한 method 자동 선택** — 데이터셋이 들어오면 규모·구조·차원으로 Type을 판별하고 6.1 표에 따라 견고히 우월한 강한 method를 자동으로 고른다. 군집화 계열 세 method는 어느 Type에서도 권장하지 않는다.
- 결합(CaseB)을 기본값으로** — method 추정값을 논문 방식 통째 대체에 쓰지 말고 산술 평균으로 결합한다($est_final = (est_b1 + est_method) / 2.0$). 음성 대조군 CaseA가 35.2%에 그친 반면 CaseB는 89.1%에서 우월하므로 method 단독은 위험하고 평균 결합이 안정적 개선을 만든다.
- 정확도와 분포 파악 속도 함께 저울질** — chao_weighted가 1순위(중앙값 -6.22%·fit 11.03초). 데이터셋이 자주 바뀌어 오프라인 비용이 결정적 제약일 때만 sparse_rp(fit 2.91초·중앙값 -4.37%)를 택한다.

6.3 결론

본 연구는 카디널리티 추정 파이프라인에서 표본을 어떻게 뽑느냐 하는 단계 하나를 무작위 베르누이 표본 추출에서 데이터 분포 인지 총화로 바꾸었을 때 추정 오차가 어떻게 달라지는지를 검증하였다. 다섯 종의 단일 벡터 데이터셋과 직접 만든 다중 벡터 데이터셋, selectivity·표본 선택 method·데이터 구조·규모·계층 수 K의 다섯 조작 변인 전반에 걸쳐 표본 선택이라는 단일 개입의 효과를 빠짐없이 측정하였다.

측정의 결론은 분명하다. 결합(CaseB)은 대조군 B1 대비 1,508건 중 1,344건(89.1%)에서 Q-error가 개선되었으며 개선 폭의 중앙값은 -4.38%였다. 반면 음성 대조군 완전 대체(CaseA)는 35.2%·평균 +12.90%로 효과가 불안정했다 — 추정 정확도 향상의 원천은 분포 인지 method로의 단순 교체가 아니라 논문 방식과 분포 인지 방식을 함께 쓰는 결합에 있다. 표본 선택 method를 통째로 갈아 끼우면 효과가 들쭉날쭉하지만 두 추정값을 평균하는 결합은 일관된 개선을 만들어 낸다는 사실을, 본 연구는 음성 대조군을 통해 거꾸로 입증하였다. 위의 개선은 표본을 더 많이 쓰는 대가로 얻은 것이 아니다 — 논문 식 10이 정한 표본 예산 N=385는 대조군·실험군 모두에서 한 톨도 늘어나지 않았으며 본 연구가 바꾼 것은 오직 같은 예산 안에서 표본을 어느 계층에서 뽑을 것인가 하는 한 가지뿐이다.

6.4 향후 작업

- 엔진 적용 검증 측정 평면 확장** — Ch.5는 DEEP·sf=10·sel=0.001의 12 cell(core 4 × qid 3)에 한정. carry-over 측정으로 sel=0.01의 4 cell은 plan 변경·2~3× 가속·짜지는 검정 모두 유의, sel=0.1의 Q3·Q10·Q12 3 cell은 plan 동일·latency 차이 무의함이 확인되었다.

Q9 × sel=0.1 한 cell은 plan이 baseline과 다르되 oracle/baseline 비율 0.93× 감소의 단일 예외(honest exception, sub-optimal plan 유도)가 관측되어 qid·query 전수 확장이 후속 과제다. SIFT·SSN·다중 벡터·sf=1·sf=100 확장 동반.

- **통계 검증 확장 (실측 PoC 완료)** — §5.4 표 5-3에 더해 plan-level effect size 분층(표 5-4)·cluster paired bootstrap(§5.4 두 번째 검정 paragraph 끝)·variance decomposition(§5.5 마지막 bullet)의 세 통계 절차를 phase2 sel=0.001 + phase3 sel=0.01·0.1 carry-over = 20 cell·580 paired 평면에서 실측하여 §5.4 결론과 합치함을 정량 확정. 분산 분해 모델 3에서 baseline 제외 시 condition % SS가 0.00%(p=0.866)로 수렴해 latency 동등성이 sel main effect 70.8% 뒤로 사라지는 분포가 드러난다. 남은 후속은 PoC를 sf=1·sf=100·다중 벡터·SIFT·SSN 데이터셋과 4 엔진(pgvector·VBASE·DuckDB·Exqutor 통합)으로 확장.
- **4 엔진 통합 PoC** (박광현 교수님 제안) — pgvector·VBASE·DuckDB·vector.c 기반 PostgreSQL 네 엔진을 통합 측정 틀로 묶어 분포 인지 증화 개입의 엔진 횡단 일반화 검증.
- **측정 공간 확장** — multi-modal 벡터 조합 다양성·실제 작업 부하(real workload) 환경에서의 효과 검증.

7. 진행 및 역할 분담

7.1 진행 일정

본 연구는 2026년 3월 초~6월 중순 한 학기 동안 수행되었다. 3월에 Exqutor 논문(arXiv:2512.09695v2) §V-A·§V-B 분석·서버 권한 인계·빌드·측정 환경을 구축하고 핵심 방향(베르누이→분포 인지 증화의 단일 개입 검증)을 확정하였다. 4월 28일 중간보고서·중간발표 후 5월 초~중순에 §V-B verbatim 재현 측정으로 방법론 토대를 다지고 3-way matched 측정 캠페인으로 B1·CaseA·CaseB 각 1,508건 = 총 4,524행을 확보하였다. 5월 말~6월 중순에 산출물 작성·제출 — 5/27·5/29 양일 최종 발표, 5/28 12:00 전시 포스터 제출, 6/5 전시회, 6/11 최종 보고서 제출.

7.2 역할 분담

본 연구는 박세은(팀장)·강재현·조현빈·이동욱 4인으로 구성된 팀 "속도는벡터"가 박광현 교수님(BDAI 연구실) 지도·임채림 석사 지원·삼성전자 AI센터 박성원 멘토 자문 아래 수행하였다. 측정 portfolio 구성·1,508건 3-way 측정·분석·산출물 제작은 공동 진행하였다. 보고서 집필은 다음과 같이 분담하였다.

팀원	담당 장	담당 내용
박세은 (팀장)	Ch.1 · Ch.6 · Ch.7 + 전체 통합	연구 주제·목표·개요, 제안 모델·결론·향후 작업, 진행·역할, 전체 통합·검토
이동욱	Ch.2	연구의 필요성 — 기존 시스템, Exqutor §V-B, 연구의 필요성
강재현	Ch.3	연구 내용·방법 — framing, 세 단계 흐름, 측정 mode, 데이터셋 분류, 측정 설계
조현빈	Ch.4 · Ch.5	분석·실험 결과 — 1,508건 3-way 오프라인 측정, 엔진 적용 검증
공동	Ch.9	참고문헌

표 7-1. 최종 보고서 장별 집필 분담.

8. 감사의 글 (Acknowledgment)

본 연구는 연세대학교 컴퓨터과학과 BDAI 연구실 박광현 교수님의 지도와 임채림 석사의 직접 멘토링 아래 수행되었다. 박광현 교수님께서 본 연구의 framing — 표본 선택 단계 하나의 개입을 전 변인에 걸쳐 검증하는 controlled verification experiment — 의 방향 설정에서부터 측정 portfolio의 구조, paired matched 측정의 통계적 정합성, 4 엔진 통합 PoC라는 후속 연구 방향에 이르기까지 일관된 지도를 해 주셨다. 임채림 석사께서는 Exqutor §V-B 식 1-6 verbatim 해석, 서버 환경 구축과 패치된 PostgreSQL 운용, 1,508건 3-way matched 측정과 2,880회 end-to-end latency 측정 전반의 운용에서 직접적인 도움을 주셨다. 본 연구의 산업 자문 멘토 박성원 멘토(삼성전자 AI센터)께서는 세 차례 자문 메일을 통해 측정 결과의 산업적 함의와 4 엔진(pgvector·VBASE·DuckDB·Exqutor) 통합 검증의 실무적 의미에 대해 귀중한 조언을 주셨다. 본 보고서의 모든 결과는 위 세 분의 지도와 자문 위에서 작성되었으며, 발견되는 모든 오류는 본 연구진의 책임이다.

9. 참고문헌

- [1] BDAI Research. *Exqutor: Extended Query Optimizer for Vector-augmented Analytical Queries*. arXiv:2512.09695v2, 2025. <https://arxiv.org/abs/2512.09695>
- [2] Cochran, W. G. *Sampling Techniques*, 3rd ed. New York: John Wiley & Sons, 1977. — 층화 표본 추출(Stratified Random Sampling, Chapter 5)의 고전 이론. 본 연구의 분포 인지 층화·균등 배분 방식은 특히 §5.5 Optimum Allocation 의 이론적 토대 위에 있다 (네이만 배분이 계층별 분산 균일 시 비례 배분으로 환원되는 결과 — RQ2 의 Neyman paradox 와 직접 연결).
- [3] Malkov, Y. A., and Yashunin, D. A. "Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs." *IEEE TPAMI*, vol. 42, no. 4, pp. 824-836, 2020.
- [4] PostgreSQL Global Development Group. *PostgreSQL Documentation*. <https://www.postgresql.org/docs/>
- [5] pgvector — Open-source vector similarity search for PostgreSQL. <https://github.com/pgvector/pgvector>
- [6] DuckDB — An in-process SQL OLAP database management system. <https://duckdb.org/>
- [7] VBASE — Unifying Online Vector Similarity Search and Relational Queries via Relaxed Monotonicity. <https://github.com/microsoft/MSVBASE>
- [8] Johnson, J., Douze, M., and Jégou, H. "Billion-Scale Similarity Search with GPUs." *IEEE Transactions on Big Data*, vol. 7, no. 3, pp. 535-547, 2021. — FAISS 라이브러리.
- [9] FAISS — A library for efficient similarity search and clustering of dense vectors. <https://github.com/facebookresearch/faiss>
- [10] Lewis, P., et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks." *NeurIPS*, 2020.
- [11] DEEP1B — Deep Billion-Scale Indexing benchmark dataset. <http://sites.skoltech.ru/compvision/noimi/>
- [12] SIFT — ANN_SIFT1B / Datasets for approximate nearest neighbor search. <http://corpus-texmex.irisa.fr/>
- [13] pg_hint_plan — Extension to control PostgreSQL execution plans with hints. https://github.com/osscc-db/pg_hint_plan
- [14] Li, P., Hastie, T. J., and Church, K. W. "Very Sparse Random Projections." *Proceedings of the 12th ACM SIGKDD (KDD '06)*, pp. 287-296, 2006. — `sparse_rp` method의 $1/\sqrt{D}$ 희소 무작위 투영 변형의 정보 출처. §4.7 method 명칭 정직성 참조.