

RQ3 측정 결과 — 팀원 공유용 (7-way 전체 완료)

작성: 조현빈 · 2026-05-06 21:55 KST · 5/8 비대면 회의 자료 **TL;DR:** RQ3 7가지 후보 모두 측정 완료 (총 ~12분, sample_size 작은 환경 + PG buffer warm cache 효과). **3개 contribution 발견:** (1) **Hilbert Curve** (학습 0 + 결정론) 가 MiniBatch (1% 학습) 와 동등 → 본 연구 핵심 contribution 격상. (2) **MiniBatch K-means** = production-ready 솔루션. (3) **Cluster 분할의 결정적 가치** — Distance-Shell (cluster 정보 X) +14%, IS (분할 X) 최대 +866% 까지 RANDOM20 보다 나쁨.

1. RQ3 가 묻는 질문

"분포를 모르는 환경에서 어떤 stratification 알고리즘이 RANDOM 보다 나은 sampling 효과를 내는가?"

기존 KM20 oracle 은 사전에 K-means 학습이 필요해 production 환경에서 매번 학습이 부담. RQ3 는 7가지 후보를 비교해 (a) **production-ready 솔루션** 과 (b) **학습 없는 결정론 솔루션** 을 찾는 것이 목표.

2. 평가 기준 (5/5 회의 §RQ3)

이론 metric:

```
recovery_rate = (방법X - RANDOM20) / (KM20 - RANDOM20)
1.0 → KM20 oracle 수준 회수
0.0 → RANDOM20 (분포 인식 X) 수준
음수 → RANDOM20 보다 나쁨
```

그러나 측정 결과 KM20 vs RANDOM20 격차가 0.26~3.98% 로 너무 작음 (분모 붕괴) → 사전 등록된 fall-back 적용:

method_minus_random_pct = (방법 q_error - RANDOM20 q_error) / RANDOM20 × 100 (%) 를 primary metric 으로 사용. 음수일수록 좋음 (방법이 RANDOM20 보다 q_error 낮음).

3. 측정 환경

- 데이터셋: DEEP (1M, 96d, normal 분포) + SIFT (1.5M, 128d, skew 분포)
- selectivity: 5종 (0.01, 0.05, 0.10, 0.30, 0.50)
- seed: 5종, query: 100개/seed, sample_size: 385
- 측정 시간: offline 4종 ~10분 + online 3종 ~2분 = 총 12분 (sample_size 작은 환경)

4. 결과 한눈에 — 7-way Primary Metric 표

`method_minus_random_pct` (음수 = 좋음, RANDOM20 보다 q_error 낮음):

4-1. DEEP

sel	MiniBatch (#8)	Hilbert (#7)	KDE-pilot (#10)	LSH (#6)	RandProj (#5)	Distance-Shell (#9)
0.01	-4.22	-3.70	-0.62	+16.18 ✖	+18.46 ✖	+1.45 ✖
0.05	-0.99	-1.99	-0.02	+5.03 ✖	+6.56 ✖	+11.87 ✖
0.10	-1.19	-0.63	+0.53	+3.28 ✖	+3.30 ✖	+15.05 ✖✖
0.30	-0.89	-0.47	+0.07	+1.04	+1.19	+14.29 ✖✖
0.50	-0.41	-0.41	-0.30	+0.63	+0.99	+8.02 ✖

4-2. SIFT

sel	MiniBatch (#8)	Hilbert (#7)	KDE-pilot (#10)	LSH (#6)	RandProj (#5)	Distance-Shell (#9)
0.01	-3.67	-4.12	+4.07 ✖	+23.81 ✖	+45.14 ✖✖	+2.52 ✖
0.05	-2.73	-4.04 ★	-3.28 ★	+4.22 ✖	+7.81 ✖	+13.81 ✖✖
0.10	-2.42	-3.35 ★	-0.27	+3.03 ✖	+4.90 ✖	+16.68 ✖✖
0.30	-2.07	-1.85	-0.67	+1.12	+2.22	+15.58 ✖✖
0.50	-1.42	-1.41	-0.97	+0.58	+1.20	+9.16 ✖

4-3. Importance Sampling (#11) — 4 mode factorial (모두 매우 나쁨)

dataset	sel	best mode	best %	비고
DEEP	0.01	is_p50_clip	-17.16	유일한 negative cell
DEEP	0.05	is_p200_noclip	+64.85	다른 모든 cell +5~+1000%
DEEP	0.10	is_p50_noclip	+55.93	
DEEP	0.30	is_p50_noclip	+13.22	
DEEP	0.50	is_p50_noclip	+6.41	
SIFT	0.01	is_p50_clip	-11.20	유일한 negative cell
SIFT	0.05	is_p200_noclip	+53.75	
SIFT	0.10	is_p50_noclip	+51.57	
SIFT	0.30	is_p50_noclip	+12.40	
SIFT	0.50	is_p50_clip	+6.70	

★ = Hilbert 가 MiniBatch 보다 우수한 cell. ✖ = RANDOM20 보다 나쁨. ✖✖ = 매우 나쁨 (>+10%).

4-4. 통계 유의성 (paired Wilcoxon vs RANDOM20 + BH-FDR)

10개 cell 중 통계적 유의 ($p_{BH} \leq 0.05$) 개수:

method	DEEP	SIFT	합계
MiniBatch	3/5	5/5	8/10
Hilbert	2/5	4/5	6/10
KDE-pilot	0/5	1/5	1/10
LSH	0/5	0/5	0/10
Random Projection	0/5	0/5	0/10
Distance-Shell	0/5	0/5	0/10
IS (best mode)	0/5	0/5	0/10

5. 7가지 가설 → 결과 비교

#	method	가설 H3-X	예상 recovery	실제 결과	판정
#8	MiniBatch	75% 이상	75-95%	모든 cell 에서 RANDOM20 우수, 통계 유의 8/10	Confirm 강
#7	Hilbert	20-60%	20-60%	MiniBatch 와 동등 또는 SIFT 에서 우수	예상 훨씬 초과 ★
#10	KDE-pilot	50-80%	50-80%	SIFT mid-sel 만 효과 (-3.28%), DEEP/좁은 sel 약함	부분 Confirm
#5	RandProj	10-40%	10-40%	RANDOM20 보다 매우 나쁨 (좁은 sel SIFT +45%)	Refute 역방향
#6	LSH	30-60%, RandProj 우수	30-60%	RANDOM20 보다 나쁨, RandProj 와 동급	Refute
#9	Distance-Shell	25-50%	25-50%	매우 나쁨 (+8~+17%), cluster 정보 X 의 분할 한계	Refute 매우 강 역방향
#11	IS	30-70%	30-70%	massive worse (+5~+866%), 분할 X 의 한계	Refute 매우 강 역방향

6. 핵심 발견 — 3 contributions

6-1. Hilbert Curve — 본 연구 핵심 contribution 1순위 ★

학습 0 + 결정론적 알고리즘이 1% 학습 솔루션과 동등한 성능. SIFT 에서 더 강함.

Mechanism 분석 (서버 측 학습 단계 log 추출): - **PCA 2D explained variance**: SIFT 22% > DEEP 12% — SIFT 의 cluster 구조가 2D 로 더 잘 압축 - **Bucket 분포**: max/min ratio 1.16~1.18 (매우 균질, quantile 분할 효과) - **vs MiniBatch**: max/min ratio 2.45~4.77 (자연 cluster, 비균질) - → 좁은 sel 에서 균질 분할이 sample efficiency 의 가치 발휘 (RQ2 의 Anti-Neyman 효과와 유사)

5/27 발표의 핵심 differentiator: "learning-free stratification 도 oracle 수준 가능".

6-2. MiniBatch K-means — Production-ready 솔루션 ★

- 1% 학습 (10K row, ~수초) 으로 KM20 oracle 효과 회수
- DEEP 에선 -0.4~-4.2%, SIFT 에선 -1.4~-3.7%, 통계 유의 8/10
- RQ재정립 plan 의 Limitation 1 (KM20 = oracle, production X) 해소

6-3. Cluster 분할의 결정적 가치 — 부정적 control 3종 ★

본 연구의 negative control 로서 가장 강한 결과:

- **LSH/Random Projection** (+0.6~+45%): 단순 hash/projection 만으로는 cluster 정보 회수 불가
- **Distance-Shell** (+1.4~+17%): cluster 분할 (KM) 대신 distance shell 만으로는 매우 나쁨 — **cluster 의 spatial 정보가 결정적**
- **Importance Sampling** (+5~+866%): cluster/shell 분할 X, weight 만으로는 한계 — **분할 자체가 핵심 mechanism**

→ "stratification 의 가치는 cluster-aware 분할에서 온다" 의 정량 증명.

6-4. 분모 붕괴 caveat

- KM20 oracle 과 RANDOM20 의 q_error 격차 0.26~3.98% — recovery_rate 분모가 약함
- → **primary metric 을 method_minus_random_pct 로 변경** (사전 등록된 fall-back 활성화)
- 향후 sample_size 더 작은 환경 (예: 100, 50) 에서 격차 회복 검증 필요 (sensitivity)

7. 5/8 회의 핵심 메시지

RQ3 7-way 측정 (offline 4 + online 2 + 비분할 1) 완료. 3개 contribution 발견.

Best 2 — confirm 강 / 격상: - MiniBatch K-means (#8): H3-F confirm — 1% 학습으로 KM oracle 수준, 통계 유의 8/10. - Hilbert Curve (#7): H3-E refute 강 in 좋은 방향 — MiniBatch 와 동등, SIFT 에서 우수. 학습 0 + 결정론으로 oracle 수준 회수. 본 연구 contribution 1순위 격상.

Negative controls — cluster 분할의 가치 정량 증명: - Distance-Shell (#9): cluster 정보 X 의 shell 분할 → +14% (매우 나쁨) - Importance Sampling (#11): 분할 X 의 weight 만 → 최대 +866% (massive 나쁨) - LSH/RandProj (#5/#6): 단순 hash/projection → +5~+45% (나쁨)

Online 보조 결과: - KDE-pilot (#10): SIFT mid-sel 에서만 효과 (-3.28%) — pilot noise 한계.

Caveat: KM20 vs RANDOM20 격차 0.3~4% → recovery rate 분모 붕괴. method_minus_random_pct 를 primary metric.

8. 다음 단계

8-1. 자문 요청 초안 (5/15까지)

채림 석사 자문 (정량 검증 + mechanism): - "Hilbert Curve 가 MiniBatch (1% 학습) 와 동등한 결과 — 정상인가? PCA 2D explained variance 12% (DEEP) / 22% (SIFT) 만으로 high-d cluster 구조 회수 가능한 메커니즘이 무엇인지?" - "Distance-Shell 이 RANDOM20 보다 +14% 나쁨 — cluster 정보가 sigma 추정의 핵심인가, 분할 단위 자체가 중요한가?"

지도교수 자문 (학술 가치 + narrative): - contribution 1순위 narrative ("learning-free stratification 도 oracle 수준") 의 학술적 가치 평가 - 5/27 발표 핵심 발견으로 격상 가능 여부 - IS 의 massive failure (+866%) 가 본 연구의 분할 가치 증명에 충분한가

8-2. 추가 sensitivity 분석 (5/22 미팅 전)

- sample_size 100, 200, 1000 에서 KM20 vs RANDOM20 격차 회복 여부 (분모 붕괴 caveat 보완)
- Hilbert 의 p (grid resolution), n_strata 변경 시 robustness

8-3. 5/27 발표 자료 (5/26 마감)

- Slide 핵심 1: Hilbert Curve learning-free contribution

- Slide 핵심 2: MiniBatch production solution
 - Slide 핵심 3: Distance-Shell/IS 의 negative control → cluster 분할의 가치
-

9. 산출 파일 (git: `5cfb92c` + 후속 commit)

- `experiments/code/rq3/run_*.py` — 5종 측정 wrapper
 - `experiments/code/rq3/{kde,online_weight}/*.py` — 2차 3종 wrapper (병렬 세션 산출)
 - `experiments/code/local_analysis/rq3_recovery_analysis.py` — 7-way 분석 driver
 - `experiments/results/rq3_agnostic/` — parquet ×9, csv ×3, RQ3_1차_결과정리.md (상세)
 - `submission/_drafts/속도는벡터_RQ3_1차결과정리_20260506.md` — 본 문서 (팀원 공유용)
-

작성자: 조현빈 **상태:** RQ3 7-way 측정 완료. 5/8 회의 자료 ready. **다음 동기화:** 5/8 19:00 비대면 회의