

속도는벡터 — 본 연구 narrative 최종 정리 v1

박세은 review + 박광현 5/15 미팅 + 5/27 최종 발표 + 6/11 최종 보고서 공통 base. 박세은 5/13 12:13 피드백 (method 개수 줄임 + 숫자/공식 최소화) 반영. 학부생 톤, 산문 흐름.

작성: 2026-05-14 07:55 KST · 측정 portfolio 1065 file 종료 후 시나리오 B 확정 narrative

1. 출발점: 어디서 부정확해지는가

본 논문 (Exqutor) 은 벡터 증강 분석 쿼리에서 인덱스가 없을 때 무작위 표집 (베르누이 + 동적 표본 수 조정) 으로 카디널리티를 추정한다. 단일 테이블 + 단순 분포에서는 잘 작동하지만, 분포가 한쪽으로 쏠려 있을 때 (skew) 표집의 정밀도가 떨어진다. 우리는 이 영역에서 "분포 정보를 알 수 있다면 어디까지 정확도를 끌어올릴 수 있나" 를 정량으로 확인했다.

2. 탐색: 분포 정보를 얻는 방법 56 가지

분포 정보를 얻을 수 있는 후보 method 56 개를 8 갈래 (클러스터링, 공간 분할, 스트리밍, 차원 축소, 정보 이론, 양자화, 준 무작위, 밀도 추정) 로 모았다. 9 가지 측정 환경 (DEEP/SIFT/SSN 단일 테이블 + 다중 테이블 Fig7/Fig9 + 선택도 sweep + scale sweep) × 2 가지 모드로 매트릭스를 짰다.

3. 폐기: 정직하게 떨어뜨린 39 method

측정을 진행하면서 39 method 를 폐기했다. 자원 한계 7 종 (예: birch 가 한 측정에 50 ~ 200GB 메모리를 차지 해서 실행 불가), 5월 10일 코드 정독 검토로 reference 위반이 발견된 23 종 (예: vinecopula 가 vine copula 가 아니라 PCA 1 차원 정렬의 별칭, neuram 이 PCA1D 와 한 줄씩 동일), 그리고 큰 데이터셋에서 추정값이 외곽으로 튀는 정합성 위반 9 종. 폐기 사유 자체를 보고서에 분류한 것이 본 연구의 정직성 갈래다.

4. 단독 대체: 베르누이를 분포 인지 추정량으로 갈아끼우기

남은 method 들로 첫 번째 모드를 측정했다. 본 논문의 베르누이 추정값을 우리 method 의 추정값으로 단순히 바꿔 끼우는 방식이다. 측정 결과 56 method 중 약 40% 가 평균적으로 베르누이보다 정확했고, 통계 검정으로 9 가지 측정 환경 전반에서 안정적으로 우위를 점한 method 가 15 개였다. 이 15 method 의 평균 개선폭은 -5 ~ -12% 였고, 단독 best 는 minibatch_partial 의 **-10.17%** 였다. 본 논문 자체 재현 시 발생하는 측정 변동 -4.3% 의 2.4 배 수준이다.

5. 결합 시도: 산술 평균으로 둘을 섞으면 어떨까

두 번째 모드는 베르누이 추정값과 우리 method 의 추정값을 산술 평균으로 결합하는 방식이다. 492 짝지어 비교한 측정 중 92.5% 가 베르누이보다 정확했다. 짝지어 보면 거의 항상 좋아진다는 의미다. 결합 best 는 Centroid tuple 의 **-7.37%** 였다.

평균을 어느 비율로 섞어야 best 인지도 sweep 으로 확인했다. 0.3 / 0.4 / 0.6 / 0.7 네 값을 측정한 결과, 네 method 중 셋이 0.5 (산술 평균) 에서 best 였고, 양쪽 극단으로 갈수록 효과가 감소하는 U 자 형태를 보였다.

6. 결합의 한계: 단독 best 를 넘지 못한다

결합 best (-7.37%) 가 단독 best (-10.17%) 보다 약했다. 결합으로 단독을 능가할 수는 없었다. 이 발견이 본 연구의 narrative 분기점이다.

7. 결합의 진짜 가치 재발견

그렇다면 결합은 의미가 없는가? 그렇지 않다. 결합 모드의 92.5% 짝지어 우위는 "method 선택을 잘못해도 거의 항상 베르누이보다는 낫다" 는 안정성을 뜻한다. 9 가지 측정 환경별 변동성도 단독 대체보다 결합 모드가 더 작았다. 즉 결합의 가치는 "더 큰 정확도" 가 아니라 "method 선택의 안정성 + 측정 환경별 변동성 감소" 다.

8. 자원 효율: 정확도 + 자원이 동시에 좋은 method 가 있다

추가로 학습 자원 (시간 + 메모리) 도 비교했다. 정확도 측면에서 안정적인 12 가지 measurement 에서 우위를 점한 5 method 와, 자원 효율 측면에서 파레토 우위인 5 method 가 동일하다는 점을 발견했다 — sparse_rp, chao_weighted, neuram, pca1d, hilbert. 정확도와 자원이 같은 방향을 가리킨다.

특히 reservoir 표집은 메모리 사용이 데이터 크기와 무관한 상수 $O(1)$ 인데도 anchor 수준 정확도를 낸다. 모바일 / 임베디드 / 스트리밍처럼 메모리가 제약인 환경에 그대로 갖다 쓸 수 있는 finding 이다.

9. 권장: 단독 대체 우선 + 결합 보조

위 결과를 종합한 권장 설계는 다음과 같다.

1. **단독 대체 우선** — 산업 환경에 맞는 method 를 위 5 ~ 6 후보 중에서 골라 베르누이를 갈아끼운다. 가장 단순 하면서 가장 큰 정확도 개선을 얻는다.
2. **결합 보조** — method 선택에 자신이 없거나 안정성이 중요한 환경에서 산술 평균 결합을 추가 안전망으로 둔다.
3. **자원 우선 환경** — 메모리가 가장 제약이라면 reservoir 같은 상수 메모리 method 를 단독으로 쓴다.

10. 다중 테이블 결합

마지막으로 다중 테이블 환경에서 두 테이블 클러스터링을 어떻게 합칠지 검토했다. 비싼 방식 (두 테이블 벡터를 합쳐 처음부터 다시 학습) 과 저렴한 방식 (이미 학습된 두 클러스터링의 결과를 가볍게 합치는 Centroid tuple) 두 후보 중 Centroid tuple 이 학습 비용 추가 0 으로 안정 우위를 보였다. 다중 테이블 환경에도 단독 대체 + 결합 보조 원칙이 그대로 적용 가능하다.

한 줄 요약

"분포 정보를 알면 베르누이를 갈아끼우는 단독 대체가 가장 단순하고 가장 큰 정확도 개선을 가져온다. 결합은 더 큰 정확도가 아니라 method 선택의 안정성을 위한 보조 안전망이다. 정확도와 자원 효율이 같은 method 군을 가리키며, 그중 reservoir 의 상수 메모리는 산업 적용에 의미가 크다."

narrative 흐름 한 줄 도식

- [1. 문제: skew 영역 베르누이 부정확]
↓
- [2. 탐색: 56 method × 8 갈래 × 9 측정 환경]
↓
- [3. 폐기: 39 method 정직 분류 (자원 7 + audit 23 + 정합성 9)]
↓
- [4. 단독 대체: 베르누이 갈아끼우기 → best -10.17%]
↓
- [5. 결합 시도: 산술 평균 → best -7.37%, $\alpha=0.5$ best, U-shape]
↓
- [6. 결합 한계 발견: 결합 < 단독]
↓
- [7. 결합 진짜 가치: 안정성 + 변동성 감소]
↓
- [8. 자원 효율: 정확도 best 5 = 파레토 best 5, reservoir 0(1) 산업 적용]
↓
- [9. 권장 설계: 단독 대체 우선 + 결합 보조 + 자원 우선]
↓
- [10. 다중 테이블: Centroid tuple 로 원칙 그대로 적용]

측정 portfolio 종합 (배경, 필요 시 참조)

- 총 측정 1065 file (paper exact carry-over 1001 + 본 세션 64: multi-join 8 + Centroid tuple 8 + B1/B2/B3 cheap 24 + A2-Fig8 mv 8 + α sweep 16)
- 폐기 39 method (자원 한계 7 + audit drop 23 + 정합성 위반 9)
- 사용 method 약 17 개 (56 - 39)
- 8 갈래 paradigm rollup: P10 Density / P9 InfoTheoretic / P3 Streaming / P4 DimReduction / P2 Spatial 우위 (CaseB 기준 -5 ~ -12%)
- 본 논문 §V-B Fig 12 영역 절사 평균 Q-error 본 측정 1.618 vs paper 보고값 1.69 = -4.3% 재현 (paper review-grade 정합성 확보)
- 자원 한계 폐기 method 중 kde_parzen 은 5/13 ~ 5/14 측정 chain 진행했으나 5/5 timeout 으로 5/14 07:39 폐기 결정

11. 사용 method 깊이 소개 (핵심 6)

§4 ~ §9 에 등장한 결과를 만든 method 들 중 본 narrative 의 핵심 6 개를 알고리즘 메커니즘 + 이론적 근거 + 실측 결과로 정리한다. 17 사용 method 전체 list 는 §12 부록 table + 자원 효율 분석 file ([_internal/analysis/resource_efficiency_pareto_20260513.md](#)) 참조.

11.1 minibatch_partial — 클러스터링 갈래, 단독 대체 best

방법 — 데이터를 청크 단위로 흘려보내면서 K=20 클러스터 중심을 점진적으로 학습한다 (partial_fit). 전체 데이터를 메모리에 올리지 않고 stream 처럼 처리.

이론적 근거 — Sculley (WWW 2010) 의 Web-scale K-means 변형. scikit-learn 의 MiniBatchKMeans 의 partial_fit API 직접 활용.

실측 결과 — 단독 대체 모드 9 측정 환경 평균 **-10.17%** (본 portfolio 단독 best). 학습 시간 0.5 초, 메모리 사용량 작음 (청크 × 차원 D), 측정 환경별 변동성 std 3.33. 단독 대체로 갈아끼울 때 가장 큰 정확도 개선을 가져오는 method.

11.2 sparse_rp — 차원 축소 갈래, 학습 시간 가장 짧음

방법 — 데이터 차원 D 를 sparse random matrix (Achlioptas density 1/3, 즉 +1 / 0 / -1 의 sparse entries) 로 곱해 낮은 차원 k 로 사영한다. 그 후 K=20 클러스터로 stratum 분할.

이론적 근거 — Achlioptas (JCSS 2003) 의 sparse Bernoulli projection + Li-Hastie-Church (KDD 2006) 의 매우 sparse 변형. Johnson-Lindenstrauss lemma 의 distance preservation 보장 위에서 sparse 화로 계산 비용을 크게 낮춤.

실측 결과 — 결합 모드 9 측정 환경 평균 **-9.43%**, 학습 시간 **0.1 초** (본 portfolio 최단), 메모리 $O(D \times k)$ 매우 작음, std 3.30. 정확도와 자원 두 axis 에서 모두 Pareto frontier 위에 있는 method.

11.3 chao_weighted — 스트리밍 갈래, Pareto Top 정확도

방법 — 가중 reservoir 표집. 청크 단위로 들어오는 데이터에서 weight 기반 sampling 으로 분포 정보를 streaming 으로 유지한다.

이론적 근거 — Chao M-T (Biometrika 1982) 의 weighted reservoir sampling. 각 sample 의 probability of inclusion 이 weight 에 비례하도록 보장.

실측 결과 — 결합 모드 9 측정 환경 평균 **-9.60%** (Pareto frontier 정확도 Top 1), 학습 시간 0.5 초, 메모리 $O(K)$ 매우 작음, std 6.36. 정확도는 가장 좋으나 측정 환경별 변동성은 다소 큼.

11.4 hilbert_real — 공간 분할 갈래, 진짜 Hilbert curve 구현

방법 — 데이터 차원 D 를 그대로 유지한 채 Hilbert space-filling curve indexer 로 1 차원 좌표 매핑. 그 후 매핑 된 1 차원 좌표를 $K=20$ stratum 으로 분할.

이론적 근거 — Faloutsos (SIGMOD 1989) 의 진짜 D 차원 Hilbert space-filling curve. 본 연구의 이전 hilbert method 는 코드 정독 검토 결과 PCA 2 차원 정렬의 별칭으로 발견되어 (★3 정정), 진짜 Hilbert curve 구현인 hilbert_real 을 별도 method 로 측정.

실측 결과 — 결합 모드 9 측정 환경 평균 **-9.27%**, 학습 시간 0.5 초, 메모리 $O(N)$, std 3.12. 공간 분할 paradigm 의 진짜 anchor.

11.5 hyperloglog — 정보 이론 갈래, 가장 안정

방법 — hash 기반 분포 카디널리티 추정량. $K=20$ stratum 별로 trailing zero 의 max 를 추적해 cardinality 를 streaming 으로 추정.

이론적 근거 — Flajolet et al (DMTCS 2007) 의 HyperLogLog. 분포의 unique element 수를 매우 적은 메모리 로 정확히 추정하는 정보 이론 기반 알고리즘.

실측 결과 — 결합 모드 9 측정 환경 평균 **-8.65%**, 학습 시간 0.5 초, 메모리 $O(K \log K)$, std **2.73** (본 portfolio ★★ Best + ★ Excellent 19 method 中 가장 안정). 정확도와 안정성을 모두 잡은 method.

11.6 reservoir — 스트리밍 갈래, 메모리 $O(1)$

방법 — 가장 단순한 reservoir sampling. 청크 단위 데이터에서 K 개를 균등 확률로 sampling 한다.

이론적 근거 — Vitter (TOMS 1985) 의 reservoir sampling. 데이터 크기 N 을 미리 모르더라도 K 개의 균등 random sample 을 한 번의 pass 로 얻는 알고리즘.

실측 결과 — 결합 모드 9 측정 환경 평균 **-9.25%**, 학습 시간 **0.1 초**, 메모리 사용량 **$O(1)$** (sample size K 만 보존, 데이터 크기 N 과 무관), std 3.00. §8 의 산업 적용 핵심 finding — 모바일 / 임베디드 / 스트리밍처럼 메모리가 제약인 환경에 그대로 적용 가능한 가장 강력한 method.

12. 17 사용 method 전체 list (부록)

39 폐기 후 남은 17 사용 method 의 paradigm 분포 + 결합 모드 평균 + 자원 효율 등급 + 이론적 근거. 자세한 자원 정량 (학습 시간 + 메모리 + SF=100 feasibility) 은

[_internal/analysis/resource_efficiency_pareto_20260513.md](#) 참조.

paradigm	method	CaseB Δ%	자원 등급	이론적 근거
P1 클러스터링	minibatch_partial	-6.98%	★ Excellent	Sculley 2010 (partial fit)
P1 클러스터링	minibatch	-9.28%	★ Excellent	Sculley 2010
P1 클러스터링	gmm	+2.45%	Good	Dempster 1977 EM (marginal)
P2 공간 분할	hilbert_real	-9.27%	★★ Best	Faloutsos 1989 진짜
P2 공간 분할	zorder_morton	-9.26%	★ Excellent	Morton 1966 bit-interleaving
P2 공간 분할	skilling_hilbert	-9.01%	★ Excellent	Skilling 2004 변형
P2 공간 분할	lpm2	-9.45%	★★ Best	Grafström 2012 local pivot
P3 스트리밍	chao_weighted	-9.60%	★★ Best	Chao 1982 weighted reservoir
P3 스트리밍	reservoir	-9.25%	★★ Best	Vitter 1985, 메모리 O(1)
P3 스트리밍	thompson_sampling	-8.98%	★ Excellent	Thompson 1933 Beta posterior
P3 스트리밍	cum_sqrtf	-8.45%	Good	Cochran 1977 sqrt(F)
P4 차원 축소	sparse_rp	-9.43%	★★ Best	Li-Hastie-Church 2006
P4 차원 축소	neuram	-9.97%	★★ Best	autoencoder (PCA1D 등가 audit)
P4 차원 축소	pca1d	-9.63%	★ Excellent	Pearson 1901 PCA
P4 차원 축소	rsvd	-8.49%	★ Excellent	Halko-Martinsson 2011
P6 양자화	pq	-9.25%	★ Excellent	Jégou 2011 product quantization
P9 정보 이론	hyperloglog	-8.65%	★★ Best	Flajolet 2007 HyperLogLog

- CaseB Δ% = 결합 모드 9 측정 환경 평균 (음수가 클수록 정확도 개선). 학습 시간 모두 0.1 ~ 1 초 범위.
- 자원 효율 등급: ★★ Best (fit < 1s + 메모리 O(N) 이하 + SF=100 OK + Δ% < -9%) / ★ Excellent (fit < 2s + Δ% < -8%) / Good (fit < 2s + Δ% -5 ~ -8%) / Marginal (Δ% -3 ~ -5%).
- P5 준 무작위 / P10 밀도 추정 paradigm 은 모두 폐기되어 사용 method 없음.
- §11 의 핵심 6 method (minibatch_partial / sparse_rp / chao_weighted / hilbert_real / hyperloglog / reservoir) 는 paradigm 다양성 + Pareto frontier + 본 narrative §4 ~ §9 핵심 등장 기준으로 선정.

사용 시 안내

- **5/15 박광현 미팅:** §1 ~ §10 흐름 + §11 핵심 6 method 깊이 소개 base. §9 권장 + §10 다중 테이블 + §11.6 reservoir 부분이 자문 질문 대비 핵심.
- **5/27 최종 발표:** §3 폐기 정직성, §4 단독 대체 main finding, §6 ~ §7 결합 한계 + 진짜 가치, §8 자원 효율 + reservoir $O(1)$, §11 핵심 method 6 소개가 분량 비중.
- **6/11 최종 보고서:** §1 ~ §12 그대로 보고서 4.3 RQ3 본문 base. 각 단락 1 ~ 2 page 로 확장.
- **팀원 공유:** §1 ~ §10 그대로 peer 톤 변환 (~해 / ~지) + §11 핵심 6 method 만 1 page 압축.

작성: 2026-05-14 07:55 KST · §11 ~ §12 method 깊이 소개 + 17 사용 method 부록 추가: 2026-05-14 08:25 KST