

[속도는벡터] 연구 진행 경과 보고 및 3차 자문 요청

박성원 멘토님 안녕하세요, 연세대학교 캡스톤 디자인 속도는벡터 팀 조현빈입니다.

4월 15일 2차 자문에서 단일 테이블 시나리오 좁힘과 Two-Level Decomposition에 대해 조언해주신 이후로 4월 28일 중간보고서 + 4월 30일 중간발표를 잘 마쳤고, 5월 6일~9일 sprint를 통해 단일과 multi 환경의 측정을 모두 완료했습니다. 5월 27일 최종 발표 전 마지막 자문으로 SF100 (80M 행) 측정 추가 여부에 대한 판단을 구하고자 합니다.

연구 경과

5월 5일 비대면 회의에서 RQ 구조를 RQ1 (분포 차이가 추정 정확도에 영향을 주는가) / RQ2 (분포를 알 때 어떤 sample 분배가 최적인가) / RQ3 (분포를 모를 때 어떤 method가 최적인가) 의 3단계로 재정립하고, sprint 기간 동안 다음 세 가지 측정을 모두 완료했습니다.

단일 10 cell 측정 (5 dataset × sf1/sf10, 30 method × 5 selectivity). RQ3의 분포 무인지 method 후보를 inductive bias 기준 5 paradigm (Density Cluster / Spatial Locality / Online Streaming / Linear Projection / Quasi-random) × 11 representative method로 학술적으로 분류하고, 5 paradigm 중 4 paradigm의 distinct representative로 4강 method를 도출했습니다 — HDBSCAN / MiniBatch_partial / Hilbert curve / sparse Random Projection. 4강의 BERN baseline 대비 평균 정확도 개선은 -7~-8%, SIFT_sf1 sweet spot에서 -34%였습니다.

Exqutor Adaptive Sampling 본 논문 직접 비교 (5월 8일 박세은 팀장 결정). 본 논문 §V-B 의 Adaptive Sampling 알고리즘을 §VI hyperparameter (모멘텀 0.9, 초기 sample 385 등) 그대로 재현하여 4강 method와 query별로 paired alignment된 직접 비교를 수행했습니다. 단일 환경에서 HDBSCAN이 10 cell 모두에서 Adaptive보다 정확했고 7 cell에서 paired Wilcoxon $p < 0.05$ 통계 유의 (SIFT 양 scale $p < 1e-7$) 였으며, MB_partial / Hilbert도 6 cell 통계 유의 우위였습니다. 다만 ★4 sparse RP만 Adaptive와 통계적으로 동등 (0 cell 유의) 했는데, 이는 sparse RP의 *데이터 분포를 모르는* 무작위 행렬 투영 (Achlioptas 2003) 과 Adaptive의 *unstratified Bernoulli* 가 모두 학습 비용 0의 영역에서 동등한 효과를 갖는다는 결과로 해석했습니다. 본 결과는 분포 인지 stratification이 분포 무인지 adaptive sampling보다 단일 환경에서 paired 우위임을 정량 입증합니다.

Multi 환경 일반화 측정 (multi-vector 4 cell + multi-table-join 2 cell × 11 method × 5 selectivity). 단일 sweet spot의 4강 평균 $|\Delta\%|$ 17.13%가 multi 6 cell 평균 0.70%로 **24.5x 감소**했습니다. 4강 vs Adaptive head-to-head도 multi sweet spot 24 비교 (6 cell × 4 method) 중 paired-better가 0건으로, 단일 환경의 우위가 multi 환경에서는 통계적으로 사라졌습니다. "단일 정확성은 multi 정확성의 필요조건만 성립한다" 는 정량 결과입니다.

자문 요청

위 결과를 바탕으로 한 가지 판단을 부탁드립니다.

SF100 (80M 행) 추가 측정 여부. 본 sprint는 sf1 (800K 행) + sf10 (8M 행) 두 scale만 측정했고, sf100 (80M 행) 은 측정 시간 60~80시간 부담으로 5월 27일 발표 전까지 전체 실행은 불가능해 future work로 처리하려고 합니다. 산업 환경 (실제 vector DB의 row 수가 sf100 영역) 관점에서 (1) sf1/sf10 두 scale의 부호 일관성으로 cross-scale invariance를 부분 입증한 현재 처리가 충분한지, (2) 또는 sf100 일부 dataset (DEEP / SIFT / SSN sf100만 PG 적재 완료, 측정 시 ~6시간 가능) 만이라도 추가하는 것이 narrative 강화에 효과적인지 멘토님의 판단을 부탁드립니다.

가능하시면 **5월 13일 (화)** 까지 회신을 받을 수 있으면 5월 22일 박광현 지도교수님 미팅과 5월 27일 최종 발표에 충분히 반영하겠습니다.

감사합니다.

속도는벡터 팀 조현빈 드림