

[속도는벡터] 연구 진행 경과 보고 및 3차 자문 요청

박성원 멘토님 안녕하세요, 연세대학교 캡스톤 디자인 속도는벡터 팀 조현빈입니다.

4월 15일 2차 자문에서 조언해주신 단일 테이블 시나리오 좁힘과 Two-Level Decomposition 의견을 반영해 4월 말 중간보고서와 중간발표를 마쳤습니다. 이후 최종 발표를 위한 본선 실험을 5 paradigm × 11 method 의 학술적 분류 위에서 단일·멀티 환경 모두에서 완료하였고, Exqutor 본 논문 §V-B 의 Adaptive Sampling 알고리즘을 본 연구 method 와 직접 paired 비교하여 우리 연구의 기여 위치를 정량 확인하였습니다. 최종 발표 (5월 27일) 와 보고서 (6월 11일) 전 마지막 자문을 부탁드립니다.

연구 경과

본 연구는 RQ1 (분포 차이가 추정 정확도에 영향을 주는가) → RQ2 (분포를 *알* 때 어떤 표집 분배가 최적인가) → RQ3 (분포를 *모를* 때 어떤 표집 방식이 최적인가) 의 3단계 구조이며, 본선에서는 (i) 5개 paradigm 으로 학술 분류한 11개 표집 method 의 단일 환경 측정, (ii) Exqutor Adaptive Sampling 의 본 논문 그대로 재현 후 본 연구 결과와의 직접 paired 비교, (iii) multi-vector + multi-table-join 환경으로의 외적 타당성 확장을 수행했습니다.

표 1. 측정 매트릭스 (단계 × 데이터셋 × 규모 × 방법 × selectivity)

단계	Dataset (5종)	Scale	Method	Selectivity	측정 단위
RQ1 — 진 단	DEEP / SIFT / SSN++ / WIKI / YFCC	sf1 (800K) + sf10 (8M)	KM20 baseline	5 구간 (0.01 ~ 0.50)	12 cell × 100 query
RQ2 — 분 포 인지 표 집	위 5 dataset	sf1 + sf10	KM20 + 4 분배 모드 (Bernoulli / Proportional / Neyman / Anti-Neyman)	5 구간	10 cell × 5 mode × 5 seed
RQ3 — 분 포 무인지 표집	위 5 dataset	sf1 + sf10	11 method (5 paradigm 분류)	5 구간	10 cell × 11 method × 5 seed
Exqutor 직 접 비교	위 5 dataset	sf1 + sf10	Adaptive Sampling (본 논문 §V-B 재현) vs 4강 method	5 구간	10 cell × paired Wilcoxon
Multi 일반 화	partsupp_deep × {SIFT, WIKI} (multi-vector) + partsupp_deep × part_wiki (multi-table-join)	sf1 + sf10	11 method + Adaptive	5 구간	6 cell × 11 method × 5 seed

표 2. RQ3 — 5 paradigm × 11 method 학술 분류와 단일 4강

분포 무인지 표집 method 후보를 *학습적 가정* (inductive bias) 기준으로 5개 paradigm 으로 분류하고, 각 paradigm 의 대표 method 를 측정한 결과 5 paradigm 중 4 paradigm 의 대표가 **4강 (production-friendly tier)** 에 해당하였습니다.

Paradigm	학습적 가정	대표 method	단일 평균 Δ% (BERN 대비)
P1 Density Cluster	"유사 데이터는 군집을 이룬다"	HDBSCAN ★1 / MiniBatch K-means / GMM	-8.04%
P2 Spatial Locality	"고차원 → 1D quantile 분할로 위치 정보 보존"	Hilbert curve ★3 / faiss IVF	-7.54%
P3 Online Streaming	"OLTP 환경 = 점진적 학습 (partial_fit) / single-pass"	MiniBatch_partial ★2 / Reservoir	-7.63%
P4 Linear Projection	"고차원의 핵심 정보는 저차원 무작위 행렬 투영으로 보존"	sparse Random Projection ★4 / PCA1D	-6.91%
P5 Quasi-random	"결정론적 균등 표집으로 random variance 감소"	Sobol / LSH (P5 한계 명시)	(한계 영역)

* sweet spot (SIFT_sf1) 에서 4강 모두 -26 ~ -34% 의 강력 효과. 4강은 모두 10 cell 중 8 cell 에서 BERN 대비 부호 일관 개선.

표 3. Exqutor Adaptive Sampling 본 논문 직접 비교 — 단일 환경

본 논문 §V-B 의 Adaptive Sampling 알고리즘을 §VI hyperparameter (모멘텀 0.9, 초기 표본 385 등) 그대로 재현하여 4강 method 와 *query 별 paired alignment* 한 직접 비교 ($\Delta\%_{h2h} = (4\text{강 } q\text{-error} - \text{Adaptive } q\text{-error}) / \text{Adaptive } q\text{-error} \times 100$; 음수 = 4강이 더 정확).

Cell	HDBSCAN ★1	MiniBatch_partial ★2	Hilbert ★3	sparse RP ★4
DEEP_sf1	-0.53*	-0.69*	-0.50*	-0.12
DEEP_sf10	-0.67*	-0.33*	-0.22	+0.21
SIFT_sf1	-1.16***	-0.82*	-1.11***	+0.01
SIFT_sf10	-1.12***	-1.14***	-1.15***	-0.13
WIKI_sf10	-0.37*	+0.30	-0.32*	+0.05
YFCC_sf1	-0.97**	-0.69***	-0.40*	+0.05
YFCC_sf10	-0.62**	-0.57**	-0.69**	-0.05
(3 cell 생략 — SSN/WIKI sf1, ceiling 영역, mean ≈ 0)				
paired Wilcoxon p<0.05 비율	7/10	6/10	6/10	0/10

* p<0.05 ** p<0.001 *** p<1e-7 | Bonferroni / Benjamini-Hochberg 보정 후에도 결론 안정.

분포 인지가 강한 3 method (HDBSCAN, MiniBatch_partial, Hilbert) 가 SIFT 양 scale 에서 highly significant 우위. ★4 sparse Random Projection 만 Adaptive 와 통계적으로 동등 (0/10 통계 유의) — 이는 sparse RP 의 데이터 분포를 모르는 무작위 행렬 투영과 Adaptive Sampling 의 *unstratified Bernoulli* 가 모두 학습 비용 0 의 영역에서 동등한 효과를 갖는다는 결과입니다. 분포 인지 stratification 이 분포 무인지 adaptive sampling 보다 단일 환경에서 paired 우위 임을 정량 입증하였습니다.

표 4. Multi 환경 일반화 — 단일 → multi 효과 크기 비교

multi-vector 4 cell + multi-table-join 2 cell × 11 method × 5 selectivity × 5 seed 측정 결과:

비교 항목	단일 환경 (10 cell)	Multi 환경 (6 cell)
4강 평균 Δ% (BERN baseline 대비, sweet spot)	17.13%	0.70% → 24.5× 감소
4강 vs Adaptive Sampling paired-better 비율	7/10 (HDBSCAN), 6/10 (MB_partial · Hilbert), 0/10 (sparse RP)	0/24 (sweet spot, 6 cell × 4 method)
4강 method 간 ranking 일관성	8/10 cell 에서 부호 + ranking 일관	Multi 환경에서 ranking 와해

단일 환경의 paired 우위가 multi 환경에서는 통계적으로 사라지며, 효과 크기도 24.5× 감소합니다. 이는 "단일 정확성은 multi 정확성의 필요조건만 성립한다" 는 정량 결과이며, multi-relation 일반화는 future work (multi-table joint-aware clustering 또는 ECQO 통합) 으로 처리하고자 합니다.

자문 요청

위 결과를 바탕으로 세 가지 판단을 부탁드립니다.

첫째, 실험 결과의 narrative 적합성. 본 연구의 최종 narrative — "단일 테이블 환경에서 분포 인지 stratification 이 Exqutor Adaptive Sampling 대비 paired 우위 (HDBSCAN 7/10 cell 통계 유의) + multi-relation 환경에서 그 우위가 통계적으로 사라짐 (24.5× 효과 감소)" — 가 산업 관점 (실제 vector DB 운영 환경) 에서 본 연구의 기여 위치로 충분한지, 또는 추가 측정·보강이 필요한지 의견을 부탁드립니다.

둘째, SF100 (80M 행) 추가 측정의 가치. 본 본선은 sf1 (800K 행) + sf10 (8M 행) 두 scale 만 측정했고 sf100 (80M 행) 은 측정 시간 60~80시간 부담으로 future work 처리하려고 합니다. 산업 환경 (실제 vector DB 의 row 수가 sf100 영역) 관점에서 (1) sf1/sf10 두 scale 의 부호 일관성으로 cross-scale invariance 를 부분 입증한 현재 처리가 충분한지, (2) 또는 sf100 일부 dataset (DEEP / SIFT / SSN sf100 만 PG 적재 완료, 부분 측정 시 ~6시간 가능) 만이라도 추가하는 것이 narrative 강화에 효과적인지 판단을 부탁드립니다.

셋째, RQ3 의 5 paradigm × 11 method 분류 학술 타당성. 표 2 의 5 paradigm 분류 (Density Cluster / Spatial Locality / Online Streaming / Linear Projection / Quasi-random) 와 4강 method 가 5 paradigm 중 4 paradigm 의 대표라는 narrative 가 학술적으로 타당한지, 또는 paradigm 분류 자체가 *post-hoc rationalization* 로 비판받을 여지가 있는지 의견을 부탁드립니다. 본 분류 체계는 ACM Computing Surveys 의 clustering taxonomy + UWisconsin Wu et al. 의 sampling-based cardinality estimation survey 와 cross-check 하였습니다.

가능하시다면 5월 13일 (화) 까지 회신을 받을 수 있으면 최종 발표에 충분히 반영하겠습니다. 감사합니다.

속도는벡터 팀 조현빈 드림