

[속도는벡터] 연구 진행 경과 보고 및 3차 자문 요청

박성원 멘토님 안녕하세요, 연세대학교 캡스톤 디자인 속도는벡터 팀 조현빈입니다.

4월 15일 2차 자문에서 단일 테이블 시나리오 줍힘과 Two-Level Decomposition 의견을 반영해 4월 28일 중간 보고서와 4월 30일 중간발표를 마무리하였습니다. 이후 5월 27일 최종 발표를 위한 본선 실험을 모두 완료하였고, 마지막 자문을 부탁드립니다.

1. 본 연구의 큰 그림

본 연구는 다음 3단계 질문을 정량 검증하는 구조입니다.

단계	질문	한 줄 답
RQ1	데이터의 분포 차이가 cardinality 추정 정확도에 영향을 주는가?	그렇다 — 12 cell × Spearman $\rho < 0$ 부호 일관성 100%
RQ2	분포를 <i>알</i> 때 어떤 표집 분배 (sample allocation) 가 최적인가?	분포 인지 stratification 자체가 결정적 (51/52 cell paired CI 0 제외, 5 mode 간 격차 $< 1\%$ in 7/12 cell)
RQ3	분포를 <i>모를</i> 때 어떤 표집 방식이 최적인가?	학술적으로 분류한 5 paradigm × 11 method 중 4강이 BERN baseline 대비 평균 -7~-8% Q-error 개선, sweet spot -34%

추가로 (a) 본 연구 4강 method 와 **Exqutor** 본 논문 §V-B 의 Adaptive Sampling 알고리즘 을 동일 query 위에서 paired 비교하여 본 연구의 기여 위치를 정량 확인하고, (b) 단일 테이블에서 검증된 효과가 **multi-vector / multi-table-join 환경** 으로 일반화되는지 외적 타당성을 측정하였습니다.

2. 측정 환경 — Q-error 와 16 cell 매트릭스

핵심 평가 지표 = Q-error: 추정 cardinality / 실제 cardinality 의 비율 (1.0 = 완벽). Q-error 가 1.0 에 가까울수록 추정이 정확.

$\Delta\%$ 의 의미 (이하 모든 표): $-\Delta\% = (\text{대상 method 의 Q-error} - \text{비교 baseline 의 Q-error}) / \text{baseline Q-error} \times 100$ - 음수 = 대상 method 가 더 정확 (Q-error 가 baseline 보다 작음)

표 1. 측정 cell 16개 (단일 10 + 멀티 6)

환경	Dataset	차원	sf1 (800K 행)	sf10 (8M 행)
단일	DEEP	96	✓	✓
단일	SIFT	128	✓	✓
단일	SSN++	256	✓	✓
단일	WIKI	768	✓	✓
단일	YFCC	192	✓	✓
멀티 vector	DEEP + SIFT (한 행에 결합)	96+128	✓	✓
멀티 vector	DEEP + WIKI (한 행에 결합)	96+768	✓	✓
멀티 join	partsupp_DEEP $\bowtie$ part_WIKI	96, 768	✓	✓

각 cell 은 5 selectivity 구간 (0.01 / 0.05 / 0.10 / 0.30 / 0.50) $\times$ 5 random seed $\times$ 100 query = **2,500 paired measurement**, paired Wilcoxon signed-rank test 로 통계 유의성 검증.

3. RQ1 결과 — 분포 차이가 정확도에 영향을 주는가

5 dataset $\times$ 2 scale 의 12 cell 에서 분포 skew 지표 (HHI / cluster_ratio / intrinsic_dim) 와 BERN baseline Q-error 의 Spearman 상관 ρ 를 측정.

- 모든 12 cell 에서 $\rho < 0$ (부호 일관성 100%)
- 대표 cell DEEP-KM20: $\rho = -0.680$, 95% CI [-0.800, -0.440] (0 제외, 통계 유의)
- 해석: selectivity 가 좁아질수록 BERN baseline 의 Q-error 부정확이 단조 증가

4. RQ2 결과 — 분포를 알 때 어떤 표집 분배가 최적인가

10 단일 cell 에서 KM20 (K=20 cluster) 위에 5가지 표집 분배 mode 를 ablation 비교: BERN baseline / Proportional / Neyman / Anti-Neyman / Equal.

측정	결과
paired bootstrap 95% CI 가 0 을 제외하는 cell 비율	51/52 (98.1%) — 분포 인지 stratification 의 강건한 우위
5 mode 간 Q-error 격차 < 1%p in cell	7/12 (58.3%) — mode 선택 자체는 부차적

부수 발견: "어떤 분배 mode 를 쓰느냐" 보다 "분포 정보를 인지하느냐 vs 안 하느냐" 가 본질적 결정 변수.

5. RQ3 결과 — 분포를 모를 때 어떤 표집 방식이 최적인가

분포 무인지 method 후보를 학습적 가정 (inductive bias) 기준으로 5개 paradigm 으로 분류하고, 각 paradigm 의 대표 method 11개를 측정.

표 2. 5 paradigm × 11 method 학술 분류

Paradigm	학습적 가정	대표 method (11종)
P1 Density Cluster	유사 데이터는 군집을 이룬다	HDBSCAN, MiniBatch K-means, GMM
P2 Spatial Locality	고차원 → 1D quantile 분할로 공간 정보 보존	Hilbert curve, faiss IVF
P3 Online Streaming	OLTP = 점진적 학습 (<code>partial_fit</code>) / single-pass	MiniBatch_partial, Reservoir
P4 Linear Projection	고차원 핵심 정보는 저차원 무작위 행렬 투영으로 보존	sparse Random Projection (Achlioptas 2003), PCA1D
P5 Quasi-random	결정론적 균등 표집으로 random variance 감소	Sobol, LSH (P5 한계 발견)

표 3. RQ3 결과 — 4강 method 의 단일 환경 Q-error 개선

11 method 중 BERN baseline 대비 평균 $\Delta\%Q$ -error 가 가장 낮은 4종이 5 paradigm 중 4 paradigm 의 대표 method 로 자연스럽게 도출됨.

순위	Method	Paradigm	단일 평균 $\Delta\%$ (vs BERN)	부호 일관 cell
★1	HDBSCAN	P1 Density Cluster	-8.04%	8/10
★2	MiniBatch_partial	P3 Online Streaming	-7.63%	8/10
★3	Hilbert curve	P2 Spatial Locality	-7.54%	8/10
★4	sparse Random Projection	P4 Linear Projection	-6.91%	8/10

* sweet spot SIFT_sf1 에서 4강 모두 **-26% ~ -34%** 의 강력한 Q-error 개선 * boundary cell SSN++ (분포 균형 데이터) 에서는 4강 모두 +1~+2% (효과 ceiling)

6. Exqutor Adaptive Sampling 본 논문과 직접 비교 — 단일 환경

본 논문 §V-B 의 Adaptive Sampling 알고리즘 (식 1~6) 을 §VI hyperparameter (모멘텀 0.9, 초기 표본 385 등) 그대로 재현하고, 본 연구의 4강 method 와 **동일 query × 동일 seed × 동일 selectivity** 위에서 paired 비교.

표 4. 4강 vs Adaptive paired Q-error 비교 (단일 10 cell)

$\Delta\%_{h2h} = (4\text{강 Q-error} - \text{Adaptive Q-error}) / \text{Adaptive Q-error} \times 100$. 음수 = 4강이 더 정확.

Cell	HDBSCAN ★1	MiniBatch_partial ★2	Hilbert ★3	sparse RP ★4
DEEP_sf1	-0.53*	-0.69*	-0.50*	-0.12
DEEP_sf10	-0.67*	-0.33*	-0.22	+0.21
SIFT_sf1	-1.16***	-0.82*	-1.11***	+0.01
SIFT_sf10	-1.12***	-1.14***	-1.15***	-0.13
WIKI_sf10	-0.37*	+0.30	-0.32*	+0.05
YFCC_sf1	-0.97**	-0.69***	-0.40*	+0.05
YFCC_sf10	-0.62**	-0.57**	-0.69**	-0.05
SSN_sf1 / SSN_sf10 / WIKI_sf1 (ceiling 영역)	mean $\approx$ 0	mean $\approx$ 0	mean $\approx$ 0	mean $\approx$ +0.1
paired Wilcoxon $p < 0.05$ 비율	7/10	6/10	6/10	0/10

* $p < 0.05$ ** $p < 0.001$ *** $p < 1e-7$ | Bonferroni / Benjamini-Hochberg 보정 후에도 결론 안정

해석: - ★1 ~ ★3 (분포 인지 강한 3 method): SIFT 양 scale 에서 paired Wilcoxon $p < 1e-7$ 의 highly significant 우위 → 분포 인지 stratification 이 분포 무인지 adaptive sampling 보다 paired 우위 - ★4 **sparse Random Projection** 만 통계적으로 동등 (0/10 유의): sparse RP 의 데이터 분포를 모르는 무작위 행렬 투영과 Adaptive 의 *unstratified Bernoulli* 가 모두 학습 비용 0 의 영역에서 동등 효과

7. 단일 → 멀티 환경 일반화

multi-vector 4 cell + multi-table-join 2 cell 의 6 멀티 cell 에서 11 method × 5 selectivity × 5 seed 측정 후, 단일 환경 결과와 비교.

표 5. 단일 vs 멀티 환경 비교

비교 항목	단일 환경 (10 cell)	멀티 환경 (6 cell)
4강 평균 $ \Delta\%_Q\text{-error} $ (BERN 대비, sweet spot)	17.13%	0.70%
단일 → 멀티 효과 크기 비율	(기준 1.0×)	24.5× 감소
4강 vs Adaptive paired-better 비율 (sweet spot)	7/10 (HDBSCAN), 6/10 (★2,★3)	0/24 (6 cell × 4 method)
4강 method ranking 일관성	8/10 cell 부호 일관	ranking 와해

해석: - 단일 환경의 4강 paired 우위가 멀티 환경에서는 **통계적으로 사라짐** (24 비교 중 0건 paired-better) - 효과 크기 자체도 **24.5× 감소** (17.13% → 0.70%) - 정량 narrative: "**단일 정확성은 멀티 정확성의 필요조건만 성립한다**" - multi-relation 일반화는 future work (multi-table joint-aware clustering 또는 ECQO 통합) 으로 처리

8. 자문 요청

위 결과를 바탕으로 세 가지 판단을 부탁드립니다.

첫째, 실험 결과의 narrative 적합성. 본 연구의 최종 narrative — "*단일 환경에서 분포 인지 stratification of Exqutor Adaptive Sampling 대비 paired 우위 (HDBSCAN 7/10 cell 통계 유의), 멀티 환경에서 그 우위가 통계적으로 사라지며 효과 크기 24.5× 감소*" — 가 산업 관점 (실제 vector DB 운영 환경) 에서 본 연구의 기여 위치로 충분한지, 또는 추가 측정·보강이 필요한지 의견 부탁드립니다.

둘째, SF100 (80M 행) 추가 측정의 가치. 본 본선은 sf1 (800K) + sf10 (8M) 두 scale 만 측정했고, sf100 (80M) 은 측정 시간 60~80시간 부담으로 future work 처리하려고 합니다. 산업 환경 (실제 vector DB 의 row 수가 sf100 영역) 에서 (1) sf1/sf10 두 scale 의 부호 일관성으로 cross-scale invariance 를 부분 입증한 현재 처리가 충분한지, (2) 또는 sf100 일부 dataset (DEEP / SIFT / SSN sf100 만 부분 측정 시 ~6시간 가능) 만이라도 추가하는 것이 narrative 강화에 효과적인지 의견 부탁드립니다.

셋째, RQ3 의 5 paradigm × 11 method 분류 학술 타당성. 표 2 의 paradigm 분류 (Density Cluster / Spatial Locality / Online Streaming / Linear Projection / Quasi-random) 와 4강이 5 paradigm 중 4 paradigm 의 대표라는 narrative 가 학술적으로 타당한지, 또는 paradigm 분류 자체가 *post-hoc rationalization* 으로 비판받을 여지가 있는지 의견 부탁드립니다. 본 분류 체계는 ACM Computing Surveys 의 clustering taxonomy + UWisconsin Wu et al. 의 sampling-based cardinality estimation survey 와 cross-check 하였습니다.

가능하시다면 5월 13일 (화) 까지 회신을 받을 수 있으면 최종 발표에 충분히 반영하겠습니다.

감사합니다.

속도는벡터 팀 조현빈 드림