

자문 이메일 v4 — 2026-05-15 ~ 5-20 발송 예정

발신: 속도는벡터 팀 (연세대학교 컴퓨터과학과 캡스톤 디자인, 조현빈)

수신: 박성원 멘토님 (삼성전자 AI센터, 빅데이터/DB/Web)

참조: 팀원 전원 (박세은 / 강재현 / 이동욱)

제목: [캡스톤 속도는벡터] 3차 자문 요청 — Adaptive Sampling 본 논문 직접 비교 결과와 단일 → multi 일반화 처리 방향

본문

박성원 멘토님, 안녕하세요.

연세대학교 컴퓨터과학과 캡스톤 디자인 속도는벡터 팀의 조현빈입니다. 4월 15일에 보내드린 2차 자문 (RANDOM20 selectivity gradient + Two-Level Decomposition) 의 회신을 4월 28일 중간보고서와 4월 30일 중간발표에 반영해 잘 마무리하였습니다. 5월 5일 비대면 회의에서 RQ 구조를 재정립하고 5월 6일~9일 sprint 동안 단일 + multi 환경의 측정을 모두 finalize하였으며, 5월 27일 최종 발표 (D-18) 와 6월 11일 최종보고서 (D-33) 전 마지막 자문을 요청드립니다. 본 메일은 박성원 멘토님 단독 발송이며, 박광현 지도교수님은 5월 22일 미팅에서 직접 자문을 받을 예정입니다.

이번 sprint 의 핵심은 **Exqutor 본 논문의 Adaptive Sampling 알고리즘을 본 연구의 4강 method 와 직접 paired 비교**한 것입니다. 단일 환경에서는 본 연구가 Adaptive Sampling 대비 paired 우위를 통계적으로 입증하였고, multi-table 환경에서는 그 우위가 사라짐을 정량 확인하였습니다. 본 결과를 산업 관점에서 어떻게 frame 할지에 대한 자문이 핵심 요청 사항입니다.

1. 2차 자문 이후 연구 경로 (4/15 → 5/9)

시점	결정 / 결과
4/15 2차 자문 발송	RANDOM20 gradient + Two-Level Decomposition
4/28 중간발표 + 보고서 제출	2차 자문 회신 반영 완료
5/5 비대면 회의	RQ 구조 3-tier 로 재정립 (RQ1 진단 / RQ2 분포 인지 / RQ3 분포 무인지)
5/6 ~ 5/9 W1 sprint	단일 10 cell + multi 6 cell 측정 100% 완료 + Exqutor Adaptive Sampling 직접 비교
5/22 박광현 교수님 미팅	본 자문 회신 + sprint 결과 합산 보고 예정
5/27 최종 발표 / 6/11 최종보고서	-

3 RQ 의 본 sprint 답:

RQ	질문	본 sprint 답
RQ1 (진단)	skewed 분포가 cardinality 추정 정확도에 영향을 주는가?	12 cell × Spearman $\rho < 0$ 100% 일관 (DEEP-KM20 $\rho = -0.680$, 95% CI [-0.800, -0.440]) — selectivity 가 좁아질수록 BERN 부정확이 단조 증가
RQ2 (분포 인지)	분포를 알 때 어떤 sample 분배가 최적인가?	단일 10 cell × 5 mode (BERN / Proportional / Neyman / Anti-Neyman / Equal) ablation — paired CI 가 0 을 제외하는 cell 51/52 (98.1%), 단 5 mode 간 격차 < 1%p in 7/12 cell → "mode 선택보다 분포 인지 자체가 결정적"
RQ3 (분포 무인지)	분포를 모를 때 어떤 method 가 최적인가?	5 paradigm × 11 method framework 위에서 단일 4강 = HDBSCAN / MiniBatch_partial / Hilbert / sparse Random Projection 도출 (5 paradigm 중 4 paradigm 의 distinct representative). avg $\Delta\%$ -7~-8% (BERN baseline 대비), SIFT_sf1 -34% 단일 sweet spot

2. ★ 핵심 결과 — Exqutor Adaptive Sampling 본 논문 직접 비교

5월 8일 박세은 팀장 결정 (☆☆☆ 우선순위) 으로 Exqutor 본 논문 §V-B 의 Adaptive Sampling 알고리즘을 §VI hyperparameter 그대로 (모멘텀 $m=0.9$ / learning rate $\eta_0=0.1$ / period=50 / 초기 $N_0=385$) 재현하고, query_id × seed × selectivity paired alignment 가 가능한 row schema 로 구현하여 본 연구의 4강 method 와 직접 비교하였습니다. Adaptive Sampling 자체가 학습-free 의 단순 Bernoulli + 모멘텀 budget 확장이라 본 연구 4강의 학습 비용 (~5 시간) 보다 **3,750× 빠름** (5/8 21:30~21:34 단일 10 cell 측정 80 초 완료).

2-1. 단일 환경 — 4강이 Adaptive 대비 paired 우위 (HDBSCAN 7/10 cell 통계 유의)

paired $\Delta\%$ = (4강 method 의 q_error – Adaptive Sampling 의 q_error) / Adaptive Sampling 의 q_error $\times$ 100. 음수 = 4강이 더 정확.

Cell	HDBSCAN	MB_partial	Hilbert	sparse RP
DEEP_sf1	-0.53*	-0.69*	-0.50*	-0.12
DEEP_sf10	-0.67*	-0.33*	-0.22	+0.21
SIFT_sf1	-1.16***	-0.82*	-1.11***	+0.01
SIFT_sf10	-1.12***	-1.14***	-1.15***	-0.13
WIKI_sf10	-0.37*	+0.30	-0.32*	+0.05
YFCC_sf1	-0.97**	-0.69***	-0.40*	+0.05
YFCC_sf10	-0.62**	-0.57**	-0.69**	-0.05
(3 cell 생략 — SSN_sf1/sf10, WIKI_sf1: ceiling 영역, mean $\approx$ 0)				
10 cell mean	-0.62	-0.43	-0.48	+0.05
paired Wilcoxon p<0.05	7/10	6/10	6/10	0/10

* p < 0.05 ** p < 1e-3 *** p < 1e-7 / Bonferroni $\alpha=0.00125$ / Benjamini-Hochberg q<0.05 보정 후에도 결론 안정 (HDBSCAN BH 7/10, Bonferroni 6/10).

해석: 분포 인지 강한 3 method (HDBSCAN, MB_partial, Hilbert) 가 SIFT 양 scale 에서 p < 1e-7 의 highly significant 우위. ★4 sparse Random Projection 만 Adaptive 와 통계적 동등 (4/10 cell win + 0/10 통계 유의, mean +0.05%) — 이는 sparse RP 의 데이터 분포를 모르는 무작위 행렬 투영 (Achlioptas 2003) 과 Adaptive 의 *unstratified Bernoulli* 가 모두 학습 비용 0 의 streaming-friendly 영역에서 동등한 효과를 갖는다는 finding 입니다.

본 결과는 본 연구의 contribution narrative — "Exqutor 가 미작동하는 단일 테이블 영역에 대한 분포 정보의 가치" — 를 정량 입증합니다. 4강 vs BERN 의 sweet spot magnitude (-7 ~ -32%) 위에 추가 0.5 ~ 1.2%p 의 paired improvement 를 가져옵니다.

2-2. Multi 환경 — 단일 우위가 통계적으로 사라짐

Multi-vector (4 cell, deep+sift / deep+wiki $\times$ sf1+sf10) + Multi-table-join (2 cell, partsupp_deep $\bowtie$ part_wiki $\times$ sf1+sf10) = 6 cell $\times$ 11 method $\times$ 5 sel $\times$ 5 seed $\times$ 100 query = 16,500 measurement + Multi Adaptive baseline 15,000 measurement. 5월 9일 02:20 finalize.

Sweet spot sel=0.5 paired median $\Delta\%_{h2h}$ (4강 vs Adaptive):

Cell	HDBSCAN	MB_partial	Hilbert	sparse RP
partsupp_deep_sift_10	+0.005	+0.180	-0.167	+0.537*
partsupp_deep_wiki_10	+0.609**	+0.432*	+0.208	+0.439*
multi_join_deep_wiki	+0.376*	+0.152	+0.163	+0.277*
partsupp_deep_sift_1	+0.391	+0.146	+0.011	+0.186
partsupp_deep_wiki_1	-0.008	+0.064	-0.165	+0.106
multi_join_deep_wiki_1	-0.008	+0.064	-0.165	+0.106
paired-better (median<0 + Wilcoxon p<0.05)	0/6	0/6	0/6	0/6

24 cell pair (6 cell $\times$ 4 method) 중 **paired-better** 가 **0/24** — 단일 환경의 4강 우위가 multi 에서는 **통계적 유의성이 완전히 사라짐**. Bonferroni / BH-FDR 어느 보정 기준에서도 동일.

2-3. 단일 → multi 일반화 시 효과 크기 24.5× 감소

단계	cell	4강 평균 $ \Delta\% $ (vs BERN)	단일 대비 비율
단일 sweet spot	4 dataset (sf1+sf10)	17.13%	1.0× (baseline)
Multi-vector + Multi-join 6 cell	본 sprint 측정	0.70%	24.5× 감소

본 결과는 "단일 정확성은 multi 정확성의 필요조건만 성립, 충분조건은 아님" 을 정량 입증합니다. 단일에서 분포 인지가 강력한 method 라도 multi 환경에서는 거의 BERN baseline 수준으로 약화되며, 4강 method 의 ranking 도 multi 에서는 일관성 없이 와해됩니다.

2-4. 추가 finding — Multi-table-join 1:1 key join 의 q_error 환원

`multi_join_deep_wiki_1` (1:1 key join) 의 4강 q_error 가 `partsupp_deep_wiki_1` (multi-vector) 의 4강 q_error 와 query_id 별로 **정확히 일치** 함을 raw csv md5 비교로 확인하였습니다. 이는 foreign-key dimension join (1:1 key) 환경에서 join cardinality 추정이 single-side dominant cardinality 추정으로 환원되는 구조적 특성으로, multi-relation 환경의 sampling-based estimator 가 single-side 측정으로 대체 가능한 cell 류를 식별하는 supplementary finding 입니다.

3. 자문 요청 3 항목 — 박성원 멘토님께

박성원 멘토님께서 삼성전자 AI센터 빅데이터/DB/Web 영역의 산업 연구 관점에서 다음 세 가지에 대한 자문을 부탁드립니다.

(a) **Adaptive Sampling** 본 논문과의 직접 **paired 비교 narrative 정합성**. §2-1 의 단일 10 cell paired 결과 (HDBSCAN 7/10 cell 통계 유의 우위, sparse RP 동등) 가 본 연구의 핵심 contribution narrative — "분포 인지 stratification 이 분포 무인지 adaptive sampling 보다 우위" — 를 입증하는 실험 설계로 적절한지, 또는 비교 조건 (free vs matched vs fixed-385) 의 추가 보강이 필요한지 자문 부탁드립니다. Adaptive Sampling 의 hyperparameter 는 본 논문 §VI 그대로 사용하였으며, 4강 method 와 query_id 까지 paired align 한 동등 sample budget 비교입니다.

(b) ★4 **sparse Random Projection** 의 산업 적용 가치. ★4 sparse RP 는 단일 standalone 에서 Adaptive Sampling 과 **통계적 동등** (0/10 paired sig, mean +0.05%) 으로 측정되었습니다. 본 연구는 이를 *standalone 우위* 가 아닌 *5 paradigm 분류 체계의 P4 Linear Projection 대표 + 학습 비용 0 의 streaming-friendly tier* 로 재정의하였습니다. 산업 환경에서 (1) 학습 비용 0 의 random projection (Achlioptas 2003 PODS, scikit-learn **SparseRandomProjection**) vs 학습 비용 동반의 density/centroid clustering 사이 trade-off 가 어느 쪽이 현실적인지, (2) data-independent inductive bias 의 paradigm 분류 가치가 발표·보고서 narrative 에서 충분한 지에 대해 자문 부탁드립니다.

(c) **단일 → multi 일반화의 future work 처리 방식**. §2-2 + §2-3 의 결과는 단일 4강 우위가 multi 환경에서 0/24 paired-better 로 사라지고 효과 크기가 24.5× 감소함을 보입니다. 본 팀은 이를 "본 연구는 단일 영역 한정 으로 분포 정보의 가치를 정량 입증, multi 일반화는 future work" 로 처리할 예정입니다. 산업 환경 (대부분의 vector DB 가 multi-relation) 에서 본 처리의 narrative 가치 (단일 영역만이라도 정량 확정) 가 충분한지, 또는 multi-table joint-aware clustering 의 prototype 측정을 5/27 발표 전까지 추가하는 것이 narrative 강화에 효과적인지 자문 부탁드립니다.

4. 회신 요청 및 일정

5월 22일 박광현 지도교수님 미팅 전에 멘토님 자문을 반영하고자 **5월 15일 (목) ~ 5월 20일 (화)** 사이 회신을 받을 수 있으면 5월 27일 최종 발표자료에 충분히 반영 가능합니다. 회신이 늦어질 경우 기본 결정대로 진행 후 최종 보고서 (6월 11일) 에 반영하겠습니다.

첨부:

1. **experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft_filled_partial.md** — W1 sprint master 분석본 (단일 10 cell × 30 method × 5 sel paired CI raw + Adaptive Sampling 결과)

2. [experiments/results/master_v6_§10.6_Multi_광범위_20260509.md](#) — Multi 6 cell × 11 method paradigm 분석 (5/9 fill 본)
3. [experiments/results/master_v6_§10.7_Adaptive_분석_20260508.md](#) — Single 10 cell + Multi 6 cell × Adaptive Sampling paired 분석
4. [_internal/RQ3_paradigm_심층검증_20260508.md](#) — 5 paradigm × 11 method 학술 정합성 검증 (ACM Computing Surveys 2024 + Wu UWisconsin survey cross-check)
5. [submission/_drafts/속도는벡터 - Academic v3 · Final 5_27.pdf](#) — 5월 27일 최종 발표 deck 16-page draft (paradigm framework + Adaptive 결과 반영 v2 update 예정)

3월 14일 산학멘토 배정 이래 박성원 멘토님의 지속적인 자문에 진심으로 감사드리며, 본 자문 회신을 받은 후 5월 27일 최종 발표 전까지 충실히 반영하겠습니다.

감사합니다.

속도는벡터 팀 조현빈 드림 2026년 5월 15일 (발송 예정)

(별첨) 박성원 멘토님 카톡/메신저 발송 message draft

다음은 박성원 멘토님께 본 자문 메일 발송 직전 카톡 또는 메신저로 안내드릴 짧은 message draft (~150자)입니다.

박성원 멘토님 안녕하세요, 캡스톤 속도는벡터 팀 조현빈입니다. 4/15 2차 자문 회신해주신 내용 잘 반영해 4/30 중간발표 마쳤고, 5/27 최종발표 전 마지막 3차 자문 메일 보내드렸으니 검토 부탁드립니다 (Exqutor Adaptive Sampling 본 논문 직접 비교 + 단일 → multi 일반화 처리). 5/15~5/20 회신 가능하시면 5/22 교수님 미팅에 반영하겠습니다. 감사합니다!

작성: 2026-05-08 21:30 KST · v4 초안 (지도확인서 v3 base + Adaptive 결과 + Multi 진행 중 placeholder)
최종 수정: 2026-05-09 13:35 KST · narrative 명료화 재작성 (자문 요청 6 → 3 항목, 1차/2차 자문 톤 적용, jargon 풀어쓰기) **작성 모델:** Claude Opus 4.7 1M (1M context) **선행 본:** 1차 자문 (3/14 산학멘토 배정 직후) → 2차 자문 (4/15 RANDOM20 gradient + Two-Level Decomposition) → **3차 자문 v4 (5/9 13:35 박성원 멘토 단독 발송본, narrative 명료화 재작성)** **발송 예정:** 5/15 (목) ~ 5/20 (화), 박세은 → 박성원 멘토 발송 ready