

[속도는벡터] 연구 진행 경과 보고 및 3차 자문 요청

박성원 멘토님 안녕하세요, 연세대학교 캡스톤 디자인 속도는벡터 팀 조현빈입니다.

4월 15일 2차 자문에서 단일 테이블 시나리오 좁힘과 Two-Level Decomposition에 대해 조언해주신 내용을 반영해 4월 28일 중간보고서와 4월 30일 중간발표를 잘 마쳤습니다. 이후 5월 27일 최종 발표를 위한 본선 실험을 모두 마무리하였고, 마지막 자문을 부탁드립니다.

1. 본 연구가 풀려는 문제

벡터 데이터베이스가 쿼리를 받으면 "이 쿼리의 결과가 몇 행 정도일까"를 미리 추정해야 효율적인 실행 계획을 세울 수 있습니다. 추정값이 실제와 가까울수록 좋고, 멀어질수록 잘못된 실행 계획으로 인해 쿼리가 느려집니다.

기존 방식은 모든 행 중에서 무작위로 일부를 뽑아 (random sampling) 그 비율로 추정합니다. 그런데 데이터가 한 쪽 영역에 몰려 있을 때, 무작위 표집은 쏠린 영역을 충분히 반영하지 못해 추정이 부정확해집니다.

본 연구는 이 문제를 세 단계 질문으로 나눠 검증했습니다.

- **RQ1:** 데이터의 분포 차이가 추정 정확도에 정말 영향을 주는가?
- **RQ2:** 분포를 *알* 때, 어떻게 표집하면 가장 정확한가?
- **RQ3:** 분포를 *모를* 때, 어떤 방법이 가장 정확한가?

추가로, Exquitor 본 논문이 제시한 Adaptive Sampling 방식과 본 연구의 결과를 같은 쿼리 위에서 직접 비교하여 본 연구가 어떤 부분을 개선했는지 정량 확인하였습니다.

2. 측정된 데이터셋

5종의 벡터 데이터셋을 두 가지 규모 (sf1 = 80만 행, sf10 = 800만 행) 로 측정하고, 추가로 두 종류의 벡터를 한 행에 결합한 환경 (multi-vector) 과 두 테이블을 조인한 환경 (multi-table-join) 도 측정했습니다.

환경	Dataset	차원	sf1 (80만)	sf10 (800만)
단일 테이블	DEEP	96	✓	✓
단일 테이블	SIFT	128	✓	✓
단일 테이블	SSN++	256	✓	✓
단일 테이블	WIKI	768	✓	✓
단일 테이블	YFCC	192	✓	✓
multi-vector	DEEP+SIFT 결합	96+128	✓	✓
multi-vector	DEEP+WIKI 결합	96+768	✓	✓
multi-table-join	DEEP × WIKI 조인	96, 768	✓	✓

→ 단일 10개 + 멀티 6개 = **총 16개 cell** (cell = 데이터셋 한 종류 × 한 규모) 측정.

각 cell 에서 5가지 selectivity 구간 (0.01, 0.05, 0.10, 0.30, 0.50, 즉 결과가 전체의 1%~50% 인 영역) × 5개 random seed × 100개 query = 2,500개 측정. 핵심 평가 지표는 **Q-error** (추정한 결과 행 수 ÷ 실제 결과 행 수, 1.0 에 가까울수록 정확).

3. RQ1 결과 — 분포 차이가 정확도에 영향을 주는가

답: 그렇다. 측정된 12개 cell 모두에서 일관된 결과를 확인했습니다.

쿼리 범위가 좁아질수록 (selectivity 가 작아질수록) 무작위 표집의 추정 정확도가 단조적으로 떨어졌습니다. 대표 데이터셋 DEEP 에서 Spearman 상관계수 $\rho = -0.680$ (95% 신뢰구간 $[-0.80, -0.44]$, 0 제외) 으로 통계적으로 유의했습니다.

4. RQ2 결과 — 분포를 알 때 어떻게 표집하면 가장 정확한가

10개 단일 cell 에서 다섯 가지 표집 분배 방식을 비교했습니다 — 단순 무작위 (Bernoulli) / 비례 분배 (Proportional) / Neyman 분배 / Anti-Neyman 분배 / 균등 분배 (Equal).

핵심 결과 두 가지:

- 분포 인지 표집이 **52개 cell 중 51개 (98%)** 에서 단순 무작위보다 통계적으로 유의하게 우위
- 다만 다섯 가지 방식 사이의 정확도 차이는 **12개 cell 중 7개에서 1%p 미만** 으로 작음

→ "어떤 분배 방식을 쓰느냐" 보다 "**분포 정보를 인지하느냐 vs 안 하느냐**" 가 본질적 결정 변수.

5. RQ3 결과 — 분포를 모를 때 어떤 방법이 가장 정확한가

분포를 모를 때 사용 가능한 표집 방법들을 *어떤 가정에 기반한 방법인가* 기준으로 5개 paradigm (계열) 으로 분류하고, 각 paradigm 에서 대표 method 11개를 측정했습니다.

Paradigm	핵심 가정	대표 method
P1 Density Cluster	"비슷한 데이터는 군집을 이룬다"	HDBSCAN, MiniBatch K-means, GMM
P2 Spatial Locality	"고차원 데이터를 1차원으로 펼쳐도 위치 정보 일부 보존"	Hilbert curve, faiss IVF
P3 Online Streaming	"데이터를 한 번씩만 훑으며 학습 (OLTP 친화)"	MiniBatch_partial, Reservoir
P4 Linear Projection	"고차원 → 저차원 무작위 행렬 투영해도 핵심 정보 보존"	sparse Random Projection (Achlioptas 2003), PCA1D
P5 Quasi-random	"결정론적 균등 표집으로 무작위성 줄이기"	Sobol, LSH (한계 발견)

11 method 측정 결과 **Top 4 method** 가 5 paradigm 중 4 paradigm 의 대표로 자연스럽게 도출되었습니다.

순위	Method	Paradigm	평균 정확도 개선 (vs 무작위)	부호 일관 cell
★1	HDBSCAN	P1 Density Cluster	-8.04%	8/10
★2	MiniBatch_partial	P3 Online Streaming	-7.63%	8/10
★3	Hilbert curve	P2 Spatial Locality	-7.54%	8/10
★4	sparse Random Projection	P4 Linear Projection	-6.91%	8/10

* "정확도 개선" 은 "추정 정확도가 무작위 표집 대비 얼마나 좋아졌는가" 를 % 로 표현한 값. 음수일수록 개선. * SIFT (sf1) sweet spot 에서 Top 4 모두 **-26 ~ -34%** 의 강한 개선 * boundary 데이터셋 SSN++ (분포가 비교적 균형) 에서는 Top 4 모두 +1~2% (효과 ceiling 영역)

6. Exqutor Adaptive Sampling 본 논문과 직접 비교 — 단일 환경

본 논문 §V-B 의 Adaptive Sampling 알고리즘 (식 1~6) 을 §VI hyperparameter (모멘텀 0.9, 초기 표본 385 등) 그대로 재현하고, 본 연구의 Top 4 method 와 동일 *query* × 동일 *seed* × 동일 *selectivity* 위에서 paired 비교 (같은 쿼리 위에서 두 방법의 결과를 짝지어 통계 검정) 했습니다.

Cell	HDBSCAN ★1	MiniBatch_partial ★2	Hilbert ★3	sparse RP ★4
DEEP_sf1	-0.53*	-0.69*	-0.50*	-0.12
DEEP_sf10	-0.67*	-0.33*	-0.22	+0.21
SIFT_sf1	-1.16***	-0.82*	-1.11***	+0.01
SIFT_sf10	-1.12***	-1.14***	-1.15***	-0.13
WIKI_sf10	-0.37*	+0.30	-0.32*	+0.05
YFCC_sf1	-0.97**	-0.69***	-0.40*	+0.05
YFCC_sf10	-0.62**	-0.57**	-0.69**	-0.05
SSN_sf1 / SSN_sf10 / WIKI_sf1 (ceiling)	mean ≈ 0	mean ≈ 0	mean ≈ 0	mean ≈ +0.1
통계 유의 (p<0.05) cell 비율	7/10	6/10	6/10	0/10

* p<0.05 ** p<0.001 *** p<1e-7 * 음수 = Top 4 method 가 Adaptive 보다 정확

해석:

- ★1~★3 (HDBSCAN / MiniBatch_partial / Hilbert) 은 SIFT 두 규모 모두에서 매우 강한 통계 유의 우위. **분포를 인지하는 표집이 분포를 모르는 Adaptive Sampling 보다 단일 환경에서 paired 우위** 임을 정량 입증.
- ★4 sparse Random Projection 만 Adaptive 와 통계적으로 동등. 두 방식 모두 "데이터 분포를 모르는 무작위적 접근" 이라는 공통점이 있음.

7. 단일 → 멀티 환경 일반화

multi-vector 4 cell + multi-table-join 2 cell = 멀티 6 cell 에서도 11 method 를 동일하게 측정한 후 단일 환경 결과와 비교했습니다.

비교 항목	단일 환경 (10 cell)	멀티 환경 (6 cell)
Top 4 평균 정확도 개선 (sweet spot, vs 무작위)	17.13%	0.70%
단일 → 멀티 효과 크기 비율	(기준 1.0×)	24.5× 감소
Top 4 가 Adaptive 보다 paired 우위 비율	7/10 (HDBSCAN), 6/10 (★2,★3)	0/24 (6 cell × 4 method)
Top 4 method 간 ranking 일관성	8/10 cell 부호 일관	멀티에서 ranking 와해

→ 단일 환경에서는 Top 4 의 paired 우위가 강했지만, 멀티 환경에서는 그 우위가 통계적으로 사라지고 효과 크기 자체도 24.5× 감소했습니다.

→ 정량 narrative: "단일 환경의 정확도가 멀티 환경 정확도의 필요조건만 성립한다 (충분조건은 아니다)"

multi-relation 환경의 일반화는 future work (multi-table joint-aware clustering 또는 ECQO 통합) 로 처리할 예정입니다.

8. 자문 요청

위 결과를 바탕으로 세 가지 판단을 부탁드립니다.

첫째, 실험 결과의 narrative 적합성. 본 연구의 최종 narrative — "단일 환경에서 분포 인지 표집이 Exqutor Adaptive Sampling 보다 paired 우위 (HDBSCAN 7/10 cell 통계 유의), 멀티 환경에서 그 우위가 사라지며 효과 24.5× 감소" — 가 산업 관점 (실제 vector DB 운영 환경) 에서 본 연구의 기여 위치로 충분한지, 또는 추가 측정·보강이 필요한지 의견 부탁드립니다.

둘째, SF100 (8000만 행) 추가 측정의 가치. 본 본선은 sf1 (80만 행) + sf10 (800만 행) 두 규모만 측정했고, sf100 (8000만 행) 은 측정 시간 60~80시간 부담으로 future work 처리하려고 합니다. 산업 환경 (실제 vector DB 의 행 수가 sf100 영역) 에서 (1) sf1/sf10 두 규모의 부호 일관성으로 cross-scale invariance 를 부분 입증한 현재 처리가 충분한지, (2) 또는 sf100 일부 데이터셋 (DEEP / SIFT / SSN sf100 만 부분 측정 시 ~6시간 가능) 만이라도 추가하는 것이 narrative 강화에 효과적인지 의견 부탁드립니다.

셋째, RQ3 의 5 paradigm 분류 학술 타당성. §5 의 5 paradigm 분류와 Top 4 가 5 paradigm 중 4 paradigm 의 대표라는 narrative 가 학술적으로 타당한지, 또는 paradigm 분류 자체가 *사후 정당화* (post-hoc rationalization, 결과를 보고 나서 분류 체계를 만든 것 아니냐는 비판) 로 비판받을 여지가 있는지 의견 부탁드립니다. 본 분류는 ACM Computing Surveys 의 clustering taxonomy + UWisconsin Wu et al. 의 sampling-based cardinality estimation survey 와 비교하여 정합성을 확인하였습니다.

가능하시다면 **5월 13일 (화)** 까지 회신을 받을 수 있으면 최종 발표에 충분히 반영하겠습니다.

감사합니다.

속도는벡터 팀 조현빈 드림