

자문 이메일 v4 — 2026-05-15 ~ 5-20 발송 예정

발신: 속도는벡터 팀 (연세대학교 컴퓨터과학과 캡스톤 디자인, 조현빈)

수신: 박성원 멘토님 (삼성전자 AI센터, 빅데이터/DB/Web)

참조: 팀원 전원 (박세은 / 강재현 / 이동욱)

제목: [캡스톤 속도는벡터] 3차 자문 요청 — RQ1·RQ2 finalize + RQ3 5 paradigm framework + Exqutor Adaptive Sampling 직접 비교

본문

박성원 멘토님, 안녕하십니까.

연세대학교 컴퓨터과학과 캡스톤 디자인 속도는벡터 팀의 조현빈입니다. 4월 15일에 보내드린 2차 자문 (Two-Level Decomposition + RANDOM20 selectivity gradient) 에 회신해주신 의견을 4월 28일 중간보고서와 4월 30일 중간발표 (강재현 단독 발표, 인증 A428) 에 반영하여 잘 마무리하였습니다. 이번에는 W1 sprint 결과 종합과 5월 27일 최종 발표 전 마지막 자문을 요청드립니다. 본 메일은 박성원 멘토님 단독 발송이며, 임채림 지도연구원께서는 별도 자문 의뢰가 가지 않고, 박광현 지도교수님은 5월 22일 미팅에서 직접 자문을 받을 예정입니다.

5월 27일 최종 발표 (D-19) 와 6월 11일 최종보고서 (D-34) 가 다가오면서 본 연구의 contribution narrative finalize 단계에 있으며, 특히 멘토님께서 1차 자문 때 강조해주신 "산업 적용 가능성" 관점에서의 검증을 요청드리고자 합니다.

1. W1 sprint (5/6~5/8) 종합 결과

5월 5일 비대면 회의에서 RQ 구조를 RQ1 (Normal vs Skew 분포 직접 비교) / RQ2 (분포 인지 시 최적 sampling allocation) / RQ3 (분포 미인지 시 최적 sampling method) 의 3-tier 로 재정립한 후, 사흘간 sprint 를 통해 RQ1·RQ2 의 측정을 SF1 (800K) 과 SF10 (8M) 두 규모에서 100% 완료하고 RQ3 의 method 후보군을 학술 정합성 검증을 거쳐 5 개 paradigm 으로 확정하였습니다.

RQ1 — Normal vs Skew 정량 비교: 5 개 dataset (DEEP 96d / SIFT 128d / SimSearchNet++ 256d / WIKI 768d / YFCC 192d) $\times$ 2 SF = 10 single cell 모두에서 BERN q-error 와 분포 skew 지표 (HHI / cluster_ratio / intrinsic_dim) 간 Spearman $\rho < 0$ 의 sign 일관성 100% 가 관찰되었으며, 대표 셀인 DEEP-KM20 의 $\rho = -0.680$ (95% CI [-0.800, -0.440], 0 제외) 으로 통계적 유의성도 확보되었습니다. "selectivity 가 좋아질수록 BERN 부정확도가 단조 증가" 라는 가설 H1 의 정량 증거입니다.

RQ2 — KM20 + Allocation Mode Ablation: 동일 10 cell 에 KM20 (K=20 cluster) 위에서 5 개 sample allocation mode (BERN baseline / Proportional / Neyman / Anti-Neyman / Equal) 를 selectivity 5 구간에서 비교한 결과, paired bootstrap 95% CI 가 0 을 제외하는 cell 비율이 51/52 (98.1%) 로 분포 인지 stratification 의 강건한 우위가 입증되었습니다. 한편 5 개 mode 간 q-error 격차가 1%p 미만인 cell 이 7/12 (58.3%) 에 달하여 **mode 선택보다 분포 인지 자체가 결정적**이라는 부수 발견을 확보하였습니다.

RQ3 — 5 Paradigm Framework 확정: 광범위 후보 (~30 method) 검토 후 inductive bias 의 학술적 근거에 따라 다음 5 paradigm × 11 representative method 로 분류하고, 5월 8일 저녁 학술 정합성 심층 검증 (ACM Computing Surveys 2024 의 clustering taxonomy + Wu UWisconsin sampling-based cardinality estimation survey 와 cross-check) 을 통해 paradigm naming 을 최종 확정하였습니다.

Paradigm	Inductive bias	Representative
P1. Density Clustering	"유사 데이터는 군집을 이룬다"	HDBSCAN, MiniBatch K-means, GMM
P2. Space-Filling Locality	"고차원 → 1D mapping 후 quantile 분할"	Hilbert curve, faiss IVF
P3. Online Streaming	"OLTP 환경 = partial fit / single-pass"	MiniBatch_partial, Reservoir
P4. Linear Projection	"고차원 핵심 정보는 저차원 투영 보존"	sparse RP (Achlioptas 2003), PCA1D
P5. Low-discrepancy / Quasi-random	"결정론적 균등 sampling 으로 random variance 감소"	Sobol, Halton

본 paradigm framework 에서 도출한 단일 4강은 **HDBSCAN (P1) / MiniBatch_partial (P3) / Hilbert curve (P2) / sparse RP (P4)** 로, 5 paradigm 중 4 paradigm 의 distinct representative 가 1위씩 차지하는 학술적 narrative 가 형성되어 있습니다. 단일 SF1-SF10 매트릭스에서 sweet spot 4강 평균 |Δ%| 는 17.13% 였으나 multi-vector / multi-table-join 환경에서는 0.67~0.68% 로 25.2× 약화되어, "단일 정확성은 multi 정확성의 필요조건만 성립" 을 정직하게 보고할 예정입니다.

또한 5월 8일 회의에서 SIGMOD 2025 의 PDX (Kuffo et al., CWI Amsterdam, arXiv:2503.04422) 가 본 연구의 핵심 framing — "intrinsic_dim + skewness 가 algorithm selection 을 결정한다" — 와 정확히 일치하는 결론을 학술 confirmation 함을 확인하였습니다. PDX 는 compute layer (data layout for fast similarity), 본 연구는 pre-process layer (sampling 분배 전략) 로 complementary contribution 을 형성합니다.

2. Exqutor 본 논문 Adaptive Sampling 직접 비교

5월 8일 19시 비대면 회의에서 박세은 팀장의 결정 (☆☆☆ 우선순위) 으로 Exqutor 본 논문 (arXiv:2512.09695v2) Section V-B 의 Adaptive Sampling 알고리즘과 본 연구 4강의 직접 paired $\Delta\%$ 비교 실험을 launch 하였습니다.

Adaptive Sampling 의 식 1~6 (초기 $N=385$, momentum $m=0.9$, learning rate $\eta_0=0.1$, weight $\alpha=50$, target Q-error $\beta=1.5$, decay $\gamma=0.99$, update period 50 queries) 을 본 논문 Section VI 의 hyperparameter 그대로 in-memory 로 재현하였으며, 본 연구의 측정 framework (`_measure_common.py`) 와 호환되는 row schema (dataset, mode, selectivity, seed, query_id, D_target, true_card, est, q_error, sample_size_used) 를 산출하여 query_id paired alignment 가 가능한 구조로 구현하였습니다.

5월 8일 21:30 ~ 21:34 단일 10 cell 전체 측정을 완료하였습니다 (Phase 1+2+3 합계 80초 — Adaptive Sampling 알고리즘이 학습을 동반하지 않는 단순 Bernoulli 추정이라 본 연구 4강의 학습 비용 가정 (~5시간) 보다 **3,750x 빠름**). Multi-table 환경에서의 11-method $\times$ 6 multi cell (multi-vector sift_{10/wiki₁₀/sift₁/wiki₁ + multi-table-join sf_{10/sf1}) $\times$ 5 sel $\times$ 5 seed = 16,500 measurement + Multi Adaptive 15,000 measurement 는 5월 9일 02:20 KST 에 finalize 되었으며, 5월 9일 12:25~12:29 분석 csv 4 종 (`_internal/cache/multi_paradigm_paired/`) 산출 후 본 §2 에 반영하였습니다.}

Single 10 cell paired $\Delta\%$ 결과 — Outcome A + B 혼합 판정 (★1~★3 = Outcome A 우위, ★4 sparse_rp = Outcome B 동등). 보고서 outline v2 §4.4 의 4 outcome 정의 기준: A = 4강 우위, B = 동등, C = Adaptive 우위 (thesis fail), D = Hybrid. HDBSCAN ★1 = **10/10 cell win + 7/10 paired Wilcoxon $p<0.05$ 유의** (SIFT 양 scale $p<1e-7$), Hilbert ★3 = 9/10 win + 6/10 sig, MB_partial ★2 = 8/10 win + 6/10 sig 으로 **분포 인지 강도가 강한 3종**이 Adaptive Sampling 에 paired-significant 우위 (Outcome A). 한편 sparse_rp ★4 = 4/10 win + **0/10 sig** 로 Adaptive Sampling 과 통계적 동등 (mean of cell median $\Delta\% = +0.05\%$, Outcome B) — 이는 sparse_rp 의 *data-independent random projection* (Achlioptas 2003) 과 Adaptive 의 *unstratified Bernoulli* 가 모두 학습 비용 0 의 production-friendly tier 에서 동등한 효과를 갖는다는 honest finding 입니다.

본 결과의 narrative implication 은 두 갈래입니다. ① ★1~★3 (HDBSCAN/Hilbert/MB_partial) 의 paired Wilcoxon 유의 6~7/10 cell 은 본 연구 narrative ("Exqutor 가 미작동하는 단일 테이블 영역에 대한 분포 정보의 가치") 의 marginal value 를 정량 입증하며, 4강 vs BERN 의 sweet spot magnitude (-7~-32%) 위에 추가 0.5~1.2%p 의 paired improvement 를 가져옵니다. ② ★4 sparse_rp 는 5 paradigm framework 의 P4 (Linear Projection) anchor 로 framework 완전성을 보존하면서, 학습 free 의 production-friendly 영역에서 Adaptive Sampling 과 동등한 효과로 **산업 친화 paradigm anchor** 의 가치를 증명합니다 — 즉 단일 standalone 우위 X 가 honest 하게 보고되나 paradigm coverage 가치는 별도로 정량 확인됩니다.

multiple comparison correction (40 test = 10 cell × 4 method) 적용 시에도 Outcome 판정은 안정적입니다. Bonferroni ($\alpha = 0.00125$) 기준 HDBSCAN 6/10 / MB_partial 4/10 / Hilbert 3/10 / sparse_rp 0/10, Benjamini-Hochberg FDR ($q = 0.05$) 기준 HDBSCAN 7/10 / MB_partial 5/10 / Hilbert 6/10 / sparse_rp 0/10 으로, raw $p < 0.05$ 기준의 sig count (HDBSCAN 7 / MB 6 / Hilbert 6 / sparse_rp 0) 에서 ★4 sparse_rp 동등 결론은 모든 보정 기준에서 변함없으며 ★1~★3 우위 결론도 유지됩니다.

Multi 6 cell paired $\Delta\%$ 결과 — Outcome C (동등) dominant + 부분 D (low-sel mixed). 5월 9일 새벽 finalize 된 multi-vector × 4 cell + multi-table-join × 2 cell 측정의 4강 vs Adaptive head-to-head paired Wilcoxon 결과는 sweet spot sel=0.5 영역에서 24 test (6 cell × 4 method) 중 **paired-better 가 0/24** 로 측정되어 단일 §10.7 Outcome A 가 multi 환경에서는 **불성립**, 분포 정보 *marginal value* 가 통계적 *indistinguishable* 영역으로 약화 (Outcome C dominant). 4강 cell median $\Delta\%$ 의 6 cell mean 은 -0.021 (Hilbert) ~ +0.275 (sparse_rp) 의 near-zero band 로 수렴하며 Wilcoxon $p < 0.05$ + median < 0 의 paired-significant 우위는 0/24 입니다. Low-selectivity 영역 (sel=0.01~0.1) 에서는 4강 mean $\Delta\%_{h2h}$ 가 +5 ~ +50% 로 Adaptive 보다 **명확히 worse** (Outcome D 부분 발현) — multi 환경의 momentum-기반 dynamic budget 확장이 본 연구 분포 인지 stratification 보다 우월합니다. 이는 §10.6 의 단일 → multi shrinkage chain (단일 sweet spot 17.13% → multi 6 cell mean 0.70%, **24.5x shrinkage**) 과 정합하는 결과로 "단일 정확성은 multi 정확성의 필요조건만 성립" narrative 를 정량 강화합니다. 추가로 multi-table-join sf1 cell ([multi_join_deep_wiki_1](#)) 의 q_error 가 multi-vector sf1 cell ([partsupp_deep_wiki_1](#)) 의 q_error 와 query_id 별 정확 일치 (raw csv md5 검증, 1:1 key join 의 구조적 collapse) 로 *foreign-key dimension join* 환경의 *cardinality estimation* 이 *single-side dominant cardinality* 추정으로 환원 된다는 supplementary finding 을 정량 확인하였으며, 이는 multi-relation 환경의 sampling-based estimator 가 single-side 측정으로 대체 가능한 cell 류를 식별하는 추가 contribution 으로 해석됩니다.

3. 자문 요청 5종 — 박성원 멘토님께

박성원 멘토님께서 삼성전자 AI센터 빅데이터/DB/Web 영역의 산업 연구 관점에서 다음 사항에 대한 자문을 부탁드립니다.

(1) 5 paradigm framework 의 production 적용 가능성. 본 연구의 5 paradigm × 11 representative 분류 체계가 삼성전자 vector DB 운영 환경 (대규모 고차원 embedding 위 analytical workload) 에서 production 적용 가능한 형태인지 자문 부탁드립니다. 특히 P3 paradigm (Online Streaming, MiniBatch_partial / Reservoir) 의 OLTP 친화성과 P1 paradigm (Density Clustering, HDBSCAN) 의 사전 학습 비용 trade-off 가 산업 환경에서 어느 쪽이 더 현실적인지 의견 부탁드립니다.

(2) ★4 = sparse RP 의 산업 anchor 가치 — Adaptive Sampling 동등 finding 의 reframe. §2 결과에서 sparse_rp ★4 가 Adaptive Sampling 과 paired Wilcoxon $p < 0.05$ 유의 0/10 (통계적 동등) 으로 측정되어, 본 연구는 ★4 의 narrative 를 *standalone* 우위 가 아닌 5 paradigm 의 P4 anchor + 학습 free production-friendly tier 로 honest reframe 하였습니다. 즉 sparse_rp (Achlioptas 2003 PODS, data-independent $\{-\sqrt{3}, 0, +\sqrt{3}\}$ matrix, scikit-learn `SparseRandomProjection`) 는 Adaptive Sampling 과 동일하게 학습 phase 0 의 streaming-friendly 영역에서 동등 효과를 가지며, ★1~★3 의 학습 동반 분포 인지 와 함께 5 paradigm framework 를 완성하는 anchor 역할을 합니다. 산업 환경에서 (1) 학습 비용 0 의 random projection vs 학습 비용 동반의 density/centroid clustering 의 trade-off 를 production deployment 에서 어느 쪽이 현실적인지, (2) data-independent inductive bias 의 paradigm anchor 가치 (P4 paradigm coverage, ARI orthogonality #1, scikit-learn API 호환) 가 발표·보고서 narrative 에서 honest reporting 으로 충분한지, (3) PCA1D (data-dependent, avg $\Delta\%$ -7.35) 를 ★4 alternative 로 ablation 차원에서 보유하는 것이 적절한지에 대해 자문 부탁드립니다.

(3) Adaptive Sampling 본 논문 paired 비교의 narrative 정합성. Exqutor 본 논문 §V-B Adaptive Sampling 과 본 연구 4강의 직접 paired $\Delta\%$ 비교 (동일 dataset / selectivity / sample budget 385 / query_id alignment) 가 본 연구 narrative ("distribution-aware stratification 이 distribution-agnostic adaptive sampling 보다 우위") 를 입증하는 실험 설계로 적절한지, 또는 비교 조건 (free vs matched vs fixed-385) 의 추가 보강이 필요한지 자문 부탁드립니다. 결과는 본 메일 발송 시점에 fill 예정이며 회신 시 함께 검토 부탁드립니다.

(4) Adaptive×4강 Ensemble 의 narrative 가치 평가. 본 연구는 5월 8일 22시에 4강 stratification (HDBSCAN/MB_partial/Hilbert/sparse_rp) × Adaptive Sampling dynamic budget 의 ensemble 측정 (단일 10 cell × 4 base method × 5 sel × 5 seed × 100 query = 10,000 measurement) 을 launch 하였으며 1~2시간 내 완료 예정입니다. 4강 stratification 의 분포 인지 + Adaptive Sampling 의 momentum 기반 동적 budget 결합이 단순 4강 또는 단순 Adaptive 보다 우월한지가 핵심 검증 사항입니다. 산업 환경에서 (1) ensemble 의 production deployment 가치 (학습 cost + dynamic budget 결합 trade-off), (2) 5월 27일 발표 contribution 으로 추가 narrative 형성 가능성에 대한 자문 부탁드립니다. (참고: SF100 (80M) cross-scale 확장은 5/8 회의 결과 본 연구 scope 외로 결정되었으며, future work 으로 보고서 limitation 에 명시합니다.)

(5) Multi-table 일반화의 future work 처리 방식. 단일 sweet spot 4강 평균 $|\Delta\%|$ 17.13% 가 multi-vector / multi-table-join 환경에서 0.67~0.68% 로 25.2× 약화되는 결과는 "단일 → multi 일반화는 future work" 로 처리할 예정입니다. 산업 환경 (대부분의 vector DB 가 multi-relation) 에서 본 honest reporting 의 narrative 가치 (단일 영역만이라도 정량 확정) 가 충분한지, 또는 multi-table joint-aware clustering 의 prototype 측정을 5월 27일 발표 전까지 추가하는 것이 narrative 강화에 효과적인지 자문 부탁드립니다.

(6) method-level mathematical correctness 의 honest reporting. V7 audit 결과 11 method 중 9 paper-correct + 2 minor deviation (Reservoir single-cell = RANDOM20 proxy, LSH $K=20$ vs $n_{hp}=5$ misalignment) 발견되었으며, sparse_rp 는 Achlioptas 2003 PODS 의 density 1/3 보다 Li et al. 2006 의 $1/\sqrt{D}$ variant 구현임을 확인하였습니다. 산업 환경에서 이러한 minor deviation 의 honest limitation reporting (vs hyperparameter fix 후 재측정) 의 trade-off 에 대한 자문 부탁드립니다.

4. 회신 요청 및 일정

5월 22일 박광현 지도교수님 미팅 전에 멘토님 자문을 반영하고자 **5월 15일 (목) ~ 5월 20일 (화)** 사이 회신을 받을 수 있으면 5월 27일 최종 발표자료에 충분히 반영 가능합니다. 회신이 늦어질 경우 기본 결정대로 진행 후 최종 보고서 (6월 11일) 에 반영하겠습니다. 5월 27일 최종 발표 슬라이드 (현재 16 page deck **속도는벡터 - Academic v3 · Final 5_27.pdf**) 를 별도로 받아보고 싶으시면 말씀해주시면 즉시 송부드리겠습니다.

첨부 자료:

1. **submission/_drafts/속도는벡터_연구지도확인서_20260508_v3.pdf** — 본 W1 sprint 종합 자료 (RQ1/RQ2 finalize + RQ3 5 paradigm framework + 학술 정합성 심층 검증)
2. **experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft_filled_partial.pdf** — W1 sprint master 분석본 (10 cell × 30 method × 5 sel paired CI raw + Adaptive Sampling 결과 [발송 시점 fill])
3. **_internal/Adaptive_Sampling_method_분석_20260508.md** — Exqutor §V-B 정독 + 식 1~6 + Section VI hyperparam exact 구현 design
4. **_internal/RQ3_paradigm_심층검증_20260508.md** — 5 paradigm 학술 정합성 검증 (ACM Computing Surveys 2024 + Wu UWisconsin survey cross-check)
5. **submission/_drafts/속도는벡터 - Academic v3 · Final 5_27.pdf** — 5월 27일 최종 발표 deck 16 page draft

3월 14일 산학멘토 배정 이래 박성원 멘토님의 지속적인 자문에 진심으로 감사드리며, 본 자문 회신을 받은 후 5월 27일 최종 발표 전까지 충실히 반영하겠습니다.

감사합니다.

속도는벡터 팀 조현빈 드림 2026년 5월 15일 (발송 예정)

(별첨) 박성원 멘토님 카톡/메신저 발송 message draft

다음은 박성원 멘토님께 본 자문 메일 발송 직전 카톡 또는 메신저로 안내드릴 짧은 message draft (~150자) 입니다.

박성원 멘토님 안녕하세요, 캡스톤 속도는벡터 팀 조현빈입니다. 4/15 2차 자문 회신해주신 내용 잘 반영해 4/30 중간발표 마쳤고, 5/27 최종발표 전 마지막 3차 자문 메일 보내드렸으니 검토 부탁드립니다 (W1 sprint 종합 + Exqutor Adaptive Sampling 직접 비교 + 5 paradigm framework). 5/15~5/20 회신 가능하시면 5/22 교수님 미팅에 반영하겠습니다. 감사합니다!

작성: 2026-05-08 21:30 KST · v4 (지도확인서 v3 base + Adaptive 결과 + Multi 결과 fill) **최종 수정:** 2026-05-09 13:00 KST · §2 Multi 6 cell paired $\Delta\%$ 결과 추가 (Outcome C dominant + 부분 D) **작성 모델:** Claude Opus 4.7 1M (1M context) **선행 본:** v2 (4/15 2차 자문 발송본) → v3 (5/8 14:13 W4 sprint 자문메일초안, 채림 +교수님 dual 발송본 — 채림 자문 deprecated) → **v4 (5/8 21:30 single + 5/9 13:00 multi fill, 박성원 멘토 단독 발송본)** **발송 예정:** 5/15 (목) ~ 5/20 (화), 박세은 → 박성원 멘토 발송 ready