

[속도는벡터] 연구 진행 경과 보고 및 3차 자문 요청

박성원 멘토님 안녕하십니까, 연세대학교 캡스톤 디자인 속도는벡터 팀 조현빈입니다.

4월 15일 2차 자문에서 단일 테이블 시나리오 좁힘과 Two-Level Decomposition에 대해 조언해주신 내용을 반영해 4월 28일 중간보고서와 4월 30일 중간발표를 잘 마쳤습니다. 이후 5월 27일 최종 발표를 위한 본선 실험을 모두 마무리하였고, 본 **3차 자문** 을 부탁드립니다 (최종 보고서 제출 (6월 11일) 전 4차 자문도 한 차례 더 부탁드립니다).

1. 본 연구가 풀려는 문제

벡터 데이터베이스가 쿼리를 받으면 "이 쿼리의 결과가 몇 행 정도일까" 를 미리 추정해야 효율적인 실행 계획을 세울 수 있습니다. 추정값이 실제와 가까울수록 좋고, 멀어질수록 잘못된 실행 계획으로 인해 쿼리가 느려집니다. 기존 방식은 모든 행 중에서 무작위로 일부를 뽑아 (random sampling) 그 비율로 추정하는데, 데이터가 한쪽 영역에 몰려 있을 때 무작위 표집은 쏠린 영역을 충분히 반영하지 못해 추정이 부정확해집니다.

본 연구의 *기여 위치* 는 2차 자문에서 정리한 대로 **단일 테이블 vector range query 영역** 입니다. Exqutor 본 논문은 multi-table join 시나리오에 Adaptive Sampling 을 적용하지만, 본 논문 소스 분석 결과 단일 테이블 쿼리는 hook trigger 사각지대로 남아 있어 default 추정이 적용됩니다. 이 사각지대에서 분포 정보를 활용하면 추정 정확도가 얼마나 개선되는지를 정량 검증하는 것이 본 연구의 목적입니다.

본 연구는 이 문제를 세 단계 질문으로 나눠 검증했습니다.

- **RQ1:** 데이터의 분포 차이가 추정 정확도에 정말 영향을 주는가?
- **RQ2:** 분포를 *알* *때*, 어떻게 표집하면 가장 정확한가?
- **RQ3:** 분포를 *모를* *때*, 어떤 방법이 가장 정확한가?

추가로, Exqutor 본 논문이 제시한 Adaptive Sampling 방식과 본 연구의 결과를 같은 쿼리 위에서 직접 paired 비교하여 본 연구가 어떤 부분을 개선했는지 정량 확인하였고, multi-vector / multi-table-join 환경으로의 외적 타당성도 측정하였습니다.

2. 측정된 데이터셋

5종의 벡터 데이터셋을 두 가지 규모 (sf1 = 80만 행, sf10 = 800만 행) 로 측정하고, 추가로 두 종류의 벡터를 한 행에 결합한 환경 (multi-vector) 과 두 테이블을 조인한 환경 (multi-table-join) 도 측정했습니다.

환경	Dataset	차원	sf1 (80만)	sf10 (800만)
단일 테이블	DEEP	96	✓	✓
단일 테이블	SIFT	128	✓	✓
단일 테이블	SSN++	256	✓	✓
단일 테이블	WIKI	768	✓	✓
단일 테이블	YFCC	192	✓	✓
multi-vector	DEEP+SIFT 결합	96+128	✓	✓
multi-vector	DEEP+WIKI 결합	96+768	✓	✓
multi-table-join	DEEP × WIKI 조인	96, 768	✓	✓

→ 단일 10개 + 멀티 6개 = **총 16개 cell** (cell = 데이터셋 한 종류 × 한 규모) 측정.

각 cell 에서 5가지 selectivity 구간 (0.01, 0.05, 0.10, 0.30, 0.50) × 5개 random seed × 100개 query = 2,500개 측정. 핵심 평가 지표는 **Q-error** (추정한 결과 행 수 ÷ 실제 결과 행 수, 1.0 에 가까울수록 정확).

3. RQ1 결과 — 분포 차이가 정확도에 영향을 주는가

답: 그렇다. 측정된 12개 cell 모두에서 일관된 결과를 확인했습니다.

쿼리 범위가 좁아질수록 (selectivity 가 작아질수록) 무작위 표집의 추정 정확도가 단조적으로 떨어졌습니다. 대표 데이터셋 DEEP 에서 Spearman 상관계수 $\rho = -0.680$ (95% 신뢰구간 $[-0.80, -0.44]$, 0 제외) 으로 통계적으로 유의했습니다.

4. RQ2 결과 — 분포를 알 때 어떻게 표집하면 가장 정확한가

10개 단일 cell 에서 KM20 (K=20 cluster) 위에 다섯 가지 표집 분배 방식을 ablation 비교했습니다 — 단순 무작위 (Bernoulli) / 비례 분배 (Proportional) / Neyman 분배 / Anti-Neyman 분배 / 균등 분배 (Equal).

기존 방식 (Bernoulli/Proportional) 의 최대 성능: 분포 인지 표집이 52개 cell 중 51개 (98%) 에서 단순 무작위보다 통계적으로 유의하게 우위였으며, 단일 sweet spot에서 평균 17.13% Q-error 개선 (SIFT_sf1 sweet spot -34%) 을 보였습니다.

Neyman 분배 도입과 honest finding: 위 결과에서 한 단계 더 정확도를 끌어올리기 위해 σ_i (cluster 별 표준편차) 정보를 활용하는 Neyman 분배를 도입했습니다. 그러나 본 측정 결과 Neyman 분배는 **작은 selectivity (0.01~0.05) skew 데이터셋에서만 marginal 개선** (비례 분배 대비 +0.5%p 수준) 으로 제한적이었습니다. 한편 σ_i 를 **반대로** 사용하는 Anti-Neyman 분배는 systematic hurt (DEEP +5.21%, SIFT +9.49%, paired CI 0 제외) 를 보여, σ_i 신호가 **약하지만 분명히 존재** 한다는 negative control 을 정량 확인했습니다.

원인 추정: 다섯 가지 분배 방식 사이의 정확도 차이가 12개 cell 중 7개에서 1%p 미만 으로 매우 작았던 점, 그리고 KM20 cluster 의 σ_i 가 cluster 간 변별력이 충분히 크지 않은 점이 결합된 결과로 보입니다 — **어떤 분배 방식을 쓰느냐보다 분포 정보를 인지하느냐 vs 안 하느냐**가 본질적 결정 변수임을 시사합니다.

5. RQ3 결과 — 분포를 모를 때 어떤 방법이 가장 정확한가

분포를 모를 때 사용 가능한 표집 방법들을 **어떤 가정에 기반한 방법인가** 기준으로 5개 paradigm 으로 분류하고, 각 paradigm 에서 대표 method 11개를 측정했습니다.

Paradigm	핵심 가정	대표 method
P1 Density Cluster	비슷한 데이터는 군집을 이룬다	HDBSCAN, MiniBatch K-means, GMM
P2 Spatial Locality	고차원 데이터를 1차원으로 펼쳐도 위치 정보 일부 보존	Hilbert curve, faiss IVF
P3 Online Streaming	데이터를 한 번씩만 훑으며 학습 (OLTP 친화)	MiniBatch_partial, Reservoir
P4 Linear Projection	고차원 → 저차원 무작위 행렬 투영해도 핵심 정보 보존	sparse Random Projection (Achlioptas 2003), PCA1D
P5 Quasi-random	결정론적 균등 표집으로 무작위성 줄이기	Sobol, LSH (한계 발견)

11 method 측정 결과, **Top 4 method** 가 5 paradigm 중 4 paradigm 의 distinct 대표로 자연스럽게 도출되었습니다.

순위	Method	Paradigm	평균 정확도 개선 (vs 무작위)	부호 일관 cell
★1	HDBSCAN	P1 Density Cluster	-8.04%	8/10
★2	MiniBatch_partial	P3 Online Streaming	-7.63%	8/10
★3	Hilbert curve	P2 Spatial Locality	-7.54%	8/10
★4	sparse Random Projection	P4 Linear Projection	-6.91%	8/10

* SIFT (sf1) sweet spot 에서 Top 4 모두 **-26 ~ -34%** * boundary 데이터셋 SSN++ (분포 균형) 에서는 Top 4 모두 +1~2% (효과 ceiling)

본 분류는 ACM Computing Surveys 2024 의 clustering taxonomy + UWisconsin Wu et al. 의 sampling-based cardinality estimation survey 와 cross-check 하였습니다.

6. Exqutor Adaptive Sampling 본 논문과 직접 비교 — 단일 환경

본 논문 §V-B 의 Adaptive Sampling 알고리즘 (식 1~6) 을 §VI hyperparameter (모멘텀 0.9, 초기 표본 385 등) 그대로 재현하고, 본 연구의 Top 4 method 와 동일 *query* × 동일 *seed* × 동일 *selectivity* 위에서 paired 비교 (같은 쿼리 위에서 두 방법의 결과를 짝지어 통계 검정) 했습니다.

Cell	HDBSCAN ★1	MiniBatch_partial ★2	Hilbert ★3	sparse RP ★4
DEEP_sf1	-0.53*	-0.69*	-0.50*	-0.12
DEEP_sf10	-0.67*	-0.33*	-0.22	+0.21
SIFT_sf1	-1.16***	-0.82*	-1.11***	+0.01
SIFT_sf10	-1.12***	-1.14***	-1.15***	-0.13
WIKI_sf10	-0.37*	+0.30	-0.32*	+0.05
YFCC_sf1	-0.97**	-0.69***	-0.40*	+0.05
YFCC_sf10	-0.62**	-0.57**	-0.69**	-0.05
SSN_sf1 / SSN_sf10 / WIKI_sf1 (ceiling)	mean ≈ 0	mean ≈ 0	mean ≈ 0	mean ≈ +0.1
통계 유의 (p<0.05) cell 비율	7/10	6/10	6/10	0/10

* p<0.05 ** p<0.001 *** p<1e-7 | 음수 = Top 4 가 Adaptive 보다 정확

해석: ★1~★3 (HDBSCAN / MiniBatch_partial / Hilbert) 은 SIFT 두 규모 모두에서 매우 강한 통계 유의 우위 — *분포를 인지하는* 표집이 *분포를 모르는* Adaptive Sampling 보다 단일 환경에서 paired 우위임을 정량 입증. ★4 sparse Random Projection 만 Adaptive 와 통계적으로 동등 (sparse RP 의 *데이터 분포를 모르는* 무작위 행렬 투영과 Adaptive 의 *unstratified Bernoulli* 가 모두 학습 비용 0 의 영역에서 동등 효과).

7. 단일 → 멀티 환경 일반화

multi-vector 4 cell + multi-table-join 2 cell = 멀티 6 cell 에서도 11 method 를 동일하게 측정한 후 단일 환경 결과와 비교했습니다.

비교 항목	단일 환경 (10 cell)	멀티 환경 (6 cell)
Top 4 평균 정확도 개선 (sweet spot, vs 무작위)	17.13%	0.70%
단일 → 멀티 효과 크기 비율	(기준 1.0×)	24.5× 감소
Top 4 가 Adaptive 보다 paired 우위 비율	7/10 (HDBSCAN), 6/10 (★2,★3)	0/24 (6 cell × 4 method)

→ 단일 환경의 Top 4 우위가 멀티 환경에서는 통계적으로 사라지고 효과 크기도 24.5× 감소. 본 연구의 *기여 위치*는 §1 에서 정리한 대로 단일 테이블 vector range query 영역에 한정되며, 멀티 환경의 효과 약화는 본 연구의 **적용 범위 (outer boundary) 의 정량 입증** 입니다. multi-relation 환경의 일반화는 multi-table joint-aware clustering 또는 Exqutor Adaptive Sampling 과의 ensemble 같은 future work 로 처리하고자 합니다.

8. 자문 요청

위 결과를 바탕으로 두 가지 판단을 부탁드립니다.

첫째, RQ2 (분포 인지) 의 next direction

§4 의 결과를 정리하면 — 기존 분포 인지 표집의 최대 성능은 단일 sweet spot에서 약 17%p Q-error 개선이며, 더 정확하게 만들기 위해 도입한 Neyman 분배는 skew 데이터셋의 작은 selectivity 에서만 제한적 개선 에 그쳤습니다. σ_i 신호가 약한 것이 원인으로 추정됩니다 (Anti-Neyman 의 systematic hurt 로 σ_i 신호의 존재 는 확인되나, KM20 cluster 의 σ_i 변별력이 작음).

이 위에서 다음 탐색 방향을 어떻게 잡으면 좋을지 의견 부탁드립니다 — (a) Neyman 분배를 변형 (예: cluster-aware $\hat{\sigma}$ 정밀화, query-conditional weighting, hierarchical Neyman) 하는 방향, 또는 (b) 아예 새로운 분배 방식 (예: dynamic mode 선택, 분포 estimation 정밀화 등) 을 찾는 방향. 산업 환경 (실제 vector DB 운영) 에서 어느 쪽이 더 현실적이고 효과적일지 멘토님 의견을 듣고 싶습니다.

둘째, RQ3 (분포 무인지) 의 5 paradigm 분류 적절성

§5 에서 분포 무인지 표집 방법을 5 paradigm $\times$ 11 method 로 분류 (Density Cluster / Spatial Locality / Online Streaming / Linear Projection / Quasi-random) 하고 비교했습니다. Top 4 가 5 paradigm 중 4 paradigm 의 distinct 대표로 자연스럽게 도출되었지만, 이러한 분류 체계 자체에 대해 자문을 받고 싶습니다.

세 가지 세부 사항입니다 — (a) paradigm 개수 5개를 그대로 유지 하는 것이 좋은지 (4개로 축소 또는 6~7개로 확장 — 예: Hierarchical Cluster, Latent Embedding paradigm 추가 — 이 narrative 강화에 도움이 될지), (b) 이렇게 inductive bias 기준으로 분류해서 비교 하는 방식이 학술적으로 타당한지 또는 사후 정당화 (post-hoc rationalization, 결과를 본 뒤 분류 체계를 끼워 맞추는 것 아니냐는 비판) 으로 비판받을 여지가 있는지, (c) ACM Computing Surveys 2024 의 clustering taxonomy + UWisconsin Wu et al. 의 sampling-based cardinality estimation survey 와의 cross-check 가 충분한 학술 grounding 인지.

가능하시다면 5월 13일 (화) 까지 회신을 받을 수 있으면 최종 발표에 충분히 반영하겠습니다.

감사합니다.

속도는벡터 팀 조현빈 드림