

[속도는벡터] 4차 자문 요청 — Exqutor §V-B paper exact 재현 측정 완료 + ensemble augment 학술 정합성

박성원 멘토님 안녕하세요, 연세대학교 캡스톤 디자인 속도는벡터 팀 조현빈입니다.

5월 9일 v5 자문 메일에서 말씀드렸던 5/27 최종 발표를 위한 **Exqutor 논문 §V-B Adaptive Sampling 영역 paper exact 재현 측정**이 5월 11일에 모두 마무리되었습니다. v5에서 자문해주신 5 paradigm framework + Neyman 분배 next direction에 대한 의견을 반영하여 측정 영역을 재정의하였고, paper의 모든 hyperparam과 query 정의를 verbatim 재현 + 우리 method를 paper baseline 위에 산술 평균 ensemble로 augment하는 새 구조를 정량 검증하였습니다. 본 **4차 자문**을 부탁드립니다 (최종 보고서 6월 11일 제출 전 마지막 자문입니다).

본 메일은 5월 15일 (금) 14시 박광현 교수님 미팅 후 narrative 확정 사항을 반영하여 5월 16~20일 발송 예정입니다.

1. 본 연구의 위치 — Exqutor §V-B 영역 한정

본 연구의 base 논문 Exqutor (arXiv:2512.09695v2)는 vector-augmented analytical query (VAQ)에 대한 cardinality estimation을 두 paradigm으로 해결합니다 — **§V-A ECQO** (벡터 인덱스 있을 때 HNSW range query 활용, 1-2ms)과 **§V-B Adaptive Sampling** (인덱스 없을 때 모멘텀 기반 동적 sample size 조정 식 1-6).

본 연구의 *기여 위치*는 **§V-B 영역 한정**입니다. ECQO §V-A는 paper main result로 그대로 인정하며, §V-B sampling step에 우리 method의 KM20 stratified estimator를 산술 평균으로 ensemble 추가하는 augment 구조의 정량적 가치를 검증합니다. paper §V-B Bernoulli random sampling은 그대로 보존되며, 우리 method는 layer로 추가만 됩니다 (paper-friendly augment).

```
estimator 1 = paper §V-B Bernoulli random sampling (paper exact verbatim)
estimator 2 = 우리 method (KM20 stratified, 분포 인지)
최종 cardinality = (est1 + est2) / 2          ← simple average ensemble
```

이 구조의 통계적 정당성은 bias-variance trade-off에서 나옵니다. random sampling은 bias 0이지만 cluster imbalance 시 variance가 크고, stratified sampling은 분포 가정이 맞을 때 variance가 낮습니다. 두 estimator의 산술 평균은 한 쪽이 분포 misspecification으로 fail해도 다른 쪽이 보완하는 robust 구조입니다.

2. 측정 portfolio + 정합성 검증

본 연구는 9 cells × 56 method × 2 modes (CaseA 단독 대체 + CaseB ensemble augment) 매트릭스를 paper exact로 측정합니다. 5/11 18:50 기준 측정 완료 portfolio는 918+ JSON file (coverage 80.4%+)로, P9 InfoTheoretic (HyperLogLog) + P10 Density (KDE Parzen) 신규 paradigm anchor 18+ 측정 추가 진행 중입니다.

측정 자체의 정합성은 4측에서 paper review-grade로 검증되었습니다.

검증 축	결과
JSON integrity	918+ file 0 parse fail / 0 NaN-Inf / 0 corruption
Reproducibility	4 cells × 10 trials × 7 fields = 280/280 byte-identical (SHA-256 일치, deterministic 보장)
Paper verbatim line-by-line	Eq 1-6 + hyperparam 8건 ($m=0.9$ / $\eta_0=0.1$ / $\alpha=50$ / $\beta=1.5$ / $\gamma=0.99$ / period=50 / $N=385$ / HNSW $M=16$, $ef=400$) + queries (DEEP/SIFT=Q3,10,12 / SSN=Q3,9,10) + threshold (TPC-H < 0.86) + trim (lowest+highest 1개 제외 8 runs) 모두 100% 일치
Fig 12 영역 mean qe_trim	8 cells (DEEP/SIFT/SSN sf=100, YFCC sf=10, DEEP+WIKI cross sf=10, DEEP scale sf=1/10/100) 1.6180 vs paper 1.69 (-4.26%, measurement variance 범위 내 일치)

3. RQ1/RQ2/RQ3 paper exact 결과 종합

RQ1 (random sampling skew 부정확)

DEEP/SIFT/SimSearchNet++ × sf=100 + DEEP × sf=1/10의 5 cell × Bernoulli vs KM20 stratified × sel{0.01, 0.10} × 5 seed × 100 query 측정에서 mean Q-error gap **+3.74%** (Bernoulli > KM20 stratified). v5 시점 보고서의 "약 5%" 추정치에서 정확 측정으로 정정되었습니다.

RQ2 (분포 알 때 + Anti < Prop < Neyman paradox honest finding)

DEEP/SIFT × sf=100 × Bernoulli/Equal/Proportional/Neyman/Anti-Neyman 5-way ablation (paired n=455) 결과:

Mode	Mean Q-error	$\Delta\%$ vs Bernoulli
Bernoulli	1.748	(baseline)
Equal	1.644	-5.85%
Proportional	1.580	-9.53%
Neyman	1.595	-8.66% (Prop보다 worse)
Anti-Neyman	1.540	-11.81% (최저)

paper §V-B 이론 (Neyman optimal allocation σ -weighted)에 따르면 Neyman < Proportional이어야 하나, 측정 결과는 Anti < Prop < Neyman으로 paper 이론 위배 양상을 보입니다. 본 paradox의 root cause는 σ_j range 1.3-1.6× narrow (DEEP/SIFT/SSN sf=100 KM20 cluster의 cluster 내 sigma는 [0.18, 0.29] 범위) + N_i CV=0 (KM20 cluster 균등 size) → σ -weighted Neyman alloc cos_sim 0.99 (L1 diff 21-39 / 385 budget) → budget=385 hit count noise (~50/seed @ sel=0.1) > Neyman signal (~3 hits 차이)로, PartSupp PK가 uniform stratum density 분포로 σ -weighted optimization의 변별력이 marginal이 되는 boundary case입니다. v5 자문 의견 (Neyman 분배 변형 vs 새 방식)에 대한 본 연구의 finding은 "**분포 알면 prop allocation 답이며, σ range 큰 cluster imbalance 영역 (RQ3)에서 Neyman 우위 재검증 필요**"의 honest narrative로 RQ3 추정 framework로의 자연 전환을 정당화합니다.

RQ3 (분포 모를 때 9 paradigm × 56 method)

v5에서 자문해주신 5 paradigm framework는 5/10 8 agent algorithm audit (각 paradigm 별 reference fraud / algorithm misrepresentation 점검)을 거쳐 다음과 같이 9 paradigm으로 확장되었습니다.

Paradigm	Inductive bias	active method 수	CaseB anchor
P1 Cluster	유사 데이터 군집	9	mb_partial ★2
P2 Spatial	1D quantile 분할 (SFC, indexing)	12	hilbert_real + M6 zorder + M7 skilling
P3 Streaming	partial-fit / single-pass	6	chao_weighted M1
P4 DimReduction	고차원 → 저차원 투영	12	sparse_rp ★4 + ica_fastica
P5 QMC/Hashing	결정론적 균등	8	(LSH Wave 0 fail honest)
P6 Quantization	vector → codeword	6	rabitq_strat M10 (VLDB 2024)
P9 InfoTheoretic ★ 신규	sketch / cardinality 추정	1	hyperloglog (Flajolet 2007)
P10 Density ★ 신규	non-parametric density	1	kde_parzen (Parzen 1962)
P7 Subspace / P8 Graph	future work	0	CLIQUE 1998 / Leiden 2019 + Bao VLDB 2025

8 agent audit 결과 23 method가 algorithm misrepresentation 또는 reference fraud로 폐기/rename 권고되었으며 (예: vinecopula = rank+PCA1D / neuram = PCA1D 100% 동일 / kdtree = idx % n_strata random hash 등가 / ams_count_sketch = lsh line-by-line 동일), 본 연구는 audit 권고를 honest disclosure로 보고서 §5.3 Limitation에 명시하되 측정 결과 자체는 paradigm rollup의 honest comparison을 위해 보존합니다. ★3 hilbert (코드 차원 PCA 2D lex sort, Faloutsos 1989 Hilbert curve indexing 표명 ✗)는 코드 line 449에서 `("hilbert", "pca2d_lex") alias` 정직 명명되며, 진짜 Hilbert curve는 M6 zorder_morton + M7 skilling_hilbert + hilbert_real 3건의 paradigm anchor로 보강됩니다.

4. CaseA 무너짐 + CaseB ensemble climax (본 연구 핵심 contribution)

CaseA (단독 대체) 무너짐

CaseA mode (우리 method가 paper §V-B Bernoulli sampling step을 단독으로 대체) 측정 결과: - one-sided BH-FDR $\alpha=0.05$ outperform: **0/437 (0.0%)** ← 통계 무효 - Cliff's δ large worsening (≤ -0.474): 161 (36.8%) > Cliff's δ large better ($\geq +0.474$): 63 (14.4%)

paper §V-B Adaptive Sampling이 momentum 기반 동적 sample size 조정 + Q-error feedback loop를 통해 자체 robustness를 확보하기 때문에, 우리 method의 분포 인지 stratification이 KM20 oracle 가정 하에서도 single estimator로는 paper baseline을 surpass하지 못한다는 honest finding입니다. v5 시점 보고서의 4강 narrative (★1 HDBSCAN / ★2 MB_partial / ★3 Hilbert / ★4 sparse RP)가 5/8 시점 단일 dataset 비교에서는 Adaptive 대비 우위였으나, paper exact CaseA 측정에서는 통계적으로 무너집니다.

CaseB (ensemble augment) 통계 압도

CaseB mode (paper §V-B + 우리 method 산술 평균) 측정 결과: - **paired CaseB > CaseA: 92.9% (404/435)** — paper review-grade 우위 - **Cliff's δ large better: 63.5% (284/447)** - **Hedges' g large effect ($g \leq -0.8$): 56.4% (252/447)** - **One-sided BH-FDR $\alpha=0.05$ outperform: 45.0% (201/447)** - **Trial-level sign test: 740/1030 (71.8%) better trials, $p = 3.1e-46$ binomial**

paradigm rollup CaseB mean $\Delta\%$: P10 Density (KDE Parzen) -11.93% / **P9 InfoTheoretic (HyperLogLog) -7.60% (9 cells, 5/9 cells signif $p_{adj} < 0.05$)** / P3 Streaming (Chao 1982 weighted) -6.53% / P4 DimReduction -5.92% / **P2 Spatial -5.52% (★3 hilbert + M6/M7/hilbert_real anchor)** — 5 paradigm 모두 ensemble 가치를 통계 신뢰성 paper review-grade로 입증합니다. v5 자문 의견 (paradigm 개수 5 → 더 적게? 더 많게?)에 대한 본 연구의 finding은 "**P9 InfoTheoretic + P10 Density 신규 paradigm 추가가 narrative 강화에 큰 가치**"입니다.

5. 자문 요청 (4건)

첫째, CaseB ensemble augment 구조의 학술적 적절성

§1에서 정리한 paper §V-B Bernoulli + 우리 method KM20 stratified의 산술 평균 ensemble 구조에 대한 학술적 평가를 부탁드립니다. 두 estimator의 단순 산술 평균 ($(est1 + est2) / 2$)이 bias-variance trade-off의 textbook robust 구조이지만, 가중 평균 (예: $\alpha \times est1 + (1-\alpha) \times est2$ with method-specific α) 또는 query-conditional ensemble (cell 별 winner routing)이 5/27 발표 + 6/11 보고서에서 더 강력한 narrative가 될지 의견 부탁드립니다. 산업 환경 (실제 vector DB 운영)에서 CaseB ensemble의 sample budget 분배 (paper Eq 1 $N=385$ 를 두 estimator가 공유) 방식이 적절한지도 확인 부탁드립니다.

둘째, ★3 hilbert defect rectify의 학술 contribution narrative 적절성

v5에서 5 paradigm framework의 학술 정합성 (post-hoc rationalization 우려)을 지적해주신 의견을 반영하여, 본 연구는 5/10 8 agent algorithm audit으로 5 paradigm 내부의 reference fraud / algorithm misrepresentation을 점검하였습니다. 그 중 ★3 hilbert가 코드 차원에서 PCA 2D lex sort로 구현되어 Faloutsos 1989 *Hilbert curve indexing* (SIGMOD)의 진짜 locality 효과가 아닌 PCA proxy 효과를 측정하는 것임을 발견하고, alias `pca2d_lex` 정직 명명 + 진짜 Hilbert curve는 M6 zorder_morton (Morton 1966) + M7 skilling_hilbert (Skilling 2004 AIP Conf Proc 707, conditional swap simplification 1줄 disclosure) + hilbert_real (Wikipedia xy2d 표준) 3건의 paradigm anchor를 추가 측정하였습니다. 이 4건 비교가 "PCA proxy locality vs 진짜 Hilbert locality 분리 검증"의 학술 contribution으로 충분한지, paper review에서 reviewer가 "★3 hilbert defect를 그냥 폐기하지 왜 alias로 보존했는가" 질문 시 답변 narrative 권고도 부탁드립니다.

셋째, RQ2 Neyman paradox honest finding의 학술 기여 위치

§3의 Anti < Prop < Neyman paradox는 paper §V-B 이론 (Neyman optimal allocation)의 boundary case로 σ_j range narrow + N_i CV=0의 자연 결과인 honest finding입니다. v5에서 Neyman 분배 next direction (변형 vs 새 방식) 자문 의견에 대해, 본 연구는 "Neyman 분배 자체는 paper 이론대로 정확하지만, σ range 좁은 cluster (KM20 oracle on PartSupp PK)에서는 변별력이 marginal하고, σ range 큰 cluster imbalance 영역 (RQ3 추정 framework)에서 Neyman 우위 재검증이 필요"의 narrative로 정정합니다. 이 honest finding이 "분포 알면 prop allocation 답" (RQ2 결론) + "분포 모르면 RQ3 ensemble augment" (RQ3 자연 전환)의 두 단계 narrative를 정당화하는 학술 기여로 충분한지 의견 부탁드립니다.

넷째, Future work 우선순위

5/27 발표 + 6/11 보고서의 §6.2 Future work 우선순위로 다음 8건을 제시하려 합니다.

1. **P7 Subspace clustering** (CLIQUE Agrawal 1998) — high-D subspace clustering paradigm 추가

2. **P8 Graph-based** (Leiden Traag 2019 + **Bao et al. VLDB 2025** Exqutor HNSW를 분포 정보 추출 용도로 재활용) — 5/27 발표 climax 직전 추가 paradigm
3. multi-table aware ensemble (단일 → 멀티 일반화, joint-aware clustering)
4. SF=100 cross-scale full validation (현재 80.4% coverage → 100% target)
5. RQ2 σ range 큰 cluster imbalance 영역에서 Neyman 우위 재검증
6. CaseB ensemble의 가중 평균 / query-conditional routing (자문 첫째 영역)
7. ★3 hilbert defect rectify narrative의 paper acceptance 검증
8. 2024-25 SIGMOD/VLDB integration (RaBitQ Gao-Lin VLDB 2024 / PRICE Zeng 2024 / LpBound SIGMOD 2025 / PDX SIGMOD 2025)

이 8건의 우선순위와 5/27 발표 단일 slide (S15 Future Work)에 어떻게 압축하면 좋을지 의견 부탁드립니다. 또한 멘토님이 산업 관점에서 본 연구의 가장 큰 한계 또는 추가 검증이 필요한 영역으로 보시는 것이 무엇인지 의견도 부탁드립니다 (Limitation 18종 honest disclosure 외).

가능하시다면 **5월 20일 (화)** 까지 회신을 받을 수 있으면 5/27 발표에 충분히 반영하겠습니다.

감사합니다.

속도는벡터 팀 조현빈 드림

부록 — 본 메일 작성 시점 자료 위치

본 메일 narrative의 학술 detail은 다음 자료에서 확인 가능합니다.

- 요약 1장: [submission/_drafts/팀원_요약_20260511.{md,pdf}](#)
- 학술 상세 (10p): [submission/_drafts/팀원_이해용_종합_20260511.{md,pdf}](#)
- 5/15 박광현 미팅 자료: [submission/_drafts/박광현_5월15일_미팅/](#) (slide draft + deck plan + README)
- 5/27 storyline v2.5: [plans/5_27_storyline_draft_20260511_1410.md](#)
- 6/11 보고서 outline v3 plan + 본문 sketch 4건: [plans/6_11_*.md](#)
- 분석 본체 REPORT v8.5: [/mnt/hdd0/home/capstone2026/cache/rq3/paper_exact/REPORT_paper_exact.md](#) (1285 line)
- figures 6건: [experiments/figures/paper_exact_v7/F1~F6.png](#) (Apple SD Gothic Neo)

작성: 2026-05-11 19:30 KST

발송 예정: 2026-05-16~5/20 (5/15 박광현 교수님 미팅 confirm 결과 반영 후)