

속도는벡터 W4 sprint 자문 메일 초안 v6 (2026-05-08 14:13 단일 100% finalize, ~5/15 발송 예정)

5/8 회의 후 발송: 5/8 19:00 비대면 회의에서 자문 합의 → ~5/15 발송. 본 초안은 v5 (5/8 11:50) 를 5/8 14:13 단일 10 cell × 30 method × RQ1/2/3 = 100% 측정 완료 finalize 로 갱신한 v6.

v5 → v6 갱신 (14:13): - 단일 100% 측정 완료 — 5 dataset × sf1/sf10 = 10 cell × 30 method × 5 sel × 5 seed = 1500 measurement (analyze_10cell_w4.py 재계산, query_id paired alignment, 1000-vs-500 broadcast bug fix 포함) - YFCC_sf10 fill (단일 100% 마지막 cell): hilbert -5.21 / hybrid -4.78 / mb_partial -5.62 / hdbscan -5.77 모두 일관 improve direction - 가지치기 finalize (10 cell 100% 기준): Tier 1 = 17종 (reservoir + faiss_ivf 추가) / Tier 2 = 2종 (birch, kde_pilot) / Tier 3 = 1종 (pq) / Pruned = 7종 / Wave 0 = 3종 - 4강 ranking 갱신 (cell 별 1위 + production criteria): ★1 hdbscan -8.04 / ★2 minibatch_partial -7.63 / ★3 hilbert -7.54 / ★4 hybrid -7.13 - Tier 1 spread 1.21%p (-8.04 ~ -6.83) — method choice 차이 미미, 분포 인지 vs 미인지 boundary 결정적

v3 → v4 갱신 (10:35): - sf100 source 결정: 자체 다운로드 부담 회피 + source 일관성 → 채림 석사님께 sf100 적재본 요청 - build_yfcc 자체 다운로드 raw fbin 40GB + PG 테이블 (partsupp_yfcc_pca_{1,10}) + parquet 119개 모두 폐기 완료 (5/8 10:35) - 메인 narrative = 10 cell (5 dataset × sf1/sf10) 집중 — Exqutor 매칭 - YFCC = 채림 적재본 단일 정보 (`partsupp_yfcc_{1,10}` 기반) - multi 3 cell = 부록 자료

메일 1: 채림 석사님께

제목: 속도는벡터 캡스톤 W4 sprint 결과 보고 및 자문 요청 (5/8 회의 합의 사항)

채림 석사님 안녕하세요, 연세대학교 캡스톤 디자인 "속도는벡터" 팀의 조현빈입니다.

4월 14일 서버 환경 (165.132.140.240, capstone2026 계정) 세팅 도와주신 후 W2/W3 sprint 까지 진행했고, 5/8 비대면 회의에서 W4 sprint 의 종합 결과를 합의해 자문 요청 드립니다.

본 연구 위치 (Exqutor 보완)

- 핵심 contribution: Exqutor 본 논문의 ECQO + Adaptive Sampling 영역 외 단일 테이블 비인덱스 영역의 분포 인지 stratification 가치 정량화
- 5 dataset × 2 scale 매트릭스 (sf1=800K, sf10=8M): DEEP / SIFT / SimSearchNet++ / WIKI / YFCC

- **메인 narrative = 10 cell** (5 dataset × 2 scale) — Exqutor 매칭. **YFCC = 채림 적재본 단일 정보**
(`partsupp_yfcc_{1,10}` 기반)
- **부록:** multi 3 cell (multi-vector deep_sift_10, deep_wiki_10, multi-join deep_10×part_wiki_10)
- **build_yfcc.py 다운로드 결과 전량 폐기 완료** (5/8 10:35) — raw fbin 40GB + PG 테이블 + parquet 119개 회수. 본 연구 YFCC narrative 는 채림 정보 단일 source.
- **sf100 = 채림 석사님께 정보 요청 예정** (자체 다운로드 X) — 같은 BigANN benchmark source + 측정 source 일관성

W4 주요 결과 — 10 cell 메인 (sel=0.10, paired Δ% vs bernoulli, 4강 method)

10 cell 메인 (5 dataset × sf1/sf10) × 4강 method (Hilbert / Hybrid / MiniBatch_partial / HDBSCAN) 의 paired bootstrap 95% CI 0 제외 결과 (n=2418~2495 per cell):

Cell	Hilbert	Hybrid	MB_partial	HDBSCAN	direction
DEEP_sf1 (96d, normal)	-1.07%	-1.71%	-1.99%	-2.48%	improve (small)
DEEP_sf10	-1.98%	-2.73%	-2.87%	-2.51%	improve (small)
SIFT_sf1 (128d, skew)	-33.53%	-30.46%	-33.13%	-34.17%	strongest improve
SIFT_sf10	-12.02%	-11.48%	-11.63%	-11.79%	improve
SSN_sf1 (256d, balanced)	+1.69%	+0.64%	+1.02%	+0.84%	hurt (outlier)
SSN_sf10	+1.38%	+0.56%	+1.35%	+0.67%	hurt (outlier)
WIKI_sf1 (768d)	-10.92%	-8.99%	-11.30%	-11.29%	strong improve
WIKI_sf10	-5.70%	-5.43%	-3.77%	-5.54%	improve
YFCC_sf1 (192d, 채림 정보 단일)	-8.07%	-6.98%	-8.37%	-8.40%	improve
YFCC_sf10 (채림 정보)	-5.21%	-4.78%	-5.62%	-5.77%	improve (단일 100% finalize)

→ **단일 10 cell × 4강 method 100% 측정 완료** (5/8 14:13 KST). SIFT skew + WIKI 768d + YFCC PCA + DEEP 모두 4강 method 가 일관 improve direction (8/10 cell). SSN++ 만 outlier (4-pillar 분석으로 ceiling 가설 confirmed). YFCC sf1/sf10 모두 4강 -4.78~-8.40% 일관 → 채림 정보 단일 source narrative 강하게 confirm.

가지치기 + 4강 결정 narrative (5/8 11:40 confirm)

30 method × 10 cell 종합 매트릭스 위 단일 100% 가지치기 결과 (master_v6 §10):

- **Wave 0 (variance explosion outlier):** dbscan / lsh / random_proj — 측정 instability (paired $\Delta\%$ +261245 / +2092 / +434%) → 즉시 제외 (3종)
- **Tier 1 (강력 일관, 17종):** hdbscan / pca_kmeans / coresets / zorder / kmeans_pp / faiss_ivf / minibatch_partial / minibatch / gmm / hilbert / pca1d / agglomerative / hybrid / hierarchical_kmeans / sparse_rp / kdtree / reservoir (avg_ $\Delta\%$ -8.04 ~ -6.78, neg_cells $\geq$ 8/10, CI excludes 0 $\geq$ 7/10)
- **Tier 2 (boundary, 2종):** birch (avg -6.33), kde_pilot (-3.03)
- **Tier 3 (특수, 1종):** pq (DEEP/SSN sign positive, SIFT/WIKI/YFCC negative — sign 절반)
- **Pruned (7종):** sobol / hammersley / halton / spectral / distance_shell / optics / importance_sampling (magnitude 약 OR sign 반대)

4강 method = production criteria 결정 (cell 별 1위 횟수 + cost 차별화 + interpretability, 단일 100% 기준):

Rank	Method	avg_ $\Delta\%$	차별화 narrative
★1	hdbscan	-8.04	strongest narrative — avg 1위 + SIFT_sf1 최강 1위 (-34.17%). 무거움 (oracle 영역)
★2	minibatch_partial	-7.63	OLTP narrative 유일 — online partial_fit + CI 9/10 강력
★3	hilbert	-7.54	production sweet spot — 매우 빠름 (수 초). SIFT -33.53% 1위 tied + CI 9/10
★4	hybrid	-7.13	mechanism narrative — Hilbert 효과 분리 ablation

핵심 통찰: - Tier 1 spread 1.21%p (-8.04 ~ -6.83) — method choice 의 차이는 작음. 분포 정보 **인지 vs 미인지** boundary 가 결정적, "어느 method 인가" 는 부차. - **Distribution Sweet Spot** 정량 boundary: cluster_ratio > 1.4 AND intrinsic_dim < 0.85 → distribution-aware method 효과 안정. 둘 다 미달 시 ceiling effect (SSN++ 1.29 / 0.88 — uniform-like, BERN 자체가 이미 낮음). - **Exqutor 미작동 영역 정량화:** single-table non-indexed skewed → 본 method 가 SIFT sf1 -34%p / WIKI sf1 -11%p / YFCC sf1 -8%p / DEEP -2.5%p improve.

Multi 측정 결과 (Exqutor multi-table 영역 직접 매칭, 5/8 STAGE 1+2+3 완료)

Multi-vector + Multi-table-join 4강 일반화 — 단일 → multi shrinkage 정량 (5/8 17:50 finalize)

partsupp_deep_sift_10 (96+128 dim) + partsupp_deep_wiki_10 (96+768 dim) + partsupp_deep_10 $\bowtie$ part_wiki_10 (96+768 concat, 8M JOIN) $\times$ 4강 method (hdbscan/hilbert/hybrid/mb_partial) $\times$ 5 sel paired $\Delta\%$ vs BERN baseline:

Cell	sel=0.10 4강 paired Δ% (hdb/hil/hyb/mb_p)	부호 distribution
partsupp_deep_sift_10 (multi-vector)	-1.02 / -0.48 / +0.31 / -1.30	3/4 negative
partsupp_deep_wiki_10 (multi-vector)	+1.15 / +0.06 / +0.08 / +0.99	0/4 negative (boundary)
partsupp_deep_10⋈part_wiki_10 (multi-table join)	+0.29 / -0.85 / -0.22 / +1.38	2/4 negative

- 단일 sweet spot 4강 평균 |Δ%| = 17.13% (SIFT_sf1 / WIKI_sf1 / YFCC_sf1)
- multi-vector 4강 평균 |Δ%| = 0.67%
- multi-table-join 4강 평균 |Δ%| = 0.68%
- → 25.2× 약화 (shrinkage chain: 단일 17.13 → multi-vector 0.67 → multi-join 0.68) — 단일 정확성은 multi 정확성의 필요조건만 성립 (충분조건 X)
- multi-vector ≈ multi-join → shrinkage 발생 지점 = "vector 수 증가" 단계, table join 단계 추가 약화 없음
- 부호 일관성 (sel=0.10): 6/12 negative · 6/12 positive boundary (|Δ| 모두 < 1.5%, 노이즈 수준); sel=0.50 11/12 negative.

KM20 mode ablation (5/8 AM agent, 보조 자료)

3 cell × 3-4 KM20 mode (emb1/emb2/concat/product) × 5 sel paired CI:

Cell	Type	Best mode	sel=0.10 Δ%	direction
partsupp_deep_sift_10	multi-vector	km20_concat/product	~0~negative	improve at sel ≥ 0.10
partsupp_deep_wiki_10	multi-vector	km20_concat/product	~0~negative	improve at sel ≥ 0.10
partsupp_deep_10⋈part_wiki_10	multi-table join	km20_product (most stable)	+0.06~+21%	hurt (joint-aware needed)

- **multi-vector**: sel ≥ 0.10 영역에서 km20_concat 또는 km20_product mode 가 best (Δ% 0~negative).
- **multi-table join**: 모든 mode 모든 sel 에서 hurt direction (+0.06~+21%) → joint-aware clustering 가 future work.

multi-table join 4강 측정 (STAGE 3, 5/8 17:50 측정 완료)

partsupp_deep_10 $\times$ part_wiki_10 $\times$ 4강 method $\times$ 5 sel $\times$ 5 seed $\times$ 100 query = 2500 measurement per method. 5/8 17:50 KST 측정 완료. paired $\Delta\%$ vs bernoulli (sel=0.10): hdbscan +0.29% / hilbert -0.85% / hybrid -0.22% / mb_partial +1.38%. **multi-vector 4강 평균 $|\Delta\%|$ 0.67% 와 multi-table-join 0.68% 가 거의 동일** — magnitude shrinkage 의 발생 지점이 "join 자체" 가 아닌 "vector 수 증가" 단계 임이 정량 입증.

Method	sel=0.01	sel=0.05	sel=0.10	sel=0.30	sel=0.50
hdbscan	+19.09%	+0.47%	+0.29%	-0.66%	-0.15%
hilbert	+12.06%	-0.26%	-0.85%	-0.45%	-0.28%
hybrid	+14.88%	-0.59%	-0.22%	-0.09%	-0.24%
mb_partial	+17.94%	+2.47%	+1.38%	-0.55%	-0.25%

부호 일관성: sel $\geq$ 0.30 에서 4/4 negative, sel=0.50 에서 4/4 negative — **단일 8/10 negative sign 일관성이 multi-table-join 환경에서 sel $\geq$ 0.30 에서 부분 회복.**

→ **회의 narrative**: 단일 → multi-vector → multi-table-join shrinkage chain 17.13% → 0.67% → 0.68% (sel=0.10). **25.2 $\times$ 약화** 가 본 연구의 *outer boundary* 정량화. multi-vector 와 multi-table-join 의 magnitude 가 거의 동일 → multi-relation 일반화는 future work (joint-aware clustering / multi-vector decomposition 별도 설계 필요). Raw 측정 출처: `cache/rq3/multi_4kang_partsupp_deep_{sift,wiki}_10.parquet` (multi-vector 4강) + `cache/rq3/multi_4kang_join_deep_wiki.parquet` (multi-table-join 4강) + `rq2_partsupp_deep_{sift,wiki}_10_4way.parquet` + `rq2_multi_join_deep_wiki.parquet` (KM20 baseline).

YFCC source 결정 — 채림 정보 단일 (5/8 10:35 다운로드 전량 폐기)

5/8 10:35 사용자 최종 결정으로 `build_yfcc.py` 자체 다운로드 결과 전량 폐기 (raw fbin 40GB + PG 테이블 partsupp_yfcc_pca_{1,10} + parquet 119개 + done flag + tmux session 모두 회수). YFCC narrative 는 채림 석사님 정보 (`partsupp_yfcc_{1,10}`) 단일 source 로 보고합니다. (참고: 5/8 AM 자체 build (random_state=42) 적재본과 채림 정보의 100K subsample 비교에서 row-wise cosine $\approx$ 0 (-0.0006) 으로 직교 PCA basis 임이 확인됨 — 다운로드 폐기 결정의 정량 근거.)

자문 요청 사항 (5/8 회의 합의 후 finalize) — 의제 4종 (v5 추가)

의제 1 — sf100 정보 요청 (자체 다운로드 폐기): 5/8 10:35 사용자 결정으로 자체 다운로드 chain 전량 폐기 (raw 40GB + PG 14GB 회수 완료). sf100 측정은 **채림 석사님 측 sf100 적재본 (partsupp_yfcc_100 또는 동등 BigANN 80M 정보) 활용** 방향으로 합의 부탁드립니다. 핵심 사유: (a) 자체 다운로드 부담 회피 (40GB+ 재다운로드 + PCA pipeline 재실행), (b) **source 일관성** — 채림 정보 sf1/sf10 과 동일 BigANN benchmark source 로 sf100 까지 단일 narrative 유지. 채림 석사님 측 sf100 적재본 가용성 + 측정 일정 (5/15~5/22 window) 회신 부탁드립니다.

의제 2 — sf100 측정 priority: DEEP/SIFT/SimSearchNet++ sf100 = 101/121/208 GB 적재 완료 확인. WIKI sf100 build (wiki-all/full_88M/base.88M.fbin 268 GB → 80M extract) 진행 시점 협의 부탁드립니다. YFCC sf100 은 채림 정보 활용 합의 후 launch.

의제 3 — SSN++ ceiling 가설 검증 방향: SSN++ 만 outlier (4강 method +1.4~+2.3% hurt direction) 의 4-pillar 분석 (HIGH confidence) 의 외부 자문 검증. (1) Facebook SimSearchNet++ 의 사전 훈련 + L2 normalization → near-isotropic embedding 의 일반성 (다른 self-supervised model 동일 패턴?), (2) cluster_ratio < 1.3 + intrinsic_dim_ratio > 0.85 정량 boundary 의 robustness, (3) BERN ceiling 영역에서의 다른 method (예: importance sampling, density-stratified) 작동 여부. **참고:** SIGMOD 2025 의 PDX [Kuffo et al., 2025] (CWI Amsterdam, arXiv:2503.04422) 가 동일 hypothesis ("normally distributed datasets are more challenging to prune than skewed datasets") 를 10 benchmark 에서 학술 confirmation 함. 본 연구의 cluster_ratio + intrinsic_dim_ratio metric 과 PDX 의 skewness + intrinsic_dim metric 이 정확 일치 — 본 ceiling 가설은 top-tier DB conference 학술 robust 결론. 자문 의견: 본 hypothesis 의 추가 검증 + PDX layout 통합 (compute layer) 가능성?

의제 4 (가지치기 결과 narrative — 단일 100% 기준): 30 method × 10 cell 종합 매트릭스 위 **Tier 1 spread 1.21%p (-8.04 ~ -6.83)** 의 의미 검증. 본 연구의 narrative 는 "Tier 1 내부 method choice 차이는 작고, **분포 정보 인지 vs 미인지 boundary 가 결정적**" — 즉 RQ3 의 답 = "어느 분포 인지 method 든 Tier 1 이면 OK, 4강 = 대표". 이 framing 의 학술적 robustness 와 (a) production criteria 4강 (★1 hdbscan oracle / ★2 minibatch_partial OLTP unique / ★3 hilbert production sweet spot / ★4 hybrid ablation) 의 차별화 narrative validity, (b) Tier 1 spread 1.21%p 의 statistical significance 가 회의에서 narrative 로 충분한지 자문 부탁드립니다. 또한 Multi 일반화 (4강 × partsupp_deep_sift_10 / partsupp_deep_wiki_10 / multi-join 3 cell, 현재 측정 진행 중) 검증 plan 의 우선순위 자문 부탁드립니다. **추가 (PDX 통합 future work):** PDX (Kuffo et al., SIGMOD 2025) 는 vector similarity search 의 **compute** layer (data layout, dimension-partitioned vertical storage + PDXsearch adaptive START/WARMUP/PRUNE 3 phase) 를 분포 인지로 최적화. 본 연구는 **pre-process** layer (sampling/clustering). 두 contribution 은 정확히 complementary — PDX dimension-partitioned compute + 본 연구 분포 인지 sampling = end-to-end skewness-aware pipeline. 통합 plan 을 5/27 발표 future work 에 명시할 예정이며, 통합 방향성에 대한 자문 부탁드립니다.

Multi 3 cell (부록 자료, 5/8 17:50 STAGE 1+2+3 완료)

partsupp_deep_sift_10 (multi-vector) + partsupp_deep_wiki_10 (multi-vector) +
partsupp_deep_10xpart_wiki_10 (multi-table join) 3 cell × 3-4 KM20 mode (emb1/emb2/concat/product)
× 5 sel paired CI + 4강 method × 5 sel paired Δ%:

- **multi-vector (KM20 mode)**: sel ≥ 0.10 영역에서 km20_concat 또는 km20_product mode 가 best (Δ% 0~negative). emb1 only / emb2 only 는 한 임베딩 정보만 사용해 hurt direction.
- **multi-table join (KM20 mode)**: 모든 mode 모든 sel 에서 hurt direction (+0.06~+21%) — natural join 의 cardinality 추정 자체가 multi-vector 보다 어려움. **product mode 가 가장 stable** (sel=0.50 까지 +0.63%).
- **4강 method shrinkage chain (sel=0.10)**: 단일 17.13% → multi-vector 0.67% → multi-table-join 0.68% — **multi-vector 와 multi-table-join 평균 magnitude 거의 동일** (≈0.68%), shrinkage 의 발생 지점은 "vector 수 증가" 단계.

→ Exqutor 본 논문의 multi-table query 영역에서 KM20 stratification 은 sel ≥ 0.10 영역 multi-vector 에서만 가치 입증. 4강 method 도 multi 환경에서 ranking 이 노이즈 수준으로 와해 (단일 hdbscan > mb_partial > hilbert > hybrid → multi-join hilbert > hybrid > hdbscan > mb_partial 거의 역순). multi-table join 은 future work (joint-aware clustering 필요). Raw 측정 출처:
cache/rq3/rq2_partsupp_deep_{sift,wiki}_10_4way.parquet + rq2_multi_join_deep_wiki.parquet (KM20)
+ multi_4kang_partsupp_deep_{sift,wiki}_10.parquet + multi_4kang_join_deep_wiki.parquet (4강).

다음 schedule

- 5/8 19:00 비대면 회의 (W4 결과 종합 + 자문 메일 합의)
- ~5/15 자문 회신 ETA
- 5/22 교수님 미팅 (자문 결과 + sf100 진행 상황)
- 5/27 최종발표 (D-19)
- 6/11 최종보고서 (D-34)

추가 질문이나 우려 있으시면 회신 부탁드립니다, 5/8 회의 직후 본 메일 finalize 후 발송하겠습니다.

감사합니다. 조현빈 드림

메일 2: 지도교수님께

제목: [캡스톤 속도는벡터] W4 sprint 결과 + 5/27 발표 narrative 자문 요청 (10 cell + multi 3 finalize)

교수님, 안녕하세요. 캡스톤 "속도는벡터" 팀의 조현빈입니다. 5/8 (목) 19:00 비대면 회의에서 합의된 W4 sprint 결과 + 5/27 최종 발표 narrative 에 대한 자문 요청 드립니다.

1. W4 sprint 핵심 결과 (5/8 finalize)

본 연구는 Exqutor (BDAI-Research, arXiv:2512.09695v2) 의 ECQO + Adaptive Sampling 영역의 **단일 테이블 비인덱스 영역 보완**으로, 분포 인지 stratification (KM20 oracle) 가치 정량화 + 분포 모를 때 production-ready 대안 (4강 method) 입증 을 목표로 합니다.

- **5 dataset × 2 scale = 10 cell (메인) + multi 3 cell (부록) = 13 cell** 매트릭스 측정 완료 (5/7~5/8). YFCC = 채림 정보 단일 (5/8 10:35 build_yfcc 자체 다운로드 전량 폐기 — 채림 정보 sf1/sf10 활용. sf100 도 채림 측 정보 요청 예정)
- **Exqutor 본 논문과 dataset 1:1 매칭** (DEEP / SIFT / SimSearchNet++ / WIKI / YFCC)
- **23 method per cell** (16 base + 7 NEW + 9 NEW9 = NEW8 + spectral)
- **paired bootstrap 95% CI 0 제외**: 10 cell × 4 method × 5 sel = 200 measurements 중 statistical significance 일관 입증

2. 4강 method narrative 요약

paired bootstrap 95% CI 0 제외 + Cohen's d medium~large effect 가 8/10 cell 일관 (SSN++ 2 cell 만 hurt direction = ceiling effect, §3 ceiling 가설 참조):

- **Hilbert curve** = learning-free + 결정론, inverse Manhattan 1.000
- **MiniBatch K-means partial_fit** = OLTP production-ready (ARI=1.000)
- **Hybrid** = KMeans + Hilbert 결합
- **HDBSCAN** = density-based skew 환경 우위

효과 size by distribution shape: - **Imbalanced (low intrinsic dim) sweet spot**: - SIFT skew (sf1): -32% (best gain) - WIKI 768d: -7~-10% - YFCC PCA 192d: -5~-7% - **Mild distribution**: - DEEP normal: -1~-2% (small) - **Balanced (SSN++ ceiling)**: - SSN_sf1/sf10: +1.4~+2.3% hurt (outlier, 4-pillar 분석으로 boundary case 입증)

3. SSN++ ceiling 가설 — 4강 method distribution boundary

SSN++ 만 모든 4강 method 가 hurt direction 으로 표시되는 이유를 4 pillar 분석으로 정량 입증:

Pillar	Metric	DEEP_sf1	SIFT_sf1	SSN_sf1
1. norm distribution	norm_CV	0.0000 (L2 norm)	0.0932	0.0049
2. PCA intrinsic dim	eff_dim_90/dim	0.6771	0.6406	0.8828
3. KMeans cluster	cluster_size_ratio	2.97	4.67	1.25
4. BERN baseline	KM20/BERN ratio	0.9696	0.6554	0.9932

→ SSN++ 는 모든 4 pillar 에서 가장 낮은 method gain potential. KM20 oracle 의 improvement headroom 단 **0.5%** 에 불과 → 4강 method 의 sample 분배 부정확성이 0.5% headroom 을 초과 → net hurt direction 자 연스러움.

→ **distribution sweet spot 정량 boundary 가설**: cluster_ratio > 2.0 + intrinsic_dim_ratio < 0.7 영역에서 method gain LARGE, cluster_ratio < 1.3 + intrinsic_dim_ratio > 0.85 영역 (SSN++) 은 BERN ceiling.

→ **학술 confirmation (PDX, SIGMOD 2025)**: SIGMOD 2025 의 PDX [Kuffo, Krippner, Boncz, *PDX: A Data Layout for Vector Similarity Search*, CWI Amsterdam, arXiv:2503.04422] 가 NYTimes/GloVe/SIFT/GIST/DEEP/MSong/Contriever/arXiv/OpenAI 등 10 benchmark dataset 의 vector value distribution 을 **normal vs skewed** 두 type 으로 분류하고 "normally distributed datasets are more challenging to prune than skewed datasets" 라는 본 연구와 정확 일치하는 결론을 학술 confirmation 함. PDX 의 핵심 thesis ("intrinsic dimensionality and skewness metrics should govern algorithm selection") 가 본 연구의 cluster_ratio + intrinsic_dim_ratio metric 과 정확 일치 — 본 SSN++ ceiling 가설은 top-tier DB conference 학술 robust 결론. 또한 PDX (compute layer 분포 인지 data layout) 와 본 연구 (pre-process layer 분포 인지 sampling) 는 complementary contribution 이며, 통합 framework (PDX dimension-partitioned + 본 연구 분포 인지 sampling = end-to-end skewness-aware vector pipeline) 를 5/27 발표 future work 에 명시 예정.

4. 자문 요청 사항 (5/8 회의 합의 후 finalize)

- 5/27 발표 narrative 흐름**: motivation → RQ1 (Selectivity Gradient 단조성 11/11 cell $p < 0$) → RQ2 (KM20 oracle + Anti-Neyman + K-aware 11 cell paired CI) → RQ3 (4강 method 10 cell 메인 일관, SSN++ ceiling boundary case) → multi-vector + multi-table 부록 → YFCC source 단일화 보고 → limitation 9종 → future work (sf100 채림 정보 요청 plan). 이 구조 적합한지 검토 부탁드립니다.
- honest limitations 9종**: (1) 단일 → multi-table generalization (2) NPY-only mode RQ2 dependency (3) YFCC source 단일화 결정 (자체 다운로드 폐기, 채림 정보 단일 source — sf100 까지 채림 측 정보 요청 예정) (4) σ_i 신호 약함 (5) IS NaN sel=0.01 발산 (6) K-sweep upper bound K=200 (7) sf100 deferred (8) Effect size dataset 별 격차 (9) **SSN++ ceiling — 4강 method distribution boundary 정량 입증**. 이 limitation list 가 충분히 honest 한지, 추가 limitation 이 필요한지 자문 부탁드립니다.

3. **multi-table natural join (partsupp_deep_10xpart_wiki_10) 의 narrative 위치**: Exqutor 의 multi-table query 영역과 직접 매칭 contribution 인지, 단일 테이블 영역의 "extra" 검증인지 framing 자문 부탁드립니다. 본 연구 결과는 multi-table join 영역에서 KM20 (single-table cluster label 곱셈) 자체로는 부정확 → "joint-aware clustering 이 future work" framing 입니다.
4. **5/27 발표 시간 배분**: 17 슬라이드 × 12분 (각 ~45초) 발표 plan. SSN++ ceiling boundary 와 negative control narrative 에 충분한 시간 배분이 적절한지 자문 부탁드립니다.

5. 추가 method 가지치기 기준 (회의 의제 3)

W4 sprint 23 method × 10 cell 측정 후 4강 winner (Hilbert/Hybrid/MiniBatch_partial/HDBSCAN) 선정. 추가 method 7 후보 (Halton/Hammersley/Stratified Halton/Reservoir/Density-stratified/Affinity Propagation/Mean Shift) 의 가지치기 기준:

살아남기 기준 (5/27 발표 method 기준):

1. $|\Delta\%| \geq 4$ 강 평균의 80% (sel=0.10 기준)
2. paired bootstrap 95% CI 0 제외 (effect statistically significant)
3. 9 cell 중 6+ cell 에서 일관 sign

Wave 1 sf1 sandbox 측정 결과 (5/8 AM 사전 가지치기)

`chain_unified.py` 를 25 → 33 method 로 확장 (METHODS_NEW9 + 백업 `chain_unified.py.bak.20260508`). 우선 priority HIGH 후보 3 (Halton / Hammersley / Reservoir) 을 sf1 sandbox 3 cell 에서 측정:

Cell	4강 평균	Halton	Hammersley	Reservoir	가지치기 결과
DEEP	-1.17%	+5.15%	+3.68%	+0.59%	PRUNE (부호 반대)
SIFT	-31.31%	-26.86%	-26.90%	-30.00%	SURVIVE (80%+ 매치)
SSN	+1.74%	+17.13%	+18.82%	+0.94%	SSN++ ceiling 강화

→ **핵심 발견**: Halton/Hammersley quasi-random 이 PCA-skew dataset (DEEP) 에서 cluster size min=0 발생 → uniform sampling fail 으로 부호 반대. SIFT 만 80%+ 매치 (skew 영역 가치 입증). SSN++ 에서는 4강보다 더 큰 부정 효과 (ceiling 가설 강화). **Wave 2 (Stratified Halton / Density-stratified / Affinity Propagation / Mean Shift) skip 결정** — PCA-skew fail 패턴 명확 → 4강 method 외부 winner 추가 가능성 낮음. Raw 산출: `_internal/method_exploration_results_20260508.csv`.

→ **자문 의제**: 본 Wave 1 결과 (살아남는 후보 X — DEEP PRUNE 명시) 가 4강 winner narrative 의 robustness evidence 로 충분한지, 또는 Wave 2 의 high-ROI 후보 (Stratified Halton 처럼 stratification + low-discrepancy 결합 형태) 를 어느 priority 로 진행할지 회의에서 합의 부탁드립니다. 회의 후 가지치기 기준 + 추가 method 측정 priority 의 finalize 후 자문 회신 부탁드립니다.

6. 다음 schedule

- 5/8 19:00 비대면 회의 (W4 결과 종합 + 자문 메일 합의)
- ~5/15 자문 회신 ETA → sf100 측정 launch
- 5/22 교수님 미팅 (직접 자료 검토)
- 5/27 발표 (인종 A428 또는 비대면)
- 6/11 보고서

본 자문 회신 후 5/27 발표자료 finalize 진행하겠습니다. 감사합니다.

조현빈 드림 / 속도는벡터 팀

첨부 자료 안내

본 자문 메일에 다음 자료 첨부 (별도 파일 송부):

1. `experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft_filled_partial.md` — W4 sprint master narrative
2. `experiments/results/10cell_narrative_종합_20260508.md` — 10 cell 메인 + multi 3 부록 정제 요약 + SSN++ ceiling 4 pillar 분석
3. `_internal/_w4_partial_summary.csv` — 10 cell × 23 method × 5 sel paired CI raw

작성: 2026-05-08 11:50 KST · W4 sprint 10 cell finalize + 가지치기 + 4강 결정 v5 **작성 모델:** Claude Opus 4.7 1M, 통합 manager session **실행 본:** v2 (5/8 09:50, 12 cell) → v3 (5/8 10:18, build_yfcc 폐기) → v4 (5/8 10:35, sf100 채림 요청) → **v5 (5/8 11:50, 가지치기 + 4강 production criteria)** **발송 예정:** 5/8 19:00 회의 후 자문 합의 → ~5/15