

Exqutor 벡터 카디널리티 추정의 단일 테이블 사각지대와 Skew-Aware Sampling

Pivot A BERNOULLI 교체 + Pivot C KM20 Stratified — 3 데이터셋 5-seed CI 검증

속도는 벡터

박세은 (팀장) · 강재현 · 조현빈 · 이동욱

연세대학교 컴퓨터과학과 · 2026-1 캡스톤 디자인

지도교수 박광현 · 지도연구원 임채림 석사

Table of Contents

01

Problem

벡터 카디널리티 추정의 사각지대

02

Background

Exqutor 의 두 해법과 한계

03

Our Approach

Skew-Aware Sampling 의 차별성

04

Experiments

RQ1 · RQ2 · RQ3 설계와 결과

05

Plan

현재 진행 상황 및 향후 계획

1. 해결하고자 하는 문제

벡터 조건의 선택도를 시스템마다 "고정 비율"로 추정한다

기존 시스템 — 고정 비율 추정

pgvector

33.3%

PostgreSQL operator default

VBASE

50.0%

fixed estimator

DuckDB

100%

scan all rows

실제 — 0.001% ~ 90% 의 광범위한 분포

- 실제 선택도는 query 에 따라 0.001% ~ 90% 의 광범위한 분포
- 옵티마이저가 잘못된 실행 계획 선택 → nested loop vs hash join, index 사용 여부
- 이미지 검색 / 추천 / RAG retrieval 등 단일 테이블 vector range query 에서 빈번

"기술적으로 좋은 추정" vs "실행 계획에 진짜 도움 되는 추정" — 이 간극을 어떻게 메울 것인가?

2-1. 기존 연구의 현황 — Exqutor 의 두 보완책

arXiv:2512.09695v2 (2024) · 4/3 교수님 미팅에서 본 논문 채택

ECQO

HNSW 인덱스가 있을 때

HNSW range query 를 직접 실행해 1~2ms 로 정확 카디널리티 산출

1~2 ms

정확 카디널리티

Adaptive Sampling

인덱스가 없을 때

모멘텀 기반 동적 샘플링 — sample size 를 점진 확장하며 분산 수렴 판정

1000×

pgvector 대비 최대

→ pgvector 1000×, VBASE 10000×, DuckDB 1.5~37× 성능 향상 (논문 보고)

2- II . Adaptive Sampling 의 한계 — 사각지대

본 팀 4/14 소스 검증으로 첫 정량 확인

#1

Hook Trigger 사각지대

vector.c L243 · if (table_count > 2)

단일 테이블 vector range query 가 hook 경로에서 배제 → 모든 query 가 PG default selectivity 1/3 로 fall-through

#2

Plan Replacement 부작용

hook 우회 시 outer query plan-tree → Sample Scan

true=100,000 query 의 SELECT count(*) 가 sample 안 부분 카운트 32 로 격하

#3

Skew 지표 8 종 전수 negative

Phase 1·5 — 글로벌 4 + 로컬 4 = 8 지표

Fisher γ , k-NN entropy, PCA EVR1 등 모든 지표 vs Q-error · Spearman $|\rho| < 0.2$ (4 지표 × 6 selectivity = 24 조합)

vector.c — Hook Trigger 사각지대 (line 243)

```
vector.c (Exqutor adaptive sampling hook)
Pivot A — Hook trigger (line 243)
- if (table_count > 2)
+ if (table_count >= 1)
  # 2-way join 부터 hook 활성화 → 단일 테이블 query 에도 주입

Pivot B — Sampling method (line 889)
- TABLESAMPLE SYSTEM(%f)
+ TABLESAMPLE BERNOULLI(%f)
  # 블록 단위 SYSTEM → 행 단위 BERNOULLI 로 교체 (skew 내성 +)

Pivot C — Stratified sampling branch
- (no stratification logic)
+ +228 lines: KM20 strata read -> per-stratum BERNOULLI -> HT aggregate
  # skew 을 명시적으로 활용하는 층화 추정 경로 추가 (합산/분산 추정 포함)
```

3 surgical edits — SYSTEM 의 block skew bias 제거 + 층화 경로 활성화

vector.c L243 — table_count > 2 hook trigger 사각지대

★ 단일 테이블 vector range query (이미지 검색·추천·RAG) 는 Exqutor 가 ****명시적으로 배제한**** 사각지대

3. 차별성 및 제안 연구의 중요성

Skew-Aware Sampling — 분포 정보를 사용한 두 단계 보강

Pivot A

Block-bias 제거

vector.c L889 의 TABLESAMPLE SYSTEM(%f) → BERNOULLI(%f) 한 줄 교체

fair baseline 도구

+9.6%

s=0.500, p<0.001

Pivot C

Data-side k-means K=20

vector.c +228 줄 native 구현 — stratum_id 사전 부여 + Horvitz-Thompson 가중 추정

공간 인식 sampling

+1.64%


DEEP 1M, 5-seed CI [+1.11, +2.18]

◆ 두 Pivot 은 직교적 — SYSTEM × BERNOULLI × STRATIFIED 의 ablation matrix 로 각 기여 분리

본 연구의 핵심 기여

- RQ1: 8 지표 negative 로 query-side feature 의 사전 layer 정의 불가능성을 정량 증명
- RQ2: KM20 stratified 가 BERNOULLI 위에서 추가 개선 — 5-seed CI 하한 양수
- RQ3 설계: 분포 미지 시 KM20 의 "공간 인식 효과" 를 Recovery Rate 프레임워크로 측정

Figure 9 · Two-Level Decomposition — KM20 개선을 비례 배분(L1)과 공간 인식(L2)으로 분해



주: Level 1은 RANDOM20의 개선분(비례)에 해당 (무작위). Level 2는 KM20-RANDOM20 차이(공간 인식 기여). selectivity가 클수록 Level 2의 기여가 감소하며, DEEP 1M s=0.01에서 Level 2 단독 +19.60%p, SIFT는 s=0.50부터 이미 Level 2(+2.06%)가 유의 — 실험이 클수록 공간 인식의 영향이 넓은 구간에 발견.

Two-Level Decomposition — Level 1 (비례) + Level 2 (공간 인식) 분해

4- I . RQ1 — Skew 지표는 Q-error 를 예측하지 못한다

Phase 1 (글로벌) + Phase 5 (로컬) = 8 지표 전수 검증, 총 3000 측정


실험 셋업

데이터셋	DEEP 1M subset · 96d
쿼리	100 query × 6 selectivity × 5 seed = 3000
지표 (글로벌)	Fisher γ , log-Fisher γ , P99/P50 tail ratio, Bowley skew
지표 (로컬)	k-NN entropy, PCA EVR1, KDE modality, NN clustering

주요 발견 (Phase 1 + Phase 5)

- ① 12 조합 모두 Q-error ratio ≈ 1.0 (skewed/non-skewed 그룹 차이 없음)
- ② 글로벌 24 + 로컬 24 = 48 조합 모두 Spearman $|\rho| < 0.2$ (Cohen 1988 small-effect 미달)
- ③ 100 query 전부 Fisher $\gamma < 0$ (left-skewed) — 고차원 거리 집중 현상

Phase 5 Local Skew × Selectivity Spearman ρ




Phase 5 — 로컬 4 지표 × 6 selectivity = 24 조합 모두 $|\rho| < 0.2$

→ 고차원 벡터에서 query-side feature 로 layer 를 사전 정의하는 것은 불가능 — 본 연구의 Motivation 첫 줄

4- II . RQ2 (1) — BERNOLLI 가 SYSTEM 의 block-bias 를 제거

100 query × 6 selectivity × 1 seed × 2 mode = 1200 측정 · paired Wilcoxon

selectivity	SYS median	BERN median	diff%	p-value	유의
0.001	2.597	2.597	+0.0	0.596	—
0.010	1.558	1.299	+20.0	0.240	—
0.050	1.203	1.195	+0.7	0.0009	★★
0.100	1.212	1.132	+7.0	<0.001	★★★
0.300	1.210	1.079	+12.0	<0.001	★★★
0.500	1.153	1.052	+9.6	<0.001	★★★



Takeaways

- ① 4 selectivity 구간 (s=0.05~0.5) 에서 $p < 0.001$ — block sampling bias 는 통계적으로 유의한 구조적 약점
- ② vector.c 한 줄 교체로 Exquor 카디널리티 추정 개선 경로 확보
- ③ 단, 이는 Pivot C 의 fair baseline 도구이지 단독 기여가 아님


Phase 4 — SYS vs BERN paired Q-error 4 panel (s=0.05/0.10/0.30/0.50)

4-III. RQ2 (2) — KM20 Stratified 가 BERNOULLI 위에서 추가 개선

5-seed 신뢰구간으로 외적 타당성 확보 · vector.c +228 줄 native 구현

selectivity	5-seed 평균	95% CI	유의 seed
50%	+1.64%	[+1.11, +2.18]	5/5
30%	+2.62%	[+1.45, +3.80]	5/5 ($p < 0.001$)
10%	+4.19%	[+0.72, +7.66]	5/5 ($p < 0.004$)
5%	+1.85%	1-seed (W5 보충)	3/5
1%	+8.93%	1-seed (W5 보충)	4/5

BERNOULLI vs STRATIFIED (KM20)



Phase 6 Step 4 — BERNOLLI vs STRATIFIED (KM20) 100 query boxplot


- ① 50% / 30% / 10% 세 구간 모두 95% CI 가 0 을 포함하지 않음 — real effect 통계적 확정
- ② $s=0.500$ 1-seed $p=4.01e-05$ (Bonferroni 통과) → 5-seed 재현으로 우연 가능성 배제
- ③ BERNOLLI 위에서 추가 개선 — 누적 vs SYSTEM 은 +12.5% ($s=0.500$)

vector.c +228 줄 native · GUC 3 개 · stratum_id 사전 부여 · Horvitz-Thompson 가중 추정

4-IV. External Validity — 3 데이터셋 교차 검증

DEEP 1M · DEEP 8M · SIFT 1.5M — D_target 데이터셋별 재계산

Figure 8 · 외적 타당성 — 3 데이터셋에서 KM20 $s=0.500$ 효과 (95% CI)



주: DEEP 1M/8M의 CI는 겹침(외적 재현 CONSISTENT). SIFT의 CI는 DEEP과 겹치지 않아 통계적으로 구별. 쓸림도(CV)가 큰 데이터일수록 공간 인식 샘플링의 이점이 더 크게 발현됨.

외적 타당성 — DEEP 1M / 8M / SIFT 1.5M, KM20 $s=0.500$ 효과 95% CI

주요 발견 + 시사점

- ① DEEP 1M vs 8M : CI 겹침 (CONSISTENT) — 8 배 규모에서 동일 효과 재현
- ② SIFT 1.5M : CI 가 DEEP 과 겹치지 않음 (~2 배 효과) — 통계적 구별
- ③ 쓸림도 (CV) DEEP 0.234 vs SIFT 0.394 (68% 높음) — 쓸림 ↑ ⇒ 공간 인식 가치 ↑

DEEP 1M (96d)

CI [+1.11, +2.18] · CV 0.234

+1.64%

DEEP 8M (96d)

CI [+0.65, +2.86] · CV 0.234

+1.76%

SIFT 1.5M (128d)

CI [+2.66, +3.48] · CV 0.394

+3.07%


4-V. 결과 해석 — 데이터 쏠림과 공간 인식 효과

Two-Level Decomposition + 클러스터 쏠림도 (HHI / CV) 정량

▣ KM20 개선 = Level 1 (비례 배분) + Level 2 (공간 인식)

selectivity	KM20	RANDOM20	격차 (Level 2)	지배 요인
s = 50%	+1.64%	+2.20%	~0	비례만
s = 30%	+2.62%	+0.26%	+2.4%p	Level 2
s = 10%	+4.19%	+1.74%	+2.5%p	Level 2
s = 5%	+1.85%	+0.79%	+1.1%p	Level 2
s = 1%	+8.93%	-10.67%	+19.6%p	★ 공간 인식 단독

▣ 데이터셋 쏠림도 — DEEP CV 0.234 vs SIFT CV 0.394 (68% 높음)



주: HHI는 각 클러스터 비율의 제곱합(균일=1/K=0.05), CV는 표준편차/평균(균일=0). SIFT는 최대 클러스터 14.8만으로 기대값 7.5만의 2배, 클러스터 1과 18 합계가 전체의 약 19% (기대 10%). 쏠림의 정량 차이가 Figure 8의 KM20 효과 2배 격차의 직접적 원인.

클러스터 쏠림도 — DEEP CV 0.234 vs SIFT CV 0.394 (HHI 정량)

- SIFT 최대 클러스터 14.8 만 (기대값 7.5 만의 2 배)
- 상위 2 클러스터가 전체 19% 점유
- KM20 효과 SIFT +3.07% (DEEP +1.64% 의 약 2 배)

★ 쏠림 ↑ ⇒ Level 2 (공간 인식) 단독 효과 ↑ — 본 가설 단조 관계 재확인

4-V. RQ3 (설계) — 분포를 모를 때의 Recovery Rate 프레임워크

3 패러다임 × 7 방법 — W5~W7 실험 예정

$$\text{Recovery Rate} = (\text{방법X} - \text{RANDOM20}) / (\text{KM20} - \text{RANDOM20})$$

P1 Offline Partition (4 방법)

- 1. LSH Random Hyperplane
- 2. Random Projection (JL)
- 3. Hilbert Curve
- 4. Mini-batch K-means

1회 사전 처리 — KM20 와 비용 동등

P2 Online Query-Adaptive (2 방법)

- 5. Distance-Shell
- 6. KDE-pilot (Neyman)

Query 도착 시점 학습 — D_target 의존성 제거

P3 Weight-based (1 방법)

- 7. Importance Sampling

Sample 후 재가중 — partition 자체 불필요

평가 조건

→ DEEP 1M · 8M · SIFT 1.5M 3 데이터셋 × 5 seed × 5 selectivity 동일 조건

★ 최소 1 방법이 $RR \geq 0.5$ → 분포 미지 시에도 KM20 의 절반 효과 회수

5-1. 현재 진행 상황 (W1~W4)

W1 ✓	W2 ✓	W3 ✓	W4 ▶
3/2~4/4 Scope · 환경 세팅 · 주제 확정 (3/3) · Exqutor 채택 (4/3) · 서버 수령 + Docker (4/14) · 코드·데이터 수령 (4/7~)	4/11~4/15 RQ1 Motivation · Phase 1 가설 H1 기각 (4/14) · Phase 5 로컬 4 지표 negative (4/15) · Design Constraint 발견 (4/14)	4/15~4/16 RQ2 Aware · Phase 4 Pivot A native (4/14~15) · Phase 6 Step 4 KM20 1-seed (4/15) · 5-seed CI · DEEP 1M/8M/SIFT (4/16)	4/17~4/28 보강 + 발표 · Two-Level 분해 +19.6%p (4/16) · HHI/CV 정량 (4/17) · RQ3 7-way 설계 (4/16) · 중간보고서 + 발표 (4/28)

✓ RQ1 + RQ2 본선 + 5-seed 외적 타당성 + RQ3 설계 — 학기 중간 시점 완료

5- II . 향후 계획 (W5~W10)

W5	4/29~5/6	RQ3-A Offline Partition	Random K=20, Subspace decile, LSH 3 방법 — DEEP 1M 1-seed
W6	5/7~5/13	RQ3-A 5-seed	선별된 1~2 방법 5-seed × 3 데이터셋 — Recovery Rate 산출
W7	5/14~5/20	RQ3-B + Layer K sweep	Online + Weight 패러다임 + K=10/20/30/50 sweep
W8	5/21~5/27	심화 + 최종발표 준비	per-stratum BERN 최적화, sample_size sensitivity
W9	5/28~6/4	최종발표 + 전시회	5/27~29 발표, 6/5 전시회
W10	6/5~6/11	최종보고서 작성	RQ1 + RQ2 + RQ3 통합 + 실험 재현 가이드

산출물

최종발표 PDF (5/27~29) · 전시회 포스터 (6/5) · 최종보고서 PDF (6/11)

결론 — 본 발표의 4 핵심 발견

RQ1 negative · RQ2 외적 타당성 · Two-Level 분해 · RQ3 설계

RQ1

Skew 지표는 Q-error 를 예측하지 못한다

48 / 48

조합 모두 $|p| < 0.2$

글로벌 4 + 로컬 4 = 48 조합 모두 negative — query-side feature 사전 layer 정의 불가능성을 정량 증명 (Cohen 1988)

RQ2

Skew-Aware Sampling 의 외적 타당성

+1.64 ~ +3.07%

DEEP 1M / 8M / SIFT 5-seed 95% CI

3 데이터셋 모두 BERN 위에서 추가 개선 — DEEP 1M vs 8M CI 겹침 (CONSISTENT) · SIFT 1.5M 약 2배 효과 (CV 0.394, 통계적 구별)

Two-Level

공간 인식 단독 효과 정량화

+19.6 %p

Level 2 단독 (DEEP 1M, $s=0.010$)

KM20 +8.93%, RANDOM20 -10.67% — 비례 배분 (Level 1) 과 공간 인식 (Level 2) 분해, 가설 단조 관계 재확인 (Horvitz-Thompson 1952)

RQ3

Recovery Rate 프레임워크 설계 완료

3 × 7

패러다임 × 방법 (W5~W7 실험)

Offline (LSH/RP/Hilbert/MiniBatch) + Online (Shell/KDE-pilot) + Weight (IS) — 분포 미지 시 KM20 의 절반 효과 회수 목표 (Neyman 1934)

★ skewed 거리 분포에서 카디널리티 추정 정확도 — 본 연구의 단계적 sanitize 가 측정 가능한 개선을 정량 확보

감사합니다

질문 부탁드립니다

속도는벡터

박세은 (팀장) · 강재현 · 조현빈 · 이동욱