

속도는벡터 → 임채림 연구원님 — 구체적 측정 데이터 정리

수신: 박세은 (팀장 경유) → 임채림 연구원 (BDAI 연구실) 발신: 속도는벡터 (조현빈 작성·3-multi-AI 검증 정본) 작성: 2026-05-24 22:47 KST 목적: BDAI 연구실 전달용 구체적 데이터 — 서버 스펙·측정 환경·Exqutor 베이스라인 측정값·우리 method 중 최저 q-error·해당 method 의 latency·query plan 정보 정리 검증: Claude (자체 정본 raw 직접 분석) + Codex xhigh (적대 재검증, 신뢰도 82/100) + Gemini 3.1 Pro (문헌·통계 정합성, 신뢰도 91.5/100) = **3-multi-AI conditional pass**

1. 서버·하드웨어·소프트웨어 스펙

1.1 서버 환경 (BDAI 연구실)

항목	값
호스트	165.132.140.240 (계정 <code>capstone2026</code>)
작업 디렉토리	<code>/mnt/hdd0/home/capstone2026/</code>
CPU	Intel Xeon Gold 6530 · 128 vCPUs
RAM	1.0 TB
GPU	4× NVIDIA RTX 6000 Ada 49 GB (CPU 측정만 사용, GPU 미활용)
Disk	<code>/mnt/hdd0</code> 13 TB (89% used, 1.4 TB 여유)
PostgreSQL 포트	55435 (Exqutor-patched pgvector, <code>vanilla_sf100</code> data dir)
DB / user / pass	<code>wns41559</code> / <code>wns41559</code> / <code>wns41559</code>
OS·환경	Linux + tmux 다중 세션 + ssh ed25519

1.2 Exqutor patched pgvector — 카디널리티 주입 GUC

GUC	역할	값 (본 측정 carry)
<code>vector.injected_card</code>	벡터 숨어 카디널리티 강제 주입 (≥0 시 샘플링 우회)	mode 별 다름
<code>vector.disable_estimation</code>	<code>on</code> 시 추정 자체 끄고 default selectivity 사용	baseline 만 on
<code>vector.update_sample_size</code>	표본 크기 동적 갱신	전 조건 off 고정

세션 setup: `LOAD 'auto_explain'` → `LOAD 'vector'` 순서 고정 (역순 시 pass-2 플랜 로깅 X). `work_mem = 256MB` , `max_parallel_workers_per_gather = 2` , `plan_cache_mode = force_custom_plan` .

1.3 측정 하네스 (Python + psycopg)

- 위치: `_internal/scripts/measure_latency_realengine.py`
- 한 cell = 쿼리 × 데이터셋 × sf × selectivity × qid 하나 · 16 variant × 15 rep
- 매 rep 마다 16 variant 고정 시드 셔플 round-robin (인접 시점 측정 → paired 검정 정합)
- 실제 실행 + 결과 fetch 까지 perf_counter (2-pass overhead 포함 정직한 end-to-end)
- statement_timeout = 180s (도달 시 None 검열 기록)

2. 측정 환경 정리

2.1 데이터셋

데이터셋	차원	서버 테이블 약칭	비고
DEEP	96	partsupp_deep_{1,10,100}	정본
SIFT	128	partsupp_sift_{1,10,100}	정본
SSN (SimSearchNet++)	256	partsupp_fb_{1,10,100} ⚠	논문·문서 = SSN, 서버 테이블 = fb (Facebook AI 출처 alias)
WIKI	768	partsupp_wiki_{1,10}	고차원 (engine sf=10 timeout)
YFCC	192	partsupp_yfcc_{1,10}	정본

2.2 측정 평면 (1,508 cell × 3-way matched, 정본)

변인	값
Scale Factor	sf = 1·10·100 (분포: 416·580·512 = 1,508)
데이터셋	5 단일 + 4 multi/concat = 9 종
Selectivity	sel = 0.001·0.01·0.1 (분포: 448·628·432 = 1,508)
계층 수 K	K = 10·20·30 (분포: 192·1124·192 = 1,508, K=20 중심 74.5%)
Method	16 종 (7 paradigm 일곱 계열 대표)
측정 mode	3-way matched (B1·CaseA·CaseB) = 4,524 row
Trials per cell	10 회 · 1,000 queries per trial
Type 분포	Type 1 (272)·Type 2 (224)·Type 3 (464)·Type 4a (368)·Type 4b (180) = 1,508

2.3 Adaptive Sampling Hyperparam (paper §V-B verbatim, 모든 mode 동일 carry)

변수	값	출처
N (표본 예산)	385	식 1: $\lceil z^2 \cdot P(1-P)/e^2 \rceil = \lceil 1.96^2 \cdot 0.25/0.05^2 \rceil = 385$
m (momentum coefficient)	0.9	식 4
η_0 (initial learning rate)	0.1	식 4
α (target Q-error weight)	50	식 3
β (target Q-error)	1.5	식 3
γ (learning rate decay)	0.99	식 6
update_period	50 queries	—

2.4 TPC-H VAQ 쿼리·threshold

- 쿼리: TPC-H Q3·Q9·Q10·Q12 (벡터 술어가 SeqScan 분기에서 평가)
- 벡터 range threshold: `<-> 'image_embedding' < 0.86` (DEEP 96d 기준, 8 queries 동일)
- TPC-DS Q7/Q12/Q20/Q72: `< 1.08` · Q19/Q42: `< 1.20` · Q98: `< 1.30`

3. Exquitor 베이스라인 측정값 (B1 정보)

3.1 Offline Q-error (1,508 cell × 16 method)

항목	B1 정보
qe_trim mean (1,508 cell)	1.4582
qe_trim median	1.5616
qe_trim std	0.1925
qe_trim min / max	1.1539 / 1.6560
paired vs B1 정의	측정별 (cell × method × sel × K) trial 10 평균

3.2 Engine Latency 베이스라인 (DEEP sf=10 sel=0.001, 12 cell × 15 rep)

항목	값	단위
baseline (pgvector 기본, disable_estimation=on)	5,677.7	ms (median 평균)
B1 inject (Adaptive Sampling 무작위 베르누이)	977.6	ms (median 평균)
oracle (정답 카디널리티 inject)	992.3	ms (median 평균)
B1 inject vs baseline gain (12 cell mean)	5.77×	mean (median 기준)
oracle vs baseline gain (12 cell mean)	5.65×	mean (median 기준)
보고서 §5.2 verbatim 12 cell oracle gain 평균 (trim mean)	5.67×	range 2.93×~7.40×

3.3 Engine Plan 회복 (12 cell × 15 rep, plan_signature = Node Type pre-order 튜플)

항목	값
B1 정답 plan 회복 (cell 단위)	7/12 = 58.3%
qid 별 회복: qid 0 / qid 1 / qid 2	0/4 / 4/4 / 3/4
회복 실패 cell	모두 sel=0.001 영역의 결정 경계 cell

3.4 paired Wilcoxon 통계 검증 (anchor=baseline, 180 비교)

지표	B1 vs baseline
p_holm < 0.05	180/180 = 100%
Hedges' g g ≥ 0.8 (large)	180/180 = 100%
Cliff's δ large	180/180 = 100%
bootstrap 95% CI ≠ 0	180/180 = 100%

→ 카디널리티 주입 가속은 통계적 유의·실질 효과 모두 압도적.

4. 우리 method 중 최저 Q-error (paired $\Delta\%$ vs B1 기준)

4.1 method 별 정보 ranking (1,508 cell $\times$ method 평균)

method	paradigm	n	better%	mean $\Delta\%$	median $\Delta\%$	비고
hilbert_real	P2 Spatial	95	98.9%	-6.54%	-5.91%	★ 최저 (단, audit caveat ↓)
skilling_hilbert	P2	94	100.0%	-6.34%	-5.75%	true high-D Hilbert curve
chao_weighted	P3	95	100.0%	-6.30%	-6.22%	Pareto frontier 1순위
ica_fastica	P4	94	100.0%	-6.13%	-5.69%	
pcaId	P4	94	97.9%	-6.05%	-5.55%	textbook anchor
zorder_morton	P2	94	98.9%	-5.87%	-4.89%	Z-order paradigm anchor
hyperloglog	P9	95	100.0%	-5.75%	-4.58%	InfoTheoretic 신규 paradigm

⚠ method audit caveat (보고서 §4.7 carry): - **hilbert_real** = PCA 2D lex sort alias (Faloutsos 1989 Hilbert curve indexing 이 아님). 결과 수치는 유효, reference 정직성 carry — rename **pca2d_lex** 권고 가능. - **sparse_rp** = Li-Hastie-Church 2006 정보 출처 (Achlioptas 2003 표명 → 정정 carry).

4.2 최저 Q-error method 의 절대값

hilbert_real (P2): - B1 평균 qe_trim 1.4582 → CaseB(hilbert_real) 평균 qe_trim 약 **1.4063** (가설값, paired $\Delta\%$ mean -6.54% 기준) - median 기준 약 1.4711 (paired $\Delta\%$ median -5.91%)

4.3 Pareto frontier (정확도 $\times$ fit_time)

method	mean $\Delta\%$	fit_time mean (s)	권장 use case
chao_weighted	-6.30%	11.03 s	정확도 1순위 (균형)
hilbert_real	-6.54%	40.66 s	정확도 최저 (시간 무관 시)
sparse_rp	-3.69%	2.91 s	분포 파악 속도 결정적 제약 시

5. 최저 Q-error method 의 Latency-Plan 정보

5.1 paired Wilcoxon (anchor=B1, 168 비교 = 12 cell $\times$ 14 variant)

지표	값
p_holm<0.05 (유의)	13/168 = 7.7%
Hedges' g small ($ g < 0.5$)	146/168 = 86.9%
Hedges' g large ($ g \geq 0.8$)	14/168 = 8.3%
Cliff's δ large	29/168 = 17.3%
bootstrap 95% CI $\neq 0$	44/168 = 26.2%

→ B1-CaseB-oracle 의 latency 사실상 동등 (87% small effect, 7.7%만 유의).

5.2 plan 회복 매트릭스 (3 평면 통합 700 paired)

항목	값
plan_recovered=True (same plan as oracle)	649/700 = 92.7%
plan_recovered=False (different plan)	51/700 = 7.3%

→ B1-CaseB 가 거의 같은 plan 으로 가며, 다른 plan 7.3% 영역에서도 latency 동등.

5.3 결합 13 method plan 회복 (12 cell × 13 method = 156)

항목	값
결합 13 method 정답 plan 회복	148/156 = 94.9%
실패 8건	모두 Q3 (qid 0 hilbert_real·qid 1 sparse_rp·qid 2 6 method split)
qid 별 결합 평균 회복	qid 0: 12.8/13 · qid 1: 12.8/13 · qid 2: 11.5/13

5.4 Variance Decomposition (latency 동등성 정량 확정)

factor	df	% SS (Type-I 순차)	p (Type-III partial)
sel	2	49.1%	0
qid	2	28.0%	1.80e-65
query	3	5.5%	3.45e-96
condition (B1·CaseB·oracle)	2	0.000773%	p = 0.945 ← 추정 inject 동등 확정
residual	2230	17.3%	—

(legacy 평면 20 cell n=4,500: condition p = **0.866**, 같은 결론)

★ 결과 한 줄: Q-error 89% 우위가 plan 결정·latency 차이로 직결되지 않음 — 추정 정확도 ↑ ≠ engine latency ↑ 구조적 한계 드러남.

6. ★ 사전 등록 통제 측정 (CaseC dual-Bernoulli ensemble) — 별도 박스

3-multi-AI 검증 (Codex+Gemini) 공동 권고: "분포 인지 효과" 인과 주장 낮춤. 89% 우위의 진짜 메커니즘 = 두 독립 추정량 평균의 앙상블 분산 감소 효과임이 통제 측정으로 입증됨.

6.1 v14 사전 등록 통제군 (9 cell × sel=0.01·K=20)

항목	값
CaseC dual-Bernoulli mean qe_trim	1.3729 (range [1.3452, 1.3948], std 0.019)
동일 9 cell B1 평균	1.5838 (16 method 평균)
동일 9 cell CaseB 평균	1.4723 (16 method 평균)
CaseC < B1 cell	9/9 = 100%
CaseC < CaseB cell	9/9 = 100%
Δ% vs B1	-13.32%
Δ% vs CaseB	-6.75%

6.2 v16 95 tuple 전수 측정 (BLOCKER E rng fix 후)

항목	값
CaseC mean qe_trim (95 tuple)	1.3060
qe_trim_B1 (paired subset)	1.4595
qe_trim_CaseB	1.4022
CaseC vs B1 paired	95/95 = 100% better, median Δ% -11.32%
CaseC vs CaseB paired	95/95 = 100% better, median Δ% -5.98%
측정 시점	2026-05-24 12:24 KST

6.3 메커니즘 해석 (3-multi-AI 검증 공동 결론)

본 결합 우위의 메커니즘은 다음 두 효과의 합으로 분해된다: - (a) 두 독립 베르누이 추정량 평균에 따른 분산 감소 (일반 앙상블 효과, B1 단일 표본 대비 표본 용량 2배) - (b) 같은 앙상블 조건 하 method (분포 인지) 의 유효성 검정

CaseC vs CaseB 비교 (동일 앙상블 조건 하)에서 CaseC < CaseB 95/95 = (b) 분포 인지가 양의 효과를 더하지 못함 (오히려 미세 음의 잡음). 본 연구의 핵심 negative + methodological 결과.

★ 89% 우위를 "분포 인지 효과" 로 단순 귀속해선 안 됨.

7. 측정 한계 (honest limitation)

7.1 측정 평면 한계

- A2-Fig8 (DEEP+CC3M sf=10, 1024d): 16 method 중 4 method 만 측정 (희소 cell, 보고서 §4.7 단독 finding 인용 X)
- A4-sel: 16 measurement 희소 cell carry
- WIKI sf=10 engine 측정: 768d SeqScan `statement_timeout=180s` 도달, 측정 불가 (honest exception)
- sf=1 engine 측정: 작은 테이블 IndexScan 경로 선택 → 카디널리티 주입 미발동 (plan-invariant)
- sf=100 engine 측정: phase4_extension carry 미진행, Future Work
- 타 엔진 (VBASE·DuckDB-vss·Milvus): 미측정, Future Work

7.2 측정 portfolio 한계

- $1,508 / 3,600 = 41.9\%$ (의도 max 대비 41.9% 측정) — 구조화된 portfolio (보고서 §3.6), full factorial 아님
- K=20 중심 (74.5%), K=10·30 각 12.7% — K scaling 일반화 한계
- 5 단일 dataset + 4 multi/concat — 데이터셋 모집단 일반화 한계

7.3 통계·코드 carry item (6/11 재측정 전 fix 권고)

- `measure_paper_exact.py:1328` query-selectivity miss fallback 잔존 — `raise` 또는 `missing_qsel_count` 기록 추가 권고 (현재 95/95 OK 는 실행 성공 검증이지 miss 부재 증명은 아님)
- `gen_latency_estimates.py` concat dataset table prefix mismatch (`partsupp_{combo}_{sf}` vs 실제 `partsupp_{combo}_concat_{sf}`)
- `measure_offline_casac_portfolio` DEFAULT_PORTFOLIO 18 vs KNOWN_CELLS 25

7.4 ICDE 측정 환경 정합성

- Exqutor 논문 verbatim: "Intel Xeon Gold 6530 with 128 vCPUs and 1.0 TB of RAM" — 본 연구 환경 동일 ✓

8. 산출물 위치 (raw data 직접 확인 가능)

산출물	경로
v13 정보 raw (1,508 cell × 3 mode)	<code>_internal/cache/rq3/aggregated_v13_full.parquet</code> (4,524 row, 1 MB)
v13 paired delta (3 comparison × 1,508)	<code>_internal/cache/rq3/paired_delta_v13.parquet</code> (213 KB)
v14 사전 등록 통제군 raw (9 cell × CaseC)	<code>_internal/cache/rq3/aggregated_v14.parquet</code> (26 KB)
v16 95 tuple 전수 raw	<code>_internal/cache/rq3/paper_exact_v16_summary_20260524_122419/v16_full95_paired.parquet</code> (52 KB)
Engine latency phase2 (DEEP sf=10 sel=0.001, 12 cell)	<code>_internal/cache/rq3/latency/phase2/</code>
Engine latency phase3 (DEEP sf=10 sel=0.01~0.1, 8 cell carry-over)	<code>_internal/cache/rq3/latency/phase3/</code>
Engine latency phase4_extension (SIFT·SSN·YFCC sf=10, 36 cell)	<code>_internal/cache/rq3/latency/phase4_extension/</code>
paired statistics (cell × variant × g/δ/p)	<code>_internal/cache/rq3/latency/{phase2,phase3,phase4_extension}/figures/paired_stats.csv</code>
variance decomposition (poc_6_4-extended)	<code>_internal/cache/rq3/latency/poc_6_4{,_extended}/variance_decomp_*.csv</code>
plan_level_effect_size	<code>_internal/cache/rq3/latency/poc_6_4_extended/plan_level_effect_size.csv</code>
서버 측정 raw 전체 백업 (NPY 제외)	<code>experiments/server_backup_20260524_223129/</code> (474 MB · 2,507 파일)
보고서 6/11 정보 (정정 후)	<code>submission/_drafts/속도논벡터_6_11_최종보고서_20260523_215000.{md,pdf}</code>
본 자료 PDF	<code>submission/_drafts/속도논벡터_채림님_전달용_구체적_데이터_20260524_224713.pdf</code>
3-multi-AI 검증 결과	<code>/tmp/codex_verification_20260524_224713.txt</code> · <code>/tmp/gemini_verification_20260524_224713.txt</code>

9. 검증 추적 (3-multi-AI 신뢰도)

axis	모델	신뢰도	판정
Claude (자체 정보 raw 직접 분석)	Opus 4.7	—	pass
Codex (xhigh effort 적대 검증)	GPT-5.5	82/100	conditional pass
Gemini (문헌·통계 정합성)	3.1 Pro	91.5/100	conditional pass
3-axis 종합	—	~87/100	conditional pass

검증 정정 항목: 15 건 (수치 drift·표기 오류·narrative 정정) 모두 본 자료 반영 carry.

작성: 2026-05-24 22:47 KST. 속도논벡터 (조현빈). 박세은 팀장 검토 후 임채림 연구원께 전달.